

Федеральное государственное автономное
образовательное учреждение высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики

ЛЕКЦИИ И СЕМИНАРЫ ПО МЕТОДАМ ОПТИМИЗАЦИИ

Авторы:

А. Н. Безносиков, А. И. Богданов, Д. А. Былинкин, Ф. А. Хафизов, Г. Л. Молодцов,
Д. О. Медяков, А. С. Веприков, С. А. Чежегов, Н. М. Корнилов, И. А. Курузов,
Д. С. Метелев, А. А. Моложавенко

МОСКВА
ФПМИ МФТИ
2025

Учебное пособие содержит конспект лекций и материалы семинарских занятий по курсу «Методы оптимизации». В таком виде курс был прочитан осенью 2025–2026 учебного года студентам 3-го курса физтех-школы прикладной математики и информатики МФТИ. Важно отметить, что материалы курса опираются на различные курсы методов оптимизации, прочитанные в России и за рубежом. А именно, авторы данного пособия хотели бы поблагодарить А. Бен-Тала, А. Г. Бирюкова, А. В. Гасникова, В. Г. Жадана, А. М. Катруцу, Д. А. Кропотова, А. С. Немировского, Ю. Е. Нестерова, Б. Т. Поляка, Ф. С. Стонякина, М. Такача, Р. Хильдебранда, М. Шмидта, М. Ягги за неоценимый вклад в преподавание и популяризацию численных методов оптимизации во всем мире.

**РАБОТА НАД ПОСОБИЕМ ВЕДЕТСЯ В ДАННЫЙ
МОМЕНТ! АВТОРЫ ПРИЗНАТЕЛЬНЫ ЗА ЛЮБЫЕ
КОММЕНТАРИИ ПО ЕГО УЛУЧШЕНИЮ!**

Содержание

Обозначения и классические факты	5
C1 Пререквизиты из линейной алгебры	7
C1.1 Векторные нормы	7
C1.2 Матричные нормы	9
C1.3 Сопряжённые нормы	17
C1.4 Квадратичные формы	18
C2 Матрично-векторное дифференцирование	21
C2.1 Первый дифференциал	21
C2.2 Второй дифференциал	24
C2.3 Примеры и задачи	24
C2.4 Автоматическое дифференцирование	37
C3 Классы множеств	43
C3.1 Выпуклые множества	43
C3.2 Размерность множеств	47
C3.3 Выпуклая оболочка	48
C3.4 Операции, сохраняющие выпуклость	53
C3.5 Теоремы об отделимости	55
C4 Выпуклые функции	59
C4.1 Основные понятия	59
C4.2 Выпуклые функции	60
C4.3 Операции, сохраняющие выпуклость	71
C4.4 Сильно выпуклые функции	74
C5 Субдифференциал	78
C5.1 Свойства субдифференциала	81
C5.2 Субдифференциальное исчисление	85
C6 Сопряжённые функции Фенхеля	90
C6.1 Определение сопряжённой функции Фенхеля	90
C6.2 Вычисление сопряжённой функции в одномерном случае	91
C6.3 Вычисление сопряжённой функции в многомерном случае	95
C6.4 Анализ на сопряжённых функциях	99
C6.5 Связь с субдифференциалом	101
C7 Двойственность по Лагранжу	105
C7.1 Лагранжиан	105
C7.2 Двойственная функция по Лагранжу	106
C7.3 Двойственная задача	107
C7.4 Примеры	108
C7.5 Связь сопряжения Фенхеля и Лагранжа	112
C7.6 Ввод искусственных ограничений	114
C8 Условия оптимальности Каруша–Куна–Таккера	117
C8.1 Условия Каруша–Куна–Таккера	117
C8.2 Примеры	119
C8.3 Решение прямой задачи через двойственную	128
C8.4 Условия ККТ для локальных экстремумов невыпуклых задач	130
C9 Классические виды оптимизационных задач	133
C9.1 Линейное программирование	133
C9.2 Квадратичное программирование с квадратичными ограничениями	136
C9.3 Коническое программирование второго порядка	138
C9.4 Полуопределенное программирование	143
C10 Задача программирования с коническими ограничениями	148
C10.1 Сопряжённые конусы	148
C10.2 Свойства сопряжённых конусов	153
C10.3 Обобщенные неравенства	157

	C10.4	Обобщенная монотонность	159
	C10.5	Обобщенная выпуклость	162
	C10.6	Задача конической оптимизации в общем виде	164
	C10.7	Материал, который не вошел в параграф	167
C11		Симплекс–метод	168
	C11.1	Идея симплекс–метода	169
	C11.2	Примеры	172
	C11.3	Двухфазный симплекс–метод	174
L1		Основные понятия	176
	L1.1	Примеры задач оптимизации	177
	L1.2	Общая схема методов оптимизации	181
	L1.3	Сложность методов. Верхние и нижние оценки	184
	L1.4	Скорость сходимости методов	189
L2		Условия оптимальности. Выпуклость и гладкость	192
	L2.1	Условия оптимальности	192
	L2.2	Выпуклость	193
	L2.3	Гладкость	196
L3		Градиентный спуск	201
	L3.1	Градиентный спуск для гладких сильно выпуклых задач	202
	L3.2	Градиентный спуск для гладких выпуклых задач	209
	L3.3	Градиентный спуск для гладких невыпуклых задач	213
	L3.4	Выбор шага градиентного спуска	215
L4		Ускоренные и оптимальные методы	224
	L4.1	Метод тяжёлого шарика	224
	L4.2	Ускоренный градиентный метод	229
	L4.3	Нижние оценки	236
	L4.4	Линейный каплинг	240
	L4.5	Catalyst	244
L5		Стохастический градиентный спуск	248
	L5.1	Стохастический градиентный спуск	249
	L5.2	Модификации стохастического градиентного спуска	254
	L5.3	Нижние оценки	257
L6		Метод сопряжённых градиентов	260
	L6.1	Сопряжённые направления	260
	L6.2	Метод сопряжённых градиентов	261
	L6.3	Нелинейные методы сопряжённых градиентов	272
L7		Метод Ньютона. Квазиньютоновские методы	275
	L7.1	Задача поиска нуля	275
	L7.2	Метод Ньютона	277
	L7.3	Метод Ньютона с кубической регуляризацией	281
	L7.4	Метод Ньютона с квадратичной регуляризацией	282
	L7.5	Квазиньютоновские методы	283
	L7.6	Trust-Region шаг	288
	L7.7	Метод Гаусса–Ньютона	290
	L7.8	Natural Gradient Descent	291
	L7.9	Аппроксимации матрицы Фишера	293
	L7.10	Вероятностная формулировка задачи	294
L8		Негладкая оптимизация. Адаптивные методы	295
	L8.1	Негладкие задачи	295
	L8.2	Субградиентный метод	297
	L8.3	Адаптивные методы	299
	L8.4	Проксимальный оператор	306
L9		Градиентный спуск с проекцией. Алгоритм Франк–Вульфа	313

Л9.1	Задача оптимизации с ограничениями	313
Л9.2	Градиентный спуск с проекцией	315
Л9.3	Метод Франк–Вульфа	324
Л10	Метод зеркального спуска	334
Л10.1	Дивергенция Брэгмана	334
Л10.2	Зеркальный спуск	338
Л11	Метод штрафов. ADMM	347
Л11.1	Штрафная функция	347
Л11.2	Свойства решений штрафной задачи	347
Л11.3	Двойственный подъем и аугментация	350
Л11.4	ADMM	351
Л12	Метод внутренней точки	359
Л12.1	Барьерные функции	359
Л12.2	Самосогласованные барьеры	361
Л12.3	Анализ метода	366
Л13	Седловые задачи	371
Л13.1	Седловая точка Лагранжиана	371
Л13.2	Метод градиентного спуска–подъёма	374
Л13.3	Экстраградиентный метод	375
Л13.4	Модификации экстраградиентного метода	380
Л13.5	Прямо–двойственный метод	383
Л14	Методы редукции дисперсии	387
Л14.1	SAGA	387
Л14.2	SVRG	391
Л14.3	SARAH	392
Л14.4	Loopless версии алгоритмов	393
Л14.5	Унифицированный анализ методов редукции дисперсии	394
Л15	Методы нулевого порядка и координатный спуск	402
Л15.1	Координатный спуск	402
Л15.2	Координатные идеи в безградиентной постановке	405
Л16	Метод эллипсоидов	414
Л16.1	Наивный подход	414
Л16.2	Приближение метода центров масс	414

Обозначения и классические факты

Числовые множества

$\mathbb{N}$	натуральные числа
$\mathbb{Z}$	целые числа
$\mathbb{R}$	вещественные числа
$\mathbb{R}_+$	неотрицательные вещественные числа
$\mathbb{R}_{++}$	положительные вещественные числа

Кванторы и логические символы

$\forall$	квантор всеобщности
$\exists$	квантор существования
$\exists!$	квантор существования и единственности

Векторные обозначения

$x \succ y$	покомпонентное сравнение векторов	$x_i > y_i$ для всех i
$\langle x, y \rangle$	скалярное произведение в $\mathbb{R}^d$	$\langle x, y \rangle = \sum_{i=1}^d x_i y_i$
$\ x\ _2$	евклидова норма	$\ x\ _2 = \sqrt{\langle x, x \rangle}$
$\ x\ _p$	p -норма для $1 \leq p < \infty$	$\ x\ _p = \left(\sum_{i=1}^d x_i ^p \right)^{\frac{1}{p}}$
$\ x\ _\infty$	∞ -норма	$\ x\ _\infty = \max_{i=1, d} x_i $
$\nabla f(x)$	градиент функции f в точке x	$(\nabla f(x))_i = \frac{\partial f}{\partial x_i}$
$\nabla^2 f(x)$	гессиан функции f в точке x	$(\nabla^2 f(x))_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$

Матричные обозначения и нормы

$\langle X, Y \rangle$	скалярное произведение матриц	$\langle X, Y \rangle = \text{Tr}(X^\top Y) = \sum_{i=1}^d \sum_{j=1}^n X_{ij} Y_{ij}$
$A \odot B$	поэлементное умножение матриц	$(A \odot B)_{ij} = A_{ij} \cdot B_{ij}$
$\ A\ $	индуцированная матричная норма	$\ A\ = \sup_{\ x\ =1} \ Ax\ $
$\ A\ _\infty$	бесконечная норма	$\ A\ _\infty = \max_{i=1, d} \sum_{j=1}^n a_{ij} $
$\ A\ _1$	первая норма	$\ A\ _1 = \max_{j=1, n} \sum_{i=1}^d a_{ij} $
$\ A\ _2$	вторая (евклидова) норма матрицы	$\ A\ _2 = \sqrt{\lambda_{\max}(A^\top A)}$
$\ A\ _F$	норма Фробениуса	$\ A\ _F = \sqrt{\sum_{i=1}^d \sum_{j=1}^n A_{ij}^2} = \sqrt{\text{Tr}(A^\top A)}$

симметричные матрицы и сравнения

$A \succ B$	$A - B$ положительно определена
$A \in \mathbb{S}^d$	$A = A^\top$ (симметричная матрица)
$A \in \mathbb{S}_+^d$	A симметрична и $A \succeq 0$
$A \in \mathbb{S}_{++}^d$	A симметрична и $A \succ 0$

Полезные неравенства

Неравенство Йенсена

$$f\left(\sum_{i=1}^n \alpha_i x_i\right) \leq \sum_{i=1}^n \alpha_i f(x_i), \quad (0.1)$$

где f — выпуклая, $\alpha_i \geq 0$, $\sum_{i=1}^n \alpha_i = 1$.

Неравенство Гёльдера

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_q, \quad (0.2)$$

где $1 \leq p, q \leq \infty$, $\frac{1}{p} + \frac{1}{q} = 1$.

Неравенство Коши–Буняковского–Шварца

$$|\langle x, y \rangle| \leq \|x\|_2 \|y\|_2. \quad (0.3)$$

Неравенства о средних

$$\frac{n}{\sum_{i=1}^n \frac{1}{x_i}} \leq \left(\prod_{i=1}^n x_i\right)^{\frac{1}{n}} \leq \frac{1}{n} \sum_{i=1}^n x_i \leq \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2},$$

для $x_i > 0$.

Неравенство между степенной функцией и экспонентой

$$(1 - \alpha)^k \leq \exp(-\alpha k), \quad \alpha \in [0, 1]. \quad (0.4)$$

Асимптотические обозначения

$f(n) \in \mathcal{O}(g(n))$	$\exists C > 0: f(n) \leq C \cdot g(n)$ при всех $n \in \mathbb{N}$
$f(n) \in \Omega(g(n))$	$\exists C > 0: f(n) \geq C \cdot g(n)$ при всех $n \in \mathbb{N}$
$f(n) \in \Theta(g(n))$	$\exists C_1, C_2 > 0: C_1 g(n) \leq f(n) \leq C_2 g(n)$ при всех $n \in \mathbb{N}$
$f(n) \in \tilde{\mathcal{O}}(g(n))$	$\exists$ полином $p: f(n) \in \mathcal{O}(g(n) \cdot p(\log n))$ при всех $n \in \mathbb{N}$

Обозначения для распределений

$U(\overline{1}, n)$	равномерное распределение на множестве $\overline{1}, n$
$\mathcal{N}(\mu, \sigma^2)$	нормальное распределение

C1 Пререквизиты из линейной алгебры

Линейная алгебра играет фундаментальную роль во многих областях математики. Её методы и концепции лежат в основе таких дисциплин, как численные методы, теория управления, анализ данных и, в том числе, теория оптимизации — предмет, которому посвящено пособие. В рамках этого параграфа обсуждаются пререквизиты из линейной алгебры, необходимые для успешного усвоения материала по оптимизации. В частности, обсуждаются векторные и матричные нормы, а также разложения матриц.

C1.1 Векторные нормы

Определение C1.1. Рассмотрим функцию $\|\cdot\| : \mathbb{R}^d \rightarrow \mathbb{R}$. Она называется *векторной нормой*, если удовлетворяет следующим условиям:

- $\|x\| \geq 0$, $\|x\| = 0 \iff x = 0$;
- $\|\lambda x\| = |\lambda| \|x\|$, $\lambda \in \mathbb{R}$;
- $\|x + y\| \leq \|x\| + \|y\|$.

Пример C1.1. Функция $\|\cdot\|_p : \mathbb{R}^d \rightarrow \mathbb{R}$, определённая как

$$\|x\|_p = \sqrt[p]{\sum_{i=1}^d |x_i|^p}, \quad p \geq 1,$$

является векторной нормой.

Доказательство. Первые два условия из Определения C1.1 не нуждаются в доказательстве. Покажем, что для произвольных $x, y \in \mathbb{R}^d$ выполнено третье условие. Рассмотрим $p \neq 1$, поскольку случай $p = 1$ тривиален. Нетрудно видеть, что

$$|x_i + y_i|^p \leq |x_i| |x_i + y_i|^{p-1} + |y_i| |x_i + y_i|^{p-1}.$$

Обозначив $q = \frac{p}{p-1}$, применим неравенство Гёльдера (0.2) к каждому из слагаемых. Получим

$$\begin{aligned} \|x + y\|_p^p &= \sum_{i=1}^d |x_i + y_i|^p \leq \sum_{i=1}^d |x_i| |x_i + y_i|^{p-1} + \sum_{i=1}^d |y_i| |x_i + y_i|^{p-1} \\ &\leq \left(\sum_{i=1}^d |x_i|^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^d |x_i + y_i|^{(p-1)q} \right)^{\frac{1}{q}} + \left(\sum_{i=1}^d |y_i|^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^d |x_i + y_i|^{(p-1)q} \right)^{\frac{1}{q}} \\ &= \left(\sum_{i=1}^d |x_i|^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^d |x_i + y_i|^p \right)^{\frac{1}{q}} + \left(\sum_{i=1}^d |y_i|^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^d |x_i + y_i|^p \right)^{\frac{1}{q}}. \end{aligned}$$

Сократив обе части на $(\sum_{i=1}^d |x_i + y_i|^p)^{\frac{1}{q}} = \|x + y\|_p^{p-1}$, учитывая, что $1 - \frac{1}{q} = \frac{1}{p}$, имеем

$$\|x + y\|_p \leq \|x\|_p + \|y\|_p.$$

■

Замечание С1.1. Нормы, введенные в Примере С1.1, будем называть *гёльдеровыми нормами* или просто *p-нормами*.

В анализе некоторых алгоритмов иногда возникает так называемая ∞ -норма.

Определение С1.2. Функцию $\|\cdot\|_\infty : \mathbb{R}^d \rightarrow \mathbb{R}$, определённую как

$$\|x\|_\infty = \max_{i=1,d} |x_i|,$$

будем называть ∞ -нормой.

Пример С1.2. ∞ -норма является предельным случаем гёльдеровых норм при $p \rightarrow \infty$.

Доказательство. Во-первых, известно, что $|x_j| \leq \max_{i=1,d} |x_i|$. Это означает, что

$$\|x\|_p \leq \left(d \max_{i=1,d} |x_i|^p \right)^{\frac{1}{p}} = d^{\frac{1}{p}} \max_{i=1,d} |x_i| \xrightarrow{p \rightarrow \infty} \|x\|_\infty.$$

С другой стороны, имеем

$$\|x\|_p \geq \left(\max_{i=1,d} |x_i|^p \right)^{\frac{1}{p}} = \max_{i=1,d} |x_i| = \|x\|_\infty.$$

По теореме о трёх последовательностях (Теорема 2 Параграфа 5 из [41]), имеем

$$\lim_{p \rightarrow \infty} \|x\|_p = \|x\|_\infty.$$

■

Теперь, когда мы ввели в рассмотрение множество примеров векторных норм, закономерно возникает вопрос о том, как они соотносятся между собой. Действительно, показав сходимость численного метода в некоторой норме, мы хотели бы иметь уверенность, что он сходится и в других нормах тоже. Из курса математического анализа известно утверждение.

Утверждение С1.1 (Лемма 3 Лекции 23 из [48]). Рассмотрим $\|\cdot\|_A, \|\cdot\|_B : \mathbb{R}^d \rightarrow \mathbb{R}$. Существуют такие $c_1, c_2 > 0$, что для любого вектора x из $\mathbb{R}^d$ выполняется соотношение:

$$c_1 \|x\|_A \leq \|x\|_B \leq c_2 \|x\|_A.$$

Таким образом, в конечномерном вещественном пространстве все нормы эквивалентны. Доказательство утверждения неконструктивно, однако в ряде задач мы хотели бы конкретизировать значения c_1 и c_2 .

Пример С1.3. Для $\|\cdot\|_1$ и $\|\cdot\|_2$ выполнено соотношение:

$$\frac{1}{\sqrt{d}} \|x\|_1 \leq \|x\|_2 \leq \|x\|_1.$$

Доказательство. Начнём с верхней оценки. Запишем

$$\begin{aligned}\|x\|_2^2 &= |x_1|^2 + \dots + |x_d|^2 \leq |x_1|^2 + \dots + |x_d|^2 + 2|x_1||x_2| + \dots + 2|x_{d-1}||x_d| \\ &= (|x_1| + \dots + |x_d|)^2 = \|x\|_1^2.\end{aligned}$$

Таким образом,

$$\|x\|_2 \leq \|x\|_1.$$

Заметим, что неравенство переходит в равенство на векторе $x = e_1$. Чтобы оценить $\|x\|_2$ снизу, воспользуемся неравенством Гёльдера (0.2), положив один из векторов в скалярном произведении равным единице:

$$\|x\|_1^2 = \left(\sum_{i=1}^d 1|x_i| \right)^2 \leq \left(\sum_{i=1}^d 1^2 \right) \left(\sum_{i=1}^d |x_i|^2 \right) = d\|x\|_2^2.$$

Заметим, что неравенство переходит в равенство на векторе $x = \mathbf{1}$, где $\mathbf{1}$ — вектор из всех единиц. Комбинируя результаты, получаем

$$\frac{1}{\sqrt{d}}\|x\|_1 \leq \|x\|_2 \leq \|x\|_1.$$

■

C1.2 Матричные нормы

В анализе численных методов помимо векторов также приходится работать с матрицами. Существует естественное обобщение определения нормы.

Определение C1.3. Рассмотрим функцию $\|\cdot\| : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$. Она называется *матричной нормой*, если удовлетворяет следующим условиям:

- $\|A\| \geq 0$, $\|A\| = 0 \iff A = 0$;
- $\|\lambda A\| = |\lambda| \|A\|$, $\lambda \in \mathbb{R}$;
- $\|A + B\| \leq \|A\| + \|B\|$.

Замечание C1.2. Для матриц помимо сложения также определена операция умножения. Ключевым для анализа численных методов является свойство

$$\|AB\| \leq \|A\| \|B\|.$$

Тем не менее, оно выполнено не для всех матричных норм. Рассмотрим норму:

$$\|A\| = \max_{\substack{i=1, n \\ j=1, d}} |a_{ij}|$$

и матрицы

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

Получим, что $\|AB\| = 2$, $\|A\| = 1$, $\|B\| = 1$, то есть свойство не выполняется.

Замечание C1.3. Если для $\|\cdot\| : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$ выполнено

$$\|AB\| \leq \|A\| \|B\|,$$

то её называют *субмультипликативной* матричной нормой.

Может показаться, что мы вынуждены вручную проверять субмультипликативность, сталкиваясь с новой матричной нормой. Эту проблему можно решить, рассматривая более узкий класс норм, для которых это свойство выполняется автоматически. В дальнейшем окажется, что наиболее часто используемые матричные нормы принадлежат этому классу.

Определение C1.4. Рассмотрим $A \in \mathbb{R}^{n \times d}$, норму $\|\cdot\|_\alpha : \mathbb{R}^d \rightarrow \mathbb{R}$ и норму $\|\cdot\|_\beta : \mathbb{R}^n \rightarrow \mathbb{R}$. Матричной нормой, *подчинённой* $\|\cdot\|_\alpha$ и $\|\cdot\|_\beta$, называется функция $\|\cdot\|_{\alpha, \beta} : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$, заданная как

$$\|A\|_{\alpha, \beta} = \sup_{\|x\|_\alpha = 1} \|Ax\|_\beta.$$

Замечание C1.4. Мы будем рассматривать только случай, когда $\alpha = \beta$, тогда определение можно переписать следующим образом:

$$\|A\| = \sup_{\|x\|=1} \|Ax\|.$$

Замечание C1.5. Определение C1.4 можно переформулировать, представив единичный x как некоторый вектор после нормировки на единичную сферу. Тогда имеем

$$\|A\| = \sup_{\|x\|=1} \|Ax\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Замечание C1.6. Из Замечания C1.5 следует неравенство

$$\frac{\|Ax\|}{\|x\|} \leq \|A\| \implies \|Ax\| \leq \|A\| \|x\|.$$

Это очень полезное свойство, которое будет неоднократно использовано в дальнейшем изложении.

Пример C1.4. Подчинённая матричная норма всегда субмультипликативна.

Доказательство. Рассмотрим матрицы A и B , имеющие правильные размерности. Записав определение подчинённой нормы, получим

$$\|AB\| = \sup_{\|x\|=1} \|ABx\| \leq \sup_{\|x\|=1} \|A\| \|Bx\| \leq \sup_{\|x\|=1} \|A\| \|B\| \|x\| = \|A\| \|B\|.$$

■

Использование подчинённой нормы также позволяет оценивать спектральный радиус матрицы.

Утверждение C1.2. Рассмотрим $A \in \mathbb{S}^d$, где $\mathbb{S}^d$ — множество симметричных матриц. Обозначим $\rho(A) = \max_{i=1,d} |\lambda_i(A)|$ — *спектральный радиус*, где $\lambda_i(A)$ — собственные числа матрицы A . Тогда

$$\rho(A) \leq \|A\|,$$

где $\|\cdot\|$ — подчинённая норма.

Доказательство. Запишем уравнение на собственные векторы матрицы A :

$$Ax = \lambda x \implies \|Ax\| = |\lambda| \|x\|.$$

В Замечании C1.6 было получено неравенство

$$\|Ax\| \leq \|A\| \|x\|.$$

Тогда можем утверждать, что

$$|\lambda| \leq \|A\|.$$

Отсюда очевидно следует, что

$$\rho(A) = \max_{i=1,d} |\lambda_i(A)| \leq \|A\|.$$

Заметим, что на I_d достигается равенство. ■

Помимо собственных чисел часто оказывается удобным использовать сингулярные. Например, если работаем с прямоугольной матрицей.

Определение C1.5. *Сингулярным числом* матрицы $A \in \mathbb{R}^{n \times d}$ называется

$$\sigma_i(A) = \sqrt{\lambda_i(A^\top A)}.$$

На практике часто приходится работать с квадратными симметричными матрицами. В этом случае сингулярные числа имеют более удобный вид.

Утверждение C1.3. Пусть $A \in \mathbb{S}^d$. Тогда сингулярные числа имеют вид

$$\sigma_i(A) = |\lambda_i(A)|.$$

Доказательство. Существует ортонормированный базис, составленный из собственных векторов вещественной симметричной матрицы A (Теорема 1 Лекции 33 из [48]). Таким образом, можно привести A к диагональному виду. Запишем её преобразование при переходе от стандартного базиса в базис собственных векторов:

$$A = V \Lambda V^\top,$$

где $V \in \mathbb{R}^{d \times d}$ — ортогональная матрица, составленная из собственных векторов A , $\Lambda = \text{diag}(\lambda_1(A), \dots, \lambda_d(A))$. Теперь запишем

$$A^\top A = A^2 = (V \Lambda V^\top)(V \Lambda V^\top) = V \Lambda^2 V^\top.$$

Таким образом, доказали, что $\lambda_i(A^\top A) = \lambda_i(A)^2$, откуда следует, что $\sigma_i(A) = |\lambda_i(A)|$. ■

Таким образом, подчинённая матричная норма определена достаточно удачно и имеет ряд хороших свойств. Более того, она даёт связь с векторными нормами. Оказывается, что Определение C1.4 позволяет давать аналитические выражения для подсчёта матричных норм.

Пример C1.5. Рассмотрим $A \in \mathbb{R}^{n \times d}$. Для подчинённых норм $\|\cdot\|_\infty, \|\cdot\|_1, \|\cdot\|_2 : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$, имеем следующие выражения:

- $\|A\|_\infty = \max_{i=1, n} \sum_{j=1}^d |a_{ij}|$ — максимум сумм по строкам,
- $\|A\|_1 = \max_{j=1, d} \sum_{i=1}^n |a_{ij}|$ — максимум сумм по столбцам.
- $\|A\|_2 = \max_{i=1, d} \sqrt{\lambda_i(A^\top A)} = \max_{i=1, d} \sigma_i(A)$ — максимальное сингулярное число.

Доказательство. Будем доказывать в том же порядке, в котором утверждения приведены в формулировке примера.

- Распишем:

$$\begin{aligned} \|Ax\|_\infty &= \max_{i=1, n} \left| \sum_{j=1}^d a_{ij} x_j \right| \leq \max_{i=1, n} \sum_{j=1}^d |a_{ij} x_j| \leq \max_{k=1, d} |x_k| \max_{i=1, n} \sum_{j=1}^d |a_{ij}| \\ &= \|x\|_\infty \max_{i=1, n} \sum_{j=1}^d |a_{ij}|. \end{aligned}$$

Пусть максимум правой части достигается при $i = i_0$. Рассмотрим вектор $x = \left(\frac{a_{i_0 1}}{|a_{i_0 1}|}, \dots, \frac{a_{i_0 d}}{|a_{i_0 d}|} \right)^\top$. Тогда, подставляя его в выражение выше, получаем равенство. Таким образом, существует вектор, на котором верхняя грань достигается.

- Будем расписывать почти как в предыдущем примере:

$$\|Ax\|_1 = \sum_{i=1}^n \left| \sum_{j=1}^d a_{ij} x_j \right| \leq \sum_{j=1}^d |x_j| \sum_{i=1}^n |a_{ij}| \leq \|x\|_1 \max_{j=1, d} \sum_{i=1}^n |a_{ij}|.$$

Пусть максимум правой части достигается при $j = j_0$. Рассмотрим вектор $x = e_{j_0}$. Тогда, подставляя его в выражение выше, получаем равенство. Таким образом, существует вектор, на котором верхняя грань достигается.

- Раскроем определение:

$$\|A\|_2 = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sup_{x \neq 0} \sqrt{\frac{\langle A^\top Ax, x \rangle}{\langle x, x \rangle}}.$$

Разложим x по ортонормированному базису $\nu_1, \dots, \nu_d$ собственных векторов, отвечающих собственным числам $\lambda_1, \dots, \lambda_d$ матрицы $A^\top A$. Напомним, что собственные числа симметричной положительно полуопределённой матрицы неотрицательны. Тогда:

$$\|A\|_2 = \sup_{\|x\|_2=1} \sqrt{\frac{\sum_{j=1}^d \lambda_j c_j^2}{\sum_{j=1}^d c_j^2}} \leq \max_{i=1,d} \sqrt{\lambda_i} = \max_{i=1,d} \sigma_i(A),$$

где c_i — коэффициенты разложения x по базису $\nu_1, \dots, \nu_d$:

$$x = \sum_{i=1}^d c_i \nu_i.$$

Рассмотрим нормированный вектор, соответствующий максимальному собственному значению матрицы $A^\top A$. Тогда, подставляя его в выражение выше, получаем равенство. Таким образом, существует вектор, на котором верхняя грань достигается. ■

Пример C1.6. Матричные нормы $\|\cdot\|_\infty$, $\|\cdot\|_1$ и $\|\cdot\|_2$ связаны соотношением:

$$\|A\|_2^2 \leq \|A\|_1 \|A\|_\infty.$$

Доказательство. Поскольку при транспонировании строки и столбцы меняем местами, верно равенство $\|A\|_1 = \|A^\top\|_\infty$. Запишем определение второй нормы матрицы и для того, чтобы ограничить собственное значение матрицы, воспользуемся Утверждением C1.2:

$$\|A\|_2^2 = \max_{i=1,d} \lambda_i(A^\top A) \leq \|A^\top A\|_1 \leq \|A^\top\|_1 \|A\|_1 = \|A\|_1 \|A\|_\infty.$$
■

Пример C1.7. Матричная норма $\|A\|_2$ может быть определена иначе:

$$\|A\|_2 = \sup_{\|x\|_2=1, \|y\|_2=1} |y^\top A x|.$$

Доказательство. Ранее уже отмечалось, что для матричных норм верно неравенство $\|Ax\| \leq \|A\| \|x\|$. Пользуясь этим свойством и неравенством Коши–Буняковского–Шварца (0.3), запишем:

$$|y^\top A x| = |\langle y, Ax \rangle| \leq \|y\|_2 \|Ax\|_2 \leq \|y\|_2 \|A\|_2 \|x\|_2 = \|A\|_2.$$

Выберем единичный вектор x_* , на котором достигается $\|A\|_2$ и определим $y_* = \frac{Ax_*}{\|Ax_*\|_2}$. Тогда:

$$|y_*^\top A x_*| = \left| \frac{x_*^\top A^\top A x_*}{\|Ax_*\|_2} \right| = \frac{\|Ax_*\|_2^2}{\|Ax_*\|_2} = \|Ax_*\|_2 = \|A\|_2.$$
■

Тем не менее, не все нормы, используемые на практике, являются подчинёнными. Чтобы перейти к их рассмотрению, требуется ввести понятие ранга матрицы.

Определение C1.6. *Столбцовым рангом* матрицы $A \in \mathbb{R}^{n \times d}$ называется число $\text{rank}_c(A)$, такое, что в A существует линейно независимая система из $\text{rank}_c(A)$ столбцов и нет линейно независимой системы из большего числа столбцов.

Замечание C1.7. Существует множество способов определения ранга матрицы. Мы считаем известным из курса линейной алгебры утверждение об их эквивалентности (Следствие 2 Лекции 7 из [48]). В связи с этим, будем пользоваться обозначением $\text{rank}(A) = \text{rank}_c(A)$.

Пример C1.8. Пусть $A \in \mathbb{R}^{n \times d}$. Матричная норма

$$\|A\|_F = \sqrt{\sum_{i=1}^{\text{rank}(A)} \sigma_i^2(A)}$$

не подчинена никакой векторной норме.

Доказательство. Если бы норма была подчинённой, то для единичной матрицы I_d выполнялось бы

$$\|I_d\|_F = \sup_{\|x\|=1} \|I_d x\| = \sup_{\|x\|=1} \|x\| = 1.$$

Однако

$$\|I_d\|_F = \sqrt{\sum_{i=1}^d 1} = \sqrt{d}.$$

Таким образом, предложенная норма не подчинена ни одной из векторных норм. ■

Определение C1.7. Пусть $A \in \mathbb{R}^{n \times d}$. Функцию $\|\cdot\|_F : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$, определённую как

$$\|A\|_F = \sqrt{\sum_{i=1}^{\text{rank}(A)} \sigma_i^2(A)},$$

будем называть *фробениусовой нормой*.

Замечание C1.8. Обратим внимание, что пространство матриц является конечномерным вещественным. Это означает, что матричные нормы эквивалентны, как и векторные.

Пример C1.9. Для $\|\cdot\|_2$ и $\|\cdot\|_F$ выполнено соотношение:

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{d} \|A\|_2.$$

Доказательство. Без ограничения общности расположим сингулярные числа в порядке убывания и положим $\text{rank}(A) = r$. Поскольку $\|A\|_2 = \sigma_1$, то по определению фробениусовой нормы имеем

$$\|A\|_2 \leq \|A\|_F.$$

С другой стороны, $\|A\|_F \leq \sqrt{r} \sigma_1 = \sqrt{d} \sigma_1 = \sqrt{d} \|A\|_2$. Объединяя неравенства, запишем

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{d} \|A\|_2.$$

Фробениусова норма может показаться сложной для вычисления по сравнению с рассмотренными ранее. В дальнейшем выяснится, что можно дать простое эквивалентное определение. Для этого нам потребуется ряд вспомогательных утверждений.

Теорема C1.1. Матрица $A \in \mathbb{R}^{n \times d}$ представима в виде SVD-разложения:

$$A = U \Sigma V^\top,$$

где $U \in \mathbb{R}^{n \times n}$, $V \in \mathbb{R}^{d \times d}$ — ортогональные, $\Sigma \in \mathbb{R}^{n \times d}$ — диагональная матрица, составленная из сингулярных чисел A , расположенных в порядке убывания.

Доказательство. $A^\top A$ неотрицательно определена и симметрична, поэтому её собственные числа неотрицательны и соответствующие им собственные векторы ортогональны. Отсюда из Утверждения C1.3 следует существование ортогональной матрицы V , такой что

$$V^\top A^\top A V = \text{diag}(\sigma_1^2, \dots, \sigma_d^2).$$

Без ограничения общности, будем считать $\sigma_1^2 \geq \dots \geq \sigma_d^2 \geq 0$. Поскольку $\text{rank}(A) = r$, имеем

$$\sigma_i = 0, \quad \forall i > r.$$

Обозначим $V_r = (v_1, \dots, v_r)$, $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$. Тогда имеем

$$V_r^\top A^\top A V_r = \Sigma_r^2.$$

Умножив равенство слева и справа на Σ_r^{-1} , получим

$$(\Sigma_r^{-1} V_r^\top A^\top)(A V_r \Sigma_r^{-1}) = I.$$

Обозначим $U_r = A V_r \Sigma_r^{-1}$. Из написанного выше следует $U_r^\top U_r = I$, то есть U_r матрица с ортонормированными столбцами. Поскольку систему линейно независимых векторов можно дополнить до базиса, присоединим к U_r произвольные ортонормированные столбцы и получим новую матрицу U . Тогда

$$A = U \Sigma V^\top.$$

Теперь мы готовы дать эквивалентное определение фробениусовой нормы.

Утверждение C1.4. Для матрицы $A \in \mathbb{R}^{n \times d}$ фробениусова норма может быть эквивалентно определена как

$$\|A\|_F^2 = \sum_{i=1}^n \sum_{j=1}^d |a_{ij}|^2.$$

Доказательство. Для простоты изложения введём обозначение:

$$\|A\|_S^2 = \sum_{i=1}^n \sum_{j=1}^d |a_{ij}|^2.$$

Будем работать с квадратными матрицами $A \in \mathbb{R}^{d \times d}$. Во-первых, заметим, что для ортогональной матрицы Q выполнено

$$\|QA\|_S = \|A\|_S.$$

Действительно, рассмотрим A как совокупность вектор-столбцов: $A = (a_1, \dots, a_d)$. Тогда имеем

$$\|QA\|_S^2 = \|(Qa_1, \dots, Qa_d)\|_S^2 = \sum_{i=1}^d \sum_{j=1}^d |(Qa_i)_j|^2 = \sum_{i=1}^d \|Qa_i\|_2^2 = \sum_{i=1}^d \|a_i\|_2^2 = \|A\|_S^2.$$

Аналогично проверяется инвариантность относительно умножения на Q справа. Воспользуемся SVD-разложением C1.1 и запишем $\|A\|_S$, применив эту идею. Получим

$$\|A\|_S^2 = \|U\Sigma V^\top\|_S^2 = \|\Sigma\|_S^2 = \sum_{i=1}^r \sigma_i^2 = \|A\|_F^2.$$

■

Теперь мы получили простой способ подсчёта фробениусовой нормы. Поскольку она не подчинена ни одной из векторных норм, выполнение субмультипликативного свойства надо проверять вручную.

Пример C1.10. Для матриц $A \in \mathbb{R}^{d \times n}$ и $B \in \mathbb{R}^{n \times k}$ фробениусова норма субмультипликативна:

$$\|AB\|_F \leq \|A\|_F \|B\|_F.$$

Доказательство. Пользуясь новым определением и неравенством Коши–Буняковского–Шварца (0.3), запишем

$$\begin{aligned} \|AB\|_F^2 &= \sum_{i=1}^d \sum_{j=1}^k \left| \sum_{t=1}^n a_{it} b_{tj} \right|^2 \leq \sum_{i=1}^d \sum_{j=1}^k \left(\sum_{t=1}^n |a_{it}|^2 \right) \left(\sum_{m=1}^n |b_{mj}|^2 \right) \\ &= \left(\sum_{i=1}^d \sum_{t=1}^n |a_{it}|^2 \right) \left(\sum_{m=1}^n \sum_{j=1}^k |b_{mj}|^2 \right) = \|A\|_F^2 \|B\|_F^2. \end{aligned}$$

■

Фробениусова норма широко используется в анализе методов наряду с подчинёнными. Действительно, её вычисление значительно проще, чем, например, второй нормы, при этом она субмультипликативна.

Замечание C1.9. Используя эквивалентное определение, можно заметить, что для квадратных матриц выполнено

$$\|A\|_F^2 = \text{Tr}(A^\top A),$$

где $\text{Tr}(A) = \sum_{i=1}^d a_{ii}$ — *след матрицы*. Таким образом, мы говорим, что фробениусова норма порождена скалярным произведением матриц:

$$\langle A, B \rangle = \text{Tr}(A^\top B).$$

Это замечание окажется особенно полезным для дифференцирования функций, принимающих на вход матрицу. Напомним без доказательства ряд важных свойств следа.

Утверждение C1.5. Для $\text{Tr} : \mathbb{R}^{d \times d} \rightarrow \mathbb{R}$ выполнены следующие равенства:

- $\text{Tr}(A^\top) = \text{Tr}(A)$,
- $\text{Tr}(A + B) = \text{Tr}(A) + \text{Tr}(B)$,
- $\text{Tr}(cA) = c \text{Tr}(A)$,
- $\text{Tr}(A_1 \dots A_n) = \text{Tr}(A_n A_1 \dots A_{n-1})$.

C1.3 Сопряжённые нормы

Если на исходном пространстве задана норма, то на сопряжённом пространстве задана сопряжённая норма.

Определение C1.8. Пусть в $\mathbb{R}^d$ задана норма $\|\cdot\|$. Тогда *сопряжённая норма* $\|\cdot\|_* : \mathbb{R}^d \rightarrow \mathbb{R}$ определяется как

$$\|y\|_* = \sup_{\|x\| \leq 1} x^\top y.$$

Введённая функция ещё не обязана удовлетворять свойствам нормы, докажем их напрямую.

Утверждение C1.6. $\|\cdot\|_*$ является нормой в $\mathbb{R}^d$.

Доказательство. Рассмотрим свойства нормы. Однородность очевидна, покажем положительную определённость: для произвольного $y \neq 0$ можно взять $x = \frac{y}{\|y\|}$, для которого выполняется

$$x^\top y = \frac{y^\top y}{\|y\|} > 0.$$

А для $y = 0$ имеем

$$\|0\|_* = \sup_{\|x\| \leq 1} x^\top 0 = 0.$$

Остаётся показать неравенство треугольника: $\forall y_1, y_2 \in \mathbb{R}^d$:

$$\|y_1 + y_2\|_* = \sup_{\|x\| \leq 1} x^\top (y_1 + y_2) \leq \sup_{\|x\| \leq 1} x^\top y_1 + \sup_{\|x\| \leq 1} x^\top y_2 = \|y_1\|_* + \|y_2\|_*.$$

Следовательно, сопряжённая норма является нормой. ■

Пример C1.11. Пусть $\frac{1}{p} + \frac{1}{q} = 1$, тогда сопряжённая норма к $\|\cdot\|_p$ имеет вид $\|\cdot\|_* = \|\cdot\|_q$.

Доказательство. Для начала покажем, что $\forall y \in \mathbb{R}^d$ $\|y\|_* \leq \|y\|_q$. Из неравенства Гёльдера (0.2) $\forall x, y \in \mathbb{R}^d$: $\|x\|_p \leq 1$:

$$x^\top y \leq \|x\|_p \|y\|_q \leq \|y\|_q.$$

Покажем, что равенство достигается. Пусть $y \neq 0$ и $x \in \mathbb{R}^d$, тогда:

$$x_i = \frac{|y_i|^{q-1} \cdot \text{sign}(y_i)}{\|y\|_q^{q-1}}$$

Нетрудно проверить, что $\|x\|_p = 1$, кроме того имеем

$$x^\top y = \frac{\sum_{i=1}^n |y_i|^q}{\|y\|_q^{q-1}} = \|y\|_q.$$

Таким образом, $\forall y \in \mathbb{R}^d \quad \|y\|_* = \|y\|_q$. ■

C1.4 Квадратичные формы

Часто специальные свойства матриц играют ключевую роль в эффективности методов оптимизации и гарантируют некоторые теоретические оценки. Разберёмся с ними подробнее.

Определение C1.9. Пусть на $\mathbb{R}^d$ задана симметричная билинейная (линейная по обоим аргументам) функция $\alpha : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$, тогда соответствующая ей *квадратичная форма* $Q : \mathbb{R}^d \rightarrow \mathbb{R}$ определяется следующим образом $\forall x \in \mathbb{R}^d$:

$$Q(x) = \sum_{i=1}^d \sum_{j=1}^d \alpha_{ij} x_i x_j, \quad \alpha_{ij} = \alpha_{ji}.$$

Замечание C1.10. Заметим, что любой квадратичной форме в соответствие можно поставить матрицу $A \in \mathbb{S}^d$. То есть $A = \{\alpha\}_{ij}$, и $Q(x) = x^\top A x$.

Далее мы будем отождествлять квадратичную форму и соответствующую ей симметричную матрицу.

Определение C1.10. Квадратичная форма $A \in \mathbb{S}^d$ называется *положительно определённой (полуопределённой)*, если $\forall x \in \mathbb{R}^d \setminus \{0\}$:

$$x^\top A x \underset{(\geq)}{>} 0.$$

Аналогично определяются *отрицательная определённость (полуопределённость)*.

Замечание C1.11. Множество положительно полуопределённых матриц обозначается $\mathbb{S}_+^d$. Если $A \in \mathbb{S}_+^d$, то $A \succeq 0$. Множество положительно определённых матриц обозначается $\mathbb{S}_{++}^d$. Если $A \in \mathbb{S}_{++}^d$, то $A \succ 0$.

Полезными фактами о квадратичных формах, которые пригодятся нам в дальнейшем, являются критерии Сильвестра, которые позволяют проверять матрицы на положительную/отрицательную определённость и полуопределённость.

Теорема C1.2. (Критерий Сильвестра)

- Квадратичная форма положительно определена $\iff$ все угловые миноры

соответствующей ей матрицы положительны.

- Квадратичная форма положительно полуопределена $\iff$ все главные миноры соответствующей ей матрицы неотрицательны. *Главным минором* называется определитель подматрицы, симметричной относительно главной диагонали.

Пример С1.12. Покажите, что матрица

$$A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}$$

положительно определённая.

Решение. Угловой минор порядка 1: $2 > 0$. Угловой минор порядка 2:

$$\det \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} = 3 > 0.$$

Угловой минор порядка 3:

$$\det \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix} = 4 > 0.$$

По критерию Сильвестра, матрица A положительно определена. ■

Пример С1.13. Покажите, что матрица

$$A = \begin{pmatrix} 2 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

положительно полуопределённая.

Решение. Заметим, что все диагональные элементы неотрицательны. Рассмотрим теперь миноры порядка 2:

$$\det \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} = 1 \geq 0,$$

$$\det \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} = 1 \geq 0,$$

$$\det \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = 1 \geq 0.$$

Теперь рассмотрим единственный главный минор порядка 3:

$$\det \begin{pmatrix} 2 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix} = 0.$$

По критерию Сильвестра матрица A положительно полуопределена. Заметим, что она не является положительно определённой. ■

Замечание C1.12. Отметим, что неотрицательности только лишь угловых миноров недостаточно для положительной полуопределённости. Действительно, рассмотрим матрицу

$$A = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix}.$$

Нетрудно видеть, что все угловые миноры матрицы равны нулю. Тем не менее, она не является положительно полуопределённой. Действительно,

$$(0, 1)A(0, 1)^{\top} = (0, 1)(0, -1)^{\top} = -1.$$

С2 Матрично-векторное дифференцирование

В численных методах оптимизации текущее приближение оптимума x^k обновляется за счёт сдвига вдоль некоторого направления d^k . В простейшем случае, Пример Л1.1, это выглядит как

$$x^{k+1} = x^k + \alpha_k d^k,$$

где α_k , d^k — длина и направление шага на k -ой итерации. Чтобы такое обновление имело смысл, пространство параметров модели должно быть наделено линейной структурой, то есть быть замкнуто относительно сложения элементов и умножения на число. Кроме того, для оценки скорости сходимости методов на пространстве параметров должна быть задана норма.

Определение С2.1. *Линейным нормированным пространством (ЛНП) будем называть пару $(U, \|\cdot\|)$, где U — линейное пространство, а $\|\cdot\| : U \rightarrow \mathbb{R}_+$ — действующая на нём норма.*

Замечание С2.1. В основном мы будем рассматривать пространства $\mathbb{R}^d$, $\mathbb{R}^{n \times d}$ и вторую норму на них.

Замечание С2.2. Обычно маленькая латинская буква будет означать вектор, а большая — матрицу.

С2.1 Первый дифференциал

Самые распространённые на практике численные методы используют градиент (Алгоритм Л3.1, Алгоритм Л4.2) или гессиан (Алгоритм Л7.1) целевой функции для построения направления спуска d^k . В этом разделе мы введём формальное определение дифференцирования в конечномерных ЛНП, а также определим градиент и гессиан функции. Кроме этого, мы также подробно поговорим о частных случаях — действительных пространствах векторов и матриц.

Определение С2.2. Пусть U , V — конечномерные ЛНП. Линейный оператор $df(x) : U \rightarrow V$ называется *производной функции* $f : U \rightarrow V$ в точке $x \in U$, если для $h \in U$ выполнено

$$f(x+h) = f(x) + df(x)[h] + o(\|h\|), \quad \|h\| \rightarrow 0.$$

Сама функция f в случае существования такого оператора называется *дифференцируемой по Фреше в точке x* . $df(x)[h]$ называют *дифференциалом функции f в точке x* .

Замечание С2.3. $df(x)[h]$ — действие производной функции на h .

Замечание С2.4. Иногда для обозначения приращения h мы будем использовать dx .

Пример С2.1. Найдите дифференциал функции $f : \mathbb{R} \rightarrow \mathbb{R}$: $f(x) = x^2$.

Решение. Воспользуемся определением дифференцируемости по Фреше:

$$(x+h)^2 = x^2 + 2xh + h^2 \implies df(x)[h] = 2xh,$$

так как $h^2 = o(\|h\|)$ при $|h| \rightarrow 0$. ■

Определение С2.2 накладывает достаточно сильные условия на функцию. Оно проверяет существование единого линейного приближения вдоль всех направлений. Можно рассматривать более слабый вариант производной.

Определение С2.3. Пусть U, V — конечномерные ЛНП. Оператор $\tilde{d}f(x) : U \rightarrow V$ называется *производной по направлению функции $f : U \rightarrow V$ в точке $x \in U$* , если существует предел

$$\tilde{d}f(x)[h] = \lim_{t \rightarrow 0} \frac{f(x + th) - f(x)}{t}, \quad \forall h \in U.$$

Сама функция f в случае существования такого оператора называется *дифференцируемой по Гато в точке x* .

Замечание С2.5. Пусть $\{e_i\}_{i=1}^d$ — ортонормированный базис в U . Тогда $\tilde{d}f(x)[e_i]$ называется *i -ой частной производной f в точке x* .

Из дифференцируемости по Фреше следует дифференцируемость по Гато, однако обратное неверно.

Пример С2.2. Для функции $f : \mathbb{R}^2 \rightarrow \mathbb{R}$:

$$f(x) = \begin{cases} \frac{x_1^3 x_2}{x_1^4 + x_2^2}, & x \neq (0, 0)^\top, \\ 0, & x = (0, 0)^\top. \end{cases}$$

в точке $(0, 0)^\top$ существует производная по Гато, но не существует производной по Фреше.

Доказательство. Воспользуемся Определением С2.3. Поскольку $f(0) = 0$, то достаточно рассмотреть $\frac{f(th)}{t}$ и расписать:

$$\frac{f(th)}{t} = \frac{1}{t} \frac{t^4 h_1^3 h_2}{t^4 h_1^4 + t^2 h_2^2} = t \frac{h_1^3 h_2}{t^2 h_1^4 + h_2^2} \rightarrow 0, \quad t \rightarrow 0.$$

Тогда производная по Гато — нулевое отображение. Если производная по Фреше существует, то она совпадает с производной по Гато и также равна нулевому отображению. Рассмотрим $h_2 = h_1^2$, $h_1 \rightarrow 0$:

$$\lim_{\|h\|_2 \rightarrow 0} \frac{f(h)}{\|h\|_2} = \lim_{h_1 \rightarrow 0} \frac{h_1^3 h_2}{\sqrt{h_1^2 + h_2^2} (h_1^4 + h_2^2)} = \lim_{h_1 \rightarrow 0} \frac{h_1^5}{2\sqrt{1 + h_1^2} h_1^5} = \frac{1}{2}.$$

Пришли к противоречию. ■

Замечание С2.6. В дальнейшем, дифференцируемость функции будем понимать в смысле Фреше.

В $\mathbb{R}^d$ и $\mathbb{R}^{n \times d}$ действие оператора производной единственным образом представляется через скалярное произведение.

Теорема С2.1. Пусть $df(x) : U \rightarrow \mathbb{R}$ — линейный функционал, действующий на конечномерном линейном пространстве U , снабжённом скалярным произведе-

нием. Тогда существует единственный $g_f(x) \in U$, такой, что

$$df(x)[h] = \langle g_f(x), h \rangle.$$

Доказательство. Пусть $\{e_i\}_{i=1}^d$ — ортонормированный базис в U . Тогда любой элемент $h \in U$ представим в виде

$$h = \sum_{i=1}^d h_i e_i.$$

Поддействуем оператором $df(x)$ на h и воспользуемся его линейностью:

$$df(x)[h] = df(x) \left[\sum_{i=1}^d h_i e_i \right] = \sum_{i=1}^d h_i df(x)[e_i].$$

Обозначим $g_f^i(x) = df(x)[e_i]$ и положим

$$g_f = \sum_{i=1}^d g_f^i(x) e_i.$$

Тогда

$$df(x)[h] = \langle g_f(x), h \rangle.$$

■

Этот факт является частным случаем более общей теоремы Риса о представлении линейного функционала для произвольного гильбертова пространства.

Замечание C2.7. В случае ортонормированного базиса $g_f(x)$ — вектор частных производных $\frac{\partial f}{\partial x_i}$. Он называется *градиентом* функции и обозначается как $\nabla f(x)$.

Замечание C2.8. Рассмотрим $f : \mathbb{R}^d \rightarrow \mathbb{R}^n$. Представим

$$f(x) = (f_1(x), \dots, f_n(x))^{\top}.$$

Каждая координатная функция — понятное с точки зрения производной функция $\mathbb{R}^d \rightarrow \mathbb{R}$. Получается, производная функции $\mathbb{R}^d \rightarrow \mathbb{R}^n$ — матрица Якоби, этого отображения $(J_{ij}(x) = \frac{\partial f_i}{\partial x_j}(x))$. В общем случае отображения матрицы в матрицу для построения градиента достаточно найти все частные производные в виде тензора

$$\left\{ \frac{\partial f_{ij}}{\partial x_{kl}}(x) \right\}_{ijkl}.$$

Рассуждения, приведённые в Замечании C2.8, сформулируем в виде таблицы.

Выход Вход	Скаляр $\mathbb{R}$	Вектор $\mathbb{R}^d$
Скаляр $\mathbb{R}$	$\nabla f(x)$ скаляр, h скаляр	$\nabla f(x)$ вектор, h скаляр
Вектор $\mathbb{R}^d$	$\nabla f(x)$ вектор, h вектор	$\nabla f(x)$ матрица, h вектор
Матрица $\mathbb{R}^{n \times d}$	$\nabla f(x)$ матрица, h матрица	$\nabla f(x)$ тензор, h матрица

Утверждение С2.1. Из формулы градиента верно, что

$$df(x) = (\nabla f(x))^T dx \iff \nabla f(x) = J_f^T(x).$$

Доказательство. Утверждение следует из покомпонентного представления градиента и матрицы Якоби. ■

С2.2 Второй дифференциал

Пусть U, V — конечномерные ЛНП. Пусть отображение $f : U \rightarrow V$ дифференцируемо в каждой точке $x \in U$. Второй дифференциал будем определять, фиксируя приращение h_1 и рассматривая первый дифференциал как функцию от x :

$$g(x) = df(x)[h_1].$$

Определение С2.4. Если в некоторой точке x функция $g(x) = df(x)[h_1]$ дифференцируема, то билинейный оператор $dg(x)[h_2] = d(df(x)[h_1])[h_2]$ называется вторым дифференциалом.

Замечание С2.9. Если $f : \mathbb{R}^d \rightarrow \mathbb{R}$, то второй дифференциал — билинейная форма, имеющая вид

$$d^2f(x)[h_1, h_2] = \langle G_f(x)h_1, h_2 \rangle.$$

В случае стандартного базиса $G_f(x)$ — матрица вторых производных $\frac{\partial^2 f}{\partial x_i \partial x_j}$. Она называется гессианом отображения и обозначается $\nabla^2 f(x)$.

Утверждение С2.2. Из формулы гессиана верно, что

$$d(\nabla f(x)) = (\nabla^2 f(x))^T dx \iff \nabla^2 f(x) = J_{\nabla f}^T(x).$$

Доказательство. Утверждение следует из покомпонентного представления градиента и матрицы Якоби. ■

С2.3 Примеры и задачи

Известные из курса математического анализа правила дифференцирования (производная произведения, частного, композиции) сохраняются. Мы напомним их, не обращаясь к доказательствам.

Утверждение С2.3. Пусть U, V — ЛНП. Тогда для векторных и матричных дифференциалов справедливо:

1. $d(\alpha x) = \alpha dx, \alpha \in \mathbb{R}$;
2. $d(x + y) = dx + dy$;
3. $d\langle x, y \rangle = \langle dx, y \rangle + \langle x, dy \rangle$;
4. $d(f(x)g(x)) = d(f(x))g(x) + f(x)d(g(x))$ ($f : U \rightarrow \mathbb{R}, g : U \rightarrow \mathbb{R}$);
5. $d\left(\frac{f(x)}{\phi(x)}\right) = \frac{\phi(x)df(x) - f(x)d\phi(x)}{\phi^2(x)}$ ($f : U \rightarrow \mathbb{R}, \phi : \mathbb{R} \rightarrow \mathbb{R} \setminus \{0\}$);

6. $d(g \circ f(x)) = dg(f(x)) [df(x)] \quad (f : U \rightarrow f(U), g : f(U) \rightarrow V);$
7. $J_{g \circ f}(x) = J_g(f(x)) J_f(x) \quad (f : U \rightarrow f(U), g : f(U) \rightarrow V).$

Дополнительно для матричных дифференциалов справедливо:

1. $d(AXB) = A dX B;$
2. $d(XY) = (dX)Y + X(dY);$
3. $d(X^\top) = (dX)^\top.$

Перед тем как перейти к вычислению нетривиальных примеров, придётся воспользоваться определением и получить выражения для базовых градиентов.

Пример C2.3. Справедливы следующие выражения:

- $d\langle c, x \rangle = \langle c, dx \rangle \implies \nabla(\langle c, x \rangle) = c;$
- $d\langle Ax, x \rangle = \langle (A + A^\top)x, dx \rangle \implies \nabla(\langle Ax, x \rangle) = (A + A^\top)x;$
- $d(X^{-1}) = -X^{-1} dX X^{-1}$ при $\det X \neq 0;$
- $d \det(X) = \langle \det(X) X^{-\top}, dX \rangle$ при $\det X \neq 0 \implies \nabla(\det(X)) = \det(X) X^{-\top}.$

Доказательство.

- Для $f(x) = \langle c, x \rangle$ запишем

$$f(x+h) - f(x) = \langle c, x+h \rangle - \langle c, x \rangle = \langle c, h \rangle.$$

При этом $h \rightarrow \langle c, h \rangle$ — линейный оператор. То есть по определению

$$df(x)[h] = \langle c, h \rangle.$$

- Для $f(x) = \langle Ax, x \rangle$ запишем

$$f(x+h) - f(x) = \langle Ax + Ah, x+h \rangle - \langle Ax, x \rangle = \langle (A + A^\top)x, h \rangle + \langle Ah, h \rangle.$$

Заметим, что

$$\langle Ah, h \rangle \leq \|Ah\|_2 \|h\|_2 \leq \|A\|_2 \|h\|_2^2 = o(\|h\|_2),$$

где первое неравенство следует из Коши–Буняковского–Шварца (0.3), а второе — из подчинённости матричной нормы (Замечание C1.6). При этом $h \rightarrow \langle (A + A^\top)x, h \rangle$ — линейный оператор. То есть по определению

$$df(x)[h] = \langle (A + A^\top)x, h \rangle.$$

- Для $f(X) = X^{-1}$ запишем

$$\begin{aligned} f(X+H) - f(X) &= (X+H)^{-1} - X^{-1} = (X(I_d + X^{-1}H))^{-1} - X^{-1} \\ &= ((I_d + X^{-1}H)^{-1} - I_d)X^{-1}. \end{aligned}$$

Поскольку H можно выбрать так, чтобы $\|X^{-1}H\|_2 \leq \|X^{-1}\|_2 \|H\|_2 < \frac{1}{2}$, то можно воспользоваться разложением в ряд Неймана (Параграф 3.3 из [47]):

$$(I_d + X^{-1}H)^{-1} = I_d - X^{-1}H + \sum_{k=2}^{\infty} (-X^{-1}H)^k.$$

Оценим норму последнего слагаемого:

$$\begin{aligned} \left\| \sum_{k=2}^{\infty} (-X^{-1}H)^k \right\|_2 &\leq \sum_{k=2}^{\infty} \|(-X^{-1}H)^k\|_2 \leq \sum_{k=2}^{\infty} \|X^{-1}\|_2^k \|H\|_2^k \\ &= \frac{\|X^{-1}\|_2^2 \|H\|_2^2}{1 - \|X^{-1}\|_2 \|H\|_2} = o(\|H\|_2), \end{aligned}$$

где первое неравенство получается из неравенства треугольника в пределе, второе — из субмультипликативности матричной нормы (Замечание C1.3), а третье равенство — это сумма геометрической прогрессии. В итоге получаем разность

$$f(X + H) - f(X) = -X^{-1}HX^{-1} + o(\|H\|_2),$$

при этом $H \rightarrow -X^{-1}HX^{-1}$ — линейный оператор. То есть по определению

$$df(X)[H] = -X^{-1}HX^{-1}.$$

- Для $f(X) = \det(X)$ запишем

$$\begin{aligned} f(X + H) - f(X) &= \det(X + H) - \det(X) = \det(X(I_d + X^{-1}H)) - \det(X) \\ &= \det(X)(\det(I_d + X^{-1}H) - 1). \end{aligned}$$

Отдельно оценим $\det(I_d + X^{-1}H)$. Пусть $\lambda_i(X^{-1}H)$ — собственные числа матрицы $X^{-1}H$ (в произвольном порядке и, возможно, комплексные). Тогда собственными числами матрицы $I_d + X^{-1}H$ будут $1 + \lambda_i(X^{-1}H)$. Поэтому

$$\begin{aligned} \det(I_d + X^{-1}H) &= \prod_{i=1}^d [1 + \lambda_i(X^{-1}H)] \\ &= 1 + \sum_{i=1}^d \lambda_i(X^{-1}H) + \left(\sum_{1 \leq i \leq j \leq d} \lambda_i(X^{-1}H) \lambda_j(X^{-1}H) + \dots \right), \end{aligned}$$

где многоточие обозначает всевозможные тройки, четвёрки и так далее из $\lambda_i(X^{-1}H)$. Для произвольной матрицы $A \in \mathbb{R}^{d \times d}$ все её собственные числа по модулю не превосходят её операторную норму (Утверждение C1.2). Следовательно, всё выражение в скобках — $o(\|H\|_2)$, поскольку в каждом слагаемом больше одного собственного числа. Таким образом,

$$\det(I_d + X^{-1}H) = 1 + \sum_{i=1}^d \lambda_i(X^{-1}H) + o(\|H\|_2) = 1 + \text{Tr}(X^{-1}H) + o(\|H\|_2).$$

При этом $H \rightarrow \det(X) \text{Tr}(X^{-1}H)$ — линейный оператор. То есть по определению

$$df(X)[H] = \det(X) \text{Tr}(X^{-1}H) = \det(X) \langle X^{-\top}, H \rangle.$$

■

Замечание С2.10. Мы доказали формулу $d(\det(X)) = \det(X) \langle X^{-\top}, dX \rangle$ только для обратимых X . Однако выражение для $d(\det(X))$ можно получить и для произвольной матрицы из $\mathbb{R}^{d \times d}$. Эта формула называется *формулой Якоби* и записывается как

$$d(\det(X)) = \langle \text{Adj}(X)^{\top}, dX \rangle,$$

где $\text{Adj}(X)$ — присоединённая матрица к X . Она определяется как

$$\text{Adj}(X)_{ji} = (-1)^{(i+j)} M_{ij},$$

где M_{ij} — дополнительный минор — определитель матрицы, получившийся вычеркиванием i -ой строки и j -го столбца из X . В случае невырожденной X выполнено $\text{Adj}(X) = \det(X) X^{-1}$, и формулы переходят друг в друга. Вспомним формулу вычисления определителя через дополнительные миноры по i -ой строке

$$\det(X) = \sum_{j=1}^d x_{ij} (-1)^{(i+j)} M_{ij}.$$

Тогда градиент равен

$$\frac{\partial \det(X)}{\partial x_{ij}} = (-1)^{(i+j)} M_{ij} = \text{Adj}(X)_{ji}.$$

С2.3.1 Дифференцирование по вектору

В машинном обучении широко известен метод наименьших квадратов (МНК) (Параграф 3.1.1 из [5]). По матрице признаков $\tilde{A}$ и вектору параметров x требуется линейно приблизить целевой вектор $\tilde{b}$. Для решения этой задачи требуется вычислять градиент невязки

$$f(x) = \frac{1}{2} \|\tilde{A}x - \tilde{b}\|_2^2 = \frac{1}{2} \langle \tilde{A}x, \tilde{A}x \rangle - \langle \tilde{A}x, \tilde{b} \rangle + \frac{1}{2} \|\tilde{b}\|_2^2$$

Если мы введём обозначения $A = \tilde{A}^{\top} \tilde{A}$, $b = -\tilde{A}^{\top} \tilde{b}$, $c = \frac{1}{2} \|\tilde{b}\|_2^2$, то вычисление градиента невязки эквивалентно вычислению градиента функции

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c.$$

Пример С2.4. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c, \quad A \in \mathbb{R}^{d \times d}, \quad b \in \mathbb{R}^d, \quad c \in \mathbb{R}.$$

Решение. Найдём первый дифференциал

$$\begin{aligned} df(x) &= d\left(\frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c\right) = \frac{1}{2} \langle (A + A^{\top})x, dx \rangle + \langle b, dx \rangle + 0 \\ &= \left\langle \frac{1}{2} (A + A^{\top})x + b, dx \right\rangle. \end{aligned}$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{1}{2} (A + A^{\top})x + b.$$

Для поиска гессиана фиксируем первое приращение dx_1 у первого дифференциала и берём уже от него ещё один дифференциал

$$d^2 f(x) = d \left\langle \frac{1}{2} (A + A^\top) x + b, dx_1 \right\rangle = \left\langle \frac{1}{2} (A + A^\top) dx, dx_1 \right\rangle.$$

Переносим и транспонируем матрицу в скалярном произведении, но поскольку $A + A^\top$ симметричная, то она не меняется:

$$d^2 f(x) = \left\langle dx, \frac{1}{2} (A + A^\top)^\top dx_1 \right\rangle = \left\langle \frac{1}{2} (A + A^\top) dx_1, dx \right\rangle.$$

Следовательно, приведя к стандартному виду $d^2 f(x) = \langle \nabla^2 f(x) dx_1, dx \rangle$, получаем гессиан

$$\nabla^2 f(x) = \frac{1}{2} (A + A^\top).$$

■

Замечание C2.11. Заметим, что в случае если A симметричная, то

$$\nabla f(x) = Ax + b, \quad \nabla^2 f(x) = A.$$

Пример C2.5. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \setminus \{0\} \rightarrow \mathbb{R}$:

$$f(x) = \log \langle Ax, x \rangle, \quad A \in \mathbb{S}_{++}^d.$$

Решение. Найдём первый дифференциал

$$df(x) = d \log \langle Ax, x \rangle = \frac{1}{\langle Ax, x \rangle} d \langle Ax, x \rangle = \frac{2 \langle Ax, dx \rangle}{\langle Ax, x \rangle} = \left\langle \frac{2Ax}{\langle Ax, x \rangle}, dx \right\rangle.$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{2Ax}{\langle Ax, x \rangle}.$$

Теперь найдём дифференциал градиента

$$\begin{aligned} d \left(\frac{2Ax}{\langle Ax, x \rangle} \right) &= \frac{d(2Ax) \langle Ax, x \rangle - (2Ax) d \langle Ax, x \rangle}{\langle Ax, x \rangle^2} = \frac{2 \langle Ax, x \rangle A dx - 4Ax \langle Ax, dx \rangle}{\langle Ax, x \rangle^2} \\ &= \left(\frac{2A}{\langle Ax, x \rangle} - \frac{4Ax x^\top A}{\langle Ax, x \rangle^2} \right) dx = J_{\nabla f}(x) dx. \end{aligned}$$

Поскольку $\nabla^2 f(x) = J_{\nabla f}^\top(x)$, а гессиан симметричен из-за непрерывности, то

$$\nabla^2 f(x) = \frac{2A}{\langle Ax, x \rangle} - \frac{4Ax x^\top A}{\langle Ax, x \rangle^2}.$$

■

Пример C2.6. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \setminus \{0\} \rightarrow \mathbb{R}$:

$$f(x) = \|x\|_2.$$

Решение. Найдём первый дифференциал

$$df(x) = d\langle x, x \rangle^{\frac{1}{2}} = \frac{d(\langle x, x \rangle)}{2\langle x, x \rangle^{\frac{1}{2}}} = \left\langle \frac{2x}{2\langle x, x \rangle^{\frac{1}{2}}}, dx \right\rangle = \left\langle \frac{x}{\|x\|_2}, dx \right\rangle.$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \frac{x}{\|x\|_2}.$$

Теперь посчитаем второй дифференциал, зафиксировав приращение dx_1 первого

$$\begin{aligned} d^2 f(x) &= d\left\langle \frac{x}{\|x\|_2}, dx_1 \right\rangle = \left\langle \frac{dx \|x\|_2 - x d(\|x\|_2)}{\|x\|_2^2}, dx_1 \right\rangle \\ &= \left\langle \frac{dx}{\|x\|_2} - x \left\langle \frac{x}{\|x\|_2^3}, dx \right\rangle, dx_1 \right\rangle = \left\langle \left(\frac{I_d}{\|x\|_2} - \frac{xx^\top}{\|x\|_2^3} \right) dx, dx_1 \right\rangle. \end{aligned}$$

Поскольку $\nabla^2 f(x) = J_{\nabla f}^\top(x)$, а гессиан симметричен

$$\nabla^2 f(x) = \frac{I_d}{\|x\|_2} - \frac{xx^\top}{\|x\|_2^3}.$$

■

Пример C2.7. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \setminus \{0\} \rightarrow \mathbb{R}$:

$$f(x) = \frac{1}{3} \|x\|_2^3.$$

Решение. Найдём первый дифференциал

$$df(x) = \frac{1}{3} d\langle x, x \rangle^{3/2} = \frac{1}{2} \langle x, x \rangle^{1/2} d\langle x, x \rangle = \langle x, x \rangle^{1/2} \langle x, dx \rangle = \langle x \|x\|_2, dx \rangle.$$

Приведя к стандартному виду $df(x) = \langle \nabla f(x), dx \rangle$, получаем

$$\nabla f(x) = \|x\|_2 x.$$

Найдём второй дифференциал

$$\begin{aligned} d^2 f(x) &= d(\|x\|_2 \langle x, dx_1 \rangle) = \left\langle \frac{x}{\|x\|_2}, dx \right\rangle \langle x, dx_1 \rangle + \|x\|_2 \langle dx, dx_1 \rangle \\ &= \left\langle dx, \left(\frac{xx^\top}{\|x\|_2} + I_d \|x\|_2 \right) dx_1 \right\rangle. \end{aligned}$$

Получаем гессиан

$$\nabla^2 f(x) = \frac{xx^\top}{\|x\|_2} + I_d \|x\|_2.$$

■

Замечание C2.12. Заметим, что гессиан не определён в точке $x = 0$, поскольку мы дифференцировали норму, а её градиент не определён в 0. Тем не менее, можно найти производную функции из условия в $x = 0$ по определению. Зафиксируем приращение h_1 и рассмотрим

$$\begin{aligned} \lim_{\|h_2\|_2 \rightarrow 0} \frac{\|df(h_2)[h_1] - df(0)[h_1]\|_2}{\|h_2\|_2} &= \lim_{\|h_2\|_2 \rightarrow 0} \frac{|\langle \|h_2\|_2 h_2, h_1 \rangle|}{\|h_2\|_2} \\ &= \lim_{\|h_2\|_2 \rightarrow 0} \frac{\|h_2\|_2 |\langle h_2, h_1 \rangle|}{\|h_2\|_2} \\ &= \lim_{\|h_2\|_2 \rightarrow 0} |\langle h_2, h_1 \rangle| = 0. \end{aligned}$$

Следовательно, по определению вторая производная в точке $x = 0$ равна 0. Можно даже сказать, что отображение дважды непрерывно дифференцируемо, потому что

$$\lim_{\|x\|_2 \rightarrow 0} \left(\frac{xx^\top}{\|x\|_2} + I_d \|x\|_2 \right) = 0.$$

Далее рассмотрим модель логистической регрессии — модель машинного обучения для задачи разделения двух классов (Параграф 4.3.2 из [5]). Её обучение может сводиться к оптимизации функции

$$f(x) = \log(1 + \exp(\langle x, a \rangle)).$$

Пример C2.8. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f: \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \log(1 + \exp(\langle x, a \rangle)), \quad a \in \mathbb{R}^d.$$

Решение. Найдём первый дифференциал

$$\begin{aligned} df(x) &= d \log(1 + \exp(\langle x, a \rangle)) = \frac{1}{1 + \exp(\langle x, a \rangle)} d(1 + \exp(\langle x, a \rangle)) \\ &= \frac{\exp(\langle x, a \rangle)}{1 + \exp(\langle x, a \rangle)} d\langle x, a \rangle = \left\langle \frac{\exp(\langle x, a \rangle)}{1 + \exp(\langle x, a \rangle)} a, dx \right\rangle. \end{aligned}$$

Для удобства введём сигмоиду

$$\sigma(x) := \frac{1}{1 + \exp(-x)}.$$

При этом заметим, что $\sigma(-x) = 1 - \sigma(x)$ и $\sigma'(x) = \sigma(x)(1 - \sigma(x))$. После этого приведём $df(x)$ к стандартному виду и получим

$$\nabla f(x) = \sigma(\langle x, a \rangle) a.$$

Таким образом, градиент $\nabla f(x)$ — вектор, коллинеарный вектору a с коэффициентом $\sigma(\langle a, x \rangle) \in (0, 1)$. От точки x зависит лишь длина градиента, но не направление.

Теперь посчитаем второй дифференциал, зафиксировав приращение dx_1 первого. Имеем

$$\begin{aligned} d^2 f(x) &= d\langle \sigma(\langle x, a \rangle) a, dx_1 \rangle = \langle d\sigma(\langle x, a \rangle) a, dx_1 \rangle = \langle \sigma'(\langle x, a \rangle) d\langle x, a \rangle a, dx_1 \rangle \\ &= \langle \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle dx, a \rangle a, dx_1 \rangle \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle \langle dx, a \rangle a, dx_1 \rangle \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) (dx^\top a a^\top dx_1) \\ &= \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \langle a a^\top dx_1, dx \rangle. \end{aligned}$$

Получим

$$\nabla^2 f(x) = \sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) a a^\top.$$

Заметим, что $\nabla^2 f(x)$ — одноранговая матрица, пропорциональная $a a^\top$ с коэффициентом $\sigma(\langle x, a \rangle) (1 - \sigma(\langle x, a \rangle)) \in (0, 0.25)$. Точка x влияет лишь на коэффициент. ■

С2.3.2 Дифференцирование по матрице

Для подсчёта градиентов по матрицам активно применяются производные таких функций, как $\det, \text{Tr}, X^{-1}$. Именно поэтому мы посвятили раздел их вычислению.

Пример С2.9. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$:

$$f(X) = \|AX - B\|_F, \quad A \in \mathbb{R}^{m \times n}, \quad B \in \mathbb{R}^{m \times d}.$$

Решение. Сначала отдельно вычислим $d\|X\|_F$:

$$d\|X\|_F = d\langle X, X \rangle^{1/2} = \frac{d\langle X, X \rangle}{2\langle X, X \rangle^{1/2}} = \left\langle \frac{2X}{2\langle X, X \rangle^{1/2}}, dX \right\rangle = \left\langle \frac{X}{\|X\|_F}, dX \right\rangle.$$

Тогда первый дифференциал

$$\begin{aligned} df(X) &= d\|AX - B\|_F = \left\langle \frac{AX - B}{\|AX - B\|_F}, d(AX - B) \right\rangle = \left\langle \frac{AX - B}{\|AX - B\|_F}, A dX \right\rangle \\ &= \text{Tr} \left(\frac{(AX - B)^\top}{\|AX - B\|_F} A dX \right) = \text{Tr} \left(\left(\frac{A^\top (AX - B)}{\|AX - B\|_F} \right)^\top dX \right) \\ &= \left\langle \frac{A^\top (AX - B)}{\|AX - B\|_F}, dX \right\rangle. \end{aligned}$$

Тогда градиент

$$\nabla f(X) = \frac{A^\top (AX - B)}{\|AX - B\|_F}. \quad \blacksquare$$

Пример С2.10. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{d \times d} \rightarrow \mathbb{R}$:

$$f(X) = \text{Tr}(AXBX^{-1}), \quad A, B \in \mathbb{R}^{d \times d},$$

при $\det(X) \neq 0$.

Решение. Перепишем след через скалярное произведение:

$$f(X) = \langle I_d, AXBX^{-1} \rangle.$$

Найдём первый дифференциал

$$\begin{aligned} df(X) &= \langle I_d, d(AXBX^{-1}) \rangle = \langle I_d, A(dX)BX^{-1} + AXB d(X^{-1}) \rangle \\ &= \langle I_d, A(dX)BX^{-1} - AXBX^{-1}(dX)X^{-1} \rangle \\ &= \text{Tr}(A(dX)BX^{-1}) - \text{Tr}(AXBX^{-1}(dX)X^{-1}) \\ &= \text{Tr}(BX^{-1}A(dX)) - \text{Tr}(X^{-1}AXBX^{-1}(dX)) \\ &= \langle A^\top X^{-\top} B^\top - X^{-\top} B^\top X^\top A^\top X^{-\top}, dX \rangle. \end{aligned}$$

При работе со скалярными произведениями можно переходить к следу и обратно, используя таким образом его полезные свойства. Тогда градиент

$$\nabla f(X) = A^\top X^{-\top} B^\top - X^{-\top} B^\top X^\top A^\top X^{-\top}.$$

■

Пример С2.11. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}$:

$$f(X) = \text{Tr}(AX^\top X), \quad A \in \mathbb{R}^{d \times d}.$$

Решение. Перепишем след через скалярное произведение

$$f(X) = \langle I_d, AX^\top X \rangle.$$

Найдём первый дифференциал

$$\begin{aligned} df(X) &= d\langle I_d, AX^\top X \rangle = \langle I_d, A d(X^\top X) \rangle = \langle I_d, A dX^\top X \rangle + \langle I_d, AX^\top dX \rangle \\ &= \text{Tr}(A dX^\top X) + \langle XA^\top, dX \rangle = \text{Tr}(XA dX^\top) + \langle XA^\top, dX \rangle \\ &= \langle XA, dX \rangle + \langle XA^\top, dX \rangle = \langle XA + XA^\top, dX \rangle. \end{aligned}$$

Тогда градиент

$$\nabla f(X) = XA + XA^\top.$$

■

Пример С2.12. Найдите $\nabla f(X)$ и $d^2 f(X)$ функции $f : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$f(X) = \log(\det(X)).$$

Решение. Найдём первый дифференциал

$$df(X) = d \log(\det(X)) = \frac{d(\det(X))}{\det(X)} = \frac{\det(X) \langle X^{-\top}, dX \rangle}{\det(X)} = \langle X^{-1}, dX \rangle.$$

Тогда градиент

$$\nabla f(X) = X^{-1}.$$

Теперь посчитаем второй дифференциал, зафиксировав приращение dX_1 первого

$$d^2 f(X) = \langle dX^{-1}, dX_1 \rangle = -\langle X^{-1} dX X^{-1}, dX_1 \rangle.$$

Мы получили билинейную форму от dX , dX_1 , выписывать тензор производных в явном виде мы не будем. Вместо этого посмотрим, является ли эта форма отрицательно полуопределённой. В следующих параграфах станет понятно, зачем мы проверяем это условие. Возьмём $H \in \mathbb{S}^d$ из исходного пространства. Поскольку $X \in \mathbb{S}_{++}^d$, то $X^{-1} \in \mathbb{S}_{++}^d$. Матрицу X^{-1} можно разложить на произведение двух одинаковых матриц, обозначим их $X^{-1/2}$, то есть $X^{-1} = X^{-1/2} X^{-1/2}$. Такое разложение можно получить, перейдя в ортонормированный базис из собственных векторов V , который всегда существует для симметричных матриц, при этом все собственные значения будут положительными:

$$X^{-1} = V \Lambda V^\top \implies X^{-1/2} = V \sqrt{\Lambda} V^\top.$$

Тогда

$$\begin{aligned} d^2 f(X) [H, H] &= -\langle X^{-1} H X^{-1}, H \rangle = -\text{Tr}(X^{-1} H X^{-1} H) \\ &= -\text{Tr}(X^{-1/2} X^{-1/2} H X^{-1/2} X^{-1/2} H) \\ &= -\text{Tr}(X^{-1/2} H X^{-1/2} X^{-1/2} H X^{-1/2}) \\ &= -\langle X^{-1/2} H X^{-1/2}, X^{-1/2} H X^{-1/2} \rangle \\ &= -\|X^{-1/2} H X^{-1/2}\|_F^2 \leq 0. \end{aligned}$$

■

Пример C2.13. Найдите $\nabla f(X)$ функции $f: \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$f(X) = \det(AX^{-1}B), \quad A \in \mathbb{R}^{n \times d}, B \in \mathbb{R}^{d \times n},$$

при $\det(AX^{-1}B) \neq 0$.

Решение. Найдём первый дифференциал

$$\begin{aligned}
df(X) &= d(\det(AX^{-1}B)) = \det(AX^{-1}B) \left\langle (AX^{-1}B)^{-\top}, d(AX^{-1}B) \right\rangle \\
&= \det(AX^{-1}B) \left\langle (AX^{-1}B)^{-\top}, A dX^{-1}B \right\rangle \\
&= -\det(AX^{-1}B) \left\langle (AX^{-1}B)^{-\top}, AX^{-1} dX X^{-1}B \right\rangle \\
&= -\det(AX^{-1}B) \operatorname{Tr}\left((AX^{-1}B)^{-1} AX^{-1} dX X^{-1}B\right) \\
&= -\det(AX^{-1}B) \operatorname{Tr}\left(X^{-1}B(AX^{-1}B)^{-1} AX^{-1} dX\right) \\
&= -\det(AX^{-1}B) \left\langle \left(X^{-1}B(AX^{-1}B)^{-1} AX^{-1}\right)^{\top}, dX \right\rangle.
\end{aligned}$$

Тогда градиент

$$\nabla f(X) = -\det(AX^{-1}B) X^{-\top} A^{\top} (AX^{-1}B)^{-\top} B^{\top} X^{-\top}.$$

■

С2.3.3 Другие примеры

Помимо классических примеров, когда нужно продифференцировать функцию по вектору/матрице, проводя алгоритмические действия, бывают и менее тривиальные. В этом разделе мы посвятим их рассмотрению немного времени.

В нейронных сетях часто встречается функция softmax, которая позволяет отобразить вектор из d координат в распределение вероятностей на d исходах (Параграф 2.4 из [5]):

$$\text{softmax}(x) := \left(\frac{\exp(x_1)}{\sum_{i=1}^d \exp(x_i)}, \dots, \frac{\exp(x_d)}{\sum_{i=1}^d \exp(x_i)} \right)^{\top}.$$

Пример С2.14. Найдите матрицу Якоби $J(x)$ функции $s : \mathbb{R}^d \rightarrow \mathbb{R}^d$:

$$s(x) = \left(\frac{\exp(x_1)}{\sum_{i=1}^d \exp(x_i)}, \dots, \frac{\exp(x_d)}{\sum_{i=1}^d \exp(x_i)} \right)^{\top}.$$

Решение. Считаем частные производные по определению

- При $k \neq j$

$$\frac{\partial s_k}{\partial x_j} = \frac{\partial}{\partial x_j} \frac{\exp(x_k)}{\sum_{i=1}^d \exp(x_i)} = -\frac{\exp(x_k) \exp(x_j)}{\left(\sum_{i=1}^d \exp(x_i)\right)^2} = -s_k \cdot s_j,$$

- при $k = j$

$$\begin{aligned}
\frac{\partial s_j}{\partial x_j} &= \frac{\partial}{\partial x_j} \frac{\exp(x_j)}{\sum_{i=1}^d \exp(x_i)} = \frac{\exp(x_j) \left(\sum_{i=1}^d \exp(x_i)\right) - \exp(x_j) \frac{\partial}{\partial x_j} \left(\sum_{i=1}^d \exp(x_i)\right)}{\left(\sum_{i=1}^d \exp(x_i)\right)^2} \\
&= \frac{\exp(x_j)}{\sum_{i=1}^d \exp(x_i)} - \frac{\exp(x_j) \exp(x_j)}{\left(\sum_{i=1}^d \exp(x_i)\right)^2} = s_j(1 - s_j).
\end{aligned}$$

Таким образом, получаем

$$J_{k,j} = \begin{cases} -s_k \cdot s_j, & k \neq j; \\ s_j(1 - s_j), & k = j. \end{cases}$$

■

Не менее часто на практике приходится применять какую-либо функцию поэлементно.

Пример C2.15. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = h(g(x)),$$

где функция $g : \mathbb{R} \rightarrow \mathbb{R}$ действует поэлементно:

$$g(x) = \sin(x),$$

а функция $h : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$h(u) = \sum_{i=1}^d u_i.$$

Решение. Вспомним правило матрицы Якоби сложной функции:

$$J_f(x) = J_h(u)J_g(x) \implies \nabla f(x) = J_g^\top(x)\nabla h(u).$$

Далее посчитаем матрицу Якоби функции вида $g(x) = \begin{pmatrix} g(x_1) \\ \vdots \\ g(x_d) \end{pmatrix}$. Получим

$$J_g(x) = \text{diag}(g'(x_1), \dots, g'(x_d)) = \text{diag}(g'(x)) = J_g^\top(x).$$

При умножении $J_g(x)$ на вектор удобно пользоваться поэлементным умножением матриц:

$$(A \odot B)_{ij} = A_{ij} \cdot B_{ij}.$$

Результат умножения $J_g(x)$ на вектор y равен

$$J_g(x)y = \begin{pmatrix} g'(x_1) \\ \vdots \\ g'(x_d) \end{pmatrix} \odot y = g'(x) \odot y.$$

Заметим, что эта операция является довольно быстро вычислимой и легко поддаётся параллелизации. Теперь приступим непосредственно к примеру. Найдём $J_g(x)$:

$$J_g(x) = \text{diag}(\cos(x_1), \dots, \cos(x_d)) = \text{diag}(\cos(x)).$$

Теперь найдём $\nabla h(u)$:

$$\nabla h(u) = \mathbf{1}.$$

Тогда $\nabla f(x)$:

$$\nabla f(x) = J_g^\top(x)\nabla h(u) = \cos(x) \odot \mathbf{1} = \cos(x).$$

Выпишем гессиан функции:

$$\nabla^2 f(x) = J_{\nabla f}^\top(x) = \text{diag}(-\sin(x)).$$

■

Пример С2.16. Выразите $\phi'(\alpha)$ и $\phi''(\alpha)$ функции $\phi : \mathbb{R} \rightarrow \mathbb{R}$:

$$\phi(\alpha) = f(x + \alpha p), \quad x, p \in \mathbb{R}^d$$

через $\nabla f, \nabla^2 f$ дважды непрерывно дифференцируемой функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$.

Решение. Важно помнить, что дифференцирование происходит не по стандартному вектору x , а по скаляру α со всеми вытекающими свойствами. Первый дифференциал

$$d\phi = \langle \nabla f(x + \alpha p), d(x + \alpha p) \rangle = \langle \nabla f(x + \alpha p), p \rangle d\alpha.$$

Заметим, что мы привели дифференциал к стандартному виду $d\phi = \phi'(\alpha) d\alpha$, то есть множитель перед $d\alpha$ — это производная:

$$\phi'(\alpha) = \langle \nabla f(x + \alpha p), p \rangle.$$

Дифференциал от первой производной:

$$\begin{aligned} d(\phi'(\alpha)) &= d\langle \nabla f(x + \alpha p), p \rangle = \langle (\nabla^2 f(x + \alpha p))^T d(x + \alpha p), p \rangle \\ &= \langle \nabla^2 f(x + \alpha p) p d\alpha, p \rangle = \langle \nabla^2 f(x + \alpha p) p, p \rangle d\alpha. \end{aligned}$$

Тогда вторая производная:

$$\phi''(\alpha) = \langle \nabla^2 f(x + \alpha p) p, p \rangle.$$

■

Теперь посмотрим на случай, когда функция переводит матрицу в вектор, и записать производные в компактном виде через матрицу или вектор не получится.

Пример С2.17. Найдите $\nabla f(X)$ функции $f : \mathbb{R}^{n \times d} \rightarrow \mathbb{R}^n$:

$$f(X) = Xa, \quad a \in \mathbb{R}^d.$$

Решение. Дифференциал найти достаточно просто:

$$df(X) = dX a.$$

Но вот записать производную в виде вектора или матрицы уже не выйдет — нужен тензор третьего порядка, имеющий вид

$$\frac{\partial f_k}{\partial X_{ij}}(X)$$

размерности $n \times n \times d$. Для этого выразим скалярную зависимость функции $f(X)$:

$$f_k(X) = \sum_{l=1}^d X_{kl} a_l.$$

Теперь возьмём производную $\frac{\partial}{\partial X_{ij}}$. Получим

$$\frac{\partial f_k}{\partial X_{ij}}(X) = \sum_{l=1}^d \frac{\partial (X_{kl} a_l)}{\partial X_{ij}} = \sum_{l=1}^d \delta(i=k, j=l) a_l = \delta(i=k) \sum_{l=1}^d \delta(j=l) a_l = \delta(i=k) a_j.$$

■

Пример C2.18. Рассмотрим прикладную задачу. Пусть имеется модель, которая для некоторого значения x возвращает y по правилу: $y = Ax + \varepsilon$, где $A \in \mathbb{R}^{n \times d}$ — некоторая матрица, а ε — некоторый шум. Чтобы не загромождать повествование техническими деталями, будем предполагать, что $\det(A^\top A) \neq 0$. Имея дело с такой моделью, мы хотим решить задачу:

$$\hat{x} = \operatorname{argmin}_{x: \hat{y} = Ax + \varepsilon} \|\varepsilon\|_2^2.$$

Мы хотим определять, какой вход модели был наиболее вероятен, если она выдала значение $\hat{y}$. Тогда, выразив $\varepsilon = \hat{y} - Ax$, будем искать минимум функции $\|\hat{y} - Ax\|_2^2$. Для этого нужно посчитать градиент и приравнять его к 0. Запишем

$$\begin{aligned} d\|\hat{y} - Ax\|_2^2 &= d\langle \hat{y} - Ax, \hat{y} - Ax \rangle = -\langle A dx, \hat{y} - Ax \rangle - \langle \hat{y} - Ax, A dx \rangle \\ &= -2\langle \hat{y} - Ax, A dx \rangle = -2\langle A^\top (\hat{y} - Ax), dx \rangle. \end{aligned}$$

Отсюда получаем, что градиент равен $\nabla f(x) = -2A^\top (\hat{y} - Ax)$. Приравнивая его к 0, имеем

$$\hat{x} = (A^\top A)^{-1} A^\top \hat{y}.$$

C2.4 Автоматическое дифференцирование

Настало время поговорить о том, как происходит подсчёт градиентов в реальной жизни. Чаще всего функции, с которыми приходится иметь дело на практике, представляют собой последовательность (дифференцируемых) параметрических преобразований. Таким образом, их можно представить в виде *вычислительного графа*, где промежуточным вершинам соответствуют преобразования, входящим стрелкам — входные переменные, а выходным стрелкам — результат преобразования. Этот граф должен быть ациклическим.




Рис. C2.1: Граф вычислений для логистической регрессии.

На Рисунке C2.1 сплошными линиями приведён вычислительный граф для логистической регрессии

$$f(x) = \log(1 + \exp(-b\langle x, a \rangle)),$$

где $a \in \mathbb{R}^d$, $b \in \{-1, 1\}$ — вход, а $x \in \mathbb{R}^d$ — параметр.

Вычисление значения функции по заданному входу называется *forward pass* (*прямым проходом*). На этом этапе происходит преобразование исходного вектора в целевой. Последовательно строятся промежуточные значения — результаты применения преобразований к предыдущим значениям слева направо. В случае линейного графа преобразование можно записать формулой

$$f(x) = u_n(u_{n-1}(\dots(u_1(x)))). \quad (\text{C2.1})$$

Но как же считать производные в таких графах? Ответ может дать правило вычисления дифференциала сложной функции. Рассмотрим одну конкретную вершину в графе вида $u(x_1, \dots, x_d)$ и её дифференциал

$$du = J_u dx,$$

причём каждый следующий дифференциал dx_i можно расписать через предыдущую вершину (если, конечно, x_i не являются искомыми переменными), двигаясь по рекурсии в графе от детей к родителям. В случае линейного графа (C2.1) получим итоговую формулу

$$\frac{\partial f}{\partial x}(x) = \frac{\partial u_1}{\partial x}(x) \cdot \frac{\partial u_2}{\partial u_1}(u_1) \cdot \dots \cdot \underbrace{\frac{\partial u_n}{\partial u_{n-1}}(u_{n-1})}_{\frac{\partial f}{\partial u_{n-1}}}. \quad (\text{C2.2})$$

C2.4.1 Backward propagation

Основная идея *backward propagation* (*обратного распространения ошибки*) заключается в подсчёте формулы (C2.2) **справа налево**.

В общем случае, пусть $u_1, \dots, u_n$ — вершины графа вычислений в топологическом порядке (то есть родители идут перед потомками). Тогда общий алгоритм действий выглядит так:

1. Произвести *forward pass* и сохранить все значения u_i как функции от их родителей;
2. Воспользоваться производной сложной функции:

$$J_{f(u)} = J_f J_u.$$

Или, что то же самое, для всех $i = \overline{n-1, 1}$ посчитать

$$\frac{\partial f}{\partial u_i} = \sum_{u_j \in \text{потомки}(u_i)} \frac{\partial u_j}{\partial u_i} \frac{\partial f}{\partial u_j}.$$

Вычисление *backward propagation* на Рисунке C2.1 показано пунктирными линиями.

Пример C2.19. Посчитайте *backward propagation* для графа, изображенного на Рисунке C2.2, где $x \in \mathbb{R}^d$ — вход, $\omega \in \mathbb{R}^d$, $b \in \mathbb{R}$ — параметры, а $\lambda, t \in \mathbb{R}$ — фиксированные константы.




Рис. С2.2: Граф вычислений для логистической регрессии с квадратичной ошибкой и ℓ_2 -регуляризацией.

Решение.

$$\begin{aligned}
 \frac{\partial \mathcal{L}}{\partial R} &= \frac{\partial \mathcal{L}}{\partial R} \frac{\partial \mathcal{L}}{\partial \mathcal{L}} = \lambda, \\
 \frac{\partial \mathcal{L}}{\partial L} &= \frac{\partial \mathcal{L}}{\partial L} \frac{\partial \mathcal{L}}{\partial \mathcal{L}} = 1, \\
 \frac{\partial \mathcal{L}}{\partial y} &= \frac{\partial L}{\partial y} \frac{\partial \mathcal{L}}{\partial L} = (y - t) \frac{\partial \mathcal{L}}{\partial L}, \\
 \frac{\partial \mathcal{L}}{\partial z} &= \frac{\partial y}{\partial z} \frac{\partial \mathcal{L}}{\partial y} = \sigma'(z) \frac{\partial \mathcal{L}}{\partial y}, \\
 \frac{\partial \mathcal{L}}{\partial \omega} &= \frac{\partial z}{\partial \omega} \frac{\partial \mathcal{L}}{\partial z} + \frac{\partial R}{\partial \omega} \frac{\partial \mathcal{L}}{\partial R} = x \frac{\partial \mathcal{L}}{\partial z} + \omega \frac{\partial \mathcal{L}}{\partial R}, \\
 \frac{\partial \mathcal{L}}{\partial b} &= \frac{\partial z}{\partial b} \frac{\partial \mathcal{L}}{\partial z} = \frac{\partial \mathcal{L}}{\partial z}.
 \end{aligned}$$

■

Это достаточно простой пример, в то время как на практике в основном встречаются отображения, действующие в пространствах матриц и векторов. Для лучшего понимания вычислим backward propagation в полносвязной нейронной сети (Параграф 4 из [4]).

Пример С2.20. Рассмотрим полносвязную нейронную сеть для задачи бинарной классификации с кросс-энтропийным лоссом:

$$\begin{aligned}
 \hat{y} &= \sigma(\sigma(XW_1)W_2), \\
 \mathcal{L}(y, \hat{y}) &= - \sum_{i=1}^n (y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)),
 \end{aligned}$$

где вход $X \in \mathbb{R}^{n \times d}$, $y \in \{0, 1\}^n$, параметры $W_1 \in \mathbb{R}^{d \times k}$, $W_2 \in \mathbb{R}^k$.




Рис. С2.3: Граф полносвязной нейронной сети.

Найдём производные по параметрам W_1, W_2 . Для удобства записи введём обозначения выходов промежуточных слоёв:

$$X_1 = XW_1, \quad X_2 = \sigma(X_1), \quad X_3 = X_2W_2.$$

1. Для начала найдём градиент функции потерь по $\hat{y}$ (все произведения покомпонентные):

$$\begin{aligned} d\mathcal{L}(\hat{y}) &= - \sum_{i=1}^n d(y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)) = \sum_{i=1}^n \left(-\frac{y_i}{\hat{y}_i} d\hat{y}_i + \frac{1 - y_i}{1 - \hat{y}_i} d\hat{y}_i \right) \\ &= \sum_{i=1}^n \frac{\hat{y}_i - y_i}{\hat{y}_i(1 - \hat{y}_i)} d\hat{y}_i. \end{aligned}$$

Тогда получаем:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}_i} = \frac{\hat{y}_i - y_i}{\hat{y}_i(1 - \hat{y}_i)}.$$

2. Воспользуемся Примером С2.15 для нахождения производной по X_3 , положив g — кросс-энтропией, а h — сигмодой:

$$\frac{\partial \mathcal{L}}{\partial X_3} = \sigma'(X_3) \odot \frac{\partial \mathcal{L}}{\partial \hat{y}} = \sigma(X_3)(1 - \sigma(X_3)) \odot \frac{\partial \mathcal{L}}{\partial \hat{y}}.$$

3. Отсюда уже можно найти $\frac{\partial \mathcal{L}}{\partial W_2}$:

$$\frac{\partial \mathcal{L}}{\partial W_2} = \frac{\partial X_3}{\partial W_2} \frac{\partial \mathcal{L}}{\partial X_3} = X_2^\top \frac{\partial \mathcal{L}}{\partial X_3}.$$

4. Аналогично можно найти $\frac{\partial \mathcal{L}}{\partial X_2}$:

$$\frac{\partial \mathcal{L}}{\partial X_2} = \frac{\partial X_3}{\partial X_2} \frac{\partial \mathcal{L}}{\partial X_3} = \frac{\partial \mathcal{L}}{\partial X_3} W_2^\top.$$

5. Снова ищем градиент для композиции с сигмодой:

$$\frac{\partial \mathcal{L}}{\partial X_1} = \sigma'(X_1) \odot \frac{\partial \mathcal{L}}{\partial X_2} = \sigma(X_1)(1 - \sigma(X_1)) \odot \frac{\partial \mathcal{L}}{\partial X_2}.$$

6. Последний шаг проделываем по аналогии с 3:

$$\frac{\partial \mathcal{L}}{\partial W_1} = \frac{\partial X_1}{\partial W_1} \frac{\partial \mathcal{L}}{\partial X_1} = X^\top \frac{\partial \mathcal{L}}{\partial X_1}.$$

- Для подсчёта backward propagation необходимо хранить все промежуточные значения u_i на всех итерациях алгоритма. Это может быть существенным требованием к памяти, например в больших нейронных сетях.
- Необязательно полностью считать производную $\frac{\partial u_j}{\partial u_i}$, важно уметь быстро превращать градиент по выходу в градиент по входу. Об этом будет рассказано в разделе C2.4.3.
- Отдельно стоит отметить нейронные сети, которые состоят из блоков. Одному блоку совершенно не надо знать, что происходит вокруг. То есть он может быть запрограммирован как отдельная сущность, умеющая внутри себя делать forward pass и backward propagation, после чего блоки механически, как кубики в конструкторе, собираются в большую сеть, которая работает как одно целое.
- Вычисление градиента можно представить через ещё один граф вычислений, тем самым, сделав уже backward propagation по графу градиента. Так можно считать гессианы и производные высших порядков.

C2.4.2 Forward propagation

Может возникнуть желание посчитать формулу (C2.2) не справа налево, а **слева направо**, распространяя производную в графе в направлении forward pass: от родителей к детям. Так производная по параметрам x будет считаться как

$$\frac{\partial u_i}{\partial x} = \sum_{u_j \in \text{родители}(u_i)} \frac{\partial u_j}{\partial x} \frac{\partial u_i}{\partial u_j}.$$

При этом можно совершать проход вместе с подсчётом u_i и нужно будет хранить только один слой графа.

Пример C2.21. Посчитайте forward propagation для графа из Примера C2.19.

Решение.

$$\begin{aligned} \frac{\partial R}{\partial \omega} &= \omega, & \frac{\partial z}{\partial b} &= 1, \\ \frac{\partial z}{\partial \omega} &= x, & \frac{\partial y}{\partial b} &= \frac{\partial z}{\partial b} \sigma'(z), \\ \frac{\partial y}{\partial \omega} &= \frac{\partial z}{\partial \omega} \sigma'(z), & \frac{\partial L}{\partial b} &= \frac{\partial y}{\partial b} \cdot (y - t), \\ \frac{\partial L}{\partial \omega} &= \frac{\partial y}{\partial \omega} \cdot (y - t), & \frac{\partial \mathcal{L}}{\partial b} &= \frac{\partial L}{\partial b}. \\ \frac{\partial \mathcal{L}}{\partial \omega} &= \frac{\partial L}{\partial \omega} + \lambda \frac{\partial R}{\partial \omega}. \end{aligned}$$

■

- В forward propagation нужно хранить производные $\frac{\partial u_i}{\partial x}$, а в backward propagation — $\frac{\partial f}{\partial u_i}$.
- Если размерность входа x намного больше, чем размерность выхода $f(x)$, то на каждом шаге forward propagation нужно будет хранить и обсчитывать больше данных, чем в backward propagation. На практике встречается именно этот вариант.

- Если, наоборот, размерность выхода функции $f(x)$ намного больше, чем размерность входа x , то выгоднее использовать forward propagation.

C2.4.3 Умножение гессиана на вектор и матрицы Якоби на строку

Пусть дана дважды непрерывно дифференцируемая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Покажем, как можно эффективно считать

$$\nabla^2 f(x) \cdot u$$

для любого вектора $u \in \mathbb{R}^d$. Считать полный гессиан и умножать его на вектор неэффективно, особенно при большой размерности d . Но заметим, что

$$d\langle \nabla f(x), u \rangle = \langle J_{\nabla f}(x) dx, u \rangle = \langle \nabla^2 f(x) u, dx \rangle = \langle \nabla g(x), dx \rangle,$$

где $g(x) = \langle \nabla f(x), u \rangle$. Таким образом, вместо полного гессиана можно найти градиент функции вида $g(x)$, с которым могут справиться библиотеки автоматического дифференцирования `jax/autograd/pytorch/tensorflow`.

Аналогично для функции вида $f : \mathbb{R}^d \rightarrow \mathbb{R}^n$ и вектора $u \in \mathbb{R}^n$ считается значение $\nabla f(x) \cdot u$:

$$d\langle f(x), u \rangle = \langle J_f(x) dx, u \rangle = \langle \nabla f(x) u, dx \rangle = \langle \nabla g(x), dx \rangle,$$

где $g(x) = \langle f(x), u \rangle$.

Именно поэтому backward propagation можно эффективно реализовать на практике.

С3 Классы множеств

Теоретический анализ широкого множества методов оптимизации задействует предположения, которые можно ввести только на множествах, обладающих «хорошими» геометрическими свойствами. Неформально говоря, требуется, чтобы рассматриваемое множество, из которого выбираются параметры, не имело «впадин» или разрывов. Формальное описание такого множества дает понятие выпуклости.

С3.1 Выпуклые множества

Определение С3.1. Множество $S \subseteq \mathbb{R}^d$ называется *выпуклым*, если для любых двух точек $x_1, x_2 \in S$ и любого числа $\alpha \in [0, 1]$, точка $\alpha x_1 + (1 - \alpha)x_2$ также принадлежит S .

Интуитивно это означает, что отрезок, соединяющий любые две точки множества, полностью лежит во множестве.




Рис. С3.1: Выпуклое множество.




Рис. С3.2: Невыпуклое множество.

Замечание С3.1. Здесь и далее вместо $\mathbb{R}^d$ можно рассматривать и другие пространства, которые изоморфны $\mathbb{R}^d$, например, матричное пространство $\mathbb{R}^{d \times n}$ или пространство симметричных матриц $\mathbb{S}^d$.

Пример С3.1. Пусть $a \in \mathbb{R}^d \setminus \{0\}$, $b \in \mathbb{R}$. Покажите, что полуплоскость

$$S(a, b) = \left\{ x \mid a^\top x \geq b \right\}$$

является выпуклым множеством.

Решение. Пусть $x_1, x_2 \in S(a, b)$, тогда $a^\top x_1 \geq b$ и $a^\top x_2 \geq b$. Покажем, что для любого $\alpha \in [0, 1]$ выполняется $a^\top (\alpha x_1 + (1 - \alpha)x_2) \geq b$:

$$a^\top (\alpha x_1 + (1 - \alpha)x_2) = \alpha a^\top x_1 + (1 - \alpha)a^\top x_2 \geq \alpha b + (1 - \alpha)b = b.$$

Следовательно, всякий отрезок между x_1 и x_2 также принадлежит полуплоскости. ■

Пример С3.2. Пусть $a, b \in \mathbb{R}^d$ — различные точки. Покажите, что полуплоскость Вороного, то есть множество всех точек, которые ближе к a , чем к b в евклидовой норме:

$$V(a, b) = \left\{ x \in \mathbb{R}^d \mid \|x - a\|_2 \leq \|x - b\|_2 \right\}$$

является выпуклым множеством.

Решение. Перепишем множество $V(a, b)$:

$$\begin{aligned}\|x - a\|_2^2 \leq \|x - b\|_2^2 &\iff (x - a)^\top (x - a) \leq (x - b)^\top (x - b) \\ &\iff x^\top x - 2a^\top x + a^\top a \leq x^\top x - 2b^\top x + b^\top b \\ &\iff 2(b - a)^\top x \leq b^\top b - a^\top a.\end{aligned}$$

Таким образом, множество $V(a, b)$ является полуплоскостью, а то, что полуплоскость — выпуклое множество, было показано в Примере С3.1. ■

Пример С3.3. Пусть $\|\cdot\|$ — норма в $\mathbb{R}^d$, $r > 0$ и $c \in \mathbb{R}^d$. Покажите, что шар

$$\overline{B}(c, r) = \left\{ x \in \mathbb{R}^d \mid \|x - c\| \leq r \right\}$$

является выпуклым множеством.

Решение. Пусть $x_1, x_2 \in \overline{B}(c, r)$. Тогда

$$\begin{aligned}\|\alpha x_1 + (1 - \alpha)x_2 - c\| &= \|\alpha(x_1 - c) + (1 - \alpha)(x_2 - c)\| \\ &\leq \alpha\|x_1 - c\| + (1 - \alpha)\|x_2 - c\| \\ &\leq \alpha r + (1 - \alpha)r = r.\end{aligned}$$

Следовательно, $\alpha x_1 + (1 - \alpha)x_2 \in \overline{B}(c, r)$. ■

Пример С3.4. Пусть $\|\cdot\|$ — норма в $\mathbb{R}^d$, $r > 0$ и $c \in \mathbb{R}^d$. Покажите, что сфера

$$S(c, r) = \left\{ x \in \mathbb{R}^d \mid \|x - c\| = r \right\}$$

не является выпуклым множеством.

Решение. Возьмём две диаметрально противоположные точки $x + c$ и $-x + c$ такие, что $\|x\| = r$. Тогда c является их средним арифметическим, но он не принадлежит S . Получили противоречие. ■

Пример С3.5. Покажите, что множество всех положительно полуопределённых матриц $\mathbb{S}_+^d$ является выпуклым.

Решение. Пусть $X_1, X_2 \in \mathbb{S}_+^d$ и $\alpha \in [0, 1]$, тогда матрица $\alpha X_1 + (1 - \alpha)X_2$ принадлежит $\mathbb{S}_+^d$. Покажем это, взяв произвольный $z \in \mathbb{R}^d$:

$$z^\top (\alpha X_1 + (1 - \alpha)X_2) z = \alpha z^\top X_1 z + (1 - \alpha)z^\top X_2 z \geq 0.$$

■

Пример С3.6. Покажите, что множество матриц 100×100 ранга хотя бы 2, у которых все элементы неотрицательные, является невыпуклым.

Решение. Пусть A — верхнетреугольная матрица, у которой все элементы на диагонали и выше равны 1, а $B = 11^\top - A$ — дополняющая её нижнетреугольная матрица. Легко заметить, что у матриц A и B ранг хотя бы 2, но у матрицы $\frac{1}{2}A + \frac{1}{2}B = \frac{1}{2}11^\top$ ранг 1. ■

Пример С3.7. Покажите, что множество

$$M = \{ x \in \mathbb{R}_{++}^2 \mid x_1 x_2 \geq 1 \}$$

является выпуклым.

Решение. Пусть $x, y \in M$. Рассмотрим $\alpha x + (1 - \alpha)y$, где $\alpha \in [0, 1]$:

$$\begin{aligned} (\alpha x_1 + (1 - \alpha)y_1)(\alpha x_2 + (1 - \alpha)y_2) &= \alpha^2 x_1 x_2 + \alpha(1 - \alpha)(x_1 y_2 + x_2 y_1) + (1 - \alpha)^2 y_1 y_2 \\ &\geq \alpha^2 + 2\alpha(1 - \alpha)\sqrt{x_1 x_2 y_1 y_2} + (1 - \alpha)^2 \geq 1. \end{aligned}$$

Таким образом, точка $\alpha x + (1 - \alpha)y \in M$, значит M выпукло. ■

Пример С3.8. Покажите, что множество

$$M = \{ x \in \mathbb{R}_{++}^2 \mid \sqrt{x_1} + x_2 \geq 1 \}$$

является выпуклым.

Решение. Мы будем использовать следующий несложный факт: если $z_1, z_2 > 0$ и $\alpha \in [0, 1]$, то

$$\sqrt{\alpha z_1 + (1 - \alpha)z_2} \geq \alpha\sqrt{z_1} + (1 - \alpha)\sqrt{z_2}.$$

Вообще говоря, это неравенство Йенсена (0.1) для вогнутой функции, но оно будет пройдено позже, поэтому его можно просто проверить возведением обеих частей неравенства в квадрат.

Пусть $x, y \in M$. Рассмотрим $\alpha x + (1 - \alpha)y$, где $\alpha \in [0, 1]$:

$$\begin{aligned} \sqrt{\alpha x_1 + (1 - \alpha)y_1} + \alpha x_2 + (1 - \alpha)y_2 &\geq \alpha\sqrt{x_1} + (1 - \alpha)\sqrt{y_1} + \alpha x_2 + (1 - \alpha)y_2 \\ &\geq \alpha + (1 - \alpha) = 1. \end{aligned}$$

Таким образом, точка $\alpha x + (1 - \alpha)y \in M$, значит M выпукло. ■

Определение позволяет проверять выпуклость некоторых наиболее простых множеств. В случае, когда множество имеет более сложную структуру, пользоваться определением может быть затруднительно. В связи с этим, требуется расширить математический аппарат анализа выпуклых множеств.

Утверждение С3.1. Пусть $S \subseteq \mathbb{R}^d$ — выпуклое множество. Тогда $\text{int } S$ (внутренность) и $\text{cl } S$ (замыкание) также являются выпуклыми множествами.

Доказательство.

- Внутренность S (множество всех точек S , содержащихся в нём с некоторой окрестностью).

Пусть $x, y \in \text{int } S$. По определению внутренней точки существуют радиусы r_x и r_y такие, что открытые шары $B(x, r_x)$ и $B(y, r_y)$ полностью содержатся в S . Рассмотрим отрезок, соединяющий x и y . Для любой точки $z \in [x, y]$ можно построить такой шар $B(z, r_z)$, который полностью лежит в S . Действительно, поскольку шары $B(x, r_x)$, $B(y, r_y)$ содержатся в выпуклом множестве S , то отрезки, соединяющие их точки, также лежат в S . То есть можно выбрать $r_z = \min\{r_x, r_y\}$ и гарантировать принадлежность S шара с таким радиусом. Таким образом, все

точки отрезка $[x, y]$ являются внутренними точками S , поэтому $\text{int } S$ является выпуклым множеством.




Рис. С3.3: Иллюстрация выпуклости внутренности множества.

- Замыкание S (множество всех пределов последовательностей из S).

Пусть $x, y \in \text{cl } S$. Тогда найдутся последовательности $\{x_k\}_{k=1}^{\infty} \subseteq S$ и $\{y_k\}_{k=1}^{\infty} \subseteq S$ такие, что $x_k \rightarrow x$ и $y_k \rightarrow y$. Таким образом, для любого $\alpha \in [0, 1]$ последовательность $\{\alpha x_k + (1 - \alpha)y_k\}_{k=1}^{\infty} \subseteq S$ и $\alpha x_k + (1 - \alpha)y_k \rightarrow \alpha x + (1 - \alpha)y \in \text{cl } S$.

■

Приведем пример, иллюстрирующий это утверждение.

Пример С3.9. Множество положительно определённых матриц $\mathbb{S}_{++}^d$ является выпуклым.

Доказательство. Ранее в Примере С3.5 мы показали выпуклость $\mathbb{S}_+^d$. Теперь рассмотрим $A \in \mathbb{S}_{++}^d$. Из положительной определённости имеем

$$x^\top A x \geq \lambda_{\min}(A), \quad \forall x \in \mathbb{R}^d, \quad \|x\|_2 = 1.$$

Покажем, что A содержится в $\mathbb{S}_+^d$ с некоторой окрестностью. Зафиксируем ненулевое возмущение $E \in \mathbb{S}^d$. Рассмотрим действие квадратичной формы $A + tE$ на вектор $x \in \mathbb{R}^d$ единичной евклидовой нормы при $t > 0$:

$$x^\top (A + tE) x = x^\top A x + tx^\top E x \geq \lambda_{\min}(A) + tx^\top E x.$$

Воспользуемся неравенством Коши–Буняковского–Шварца:

$$|x^\top E x| \leq \|E\|_2.$$

Таким образом, имеем

$$x^\top (A + tE) x \geq \lambda_{\min}(A) - t\|E\|_2.$$

Выбрав $t \leq \frac{\lambda_{\min}(A)}{\|E\|_2}$, получим, что

$$x^\top (A + tE)x \geq 0.$$

Таким образом, $\mathbb{S}_{++}^d \subseteq \text{int } \mathbb{S}_{+}^d$.

Теперь докажем обратное включение. Предположим, что матрица A имеет $\lambda_{\min}(A) = 0$. Это означает, что существует вектор x единичной евклидовой нормы, такой, что

$$Ax = 0.$$

Для $t > 0$ рассмотрим возмущение $A - txx^\top$. Тогда имеем

$$x^\top (A - txx^\top)x = x^\top Ax - t = -t < 0.$$

Это доказывает $\text{int } \mathbb{S}_{+}^d \subseteq \mathbb{S}_{++}^d$. Тогда $\mathbb{S}_{++}^d$ выпукло как внутренность выпуклого множества. ■


Замечание С3.2. Отметим, что выпуклость $\mathbb{S}_{++}^d$ может быть проверена значительно проще по определению, и пример выше следует воспринимать как искусственный.

С3.2 Размерность множеств


Возникает вопрос, как определить размерность выпуклого множества. Сделать это формально помогает понятие аффинной оболочки множества.

Определение С3.2. Аффинной оболочкой множества $S \subseteq \mathbb{R}^d$ будем называть множество вида

$$\text{aff } S = \bigcup_{k \in \mathbb{N}} \left\{ \sum_{i=1}^k \alpha_i x_i \mid \sum_{i=1}^k \alpha_i = 1, \alpha_i \in \mathbb{R}, x_i \in S \right\}.$$



(a) Аффинная оболочка двух точек:
 $y + \lambda(x - y)$.



(b) Аффинная оболочка трёх точек:
 $y + \lambda_1(x - y) + \lambda_2(z - y)$.

Рис. С3.4: Аффинная оболочка через базисные векторы.

Аффинная оболочка имеет «хорошую» геометрию. Оказывается, что это «сдвинутое» линейное подпространство.

Теорема С3.1. Аффинная оболочка $\text{aff } S$ множества $S \subseteq \mathbb{R}^d$ имеет вид

$$\text{aff } S = s + L_S,$$

где $s \in \text{aff } S$ — произвольная точка из аффинной оболочки; L_S — линейное подпространство (непустое подмножество $\mathbb{R}^d$, которое само является линейным пространством по отношению к операциям, определенным на $\mathbb{R}^d$), причём L_S единственное.

Доказательство. Зафиксируем $s \in \text{aff } S$. Положим

$$L_S = \left\{ x \in \mathbb{R}^d \mid x = y - s, y \in \text{aff } S \right\}.$$

Докажем, что L_S действительно линейное подпространство. Пусть $x \in L_S$, тогда $x = y - s$, где $y \in \text{aff } S$. По определению аффинной оболочки имеем $\lambda y + (1 - \lambda)s \in \text{aff } S$. Тогда

$$\lambda x = \lambda(y - s) = \lambda y + (1 - \lambda)s - s \in L_S.$$

Это доказывает замкнутость относительно операции умножения. Рассмотрим теперь $x_1 = y_1 - s$, $x_2 = y_2 - s \in L_S$, где $y_1, y_2 \in \text{aff } S$. Так как

$$\frac{y_1 + y_2}{2} \in \text{aff } S,$$

то

$$\frac{x_1 + x_2}{2} = \frac{y_1 + y_2}{2} - s \in L_S.$$

Домножив равенство на 2, получаем замкнутость L_S относительно операции сложения. Остаётся показать единственность. Выберем другую точку $\tilde{s} \in \text{aff } S$ и определим линейное пространство M_S аналогично L_S . Имеем

$$\tilde{s} + L_S = s + (\tilde{s} - s) + L_S = s + L_S = \text{aff } S.$$

Таким образом, $L_S = M_S$. ■

Итак, мы определили аффинную оболочку точек, которая является сдвинутым линейным подпространством. Естественно определить $\dim S = \dim \text{aff } S = \dim L_S$.

С3.3 Выпуклая оболочка

Определение С3.3. Выпуклой комбинацией точек $x_1, \dots, x_k \in \mathbb{R}^d$ называется любая точка вида

$$\sum_{i=1}^k \alpha_i x_i,$$

где $\sum_{i=1}^k \alpha_i = 1$, $\alpha_i \geq 0$.

Утверждение С3.2. Если $S \subseteq \mathbb{R}^d$ является выпуклым множеством и $x_1, \dots, x_k \in S$, то любая выпуклая комбинация точек $x_1, \dots, x_k$ также принадлежит S .

Решение. Доказательство проведем индукцией по k .

- База при $k = 2$ верна, поскольку тогда это определение выпуклого множества.
- Пусть утверждение верно для $k-1$. Рассмотрим $x_1, \dots, x_k \in S$, и пусть $\alpha_1, \dots, \alpha_k$ таковы, что $\alpha_1 + \dots + \alpha_k = 1$ и $0 \leq \alpha_i \leq 1$. Если $\alpha_k = 1$, то утверждение очевидно, поскольку тогда имеем комбинацию из одной точки. В противном случае перепишем комбинацию:

$$\alpha_1 x_1 + \dots + \alpha_k x_k = (1 - \alpha_k) \left(\frac{\alpha_1}{1 - \alpha_k} x_1 + \dots + \frac{\alpha_{k-1}}{1 - \alpha_k} x_{k-1} \right) + \alpha_k x_k,$$

где каждое слагаемое $\frac{\alpha_i}{1 - \alpha_k}$ лежит в интервале $[0, 1]$, а их сумма равна 1. По предположению индукции

$$\hat{x}_{k-1} = \frac{\alpha_1}{1 - \alpha_k} x_1 + \dots + \frac{\alpha_{k-1}}{1 - \alpha_k} x_{k-1} \in S.$$

Комбинация из двух точек $\hat{x}_{k-1}$ и x_k принадлежит S по определению выпуклого множества. ■

Определение С3.4. Выпуклой оболочкой множества $S \subseteq \mathbb{R}^d$ будем называть множество всех выпуклых комбинаций элементов S :

$$\text{conv } S = \bigcup_{k \in \mathbb{N}} \left\{ \sum_{i=1}^k \alpha_i x_i \mid \sum_{i=1}^k \alpha_i = 1, \alpha_i \geq 0, \alpha_i \in \mathbb{R}, x_i \in S \right\}.$$

Замечание С3.3. Так как $\text{conv } S \subseteq \text{aff } S$, то $\dim S = \dim \text{conv } S = \dim \text{aff } S = \dim L_S$.

Утверждение С3.3. Выпуклая оболочка множества $S \subseteq \mathbb{R}^d$ — выпуклое множество.

Доказательство. Рассмотрим две точки $x, y \in \text{conv } S$:

$$x = \sum_{i=1}^k \alpha_i x_i, \quad y = \sum_{j=1}^n \beta_j x_j$$

и соединяющий их отрезок:

$$z = \lambda x + (1 - \lambda)y, \quad \lambda \in [0, 1].$$

Заметим, что $\lambda \alpha_i \geq 0$ и $(1 - \lambda)\beta_j \geq 0$. Более того, имеем

$$\sum_{i=1}^k \lambda \alpha_i + \sum_{j=1}^n (1 - \lambda)\beta_j = \lambda + (1 - \lambda) = 1.$$

Таким образом, z — выпуклая комбинация точек S , а значит, принадлежит $\text{conv } S$ по определению. ■

Утверждение С3.4. Пусть $S, T \subseteq \mathbb{R}^d$. Тогда верны следующие утверждения:

1. $S \subseteq \text{conv } S$;
2. $S \subseteq T \rightarrow \text{conv } S \subseteq \text{conv } T$;
3. S является выпуклым тогда и только тогда, когда $S = \text{conv } S$.

Доказательство. Докажем каждый пункт по отдельности.

1. Точка $x \in S$ принадлежит $\text{conv } S$ по Определению С3.4. Таким образом, $S \subseteq \text{conv } S$.
2. Пусть $S \subseteq T$. Поскольку выпуклая комбинация согласно Определению С3.4 строится по всевозможным выпуклым комбинациям всевозможных точек множества, то в $\text{conv } T$ содержатся те же комбинации, что и в $\text{conv } S$. Таким образом, имеем $\text{conv } S \subseteq \text{conv } T$.
3. Вложение $S \subseteq \text{conv } S$ доказано в первом пункте утверждения. Вложение $S \supseteq \text{conv } S$ следует из Утверждения С3.2. Таким образом, если S выпукло, то $S = \text{conv } S$.

■

Теорема С3.2. Выпуклая оболочка $S \subseteq \mathbb{R}^d$ является пересечением всех выпуклых множеств, содержащих S .

Доказательство. Пусть T — пересечение всех выпуклых множеств, содержащих S .

⊖ Рассмотрим $y \in \text{conv } S$:

$$y = \sum_{i=1}^k \alpha_i x_i \in \text{conv } S.$$

Поскольку $S \subseteq T$ по определению множества T , то имеем $x_i \in T$ для любых $i = \overline{1, k}$. Это означает, что $y \in \text{conv } T$ как выпуклая комбинация точек T . По определению T имеем $T = \bigcap_i T_i$ — пересечение всех выпуклых множеств, содержащих S . Пусть $x, y \in \bigcap_i T_i$, тогда $\alpha x + (1 - \alpha)y \in T_i$ для любого i , значит, эта точка лежит в пересечении. Таким образом, T — выпуклое множество и $T = \text{conv } T$ согласно Утверждению С3.4. Следовательно, $y \in T$, откуда следует, что $\text{conv } S \subseteq T$.

⊖ $\text{conv } S$ является выпуклым множеством согласно Утверждению С3.3. Отсюда следует, что $T \subseteq \text{conv } S$.

■

Пример С3.10. Докажите, что

$$S = \text{conv} \left\{ xx^\top, x \in \mathbb{R}^d \mid \|x\|_2 = 1 \right\} = \left\{ A \in \mathbb{S}_+^d \mid \text{Tr}(A) = 1 \right\} = T.$$

Доказательство.

⊖ Докажем, что $S \subseteq T$. Рассмотрим $x \in \mathbb{R}^d : \|x\|_2 = 1$. Пользуясь Утверждением С1.5, покажем, что след матрицы $xx^\top$ равен 1:

$$\text{Tr}(xx^\top) = \text{Tr}(x^\top x) = \|x\|_2^2 = 1.$$

Кроме того, очевидно, что $xx^\top \in \mathbb{S}_+^d$. Действительно, для произвольного $v \in \mathbb{R}^d$ имеем

$$v^\top xx^\top v = \|v^\top x\|_2^2 \geq 0.$$

Теперь рассмотрим матрицу $A \in \text{conv} \{ xx^\top \mid x \in \mathbb{R}^d, \|x\|_2 = 1 \}$. Поскольку выпуклая оболочка — множество всевозможных выпуклых комбинаций, имеем

$$A = \alpha_1 x_1 x_1^\top + \alpha_2 x_2 x_2^\top + \dots + \alpha_k x_k x_k^\top,$$

где $\alpha_1 + \alpha_2 + \dots + \alpha_k = 1$, $\alpha_i \geq 0$ и $\|x_i\|_2 = 1$. Поэтому, используя линейность следа, получим $\text{Tr}(A) = 1$. Более того, она положительно полуопределённая в силу положительной полуопределённости каждого из слагаемых и неотрицательности α_i .

⊖ Докажем, что $S \supseteq T$. Пусть $A \in \mathbb{S}_+^d$ и $\text{Tr}(A) = 1$. Матрица A симметричная, значит у неё есть базис из собственных векторов и она диагонализуема:

$$A = V \text{diag}(\lambda_1, \dots, \lambda_d) V^\top,$$

где V — ортогональная матрица. Заметим, что

$$1 = \text{Tr}(A) = \text{Tr}(V \text{diag}(\lambda_1, \dots, \lambda_d) V^\top).$$

Пользуясь Утверждением C1.5, запишем

$$\text{Tr}(V \text{diag}(\lambda_1, \dots, \lambda_d) V^\top) = \text{Tr}(V^\top V \text{diag}(\lambda_1, \dots, \lambda_d)) = \text{Tr}(\text{diag}(\lambda_1, \dots, \lambda_d)).$$

Таким образом, имеем

$$1 = \text{Tr}(\text{diag}(\lambda_1, \dots, \lambda_d)) = \lambda_1 + \lambda_2 + \dots + \lambda_d,$$

где каждая λ_i неотрицательна в силу положительной полуопределённости матрицы A . Кроме того, из разложения A можно сделать вывод, что

$$A = \lambda_1 v_1 v_1^\top + \lambda_2 v_2 v_2^\top + \dots + \lambda_d v_d v_d^\top,$$

где v_i — соответствующие нормированные собственные вектора. Таким образом, представили A как выпуклую комбинацию одноранговых матриц, образованных вектором единичной нормы. Это завершает доказательство. ■

Теорема C3.3 (Каратеодори). Пусть $S \subseteq \mathbb{R}^d$ и $\dim \text{conv } S = d$. Тогда любой элемент $\text{conv } S$ представляется как выпуклая комбинация не более чем $d+1$ точки множества S .

Доказательство. Будем доказывать от противного. Пусть имеется вектор $x \in \text{conv } S$, такой что

$$x = \sum_{i=1}^n \alpha_i x_i, \quad \sum_{i=1}^n \alpha_i = 1, \quad \alpha_i \geq 0, \quad n \geq d+2.$$

$x_2 - x_1, \dots, x_n - x_1$ принадлежат линейному пространству L_S из Теоремы C3.1. Поскольку $\dim \text{conv } S = d$, то и $\dim L_S = d$. Это означает, что система векторов линейно зависима, поскольку состоит хотя бы из $d+1$ вектора. Тогда существуют $\beta_2, \dots, \beta_n$ не равные нулю одновременно такие, что

$$\sum_{i=2}^n \beta_i (x_i - x_1) = 0.$$

Обозначим

$$\gamma_1 = -\sum_{i=2}^n \beta_i, \quad \gamma_i = \beta_i.$$

Это значит, что можно переписать исходное выражение как

$$\sum_{i=1}^n \gamma_i x_i = 0, \quad \sum_{i=1}^n \gamma_i = 0,$$

причём не все γ_i равны нулю одновременно. Это означает, что среди них есть такие, которые принимают отрицательное значение. Обозначим

$$a = \min \left\{ -\frac{\alpha_i}{\gamma_i} : \gamma_i < 0 \right\} = -\frac{\alpha_k}{\gamma_k}.$$

Тогда для любого i $\alpha_i + a\gamma_i \geq 0$, причём

$$x = \sum_{i=1}^n (\alpha_i + a\gamma_i) x_i, \quad \sum_{i=1}^n (\alpha_i + a\gamma_i) = 1,$$

то есть это выпуклая комбинация. Но поскольку $\alpha_k + a\gamma_k = 0$ по определению, то мы уменьшили число точек на одну. Этот процесс можно продолжать до тех пор, пока не окажется $n = d + 1$. В таком случае продолжать итеративно будет невозможно, поскольку система d векторов в d -мерном пространстве не обязательно линейно зависима. ■

Теорема С3.4. (Теорема Радона) Любое конечное множество $S \subseteq \mathbb{R}^d$, содержащее не менее $d + 2$ точек, может быть разбито на два непересекающихся множества, выпуклые оболочки которых пересекаются.

Доказательство. Рассмотрим набор точек $x_1, \dots, x_n \in S$, $n \geq d + 2$. В доказательстве Теоремы С3.3 утверждается линейная зависимость системы $x_2 - x_1, \dots, x_n - x_1$. Тогда существует нетривиальная комбинация этих векторов с коэффициентами $\beta_2, \dots, \beta_n$, равная нулю. Введем коэффициенты $\gamma_1, \dots, \gamma_n$ аналогично предыдущему доказательству:

$$\sum_{i=1}^n \gamma_i x_i = 0, \quad \sum_{i=1}^n \gamma_i = 0.$$

Выделим положительные и отрицательные коэффициенты в разные группы. Не ограничивая общности рассуждений, будем считать, что $\gamma_1, \dots, \gamma_m \geq 0$, $\gamma_{m+1}, \dots, \gamma_n < 0$. Тогда имеем

$$\sum_{i=1}^m \tilde{\gamma}_i x_i = \sum_{i=m+1}^n \tilde{\gamma}_i x_i,$$

где для $i = \overline{1, m}$ определили $\tilde{\gamma}_i = \frac{\gamma_i}{\sum_{j=1}^m \gamma_j}$, а для остальных — $\tilde{\gamma}_i = -\frac{\gamma_i}{\sum_{j=1}^m \gamma_j}$. Нетрудно видеть, что в обеих частях равенства стоят выпуклые комбинации. Таким образом, получили общую точку двух выпуклых оболочек. ■

Теорема С3.5. (Теорема Хелли для конечных семейств) Семейство из $n \geq d + 1$ выпуклых множеств $S_1, \dots, S_n \subseteq \mathbb{R}^d$ такое, что любые $d + 1$ имеют общую точку, имеет общую точку.

Доказательство.

- База при $n = d + 1$ очевидна.
- Рассмотрим $n \geq d + 2$ выпуклых множеств $S_1, \dots, S_n$. Предположим, что утверждение доказано для любых $n - 1$ выпуклых множеств. Из каждого выберем некоторую точку:

$$x_k = \bigcap_{i=1, i \neq k}^n S_i.$$

Такие пересечения не пусты по предположению индукции. Но $n \geq d + 2$, то есть можем воспользоваться теоремой Радона. Переставив индексы, получаем существование такого m , что $\text{conv}\{x_1, \dots, x_m\}$ и $\text{conv}\{x_{m+1}, \dots, x_n\}$ имеют общую точку x . Более того, каждая точка из множества $x_1, \dots, x_m$ содержится в каждом из множеств $S_{m+1}, \dots, S_n$. Это означает, что x содержится в каждом $S_{m+1}, \dots, S_n$ в силу их выпуклости. Аналогично доказывается принадлежность x множествам $S_1, \dots, S_m$. Таким образом, нашли общую точку для всех множеств. ■

С3.4 Операции, сохраняющие выпуклость

Определение С3.5. Функция $f : \mathbb{R}^d \rightarrow \mathbb{R}^n$ называется *аффинной*, если найдутся $b \in \mathbb{R}^n$ и $A \in \mathbb{R}^{n \times d}$ такие, что $f(x) = Ax + b$ для любого $x \in \mathbb{R}^d$.

Ряд базовых операций имеет свойство сохранять выпуклость множеств.

Утверждение С3.5 (Параграф 3 из [46]). Следующие операции оставляют множество выпуклым:

- **Пересечение:** Пусть $\{S_i\}_{i \in I} \subseteq \mathbb{R}^d$ — не обязательно конечное семейство выпуклых множеств, тогда пересечение $\bigcap_{i \in I} S_i$ также является выпуклым множеством.
- **Линейная комбинация:** Пусть $S_1, S_2 \subseteq \mathbb{R}^d$ — выпуклые множества и $c_1, c_2 \in \mathbb{R}$, тогда линейная комбинация $c_1 S_1 + c_2 S_2 = \{c_1 x_1 + c_2 x_2 \mid x_1 \in S_1, x_2 \in S_2\}$ также является выпуклым множеством.
- **Взятие образа при аффинном отображении:** Пусть $S \subseteq \mathbb{R}^d$ — выпуклое множество, f — аффинная функция, тогда $f(S)$ также является выпуклым множеством.
- **Взятие прообраза при аффинном отображении:** Пусть $S \subseteq \mathbb{R}^d$ — выпуклое множество, f — аффинная функция, тогда $f^{-1}(S)$ также является выпуклым множеством.
- **Произведение:** Пусть $S_1, S_2, \dots, S_n \subseteq \mathbb{R}^d$ — выпуклые множества, тогда декартово произведение $S_1 \times S_2 \times \dots \times S_n$ также выпукло.

Пример С3.11. Покажите, что многогранник:

$$S(A, b, C, d) = \left\{ x \in \mathbb{R}^d \mid Ax \preceq b, Cx = d \right\},$$

где $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$, $C \in \mathbb{R}^{k \times d}$ и $d \in \mathbb{R}^k$ является выпуклым.

Решение. Ограничения можно переписать в следующем виде: $a_i^\top x \leq b_i$ и $c_i^\top x = d_i$. То есть многогранник является выпуклым множеством как пересечение полуплоскостей и плоскостей. ■

Пример С3.12. Покажите, что множество

$$S(\alpha, \beta) = \left\{ a \in \mathbb{R}^d \mid p(0) = 1, |p(t)| \leq 1 \ \forall t : \alpha \leq t \leq \beta \right\},$$

где

$$p(t) = a_0 + a_1 t + \dots + a_{d-1} t^{d-1},$$

является выпуклым.

Решение. Переформулируем ограничения на коэффициенты a в виде линейных равенств и неравенств. Тогда

$$p(0) = 1 \iff a_0 = 1,$$

ограничение вида $|p(t)| \leq 1$ переписывается как

$$-1 \leq a_0 + a_1 t + \dots + a_{d-1} t^{d-1} \leq 1.$$

Обозначим это пересечение двух полуплоскостей за $\mathcal{H}_t$. Тогда множество коэффициентов переписывается в виде

$$\bigcap_{t \in [\alpha, \beta]} \mathcal{H}_t \cap \{ a \mid a_0 = 1 \},$$

что является выпуклым как пересечение выпуклых множеств. ■

Пример С3.13. Покажите, что множество

$$S(A, b, c, d) = \left\{ x \in \mathbb{R}^d \mid \|Ax + b\| \leq c^\top x + d \right\},$$

где $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$, $c \in \mathbb{R}^d$ и $d \in \mathbb{R}$ является выпуклым.

Решение. Докажем для начала, что множество

$$T = \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid \|x\| \leq t \right\}$$

является выпуклым. Это несложно делается по определению: возьмем $\alpha \in [0, 1]$ и $(x_1, t_1), (x_2, t_2) \in T$. Тогда

$$\|\alpha x_1 + (1 - \alpha)x_2\| \leq \alpha\|x_1\| + (1 - \alpha)\|x_2\| \leq \alpha t_1 + (1 - \alpha)t_2,$$

что означает

$$(\alpha x_1 + (1 - \alpha)x_2, \alpha t_1 + (1 - \alpha)t_2) \in T.$$

Заметим, что $S = f^{-1}(T)$, где $f(x) = (Ax + b, c^\top x + d)$ — аффинная функция. Получим, что S выпукло как прообраз выпуклого множества при аффинном отображении. ■

Пример С3.14. Покажите, что множество

$$S(P, c) = \left\{ x \in \mathbb{R}^d \mid x^\top P x \leq (c^\top x)^2, \ c^\top x \geq 0 \right\},$$

где $P \in \mathbb{S}_+^d$ и $c \in \mathbb{R}^d$ является выпуклым.

Решение. Как уже известно из Примера С3.13, множество

$$T = \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid \|x\| \leq t \right\}$$

является выпуклым. Воспользуемся фактом (Пример С2.12), что

$$\forall P \in \mathbb{S}_+^d \ \exists Q \in \mathbb{S}_+^d : P = Q^2,$$

поэтому наше множество S переписывается как

$$S = \left\{ x \in \mathbb{R}^d \mid \|Qx\| \leq c^\top x \right\}.$$

Заметим, что $S = f^{-1}(T)$, где $f(x) = (Qx, c^\top x)$ — аффинная функция. Поэтому S выпукло как прообраз выпуклого множества при аффинном отображении. ■

С3.5 Теоремы об отделимости

Теорема С3.6 (Теорема об отделимости, Следствие 1.9.3 из [45]). Пусть S и T — непересекающиеся непустые выпуклые множества в $\mathbb{R}^d$. Тогда найдётся $\lambda \in \mathbb{R}^d \setminus \{0\}$ такое, что

$$\sup_{x \in S} \lambda^\top x \leq \inf_{y \in T} \lambda^\top y.$$

Пример С3.15. Пусть S — выпуклое множество с непустой внутренностью и точка x_0 такая, что $x_0 \notin \text{int } S$. Покажите, что найдётся $\lambda \in \mathbb{R}^d \setminus \{0\}$ такое, что

$$\sup_{x \in S} \lambda^\top x \leq \lambda^\top x_0.$$

Решение. Пусть $x \in \text{int } S$, $B_{r_0}(x) \subseteq S$ и $y \in \partial S$, тогда весь интервал $[x, y)$ принадлежит внутренности, так как если $z \in [x, y)$, то $B_r(z) \subseteq \text{int } S$, где

$$r = r_0 \frac{\|y - z\|_2}{\|y - x\|_2}.$$

Поэтому $\partial S \subseteq \text{cl int } S$. Получаем, что

$$\text{cl } S = \text{cl}(\text{int } S \cup \partial S) \subseteq \text{cl}(\text{cl int } S) = \text{cl int } S.$$

А так как $\text{cl } S \supseteq \text{cl int } S$, то $\text{cl } S = \text{cl int } S$. Заметим теперь, что $\text{int } S$ и x_0 — непустые непересекающиеся выпуклые множества. Применив для них теорему об отделимости,

получим

$$\sup_{x \in \text{int } S} \lambda^\top x \leq \lambda^\top x_0.$$

Требуемое утверждение получается взятием замыкания у $\text{int } S$. ■

Пример С3.16. Рассмотрим систему строгих неравенств

$$Ax \prec b, \quad A \in \mathbb{R}^{n \times d}, \quad b \in \mathbb{R}^n.$$

Она неразрешима тогда и только тогда, когда

$$\exists \lambda \in \mathbb{R}^n \setminus \{0\} : \lambda^\top A = 0, \quad \lambda^\top b \leq 0, \quad \lambda \succeq 0.$$

Доказательство. $\ominus$ Пусть система $Ax \prec b$ неразрешима, тогда выпуклые множества $\{b - Ax \mid x \in \mathbb{R}^d\}$ и $\mathbb{R}_{++}^d$ не пересекаются. Воспользуемся теоремой об отделенности:

$$\exists \lambda \in \mathbb{R}^n \setminus \{0\} : \sup_{x \in \mathbb{R}^d} \lambda^\top (b - Ax) \leq \inf_{y \in \mathbb{R}_{++}^d} \lambda^\top y.$$

Так как правая часть неравенства не может быть равна $-\infty$, то $\lambda \succeq 0$. Помимо этого, устремляя $y \rightarrow 0$, получим

$$\sup_{x \in \mathbb{R}^d} \lambda^\top (b - Ax) \leq 0.$$

Так как супремум ограничен сверху, можем сделать вывод, что

$$\lambda^\top A = 0, \quad \lambda^\top b \leq 0.$$

$\ominus$ Предположим, что нашёлся такой $x \in \mathbb{R}^d$, что $Ax \prec b$. Так как $\lambda \succeq 0$ и $\lambda \neq 0$, то

$$\lambda^\top Ax < \lambda^\top b \leq 0.$$

Отсюда мы получаем противоречие с тем, что $\lambda^\top A = 0$. ■

Сила данного утверждения в том, что разрешимость какого-то линейного неравенства от x , который лежит в d -мерном пространстве, сводится к разрешимости системы равенств и неравенств от переменной из n -мерного пространства. Это может быть полезно в случае $n \ll d$.

Пример С3.17. Операция взятия сопряжения нормы является *инволюцией*, то есть $\|\cdot\|_{**} = \|\cdot\|$.

Доказательство. Для начала заметим, что

$$\|y\|_* = \sup_{\|x\| \leq 1} x^\top y \geq \left(\frac{x}{\|x\|} \right)^\top y.$$

Из этого следует

$$x^\top y \leq \|x\| \|y\|_*.$$

Более того, так как $\{x \mid \|x\| \leq 1\}$ — компакт, то непрерывная функция $x^\top y$ по теореме Вейерштрасса достигает на нём максимума в какой-то точке, следовательно

$$\forall y \exists x \neq 0 : x^\top y = \|x\| \|y\|_*.$$

Отсюда следует, что

$$\forall x \exists y \neq 0 : \|x\|_{**} \|y\|_* = x^\top y \leq \|x\| \|y\|_*.$$

Поэтому

$$\forall x \rightarrow \|x\|_{**} \leq \|x\|.$$

Далее будем пользоваться теоремой об отделимости. Зафиксируем $x \neq 0$ (случай $x = 0$ очевиден) и рассмотрим два выпуклых непересекающихся множества:

$$B(0, 1) = \{x \mid \|x\| < 1\}, \quad \left\{ \frac{x}{\|x\|} \right\}.$$

По теореме об отделимости найдётся такой $y \neq 0$, что

$$\sup_{\|x\| < 1} x^\top y \leq \left(\frac{x}{\|x\|} \right)^\top y.$$

Следовательно,

$$\|y\|_* = \sup_{\|x\| \leq 1} x^\top y = \sup_{\|x\| < 1} x^\top y \leq \left(\frac{x}{\|x\|} \right)^\top y \leq \frac{\|x\|_{**} \|y\|_*}{\|x\|}.$$

Получили неравенство в обратную сторону:

$$\forall x \rightarrow \|x\|_{**} \geq \|x\|.$$

Это рассуждение завершает доказательство. ■

Этот пример показывает, что иногда теорема об отделимости может возникать в совершенно неожиданных местах, и без её применения некоторые утверждения доказать нелегко.

Теорема С3.7 (Теорема о строгой отделимости, Следствие 1.9.2 из [45]).

Пусть S и T — непересекающиеся непустые выпуклые множества в $\mathbb{R}^d$, причём S — компакт, а T замкнуто. Тогда найдётся $\lambda \in \mathbb{R}^d \setminus \{0\}$ такое, что


$$\sup_{x \in S} \lambda^\top x < \inf_{y \in T} \lambda^\top y.$$

Пример С3.18. Множества

$$A = \left\{ (x, y) \mid x > 0, y \geq \frac{1}{x} \right\},$$

$$B = \left\{ (x, y) \mid x > 0, y \leq -\frac{1}{x} \right\}.$$

не могут быть строго отделены гиперплоскостью.



Доказательство. Предположим, нашёлся такой $\lambda \neq 0$, который строго разделяет эти множества, то есть найдутся $c_1, c_2 \in \mathbb{R}$ такие, что

$$\sup_{a \in A} \lambda^\top a < c_1 < c_2 < \inf_{b \in B} \lambda^\top b.$$

Для любого $x > 0$ выполняются включения

$$\left(x, \frac{1}{x}\right) \in A, \quad \left(x, -\frac{1}{x}\right) \in B.$$

Возьмем такой достаточно большой $x > 0$, что выполняется

$$2 \left| \frac{\lambda_2}{x} \right| < c_2 - c_1.$$

Тогда

$$\lambda_1 x + \frac{\lambda_2}{x} < c_1 \implies \lambda_1 x - \frac{\lambda_2}{x} < c_1 - 2 \frac{\lambda_2}{x} \leq c_1 + 2 \left| \frac{\lambda_2}{x} \right| < c_2,$$

то есть

$$\lambda_1 x - \frac{\lambda_2}{x} < c_2.$$

Это приводит нас к противоречию. ■

С4 Выпуклые функции

Многие методы оптимизации опираются на свойства выпуклых функций. Для них локальный минимум всегда является глобальным, а если функция является сильно выпуклой, то минимум единственный.

С4.1 Основные понятия

Перед тем, как перейти к обсуждению основной темы параграфа, введём несколько вспомогательных определений.

Оказывается, что иногда довольно удобно разрешить функции принимать бесконечное значение и рассматривать её так, будто она задана на всём пространстве, а не только на области определения.

Определение С4.1. Множество $\overline{\mathbb{R}} = \mathbb{R} \cup \{+\infty\} \cup \{-\infty\}$ будем называть *расширенным множеством действительных чисел*.

Замечание С4.1. Операции, определённые в $\mathbb{R}$, естественным образом переносятся на $\overline{\mathbb{R}}$:

- Операции с числами из $\mathbb{R}$ понимаются в обычном смысле.
- Любое число из $\overline{\mathbb{R}} \setminus \{+\infty\}$ строго меньше $+\infty$. В частности, $-\infty < +\infty$.
- Сумма $+\infty$ и любого числа из $\overline{\mathbb{R}} \setminus \{-\infty\}$ равна $+\infty$.
- Сумма $-\infty$ и любого числа из $\overline{\mathbb{R}} \setminus \{+\infty\}$ равна $-\infty$.
- Сложение $+\infty$ и $-\infty$ не определено.
- Произведение $+\infty$ и положительного числа из $\overline{\mathbb{R}}$ (в том числе $+\infty$) равно $+\infty$.
- Произведение $+\infty$ и отрицательного числа из $\overline{\mathbb{R}}$ (в том числе $-\infty$) равно $-\infty$.
- Произведение $-\infty$ и положительного числа из $\overline{\mathbb{R}}$ (в том числе $+\infty$) равно $-\infty$.
- Произведение $-\infty$ и отрицательного числа из $\overline{\mathbb{R}}$ (в том числе $-\infty$) равно $+\infty$.
- Произведение нуля и $+\infty$, $-\infty$ не определено.

Определив $\overline{\mathbb{R}}$, мы готовы рассматривать функцию сразу в расширенном виде. Если функция определена на множестве, то вне этого множества доопределим её $+\infty$. Истинную область определения функции теперь будем называть эффективным множеством.

Определение С4.2. Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Её *эффективным множеством* называется множество:

$$\text{dom } f = \left\{ x \in \mathbb{R}^d \mid f(x) < +\infty \right\}.$$

Замечание С4.2. Здесь и далее вместо $\mathbb{R}^d$ можно рассматривать и другие пространства, которые изоморфны $\mathbb{R}^d$, например матричное пространство $\mathbb{R}^{d \times n}$ или пространство симметричных матриц $\mathbb{S}^d$.

Введём ещё одно определение, оно нам пригодится позже.

Определение С4.3. Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Будем называть её *собственной*, если $\text{dom } f \neq \emptyset$ и

$$\forall x \in \mathbb{R}^d : f(x) > -\infty.$$

С4.2 Выпуклые функции

Поскольку ранее мы уже разобрали выпуклые множества, наиболее естественно ввести выпуклость функции, опираясь на понятие *надграфика*.

Определение С4.4. Пусть функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. *Надграфиком (эпиграфом)* f называется множество

$$\text{epi } f = \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid f(x) \leq t \right\}.$$

Нетрудно заметить, что график функции — граница эпиграфа. Довольно естественно называть функцию выпуклой, если её надграфик ограничивает выпуклое множество.

Определение С4.5. Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Будем называть её *выпуклой*, если надграфик $\text{epi } f$ — есть выпуклое множество.




Рис. С4.1: Выпуклость через надграфик.

Пример С4.1. Покажите, что аффинная функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = a^\top x + b, \quad a \in \mathbb{R}^d, \quad b \in \mathbb{R}$$

является выпуклой.

Решение. Посмотрим, как устроено множество $\text{epi } f$. Это все точки, лежащие над гиперплоскостью, заданной аффинной функцией f . Покажем, что множество

$$S(a, b) = \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid a^\top x + b \leq t \right\}$$

является выпуклым по определению. Пусть $(x_1, t_1), (x_2, t_2) \in S$, тогда

$$a^\top(\alpha x_1 + (1 - \alpha)x_2) + b = \alpha(a^\top x_1 + b) + (1 - \alpha)(a^\top x_2 + b) \leq \alpha t_1 + (1 - \alpha)t_2.$$

Это означает, что аффинная функция выпукла по определению. ■

Пример С4.2. Покажите, что векторная норма $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \|x\|$$

является выпуклой.

Доказательство. Покажем, что множество

$$S = \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid \|x\| \leq t \right\}$$

является выпуклым по определению. Пусть $(x_1, t_1), (x_2, t_2) \in S$, тогда

$$\|\alpha x_1 + (1 - \alpha)x_2\| \leq \alpha\|x_1\| + (1 - \alpha)\|x_2\| \leq \alpha t_1 + (1 - \alpha)t_2.$$

Это означает, что норма — выпуклая функция по определению. ■

Пример С4.3. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \|x\|^4 - 4\|x\|^2$$

не является выпуклой.

Доказательство. Покажем, что множество

$$S = \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid \|x\|^4 - 4\|x\|^2 \leq t \right\}$$

не является выпуклым. Возьмем $((1, 0, \dots, 0)^\top, -1), ((-1, 0, \dots, 0)^\top, -1) \in S$ и рассмотрим точку посередине и получим противоречие с неравенством во множестве: $0 < -1$. ■

Работать непосредственно с эпиграфами далеко не всегда удобно и зачастую требует нетривиальных ходов. Чтобы подкрепить это утверждение, мы рассмотрим сложные примеры.

Пример С4.4. Покажите, что функция $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

$$f(x) = x \log x, \quad \text{dom } f = \mathbb{R}_+$$

является выпуклой.

Доказательство. Проанализировать надграфик предложенной функции непросто. Покажем, что он является пересечением выпуклых множеств.

- Рассмотрим вспомогательную функцию

$$g(x) = \sup_{y \in \mathbb{R}} \{xy - e^y\}.$$

Найдём явный вид этой функции. При $x < 0$ получаем, что $g(x) = +\infty$, при $x = 0$ получаем, что $g(x) = 0$, при $x > 0$ получаем, что $g(x) = x \log x - x$. В итоге

$$g(x) = \begin{cases} x \log x - x, & x > 0; \\ 0, & x = 0. \end{cases}$$

Получается, что $f(x) = g(x) + x$. В Примере C4.1 мы показали, что ер x выпуклый, поэтому если ер g выпуклый, то и ер f выпуклый.

- Надграфик функции g можно задать так:

$$\text{epi } g = \bigcap_{y \in \mathbb{R}} \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid xy - e^y \leq t \right\}.$$

При фиксированном $y \in \mathbb{R}$, множество $\{(x, t) \in \mathbb{R}^d \times \mathbb{R} \mid xy - e^y \leq t\}$ выпуклое, как полуплоскость. Но тогда и ер g выпуклое, как пересечение выпуклых множеств. ■

Пример C4.5. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(p) = \text{KL}(p|q) = \sum_{i=1}^d p_i \log \frac{p_i}{q_i}, \quad \text{dom } f = \left\{ p \in \mathbb{R}_+^d \mid \sum_{i=1}^d p_i = 1 \right\},$$

где $q \in \left\{ q \in \mathbb{R}_+^d \mid \sum_{i=1}^d q_i = 1 \right\}$, является выпуклой.

Доказательство. Запишем ер f :

$$\text{epi } f = \left\{ (p, t) \in \mathbb{R}^d \times \mathbb{R} \mid \sum_{i=1}^d p_i \log \frac{p_i}{q_i} \leq t, \sum_{i=1}^d p_i = 1, p_i \geq 0 \right\}.$$

Введём переменную s , расширив размерность надграфика:

$$M = \left\{ (s, p, t) \in \mathbb{R}^d \times \mathbb{R}^d \times \mathbb{R} \mid \sum_{i=1}^d s_i \leq t, p_i \log \frac{p_i}{q_i} \leq s_i, \sum_{i=1}^d p_i = 1, p_i \geq 0 \right\}.$$

Если показать, что множество M — выпуклое, то ер f будет выпуклым, так как это ортогональная проекция множества M . Представим множество M как пересечение выпуклых. Множество

$$R = \left\{ (s, p, t) \in \mathbb{R}^d \mid \sum_{i=1}^d s_i \leq t \right\}$$

выпукло как полуплоскость. Проверим множество

$$S = \left\{ (s, p, t) \in \mathbb{R}^d \times \mathbb{R}^d \times \mathbb{R} \mid \sum_{i=1}^d p_i = 1, p_i \geq 0 \right\}$$

на выпуклость. Пусть $(s^1, p^1, t^1), (s^2, p^2, t^2) \in S$, проверим сначала равенство

$$\sum_{i=1}^d (\alpha p_i^1 + (1 - \alpha) p_i^2) = \alpha \sum_{i=1}^d p_i^1 + (1 - \alpha) \sum_{i=1}^d p_i^2 = 1,$$

а теперь проверим неравенство:

$$\alpha p_i^1 + (1 - \alpha) p_i^2 \geq 0.$$

Осталось убедиться в выпуклости множеств вида

$$M_i = \left\{ (p, s, t) \in \mathbb{R}^d \times \mathbb{R}^d \times \mathbb{R} \mid s_i \geq p_i \log \frac{p_i}{q_i} \right\}.$$

Можно заметить, что M_i — эпиграф функции $g_i(x) = x \log x - x \log q_i$. Выпуклость $x \log x$ была показана в Примере С4.4. Кроме того было показано, что добавление линейной функции не влияет на выпуклость. Таким образом, множество M выпуклое. ■

Из последних примеров можно видеть, что проверка выпуклости по определению зачастую довольно сильно затруднена. Известен ряд эквивалентных определений.

Определение С4.6. Рассмотрим собственную функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Функция f называется *выпуклой*, если для любых $x, y \in \mathbb{R}^d$ и любого $\alpha \in (0, 1)$ выполняется

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y). \quad (\text{C4.1})$$

Замечание С4.3. Неравенство (C4.1) называется неравенством Йенсена для двух точек.

Неформально это означает, что хорда, соединяющая любые две точки графика функции, лежит над ним. Эта интуиция может быть знакома из курса математического анализа.




Рис. С4.2: Выпуклость через условие Йенсена для двух точек.

Замечание С4.4. Если в Определении С4.6 выполнено строгое неравенство, функцию f называют *строгой выпуклой*.

Замечание С4.5. Если неравенство в Определении С4.6 (строго) выполнено в обратную сторону, f называется (строго) *вогнутой*.

Замечание С4.6. Из определений легко видеть, что функция f является (строго) выпуклой тогда и только тогда, когда функция $-f$ является (строго) вогнутой.

Утверждение С4.1. Определения С4.5 и С4.6 эквивалентны.

Доказательство. $\Rightarrow$ Покажем, что из Определения С4.5 следует Определение С4.6. Возьмем $(x_1, f(x_1)), (x_2, f(x_2)) \in \text{epi } f$, тогда

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2).$$

$\Leftarrow$ Покажем, что из Определения С4.6 следует Определение С4.5. Рассмотрим для точек $(x, t_x), (y, t_y) \in \text{epi } f$ выпуклую комбинацию $(\alpha x + (1 - \alpha)y, \alpha t_x + (1 - \alpha)t_y)$. Тогда:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \leq \alpha t_x + (1 - \alpha)t_y.$$

Получили, что $\text{epi } f$ выпуклый. ■

Пример С4.6. Покажите, что функция $f : \mathbb{R} \rightarrow \bar{\mathbb{R}}$:

$$f(x) = -\sqrt{x}, \quad \text{dom } f = \mathbb{R}_+$$

является выпуклой.

Решение. Проверим по Определению С4.6, возьмем две точки x, y :

$$-\sqrt{\alpha x + (1 - \alpha)y} \leq -\alpha\sqrt{x} - (1 - \alpha)\sqrt{y}.$$

Возведём в квадрат:

$$\alpha^2 x + 2\alpha(1 - \alpha)\sqrt{xy} + (1 - \alpha)^2 y \leq \alpha x + (1 - \alpha)y.$$

Упростим:

$$-\alpha(1 - \alpha)x + 2\alpha(1 - \alpha)\sqrt{xy} - \alpha(1 - \alpha)y \leq 0.$$

Нужно показать, что:

$$2\sqrt{xy} \leq x + y \implies 0 \leq (\sqrt{x} - \sqrt{y})^2.$$
■

Утверждение С4.2. Функция $f : \mathbb{R}^d \rightarrow \bar{\mathbb{R}}$ выпукла тогда и только тогда, когда она собственная и функция одного аргумента $g(\alpha) = f(x + \alpha v)$ выпукла по α для любых ненулевых $x, v \in \mathbb{R}^d$.

Доказательство. $\Rightarrow$ Возьмём произвольную точку x , направление v и рассмотрим выпуклую комбинацию двух точек α_1, α_2 . Тогда в силу выпуклости функции $f(x)$ получаем:

$$\begin{aligned} g(\lambda \alpha_1 + (1 - \lambda)\alpha_2) &= f(x + (\lambda \alpha_1 + (1 - \lambda)\alpha_2)v) = f(\lambda(x + \alpha_1 v) + (1 - \lambda)(x + \alpha_2 v)) \\ &\leq \lambda f(x + \alpha_1 v) + (1 - \lambda)f(x + \alpha_2 v) = \lambda g(\alpha_1) + (1 - \lambda)g(\alpha_2). \end{aligned}$$

Таким образом, функция $g(\alpha)$ выпукла.

⊖ Пусть теперь x_1 и x_2 — две различные друг от друга точки, тогда направление $v = x_1 - x_2$ ненулевое. В силу выпуклости функции $g(\alpha)$ получаем:

$$\begin{aligned} f(x_2 + \alpha(x_1 - x_2)) &= f(\alpha x_1 + (1 - \alpha)x_2) = f(x_2 + (\alpha \cdot 1 + (1 - \alpha) \cdot 0)v) \\ &= g(\alpha \cdot 1 + (1 - \alpha) \cdot 0) \leq \alpha g(1) + (1 - \alpha)g(0) \\ &= \alpha f(x_1) + (1 - \alpha)f(x_2). \end{aligned}$$

Таким образом, функция $f(x)$ выпукла. ■

Пример С4.7. Покажите, что функция $f: \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = -\sum_{i=1}^n \log(b_i - a_i^\top x), \quad A \in \mathbb{R}^{n \times d}, \quad b \in \mathbb{R}^n, \quad \text{dom } f = \left\{ x \in \mathbb{R}^d \mid a_i^\top x < b_i \right\}$$

является выпуклой.

Доказательство. Покажем, что функция $g(\alpha)$:

$$g(\alpha) = -\sum_{i=1}^n \log\left((b_i - a_i^\top x) - \alpha a_i^\top v\right)$$

выпуклая. Покажем, что $-\log(z)$ — выпуклая функция. Рассмотрим две точки x, y и проверим, что выполнено неравенство (С4.1):

$$-\log(\alpha x + (1 - \alpha)y) \leq -\alpha \log x - (1 - \alpha) \log y.$$

Перепишем его:

$$x^\alpha y^{1-\alpha} \leq \alpha x + (1 - \alpha)y.$$

и введём переменную $t = \frac{x}{y}$, тогда:

$$t^\alpha \leq \alpha t + 1 - \alpha.$$

Введём функцию $\phi(t)$:

$$\phi(t) = t^\alpha - \alpha t - 1 + \alpha.$$

Найдём её производную:

$$\phi'(t) = \alpha(t^{\alpha-1} - 1).$$

При $0 < t < 1$ производная положительная, а при $t > 1$ производная отрицательная. Тогда, так как $\phi(1) = 0$, то неравенство выполняется. Покажем, что композиция выпуклой и аффинной функции выпукла. Пусть $h(x) = u(a(x))$, где u — выпуклая, a — аффинная. Применив Определение С4.6, получим

$$u(a(\lambda x + (1 - \lambda)y)) = u(\lambda a(x) + (1 - \lambda)a(y)) \leq \lambda u(a(x)) + (1 - \lambda)u(a(y)).$$

Сумма выпуклых функций выпукла по Определению С4.5, так как пересечение выпуклых множеств — выпуклое множество. ■

Определение С4.6 можно обобщить на случай произвольного конечного числа точек.

Определение С4.7. Рассмотрим собственную функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Функция f называется *выпуклой*, если $\text{dom } f$ — выпуклое множество и для любых $x_1, \dots, x_k \in \mathbb{R}^d$ и любых $\alpha_1, \dots, \alpha_k, \alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i). \quad (\text{C4.2})$$

Замечание С4.7. Неравенство (С4.2) называется неравенством Йенсена.




Рис. С4.3: Выпуклость через условие Йенсена.

Замечание С4.8. С помощью данного определения не доказывают выпуклость функции, используют только в обратную сторону, так как есть Определение С4.6.

Замечание С4.9. Для любых фиксированных точек x_i неравенство (С4.2) переходит в равенство для любых α_i , удовлетворяющих условиям, тогда и только тогда, когда функция f является аффинной, или когда все точки x_i совпадают.

Утверждение С4.3. Определения С4.5, С4.6 и С4.7 эквивалентны.

Доказательство. Достаточно доказать эквивалентность нового определения какому-то из ранее введённых.

⊖ Покажем, что из Определения С4.6 следует Определение С4.7. Доказательство будем проводить по индукции. При $k = 1$ утверждение верно, а при $k = 2$ следует из Определения С4.6 выпуклой функции. Предположим, что неравенство (С4.7) верно для всех k и докажем его для $k + 1$. Будем считать, что $\alpha_{k+1} \in (0, 1)$, так как иначе всё сводится к уже рассмотренным ранее случаям. Пусть

$$x = \sum_{i=1}^{k+1} \alpha_i x_i = \alpha_{k+1} x_{k+1} + \sum_{i=1}^k \alpha_i x_i = \alpha_{k+1} x_{k+1} + (1 - \alpha_{k+1}) \bar{x},$$

где

$$\bar{x} = \sum_{i=1}^k \frac{\alpha_i}{1 - \alpha_{k+1}} x_i,$$

В силу выпуклости функции $f(x)$ и предположения индукции

$$\begin{aligned} f\left(\sum_{i=1}^{k+1} \alpha_i x_i\right) &= f(\alpha_{k+1} x_{k+1} + (1 - \alpha_{k+1}) \bar{x}) \leq \alpha_{k+1} f(x_{k+1}) + (1 - \alpha_{k+1}) f(\bar{x}) \\ &\leq \alpha_{k+1} f(x_{k+1}) + \sum_{i=1}^k \alpha_i f(x_i) = \sum_{i=1}^{k+1} \alpha_i f(x_i). \end{aligned}$$

⊖ Покажем, что из Определения С4.7 следует Определение С4.6. Возьмём две произвольных точки и получим неравенство (С4.1). ■

Помимо введённых ранее определений выпуклости, есть ещё одно, которое вводится для дифференцируемых функций.

Определение С4.8. Рассмотрим непрерывно дифференцируемую функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$, у которой $\text{dom } f$ — выпуклое открытое множество. Функция f называется *выпуклой*, если выполняется

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle, \quad \forall x, y \in \text{dom } f. \quad (\text{С4.3})$$

Можно дать следующую геометрическую интерпретацию этому определению. Рассмотрим аффинную функцию $g(y) = f(x) + \langle \nabla f(x), y - x \rangle$ — касательную к графику функции $f(x)$ в точке x . Если функция выпуклая, то g является глобальной оценкой f снизу. Иными словами, график выпуклой функции лежит выше графика касательной, построенного в любой точке.




Рис. С4.4: Выпуклость через условие первого порядка.

Теорема С4.1. Определения С4.5, С4.6, С4.7 и С4.8 в случае дифференцируемой функции f эквивалентны.

Доказательство. Достаточно доказать эквивалентность нового определения какому-то из ранее введённых.

⊕ Покажем, что из Определения С4.6 следует Определение С4.8. Запишем неравенство (С4.1) из Определения С4.6:

$$f(x + \alpha(y - x)) \leq (1 - \alpha)f(x) + \alpha f(y).$$

Поделив обе части неравенства на α , получим

$$f(y) \geq f(x) + \frac{f(x + \alpha(y - x)) - f(x)}{\alpha}.$$

Переходя к пределу при $\alpha \rightarrow 0$, получим требуемое утверждение.

⊖ Покажем, что из Определения С4.8 следует Определение С4.6. Выберем произвольные x, y и обозначим $z = \alpha x + (1 - \alpha)y$. Воспользуемся неравенством (С4.3):

$$f(x) \geq f(z) + \langle \nabla f(z), x - z \rangle,$$

$$f(y) \geq f(z) + \langle \nabla f(z), y - z \rangle.$$

Сложив первое неравенство, умноженное на α , и второе, умноженное на $(1 - \alpha)$, получим

$$\alpha f(x) + (1 - \alpha)f(y) \geq f(z) + \langle \nabla f(z), \alpha x + (1 - \alpha)y - z \rangle = f(z).$$

■

Пример С4.8. Покажите, что функция $f : \mathbb{R}^d \rightarrow \bar{\mathbb{R}}$:

$$f(x) = \sum_{i=1}^d \frac{1}{x_i}, \quad \text{dom } f = \mathbb{R}_{++}^d.$$

является выпуклой.

Решение. Проверим неравенство (С4.3) для точек x, y :

$$\sum_{i=1}^d \frac{1}{y_i} \geq \sum_{i=1}^d \frac{1}{x_i} - \sum_{i=1}^d \frac{y_i - x_i}{x_i^2}.$$

Перепишем:

$$\sum_{i=1}^d \frac{x_i^2 - x_i y_i + y_i^2 - x_i y_i}{x_i^2 y_i} = \sum_{i=1}^d \frac{(x_i - y_i)^2}{x_i^2 y_i} \geq 0.$$

■

Теорема С4.2 (Дифференциальное условие оптимальности для выпуклой функции). Пусть $f : \mathbb{R}^d \rightarrow \bar{\mathbb{R}}$ — собственная непрерывно дифференцируемая выпуклая функция, $\text{dom } f$ является открытым множеством, и пусть $x^* \in \text{dom } f$. Тогда x^* — глобальный минимум функции f тогда и только тогда, когда $\nabla f(x^*) = 0$.

Доказательство. Следует из Определения С4.8. ■

Наиболее часто в упражнениях на проверку выпуклости мы будем вычислять гессиан функции и проверять, является ли он определённым. Это один из самых мощных подходов.

Теорема С4.3 (Критерий выпуклости второго порядка). Рассмотрим собственную дважды непрерывно дифференцируемую функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$, у которой $\text{dom } f$ — выпуклое открытое множество. Функция f выпукла тогда и только тогда, когда

$$\nabla^2 f(x) \succeq 0, \quad \forall x \in \text{dom } f.$$

Доказательство. $\Rightarrow$ По Определению С4.8 для любых $x, y \in \text{dom } f$:

$$\begin{aligned} f(y) &\geq f(x) + \langle \nabla f(x), y - x \rangle, \\ f(x) &\geq f(y) + \langle \nabla f(y), x - y \rangle. \end{aligned}$$

Сложим и получим:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0.$$

Возьмём x , направление v и $y = x + hv$:

$$\left\langle \frac{\nabla f(x + hv) - \nabla f(x)}{h}, v \right\rangle \geq 0.$$

Переходя к пределу по h , получим $v^\top \nabla^2 f(x) v \geq 0$ для любого v , то есть $\nabla^2 f(x) \succeq 0$.

$\Leftarrow$ Возьмём любые $x, y \in \text{dom } f$ и рассмотрим $g(t) = f(x + t(y - x))$, тогда

$$g'(t) = \langle \nabla f(x + t(y - x)), y - x \rangle$$

По формуле Ньютона–Лейбница:

$$\begin{aligned} g(1) - g(0) &= \int_0^1 g'(t) dt = \langle \nabla f(x), y - x \rangle \\ &\quad + \int_0^1 \int_0^t (y - x)^\top \nabla^2 f(x + s(y - x))(y - x) ds dt. \end{aligned}$$

То есть получаем, что

$$f(y) - f(x) \geq \langle \nabla f(x), y - x \rangle.$$

■

Пример С4.9. Покажите выпуклость функций $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

- $f(x) = \exp(ax)$ на $\mathbb{R}$ для любого $a \in \mathbb{R}$;
- $f(x) = -\log x$ на $\mathbb{R}_{++}$;
- $f(x) = x \log x$ на $\mathbb{R}_{++}$;
- $f(x) = x^p$ для $p \leq 0$ или $p \geq 1$ на $\mathbb{R}_{++}$.

Решение.

- $f''(x) = a^2 \exp(ax) \geq 0$ на $\mathbb{R}$;

- $f''(x) = \frac{1}{x^2} \geq 0$ на $\mathbb{R}_{++}$;
- $f''(x) = \frac{1}{x} \geq 0$ на $\mathbb{R}_{++}$;
- $f''(x) = p(p-1)x^{p-2} \geq 0$ для $p \leq 0$ или $p \geq 1$ на $\mathbb{R}_{++}$;

■

Пример С4.10. Когда функция $f : \mathbb{R}^2 \rightarrow \overline{\mathbb{R}}$:

$$f(x) = ax_1^2 + bx_1x_2 + cx_2^2$$

является выпуклой?

Решение. Найдём гессиан:

$$\nabla^2 f(x) = \begin{pmatrix} 2a & b \\ b & 2c \end{pmatrix}.$$

Согласно критерию Сильвестра эта матрица неотрицательно определена, если $a \geq 0$, $c \geq 0$, $4ac \geq b^2$. ■

Пример С4.11. Покажите с помощью Определения С4.6 неравенство между средним арифметическим и средним геометрическим для двух переменных:

$$\sqrt{ab} \leq \frac{a+b}{2},$$

где $a, b \geq 0$.

Решение. Рассмотрим выпуклую функцию $f(x) = -\log x$. Полагая в (С4.6) $\alpha = \frac{1}{2}$, получаем

$$-\log\left(\frac{a+b}{2}\right) \leq \frac{-\log a - \log b}{2}.$$

Возьмём экспоненты от левой и правой части и получим ответ. ■

Пример С4.12. Когда функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle,$$

$A \in \mathbb{S}^d$, $b \in \mathbb{R}^d$ является выпуклой?

Решение. Заметим, что $\nabla^2 f(x) = A$. Следовательно, $f(x)$ является выпуклой тогда и только тогда, когда $A \succeq 0$. ■

Пример С4.13. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \log \sum_{i=1}^d e^{x_i}$$

является выпуклой.

Решение. Найдём градиент:

$$\nabla f(x) = \left(\sum_{i=1}^d e^{x_i} \right)^{-1} (e^{x_1}, \dots, e^{x_d})^\top = \frac{1}{\mathbf{1}^\top z} z,$$

где $z = (e^{x_1}, \dots, e^{x_d})^\top$. Тогда гессиан:

$$\nabla^2 f(x) = \frac{1}{(\mathbf{1}^\top z)^2} ((\mathbf{1}^\top z) \operatorname{diag}(z) - zz^\top).$$

Покажем, что для произвольного вектора v выполняется неравенство $v^\top \nabla^2 f(x) v \geq 0$:

$$v^\top \nabla^2 f(x) v = \frac{1}{(\mathbf{1}^\top z)^2} \left(\left(\sum_{i=1}^d z_i \right) \left(\sum_{i=1}^d v_i^2 z_i \right) - \left(\sum_{i=1}^d v_i z_i \right)^2 \right) \geq 0.$$

Последнее неравенство следует из неравенства Коши–Буняковского–Шварца (0.3):

$$(a^\top a)(b^\top b) \geq (a^\top b)^2,$$

где $a_i = \sqrt{z_i}$, $b_i = v_i \sqrt{z_i}$. ■

С4.3 Операции, сохраняющие выпуклость

В этом разделе рассмотрим преобразования, которые сохраняют выпуклость функций. Такие операции позволяют из простых выпуклых функций строить более сложные выпуклые функции.

С4.3.1 Неотрицательная взвешенная сумма

Сумма двух выпуклых функций выпукла, так как сумма выпуклых множеств — выпуклое множество. Также, если умножить выпуклую функцию на неотрицательное число c , то полученная функция $cf(x)$ также выпукла. Комбинируя эти свойства, получаем

Утверждение С4.4. Рассмотрим выпуклые функции $f_1, \dots, f_n : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ и $c_1, \dots, c_n \in \mathbb{R}_+$. Тогда функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \sum_{i=1}^n c_i f_i(x)$$

является выпуклой.

Пример С4.14. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \sum_{i=1}^d i^2 e^{x_i}$$

является выпуклой.

Решение. Функция выпуклая, как сумма выпуклых функций с положительными коэффициентами. ■

С4.3.2 Аффинная подстановка аргумента

Утверждение С4.5. Рассмотрим выпуклую функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ и $A \in \mathbb{R}^{d \times n}$, $b \in \mathbb{R}^d$. Тогда функция $g : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$g(x) = f(Ax + b)$$

является выпуклой.

Пример С4.15. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \sum_{i=1}^n c_i \exp(a_i^\top x + b_i), \quad a \in \mathbb{R}^{n \times d}, \quad b \in \mathbb{R}^n, \quad c \in \mathbb{R}_+^n.$$

является выпуклой.

Решение. Функция является выпуклой, как взвешенная сумма экспонент с аффинной подстановкой аргумента. ■

С4.3.3 Поточечный максимум и супремум

Пересечение эпиграфов двух выпуклых функций $f_1(x)$ и $f_2(x)$ является выпуклым множеством. Тогда и функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \max \{f_1(x), f_2(x)\}$$

является выпуклой. Но пересекая не только два, а произвольное число выпуклых множеств, мы опять получаем выпуклое множество. Поэтому если функция двух аргументов $g(x, y)$ выпукла по x для любого y , то следующая функция

$$f(x) = \sup_{(\cdot, y) \in \text{dom } g} g(x, y)$$

также является выпуклой.

Утверждение С4.6. Рассмотрим выпуклые функции $f_1, \dots, f_n : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Тогда функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \max \{f_1(x), \dots, f_n(x)\}$$

является выпуклой.

Рассмотрим выпуклую по x функцию $g(x, y) : \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$. Тогда функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \sup_{(\cdot, y) \in \text{dom } g} g(x, y)$$

является выпуклой.

Пример С4.16. Покажите, что кусочно-линейная функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \max \left\{ a_1^\top x + b_1, \dots, a_n^\top x + b_n \right\}, \quad a \in \mathbb{R}^{n \times d}, \quad b \in \mathbb{R}^d$$

является выпуклой.

Решение. Функция является выпуклой, как поточечный максимум линейных функций. ■

Пример С4.17. Обозначим $x_{[i]}$ i -ю максимальную координату вектора $x \in \mathbb{R}^d$. Покажите, что функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \sum_{i=1}^r x_{[i]}$$

является выпуклой.

Решение. Запишем функцию $f(x)$ как

$$f(x) = \sum_{i=1}^r x_{[i]} = \max \{ x_{i_1} + \dots + x_{i_r} \mid 1 \leq i_1 < i_2 < \dots < i_r \leq d \},$$

то есть максимум из всех возможных сумм r различных координат вектора x . Видно, что $f(x)$ — это поточечный максимум линейных функций, следовательно, $f(x)$ — выпуклая функция. ■

Пример С4.18. Покажите, что опорная функция $S_C : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$S_C(y) = \sup_{x \in C} \langle y, x \rangle, \quad C \subseteq \mathbb{R}^d$$

является выпуклой.

Решение. Функция является выпуклой, как поточечный супремум от аффинных функций. ■

Пример С4.19. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ расстояния от точки x до самой удалённой точки множества C :

$$f(x) = \sup_{y \in C} \|x - y\|, \quad C \subseteq \mathbb{R}^d$$

является выпуклой.

Решение. Функция является выпуклой, как поточечный супремум от выпуклых функций. ■

С4.3.4 Монотонная суперпозиция

Утверждение С4.7. Рассмотрим выпуклую функцию $h : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ и выпуклую неубывающую функцию $g : \mathbb{R} \rightarrow \mathbb{R}$. Тогда композиция этих двух функций $f(x) = g(h(x))$ является выпуклой функцией.

Доказательство. Возьмём произвольные точки x_1, x_2 . В силу выпуклости функции $h(x)$ выполняется неравенство

$$h(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha h(x_1) + (1 - \alpha)h(x_2).$$

Но внешняя функция $g(y)$ является неубывающей и выпуклой, поэтому

$$\begin{aligned} f(\alpha x_1 + (1 - \alpha)x_2) &= g(h(\alpha x_1 + (1 - \alpha)x_2)) \leq g(\alpha h(x_1) + (1 - \alpha)h(x_2)) \\ &\leq \alpha g(h(x_1)) + (1 - \alpha)g(h(x_2)) = \alpha f(x_1) + (1 - \alpha)f(x_2). \end{aligned}$$

Пример С4.20. Рассмотрим выпуклую $g : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Покажите, что функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \exp g(x)$$

является выпуклой.

Решение. Функция является выпуклой, как композиция выпуклой и выпуклой неубывающей функции. ■

Пример С4.21. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \|x\|^p$$

является выпуклой при $p \geq 1$.

Решение. Функция является выпуклой, как композиция выпуклой и выпуклой неубывающей функции. ■

С4.4 Сильно выпуклые функции

Рассмотрим ещё один класс функций — μ -сильно выпуклые функции. Начнём с определения через неравенство Йенсена для двух точек.

Определение С4.9. Рассмотрим собственную функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Функция f называется μ -сильно выпуклой, если для любых $x, y \in \mathbb{R}^d$ и любого $\alpha \in (0, 1)$ выполняется

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) - \alpha(1 - \alpha)\frac{\mu}{2}\|x - y\|_2^2. \quad (\text{С4.4})$$




Рис. С4.5: μ -сильная выпуклость через Йенсена для двух точек.

Пример С4.22. Покажите, что функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \log \sum_{i=1}^d e^{x_i} + \|x\|_2^2$$

является 2-сильно выпуклой.

Решение. Выпуклость $\log \sum_{i=1}^d e^{x_i}$ была показана в Примере С4.13. Покажем, что $\|x\|_2^2$ 2-сильно выпукла. Запишем неравенство (С4.4) для точек x, y :

$$\|\alpha x + (1 - \alpha)y\|_2^2 \leq \alpha \|x\|_2^2 + (1 - \alpha)\|y\|_2^2 - \alpha(1 - \alpha)\|x - y\|_2^2.$$

Перепишем:

$$\alpha(1 - \alpha)\|x - y\|_2^2 \leq \alpha(1 - \alpha)\|x\|_2^2 - 2\alpha(1 - \alpha)\langle x, y \rangle + \alpha(1 - \alpha)\|y\|_2^2.$$

Получили, что неравенство верное. ■

Есть ещё одно определение, которое вводится для дифференцируемых функций.

Определение С4.10. Рассмотрим собственную непрерывно дифференцируемую функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$, у которой $\text{dom } f$ — выпуклое открытое множество. Функция f называется μ -сильно выпуклой, если выполняется

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2}\|y - x\|_2^2, \quad \forall x, y \in \text{dom } f. \quad (\text{С4.5})$$




Рис. С4.6: μ -сильная выпуклость через условие первого порядка.

Покажем эквивалентность определений.

Теорема С4.4. Определения С4.9 в случае дифференцируемой функции f и С4.10 эквивалентны.

Доказательство. $\Rightarrow$ Покажем, что из Определения С4.9 следует Определение С4.10.

Запишем неравенство (C4.4) из Определения C4.9

$$f(x + \alpha(y - x)) \leq (1 - \alpha)f(x) + \alpha f(y) - \alpha(1 - \alpha)\frac{\mu}{2}\|x - y\|_2^2.$$

Поделив обе части неравенства на α , получим

$$f(y) \geq f(x) + \frac{f(x + \alpha(y - x)) - f(x)}{\alpha} + (1 - \alpha)\frac{\mu}{2}\|x - y\|_2^2.$$

Переходя к пределу при $\alpha \rightarrow 0$, получим требуемое утверждение.

⊖ Покажем, что из Определения C4.10 следует Определение C4.9. Выберем произвольные x, y и обозначим $z = \alpha x + (1 - \alpha)y$. Воспользуемся неравенством (C4.5):

$$\begin{aligned} f(x) &\geq f(z) + \langle \nabla f(z), x - z \rangle + \frac{\mu}{2}\|x - z\|_2^2, \\ f(y) &\geq f(z) + \langle \nabla f(z), y - z \rangle + \frac{\mu}{2}\|y - z\|_2^2. \end{aligned}$$

Сложив первое неравенство, умноженное на α , и второе, умноженное на $(1 - \alpha)$, получим

$$\begin{aligned} \alpha f(x) + (1 - \alpha)f(y) &\geq f(z) + \langle \nabla f(z), \alpha x + (1 - \alpha)y - z \rangle \\ &\quad + \frac{\mu}{2}(\alpha\|x - z\|_2^2 + (1 - \alpha)\|y - z\|_2^2) \\ &\geq f(z) + \alpha(1 - \alpha)\frac{\mu}{2}\|x - y\|_2^2. \end{aligned}$$

■

Пример C4.23. Получите условие, при котором квадратичная функция $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \frac{1}{2}x^\top Ax + b^\top x, \quad A \in \mathbb{S}^d, \quad b \in \mathbb{R}^d$$

является сильно выпуклой.

Решение. Напомним, что $\nabla f(x) = Ax + b$. Тогда

$$\begin{aligned} f(y) - f(x) - \langle \nabla f(x), y - x \rangle &= \frac{1}{2}y^\top Ay - \frac{1}{2}x^\top Ax - x^\top A(y - x) \\ &= \frac{1}{2}(y - x)^\top A(y - x). \end{aligned}$$

Пользуясь Определением C4.10, получим условие, при котором $f(x)$ μ -сильно выпукла:

$$(y - x)^\top A(y - x) \geq \mu\|y - x\|_2^2 \implies (y - x)^\top (A - \mu I)(y - x) \geq 0.$$

Таким образом, должно выполняться $A \succeq \mu I_d$.

■

Теорема C4.5 (Критерий μ -сильно выпуклости второго порядка). Рассмотрим собственную дважды непрерывно дифференцируемую функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$, у которой $\text{dom } f$ — выпуклое открытое множество. Функция μ -сильно выпукла тогда и только тогда, когда

$$\nabla^2 f(x) \succeq \mu I_d, \quad \forall x \in \text{dom } f.$$

Доказательство. Если g — μ -сильно выпуклая функция, то $g(x) = f(x) - \frac{\mu}{2}\|x\|_2^2$ является выпуклой. Действительно, воспользуемся Определением С4.10:

$$g(x) = f(x) - \frac{\mu}{2}\|x\|_2^2 \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2}\|x - y\|_2^2 - \frac{\mu}{2}\|x\|_2^2.$$

Заметим, что $\|x\|_2^2 = \|y\|_2^2 + 2\langle y, x - y \rangle + \|x - y\|_2^2$ и получим

$$\begin{aligned} g(x) &\geq f(y) - \frac{\mu}{2}\|y\|_2^2 + \langle \nabla f(y), x - y \rangle + \left(\frac{\mu}{2} - \frac{\mu}{2}\right)\|x - y\|_2^2 \\ &= g(y) + \langle \nabla g(y), x - y \rangle. \end{aligned}$$

Подставим $g(x)$ в критерий выпуклости второго порядка и получим $\nabla^2 f(x) \succeq \mu I_d$. ■

Замечание С4.10. Константу сильной выпуклости можно искать как

$$\mu = \lambda_{\min}(\nabla^2 f(x)).$$

Замечание С4.11. Рассмотрим L -гладкую собственную дважды непрерывно дифференцируемую функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Запишем для неё L -гладкость (Определение Л2.5):

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2 \implies \frac{\|\nabla f(x) - \nabla f(y)\|_2}{\|x - y\|_2} \leq L.$$

При $y \rightarrow x$ получаем: $\|\nabla^2 f(x)\|_2 \leq L$, то есть $\max_i |\lambda_i(\nabla^2 f(x))| \leq L$. Если функция $f(x)$ является ещё и μ -сильно выпуклой, то:

$$\mu I_d \preceq \nabla^2 f(x) \preceq L I_d.$$

С5 Субдифференциал

В приложениях теории оптимизации порой приходится иметь дело с негладкой целевой функцией. Например, когда она задана как поточечный максимум по конечному множеству индексов. В таком случае требуется обобщить определение производной для функций, недифференцируемых в некоторых точках. Понятие субдифференциала позволяет формализовать условия оптимальности и строить методы, аналогичные градиентным, даже когда градиента в привычном смысле не существует.

В рамках этой главы мы вновь будем рассматривать функции, расширенные на всё пространство.

Определение С5.1. Пусть в евклидовом пространстве V определена собственная функция $f : V \rightarrow \mathbb{R}$. Субградиентом функции f в точке $x_0 \in \text{dom } f$ называется вектор $g \in V$ такой, что

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle, \quad \forall x \in \text{dom } f.$$

То есть субградиент в точке x_0 определяет гиперплоскость в пространстве V , которая подпирает снизу надграфик функции f в любой точке. Таким образом, для функций, определённых на множестве действительных чисел, субградиент достаточно легко находить графически.

Замечание С5.1. Из определения выше можно заметить, что субградиент зависит от введённого скалярного произведения. Поэтому при его нахождении важно указывать, как задано скалярное произведение. Мы же далее будем рассматривать стандартное скалярное произведение, если не оговорено другое.

Замечание С5.2. Понятие субградиента можно обобщить для функций $f : V \rightarrow \overline{\mathbb{R}}$, где V не обязательно евклидово (то есть скалярное произведение на этом пространстве может быть не определено). Тогда для функции f можно определить субградиент $g \in V^*$ как элемент сопряжённого пространства к V (то есть пространства всевозможных линейных непрерывных функционалов на V), при этом операция $\langle g, x \rangle$ интерпретируется как действие линейного функционала g на элемент x .

Определение С5.2. Пусть в евклидовом пространстве V определена собственная функция $f : V \rightarrow \overline{\mathbb{R}}$. Множество всех субградиентов функции в точке $x_0 \in \text{dom } f$ называется субдифференциалом функции f в точке x_0 и обозначается $\partial f(x_0)$:

$$\partial f(x_0) = \{ g \in V \mid f(x) \geq f(x_0) + \langle g, x - x_0 \rangle, \quad \forall x \in \text{dom } f \}.$$


Для $x_0 \notin \text{dom } f$ будем полагать $\partial f(x_0) = \emptyset$.

Замечание С5.3. Если субдифференциал в некоторой точке содержит хотя бы один элемент, то функция называется субдифференцируемой в этой точке.

Пример С5.1. Найдите субдифференциал функции $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}: f(x) = |x|$ в точке $x = 0$.

Решение. 1. Графический способ.

Рассмотрим график функции $f(x) = |x|$ и заметим, что любая прямая $y = ax$, где $a \in [-1, 1]$, проходит через точку $(0, 0)$ и в любой другой точке проходит не выше, чем $y = |x|$. Причём, если $|a| > 1$, то $y = ax$ уже лежит выше $y = |x|$. Таким образом, $\partial f(0) = [-1, 1]$.



2. По определению.

$f(x) = |x|$ и $f(0) = 0$. По определению, вектор $g \in \mathbb{R}$ является субградиентом для функции $f(x) = |x|$ в точке 0, если $\forall x \in \mathbb{R} \quad |x| \geq gx$. Решая данное неравенство, мы получаем, что оно выполняется для всех $g \in [-1, 1]$ и только для таких g . ■

Пример C5.2. Рассмотрите отображение $f : \mathbb{S}^d \rightarrow \mathbb{R}$, определенное как

$$f(X) = \lambda_{\max}(X).$$

Найдите субградиент $g \in \partial f(X)$.

Решение. Пусть v — нормированный собственный вектор, соответствующий максимальному собственному числу матрицы X . Рассмотрим еще одну матрицу $Y \in \mathbb{S}^d$. Заметим, что

$$\lambda_{\max}(Y) = \max_{\|u\|=1} \{u^\top Y u\} \geq v^\top Y v.$$

Добавим $v^\top X v$ в качестве умного нуля к правой части неравенства. Получим

$$\lambda_{\max}(Y) \geq v^\top X v + v^\top (Y - X) v = \lambda_{\max}(X) + \text{Tr}(v v^\top (Y - X)).$$

Осталось заметить, что $\text{Tr}(v v^\top (Y - X)) = \langle v v^\top, Y - X \rangle$. Таким образом, $v v^\top \in \partial f(X)$. ■

Следующий пример чуть более прикладной.

Пример C5.3. Пусть заданы выпуклые функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$, $h : \mathbb{R}^d \rightarrow \mathbb{R}^n$. Рассмотрим функцию $d : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$d(\lambda) = - \min_{x \in \mathbb{R}^d} \{f(x) + \lambda^\top h(x)\}.$$

Найдите субградиент $g \in \partial d(\lambda)$.

Решение. Рассмотрим $\lambda_0 \in \text{dom } d$ и пусть

$$\min_{x \in \mathbb{R}^d} \{f(x) + \lambda_0^\top h(x)\}$$

достигается в точке $x_0 \in \mathbb{R}^d$. Тогда распишем:

$$\begin{aligned} d(\lambda) &= - \min_{x \in \mathbb{R}^d} \{f(x) + \lambda^\top h(x)\} \geq -f(x_0) - \lambda^\top h(x_0) \\ &= -f(x_0) - \lambda_0^\top h(x_0) + (\lambda_0 - \lambda)^\top h(x_0) \\ &= d(\lambda_0) + \langle -h(x_0), \lambda - \lambda_0 \rangle. \end{aligned}$$

Таким образом, $-h(x_0) \in \partial d(\lambda_0)$. ■

Важнейшим примером является субдифференциал произвольной нормы $\|\cdot\|$.

Пример С5.4. Пусть $\|\cdot\|$ — произвольная норма в евклидовом пространстве V и пусть $\|\cdot\|_*$ — сопряжённая к ней норма. Рассмотрите $f(x) = \|x\|$ и покажите, что субградиент равен:

$$\partial f(x) = \begin{cases} \overline{B}_{\|\cdot\|_*}(0, 1), & x = 0, \\ \{g \in V \mid \|g\|_* \leq 1, \langle g, x \rangle = \|x\|\}, & x \neq 0. \end{cases}$$

где $\overline{B}_{\|\cdot\|_*}(0, 1) = \{g \in V \mid \|g\|_* \leq 1\}$ — единичный шар в сопряжённой норме с центром в точке 0.

Решение. Пусть $g \in V$ и g является субградиентом $f(x) = \|x\|$ в точке x_0 . Тогда верно неравенство

$$\|x\| \geq \|x_0\| + \langle g, x - x_0 \rangle \quad \forall x \in V.$$

Перепишем данное неравенство

$$\langle g, x \rangle - \|x\| \leq \langle g, x_0 \rangle - \|x_0\| \quad \forall x \in V.$$

Так как данное неравенство верно $\forall x \in V$, то оно верно и для супремума левой части по множеству V :

$$\sup_{x \in V} \{\langle g, x \rangle - \|x\|\} \leq \langle g, x_0 \rangle - \|x_0\|.$$

Но так как в точке x_0 данное неравенство переходит в равенство, то супремум левой части достигается в точке x_0 . Поэтому

$$\sup_{x \in V} \{\langle g, x \rangle - \|x\|\} = \langle g, x_0 \rangle - \|x_0\|.$$

Теперь попробуем вычислить супремум аналитически. Предположим сначала, что $\|g\|_* > 1$. Тогда по определению сопряжённой нормы существует такой $\hat{x}$, что $\|\hat{x}\| \leq 1$ и $\langle g, \hat{x} \rangle > 1$. Возьмем $x = t\hat{x}$. Тогда

$$\langle g, x \rangle - \|x\| = t(\langle g, \hat{x} \rangle - \|\hat{x}\|) \rightarrow \infty, \quad t \rightarrow \infty,$$

поскольку выражение в скобках положительно, то есть супремум неограничен. Предположим теперь, что $\|g\|_* \leq 1$. Тогда, пользуясь неравенством Гёльдера (0.2), запишем

$$\langle g, x \rangle - \|x\| \leq \|x\|(\|g\|_* - 1) \leq 0.$$

Таким образом, имеем два условия на субдифференциал в точке x_0 :

$$\|g\|_* \leq 1, \quad \langle g, x_0 \rangle = \|x_0\|.$$
■

С5.1 Свойства субдифференциала

С точки зрения численных методов, в первую очередь, субдифференциал должен состоять хотя бы из одного элемента, чтобы было возможно сделать эффективный шаг. Во-вторых, для устойчивой сходимости хотелось бы уметь гарантировать, что выбранный субградиент не может быть неограниченно большим. Таким образом, существуют два критических вопроса: непустота субдифференциала и его ограниченность. Ниже мы сформулируем несколько достаточных условий, начиная с более сильных и постепенно ослабляя их.

Теорема С5.1. Пусть в евклидовом пространстве V определена выпуклая функция $f : V \rightarrow \mathbb{R}$, $\text{dom } f$ — выпуклое множество. Если $x_0 \in \text{int dom } f$, то $\partial f(x_0)$ — непустое ограниченное множество.

Доказательство. Рассмотрим точку $(x_0, f(x_0))$. По Определению С4.4 надграфика ер f , она находится на его границе. Тогда по Теореме С3.6 отделимости существует ненулевой вектор $(p, -\lambda)$, такой что

$$\langle p, x_0 \rangle - \lambda f(x_0) \geq \langle p, x \rangle - \lambda t, \quad \forall (x, t) \in \text{epi } f. \quad (\text{С5.1})$$

Здесь мы отделяем выпуклое множество от точки, не принадлежащей его внутренности. Заметим, что $(x_0, f(x_0) + 1) \in \text{epi } f$. В совокупности с теоремой отделимости это означает

$$\langle p, x_0 \rangle - \lambda f(x_0) \geq \langle p, x_0 \rangle - \lambda(f(x_0) + 1),$$

откуда следует неотрицательность λ . Из курса математического анализа известно, что из выпуклости f и условия $x_0 \in \text{int dom } f$ следует существование окрестности $B(x_0, \varepsilon) \subset \text{int dom } f$, такой что

$$|f(\hat{x}) - f(x_0)| \leq M \|\hat{x} - x_0\|, \quad \forall \hat{x} \in B(x_0, \varepsilon).$$

Резюмируя, запишем

$$\langle p, \hat{x} - x_0 \rangle \leq \lambda \hat{t} - \lambda f(x_0) \leq \lambda M \|\hat{x} - x_0\|.$$

По следствию из теоремы Рисса-Фреше выберем такое направление $\hat{p}$, что $\|\hat{p}\| = 1$, $\langle p, \hat{p} \rangle = \|p\|_*$ и $x_0 + \varepsilon \hat{p} \in B(x_0, \varepsilon)$. Положим $\hat{x} = x_0 + \varepsilon \hat{p}$. Тогда

$$\varepsilon \|p\|_* \leq \lambda M \varepsilon.$$

Ранее мы уже установили $\lambda \geq 0$. Положим теперь $\lambda = 0$. Тогда автоматически получим $p = 0$, что находится в противоречии с теоремой об отделимости, поскольку $(p, -\lambda)$ — ненулевой вектор. Таким образом, $\lambda > 0$. Выбирая $t = f(x)$ в (С5.1) и осуществляя деление на λ , получаем

$$f(x) \geq f(x_0) + \left\langle \frac{p}{\lambda}, x - x_0 \right\rangle.$$

Это доказывает непустоту субдифференциала. Чтобы показать ограниченность, для произвольного субградиента $g \in \partial f(x_0)$ выберем направление $\hat{g}$, такое что $\|\hat{g}\| = 1$ и $\langle g, \hat{g} \rangle = \|g\|_*$. Выбирая $x = x_0 + \varepsilon \hat{g}$, получаем:

$$\varepsilon \|g\|_* \leq f(x) - f(x_0) \leq M \|x - x_0\| = M \varepsilon.$$

Таким образом, субдифференциал в точке ограничен локальной константой Липшица выпуклой функции. ■

Замечание С5.4. Отметим, что для следования непустоты субдифференциала из выпуклости f существенно, чтобы x_0 принадлежало внутренности эффективного множества. Проиллюстрируем это примером.

Пример C5.5. Рассмотрим функцию $f : \mathbb{R} \rightarrow \bar{\mathbb{R}}$:

$$f(x) = -\sqrt{x}, \quad \text{dom } f = \mathbb{R}_+.$$

Это выпуклая функция, которая, тем не менее, несубдифференцируема в нуле. Предположим, что существует такой $g \in \mathbb{R}$, что:

$$-\sqrt{y} \geq gy, \quad \forall y \geq 0.$$

Подставив $y = 1$, получим $g \leq -1$. Подставив затем $y = \frac{1}{2g^2}$, получим новое условие на g (с учётом $g < -1$):

$$\frac{1}{2g^2} \leq \frac{1}{4g^2}.$$

Это неравенство не может быть выполнено.

Доказанную теорему об ограниченности субдифференциала можно расширить, показав, что даже объединение субдифференциалов по всем точкам компактного подмножества внутренности $\text{dom } f$ ограничено.

Теорема C5.2. Пусть в евклидовом пространстве V определена выпуклая функция $f : V \rightarrow \bar{\mathbb{R}}$, $\text{dom } f$ — выпуклое множество. Пусть $X \subseteq \text{int dom } f$ — непустой компакт. Тогда $Y = \bigcup_{x \in X} \partial f(x)$ — непустое ограниченное множество.

Доказательство. Непустота Y очевидна, поскольку не пуст каждый субдифференциал, поэтому перейдём сразу к доказательству ограниченности. Предположим, что существует последовательность $\{x_k\}_{k=1}^\infty$, такая, что $\|g_k\|_* \rightarrow \infty$, где $g_k \in \partial f(x_k)$. Для каждого g_k выберем вектор $\hat{g}_k$ такой, что $\|\hat{g}_k\| = 1$ и $\langle g_k, \hat{g}_k \rangle = \|g_k\|_*$. Тогда выполнено

$$f(x_k + \varepsilon \hat{g}_k) - f(x_k) \geq \varepsilon \|g_k\|_*.$$

Тогда

$$f(x_k + \varepsilon \hat{g}_k) - f(x_k) \rightarrow \infty. \quad (\text{C5.2})$$

Поскольку обе последовательности существуют на компакте в евклидовых пространствах, из них можно выделить сходящиеся подпоследовательности $\{x_m\}_{m=1}^\infty, \{g_m\}_{m=1}^\infty$:

$$f(x_m + \varepsilon \hat{g}_m) - f(x_m) \rightarrow f(x_{\text{lim}} + \varepsilon \hat{g}_{\text{lim}}) - f(x_{\text{lim}}).$$

Здесь дополнительно воспользовались переходом к пределу под знаком непрерывной функции. Это находится в противоречии с (C5.2). Тогда произвольная $\{g_k\}_{k=1}^\infty$ ограничена. ■

Таким образом, во внутренности эффективного множества субдифференциал обладает рядом полезных свойств, позволяющих строить эффективные методы. Однако есть и ряд патологических случаев. Например, если целевая функция задана на подмножестве, имеющем меньшую размерность, чем объёмлющее пространство.

Теорема C5.3. Пусть в евклидовом пространстве V определена собственная функция $f : V \rightarrow \bar{\mathbb{R}}$. Пусть $\dim \text{dom } f < \dim V$ и $\partial f(x_0) \neq \emptyset$ для некоторой $x_0 \in \text{dom } f$. Тогда $\partial f(x_0)$ — неограниченное множество.

Доказательство. Зафиксируем произвольный $g \in \partial f(x_0)$. Напомним, что размерность множества мы определяли как размерность его аффинной оболочки. Тогда для $\widehat{V} = \text{aff dom } f - \{x_0\}$ имеем

$$\dim \widehat{V} < \dim V.$$

В частности, это значит, что существует ненулевой вектор $v \in V$ такой, что

$$\langle v, w \rangle = 0, \quad \forall w \in \widehat{V}.$$

Воспользуемся определением субградиента:

$$f(y) \geq f(x) + \langle g, y - x \rangle = f(x) + \langle g + \lambda v, y - x \rangle.$$

Это означает, что $g + \lambda v \in \partial f(x_0)$ для любых значений λ . Таким образом, субдифференциал — неограниченное множество. ■




Рис. С5.1: Пример, когда субдифференциал — неограниченное множество.

Поговорим теперь про случай дифференцируемой функции. Интуитивно понятно, что субдифференциал либо пуст, либо является одноточечным множеством, состоящим из градиента. Формализуем это в виде утверждения.

Утверждение С5.1. Пусть в евклидовом пространстве V определена собственная функция $f : V \rightarrow \mathbb{R}$, $\text{dom } f$ — выпуклое множество, и пусть задана точка $x_0 \in \text{int dom } f$, в которой функция f является дифференцируемой. Тогда $\partial f(x_0) = \emptyset$ или $\partial f(x_0) = \{\nabla f(x_0)\}$. Если функция f является выпуклой, тогда $\partial f(x_0) = \{\nabla f(x_0)\}$.

Доказательство. Если функция дифференцируема, то g определено единственным образом. В случае выпуклой функции, линейная аппроксимация с g подпирает график функции снизу — субдифференциал состоит из одного элемента. В противном случае, единственная касательная не подпирает график снизу, и субдифференциал оказывается пустым. ■

Пример С5.6. Найдите субдифференциал функции $f : \mathbb{R} \rightarrow \overline{\mathbb{R}} : f(x) = |x|$.

Решение. Заметим, что данная функция является дифференцируемой при $x \neq 0$ и выпуклой. Тогда, применяя Утверждение С5.1, мы получаем, что $\partial f(x) = f'(x) = \text{sign}(x)$, при $x \neq 0$. В Примере С5.1 мы получили, что $\partial f(0) = [-1, 1]$. Таким образом,

$$\partial|x| = \begin{cases} -1, & x < 0 \\ [-1, 1], & x = 0 \\ 1, & x > 0. \end{cases}$$

■

Пример С5.7. Найдите субдифференциал функции $f : \mathbb{R}^2 \rightarrow \overline{\mathbb{R}}$:

$$f(x, y) = \cos(xy).$$

Решение. Заметим, что функция $f(x, y)$ дифференцируема на всём $\mathbb{R}^2$, а значит, её субдифференциал есть пустое множество, либо состоит только из градиента. Осталось понять, где градиент дает нижнюю оценку функции. Для этого найдем её минимум:

$$\min f(x, y) = -1, \text{ при } y = \frac{\pi(1+2k)}{x}, k \in \mathbb{Z}.$$

Так как субградиент — это касательная плоскость, подпирающая нашу функцию снизу, то он может существовать только в точках, где $\cos(xy) = -1$, остается только найти в них градиент:

$$\begin{aligned} \frac{\partial f}{\partial x} &= -\sin(xy) \cdot y = -\sin(\pi(1+2k)) \cdot y = 0, \\ \frac{\partial f}{\partial y} &= -\sin(xy) \cdot x = -\sin(\pi(1+2k)) \cdot x = 0. \end{aligned}$$

В точках $\left(x, \frac{\pi(1+2k)}{x}\right)$, $k \in \mathbb{Z}$ субградиент единственен и равен $(0, 0)$. В остальных точках субградиента не существует. ■

Заметим, что, хоть непустота субдифференциала и не является необходимым условием выпуклости функции, её можно использовать как достаточное условие.

Утверждение С5.2. Пусть в евклидовом пространстве V определена собственная функция $f : V \rightarrow \overline{\mathbb{R}}$, $\text{dom } f$ — выпуклое множество. Если для любого $x \in \text{dom } f$ субдифференциал $\partial f(x)$ непуст, то f — выпуклая функция.

Доказательство. Зафиксируем произвольные $x, y \in \text{dom } f$ и определим $z = \lambda x + (1 - \lambda)y$, где $\lambda \in [0, 1]$. Поскольку $\text{dom } f$ выпуклое, имеем $z \in \text{dom } f$. Из непустоты субдифференциала в любой точке эффективного множества имеем

$$\begin{aligned} f(y) &\geq f(z) + \langle g, y - z \rangle = f(z) + \lambda \langle g, y - x \rangle, \\ f(x) &\geq f(z) + \langle g, x - z \rangle = f(z) - (1 - \lambda) \langle g, y - x \rangle. \end{aligned}$$

Умножим первое неравенство на $1 - \lambda$, второе — на λ . Сложив получившиеся неравенства, получим

$$f(z) \leq \lambda f(x) + (1 - \lambda)f(y).$$

Тогда f выпукла по определению. ■

Утверждение С5.3. Пусть в евклидовом пространстве V определена выпуклая функция $f : V \rightarrow \overline{\mathbb{R}}$. Точка $x_0 \in \text{dom } f$ является минимумом функции $f(x)$ тогда и только тогда, когда

$$\exists g \in \partial f(x_0) : \langle g, x - x_0 \rangle \geq 0 \quad \forall x \in \text{dom } f.$$

В случае $\text{dom } f = V$ имеем в качестве критерия $0 \in \partial f(x_0)$.

Пример С5.8. Пусть функция $f : \mathbb{R} \rightarrow \mathbb{R}$ задана следующим образом: $f(x) = |x|$. Покажите, что у данной функции минимум достигается в точке 0.

Решение. Воспользуемся Теоремой С5.3 и получим, что минимум достигается в точке $x = 0$ и только в ней, так как $0 \in \partial f(0) = [-1, 1]$ и при этом $0 \notin \partial f(x) = \text{sign } x$ при $x \neq 0$. ■

Теорема С5.4. Пусть в евклидовом пространстве V определена выпуклая функция $f : V \rightarrow \overline{\mathbb{R}}$, $\text{dom } f$ — выпуклое множество. Если $x_0 \in \text{int dom } f$, то $\partial f(x_0)$ — выпуклый компакт.

Доказательство. В евклидовом случае достаточно показать, что $\partial f(x_0)$ — ограничено и замкнуто. Ограниченность мы уже показали ранее. Заметим, что субдифференциал можно представить как

$$\partial f(x_0) = \bigcap_{y \in V} \{ g \in V \mid f(y) \geq f(x) + \langle g, y - x \rangle \}.$$

Таким образом, субдифференциал — пересечение полуплоскостей. Как следствие, он выпуклый и замкнутый. В совокупности с ограниченностью получаем компактность. ■

С5.2 Субдифференциальное исчисление

Для начала сформулируем определение относительной окрестности.

Определение С5.3. Рассмотрим подмножество S некоторого евклидового пространства V . Множество $\text{ri}(x_0, \varepsilon) = B(x_0, \varepsilon) \cap \text{aff } S$ называется *относительной окрестностью точки* $x_0 \in S$.

Неформально, относительная окрестность точки — есть обыкновенная окрестность в объемлющем пространстве, суженная на аффинное продолжение интересующего нас множества. Этот объект позволяет ввести, например, внутренние точки для отрезка на плоскости.

Определение С5.4. Рассмотрим подмножество S некоторого евклидового пространства V . Точка x_0 называется *относительно внутренней точкой множества* S , если существует $\varepsilon > 0$, такое что $\text{ri}(x_0, \varepsilon) \subset S$.

Определение С5.5. Рассмотрим подмножество S некоторого евклидового пространства V . *Относительной внутренней точкой* $\text{relint}(S)$ множества S называется множество всех его относительно внутренних точек.

Отметим, что субдифференциал линеен относительно умножения на неотрицательную константу.

Утверждение С5.4. Пусть в евклидовом пространстве V определена функция $f : V \rightarrow \mathbb{R}$, $\alpha > 0$ и пусть $x_0 \in \text{dom } f$. Тогда

$$\partial(\alpha f)(x_0) = \alpha \partial f(x_0).$$

Очевидно, что для отрицательной константы это правило не работает, так как меняется знак неравенства и функция перестает быть субдифференцируемой.

В случае привычного нам дифференцирования производная была линейным оператором. Аналог этого свойства для субдифференциалов дает теорема Моро-Рокафеллара.

Теорема С5.5 (Моро-Рокафеллара). Пусть в евклидовом пространстве V определены n выпуклых функций $f_i : V \rightarrow \mathbb{R}$. Определим их взвешенную сумму

$$f(x) = \sum_{i=1}^n \alpha_i f_i(x), \quad \alpha_i > 0.$$

Тогда в точке $x_0 \in \cap_{i=1}^n \text{relint dom } f_i$:

$$\partial f(x_0) = \sum_{i=1}^n \alpha_i \partial f_i(x_0),$$

где под суммой субдифференциалов подразумевается сумма Минковского.

Пример С5.9. Рассмотрим функцию $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

$$f(x) = -\sqrt{x}, \quad \text{dom } f = \mathbb{R}_+$$

и функцию $g : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

$$g(x) = -\sqrt{-x}, \quad \text{dom } g = \mathbb{R}_-.$$

Тогда $\partial(f+g)(0) = \mathbb{R}$, так как сумма определена только в точке 0 и $(f+g)(0) = 0$. Но при этом $\partial f(0) = \partial g(0) = \emptyset$. Это было разобрано в Примере С5.5.

Часто встречаемый в оптимизации пример — композиция какой-то функции с аффинным отображением.

Теорема С5.6. Пусть V и W — евклидовы пространства. Определим функцию $T : V \rightarrow W$: $T(x) = Ax + b$ и выпуклую функцию $f : W \rightarrow \overline{\mathbb{R}}$. Тогда для $T(x_0) \in \text{relint dom } f$ выполнено

$$\partial(f \circ T)(x_0) = A^\top \partial f(T(x_0)).$$

Пример С5.10. Найдите субдифференциал функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \|Ax + b\|_2, \quad A \in \mathbb{R}^{n \times d}, \quad b \in \mathbb{R}^n.$$

Решение. Норма — выпуклая функция, заданная на всем пространстве. Таким обра-

зом, можем воспользоваться Теоремой C5.6 и записать

$$\partial f(x) = A^\top \partial(\|z\|_2) \Big|_{z=Ax+b}.$$

Воспользуемся частным случаем Примера C5.4:

$$\partial(\|z\|_2) = \begin{cases} B_{\|\cdot\|_2}(0, 1), & z = 0, \\ \frac{z}{\|z\|_2}, & z \neq 0. \end{cases}$$

Таким образом, имеем

$$\partial f(x) = \begin{cases} \{ A^\top u \mid \|u\|_2 \leq 1 \}, & Ax + b = 0 \\ \frac{A^\top (Ax+b)}{\|Ax+b\|_2}, & Ax + b \neq 0. \end{cases}$$

■

В матрично-векторном дифференцировании ключевую роль играло правило дифференцирования сложной функции. Его аналог для субдифференциалов даёт следующая теорема.

Теорема C5.7. Пусть в евклидовом пространстве V определена выпуклая функция $g : V \rightarrow \mathbb{R}$ и функция $\varphi : \mathbb{R} \rightarrow \overline{\mathbb{R}}$ — выпуклая монотонная неубывающая функция. Рассмотрим $f(x) = \varphi(g(x))$, тогда:

$$\partial f(x) = \{ pv \mid p \in \partial \varphi(g(x)), v \in \partial g(x) \}.$$

Пример C5.11. Найдите субдифференциал функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}} : f(x) = \|x\|_2^2$.

Решение. Норма — выпуклая функция, $\varphi(u) = u^2$ — монотонная неубывающая на области значений нормы. Таким образом, имеем

$$\partial f(x) = 2\|x\|_2 \partial(\|x\|_2).$$

Выражение для субдифференциала нормы было посчитано ранее.

■

Пример C5.12. Найдите субдифференциал функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \exp(\|Ax + b\|_2), \quad A \in \mathbb{R}^{n \times d}, \quad b \in \mathbb{R}^n.$$

Решение. $\|Ax + b\|_2$ — выпуклая функция как композиция выпуклой и аффинной. Экспонента — монотонная возрастающая функция. Запишем

$$\partial f(x) = \exp(\|Ax + b\|_2) \partial(\|Ax + b\|_2).$$

Воспользуемся правилом субдифференцирования композиции выпуклой и аффинной функции

$$\partial f(x) = \exp(\|Ax + b\|_2) A^\top \partial(\|z\|_2) \Big|_{z=Ax+b}.$$

Как результат, получим

$$\partial f(x) = \begin{cases} \{ A^\top u \mid \|u\|_2 \leq 1 \}, & Ax + b = 0 \\ \frac{\exp(\|Ax+b\|_2) A^\top (Ax+b)}{\|Ax+b\|_2}, & Ax + b \neq 0. \end{cases}$$

■

Последний теоретический результат, который мы рассмотрим в рамках параграфа — теорема Дубовицкого-Милютинана.

Теорема С5.8 (Дубовицкого-Милютинана). Пусть в евклидовом пространстве V определены n выпуклых функций $f_i : V \rightarrow \mathbb{R}$. Определим

$$f(x) = \max_{i=1, n} f_i(x).$$

Тогда для $x_0 \in \cap_{i=1}^n \text{relint dom } f_i$ выполнено

$$\partial f(x_0) = \text{conv} \{ \cup_{i \in I(x_0)} \partial f_i(x_0) \},$$

где $I(x_0) = \{ i \in \overline{1, n} \mid f(x_0) = f_i(x_0) \}$ — активное множество в точке x_0 .

Эта теорема оказывается крайне полезной для получения более сильных выражений. Для начала вернемся к простому примеру из начала главы.

Пример С5.13. Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \mathbb{R} : f(x) = |x|$. Вычислим $\partial f(x)$. Заметим, что $f(x) = |x| = \max \{x, -x\}$. Для $x < 0$ и $x > 0$ активное множество состоит из одного индекса. Учитывая, что модуль — выпуклая функция, определённая на всем пространстве, получаем

$$\partial f(x) = \begin{cases} 1, & x > 0 \\ -1, & x < 0. \end{cases}$$

Если $x = 0$, то активное множество включает в себя оба индекса. Это означает

$$\partial f(0) = [-1, 1].$$

Перейдём к более сложному примеру.

Пример С5.14. Найдите субдифференциал функции $f : \mathbb{R}^d \rightarrow \mathbb{R} : f(x) = \|x\|_1$.

Решение. Заметим, что $f(x) = \sum_{i=1}^d |x_i|$. Это выпуклая функция, определённая на всём пространстве. Воспользуемся теоремой Моро-Рокафеллара:

$$\partial f(x) = \sum_{i=1}^d \partial(|x_i|).$$

Далее покомпонентно воспользуемся утверждением прошлого примера и запишем ответ в форме суммы Минковского:

$$\partial f(x) = \sum_{i \in I_{\neq}(x)} e_i \text{sign } x_i + \sum_{i \in I_{=}(x)} [-e_i, e_i],$$

где $I_{\neq}(x) = \{ i \mid x_i \neq 0 \}$, $I_=(x) = \{ i \mid x_i = 0 \}$. ■

Замечание С5.5. На практике, если необходим лишь какой-то элемент субдифференциала, можно брать $g = \text{sign } x$ — покомпонентное взятие знака.

Пример С5.15. Найдите субдифференциал функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \|Ax + b\|_1, \quad A \in \mathbb{R}^{n \times d}, \quad b \in \mathbb{R}^n.$$

Решение. По правилу субдифференцирования аффинной композиции имеем

$$\partial f(x) = A^\top \partial(\|z\|_1) \Big|_{z=Ax+b}.$$

Введём активные множества как

$$\begin{aligned} I_{\neq}(x) &= \left\{ i \mid a_i^\top x + b_i \neq 0 \right\}, \\ I_=(x) &= \left\{ i \mid a_i^\top x + b_i = 0 \right\}, \end{aligned}$$

где a_i — соответствующая строка матрицы A . Таким образом,

$$\partial(\|z\|_1) \Big|_{z=Ax+b} = \sum_{i \in I_{\neq}(x)} e_i \text{sign}(a_i^\top x + b_i) + \sum_{i \in I_=(x)} [-e_i, e_i].$$

Объединяя полученные результаты, запишем ответ:

$$\begin{aligned} \partial f(x) &= \sum_{i \in I_{\neq}(x)} A^\top e_i \text{sign}(a_i^\top x + b_i) + \sum_{i \in I_=(x)} [-A^\top e_i, A^\top e_i] \\ &= \sum_{i \in I_{\neq}(x)} a_i \text{sign}(a_i^\top x + b_i) + \sum_{i \in I_=(x)} [-a_i, a_i]. \end{aligned}$$

■

С6 Сопряжённые функции Фенхеля

Сопряжённые функции Фенхеля — важный инструмент, лежащий в основе теории двойственности. В нашем курсе мы познакомимся с определением сопряжения по Фенхелю, его интуитивной интерпретацией и основными свойствами. Выясним, как оно помогает имплементировать сопряжённые методы, получать нижнюю оценку на значение целевой функции в оптимуме или даже сводить оптимизационную задачу к более простой, имеющей очевидное аналитическое решение.

С6.1 Определение сопряжённой функции Фенхеля

Определение С6.1. Пусть $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Функция $f^* : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$, определённая как

$$f^*(y) = \sup_{x \in \mathbb{R}^d} \{ \langle x, y \rangle - f(x) \}$$

называется *сопряжённой функцией Фенхеля* к f .

Замечание С6.1. Здесь и далее вместо $\mathbb{R}^d$ можно рассматривать и другие пространства, которые изоморфны $\mathbb{R}^d$, например матричное пространство $\mathbb{R}^{d \times n}$ или пространство симметричных матриц $\mathbb{S}^d$.

Далее в рамках этой главы сопряжённые функции Фенхеля будем называть просто сопряжёнными функциями. Сопряжённая функция в точке $y \in \mathbb{R}^d$ показывает, насколько нужно сдвинуть график функции f , чтобы линейная функция $g(x) = \langle x, y \rangle$ подпирала его снизу. Иными словами, Определение С6.1 показывает, насколько та или иная функция отличается от линейной.




Рис. С6.1: Зазор показан пунктирными линиями. Если $f(x)$ дифференцируема, то пунктирная линия касается f в точке x , где $f'(x) = y$.

Из интуитивного объяснения определения должно быть ясно, что сопряжённая функция к аффинной функции с константным сдвигом — функция, тождественно равная сдвигу с обратным знаком.

Пример С6.1. Найдите сопряжённую функцию к аффинной функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \langle a, x \rangle + b, \quad a \in \mathbb{R}^d, \quad b \in \mathbb{R}.$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x \in \mathbb{R}^d} \{ \langle y, x \rangle - \langle a, x \rangle - b \} = \sup_{x \in \mathbb{R}^d} \{ \langle y - a, x \rangle - b \}.$$

Понятно, что в случае $y \neq a$ имеем две гиперплоскости с разными нормальными векторами. Как следствие, ни одна из них не может подпирать другую и $f^*(y) = +\infty$. Если же $y = a$, то $f^*(y) = -b$. Таким образом, имеем

$$f^*(y) = \begin{cases} -b, & y = a, \\ +\infty, & y \neq a. \end{cases}$$

■

Обратим внимание, что сопряжённая функция принимает значения в расширенной числовой прямой. Понятно, что с точки зрения практики интересен случай, когда она гарантированно принимает конечные значения на каком-то множестве переменных. Это можно гарантировать, если наложить дополнительные условия на функцию f .

Утверждение С6.1. Пусть $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ — замкнутая выпуклая функция. Тогда сопряжённая функция $f^* : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ выпуклая.

Доказательство. f^* — выпуклая функция, как супремум аффинных функций. ■

С6.2 Вычисление сопряжённой функции в одномерном случае

В этой секции рассмотрим ряд одномерных примеров, чтобы уловить интуицию и отработать технику. Примеры даны по возрастанию сложности.

Пример С6.2. Найдите сопряжённую функцию к функции $f : \mathbb{R} \rightarrow \mathbb{R}$:

$$f(x) = e^x.$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x \in \mathbb{R}} \{ xy - e^x \}.$$

Попытаемся вычислить максимум вогнутой функции $g(x) = xy - e^x$. Запишем производную:

$$g'(x) = y - e^x = 0.$$

Рассмотрим случаи:

- $y > 0$. Уравнение разрешимо и $x = \log y$. Подставляя в определение, получаем:

$$f^*(y) = y \log y - y.$$

- $y = 0$. Поскольку $-f(x) \rightarrow 0$ при $x \rightarrow -\infty$, то:

$$f^*(y) = 0.$$

- $y < 0$. Поскольку $g(x) \rightarrow +\infty$ при $x \rightarrow -\infty$, то:

$$f^*(y) = +\infty.$$

Таким образом, имеем

$$f^*(y) = \begin{cases} y \log y - y, & y \geq 0, \\ +\infty, & y < 0. \end{cases}$$

Здесь мы доопределяем $0 \log 0 = 0$ пределом по непрерывности. ■

Замечание С6.2. Отметим, что далее в курсе мы будем регулярно использовать факт $0 \log 0 = 0$.

Пример С6.3. Найдите сопряжённую функцию к функции $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

$$f(x) = -\log x, \quad \text{dom } f = \mathbb{R}_{++}.$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x>0} \{xy + \log x\}.$$

Попытаемся вычислить максимум вогнутой функции $g(x) = xy + \log x$. Запишем производную:

$$g'(x) = y + \frac{1}{x} = 0.$$

Рассмотрим случаи:

- $y < 0$. Уравнение разрешимо и $x = -\frac{1}{y}$. Подставляя в определение, получаем:

$$f^*(y) = -1 - \log(-y).$$

- $y \geq 0$. Поскольку $g(x) \rightarrow +\infty$ при $x \rightarrow \infty$, то:

$$f^*(y) = +\infty.$$

Таким образом:

$$f^*(y) = \begin{cases} -1 - \log(-y), & y < 0, \\ +\infty, & y \geq 0. \end{cases}$$
■

Пример С6.4. Найдите сопряжённую функцию к hinge loss $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \max \{1 - x, 0\}.$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x \in \mathbb{R}} \{yx - \max \{1 - x, 0\}\}.$$

Вспомним полезное свойство

$$-\max\{a, b\} = \min\{-a, -b\}.$$

Занося yx под минимум, получим

$$f^*(y) = \sup_{x \in \mathbb{R}} \{\min\{(1+y)x - 1, yx\}\}.$$

Рассмотрим $g(x) = \min\{(1+y)x - 1, yx\}$ более детально. Заметим, что

$$g(x) = \begin{cases} (1+y)x - 1, & x \leq 1, \\ yx, & x > 1. \end{cases}$$

Таким образом, $g(x)$ — кусочно-линейная функция. Нетрудно видеть, что она имеет конечный максимум тогда и только тогда, когда наклон левой ветви неотрицательный, а наклон правой — неположительный. Таким образом, сопряжённая функция конечна только для y , удовлетворяющих системе неравенств

$$\begin{cases} 1+y \geq 0 \\ y \leq 0. \end{cases}$$

При этом ясно, что максимум в таком случае достигается в точке перелома $x = 1$ и равен y . Таким образом:

$$f^*(y) = \begin{cases} y, & y \in [-1, 0], \\ +\infty, & y \notin [-1, 0]. \end{cases}$$

■

Пример С6.5. Найдите сопряжённую функцию к функции $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \frac{1}{p}|x|^p, \quad p > 1.$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x \in \mathbb{R}} \left\{ xy - \frac{1}{p}|x|^p \right\}.$$

Попытаемся вычислить максимум вогнутой функции $g(x) = xy - \frac{1}{p}|x|^p$. Запишем производную:

$$g'(x) = y - \text{sign } x |x|^{p-1} = 0.$$

Попытаемся решить уравнение. Записав $y = \text{sign } y |y|$, поймем, что $\text{sign } x = \text{sign } y$ и $|x|^{p-1} = |y|$. Таким образом:

$$|x| = |y|^{\frac{1}{p-1}}.$$

Тогда сопряжённая функция к f :

$$f^*(y) = \left(1 - \frac{1}{p}\right) |y|^{\frac{p}{p-1}} = \frac{1}{q} |y|^q,$$

где q удовлетворяет уравнению

$$\frac{1}{p} + \frac{1}{q} = 1.$$

■

Замечание С6.3. Пример выше намекает на связь между сопряжёнными нормами и сопряжением по Фенхелю.

Пример С6.6. Найдите сопряжённую функцию к функции $f : \mathbb{R} \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \log(1 + e^x).$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x \in \mathbb{R}} \{xy - \log(1 + e^x)\}.$$

Попытаемся вычислить максимум вогнутой функции $g(x) = xy - \log(1 + e^x)$. Запишем производную:

$$g'(x) = y - \frac{e^x}{1 + e^x} = 0.$$

Рассмотрим случаи:

- $y \in (0, 1)$. Уравнение разрешимо и $x = \log y - \log(1 - y)$. Подставляя в определение, получаем:

$$f^*(y) = y \log y + (1 - y) \log(1 - y).$$

Получили бинарную кросс-энтропию.

- $y = 0$. Поскольку $-f(x) \rightarrow 0$ при $x \rightarrow -\infty$, то:

$$f^*(y) = 0.$$

- $y < 0$. Из монотонности логарифма и того, что $e^x < 1$ при $x < 0$, следует

$$\log(1 + e^x) < \log 2, \quad \forall x < 0.$$

Это означает, что

$$xy - \log(1 + e^x) > xy - \log 2.$$

Поскольку $yx \rightarrow +\infty$ при $x \rightarrow -\infty$, то $xy - \log(1 + e^x) \rightarrow +\infty$ при $x \rightarrow -\infty$. Таким образом

$$f^*(y) = +\infty.$$

- $y = 1$. Поскольку

$$\log(1 + e^x) \geq x, \quad \forall x \in \mathbb{R},$$

супремум не может быть больше нуля, а он равен нулю, так как

$$\log(1 + e^x) = x + \log(1 + e^{-x}), \quad \forall x \in \mathbb{R}$$

и $\log(1 + e^{-x}) \rightarrow 0$ при $x \rightarrow +\infty$. Поэтому:

$$f^*(y) = 0.$$

- $y > 1$. Поскольку:

$$\log(1 + e^x) < \log(e^x + e^x) = \log 2 + x, \quad \forall x > 0.$$

Отсюда следует

$$xy - \log(1 + e^x) > (y - 1)x - \log 2, \quad \forall x > 0.$$

Устремляя $x \rightarrow +\infty$, получаем, что

$$f^*(y) = +\infty.$$

Таким образом:

$$f^*(y) = \begin{cases} y \log y + (1 - y) \log(1 - y), & y \in [0, 1] \\ +\infty, & y \notin [0, 1]. \end{cases}$$

■

С6.3 Вычисление сопряжённой функции в многомерном случае

Теперь, когда мы рассмотрели достаточно много одномерных примеров, перейдем к многомерному случаю. Как и в предыдущем разделе, начнем с более простых примеров и двинемся к более сложным.

Пример С6.7. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \frac{1}{2} x^\top A x + b^\top x, \quad A \in \mathbb{S}_{++}^d, \quad b \in \mathbb{R}^d.$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x \in \mathbb{R}^d} \left\{ y^\top x - \frac{1}{2} x^\top A x - b^\top x \right\} = \sup_{x \in \mathbb{R}^d} \left\{ -\frac{1}{2} x^\top A x - (b - y)^\top x \right\}.$$

Вычислим максимум вогнутой функции $g(x) = -\frac{1}{2} x^\top A x - (b - y)^\top x$. Запишем градиент:

$$\nabla g(x) = -Ax - (b - y) = 0 \implies x = A^{-1}(y - b).$$

Тогда сопряжённая функция к f :

$$f^*(y) = \frac{1}{2} (y - b)^\top A^{-1} (y - b).$$

■

Пример С6.8. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \log \left(\sum_{i=1}^d e^{x_i} \right).$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(y) = \sup_{x \in \mathbb{R}^d} \left\{ y^\top x - \log \left(\sum_{i=1}^d e^{x_i} \right) \right\}.$$

Попытаемся вычислить максимум вогнутой функции $g(x) = y^\top x - \log \left(\sum_{i=1}^d e^{x_i} \right)$. Запишем градиент:

$$\nabla g_i(x) = y_i - \frac{e^{x_i}}{\sum_{j=1}^d e^{x_j}} = 0, \quad i = \overline{1, d}.$$

Рассмотрим случаи:

- $y \succ 0$ и $\mathbf{1}^\top y = 1$. Уравнение разрешимо и

$$\log y_i = x_i - \log \left(\sum_{j=1}^d e^{x_j} \right) = x_i - f(x).$$

Подставляя в определение, получаем:

$$f^*(y) = \sum_{i=1}^d y_i (\log y_i + f(x)) - f(x) = \sum_{i=1}^d y_i \log y_i,$$

так как $\mathbf{1}^\top y = 1$.

- $y \succeq 0$ и $\mathbf{1}^\top y = 1$. Пусть существует $y_k = 0$, тогда $x_k \rightarrow -\infty$ и ответ не поменяется:

$$f^*(y) = \sum_{i=1}^d y_i (\log y_i + f(x)) - f(x) = \sum_{i=1}^d y_i \log y_i,$$

- $y \not\succeq 0$. Пусть существует $y_k < 0$, тогда выберем $x_k = -t$ и $x_i = 0$ ($i \neq k$), а затем устремим $t \rightarrow +\infty$. Таким образом

$$f^*(y) = +\infty.$$

- $\mathbf{1}^\top y \neq 1$. Возьмём $x = t\mathbf{1}$:

$$y^\top x - f(x) = ty^\top \mathbf{1} - t - \log(d).$$

В случае, если $\mathbf{1}^\top y > 1$, выражение не ограничено при $t \rightarrow +\infty$. В случае, если $\mathbf{1}^\top y < 1$, выражение не ограничено при $t \rightarrow -\infty$. Таким образом

$$f^*(y) = +\infty.$$

Таким образом:

$$f^*(y) = \begin{cases} \sum_{i=1}^d y_i \log y_i, & y \in \Delta_{d-1} \\ +\infty, & y \notin \Delta_{d-1}. \end{cases}$$

■

Пример С6.9. Найдите сопряжённую функцию к функции $f : \mathbb{S}_{++}^d \rightarrow \overline{\mathbb{R}}$:

$$f(X) = \log \det X^{-1}.$$

Решение. Воспользуемся определением сопряжённой функции:

$$f^*(Y) = \sup_{X \in \mathbb{S}_{++}^d} \{ \text{Tr}(XY) + \log \det X \},$$

где мы воспользовались тем, что $\det X^{-1} = (\det X)^{-1}$.

Попытаемся вычислить максимум вогнутой функции $g(X) = \text{Tr}(XY) + \log \det X$. Запишем градиент:

$$\nabla g(X) = Y + X^{-1} = 0,$$

Рассмотрим случаи:

- $Y \prec 0$. Уравнение разрешимо и $X = -Y^{-1}$. Подставляя в определение, получаем:

$$f^*(Y) = \text{Tr}(-I_d) + \log \det(-Y)^{-1} = \log \det(-Y)^{-1} - d.$$

- $Y \not\prec 0$. Y имеет нормированный собственный вектор v и собственное значение $\lambda \geq 0$. Возьмем $X = I_d + tvv^\top$, тогда

$$\text{Tr}(XY) + \log \det X = \text{Tr}(Y) + t\lambda + \log \det(I_d + tvv^\top) = \text{Tr}(Y) + t\lambda + \log(1 + t).$$

Таким образом:

$$f^*(Y) = +\infty.$$

Итого:

$$f^*(Y) = \begin{cases} \log \det(-Y)^{-1} - d, & Y \prec 0, \\ +\infty, & Y \not\prec 0. \end{cases}$$

■

Пример С6.10. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \begin{cases} -\sqrt{1 - \|x\|^2}, & \|x\| \leq 1, \\ +\infty, & \|x\| > 1. \end{cases}$$

Решение. Поскольку мы мало что знаем о сопряжении в случае сложных функций, сведем задачу к одномерному виду:

$$f^*(y) = \sup_{\|x\| \leq 1} \left\{ \langle y, x \rangle + \sqrt{1 - \|x\|^2} \right\} = \sup_{\alpha \in [0, 1]} \sup_{\|x\| = \alpha} \left\{ \langle y, x \rangle + \sqrt{1 - \alpha^2} \right\}.$$

Пользуясь определением сопряжённой нормы, раскроем один из супремумов:

$$f^*(y) = \sup_{\alpha \in [0, 1]} \left\{ \alpha \|y\|_* + \sqrt{1 - \alpha^2} \right\},$$

откуда получим

$$\alpha = \frac{\|y\|_*}{\sqrt{\|y\|_*^2 + 1}}.$$

Таким образом:

$$f^*(y) = \sqrt{\|y\|_*^2 + 1}.$$

■

Пример С6.11. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \frac{1}{2} \|x\|^2.$$

Решение. Поступим аналогично Примеру С6.10:

$$f^*(y) = \sup_{\alpha \geq 0} \sup_{\|x\| = \alpha} \left\{ \langle y, x \rangle - \frac{\alpha^2}{2} \right\} = \sup_{\alpha \geq 0} \left\{ \alpha \|y\|_* - \frac{\alpha^2}{2} \right\} = \frac{1}{2} \|y\|_*^2.$$

■

Пример С6.12. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \|x\|.$$

Решение. Рассмотрим случаи:

- $\|y\|_* > 1$. По определению сопряжённой нормы существует $z \in \mathbb{R}^d$ с $\|z\| \leq 1$ и $y^\top z > 1$. Беря $x = tz$ и устремляя $t \rightarrow +\infty$, получаем:

$$y^\top x - \|x\| = t(y^\top z - \|z\|) \rightarrow +\infty.$$

Таким образом:

$$f^*(y) = +\infty.$$

- $\|y\|_* \leq 1$. Воспользуемся неравенством Гёльдера (0.2): $y^\top x \leq \|x\| \|y\|_*$. Тогда

$$y^\top x - \|x\| \leq 0.$$

При $x = 0$, выражение $y^\top x - \|x\| = 0$, то есть

$$f^*(y) = 0.$$

Таким образом:

$$f^*(y) = \begin{cases} 0, & \|y\|_* \leq 1, \\ +\infty, & \|y\|_* > 1. \end{cases}$$

■

С6.4 Анализ на сопряжённых функциях

До этого раздела мы строили сопряжённые функции, пользуясь только определением сопряжения по Фенхелю. Однако на более сложных примерах, логично задаться вопросом: существуют ли правила, которые помогут облегчить работу с сопряжёнными функциями? К сожалению, взятие сопряжения устроено не так хорошо, как дифференцирование или даже субдифференцирование. Однако мы все же можем получить некоторые утверждения, которые окажутся полезными.

Теорема С6.1. Пусть $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ и $\alpha \in \mathbb{R}_{++}$. Тогда для $g(x) = \alpha f(x)$ и $h(x) = \alpha f\left(\frac{x}{\alpha}\right)$ выполнено:

$$g^*(y) = \alpha f^*\left(\frac{y}{\alpha}\right), \quad h^*(y) = \alpha f^*(y).$$

Доказательство. Докажем по определению:

$$g^*(y) = \sup_{x \in \mathbb{R}^d} \{\langle y, x \rangle - \alpha f(x)\} = \alpha \sup_{x \in \mathbb{R}^d} \left\{ \left\langle \frac{y}{\alpha}, x \right\rangle - f(x) \right\} = \alpha f^*\left(\frac{y}{\alpha}\right).$$

Аналогично поступим с $h(y)$:

$$\begin{aligned} h^*(y) &= \sup_{x \in \mathbb{R}^d} \left\{ \left\langle y, x \right\rangle - \alpha f\left(\frac{x}{\alpha}\right) \right\} = \alpha \sup_{x \in \mathbb{R}^d} \left\{ \left\langle y, \frac{x}{\alpha} \right\rangle - f\left(\frac{x}{\alpha}\right) \right\} \\ &= \alpha \sup_{z \in \mathbb{R}^d} \{\langle y, z \rangle - f(z)\} = \alpha f^*(y). \end{aligned}$$

■

Таким образом, для операции взятия сопряжения по Фенхелю нет линейности относительно умножения на константу, но есть правила, которые облегчают жизнь при вычислениях.

Пример С6.13. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \begin{cases} -\sqrt{\alpha^2 - \|x\|^2}, & \|x\| \leq \alpha, \\ +\infty, & \|x\| > \alpha, \end{cases}$$

где $\alpha \in \mathbb{R}$.

Решение. Можно заметить, что мы уже решали очень похожую задачу в Примере С6.10. Воспользуемся Теоремой С6.1, тогда

$$f^*(y) = \alpha \sqrt{\|y\|_*^2 + 1}.$$

■

Теорема С6.2. Рассмотрим набор собственных функций $f_i : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Пусть функция $g : \mathbb{R}^d \times \dots \times \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ задана по правилу

$$g(x_1, \dots, x_n) = \sum_{i=1}^n f_i(x_i).$$

Тогда сопряжённая функция к g имеет вид

$$g^*(y_1, \dots, y_n) = \sum_{i=1}^n f_i^*(y_i).$$

Доказательство. Распишем по определению:

$$\begin{aligned} g^*(y_1, \dots, y_n) &= \sup_{x_1, \dots, x_n} \{ \langle (y_1, \dots, y_n)^\top, (x_1, \dots, x_n)^\top \rangle - g(x_1, \dots, x_n) \} \\ &= \sup_{x_1, \dots, x_n} \left\{ \sum_{i=1}^n [\langle y_i, x_i \rangle - f_i(x_i)] \right\}. \end{aligned}$$

Поскольку каждое слагаемое в сумме независимо, можем посчитать супремумы отдельно:

$$g^*(y_1, \dots, y_n) = \sum_{i=1}^n \sup_{x_i \in \mathbb{R}^d} \{ \langle y_i, x_i \rangle - f_i(x_i) \} = \sum_{i=1}^n f_i^*(y_i).$$

■

Таким образом, взятие сопряжения по Фенхелю линейно в случае сепарабельных функций. Разберём несколько примеров, в которых Теорема С6.2 оказывается полезной.

Пример С6.14. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \begin{cases} \sum_{i=1}^d x_i \log x_i, & x \succeq 0, \\ +\infty, & x \not\succeq 0. \end{cases}$$

Решение. Поскольку функция f сепарабельна, достаточно рассмотреть одномерный случай. Рассмотрим $g(t) = t \log t$, $t \geq 0$. Воспользуемся определением сопряжённой функции:

$$g^*(s) = \sup_{t \geq 0} \{ ts - t \log t \} \implies g^*(s) = e^{s-1}.$$

Пользуясь Теоремой С6.2, получим:

$$f^*(y) = \sum_{i=1}^d e^{y_i-1}.$$

■

Пример С6.15. Найдите сопряжённую функцию к функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \begin{cases} -\sum_{i=1}^d \log x_i, & x \succ 0, \\ +\infty, & x \not\succ 0. \end{cases}$$

Решение. Заметим, что опять имеем дело с сепарабельной функцией. Для одномерного случая мы в Примере С6.3 уже вычислили сопряжение. Тогда по Теореме С6.2

получим

$$f^*(y) = \begin{cases} -\sum_{i=1}^d \log(-y_i) - d, & y \prec 0, \\ +\infty, & y \not\prec 0. \end{cases}$$

■

В случае дифференцирования и субдифференцирования мы умели удобно выражать результат применения операции к композиции функции с аффинным отображением. Аналогичная формула есть и для взятия сопряжения.

Теорема С6.3. Рассмотрим $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Пусть $A \in \mathbb{R}^{d \times d}$, $b, a \in \mathbb{R}^d$ и $\det A \neq 0$. Тогда для g , определённой по правилу

$$g(x) = f(A(x - a)) + \langle b, x \rangle$$

выполнено

$$g^*(y) = f^*(A^{-\top}(y - b)) + \langle a, y - b \rangle.$$

Доказательство. Запишем по определению:

$$g^*(y) = \sup_{x \in \mathbb{R}^d} \{ \langle y, x \rangle - f(A(x - a)) - \langle b, x \rangle \}.$$

Сделаем замену переменных $z = A(x - a)$. Тогда

$$\begin{aligned} g^*(y) &= \sup_{z \in \mathbb{R}^d} \{ \langle y, A^{-1}z + a \rangle - f(z) - \langle b, A^{-1}z + a \rangle \} \\ &= \sup_{z \in \mathbb{R}^d} \{ \langle y - b, A^{-1}z \rangle - f(z) \} + \langle a, y - b \rangle \\ &= \sup_{z \in \mathbb{R}^d} \{ \langle A^{-\top}(y - b), z \rangle - f(z) \} + \langle a, y - b \rangle \\ &= f^*(A^{-\top}(y - b)) + \langle a, y - b \rangle. \end{aligned}$$

■

С6.5 Связь с субдифференциалом

Теория, построенная в этом разделе, может пригодиться для вычисления субдифференциалов. Перед тем, как выяснить связь между сопряжёнными функциями и субдифференциалом, введём понятие второй сопряжённой функции Фенхеля.

Определение С6.2. Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$. Функция $f^{**} : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$, определённая как

$$f^{**}(x) = \sup_{y \in \mathbb{R}^d} \{ \langle x, y \rangle - f^*(y) \}.$$

называется *второй сопряжённой функцией по Фенхелю к f* .

Замечание С6.4. Нетрудно заметить, что $f^{**}(x) \leq f(x)$ для любого $x \in \mathbb{R}^d$. Действительно, по определению сопряжённой функции $f^*(y) \geq \langle x, y \rangle - f(x)$. Переходя к супремуму по y , получаем требуемое.

Чтобы выяснить связь сопряжения с субдифференциалом, потребуется выделить класс функций, для которых $f^{**} = f$.

Теорема С6.4 (Фенхеля–Моро). Пусть $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ — собственная замкнутая выпуклая функция. Тогда

$$f^{**}(x) = f(x), \quad \forall x \in \mathbb{R}^d.$$

Доказательство. Учитывая Замечание С6.4, остаётся показать обратное неравенство. Пусть нашёлся такой $x \in \mathbb{R}^d$, что $f^{**}(x) < f(x)$. Поскольку f — замкнутая выпуклая функция, её надграфик $\text{epi } f$ — непустое замкнутое выпуклое множество, причём точка $(x, f^{**}(x))$ ему не принадлежит. По теореме о строгой отделимости С3.7 существуют такие $a \in \mathbb{R}^d$, $b, c_1, c_2 \in \mathbb{R}$, что для любых $(z, s) \in \text{epi } f$ выполнено

$$\langle a, z \rangle + bs \leq c_1 < c_2 \leq \langle a, x \rangle + bf^{**}(x).$$

Переставляя члены, сделаем вывод, что

$$\langle a, z - x \rangle + b(s - f^{**}(x)) < 0.$$

- $b > 0$. Неравенство нарушается, если взять достаточно большое s при фиксированном z .
- $b < 0$. Тогда разделим последнее неравенство на b и обозначим $y = -\frac{a}{b}$. Получим

$$\langle y, z - x \rangle + f^{**}(x) - s < 0.$$

Выберем $s = f(z)$, тогда

$$\langle y, z \rangle - f(z) - \langle y, x \rangle + f^{**}(x) < 0.$$

Взяв максимум по z , воспользуемся определением сопряжённой функции. Тогда

$$f^*(y) + f^{**}(x) < \langle y, x \rangle.$$

В то же время из определения сопряжённой функции легко заметить

$$f^*(y) + f^{**}(x) \geq \langle y, x \rangle.$$

Получили противоречие.

- $b = 0$. Поскольку f — выпуклая функция, существует $\hat{y} \in \text{dom } f$. Определим $\hat{a} = a + \varepsilon \hat{y}$, $\hat{b} = -\varepsilon$. Тогда для $z \in \text{dom } f$ выполнено

$$\begin{aligned} \langle \hat{a}, z - x \rangle + \hat{b}(s - f^{**}(x)) &= \langle a, z - x \rangle + \varepsilon[\langle \hat{y}, z \rangle - f(z) + f^{**}(x) - \langle \hat{y}, x \rangle] \\ &\leq (c_1 - c_2) + \varepsilon[f^*(\hat{y}) - f^{**}(x) - \langle \hat{y}, x \rangle]. \end{aligned}$$

Здесь мы воспользовались теоремой о строгой отделимости С3.7 и взяли максимум по $\hat{y}$. Поскольку $c_1 - c_2 < 0$, а выбор ε произвольный, то его можно взять достаточно малым, чтобы сделать правую часть неравенства отрицательной. Таким образом,

$$\langle \hat{a}, z - x \rangle + \hat{b}(s - f^{**}(x)) < 0,$$

и мы свели случай $b = 0$ к первому пункту, который уже был рассмотрен. Получили противоречие. ■

Теорема С6.4 позволяет доказать желаемое утверждение о связи между сопряжением и субдифференцированием.

Теорема С6.5. Пусть $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ — замкнутая выпуклая функция. Тогда следующие три условия эквивалентны:

1. $f(x) + f^*(y) = \langle x, y \rangle$;
2. $y \in \partial f(x)$;
3. $x \in \partial f^*(y)$.

Доказательство.

- Пусть $y \in \partial f(x)$. Тогда по определению выпуклости для любого $z \in \mathbb{R}^d$ выполнено

$$f(z) \geq f(x) + \langle y, z - x \rangle.$$

Переставляя части неравенства и максимизируя по z , получим

$$\langle y, x \rangle - f(x) \geq f^*(y).$$

Учитывая Замечание С6.4, заключаем

$$f(x) + f^*(y) = \langle x, y \rangle.$$

Обратим внимание, что все переходы можно проделать и в обратном направлении, что доказывает эквивалентность.

- Поскольку функция f выпуклая и замкнутая, то по Теореме С6.4 имеем $f^{**} = f$. Это означает, что $f(x) + f^*(y) = \langle x, y \rangle$ эквивалентно равенству

$$f^{**}(x) + f^*(y) = \langle x, y \rangle.$$

По доказанной в первом пункте эквивалентности имеем $x \in \partial f^*(y)$. ■

Рассмотрим условие $f(x) + f^*(y) = \langle x, y \rangle$ более детально. По определению сопряжённой функции его можно эквивалентно переписать в виде

$$x \in \operatorname{argmax}_{\hat{x} \in \mathbb{R}^d} \{ \langle y, \hat{x} \rangle - f(\hat{x}) \}.$$

Аналогично, учитывая равенство f со второй сопряжённой, запишем

$$y \in \operatorname{argmax}_{\hat{y} \in \mathbb{R}^d} \{ \langle x, \hat{y} \rangle - f^*(\hat{y}) \}.$$

Но мы доказали эквивалентность указанного равенства и включения точек в субдифференциалы. Тогда

$$\partial f(x) = \operatorname{argmax}_{\hat{y} \in \mathbb{R}^d} \{ \langle x, \hat{y} \rangle - f^*(\hat{y}) \},$$

$$\partial f^*(y) = \operatorname{argmax}_{\hat{x} \in \mathbb{R}^d} \{ \langle y, \hat{x} \rangle - f(\hat{x}) \}.$$

Пример С6.16. Найдите субградиент в нуле функции $f : \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$:

$$f(x) = \|x\|.$$

Решение. Норма — замкнутая выпуклая функция. Таким образом, имеем

$$\partial f(0) = \operatorname{argmin}_{y \in \mathbb{R}^d} \|y\|^*.$$

Из Примера С6.12 известно, что минимум сопряжённой функции к норме равен нулю и достигается в шаре по сопряжённой норме. Таким образом

$$\partial f(0) = B_{\|\cdot\|^*}(0, 1).$$

Аналогичный результат был получен в Примере С5.4. ■

С7 Двойственность по Лагранжу

Некоторые оптимизационные задачи требуют не столько отыскания подходящих параметров модели, сколько оценки на значение целевой функции в оптимуме. Например, в задаче логистики не обязательно требуется отыскать точный маршрут для каждой машины, но важно знать, сколько в принципе будет стоить оптимальная доставка. Поскольку решение задачи со сложными ограничениями может быть связано с рядом трудностей, на помощь приходит аппарат двойственных функций Лагранжа.

С7.1 Лагранжиан

Начнём с рассмотрения постановки задачи оптимизации стандартной формы:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = \overline{1, n} \\ & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned} \tag{C7.1}$$

Замечание С7.1. Здесь и далее вместо $\mathbb{R}^d$ можно рассматривать и другие пространства, которые изоморфны $\mathbb{R}^d$, например, матричное пространство $\mathbb{R}^{d \times n}$ или пространство симметричных матриц $\mathbb{S}^d$.

Чтобы (C7.1) имела смысл, потребуем непустоту пересечения эффективных множеств функций-ограничений и целевой функции. Перепишем её в эквивалентном виде:

$$\min_{x \in \mathbb{R}^d} \quad f_0(x) + \sum_{i=1}^n I_-(f_i(x)) + \sum_{j=1}^m I_0(h_j(x)), \tag{C7.2}$$

где I_- и I_0 — индикаторные функции неположительных и нулевых значений соответственно:

$$I_-(x) = \begin{cases} 0, & x \leq 0, \\ +\infty, & x > 0, \end{cases} \quad I_0(x) = \begin{cases} 0, & x = 0, \\ +\infty, & x \neq 0. \end{cases}$$

В задаче (C7.2) целевая функция регуляризуется индикаторами, которые служат жёстким штрафом за нахождение вне требуемого множества. Поскольку отыскать минимум (C7.2) невозможно в силу недифференцируемости функции, имеет смысл перейти к более мягким ограничениям на x . Заменим индикаторы на линейные функции $\lambda_i f_i$ и $\nu_j h_j$. Тогда функция, которую мы минимизируем, становится *лагранжианом*.

Определение С7.1. Лагранжиан $\mathcal{L}$ относительно задачи оптимизации (C7.1) задаётся следующим образом:

$$\mathcal{L}(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^n \lambda_i f_i(x) + \sum_{j=1}^m \nu_j h_j(x).$$

Лагранжиан является линейной аппроксимацией ограничений исходной задачи. Переменные $\lambda \in \mathbb{R}^n$ и $\nu \in \mathbb{R}^m$ будем называть *двойственными переменными*, в то время как x — *прямой переменной*.

С7.2 Двойственная функция по Лагранжу

Основная идея подхода через функцию Лагранжа заключается в переходе от оптимизационной задачи по прямым переменным к задаче по двойственным. Как результат минимизации лагранжиана по x , определим *двойственную функцию Лагранжа*. Иногда её также называют *сопряжённой функцией по Лагранжу*.

Определение С7.2. Двойственная функция по Лагранжу к задаче (С7.1) $g : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \bar{\mathbb{R}}$ задаётся следующим образом:

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \left(f_0(x) + \sum_{i=1}^n \lambda_i f_i(x) + \sum_{j=1}^m \nu_j h_j(x) \right). \quad (\text{С7.3})$$

Замечание С7.2. Возможна ситуация, что при некоторых наборах двойственных переменных (λ, ν) лагранжиан $\mathcal{L}$ является неограниченным снизу по переменной x . Тогда будем говорить, что двойственная функция принимает значение $-\infty$ на этих наборах.

Далее мы докажем одно из ключевых практических свойств сопряжения по Лагранжу.

Утверждение С7.1. Двойственная функция, построенная по определению (С7.3), всегда является вогнутой по переменным (λ, ν) , вне зависимости от того, является ли $f_0(x)$ выпуклой или нет.

Доказательство. Рассмотрим (λ^1, ν^1) , (λ^2, ν^2) и $\alpha \in [0, 1]$, тогда:

$$\begin{aligned} & g(\alpha\lambda^1 + (1-\alpha)\lambda^2, \alpha\nu^1 + (1-\alpha)\nu^2) \\ &= \inf_{x \in \mathbb{R}^d} \left(f_0(x) + \sum_{i=1}^n (\alpha\lambda_i^1 + (1-\alpha)\lambda_i^2) f_i(x) + \sum_{j=1}^m (\alpha\nu_j^1 + (1-\alpha)\nu_j^2) h_j(x) \right) \\ &= \inf_{x \in \mathbb{R}^d} (\alpha\mathcal{L}(x, \lambda^1, \nu^1) + (1-\alpha)\mathcal{L}(x, \lambda^2, \nu^2)) \\ &\geq \alpha \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^1, \nu^1) + (1-\alpha) \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^2, \nu^2) \\ &= \alpha g(\lambda^1, \nu^1) + (1-\alpha)g(\lambda^2, \nu^2). \end{aligned}$$

Следовательно, $g(\lambda, \nu)$ является вогнутой по определению. ■

Замечание С7.3. Можно доказывать этот факт, ссылаясь на доказанное ранее свойство поточечного супремума аффинных функций.

В начале параграфа было упомянуто, что аппарат сопряжённых функций Лагранжа полезен для получения оценки на значение функции в оптимуме (обозначим его как p^*). Ниже мы докажем, что на любом наборе (λ, ν) сопряжённая функция Лагранжа оценивает p^* снизу.

Утверждение С7.2. Обозначим решение задачи (С7.1) как p^* . Для любого $\lambda \succeq 0$ и любого ν выполняется:

$$g(\lambda, \nu) \leq p^*.$$

Доказательство. Пусть $\bar{x}$ — достижимая точка, то есть $f_i(\bar{x}) \leq 0$ и $h_j(\bar{x}) = 0$. Тогда, при условии $\lambda \succeq 0$, мы имеем

$$\sum_{i=1}^n \lambda_i f_i(\bar{x}) + \sum_{j=1}^m \nu_j h_j(\bar{x}) \leq 0.$$

Тогда, используя это неравенство в определении лагранжиана, мы получаем

$$\mathcal{L}(\bar{x}, \lambda, \nu) = f_0(\bar{x}) + \sum_{i=1}^n \lambda_i f_i(\bar{x}) + \sum_{j=1}^m \nu_j h_j(\bar{x}) \leq f_0(\bar{x}).$$

Как следствие,

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda, \nu) \leq \mathcal{L}(\bar{x}, \lambda, \nu) \leq f_0(\bar{x}).$$

Так как это неравенство выполняется для любой достижимой точки (то есть выполняются ограничения типа неравенств и равенств), то мы получаем искомый результат. ■

С7.3 Двойственная задача

Утверждение С7.2 доказывает, что двойственная функция Лагранжа даёт нижнюю оценку на оптимальное значение задачи (С7.1), напрямую зависящую от λ и ν . Интуитивно понятно, что лучшая нижняя оценка на p^* получается, если решить задачу максимизации по двойственным переменным:

$$\begin{aligned} \max_{\substack{\lambda \in \mathbb{R}^n \\ \nu \in \mathbb{R}^m}} \quad & g(\lambda, \nu) \\ \text{s.t.} \quad & \lambda \succeq 0. \end{aligned}$$

Такая задача называется *двойственной задачей* к задаче (С7.1).

Обозначим оптимальное значение двойственной задачи относительно начальной как d^* . Утверждение С7.2 доказывает соотношение

$$d^* \leq p^*.$$

Это неравенство выполняется всегда. Соответствующее свойство называется *слабой двойственностью*. В частности, слабая двойственность выполняется и при бесконечных d^* и p^* . Если $p^* = -\infty$, то начальная задача не ограничена снизу и, как следствие, d^* обязана равняться $-\infty$. То же самое происходит и в случае $d^* = +\infty$.

Когда оптимальные значения двойственной и прямой задачи совпадают, говорят о *сильной двойственности*. Существует множество условий, позволяющих проверить выполнение сильной двойственности. Одним из них является *условие Слейтера*.

Утверждение С7.3. Рассмотрим задачу следующего вида:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = \overline{1, n} \\ & Ax = b, \end{aligned} \tag{С7.4}$$

где $f_0, \dots, f_n$ — выпуклые функции. Если существует такой $\bar{x} \in \text{relint} \bigcap_{i=1}^n \text{dom } f_i$,

что

$$f_i(\bar{x}) < 0, \quad i = \overline{1, n}, \quad A\bar{x} = b,$$

то для задачи (С7.4) выполняется сильная двойственность.

Приведем еще одно полезное условие.

Утверждение С7.4. Для задачи (С7.1) выполняется сильная двойственность, если все ограничения f_i и h_j являются аффинными.

С7.4 Примеры

Пример С7.1. Рассмотрим задачу оптимизации:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & x^\top x \\ \text{s.t.} \quad & Ax = b, \end{aligned}$$

где $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$. Составьте для неё двойственную задачу.

Решение. Выпишем лагранжиан:

$$\mathcal{L}(x, \nu) = x^\top x + \nu^\top (Ax - b).$$

Здесь отсутствуют ограничения типа неравенства, поэтому из двойственных переменных у нас только ν . Минимизируем лагранжиан по x . Так как это квадратичная форма, которая к тому же является выпуклой, достаточно градиент приравнять к 0.

$$\nabla_x \mathcal{L}(x, \nu) = 2x + A^\top \nu = 0.$$

Следовательно, $x = -\frac{1}{2}A^\top \nu$. Тогда подставим этот x в $\mathcal{L}$ и получим $g(\nu)$:

$$g(\nu) = \frac{1}{4}\nu^\top AA^\top \nu - \frac{1}{2}\nu^\top AA^\top \nu - \nu^\top b = -\frac{1}{4}\nu^\top AA^\top \nu - \nu^\top b.$$

Тогда двойственная задача к исходной задаче оптимизации будет иметь следующий вид:

$$\max_{\nu \in \mathbb{R}^n} -\frac{1}{4}\nu^\top AA^\top \nu - \nu^\top b.$$

■

Пример С7.2. Рассмотрим задачу оптимизации:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & x \succeq 0, \end{aligned}$$

где $A \in \mathbb{R}^{n \times d}$, $c \in \mathbb{R}^d$, $b \in \mathbb{R}^n$. Составьте для неё двойственную задачу.

Решение. Выпишем лагранжиан:

$$\mathcal{L}(x, \lambda, \nu) = c^\top x - \sum_{i=1}^d \lambda_i x_i + \nu^\top (Ax - b) = -\nu^\top b + (c + A^\top \nu - \lambda)^\top x.$$

Двойственная функция равна

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda, \nu) = -\nu^\top b + \inf_{x \in \mathbb{R}^d} (c + A^\top \nu - \lambda)^\top x.$$

Заметим, что если $c + A^\top \nu - \lambda \neq 0$, то инфимум равен $-\infty$, так как это линейная функция. Единственный случай, когда инфимум не равен $-\infty$: $c + A^\top \nu - \lambda = 0$. Тогда

$$g(\lambda, \nu) = \begin{cases} -\nu^\top b, & c + A^\top \nu - \lambda = 0, \\ -\infty, & \text{иначе.} \end{cases}$$

Тогда, поскольку интересующий нас случай — случай, когда $g > -\infty$, то для построения двойственной задачи в более удобном для нас виде мы можем ввести искусственное ограничение:

$$\begin{aligned} \max_{\substack{\lambda \in \mathbb{R}^d \\ \nu \in \mathbb{R}^n}} \quad & -\nu^\top b \\ \text{s.t.} \quad & c + A^\top \nu - \lambda = 0 \\ & \lambda \succeq 0. \end{aligned}$$

■

Замечание С7.4. Добавление такого искусственного ограничения валидно и с точки зрения математики, и с точки зрения идеи. Поскольку мы максимизируем двойственную функцию, то очевидно, что лучше рассматривать случай, когда $g(\lambda, \nu) > -\infty$. Условие, при котором это выполняется, выносится в ограничение, сразу избавляя от необходимости рассматривать «плохие» случаи.

Пример С7.3. Рассмотрим задачу оптимизации:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & x^\top Ax \leq 1, \end{aligned}$$

где $A \in \mathbb{S}_{++}^d$, $c \in \mathbb{R}^d$. Составьте для неё двойственную задачу и вычислите значение p^* .

Решение. Выпишем лагранжиан:

$$\mathcal{L}(x, \lambda) = c^\top x + \lambda(x^\top Ax - 1).$$

Заметим, что это выпуклая функция по x . Найдем градиент лагранжиана:

$$\nabla_x \mathcal{L}(x, \lambda) = c + 2\lambda Ax.$$

Приравняв градиент к нулю, получим $x = -\frac{1}{2\lambda} A^{-1} c$. Тогда двойственная функция имеет вид

$$g(\lambda) = -\frac{1}{2\lambda} c^\top A^{-1} c + \frac{1}{4\lambda} c^\top A^{-1} A A^{-1} c - \lambda = -\frac{1}{4\lambda} c^\top A^{-1} c - \lambda.$$

Ей соответствует двойственная задача

$$\begin{aligned} \max_{\lambda \in \mathbb{R}} \quad & \left[-\frac{1}{4\lambda} c^\top A^{-1} c - \lambda \right] \\ \text{s.t.} \quad & \lambda \geq 0. \end{aligned}$$

Отметим, что условие Слейтера для рассматриваемой задачи выполнено, поскольку выпуклое ограничение строго выполнено, например, при $x = 0$. Производная g по λ имеет вид

$$g'(\lambda) = \frac{1}{4\lambda^2} c^\top A^{-1} c - 1.$$

Приравнивая её к нулю, получим точку максимума:

$$\lambda = \frac{1}{2} \sqrt{c^\top A^{-1} c}.$$

Подставив её в двойственную задачу, получим:

$$p^* = -\sqrt{c^\top A^{-1} c}.$$

■

Пример С7.4. Рассмотрите задачу оптимизации:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & l \preceq x \preceq u, \end{aligned}$$

где $c, l, u \in \mathbb{R}^d$. Составьте для неё двойственную задачу.

Решение. Выпишем лагранжиан:

$$\mathcal{L}(x, \lambda_1, \lambda_2) = c^\top x + \lambda_1^\top (l - x) + \lambda_2^\top (x - u) = (c - \lambda_1 + \lambda_2)^\top x + \lambda_1^\top l - \lambda_2^\top u.$$

Это линейный функционал, заданный на всем множестве. Понятно, что при $c - \lambda_1 + \lambda_2 \neq 0$ он может быть устремлен к $-\infty$. Таким образом, приходим к двойственной функции вида

$$g(\lambda_1, \lambda_2) = \begin{cases} \lambda_1^\top l - \lambda_2^\top u, & c - \lambda_1 + \lambda_2 = 0, \\ -\infty, & \text{иначе.} \end{cases}$$

Внося $c - \lambda_1 + \lambda_2 = 0$ в ограничения, получим двойственную задачу:

$$\begin{aligned} \max_{\lambda_1, \lambda_2 \in \mathbb{R}^d} \quad & \lambda_1^\top l - \lambda_2^\top u \\ \text{s.t.} \quad & \lambda_1, \lambda_2 \succeq 0 \\ & c - \lambda_1 + \lambda_2 = 0. \end{aligned}$$

■

Пример С7.5. Рассмотрите задачу оптимизации линейного функционала на веро-

ятночном симплексе:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & \mathbf{1}^\top x = 1 \\ & x \succeq 0. \end{aligned}$$

Составьте для неё двойственную задачу и вычислите значение p^* .

Решение. Выпишем лагранжиан:

$$\mathcal{L}(x, \lambda, \nu) = c^\top x + \nu(\mathbf{1}^\top x - 1) - \lambda^\top x = (c + \nu - \lambda)^\top x - \nu.$$

Аналогично предыдущему примеру, получим выражение для двойственной функции:

$$g(\lambda, \nu) = \begin{cases} -\nu, & c + \nu - \lambda = 0, \\ -\infty, & \text{иначе.} \end{cases}$$

Тогда двойственная задача имеет вид:

$$\begin{aligned} \max_{\substack{\lambda \in \mathbb{R}^d \\ \nu \in \mathbb{R}}} \quad & -\nu \\ \text{s.t.} \quad & \lambda \succeq 0 \\ & c + \nu - \lambda = 0. \end{aligned}$$

Обсудим структуру полученного ограничения вида равенства. Если все координаты c_i неотрицательны, это не вызывает проблем, поскольку есть очевидное допустимое значение $\lambda_i = c_i$, $\nu = 0$. Однако случай $c_i < 0$ требует более тонкого анализа, потому что соответствующая координата λ_i не может быть выбрана отрицательной. Это означает, что требуется выбрать $\nu = -\min_i c_i$. Это единственный выбор, который не вызывает проблем с удовлетворением ограничений. Таким образом, имеем $d^* = \min_i c_i$. Условие Слейтера, очевидно, выполнено, поскольку ограничения имеют вид аффинного равенства, а также неравенства, заданного выпуклой функцией. Это означает $p^* = \min_i c_i$. В параграфе, посвящённом теореме Каруша–Куна–Таккера, мы получим решение прямой задачи и продемонстрируем, что двойственная задача действительно даёт правильную оценку значения функционала в оптимуме. ■

Пример С7.6. Рассмотрите задачу оптимизации:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & x^\top W x \\ \text{s.t.} \quad & x_i^2 = 1, \quad i = \overline{1, d}, \end{aligned}$$

где $W \in \mathbb{S}^d$. Составьте для неё двойственную задачу и получите нижнюю оценку на p^* .

Решение. Выпишем лагранжиан:

$$\mathcal{L}(x, \nu) = x^\top W x + \sum_{i=1}^d \nu_i (x_i^2 - 1) = x^\top (W + \text{diag}(\nu)) x - \mathbf{1}^\top \nu.$$

Двойственная функция равна:

$$g(\nu) = \begin{cases} -\mathbf{1}^\top \nu, & W + \text{diag}(\nu) \succeq 0, \\ -\infty, & \text{иначе,} \end{cases}$$

где мы воспользовались фактом, что минимум квадратичной формы равен нулю, если форма положительно полуопределена, или же, в противном случае, равен $-\infty$. Тогда двойственная задача имеет вид:

$$\begin{aligned} \max_{\nu \in \mathbb{R}^d} \quad & -\mathbf{1}^\top \nu \\ \text{s.t.} \quad & W + \text{diag}(\nu) \succeq 0. \end{aligned}$$

В отличие от предыдущих примеров, в этом не так легко сразу вывести хорошую нижнюю оценку на p^* . Если взять $\nu = -\lambda_{\min}(W)\mathbf{1}$, то можно заметить, что

$$W + \text{diag}(\nu) = W - \lambda_{\min}(W)I_d \succeq 0.$$

Посчитав значение двойственной функции при таком значении переменной, получим

$$g(\nu) = -\mathbf{1}^\top \nu = d\lambda_{\min}(W) \leq p^*.$$

■

Замечание C7.5. В прикладных сценариях, когда невозможно аналитически минимизировать лагранжиан по прямым переменным, могут быть использованы методы поиска седловой точки. Инициализируя x^0, λ^0, ν^0 , итеративный алгоритм обновляет прямые и двойственные переменные одновременно. В качестве критерия остановки обычно используют $f(x^k) - g(\lambda^k, \nu^k) \leq \varepsilon$. Поэтому, когда будет исследоваться график невязки между прямой и двойственной функцией, станет понятно, выполняется ли сильная двойственность или же нет: критерий должен стремиться к $p^* - d^*$ — так называемому *оптимальному двойственному зазору*.

C7.5 Связь сопряжения Фенхеля и Лагранжа

В качестве мотивации, рассмотрим пример, который не имеет практического смысла, но поможет уловить связь между сопряжением по Фенхелю и Лагранжу. Рассмотрим задачу:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & x = 0. \end{aligned}$$

Лагранжиан имеет вид

$$\mathcal{L}(x, \nu) = f(x) + \nu^\top x.$$

Тогда двойственная функция Лагранжа есть

$$g(\nu) = \inf_{x \in \mathbb{R}^d} (f(x) + \nu^\top x) = - \sup_{x \in \mathbb{R}^d} (-\nu^\top x - f(x)) = -f^*(-\nu).$$

Проделаем то же самое для более общей задачи

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & Ax \preceq b \\ & Cx = d, \end{aligned}$$

где $A \in \mathbb{R}^{n \times d}$, $C \in \mathbb{R}^{m \times d}$, $b \in \mathbb{R}^n$, $d \in \mathbb{R}^m$. Её лагранжиан имеет вид

$$\mathcal{L}(x, \lambda, \nu) = f(x) + \lambda^\top (Ax - b) + \nu^\top (Cx - d),$$

а двойственная функция равна

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \mathbb{R}^d} (f(x) + \lambda^\top (Ax - b) + \nu^\top (Cx - d)) \\ &= -\lambda^\top b - \nu^\top d + \inf_{x \in \mathbb{R}^d} \left(f(x) + (A^\top \lambda + C^\top \nu)^\top x \right) \\ &= -\lambda^\top b - \nu^\top d - f^*(-A^\top \lambda - C^\top \nu). \end{aligned} \quad (\text{C7.5})$$

Как можно заметить, в ряде случаев возможно «убрать» ограничения на прямую переменную в аргумент двойственной функции при построении двойственной задачи. Более того, для задач с линейными ограничениями удаётся выписать сопряжение по Лагранжу, зная лишь сопряжённую функцию Фенхеля для целевого функционала.

Пример C7.7. Рассмотрите задачу оптимизации:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \|x\| \\ \text{s.t.} \quad & Ax = b. \end{aligned}$$

Составьте для неё двойственную задачу.

Решение. В Примере C6.12 для функции $f(x) = \|x\|$ мы получили:

$$f^*(y) = \begin{cases} 0, & \|y\|_* \leq 1, \\ +\infty, & \|y\|_* > 1. \end{cases}$$

Используя результат (C7.5), имеем

$$g(\nu) = -\nu^\top b - f^*(-A^\top \nu) = \begin{cases} -\nu^\top b, & \|A^\top \nu\|_* \leq 1, \\ -\infty, & \text{иначе.} \end{cases}$$

Соответственно, двойственная задача имеет следующий вид:

$$\begin{aligned} \max_{\nu \in \mathbb{R}^d} \quad & -\nu^\top b \\ \text{s.t.} \quad & \|A^\top \nu\|_* \leq 1. \end{aligned}$$

■

Пример C7.8. Рассмотрите задачу оптимизации:

$$\begin{aligned} \min_{x \in \mathbb{R}_+^d} \quad & \sum_{i=1}^d x_i \log x_i \\ \text{s.t.} \quad & Ax \preceq b \\ & \mathbf{1}^\top x = 1. \end{aligned}$$

Составьте для неё двойственную задачу.

Решение. Чтобы найти двойственную функцию Лагранжа, необходимо найти сопряжённую функцию Фенхеля для отрицательной энтропии. Она была найдена в При-

мере C6.14:

$$f^*(y) = \sum_{i=1}^d e^{y_i - 1}.$$

Пользуясь результатом (C7.5) о связи сопряжённой и двойственной функции, имеем

$$g(\lambda, \nu) = -\lambda^\top b - \nu - \sum_{i=1}^d e^{-a_i^\top \lambda - \nu - 1},$$

где a_i — i -й столбец матрицы A . Значит, двойственная задача имеет вид

$$\begin{aligned} \max_{\substack{\lambda \in \mathbb{R}^n \\ \nu \in \mathbb{R}}} & \left[-\lambda^\top b - \nu - \sum_{i=1}^d e^{-a_i^\top \lambda - \nu - 1} \right] \\ \text{s.t.} & \quad \lambda \succeq 0. \end{aligned}$$

■

Замечание C7.6. Стоит отметить, что формально нужно было занести ограничение $x \in \mathbb{R}_+^d$ в лагранжиан. Однако это ограничение было автоматически учтено при поиске сопряжённой функции.

C7.6 Ввод искусственных ограничений

Некоторые задачи могут оказаться более простыми для решения, если искусственным образом перенести часть целевой функции в ограничения.

Пример C7.9. Рассмотрим задачу оптимизации:

$$\min_{x \in \mathbb{R}^d} \sum_{i=1}^N \|A_i x + b_i\|_2 + \frac{1}{2} \|x - x_0\|_2^2,$$

где $A_i \in \mathbb{R}^{n \times d}$, $b_i \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^d$. Составьте для неё двойственную задачу.

Решение. Переформулируем задачу, введя искусственные ограничения:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ y \in \mathbb{R}^n}} & \sum_{i=1}^N \|y_i\|_2 + \frac{1}{2} \|x - x_0\|_2^2 \\ \text{s.t.} & \quad A_i x + b_i = y_i, \quad i = \overline{1, N}. \end{aligned}$$

Соответственно, лагранжиан равен

$$\mathcal{L}(x, y, \nu_1, \dots, \nu_N) = \sum_{i=1}^N \|y_i\|_2 + \frac{1}{2} \|x - x_0\|_2^2 + \sum_{i=1}^N \nu_i^\top (y_i - A_i x - b_i).$$

Минимизируем лагранжиан относительно y_i . Заметим, что:

$$\inf_{y_i \in \mathbb{R}^n} (\|y_i\|_2 + \nu_i^\top y_i) = \begin{cases} 0, & \|\nu_i\|_2 \leq 1, \\ -\infty, & \|\nu_i\|_2 > 1. \end{cases}$$

Если $\|\nu_i\|_2 > 1$, то можно выбрать $y_i = -t\nu_i$ и устремить $t \rightarrow \infty$. Если же $\|\nu_i\| \leq 1$, то по неравенству Коши–Буняковского–Шварца (0.3):

$$\|y_i\|_2 + \nu_i^\top y_i \geq 0.$$

Тогда достаточно взять $y_i = 0$.

Для минимизации по x достаточно взять градиент по x и приравнять его к нулю. Получим:

$$x = x_0 + \sum_{i=1}^N A_i^\top \nu_i.$$

Подставляя найденные переменные в лагранжиан, получаем:

$$g(\nu_1, \dots, \nu_N) = \begin{cases} -\sum_{i=1}^N \nu_i^\top (A_i x_0 + b_i) - \frac{1}{2} \left\| \sum_{i=1}^N A_i^\top \nu_i \right\|_2^2, & \|\nu_i\|_2 \leq 1, \quad i = \overline{1, N} \\ -\infty, & \text{иначе.} \end{cases}$$

Тогда двойственная задача имеет вид:

$$\begin{aligned} \max_{\nu \in \mathbb{R}^n} \quad & \left[-\sum_{i=1}^N \nu_i^\top (A_i x_0 + b_i) - \frac{1}{2} \left\| \sum_{i=1}^N A_i^\top \nu_i \right\|_2^2 \right] \\ \text{s.t.} \quad & \|\nu_i\|_2 \leq 1, \quad i = \overline{1, N}. \end{aligned}$$

■

Пример С7.10. Рассмотрите задачу оптимизации:

$$\min_{x \in \mathbb{R}^d} \max_{i=\overline{1, n}} (a_i^\top x + b_i),$$

где $a_i \in \mathbb{R}^d$ и $b_i \in \mathbb{R}$. Составьте для неё двойственную задачу.

Решение. Переформулируем задачу, введя искусственное ограничение:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ y \in \mathbb{R}^d}} \max_{i=\overline{1, n}} \quad & y_i \\ \text{s.t.} \quad & a_i^\top x + b_i = y_i, \quad i = \overline{1, n}. \end{aligned}$$

Двойственная функция равна:

$$g(\nu) = \inf_{x, y \in \mathbb{R}^d} \left(\max_{i=\overline{1, n}} y_i + \sum_{i=1}^n \nu_i^\top (a_i^\top x + b_i - y_i) \right).$$

Инфимум по x конечен только тогда, когда $\sum_{i=1}^n \nu_i^\top a_i = 0$. Минимизируя по y , получим

$$\inf_{y \in \mathbb{R}^d} \left[\max_{i=\overline{1, n}} y_i - \nu^\top y \right] = \begin{cases} 0, & \nu \succeq 0, \quad \mathbf{1}^\top \nu = 1, \\ -\infty, & \text{иначе.} \end{cases}$$

Чтобы это доказать, покажем, что если $\nu \succeq 0$, $\mathbf{1}^\top \nu = 1$, то

$$\nu^\top y = \sum_{j=1}^n \nu_j y_j \leq \sum_{j=1}^n \nu_j \max_{i=1, \dots, n} y_i = \max_{i=1, \dots, n} y_i.$$

Тогда, как следствие, взяв $y = 0$, получаем инфимум. Если же $\nu \not\succeq 0$, то тогда без ограничения общности рассмотрим $\nu_j < 0$. Возьмем $y_i = 0$, $i \neq j$ и $y_j = -t$. Тогда при стремлении $t \rightarrow +\infty$ имеем

$$\max_{i=1, \dots, n} y_i - \nu^\top y = 0 + t\nu_j \rightarrow -\infty.$$

И наконец, если $\mathbf{1}^\top \nu \neq 1$, тогда выберем $y = \mathbf{1}t$ и получим

$$\max_{i=1, \dots, n} y_i - \nu^\top y = t(1 - \mathbf{1}^\top \nu) \rightarrow -\infty,$$

где в зависимости от знака $1 - \mathbf{1}^\top \nu$ устремляем t к $+\infty$ или $-\infty$. В итоге двойственная функция записывается следующим образом:

$$g(\nu) = \begin{cases} b^\top \nu, & \sum_{i=1}^n \nu_i a_i = 0, \nu \succeq 0, \mathbf{1}^\top \nu = 1, \\ -\infty, & \text{иначе.} \end{cases}$$

Значит, двойственная задача имеет вид:

$$\begin{aligned} \max_{\nu \in \mathbb{R}^n} \quad & b^\top \nu \\ \text{s.t.} \quad & A^\top \nu = 0 \\ & \nu \succeq 0 \\ & \mathbf{1}^\top \nu = 1. \end{aligned}$$

■

С8 Условия оптимальности Каруша–Куна–Таккера

Ранее мы ввели понятие лагранжиана задачи и построили аппарат двойственных функций Лагранжа. В рамках этого параграфа мы, предполагая нулевой двойственный зазор, продолжим анализ свойств лагранжиана и выведем условия оптимальности оптимизационной задачи. Будем рассматривать задачу минимизации функции f_0 с прямой переменной $x \in \mathbb{R}^d$, ограничениями равенства h_j и неравенства f_i :

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = \overline{1, n} \\ & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned} \tag{C8.1}$$

А также её двойственную задачу с максимизируемой функцией

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \left(f_0(x) + \sum_{i=1}^n \lambda_i f_i(x) + \sum_{j=1}^m \nu_j h_j(x) \right)$$

и двойственными переменными $\lambda \in \mathbb{R}^n$, $\nu \in \mathbb{R}^m$:

$$\begin{aligned} \max_{\substack{\lambda \in \mathbb{R}^n \\ \nu \in \mathbb{R}^m}} \quad & g(\lambda, \nu) \\ \text{s.t.} \quad & \lambda \geq 0. \end{aligned} \tag{C8.2}$$

Далее везде предполагаем дифференцируемость f_0 , f_i , h_j и существование x^* — переменной, доставляющей оптимум в прямой задаче и (λ^*, ν^*) — переменных, доставляющих оптимум в двойственной задаче.

С8.1 Условия Каруша–Куна–Таккера

Определение С8.1. Пусть x^* является оптимумом прямой задачи (C8.1), а (λ^*, ν^*) является оптимумом двойственной задачи (C8.2). Говорят, что выполнены *условия Каруша–Куна–Таккера*, если выполнены:

- Ограничения:

$$\begin{aligned} f_i(x^*) &\leq 0, \quad i = \overline{1, n}, \\ h_j(x^*) &= 0, \quad j = \overline{1, m}; \end{aligned}$$

- Неотрицательность:

$$\lambda_i^* \geq 0, \quad i = \overline{1, n};$$

- Дополняющая нежёсткость:

$$\lambda_i^* f_i(x^*) = 0, \quad i = \overline{1, n};$$

- Стационарность:

$$\nabla f_0(x^*) + \sum_{i=1}^n \lambda_i^* \nabla f_i(x^*) + \sum_{j=1}^m \nu_j^* \nabla h_j(x^*) = 0.$$

Если оптимизационная задача имеет нулевой двойственный зазор, то условия из Определения С8.1 оказываются необходимыми условиями оптимальности.

Теорема С8.1. Пусть x^* является оптимумом прямой задачи (С8.1), а (λ^*, ν^*) является оптимумом двойственной задачи (С8.2). При этом пусть выполняется сильная двойственность. Тогда, если функции f_0, f_i, h_j дифференцируемы в точке x^* , то выполняются условия ККТ.

Доказательство. По определению допустимой точки, в x^* выполнено

$$\begin{aligned} h_j(x^*) &= 0, \quad \forall j = \overline{1, m}; \\ f_i(x^*) &\leq 0, \quad \forall i = \overline{1, n}. \end{aligned}$$

Поскольку задача имеет нулевой двойственный зазор, то

$$f_0(x^*) = g(\lambda^*, \nu^*).$$

Воспользовавшись определением двойственной функции Лагранжа, запишем

$$\begin{aligned} f_0(x^*) &= \inf_{x \in \mathbb{R}^d} \left(f_0(x) + \sum_{i=1}^n \lambda_i^* f_i(x) + \sum_{j=1}^m \nu_j^* h_j(x) \right) \\ &\leq f_0(x^*) + \sum_{i=1}^n \lambda_i^* f_i(x^*) + \sum_{j=1}^m \nu_j^* h_j(x^*) \\ &= f_0(x^*) + \sum_{i=1}^n \lambda_i^* f_i(x^*) \\ &\leq f_0(x^*), \end{aligned}$$

где $\lambda_i^* \geq 0$. Получаем, что:

$$\sum_{i=1}^n \lambda_i^* f_i(x^*) = 0.$$

Все слагаемые в этой сумме являются неположительными, из чего следует условие:

$$\lambda_i^* f_i(x^*) = 0, \quad i = \overline{1, n};$$

Физически это означает, что хотя бы одна из двух переменных (прямая либо двойственная) лежит на границе множества ограничений. Далее, так как x^* минимизирует $\mathcal{L}(x, \lambda^*, \nu^*)$, дифференциал $\mathcal{L}$ по x в точке x^* должен быть равен 0:

$$\nabla f_0(x^*) + \sum_{i=1}^n \lambda_i^* \nabla f_i(x^*) + \sum_{j=1}^m \nu_j^* \nabla h_j(x^*) = 0.$$

■

Замечание С8.1. Если функции недифференцируемы в x^* , то можно использовать субградиент:

$$\partial f_0(x^*) + \sum_{i=1}^n \lambda_i^* \partial f_i(x^*) + \sum_{j=1}^m \nu_j^* \partial h_j(x^*) \ni 0.$$

Замечание С8.2. Отметим, что выполнение сильной двойственности существенно, чтобы условия ККТ были необходимыми. Рассмотрим задачу минимизации

$$\begin{aligned} \min_{x \in \mathbb{R}} \quad & x^3 + x \\ \text{s.t.} \quad & x^2 \leq 0. \end{aligned}$$

В этом примере не выполнено ни одно из условий сильной двойственности (в том числе условие Слейтера). Лагранжиан задачи имеет вид

$$\mathcal{L}(x, \lambda) = x^3 + x + \lambda x^2,$$

а градиент лагранжиана:

$$\nabla_x \mathcal{L}(x, \lambda) = 3x^2 + 1 + 2\lambda x.$$

Решение задачи — точка $x^* = 0$. Однако она не обращает в ноль градиент лагранжиана.

Накладывая дополнительные условия на рассматриваемые функции, получим достаточные условия ККТ. Мы будем пользоваться следующей теоремой.

Теорема С8.2. Пусть функции f_0, f_i являются выпуклыми, а h_j — аффинными. Тогда, если для набора переменных (x^*, λ^*, ν^*) выполнены все условия ККТ, то x^* является точкой глобального минимума прямой задачи (С8.1), а (λ^*, ν^*) — точкой глобального максимума двойственной (С8.2). При этом сильная двойственность достигается автоматически.

Доказательство. Рассмотрим некоторый набор точек $(\tilde{x}, \tilde{\lambda}, \tilde{\nu})$, удовлетворяющий условиям ККТ. Поскольку $\tilde{\lambda} \geq 0$, то лагранжиан — выпуклая функция относительно x . Тогда из последнего условия следует, что $\tilde{x}$ — точка глобального минимума функции $\mathcal{L}(x, \tilde{\lambda}, \tilde{\nu})$. Таким образом, имеем

$$g(\tilde{\lambda}, \tilde{\nu}) = \mathcal{L}(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) = f_0(\tilde{x}).$$

Получаем, что $\tilde{x}$ и $(\tilde{\lambda}, \tilde{\nu})$ обнуляют двойственный зазор, а потому являются оптимальными прямыми и двойственными переменными. ■

Условия Каруша–Куна–Таккера играют важную роль в оптимизации. В некоторых специальных случаях возможно решить задачу оптимизации аналитически. Более того, некоторые алгоритмы оптимизации могут быть интерпретированы как решение системы условий ККТ.

С8.2 Примеры

В этом разделе рассмотрим классические задачи на применение условий ККТ.

Пример С8.1. Решите задачу минимизации

$$\begin{aligned} \min_{x, y \in \mathbb{R}} \quad & (x+1)^2 + (y+1)^2 \\ \text{s.t.} \quad & 2x + 3y \geq 5. \end{aligned}$$

Решение. Это выпуклая задача, то есть можно пользоваться теоремой ККТ для достаточных условий. Выпишем Лагранжиан задачи:

$$\mathcal{L}(x, y, \lambda) = (x+1)^2 + (y+1)^2 + \lambda(5 - 2x - 3y).$$

Запишем ограничения:

$$2x + 3y \geq 5.$$

Неотрицательность:

$$\lambda \geq 0.$$

Дополняющая нежёсткость:

$$\lambda(2x + 3y - 5) = 0.$$

Стационарность:

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial x}(x, y, \lambda) &= 2(x + 1) - 2\lambda = 0, \\ \frac{\partial \mathcal{L}}{\partial y}(x, y, \lambda) &= 2(y + 1) - 3\lambda = 0.\end{aligned}$$

Пользуясь условиями на частные производные, получим

$$x = \lambda - 1, \quad y = \frac{3}{2}\lambda - 1.$$

Далее переберём все варианты выполнения условия дополняющей нежёсткости:

1. $\lambda = 0$. Получаем, что $x = -1$, $y = -1$, но ограничение: $2x + 3y = -5 < 5$ не выполнено.
2. $\lambda > 0$. Получаем, что $(2x + 3y - 5) = 0$, тогда $2(\lambda - 1) + 3(\frac{3}{2}\lambda - 1) - 5 = \frac{13}{2}\lambda - 10 = 0$, поэтому

$$\lambda^* = \frac{20}{13}, \quad x^* = \frac{7}{13}, \quad y^* = \frac{17}{13}.$$

■

Пример С8.2. Решите задачу минимизации

$$\begin{aligned}\min_{x, y \in \mathbb{R}} \quad & x + 3y \\ \text{s.t.} \quad & x - y \geq 0, \\ & (x - 1)^2 + (y - 1)^2 \leq 9.\end{aligned}$$

Решение. Рассматриваемая задача выпуклая. Её лагранжиан имеет вид:

$$\mathcal{L}(x, y, \lambda_1, \lambda_2) = x + 3y + \lambda_1(y - x) + \lambda_2((x - 1)^2 + (y - 1)^2 - 9).$$

Запишем ограничения:

$$\begin{aligned}x - y &\geq 0, \\ (x - 1)^2 + (y - 1)^2 &\leq 9.\end{aligned}$$

Неотрицательность:

$$\lambda_1, \lambda_2 \geq 0.$$

Дополняющая нежёсткость:

$$\begin{aligned}\lambda_1(x - y) &= 0, \\ \lambda_2((x - 1)^2 + (y - 1)^2 - 9) &= 0.\end{aligned}$$

Стационарность:

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial x}(x, y, \lambda_1, \lambda_2) &= 1 - \lambda_1 + 2\lambda_2(x - 1) = 0, \\ \frac{\partial \mathcal{L}}{\partial y}(x, y, \lambda_1, \lambda_2) &= 3 + \lambda_1 + 2\lambda_2(y - 1) = 0.\end{aligned}$$

Рассмотрим все варианты условия дополняющей нежёсткости:

1. $\lambda_2 = 0$. Из условия на градиент $\lambda_1 = 1$, $\lambda_1 = -3$ — противоречие.
2. $\lambda_1 = 0$, $\lambda_2 > 0$. Получаем, что $x - 1 = -\frac{1}{2\lambda_2}$, $y - 1 = -\frac{3}{2\lambda_2}$ и $(x - 1)^2 + (y - 1)^2 = 9$. Тогда $\frac{9}{4\lambda_2^2} + \frac{1}{4\lambda_2^2} = 9$. Получаем

$$\lambda_1^* = 0, \lambda_2^* = \frac{\sqrt{10}}{6}, x^* = 1 - \frac{3}{\sqrt{10}}, y^* = 1 - \frac{9}{\sqrt{10}}.$$

3. $\lambda_1 > 0$, $\lambda_2 > 0$. Получаем, что $(x - 1)^2 + (y - 1)^2 = 9$, $x = y$, но тогда $x - 1 = y - 1$ и по условию на градиенты $1 - \lambda_1 = 3 + \lambda_1 \implies \lambda_1 = -1 < 0$ — противоречие.

■

Пример С8.3. Решите задачу минимизации

$$\begin{aligned}\min_{x \in \mathbb{R}^d} \quad & \frac{1}{2}x^\top Px + q^\top x + r \\ \text{s.t.} \quad & Ax = b,\end{aligned}$$

где $P \in \mathbb{S}_+^d$, $A \in \mathbb{R}^{n \times d}$.

Решение. Заметим, что задача выпуклая в силу положительной полуопределённости матрицы. Лагранжиан задачи имеет вид

$$\mathcal{L}(x, \nu) = \frac{1}{2}x^\top Px + q^\top x + r + \nu^\top (Ax - b).$$

Запишем ограничения:

$$Ax = b$$

Стационарность:

$$\nabla_x \mathcal{L}(x, \nu) = Px + q + A^\top \nu = 0.$$

Их можно переписать в виде

$$\begin{pmatrix} P & A^\top \\ A & 0 \end{pmatrix} \cdot \begin{pmatrix} x \\ \nu \end{pmatrix} = \begin{pmatrix} -q \\ b \end{pmatrix}$$

По сути мы имеем систему из $n + d$ уравнений на $n + d$ переменных x, ν . Решая эту систему, мы получаем решение прямой и двойственной задач. ■

ККТ позволяет вычислять аналитические выражения для проекций на относительно простые множества. Следующий пример рассматривает l_2 -шар.

Пример С8.4. Решите задачу минимизации

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \|x - s\|_2^2 \\ \text{s.t.} \quad & \|x\|_2^2 \leq 1, \end{aligned}$$

где $s \in \mathbb{R}^d$ — фиксированный вектор.

Решение. Заметим, что рассматриваемая задача выпуклая, то есть условия ККТ являются достаточными. Запишем лагранжиан задачи:

$$\mathcal{L}(x, \lambda) = \|x - s\|_2^2 + \lambda (\|x\|_2^2 - 1).$$

Запишем ограничения:

$$\|x\|_2^2 \leq 1.$$

Неотрицательность:

$$\lambda \geq 0.$$

Дополняющая нежесткость:

$$\lambda (\|x\|_2^2 - 1) = 0.$$

Стационарность:

$$\nabla_x \mathcal{L}(x, \lambda) = 2(x - s) + 2\lambda x = 0 \implies x = \frac{s}{1 + \lambda}.$$

Рассмотрим два варианта условия дополняющей нежесткости:

1. $\lambda = 0$. Получаем, что $x = s$, но такой вариант подходит только когда $\|s\|_2 \leq 1$.
2. $\lambda > 0$. Получаем, что $\|x\|_2 = 1$, тогда $\|x\|_2 = \frac{1}{(1+\lambda)} \|s\|_2 = 1$. Следовательно $(1 + \lambda) = \|s\|_2$, это условие подходит, когда $\|s\|_2 > 1$. В этом случае, $x = \frac{s}{\|s\|_2}$.

Таким образом, оператор проекции на l_2 -шар имеет вид

$$x^* = \min \{ \|s\|_2, 1 \} \cdot \frac{s}{\|s\|_2}.$$

■

ККТ также позволяет решать некоторые оптимизационные задачи в явном виде. Важным примером являются линейные задачи, поскольку теоретический анализ многих алгоритмов предполагает доступ к оракулу точного минимума линейной задачи. Следующий пример рассматривает l_2 -шар.

Пример C8.5. Решите задачу минимизации

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & \|x\|_2^2 \leq 1, \end{aligned}$$

где $c \in \mathbb{R}^d$ — фиксированный вектор.

Решение. Это выпуклая задача, то есть можно пользоваться ККТ как достаточными условиями. Лагранжиан задачи имеет вид

$$\mathcal{L}(x, \lambda) = c^\top x + \lambda \left(\|x\|_2^2 - 1 \right).$$

Запишем ограничения:

$$\|x\|_2^2 \leq 1.$$

Неотрицательность:

$$\lambda \geq 0.$$

Дополняющая нежёсткость:

$$\lambda \left(\|x\|_2^2 - 1 \right) = 0.$$

Стационарность:

$$\nabla_x \mathcal{L}(x, \lambda) = c + 2\lambda x = 0 \implies 2\lambda x = -c.$$

Рассмотрим два варианта условия дополняющей нежёсткости

1. $\lambda = 0$. Такой вариант подходит только когда $c = 0$ с любым $\|x\|_2 \leq 1$.
2. $\lambda > 0$. Тогда $\|x\|_2 = 1$ и

$$\|x\|_2 = \frac{\|c\|_2}{2\lambda} = 1 \implies 2\lambda = \|c\|_2.$$

Отсюда следует

$$x = -\frac{c}{\|c\|_2}.$$

■

Рассмотрим также линейную задачу на симплексе. Это важный пример, поскольку с поиском оптимального вероятностного распределения приходится сталкиваться регулярно. В прошлой главе мы уже оценили оптимальное значение через минимизацию сопряжённой функции Лагранжа. Теперь найдём оптимальные параметры модели.

Пример С8.6. Решите задачу минимизации

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & \mathbf{1}^\top x = 1 \\ & x \succeq 0, \end{aligned}$$

где $c \in \mathbb{R}^d$ — фиксированный вектор.

Решение. Запишем лагранжиан задачи:

$$\mathcal{L}(x, \lambda, \nu) = c^\top x + \nu(\mathbf{1}^\top x - 1) - \lambda^\top x.$$

Запишем ограничения:

$$\begin{aligned} \mathbf{1}^\top x &= 1, \\ x &\succeq 0. \end{aligned}$$

Неотрицательность:

$$\lambda \succeq 0.$$

Дополняющая нежёсткость:

$$\lambda_i x_i = 0.$$

Стационарность:

$$\nabla_x \mathcal{L}(x, \lambda) = c + \nu - \lambda = 0.$$

Рассмотрим последнее условие. В прошлом параграфе мы подробно обсуждали, что единственный подходящий выбор ν — это

$$\nu = - \min_{j=1,d} c_j.$$

Таким образом, имеем

$$\lambda_i = c_i - \min_{j=1,d} c_j \geq 0.$$

Понятно, что i -я компонента вектора λ принимает нулевое значение только при условии

$$i = \operatorname{argmin}_{j=1,d} c_j.$$

Обозначим множество подходящих индексов за I . Для всех остальных индексов $\lambda_i > 0$ и $x_i = 0$. Чтобы вектор x удовлетворял всем условиям ККТ, осталось подобрать его так, чтобы его компоненты суммировались в единицу. Подойдёт любой x вида

$$x = \operatorname{conv} \{ e_i \mid i \in I \}.$$

■

Выше мы упоминали, что условия ККТ можно переформулировать и для негладких задач, записав их через субдифференциалы. Рассмотрим минимизацию линейного

функционала на l_1 -шаре.

Пример C8.7. Решите задачу минимизации

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & \|x\|_1 \leq 1, \end{aligned}$$

где $c \in \mathbb{R}^d$ — фиксированный вектор.

Решение. Лагранжиан задачи имеет вид:

$$\mathcal{L}(x, \lambda) = c^\top x + \lambda(\|x\|_1 - 1).$$

Запишем ограничения:

$$\|x\|_1 \leq 1.$$

Неотрицательность:

$$\lambda \geq 0.$$

Дополняющая нежесткость:

$$\lambda(\|x\|_1 - 1) = 0.$$

Стационарность:

$$\partial_x \mathcal{L}(x, \lambda) = c + \lambda \partial(\|x\|_1) = \{c + \lambda v \mid \|v\|_\infty \leq 1, \langle x, v \rangle = \|x\|_1\} \ni 0.$$

Из условия на субградиент следует равенство $c = -\lambda v$. Рассмотрим два варианта условия дополняющей нежесткости.

1. $\lambda = 0$. Получаем, что $c = 0$, и в этом случае подходит любой x , такой что $\|x\|_1 \leq 1$.
2. $\lambda > 0$. Тогда $\|x\|_1 = 1$. Чтобы достигалось равенство $\langle x, v \rangle = 1$ при $\|v\|_\infty \leq 1$, по неравенству Гёльдера (0.2) требуется:

$$\|v\|_\infty = 1, \quad \lambda = \|c\|_\infty, \quad v = -\frac{c}{\|c\|_\infty}.$$

В качестве решения, на котором достигается равенство, берём вектор

$$x = -\text{sign}(c_i) \cdot e_i, \quad i = \underset{j=1, d}{\operatorname{argmax}} |c_j|.$$

■

Перейдём к более сложным задачам, выходящим за рамки вычисления операторов проекции и минимизации линейных функционалов.

Пример С8.8. Решите задачу минимизации

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & - \sum_{i=1}^d \log(\alpha_i + x_i) \\ \text{s.t.} \quad & x \succeq 0 \\ & \mathbf{1}^\top x = 1, \end{aligned}$$

где $\alpha_i > 0$.

Решение. Имеем дело с задачей выпуклой минимизации, поэтому будем пользоваться условиями ККТ как достаточными условиями минимума. Выпишем лагранжиан:

$$\mathcal{L}(x, \lambda, \nu) = - \sum_{i=1}^d \log(\alpha_i + x_i) - \lambda^\top x + \nu(\mathbf{1}^\top x - 1).$$

Запишем ограничения:

$$\begin{aligned} x &\succeq 0, \\ \mathbf{1}^\top x &= 1. \end{aligned}$$

Неотрицательность:

$$\lambda \succeq 0.$$

Дополняющая нежёсткость:

$$\lambda_i x_i = 0.$$

Стационарность:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = -\frac{1}{\alpha_i + x_i} - \lambda_i + \nu = 0.$$

Заметим, что от λ можно избавиться. Тогда получим:

$$\left(\nu - \frac{1}{\alpha_i + x_i} \right) x_i = 0, \quad \nu - \frac{1}{\alpha_i + x_i} \geq 0.$$

Если $\nu \geq \frac{1}{\alpha_i}$, то ситуация $x_i > 0$ невозможна в силу условия дополняющей нежёсткости, тогда $x_i = 0$. Если $\nu < \frac{1}{\alpha_i}$, тогда $x_i > 0$. Получим:

$$\nu = \frac{1}{\alpha_i + x_i} \implies x_i = \frac{1}{\nu} - \alpha_i.$$

Решение можно объединить следующим образом:

$$x_i = \begin{cases} \frac{1}{\nu} - \alpha_i, & \nu < \frac{1}{\alpha_i}, \\ 0, & \nu \geq \frac{1}{\alpha_i}. \end{cases} \iff x_i = \max\left(\frac{1}{\nu} - \alpha_i, 0\right).$$

Подставляя это выражение во второе ограничение на x , имеем

$$\sum_{i=1}^d \max\left(\frac{1}{\nu} - \alpha_i, 0\right) = 1.$$

Если взять за переменную $\frac{1}{\nu}$, то это кусочно-линейная возрастающая функция, имеющая уникальное решение, которое можно точно определить. ■

Замечание С8.3. Пример С8.8 соответствует решению классической задачи про заполнение полости водой. На картинке ниже предоставлена её интуиция. Уровень заполнения воды — это $\frac{1}{\nu}$. Для каждого уровня местности α_i подбирается x_i .




Рис. С8.1: Интуиция: уровень воды $1/\nu$, рельеф α_i , добавка x_i .

Пример С8.9. Решите задачу минимизации

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \sum_{i=1}^d \frac{c_i}{x_i} \\ \text{s.t.} \quad & x \succeq \varepsilon \\ & \mathbf{1}^\top x = 1, \end{aligned}$$

где $c_i > 0$ и $\varepsilon > 0$.

Решение. Эта задача является задачей выпуклой оптимизации. Выпишем её лагранжиан:

$$\mathcal{L}(x, \lambda, \nu) = \sum_{i=1}^d \frac{c_i}{x_i} + \sum_{i=1}^d \lambda_i (\varepsilon - x_i) + \nu (\mathbf{1}^\top x - 1).$$

Запишем ограничения:

$$\begin{aligned} x &\succeq \varepsilon, \\ \mathbf{1}^\top x &= 1. \end{aligned}$$

Неотрицательность:

$$\lambda \succeq 0.$$

Дополняющая нежесткость:

$$\lambda_i (\varepsilon - x_i) = 0.$$

Стационарность:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = -\frac{c_i}{x_i^2} - \lambda_i + \nu = 0.$$

Пусть часть $x_i = \varepsilon$ и $\lambda_i \geq 0$ для $i \in I_1$, а другая $x_i > \varepsilon$ и $\lambda_i = 0$ для $i \in I_2$, так что $I_1 \cup I_2 = \{1, \dots, d\}$ и $I_1 \cap I_2 = \emptyset$. Для $x_i > \varepsilon$, $i \in I_2$ получаем формулу:

$$x_i = \sqrt{\frac{c_i}{\nu}}.$$

Рассмотрим теперь остальные $x_i = \varepsilon$, $i \in I_1$. По условию нормировки имеем:

$$\sum_{i=1}^d x_i = \sum_{i \in I_1} \varepsilon + \sum_{i \in I_2} \sqrt{\frac{c_i}{\nu}} = 1 \implies \nu = \left(\frac{\sum_{i \in I_2} \sqrt{c_i}}{1 - |I_1|\varepsilon} \right)^2, \quad |I_1|\varepsilon < 1.$$

Далее посчитаем λ_i , $i \in I_1$ по условию на градиент:

$$\lambda_i = \nu - \frac{c_i}{\varepsilon^2}.$$

Итого, необходимо подобрать разбиение I_1 , I_2 , чтобы были выполнены следующие неравенства:

$$\begin{aligned} x_i &= (1 - |I_1|\varepsilon) \frac{\sqrt{c_i}}{\sum_{i \in I_2} \sqrt{c_i}} > \varepsilon, \quad \forall i \in I_2, \\ \lambda_i &= \left(\frac{\sum_{i \in I_2} \sqrt{c_i}}{1 - |I_1|\varepsilon} \right)^2 - \frac{c_i}{\varepsilon^2} \geq 0, \quad \forall i \in I_1. \end{aligned}$$

Если все неравенства выполнены, получаем:

$$\begin{cases} x_i = (1 - |I_1|\varepsilon) \frac{\sqrt{c_i}}{\sum_{i \in I_2} \sqrt{c_i}}, & \forall i \in I_2, \\ x_i = \varepsilon, & \forall i \in I_1. \end{cases}$$

■

С8.3 Решение прямой задачи через двойственную

Предположим, что выполнена сильная двойственность. Выпишем задачу минимизации лагранжиана при оптимальных двойственных переменных (λ^*, ν^*) :

$$\inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^*, \nu^*).$$

Если у этой задачи единственный минимум, то он обязательно достигается в точке x^* глобального минимума прямой задачи (С8.1) ($f_0(x^*) = g(\lambda^*, \nu^*)$). Если минимум задачи минимизации лагранжиана не достигается, то и в прямой задаче он не достигается. Таким образом, зная оптимальные двойственные переменные (λ^*, ν^*) , можно попробовать найти оптимальную прямую переменную x^* с помощью безусловной минимизации. Разберём несколько примеров.

Пример С8.10. Рассмотрим задачу минимизации отрицательной энтропии

$$\begin{aligned} \min_{x \in \mathbb{R}_{++}^d} \quad & \sum_{i=1}^d x_i \log x_i \\ \text{s.t.} \quad & Ax \preceq b \\ & \mathbf{1}^\top x = 1, \end{aligned}$$

где $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$. Найдите оптимальную точку минимума прямой задачи через оптимальную точку двойственной задачи.

Решение. Двойственная задача имеет вид:

$$\begin{aligned} \max_{\substack{\lambda \in \mathbb{R}^n \\ \nu \in \mathbb{R}}} & \left[-b^\top \lambda - \nu - e^{-\nu-1} \sum_{i=1}^d e^{-a_i^\top \lambda} \right] \\ \text{s.t.} & \quad \lambda \succeq 0, \end{aligned}$$

где a_i — столбцы матрицы A . Предположим, что выполняется условие Слейтера с линейными ограничениями неравенства, чтобы говорить о сильной двойственности. Запишем лагранжиан в оптимальных двойственных переменных:

$$\mathcal{L}(x, \lambda^*, \nu^*) = \sum_{i=1}^d x_i \log x_i + (\lambda^*)^\top (Ax - b) + \nu^* (\mathbf{1}^\top x - 1).$$

Эта функция является 1-сильно выпуклой, а значит имеет единственный минимум. Взяв градиент по x и приравняв его к нулю, получим:

$$x_i^* = \frac{1}{\exp\{(a_i^\top \lambda^* + \nu^* + 1)\}}, \quad i = \overline{1, d}.$$

То есть если x^* достижима, то она обязана доставлять оптимум. ■

Пример С8.11. Рассмотрим задачу минимизации сепарабельной функции

$$\begin{aligned} \min_{x \in \mathbb{R}^d} & \quad \sum_{i=1}^d f_i(x_i) \\ \text{s.t.} & \quad a^\top x = b, \end{aligned}$$

где f_i — выпуклые дифференцируемые функции. Будем предполагать, что пересечение области определения целевой функции и ограничения непусто и минимум достигается в конечной точке. Это говорит о том, что решение существует и единственно. Найдите оптимальную точку минимума прямой задачи через оптимальную точку двойственной задачи.

Решение. Выпишем лагранжиан:

$$\mathcal{L}(x, \nu) = \sum_{i=1}^d f_i(x_i) + \nu(a^\top x - b) = -b\nu + \sum_{i=1}^d (f_i(x_i) + \nu a_i x_i).$$

Он также является сепарабельным по компонентам вектора x . Тогда двойственная

функция имеет вид

$$\begin{aligned}
 g(\nu) &= -b\nu + \inf_{x \in \mathbb{R}^d} \left(\sum_{i=1}^d (f_i(x_i) + \nu a_i x_i) \right) \\
 &= -b\nu + \sum_{i=1}^d \inf_{x_i \in \mathbb{R}} (f_i(x_i) + \nu a_i x_i) \\
 &= -b\nu - \sum_{i=1}^d f_i^*(-\nu a_i),
 \end{aligned}$$

где f_i^* — сопряжённые по Фенхелю функции. Имеем двойственную задачу:

$$\max_{\nu \in \mathbb{R}} \left[-b\nu - \sum_{i=1}^d f_i^*(-\nu a_i) \right].$$

Предположим, что ν^* — решение двойственной задачи. Для его поиска можно пользоваться уже известными методами, например, методом дихотомии или золотого сечения. В силу показанного в начале параграфа, минимум прямой задачи совпадает с минимумом $\mathcal{L}(x, \nu^*)$. Тогда, для поиска x^* можно взять градиент лагранжиана в ν^* по x и приравнять его к нулю, то есть решать уравнения:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x^*, \nu^*) = f'_i(x_i^*) + \nu^* a_i = 0.$$

■

С8.4 Условия ККТ для локальных экстремумов невыпуклых задач

Ранее мы требовали выпуклость целевой функции и ограничений, чтобы дать достаточные условия минимума оптимизационной задачи. Однако на практике часто приходится иметь дело с невыпуклыми постановками. Как и в случае минимизации без ограничений, условия, затрагивающие только первые производные, не могут быть достаточными для локальных минимумов в общем случае. Нужно вводить дополнительные условия на вторые производные, чтобы сделать условия ККТ достаточными для локального минимума. Для набора переменных (x, λ, ν) определим следующие множества из активных неравенств:

$$\begin{aligned}
 I^0(x) &= \{ i \mid f_i(x) = 0, \lambda_i = 0 \}, \\
 I^+(x) &= \{ i \mid f_i(x) = 0, \lambda_i > 0 \}.
 \end{aligned}$$

Определение С8.2. Если для любого вектора $z \neq 0$, такого что:

$$\begin{aligned}
 z^\top \nabla_x f_i(x) &= 0, \quad i \in I^+(x), \\
 z^\top \nabla_x f_i(x) &\leq 0, \quad i \in I^0(x), \\
 z^\top \nabla_x h_j(x) &= 0, \quad j = \overline{1, m}
 \end{aligned}$$

верно, что

$$z^\top \nabla_{xx}^2 \mathcal{L}(x, \lambda, \nu) z > 0,$$

то говорят, что для набора переменных (x, λ, ν) выполнено *достаточное условие второго порядка* (*second-order sufficient condition* или *SOSC*).

Используя условие второго порядка, сформулируем теорему.

Теорема С8.3. Пусть функции f_0, f_i, h_j являются дважды непрерывно дифференцируемыми. Тогда, если для набора переменных (x^*, λ^*, ν^*) выполнены все условия ККТ и SOS, то x^* является точкой локального минимума прямой задачи (С8.1).

Применим теорему на конкретном примере.

Пример С8.12. Решите задачу оптимизации

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & -x \\ \text{s.t.} \quad & x^2 + y^2 \leq 1 \\ & (x-1)^3 - y \leq 0. \end{aligned}$$

Решение. Запишем лагранжиан задачи:

$$\mathcal{L}(x, y, \lambda_1, \lambda_2) = -x + \lambda_1(x^2 + y^2 - 1) + \lambda_2((x-1)^3 - y).$$

Запишем ограничения:

$$\begin{aligned} x^2 + y^2 &\leq 1, \\ (x-1)^3 - y &\leq 0. \end{aligned}$$

Неотрицательность:

$$\lambda_1, \lambda_2 \geq 0.$$

Дополняющая нежёсткость:

$$\begin{aligned} \lambda_1(x^2 + y^2 - 1) &= 0, \\ \lambda_2((x-1)^3 - y) &= 0. \end{aligned}$$

Стационарность:

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial x}(x, y, \lambda_1, \lambda_2) &= -1 + 2\lambda_1 x + 3\lambda_2(x-1)^2 = 0, \\ \frac{\partial \mathcal{L}}{\partial y}(x, y, \lambda_1, \lambda_2) &= 2\lambda_1 y - \lambda_2 = 0. \end{aligned}$$

Переберём четыре условия дополняющей нежёсткости:

1. $\lambda_1 = 0, \lambda_2 = 0$. Из условий на градиент по x получаем противоречие $0 = -1$.
2. $\lambda_1 = 0, \lambda_2 > 0$. Из условий на градиент по y получаем $\lambda_2 = 0$ — противоречие.
3. $\lambda_1 > 0, \lambda_2 = 0$. По градиенту по y получаем $y = 0$ и $x = \pm 1$ из дополняющей нежёсткости. Точка $x = -1, y = 0$ в условии на градиент по x даёт оценку $\lambda_1 = \frac{1}{2x} = -\frac{1}{2} < 0$ — противоречие. Точка $x = 1, y = 0$ в условии на градиент по x даёт оценку $\lambda_1 = \frac{1}{2x} = \frac{1}{2} > 0$. Все ограничения выполняются. Тогда подходит набор переменных $(x, y, \lambda_1, \lambda_2) = (1, 0, \frac{1}{2}, 0)$.

4. $\lambda_1 > 0$, $\lambda_2 > 0$. Получим, что $x^2 + y^2 = 1$ и $(x-1)^3 - y = 0$. Только точки $(1, 0)$ и $(0, -1)$ подходят под эти условия. Точка $(1, 0)$ и условие градиента по y требуют $\lambda_2 = 0$ — противоречие. Для точки $(0, -1)$ решаем систему из условий на градиент и получаем $\lambda_2 = \frac{1}{3}$ и $\lambda_1 = -\frac{1}{6} < 0$ — противоречие.

Получили единственный набор переменных, удовлетворяющий ККТ. Запишем для него множества активных неравенств

$$I^+(1, 0) = \{1\}, \quad I^0(1, 0) = \{2\},$$

градиенты ограничений

$$\nabla f_1(1, 0) = \begin{pmatrix} 2x \\ 2y \end{pmatrix} \Big|_{(1,0)} = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \quad \nabla f_2(1, 0) = \begin{pmatrix} 3(x-1)^2 \\ -1 \end{pmatrix} \Big|_{(1,0)} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

и гессиан функции Лагранжа:

$$\nabla^2 \mathcal{L} \left(1, 0, \frac{1}{2}, 0 \right) = \begin{pmatrix} 2\lambda_1 + 6\lambda_2(x-1) & 0 \\ 0 & 2\lambda_1 \end{pmatrix} \Big|_{(1,0,\frac{1}{2},0)} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Для множества векторов $z \neq 0 \in \mathbb{R}^2$, таких что

$$z^\top \nabla f_1(1, 0) = 2z_1 = 0, \quad z^\top \nabla f_2(1, 0) = -z_2 \leq 0,$$

выполнено

$$z^\top \nabla^2 \mathcal{L} \left(1, 0, \frac{1}{2}, 0 \right) z = z_1^2 + z_2^2 > 0.$$

Таким образом, для набора $(1, 0, \frac{1}{2}, 0)$ ККТ и SOSC выполнены, и точка $(1, 0)$ является локальным минимумом. ■

С9 Классические виды оптимизационных задач

До этого мы изучали оптимизационные задачи в общем виде. Однако среди них можно выделить классы, для которых существуют специализированные методы решения. В этом параграфе мы рассмотрим основные классы оптимизационных задач и покажем, как некоторые прикладные проблемы могут быть к ним сведены.

С9.1 Линейное программирование

Первый и наиболее простой класс задач — *линейное программирование*. В нем минимизируется линейная функция при линейных ограничениях. Этот класс широко применяется в различных областях, таких как планирование производства, транспорт, финансы, логистика. Существует несколько основных форм записи задачи линейного программирования.

Определение С9.1. Пусть $c \in \mathbb{R}^d$, $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$, $G \in \mathbb{R}^{m \times d}$, $h \in \mathbb{R}^m$. Говорят, что задача *линейного программирования* (*Linear Programming*) (LP) записана

1. в *общей форме*, если она имеет вид

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & Gx \preceq h; \end{aligned}$$

2. в *стандартной форме*, если она имеет вид

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & x \succeq 0; \end{aligned}$$

3. в *канонической форме*, если она имеет вид

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & Gx \preceq h \\ & x \succeq 0. \end{aligned}$$

Та или иная форма записи выбирается в зависимости от ограничений решаемой задачи. Тем не менее, оказывается, что все три вида задачи LP эквивалентны.

Утверждение С9.1. Оптимизационная задача линейного программирования в любом виде может быть эквивалентно переписана в любой другой форме.

Доказательство.

1. Покажем, что любая задача линейного программирования, записанная в общей форме, представима в стандартной форме. Заметим, что неравенство $Gx \preceq h$ эквивалентно системе неравенств

$$Gx + v = h, \quad v \succeq 0$$

с новой переменной $v \in \mathbb{R}^m$. Более того, любая переменная $x \in \mathbb{R}^d$ может быть представлена в виде

$$x = x^+ - x^-,$$

где

$$x_i^+ = \begin{cases} x_i, & x_i \geq 0, \\ 0, & x_i < 0, \end{cases} \quad x_i^- = \begin{cases} 0, & x_i \geq 0, \\ -x_i, & x_i < 0. \end{cases}$$

Тогда задача при помощи введения новых переменных может быть переписана в виде

$$\begin{aligned} \min_{\substack{x^+ \in \mathbb{R}^d \\ x^- \in \mathbb{R}^d \\ v \in \mathbb{R}^m}} \quad & (c^\top \quad -c^\top \quad 0^\top) \begin{pmatrix} x^+ \\ x^- \\ v \end{pmatrix} \\ \text{s.t.} \quad & \begin{pmatrix} A & -A & 0 \\ G & -G & I_m \end{pmatrix} \begin{pmatrix} x^+ \\ x^- \\ v \end{pmatrix} = \begin{pmatrix} b \\ h \end{pmatrix} \\ & \begin{pmatrix} x^+ \\ x^- \\ v \end{pmatrix} \succeq 0. \end{aligned}$$

2. Имея задачу в стандартной форме, несложно свести ее к задаче в общей форме. Действительно, ограничение $x \succeq 0$ может быть представлено в виде $-I_d x \preceq 0$. Таким образом, получили задачу в общем виде.
3. Покажем, что задача в стандартной форме может быть переписана в канонической форме. Заметим, что ограничение $Ax = b$ эквивалентно паре ограничений

$$Ax \preceq b, \quad -Ax \preceq -b.$$

Тогда сформируем матрицу G и вектор h как

$$G = \begin{pmatrix} A \\ -A \end{pmatrix}, \quad h = \begin{pmatrix} b \\ -b \end{pmatrix}.$$

Таким образом, ограничение $Ax = b$ принимает вид

$$Gx \preceq h.$$

4. Покажем теперь, что каноническая постановка задачи может быть сведена к стандартной форме. Снова введем вектор $v \succeq 0$ и перепишем $Gx \preceq h$ в виде

$$Gx + v = h.$$

Получим задачу в стандартной форме:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ v \in \mathbb{R}^m}} \quad & (c^\top \quad 0^\top) \begin{pmatrix} x \\ v \end{pmatrix}, \\ \text{s.t.} \quad & (G \quad I_m) \begin{pmatrix} x \\ v \end{pmatrix} = h \\ & \begin{pmatrix} x \\ v \end{pmatrix} \succeq 0. \end{aligned}$$

■

Рассмотрим в качестве примеров несколько задач, которые сводятся к LP.

Пример С9.1. Пусть поставлена задача дробно-линейного программирования:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \frac{c^\top x + d}{e^\top x + f} \\ \text{s.t.} \quad & Ax = b, \\ & Gx \preceq h, \end{aligned}$$

где $e^\top x + f > 0$ для любого x . В общем случае данная задача не является выпуклой. Например, при $c = 0$, $d = -1$, $e = \mathbf{1}$, $f = 0$. Покажем, что она сводится к задаче из класса LP. Перепишем целевую функцию в виде

$$f(x) = c^\top \left(\frac{x}{e^\top x + f} \right) + d \left(\frac{1}{e^\top x + f} \right).$$

Поскольку на эффективном множестве целевого функционала выполнено $e^\top x + f > 0$, можем разделить ограничения на этот фактор. Получим

$$A \left(\frac{x}{e^\top x + f} \right) = b \left(\frac{1}{e^\top x + f} \right), \quad G \left(\frac{x}{e^\top x + f} \right) \preceq h \left(\frac{1}{e^\top x + f} \right).$$

Введем

$$y = \frac{x}{e^\top x + f} \in \mathbb{R}^d, \quad z = \frac{1}{e^\top x + f} \in \mathbb{R}_+$$

и заметим, что целевая функция и ограничения линейны по этому набору переменных. Для разрешимости этой системы по x при данных y, z необходимо, чтобы выполнялись условия

$$e^\top y + fz = 1, \quad z \geq 0.$$

Покажем, что задача дробно-линейного программирования эквивалентна задаче вида:

$$\begin{aligned} \min_{\substack{y \in \mathbb{R}^d \\ z \in \mathbb{R}}} \quad & c^\top y + dz \\ \text{s.t.} \quad & Ay - bz = 0 \\ & Gy - hz \preceq 0 \\ & e^\top y + fz = 1 \\ & z \geq 0. \end{aligned}$$

Выше показано, что для любого допустимого x в исходной задаче можно построить y, z во второй задаче. Соответственно, решение новой задачи не больше чем решение исходной. С другой стороны, если $z > 0$, то x восстанавливается по формуле

$$x = \frac{y}{z}.$$

Отдельного рассмотрения требует случай $z = 0$. Пусть x_0 допустим в исходной задаче. Тогда $x = x_0 + ty$ тоже допустим и

$$f(x_0 + ty) = \frac{c^\top(x_0 + ty) + d}{e^\top(x_0 + ty) + f} = \frac{tc^\top y + c^\top x_0 + d}{t + e^\top x_0 + f} \rightarrow c^\top y, \quad t \rightarrow +\infty.$$

Таким образом, показали, что для любой допустимой пары y, z можно построить либо x из исходной, либо последовательность допустимых x_t таких, что $f(x_t) \rightarrow c^\top y + dz$. Соответственно, задачи равносильны.

Пример С9.2. Рассмотрим задачу динамического планирования активности. Есть d экономических секторов, T временных периодов и n различных товаров. Каждый экономический сектор j в момент времени $t \in \overline{0, T}$ характеризуется своей «активностью» $x_j(t) \geq 0$. Каждый экономический сектор производит и потребляет товары пропорционально соответствующей активности. Известно, что j -й сектор производит количество $a_{ij}x_j$ товара i и потребляет $b_{ij}x_j$. Задача состоит в оптимальном планировании активности экономических секторов $x(t)$, $t = \overline{1, T}$ при заданном $x(0)$. Покажем, что она лежит в классе LP. Введём $T + 1$ новую переменную, соответствующую избыточным товарам:

$$\begin{aligned} s(t) &= Ax(t) - Bx(t+1), \quad t = \overline{0, T-1}, \\ s(T) &= Ax(T). \end{aligned}$$

Тогда целевую функцию, которую мы хотим максимизировать, можно записать в виде

$$f(x) = \sum_{t=0}^T \gamma^t c^\top s(t),$$

где $c \in \mathbb{R}^n$ — вектор стоимости товаров и $0 < \gamma \leq 1$ — дисконтирующий фактор, уменьшающий значимость будущего. Итого, задача динамического планирования активности в виде задачи линейного программирования записывается как

$$\begin{aligned} \max_{\{x(t)\}_{t=1}^T \subseteq \mathbb{R}^d} \quad & \sum_{t=0}^T \gamma^t c^\top s(t) \\ \text{s.t.} \quad & s(t) = Ax(t) - Bx(t+1), \quad t = \overline{0, T-1} \\ & s(T) = Ax(T) \\ & s(t) \geq 0, \quad t = \overline{0, T} \\ & x(t) \geq 0, \quad t = \overline{1, T}. \end{aligned}$$

С9.2 Квадратичное программирование с квадратичными ограничениями

Класс LP включает в себя задачи с линейным целевым функционалом и линейными ограничениями. Естественный способ его расширить — ввести в рассмотрение выпуклые квадратичные функции.

Определение С9.2. Задача *квадратичного программирования с квадратичными ограничениями* (*Quadratically Constrained Quadratic Programming*) (QCQP) записывается в виде:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \frac{1}{2} x^\top P_0 x + q_0^\top x + r_0 \\ \text{s.t.} \quad & \frac{1}{2} x^\top P_i x + q_i^\top x + r_i \leq 0, \quad i = \overline{1, m} \\ & Gx = h, \end{aligned}$$

где $P_i \in \mathbb{S}_+^d$, $q_i \in \mathbb{R}^d$, $r_i \in \mathbb{R}$, $G \in \mathbb{R}^{n \times d}$, $h \in \mathbb{R}^n$.

Задачи такого вида часто встречаются в оптимальном управлении.

Замечание С9.1. Понятно, что в случае $P_i = 0$ квадратичная задача вырождается в линейную. Таким образом, имеем строгое вложение $LP \subset QCQP$.

Пример С9.3. Минимизация квадратичной функции на единичном евклидовом шаре лежит в классе QCQP:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \frac{1}{2} x^\top A x + c^\top x \\ \text{s.t.} \quad & x^\top x \leq 1. \end{aligned}$$

Замечание С9.2. В случае, когда ограничения вида неравенства линейны, говорят о задаче *квадратичного программирования* (*Quadratic Programming*) (QP).

Пример С9.4. Задача наименьших квадратов представима в виде задачи квадратичного программирования:

$$\min_{x \in \mathbb{R}^d} \frac{1}{2} \|Ax - b\|_2^2 = \frac{1}{2} x^\top (A^\top A) x + (-A^\top b)^\top x + \left(\frac{1}{2} b^\top b\right).$$

Пример С9.5. Рассмотрим задачу составления оптимального портфеля. Есть d активов, в которые можно инвестировать. Классические модели предполагают, что цена i -го актива — случайная величина с известным математическим ожиданием μ_i и известной дисперсией σ_i . Показатель ковариации между активами σ_{ij} также считается известным. Задача состоит в подборе такого распределения бюджета между активами, которое минимизирует риски при условии, что ожидаемая прибыль превышает некоторое значение. Покажем, что эта задача лежит в классе QP. Роль переменных в рассматриваемой задаче играют доли актива i в портфеле. Обозначим их как x_i . Понятно, что x удовлетворяют ограничениям

$$\sum_{i=1}^d x_i = 1, \quad x \succeq 0.$$

Условие на то, что ожидаемая прибыль не меньше некоторого числа $\alpha \in \mathbb{R}$ — условие вида

$$\sum_{i=1}^d \mu_i x_i \geq \alpha.$$

Наконец, задача минимизации рисков есть задача минимизации дисперсии. Тогда задача оптимизации портфеля с ковариационной матрицей S приобретает вид

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & x^\top S x \\ \text{s.t.} \quad & \sum_{i=1}^d x_i = 1 \\ & x \succeq 0 \\ & \sum_{i=1}^d \mu_i x_i \geq \alpha. \end{aligned}$$

Пример С9.6. Рассмотрим задачу восстановления сферы по зашумлённым данным. Пусть дан набор n точек $x_i \in \mathbb{R}^d$ и известно, что это зашумлённые точки сферы радиуса r с центром в x_c . Формально, это означает

$$x_i = \bar{x}_i + v,$$

где $\bar{x}_i \in S_d^2(x_c, r)$, $v \sim \mathcal{N}(0, \varepsilon^2)$. Покажем, что эта задача лежит в классе QP. Задачу восстановления x_c и r по зашумлённым данным можно записать как задачу оптимизации вида

$$\min_{\substack{x_c \in \mathbb{R}^d \\ r \in \mathbb{R}_+}} \sum_{i=1}^n \left(\|x_i - x_c\|_2^2 - r^2 \right)^2.$$

Целевой функционал в таком виде не является выпуклым, однако задача может быть сведена к задаче выпуклой оптимизации. Заметим, что целевая функция представима в виде:

$$f(x_c, r) = \sum_{i=1}^n \left(\|x_i - x_c\|_2^2 - r^2 \right)^2 = \sum_{i=1}^n \left(\|x_i\|_2^2 - 2x_i^\top x_c + \|x_c\|_2^2 - r^2 \right)^2.$$

Введём новую переменную $t = \|x_c\|_2^2 - r^2$. Тогда исходная задача минимизации может быть переписана в виде задачи наименьших квадратов:

$$\min_{\substack{x_c \in \mathbb{R}^d \\ t \in \mathbb{R}}} \sum_{i=1}^n \left(\|x_i\|_2^2 - 2x_i^\top x_c + t \right)^2.$$

Множество решений данной задачи шире, однако если (x_c, t) — решение новой задачи, то выполнено

$$\nabla_t f(x_c, t) = 0 \implies \sum_{i=1}^n \left(\|x_i\|_2^2 - 2x_i^\top x_c + t \right) = 0,$$

откуда следует, что

$$\|x_c\|_2^2 - t = \frac{1}{n} \sum_{i=1}^n \|x_i - x_c\|_2^2 \geq 0.$$

Таким образом, изначально невыпуклую задачу аппроксимации данных сферой удалось свести к задаче из класса QP.

С9.3 Коническое программирование второго порядка

Следующим шагом к расширению класса квадратичных ограничений является обобщение на выпуклые ограничения более общего вида, в частности, на конусы. Начнем с базовых понятий.

Определение С9.3. Множество $K \subseteq \mathbb{R}^d$ называется *конусом*, если для любых $x \in K$ и $\alpha \geq 0$ точка αx также принадлежит K .

Пример С9.7. В качестве простейшей иллюстрации определения, приведем ряд базовых примеров конусов:

- Множества $\emptyset$, $\{0\}$ и $\mathbb{R}^d$;
- Прямая, проходящая через начало координат;
- Луч, начинающийся из начала координат;
- Любое линейное подпространство.

Утверждение С9.2. $K \subseteq \mathbb{R}^d$ является выпуклым конусом тогда и только тогда, когда для любых $x_1, x_2 \in K$, $\alpha_1, \alpha_2 \geq 0$ выполнено $\alpha_1 x_1 + \alpha_2 x_2 \in K$.

Доказательство.

⊕ Пусть K — выпуклый конус. Тогда верно, что для $x_1, x_2 \in K$ выполняется включение $\alpha x_1 + (1 - \alpha)x_2 \in K$, $0 \leq \alpha \leq 1$. Возьмем $\alpha_1, \alpha_2 \geq 0$ одновременно неравные нулю и представим через них α :

$$\alpha = \frac{\alpha_1}{\alpha_1 + \alpha_2}.$$

Тогда воспользуемся определением конуса и получим $\alpha_1 x_1 + \alpha_2 x_2 \in K$.

⊖ Пусть $\alpha_1 x_1 + \alpha_2 x_2 \in K$, тогда, если взять $\alpha_1 = \alpha$ и $\alpha_2 = 1 - \alpha$ при $0 \leq \alpha \leq 1$, то получим, что K является выпуклым. А если взять $\alpha_1 = \alpha$ и $\alpha_2 = 0$, то получим, что K — конус. ■

Утверждение С9.3. Пересечение любого семейства множеств сохраняет свойство быть конусом, а также сохраняется свойство быть выпуклым конусом.

Доказательство.

- Пусть $x \in \bigcap_{i \in I} K_i$, тогда $\alpha x \in \bigcap_{i \in I} K_i$, так как $\alpha x \in K_i \forall i \in I$.
- Следует из того, что пересечение выпуклых множеств выпукло и пересечение конусов — конус. ■

Теперь, когда введены необходимые определения, поставим первую задачу с конечными ограничениями.

Определение С9.4. Задача *конического программирования второго порядка* (Second-Order Cone Programming) (SOCP) записывается в виде:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & \|P_i x - q_i\|_2 \leq e_i^\top x + f_i, \quad i = \overline{1, m} \\ & Gx = h, \end{aligned}$$

где $c \in \mathbb{R}^d$, $P_i \in \mathbb{R}^{k_i \times d}$, $q_i \in \mathbb{R}^{k_i}$, $e_i \in \mathbb{R}^d$, $f_i \in \mathbb{R}$, $G \in \mathbb{R}^{n \times d}$, $h \in \mathbb{R}^n$.

SOCP находит применение в проектировании фильтров, расчете веса антенных решеток и оптимизации силы захвата в робототехнике.

Замечание С9.3. Ограничение вида неравенства означает, что пары

$$(P_i x - q_i, e_i^\top x + f_i)$$

лежат в конусах второго порядка

$$K_i = \left\{ (y, t) \in \mathbb{R}^{k_i} \times \mathbb{R}_+ \mid \|y\|_2 \leq t \right\}$$

соответствующей размерности.

Вложение QCQP $\subset$ SOCP не так очевидно, как LP $\subset$ QCQP, и требует формального доказательства.

Утверждение С9.4. Выполнено строгое вложение QCQP $\subset$ SOCP.

Доказательство. Заметим, что целевая функция может быть опущена в ограничение с помощью переформулировки оптимизационной задачи через надграфик. Действительно, рассмотрим минимизацию выпуклой функции

$$\min_{x \in \mathbb{R}^d} f(x).$$

Эта задача имеет такое же решение, как и

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ t \in \mathbb{R}}} \quad & t \\ \text{s.t.} \quad & f(x) \leq t. \end{aligned}$$

Таким образом, достаточно рассмотреть квадратичное ограничение вида

$$\frac{1}{2} x^\top P x + q^\top x + r \leq 0$$

и показать, что оно эквивалентно коническому. Так как $P \in \mathbb{S}_+^d$, то из неё можно извлечь корень, то есть существует $L \in \mathbb{R}^{d \times d}$ такой, что $P = 2L^\top L$. Тогда имеем

$$\frac{1}{2} x^\top P x + q^\top x + r = \|Lx\|_2^2 + q^\top x + r.$$

Рассмотрим линейную часть этого ограничения. Обозначая $p = q^\top x + r$ и используя тождество

$$p = \left(\frac{p+1}{2} \right)^2 - \left(\frac{p-1}{2} \right)^2,$$

получим

$$\|Lx\|_2^2 + \left(\frac{q^\top x + r + 1}{2} \right)^2 \leq \left(\frac{q^\top x + r - 1}{2} \right)^2.$$

Извлекая квадратный корень, получим:

$$\sqrt{\|Lx\|_2^2 + \left(\frac{q^\top x + r + 1}{2} \right)^2} \leq \frac{1 - q^\top x - r}{2}.$$

Рассмотрим преобразования

$$g(x) = \left(Lx, \frac{q^\top x + r + 1}{2} \right), \quad h(x) = \frac{1 - q^\top x - r}{2}.$$

Это аффинные преобразования. Таким образом, каждое выпуклое квадратичное ограничение сводится к коническому. Следовательно, QCQP $\subset$ SOCP. ■

Доказательство вложения QCQP $\subset$ SOCP использует переформулировку через надграфик. Этот же подход может быть использован и для приведения задач к виду SOCP. Рассмотрим простейшие примеры.

Пример C9.8. Рассмотрим задачу минимизации суммы норм аффинных преобразований:

$$\min_{x \in \mathbb{R}^d} \sum_{i=1}^m \|A_i x - b_i\|_2,$$

где $A_i \in \mathbb{R}^{n \times d}$, $b_i \in \mathbb{R}^n$. Покажем, что она лежит в классе SOCP. Точки (x, t_i) надграфика i -го аффинного преобразования задаются неравенством

$$\|A_i x - b_i\|_2 \leq t_i.$$

Тогда исходная задача может быть переписана в виде

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d, \\ t \in \mathbb{R}^m}} \quad & \sum_{i=1}^m t_i \\ \text{s.t.} \quad & \|A_i x - b_i\|_2 \leq t_i, \quad i = \overline{1, m}. \end{aligned}$$

Пример C9.9. Рассмотрим задачу оптимизации

$$\min_{x \in \mathbb{R}^d} \max_{i = \overline{1, m}} \|A_i x - b_i\|_2,$$

где $A_i \in \mathbb{R}^{n \times d}$, $b_i \in \mathbb{R}^n$. Аналогично предыдущему примеру, она может быть переписана в виде

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d, \\ t \in \mathbb{R}}} \quad & t \\ \text{s.t.} \quad & \|A_i x - b_i\|_2 \leq t, \quad i = \overline{1, m}. \end{aligned}$$

Замечание C9.4. Примеры C9.8, C9.9 демонстрируют, что негладкие компоненты целевой функции могут быть вынесены в ограничения, что делает задачу более удобной для решения, например, барьерными методами (Параграф Л12).

В завершение обсуждения класса SOCP перейдем к обсуждению более сложных практических примеров.

Пример C9.10. Пусть выполнено ограничение вида

$$c^\top x \leq \alpha, \quad \forall c \in \left\{ c \in \mathbb{R}^d \mid \|c - c_0\|_2 \leq \varepsilon, \quad Ac \leq b \right\},$$

где $c_0 \in \mathbb{R}^d$, $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$, $\alpha, \varepsilon \in \mathbb{R}$. Ограничения такого рода крайне тяжело проверять, поэтому их нужно каким-либо образом упростить. Покажем, что эти ограничения сводятся к ограничениям из класса SOCP. Найдем наибольшее значение $c^\top x$:

$$\begin{aligned} \max_{\|c - c_0\|_2 \leq \varepsilon} \quad & c^\top x \\ \text{s.t.} \quad & Ac \leq b. \end{aligned}$$

В силу того, что внутренность множества не пуста, выполняется сильная двойственность. То есть оптимальное значение прямой задачи совпадает с оптимальным значением двойственной. Построим двойственную задачу, запишем лагранжиан задачи:

$$\mathcal{L}(c, \lambda) = -c^\top x + \lambda^\top (Ac - b).$$

Далее, вычислим двойственную функцию:

$$\begin{aligned} g(\lambda) &= \inf_{\|c - c_0\|_2 \leq \varepsilon} \mathcal{L}(c, \lambda) \\ &= -c_0^\top x + \lambda^\top (Ac_0 - b) + \inf_{\|\Delta\|_2 \leq \varepsilon} (\lambda^\top A - x^\top) \Delta \\ &= -c_0^\top x + \lambda^\top (Ac_0 - b) - \varepsilon \|A^\top \lambda - x\|_2. \end{aligned}$$

Тогда двойственная задача имеет вид

$$\begin{aligned} \min_{\lambda \in \mathbb{R}^n} \quad & c_0^\top x - \lambda^\top (Ac_0 - b) + \varepsilon \|A^\top \lambda - x\|_2 \\ \text{s.t.} \quad & \lambda \succeq 0. \end{aligned}$$

Таким образом, исходный набор ограничений может быть переписан в виде конического ограничения:

$$\begin{aligned} \|A^\top \lambda - x\|_2 &\leq \frac{1}{\varepsilon} (Ac_0 - b)^\top \lambda + \frac{1}{\varepsilon} (\alpha - c_0^\top x), \\ \lambda &\succeq 0. \end{aligned}$$

Если требуется учитывать несколько значений параметров задачи одновременно, то говорят, что имеют дело с задачей *робастного программирования*.

Пример С9.11. Рассмотрим робастную задачу наименьших квадратов:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \sup_{(A, b) \in \mathcal{A}} \|Ax - b\|_2 \right],$$

где

$$\mathcal{A}(A_0, b_0) = \left\{ (A, b) \in \mathbb{R}^{n \times d} \times \mathbb{R}^n \mid \|(A - A_0 \quad b - b_0)\|_F \leq \rho \right\}, \quad A_0 \in \mathbb{R}^{n \times d}, \quad b_0 \in \mathbb{R}^n.$$

Покажем, что эта задача лежит в классе SOCP. Введём обозначение $\Delta A = A - A_0$, $\Delta B = B - B_0$. Пользуясь неравенством треугольника и неравенством Коши–Буняковского–Шварца (0.3), получим следующую цепочку неравенств:

$$\begin{aligned} f(x) &\leq \|A_0 x - b_0\|_2 + \sup_{\|(\Delta A \quad \Delta b)\|_F \leq \rho} \|\Delta A x - \Delta b\|_2 \\ &\leq \|A_0 x - b_0\|_2 + \sup_{\|(\Delta A \quad \Delta b)\|_F \leq \rho} \|(\Delta A \quad \Delta b)\|_F \left\| \begin{pmatrix} x \\ 1 \end{pmatrix} \right\|_2 \\ &= \|A_0 x - b_0\|_2 + \rho \left\| \begin{pmatrix} x \\ 1 \end{pmatrix} \right\|_2. \end{aligned}$$

Покажем, что все неравенства выше реализуются как равенства.

1. Пусть $A_0x - b_0 = 0$. Тогда первое неравенство реализуется как равенство. Выберем дополнительно

$$(\Delta A \quad \Delta b) = \rho \frac{\mathbf{1}x_1^\top}{\sqrt{n}\|x_1\|_2}, \quad x_1 = \begin{pmatrix} x \\ 1 \end{pmatrix}.$$

Тогда второе неравенство также обращается в равенство.

2. Теперь пусть $A_0x - b_0 \neq 0$. Тогда возьмём

$$(\Delta A \quad \Delta b) = \rho \frac{(A_0x - b_0)x_1^\top}{\|A_0x - b_0\|_2\|x_1\|_2}, \quad x_1 = \begin{pmatrix} x \\ -1 \end{pmatrix}.$$

Для такой матрицы оба неравенства реализуются как равенства.

Таким образом, исходная задача может быть переписана в виде

$$\min_{x \in \mathbb{R}^d} \quad \|A_0x - b_0\|_2 + \rho \left\| \begin{pmatrix} x \\ 1 \end{pmatrix} \right\|_2,$$

которая сводится к SOCP за счет переформулировки через надграфик.

С9.4 Полуопределенное программирование

Класс SOCP можем расширить за счет рассмотрения более общего случая конических ограничений.

Определение С9.5. Задача *полуопределенного программирования* (*SemiDefinite Programming*) (SDP) записывается в виде:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & P_0 + \sum_{i=1}^d P_i x_i \succeq 0 \\ & Gx = h, \end{aligned}$$

где $c \in \mathbb{R}^d$, $P_i \in \mathbb{S}^d$, $G \in \mathbb{R}^{n \times d}$, $h \in \mathbb{R}^n$.

Задачи этого класса используются в областях исследования операций и комбинаторной оптимизации, машинном обучении, теории автоматического управления, оптимизации сигналов и теории игр. Преобразование ограничений к виду, соответствующему SDP, как правило, опирается на лемму Шура.

Утверждение С9.5. Рассмотрим блочную матрицу

$$M = \begin{pmatrix} A & B \\ B^\top & C \end{pmatrix},$$

где $A \in \mathbb{S}_{++}^d$, $B \in \mathbb{R}^{d \times n}$, $C \in \mathbb{S}^n$. Тогда M положительно полуопределена тогда и только тогда, когда

$$B^\top A^{-1} B \preceq C.$$

Доказательство. Положительная полуопределенность матрицы M эквивалентна выполнению неравенства

$$x^\top Ax + 2x^\top By + y^\top Cy \geq 0$$

для любых $x \in \mathbb{R}^d$, $y \in \mathbb{R}^n$. Эквивалентно перепишем это в виде

$$\inf_{x \in \mathbb{R}^d} [x^\top Ax + 2x^\top By + y^\top Cy] \geq 0$$

для любого $y \in \mathbb{R}^n$. Функция

$$g(x) = x^\top Ax + 2x^\top By + y^\top Cy$$

является выпуклой по x с единственным минимумом в точке

$$x^* = -A^{-1}By.$$

Таким образом, имеем

$$\begin{aligned} g(x^*) &= y^\top B^\top A^{-1}By - 2y^\top B^\top A^{-1}By + y^\top Cy \\ &= y^\top (C - B^\top A^{-1}B)y \geq 0, \end{aligned}$$

что в свою очередь эквивалентно

$$B^\top A^{-1}B \preceq C.$$

■

Пользуясь Утверждением C9.5, докажем следующий факт.

Утверждение C9.6. Выполнено строгое вложение $\text{SOCP} \subset \text{SDP}$.

Доказательство. Рассмотрим коническое ограничение:

$$\|Px - q\|_2 \leq e^\top x + f.$$

Оно может быть эквивалентно переписано в виде

$$(Px - q)^\top \frac{I_n}{e^\top x + f} (Px - q) \leq e^\top x + f$$

что в свою очередь эквивалентно положительной полуопределенности матрицы

$$M = \begin{pmatrix} (e^\top x + f)I_n & Px - q \\ (Px - q)^\top & e^\top x + f \end{pmatrix}.$$

Распишем матрицу M :

$$M = \begin{pmatrix} fI_n & -q \\ -q^\top & f \end{pmatrix} + \sum_{i=1}^d x_i \begin{pmatrix} e_i I_n & p_i \\ p_i^\top & e_i \end{pmatrix},$$

где p_i — столбец матрицы P . Таким образом, коническое ограничение в задаче из класса SOCP сводится к виду SDP. ■

Пример С9.12. Рассмотрим задачу оптимального дизайна эксперимента. Пусть даны измерения вида

$$y_i = a^\top x_i + \varepsilon,$$

где $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ — шум, $y_i \in \mathbb{R}$ — наблюдаемая величина, $a \in \mathbb{R}^d$ — параметры модели, которые необходимо восстановить, $x_i \in \mathbb{R}^d$ — параметры измерений. Векторы x_i являются гиперпараметрами и могут быть выбраны из конечного набора $\{v_i\}_{i=1}^n$. Задача состоит в выборе K векторов x_i таким образом, чтобы дисперсия решения a была минимальна. Покажем, что эту задачу можно рассматривать как SDP. Пусть d_i — число векторов v_i в наборе. Запишем логарифм правдоподобия:

$$\log L \propto - \sum_{i=1}^K \frac{(y_i - a^\top x_i)^2}{2\sigma^2}.$$

Найдем информацию Фишера:

$$I(a) = -\nabla^2 \log L = \frac{1}{\sigma^2} \sum_{i=1}^K x_i x_i^\top = \frac{1}{\sigma^2} \sum_{i=1}^n d_i v_i v_i^\top.$$

Воспользуемся неравенством Рао–Крамера для любого $u \in \mathbb{R}^d$:

$$u^\top S u \geq u^\top I^{-1}(a) u \geq \frac{1}{\lambda_{\min}(I(a))},$$

где S — ковариационная матрица. Тогда рассматриваемая задача может быть формализована как

$$\begin{aligned} \max_{d \in \mathbb{Z}_+^n} \quad & \lambda_{\min} \left(\sum_{i=1}^n d_i v_i v_i^\top \right) \\ \text{s.t.} \quad & \sum_{i=1}^n d_i = K. \end{aligned}$$

Рассмотрим ее релаксацию:

$$\begin{aligned} \max_{\mu \in \mathbb{R}^n} \quad & \lambda_{\min} \left(\sum_{i=1}^n \mu_i v_i v_i^\top \right) \\ \text{s.t.} \quad & \mathbf{1}^\top \mu = 1 \\ & \mu \geq 0, \end{aligned}$$

где μ_i — доля векторов v_i во всем наборе. Отметим, что точность такой релаксации растёт с числом K в исходной задаче. Перепишем в виде SDP:

$$\begin{aligned} \max_{\substack{\mu \in \mathbb{R}^n \\ t \in \mathbb{R}}} \quad & t \\ \text{s.t.} \quad & \sum_{i=1}^n \mu_i v_i v_i^\top \succeq t I_n \\ \text{s.t.} \quad & \mathbf{1}^\top \mu = 1 \\ & \mu \geq 0. \end{aligned}$$

Пример C9.13. Рассмотрим задачу минимизации спектрального радиуса матрицы

$$\min_{x \in \mathbb{R}^d} \|A(x)\|_2,$$

где

$$A(x) := A_0 + \sum_{i=1}^n A_i x_i, \quad A_i \in \mathbb{R}^{n \times d}.$$

Покажем, что она лежит в классе SDP. Целевая функция негладкая. Уберем её в ограничения через надграфик и перепишем в эквивалентном виде:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^n \\ t \in \mathbb{R}}} \quad & t \\ \text{s.t.} \quad & \lambda_{\max}(A(x)^\top A(x)) \leq t^2 \\ & t \geq 0. \end{aligned}$$

Заметим, что ограничение, содержащее максимальное собственное число, эквивалентно ограничению

$$A(x)^\top A(x) \preceq t^2 I_d.$$

Поскольку $t \geq 0$, то

$$A(x)^\top A(x) \preceq t^2 I_d \iff A(x)^\top A(x) \preceq (t + \varepsilon)^2 I_d, \quad \forall \varepsilon > 0.$$

По Утверждению C9.5 это эквивалентно

$$\begin{pmatrix} (t + \varepsilon) I_n & A(x) \\ A(x)^\top & (t + \varepsilon) I_d \end{pmatrix} = \begin{pmatrix} t I_n & A(x) \\ A(x)^\top & t I_d \end{pmatrix} + \varepsilon I_{d+n} \succeq 0.$$

Но в силу произвольности выбора $\varepsilon > 0$, имеем:

$$\begin{pmatrix} t I_n & A(x) \\ A(x)^\top & t I_d \end{pmatrix} \succeq 0.$$

Таким образом, исходная негладкая задача эквивалентна следующей задаче SDP:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ t \in \mathbb{R}}} \quad & t \\ \text{s.t.} \quad & \begin{pmatrix} t I_n & A(x) \\ A(x)^\top & t I_d \end{pmatrix} \succeq 0. \end{aligned}$$

Замечание C9.5. Задачу SDP иногда формулируют для матриц в следующем виде:

$$\begin{aligned} \min_{X \in \mathbb{S}^d} \quad & \text{Tr}(A_0^\top X) \\ \text{s.t.} \quad & \text{Tr}(A_i^\top X) = b_i, \quad i = \overline{1, m} \\ & X \succeq 0, \end{aligned}$$

где $A_i \in \mathbb{R}^{d \times d}$, $b_i \in \mathbb{R}$.

Пример С9.14. Рассмотрим задачу вида

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \frac{1}{2} x^\top A_0 x + b_0^\top x + c_0 \\ \text{s.t.} \quad & \frac{1}{2} x^\top A_i x + b_i^\top x + c_i \leq 0, \quad i = \overline{1, m}. \end{aligned}$$

где $A_i \in \mathbb{S}^d$, $b_i \in \mathbb{R}^d$, $c_i \in \mathbb{R}$, то есть квадратичные формы не обязаны быть неотрицательно определенными. Покажем, что эту задачу можно рассматривать как SDP. Введём новую переменную $X = xx^\top \in \mathbb{S}_+^d$ и перепишем задачу в эквивалентном виде:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ X \in \mathbb{S}^d}} \quad & \frac{1}{2} \text{Tr}(A_0 X) + b_0^\top x + c_0 \\ \text{s.t.} \quad & \frac{1}{2} \text{Tr}(A_i X) + b_i^\top x + c_i \leq 0, \quad i = \overline{1, m} \\ & X = xx^\top. \end{aligned}$$

Заметим, что теперь целевая функция и все ограничения–неравенства являются линейными, а следовательно выпуклыми. В таком виде вся сложность исходной задачи ушла в последнее ограничение $X = xx^\top$. Ослабим его до неравенства $X \succeq xx^\top$, которое можно переписать при помощи Утверждения С9.5:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ X \in \mathbb{S}^d}} \quad & \frac{1}{2} \text{Tr}(A_0 X) + b_0^\top x + c_0 \\ \text{s.t.} \quad & \frac{1}{2} \text{Tr}(A_i X) + b_i^\top x + c_i \leq 0, \quad i = \overline{1, m} \\ & \begin{pmatrix} 1 & x^\top \\ x & X \end{pmatrix} \succeq 0. \end{aligned}$$

Отметим, что если в решении такой релаксации $\text{rank } X = 1$, то x — решение исходной задачи.

С10 Задача программирования с коническими ограничениями

Параграф С9 завершился рассмотрением проблем программирования SOCP и SDP, минимизирующих линейный функционал на пересечении конусов из определенных классов. Обобщая рассматриваемые задачи на произвольные функционалы и произвольные конусы, можно записать

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \in K_i, \quad i = \overline{1, n} \\ & h_j(x) = 0, \quad j = \overline{1, m}, \end{aligned}$$

где $\{K_i\}_{i=1}^n$ — набор конусов, на которых ведется оптимизация. Цель этого параграфа — понять, какие ограничения нужно ввести на конусы и функции, чтобы построить теорию решения таких проблем программирования. Чтобы выполнить эту задачу, мы вводим понятие сопряжённого конуса и исследуем его свойства, вводим монотонность и выпуклость относительно конуса.

С10.1 Сопряжённые конусы

Определение С10.1. Пусть $K \subseteq V$ — конус в конечномерном евклидовом пространстве. *Сопряжённым конусом* к K называется множество

$$K^* = \{ y \in V \mid \langle y, x \rangle \geq 0, \forall x \in K \}.$$




Рис. С10.1: Конус K и сопряжённый к нему конус K^* . Границы K^* перпендикулярны границам K .

Таким образом, в конечномерном случае сопряжённый конус задается как множество, ограниченное нормальными касательными плоскостями к K таким, что K целиком лежит по одну сторону от них.

Замечание C10.1. Множество K^* из Определения C10.1 действительно является конусом. Чтобы убедиться в этом, достаточно зафиксировать $\alpha \geq 0$ и заметить, что

$$\langle \alpha y, x \rangle = \alpha \langle y, x \rangle \geq 0.$$

Мы обсудим прикладной смысл сопряжённых конусов позже, пока сфокусируемся на полезных свойствах и примерах.

Пример C10.1. Постройте двойственный конус к конусу:

$$K = \{x \in \mathbb{R}^d \mid Ax \prec 0\} \cup \{0\}.$$

Решение. Заметим, что существование y , для которого $\langle y, x \rangle \geq 0$ на всех $x \in K$, эквивалентно неразрешимости системы неравенств

$$\begin{cases} Ax \prec 0, \\ y^\top x < 0. \end{cases}$$

Мы выводили критерий неразрешимости такой системы в Примере C3.16: должны существовать такие $u \succeq 0$, $\lambda \geq 0$, что

$$u^\top A + \lambda y^\top = 0.$$

Возьмем $\lambda = 1$ и получим

$$y = -A^\top u.$$

Таким образом, $K^* \subseteq M$, где

$$M = \left\{ -A^\top u \mid u \in \mathbb{R}_+^d \right\}.$$

Докажем обратное вложение. Запишем определение сопряжённого конуса:

$$\langle -A^\top u, x \rangle = u^\top (-Ax) \geq 0.$$

Таким образом, показали, что $K^* = M$. ■

Замечание C10.2. Исследуем поглубже, как устроены точки сопряжённого конуса в предыдущем примере. Нетрудно видеть, что они имеют вид

$$u = \sum_{i=1}^d u_i (-a_i),$$

где a_i — строка матрицы A . Таким образом, сопряжённый конус порожден неотрицательными линейными комбинациями внешних нормалей к полупространствам, образующим конус K . Эта интуиция часто помогает угадать вид сопряжённого конуса.

Пример C10.2. Покажите, что для конуса Лоренца:

$$K = \left\{ (x, t) \in \mathbb{R}^d \times \mathbb{R} \mid \|x\| \leq t \right\}$$

двойственным является:

$$K^* = \left\{ (u, v) \in \mathbb{R}^d \times \mathbb{R} \mid \|u\|_* \leq v \right\}.$$

Решение. По определению двойственного конуса имеем

$$K^* = \left\{ (u, v) \in \mathbb{R}^d \times \mathbb{R} \mid \langle x, u \rangle + tv \geq 0, \forall (x, t) \in \mathbb{R}^d \times \mathbb{R} : \|x\| \leq t \right\}.$$

Предположим, что $\|u\|_* > v$. Тогда по определению сопряжённой нормы

$$\exists x : \|x\| \leq 1, \langle -x, u \rangle > v,$$

откуда следует

$$\langle u, x \rangle + v < 0.$$

Это противоречит определению элемента сопряжённого конуса.

Докажем теперь, что из $\|u\|_* \leq v$ следует $\langle x, u \rangle + tv \geq 0$. Предположим, что $\|u\|_* \leq v$ и $\|x\| \leq t$ для некоторого $t > 0$. Применяя определение сопряжённой нормы, получаем:

$$\left\langle u, -\frac{x}{t} \right\rangle \leq \|u\|_* \frac{\|x\|}{t} \leq \|u\|_* \leq v,$$

откуда следует требуемое. ■

Пример C10.3. Постройте двойственный конус для степенного конуса:

$$K = \left\{ (x, z) \in \mathbb{R}_+^d \times \mathbb{R} \mid x_1^{\alpha_1} \dots x_d^{\alpha_d} \geq |z|, \sum_{i=1}^d \alpha_i = 1, \alpha_i \geq 0 \right\}.$$

Решение. Попытаемся найти множество, в которое вложено K^* , а затем будем пытаться доказать обратное вложение. Пусть $(x, z) \in K$, $(s, w) \in K^*$. Согласно определению сопряжённого конуса, должно быть выполнено условие

$$s^\top x + zw \geq 0.$$

Рассмотрим точку $(\hat{x}, \hat{z}) = ((1, 0, \dots, 0)^\top, 0)$. Она принадлежит конусу K , при этом условие на точки сопряжённого конуса вырождается в

$$s_1 \geq 0.$$

Аналогичным образом можно показать, что $s_i \geq 0$ для любого $i = \overline{1, d}$. Иначе получим противоречие с определением сопряжённого конуса. Теперь попробуем угадать какое-нибудь условие на w . Пусть

$$|w| > \prod_{i=1}^d \left(\frac{s_i}{\alpha_i} \right)^{\alpha_i} \implies |w| \prod_{i=1}^d \left(\frac{\alpha_i}{s_i} \right)^{\alpha_i} > 1.$$

Построим точку с компонентами $\hat{x}_i = \frac{\alpha_i}{s_i} \geq 0$ и $\hat{z} = -|w| \prod_{i=1}^d \left(\frac{\alpha_i}{s_i} \right)^{\alpha_i}$. Она лежит в конусе K . Распишем определение сопряжённого конуса:

$$s^\top \hat{x} + w\hat{z} = \sum_{i=1}^d s_i \frac{\alpha_i}{s_i} - |w| \prod_{i=1}^d \left(\frac{\alpha_i}{s_i} \right)^{\alpha_i} < 1 - 1 = 0.$$

Таким образом, получили противоречие. Следовательно, K^* содержится во множестве

$$M = \left\{ (s, w) \in \mathbb{R}_+^d \times \mathbb{R} \mid \prod_{i=1}^d \left(\frac{s_i}{\alpha_i} \right)^{\alpha_i} \geq |w| \right\}.$$

Докажем вложение $M \subseteq K^*$. Для этого воспользуемся определением множеств K и M и запишем

$$s^\top x + zw \geq s^\top x - |w||z| \geq s^\top x - \prod_{i=1}^d \left(\frac{s_i}{\alpha_i} \right)^{\alpha_i} \prod_{i=1}^d x_i^{\alpha_i}.$$

Воспользуемся тем, что если $y \in \mathbb{R}_+^d$ и $1^\top \alpha = 1$, то выполнено

$$\sum_{i=1}^d \alpha_i y_i \geq \prod_{i=1}^d y_i^{\alpha_i}.$$

Выберем $y_i = \frac{s_i x_i}{\alpha_i}$ и получим

$$s^\top x + zw \geq 0.$$

Таким образом, доказали $K^* = M$. ■

Пример C10.4. Постройте двойственный конус для экспоненциального конуса:

$$K = K_0 \cup (-\mathbb{R}_+ \times \mathbb{R}_+ \times \{0\}),$$

где

$$K_0 = \left\{ (x, y, z) \in \mathbb{R} \times \mathbb{R}_+ \times \mathbb{R}_{++} \mid \exp\left(\frac{x}{z}\right) \leq \frac{y}{z} \right\}.$$

Решение. Начнем с поиска выпуклого конуса, состоящего из точек s , в который вложено K^* , а затем докажем вложение в обратную сторону. Рассмотрим точку $x = (-1, 0, 0)$. Расписывая определение сопряжённого конуса, получим $s_1 \leq 0$. Аналогично, выбрав $x = (0, 1, 0)$, получим $s_2 \geq 0$. Продолжим накладывать ограничения, учитывая полученные выше. Пусть для начала $s_1 = 0$. Выбрав $x = (0, 1, 1)$, откинем случай $s_2 = 0$, $s_3 < 0$. Выбрав $x = \left(\log\left(-\frac{s_3}{2s_2}\right), -\frac{s_3}{2s_2}, 1 \right)$, откинем случай $s_2 > 0$, $s_3 < 0$. Таким образом, искомое множество содержит прямую $\{0\} \times \mathbb{R}_+ \times \mathbb{R}_+$. Пусть теперь $s_1 < 0$. Рассмотрим $x = \left(1, \frac{e^t}{t}, \frac{1}{t}\right) \in K$. Запишем определение:

$$s^\top x = s_1 + \frac{s_2 e^t}{t} + \frac{s_3}{t}.$$

Отсюда видно, что если $s_2 = 0$ и t достаточно велико, то $s^\top x < 0$, что противоречит определению сопряжённого конуса. Осталось покрыть случай $s_1 < 0$, $s_2 > 0$. Рассмотрим точку $x \in K$ с координатами

$$x_1 = \frac{s_1 - s_3}{s_1 s_2} \exp\left(-\frac{s_1 - s_3}{s_1}\right), \quad x_2 = \frac{1}{s_2}, \quad x_3 = \frac{1}{s_2} \exp\left(-\frac{s_1 - s_3}{s_1}\right).$$

Для нее имеем

$$s^\top x = \frac{s_1}{s_2} \exp\left(-\frac{s_1 - s_3}{s_1}\right) + 1.$$

Это выражение неотрицательно тогда и только тогда, когда

$$\exp\left(-\frac{s_1 - s_3}{s_1}\right) \leq -\frac{s_2}{s_1} \implies \exp\left(\frac{s_3}{s_1}\right) \leq -\frac{e s_2}{s_1}.$$

Таким образом, $K^* \subseteq M$, где

$$M = M_0 \cup (\{0\} \times \mathbb{R}_+ \times \mathbb{R}_+),$$

где

$$M_0 = \left\{ (s_1, s_2, s_3) \in -\mathbb{R}_{++} \times \mathbb{R}_+ \times \mathbb{R} \mid \exp\left(\frac{s_3}{s_1}\right) \leq -\frac{es_2}{s_1} \right\}.$$

Осталось доказать обратное вложение. Отметим, что интересен только случай $x \in K_0$, $s \in M_0$, поскольку остальные легко отмечаются по определению. Запишем

$$\begin{aligned} s^\top x &= s_1 x + s_2 y + s_3 z \geq s_1 x + s_2 z \exp\left(\frac{x}{z}\right) + s_3 z \\ &\geq s_1 x - s_1 z \exp\left(-\frac{s_1 z - s_3 z - s_1 x}{s_1 z}\right) + s_3 z. \end{aligned}$$

В этих двух переходах мы воспользовались неотрицательностью s_2 и y . Далее учтем, что $s_1 z \leq 0$ и оценим экспоненту снизу:

$$s^\top x \geq s_1 x_1 - s_1 x_3 \left(1 - \frac{s_1 x_3 - s_3 x_3 - s_1 x_1}{s_1 x_3}\right) + s_3 x_3 = 0.$$

Таким образом, имеем $M \subseteq K^*$. ■

Выше рассмотрены примеры конусов со сложной геометрией. В более простых случаях (в частности, в задаче SDP) сопряжённый конус зачастую совпадает с исходным.

Определение C10.2. Если сопряжённый конус K^* совпадает с исходным K , то K называется *самосопряжённым конусом*.

Пример C10.5. Покажите, что $K = \mathbb{R}_+^d$ является самосопряжённым конусом.

Решение. По определению имеем

$$K^* = \left\{ y \in \mathbb{R}^d \mid \langle x, y \rangle \geq 0, \forall x \in \mathbb{R}_+^d \right\} = \mathbb{R}_+^d.$$

Таким образом, имеем $K = K^* = \mathbb{R}_+^d$. ■

Пример C10.6. Покажите, что $K = \mathbb{S}_+^d$ является самосопряжённым конусом в пространстве $\mathbb{S}^d$.

Решение. Докажем вложение $K \subseteq K^*$. Зафиксируем матрицы $X, Y \in \mathbb{S}_+^d$. Заметим, что $X \in K$ имеет базис $\{v_i\}_{i=1}^d$, составленный из её собственных векторов, в котором она имеет вид

$$X = \sum_{i=1}^d \lambda_i v_i v_i^\top, \quad \lambda_i \geq 0.$$

Следовательно, имеем

$$\text{Tr}(YX) = \text{Tr}\left(Y \sum_{i=1}^d \lambda_i v_i v_i^\top\right) = \sum_{i=1}^d \lambda_i v_i^\top Y v_i \geq 0.$$

Таким образом, $Y \in K^*$.

Докажем теперь обратное вложение, рассмотрев матрицу $Y \notin \mathbb{S}_+^d$. Существует вектор $v \in \mathbb{R}^d$ такой, что

$$v^\top Y v = \text{Tr}(v^\top Y v) = \text{Tr}(v v^\top Y) < 0.$$

Введем $X = v v^\top$. Она симметричная и положительно полуопределенная, то есть нашелся такой элемент K , что $\langle Y, X \rangle < 0$. Таким образом, $Y \notin K^*$, из чего следует $K = K^*$. ■

Пример C10.7. Покажите, что $K = \mathbb{S}_+^d$ не образует самосопряженный конус в пространстве квадратных матриц $\mathbb{R}^{d \times d}$.

Решение. Введём множество M_+ :

$$M_+ = \left\{ Y \in \mathbb{R}^{d \times d} \mid z^\top Y z \geq 0, \forall z \geq 0 \right\}.$$

Рассмотрим $Y \in M_+$, $X \in \mathbb{S}_+^d$. Раскладывая X по базису ее собственных векторов $\{v_i\}_{i=1}^d$, получим

$$X = \sum_{i=1}^d \lambda_i v_i v_i^\top, \quad \lambda_i \geq 0.$$

Следовательно, имеем

$$\text{Tr}(YX) = \text{Tr}\left(Y \sum_{i=1}^d \lambda_i v_i v_i^\top\right) = \sum_{i=1}^d \lambda_i v_i^\top Y v_i \geq 0.$$

Таким образом, $Y \in K^*$. Предположим теперь, что $Y \notin M_+$, то есть существует вектор $v \in \mathbb{R}^d$ такой, что

$$v^\top Y v = \text{Tr}(v^\top Y v) = \text{Tr}(v v^\top Y) < 0.$$

Заметим, что $v v^\top \in \mathbb{S}_+^d$, то есть нашелся X , на котором скалярное произведение отрицательно. Доказано обратное вложение. Таким образом, в пространстве квадратных матриц $K^* = M_+$, то есть конус K не самосопряженный. ■

C10.2 Свойства сопряженных конусов

В следующих трех утверждениях мы показываем, что сопряженные конусы имеют «хорошую» геометрию. В частности, удастся гарантировать, что сопряженный конус выпуклый и замкнутый вне зависимости от наличия этих свойств у исходного конуса.

Утверждение C10.1. Пусть $K \subseteq V$ — конус в конечномерном евклидовом пространстве. Сопряженный конус K^* выпуклый и замкнутый.

Доказательство. Чтобы показать выпуклость конуса, достаточно продемонстрировать, что для любых $y_1, y_2 \in K^*$ и любых $\alpha_1, \alpha_2 \geq 0$ выполнено

$$\alpha_1 y_1 + \alpha_2 y_2 \in K^*.$$

Распишем неравенство из определения сопряжённого конуса:

$$\langle \alpha_1 y_1 + \alpha_2 y_2, x \rangle = \alpha_1 \langle y_1, x \rangle + \alpha_2 \langle y_2, x \rangle \geq 0.$$

Таким образом, K^* — выпуклый конус. Далее, рассмотрим $\{y_k\}_{k \in \mathbb{N}} \subset K^*$ с ее пределом $y \in V$. Нетрудно заметить:

$$\lim_{k \rightarrow \infty} \langle y_k, x \rangle = \langle y, x \rangle.$$

Поскольку при любом k имеем $\langle y_k, x \rangle \geq 0$, то и предел последовательности также неотрицательный. Таким образом, K^* замкнутый. ■

Утверждение C10.2. Пусть $K \subseteq V$ — конус в конечномерном евклидовом пространстве. Если $\text{int } K \neq \emptyset$, то K^* не содержит прямых.

Доказательство. Будем доказывать от противного. Предположим, что нашелся такой ненулевой $y \in K^*$, что $\alpha y \in K^*$ для любого $\alpha \in \mathbb{R}$. Это означает, что

$$\langle y, x \rangle = 0, \quad \forall x \in K,$$

поскольку линия в K^* содержит как y , так и $-y$. Так как $\text{int } K \neq \emptyset$, то в K содержится такой шар, что скалярное произведение равно нулю в его центре и остается равным нулю при сдвиге в любом направлении от него. Но это значит, что $\langle y, x \rangle = 0$ на всем V . Но тогда $y = 0$, что противоречит предположению, от которого мы отталкивались. ■

Утверждение C10.3. Пусть $K \subseteq V$ — конус в конечномерном евклидовом пространстве. Если K не содержит прямых, то $\text{int } K^* \neq \emptyset$.

Доказательство. Пусть $\dim V = d$. Будем доказывать от противного. Пусть K не содержит прямых, но при этом $\text{int } K^* = \emptyset$. Это означает, что $K^* \subseteq L$, где L — такое аффинное подпространство, что $\dim L \leq d - 1$. Но тогда его дополнение до всего пространства $L^\perp$ содержится в K . Следовательно, K содержит линию, что противоречит предположению. ■

Определение C10.3. Выпуклый замкнутый конус $K \subseteq V$ в конечномерном евклидовом пространстве называется *правильным конусом*, если выполнены следующие условия:

1. $\text{int } K \neq \emptyset$;
2. $\forall x \in K : x \in -K \implies x = 0$.

Таким образом, правильный конус имеет непустую внутренность и не содержит в себе прямых. В Примере C9.7 правильными конусами являются только $\emptyset$, $\{0\}$ и луч, выходящий из начала координат.

Теорема C10.1. Пусть $K \subseteq V$ — правильный конус в конечномерном евклидовом пространстве. Тогда сопряжённый ему конус K^* также правильный.

Доказательство. Следует из Утверждений C10.1, C10.2, C10.3. ■

Как и в случае сопряжения по Фенхелю, для конусов интуитивно понятно определяется второе сопряжение.

Определение С10.4. Пусть $K \subseteq V$ — конус в конечномерном евклидовом пространстве. Вторым сопряжённым конусом к K называется множество

$$K^{**} = \{ x \in V \mid \langle x, y \rangle \geq 0, \forall y \in K^* \}.$$

Отметим, что второй сопряжённый конус K^{**} не всегда совпадает с K . Однако это свойство все же удастся гарантировать для большинства встречаемых в приложениях конусов.

Утверждение С10.4. Пусть $K \subseteq V$ — выпуклый замкнутый конус в конечномерном евклидовом пространстве. Тогда $K^{**} = K$.

Доказательство. Докажем $K \subseteq K^{**}$. Зафиксируем $x \in K$. По определению сопряжённого конуса имеем $\langle y, x \rangle \geq 0$ для любого $y \in K^*$. Таким образом, $K \subseteq K^{**}$. Чтобы доказать обратное вложение, предположим, что нашелся такой $\hat{x} \in K$, что $\hat{x} \notin K^{**}$. Поскольку K — выпуклое замкнутое множество, от него можно отделить точку (Теорема С3.7). Формально, существует такое, не равное нулю $\lambda \in V$, что

$$\langle \lambda, x \rangle < \langle \lambda, \hat{x} \rangle, \forall x \in K.$$

Поскольку K — конус, то

$$\forall \alpha \geq 0 \rightarrow \alpha x \in K.$$

Это означает, что

$$\langle \lambda, \alpha \hat{x} \rangle = \alpha \langle \lambda, \hat{x} \rangle \geq \langle \lambda, x \rangle.$$

Поскольку скалярное произведение этих векторов не обязано быть не отрицательным, то можем устремить α к бесконечности и сделать вывод, что $\langle \lambda, \hat{x} \rangle \geq 0$. Таким образом, $\lambda \in K^*$. Рассмотрим теперь $z \in K^{**}$. По определению имеем $\langle z, \lambda \rangle \geq 0$. Вернемся к теореме отделимости. Мы установили, что

$$\langle \lambda, x \rangle < \langle \lambda, \hat{x} \rangle, \forall x \in K.$$

Так как λ можно устремить к нулю, то $\langle \lambda, x \rangle \leq 0$. А ранее мы показали, что $K \subseteq K^{**}$. Поэтому приходим к противоречию, а значит $K^{**} \subseteq K$. ■

Утверждение С10.4 помогает построить критерий самосопряжённости замкнутого выпуклого конуса.

Теорема С10.2. Пусть $K \subseteq V$ — замкнутый выпуклый конус в конечномерном евклидовом пространстве. Он является самосопряжённым тогда и только тогда, когда

$$\forall x \in V \exists! x_+, x_- \in K : x = x_+ - x_-, \langle x_+, x_- \rangle = 0.$$

Доказательство. $\Rightarrow$ Зафиксируем вектор $x \in V$ и его евклидову проекцию x_+ на конус. Понятно, что в конечномерном вещественном случае элемент, минимизирующий расстояние между точкой и выпуклым замкнутым множеством единственный. Более того, угол между направлением от проекции к исходной точке и направлением от проекции к любой точке множества тупой. Формализуем это в виде неравенства

$$\langle x - x_+, y - x_+ \rangle \leq 0, \forall y \in K. \quad (\text{С10.1})$$

Из определения конуса следует, что точки $y = 0$ и $y = 2x_+$ также содержатся в конусе. Подставляя их в скалярное произведение, получим

$$\langle x - x_+, -x_+ \rangle \leq 0, \quad \langle x - x_+, x_+ \rangle \leq 0,$$

откуда следует

$$\langle x - x_+, x_+ \rangle = 0.$$

Обозначив $x_- = x_+ - x$, получаем ортогональность x_+ и x_- . Подставим это уравнение в (C10.1) и получим

$$\langle x - x_+, y \rangle \leq 0, \quad \forall y \in K.$$

Но тогда по определению сопряжённого конуса имеем $x_+ - x \in K^*$.

Докажем теперь единственность разложения. Пусть нашлась еще одна пара $z_+, z_- \in K$, такая, что $x = z_+ - z_-$ и $\langle z_+, z_- \rangle = 0$. Тогда для вектора $d = x_+ - z_+ = x_- - z_-$ имеем

$$\|d\|_2^2 = \langle x_+, x_- \rangle + \langle z_+, z_- \rangle - \langle x_+, z_- \rangle - \langle z_+, x_- \rangle.$$

Из условия ортогональности первые два скалярных произведения равны нулю. При этом последние два неотрицательны, поскольку векторы принадлежат самосопряжённому конусу. Таким образом, имеем

$$\|d\|_2^2 \leq 0 \implies d = 0.$$

Следовательно, имеем $x_+ = z_+$ и $x_- = z_-$ — разложение единственно.

⊕ Выберем точку $x \in K^*$ такую, что $x \notin K$. По условию существует единственное разложение в векторы из конуса x_+, x_- . Тогда имеем

$$0 \leq \langle x_-, x \rangle = \langle x_-, x_+ - x_- \rangle = -\|x_-\|_2^2.$$

Таким образом $x_- = 0$ и $x = x_+ \in K$. Получили противоречие. Следовательно, выполнено вложение $K \subseteq K^*$. Докажем обратное вложение. Выберем $x \in K$ такой, что $x \notin K^*$. Пусть y — проекция x на сопряжённый конус. Тогда, пользуясь свойствами проекции как в первом пункте, получаем $y - x \in K^{**}$, что в совокупности с Утверждением C10.4 гарантирует принадлежность этого вектора конусу K . Поскольку $x \in K$ по предположению, а $y - x \in K$ по доказанному выше, имеем разложение вектора x : $x = y - (y - x)$. Покажем, что такое разложение удовлетворяет всем условиям из формулировки теоремы.

- По построению имеем $y \in K^*$, поскольку это проекция на сопряжённый конус. Но ранее мы уже показали $K^* \subseteq K$. Таким образом, $y \in K$.
- $y - x \in K$ согласно доказанному выше.
- $\langle y - x, x \rangle = 0$, по свойству проекции, полученном в доказательстве необходимого условия.

Таким образом, действительно построили корректное разложение. Однако поскольку $x \in K$, он имеет очевидное разложение $x = x - 0$. Таким образом, имеем

$$y = x, \quad y - x = 0,$$

то есть $x \in K^*$, но это противоречит нашему предположению. ■

С10.3 Обобщенные неравенства

В этом разделе и далее мы будем работать с правильными конусами. Перед тем, как перейти к общей теории задач с коническими ограничениями, надо научиться записывать принадлежность конусу в удобном виде. Определим необходимые термины. Заметим, что правильный конус задает на евклидовом пространстве V частичный порядок.

Определение С10.5. Пусть K — правильный конус. Элемент $x \in V$ *нестрого обобщенно меньше* элемента $y \in V$ ($x \preceq_K y$), если

$$y - x \in K.$$

Определение С10.6. Пусть K — правильный конус. Элемент $x \in V$ *строго обобщенно меньше* элемента $y \in V$ ($x \prec_K y$), если

$$y - x \in \text{int } K.$$

Пример С10.8. $\mathbb{R}_+^d$, очевидно, является правильным конусом. Порядок $\preceq_{\mathbb{R}_+^d}$ есть покомпонентное сравнение элементов. Действительно, имеем

$$x \preceq_{\mathbb{R}_+^d} y \iff y - x \in \mathbb{R}_+^d \iff x \preceq y.$$

Аналогично для правильного конуса $\mathbb{R}_+^d$.

Пример С10.9. $\mathbb{S}_+^d$ является правильным конусом. Обобщенное неравенство $X \preceq_{\mathbb{S}_+^d} Y$ означает, что $Y - X$ есть симметричная и положительно полуопределенная матрица.

Замечание С10.3. Правильный конус K не всегда задает полный порядок. Действительно, рассмотрим элементы $x = (0, 1)^\top$, $y = (1, 0)^\top$. С одной стороны, имеем $x - y = (-1, 1)^\top$. С другой стороны, $y - x = (1, -1)^\top$. Таким образом, выбранные элементы x, y несравнимы по отношению $\preceq_{\mathbb{R}_+^2}$.

Обобщенные неравенства тесно связаны с теорией двойственных конусов. В частности, можно удобно переформулировать Определения С10.5, С10.6.

Утверждение С10.5. Пусть K — правильный конус. Тогда выполнено

$$x \preceq_K y \iff \langle \lambda, x \rangle \leq \langle \lambda, y \rangle, \forall \lambda \succeq_{K^*} 0.$$

Доказательство. $\Rightarrow$ Пусть $y - x \in K$. Зафиксируем $\lambda \succeq_{K^*} 0$, то есть $\lambda \in K^*$. Тогда по определению имеем

$$\langle \lambda, y - x \rangle \geq 0 \iff \langle \lambda, x \rangle \leq \langle \lambda, y \rangle.$$

$\Leftarrow$ Пусть для любого $\lambda \in K^*$ выполнено $\langle \lambda, x \rangle \leq \langle \lambda, y \rangle$, но при этом $y - x \notin K$. Выпуклость и замкнутость правильного конуса позволяют отделить от него точку (Теорема С3.7):

$$\exists \hat{\lambda} \neq 0 : \langle \hat{\lambda}, y - x \rangle < \langle \hat{\lambda}, z \rangle, \forall z \in K.$$

Поскольку точка остается в конусе при умножении на любое неотрицательное α , то

$$\langle \hat{\lambda}, \alpha z \rangle = \alpha \langle \hat{\lambda}, z \rangle > \langle \hat{\lambda}, y - x \rangle,$$

откуда при стремлении α к бесконечности следует $\langle \hat{\lambda}, z \rangle \geq 0$. Более того, из

$$\langle \hat{\lambda}, z \rangle \geq 0, \quad \forall z \in K$$

следует, что $\hat{\lambda} \in K^*$. Таким образом, построили $\hat{\lambda}$ из сопряжённого конуса такой, что

$$\langle \hat{\lambda}, y - x \rangle < 0,$$

что противоречит предположению. Таким образом, доказали утверждение. ■

Утверждение С10.6. Пусть K — правильный конус. Тогда выполнено

$$x \prec_K y \iff \langle \lambda, x \rangle \leq \langle \lambda, y \rangle, \quad \forall \lambda \succeq_{K^*} 0, \quad \lambda \neq 0.$$

Доказательство. $\Rightarrow$ Пусть $y - x \in \text{int } K$. Зафиксируем $\lambda \in K \setminus \{0\}$. Пользуясь определением внутренней, запишем

$$\exists \varepsilon > 0 : y - x - \varepsilon \frac{\lambda}{\|\lambda\|} \in K.$$

Но тогда по определению сопряжённого конуса имеем

$$\left\langle \lambda, y - x - \varepsilon \frac{\lambda}{\|\lambda\|} \right\rangle \geq 0 \iff \langle \lambda, y - x \rangle \geq \varepsilon \|\lambda\| > 0.$$

Таким образом, необходимость доказана.

$\Leftarrow$ Пусть для любого $\lambda \in K^* \setminus \{0\}$ выполнено

$$\langle \lambda, y - x \rangle > 0.$$

Пусть при этом $y - x \notin K$. Тогда существует $\hat{\lambda} \neq 0$, для которого выполнено

$$\langle \hat{\lambda}, y - x \rangle \leq 0.$$

Получили противоречие. Таким образом, доказали достаточность. ■

Пример С10.10. Пусть $K \subseteq \mathbb{R}^d$ — правильный конус. По аналогии с Примером С3.16, получите критерий неразрешимости для системы обобщенных неравенств:

$$Ax \prec_K b.$$

Решение. Пусть система неразрешима. Это означает, что аффинное множество

$$M = \left\{ b - Ax \mid x \in \mathbb{R}^d \right\}$$

не имеет пересечений с открытым выпуклым множеством $\text{int } K$. Тогда существует $\lambda \neq 0$ такое, что

$$\lambda^\top (b - Ax) \leq \lambda^\top z, \quad \forall z \in \text{int } K.$$

Поскольку для любого $\alpha \geq 0$ имеем $\alpha z \in K$, то

$$\langle \lambda, z \rangle \geq 0, \quad \forall z \in K$$

означает, что $\lambda \in K^*$. При этом:

$$\lambda^\top A = 0, \quad \lambda^\top b \leq 0.$$

Докажем обратное следствие. Пусть выполнены полученные условия, и при этом система обобщенных неравенств разрешима. Тогда, поскольку

$$Ax - b \prec_K 0 \preceq_{K^* \setminus \{0\}} \lambda,$$

имеем

$$\lambda^\top (b - Ax) > 0.$$

Но используя $\lambda^\top A = 0$ получаем

$$\lambda^\top b > 0,$$

что противоречит одному из условий. Таким образом, получили критерий неразрешимости системы обобщенных неравенств. ■

C10.4 Обобщенная монотонность

Обобщенные неравенства позволяют расширить объекты, которые ранее вводились только для функции одной переменной, на многомерный случай. Например, можно ввести обобщенную монотонность.

Определение C10.7. Пусть K — правильный конус. Функция $f : V \rightarrow \overline{\mathbb{R}}$ называется K -неубывающей, если для любых $x, y \in V$ выполнено

$$x \preceq_K y \implies f(x) \leq f(y).$$

Определение C10.8. Пусть K — правильный конус. Функция $f : V \rightarrow \overline{\mathbb{R}}$ называется K -возрастающей, если для любых $x, y \in V$ выполнено

$$x \preceq_K y, \quad x \neq y \implies f(x) < f(y).$$

Пример C10.11. Определите, при каких $W \in \mathbb{S}^d$ функция $f : \mathbb{S}^d \rightarrow \mathbb{R}$:

$$f(X) = \text{Tr}(WX)$$

является $\mathbb{S}_+^d$ -неубывающей/возрастающей.

Решение. Рассмотрим $X, Y \in \mathbb{S}^d$ такие, что $Y - X \in \mathbb{S}_+^d$. Рассмотрим разность функций:

$$f(Y) - f(X) = \text{Tr}(W(Y - X)).$$

Поскольку $Y - X \in \mathbb{S}_+^d$, то для нее существует базис $\{v_i\}_{i=1}^d$ из собственных векторов,

соответствующих собственным числам $\{\lambda_i\}_{i=1}^d$. Тогда существует разложение

$$Y - X = \sum_{i=1}^d \lambda_i v_i v_i^\top, \quad \lambda_i \geq 0.$$

Подставим его в разность функций. Запишем

$$f(Y) - f(X) = \text{Tr} \left(W \sum_{i=1}^d \lambda_i v_i v_i^\top \right) = \sum_{i=1}^d \lambda_i v_i^\top W v_i.$$

Чтобы функция была $\mathbb{S}_+^d$ -неубывающей, необходимо, чтобы выполнялось

$$f(Y) - f(X) \geq 0.$$

Чтобы это условие всегда выполнялось, достаточно потребовать $W \succeq 0$. Перейдем к проверке возрастания. Обратим внимание, что все $\lambda_i(Y - X)$ не могут быть одновременно равны нулю, поскольку матрицы не совпадают. Таким образом, достаточно потребовать $W \succ 0$. ■

Пример C10.12. Покажите, что функция $f : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$f(x) = \det(X)$$

$\mathbb{S}_+^d$ -возрастающая на множестве $\mathbb{S}_{++}^d$.

Решение. Рассмотрим матрицы $X, Y \in \mathbb{S}_{++}^d$ такие, что $Y - X \in \mathbb{S}_+^d$. Чтобы расписать разность детерминантов, введем матрицу $L \in \mathbb{S}_+^d$ такую, что

$$Y - X = L.$$

Воспользовавшись извлечением корня из положительно определенной матрицы, запишем

$$\begin{aligned} \det(Y) &= \det(X + L) = \det \left(X^{\frac{1}{2}} X^{\frac{1}{2}} + L \right) = \det \left(X^{\frac{1}{2}} \left(I_d + X^{-\frac{1}{2}} L X^{-\frac{1}{2}} \right) X^{\frac{1}{2}} \right) \\ &= \det(X) \det \left(I_d + X^{-\frac{1}{2}} L X^{-\frac{1}{2}} \right). \end{aligned}$$

Собственные числа матрицы $I_d + X^{-\frac{1}{2}} L X^{-\frac{1}{2}}$ выражаются по правилу

$$\lambda_i \left(I_d + X^{-\frac{1}{2}} L X^{-\frac{1}{2}} \right) = 1 + \lambda_i \left(X^{-\frac{1}{2}} L X^{-\frac{1}{2}} \right).$$

Кроме того:

$$\det(Y) = \det(X) \prod_{i=1}^d \left(1 + \lambda_i \left(X^{-\frac{1}{2}} L X^{-\frac{1}{2}} \right) \right).$$

Обратим внимание, что матрица $X^{-\frac{1}{2}} L X^{-\frac{1}{2}}$ положительно полуопределена. Кроме того, она ненулевая, а значит, найдется индекс $i = \overline{1, d}$, для которого выполнено

$$\lambda_i \left(X^{-\frac{1}{2}} L X^{-\frac{1}{2}} \right) > 0.$$

Следовательно, имеем $f(Y) > f(X)$. Таким образом, детерминант матрицы $\mathbb{S}_{++}^d$ -возрастающая функция на множестве $\mathbb{S}_{++}^d$. ■

Как и для функций одной переменной, существуют дифференциальные условия K -монотонности.

Утверждение C10.7. Пусть $f : V \rightarrow \bar{\mathbb{R}}$ — дифференцируемая функция, а $\text{dom } f$ — выпуклое множество. Функция является K -неубывающей тогда и только тогда, когда

$$\nabla f(x) \succeq_{K^*} 0, \quad \forall x \in \text{dom } f. \quad (\text{C10.2})$$

Доказательство. $\Rightarrow$ Пусть f — K -неубывающая, но не удовлетворяет условию (C10.2) в некоторой точке $x \in \text{dom } f$. Тогда

$$\exists y \in K : \langle \nabla f(x), y \rangle < 0.$$

Рассмотрим $g(t) = f(x + ty)$. Из рассуждения выше имеем

$$g'(0) = \langle \nabla f(x), y \rangle < 0,$$

откуда следует существование $\hat{t}$, такого, что

$$g(\hat{t}) < g(0).$$

Таким образом, f не является K -неубывающей, что противоречит предположению.

$\Leftarrow$ Пусть f удовлетворяет (C10.2), но не является K -неубывающей, то есть существуют такие $x, y \in \text{dom } f$, что $x \preceq_{K^*} y$, но $f(x) > f(y)$. Следовательно, в силу непрерывности функции существует такое $t < 0$, что

$$\frac{d}{dt} f(x + t(y - x)) = \langle \nabla f(x + t(y - x)), y - x \rangle < 0.$$

Поскольку $y \preceq_K x$, то по определению сопряжённого конуса имеем

$$\nabla f(x + t(y - x)) \notin K^*,$$

что противоречит предположению. ■

Утверждение C10.8. Пусть $f : V \rightarrow \bar{\mathbb{R}}$ — дифференцируемая функция, а $\text{dom } f$ — выпуклое множество. Функция является K -возрастающей, если

$$\nabla f(x) \succ_{K^*} 0, \quad \forall x \in \text{dom } f.$$

Доказательство. Доказывается аналогично Утверждению C10.7. ■

Пример C10.13. Пользуясь дифференциальным условием, докажите, что функция $f : \mathbb{S}_{++}^d \rightarrow \mathbb{R}$:

$$f(X) = \det(X)$$

является $\mathbb{S}_{++}^d$ -возрастающей на множестве $\mathbb{S}_{++}^d$.

Решение. Обратим внимание, что $(\mathbb{S}_+^d)^* = \mathbb{S}_+^d$. Также в Примере C3.9 мы показывали, что $\mathbb{S}_{++}^d = \text{int } \mathbb{S}_+^d$, то есть

$$\nabla f(X) \succ_{\mathbb{S}_+^d} 0 \implies \nabla f(X) \succeq_{\mathbb{S}_{++}^d} 0,$$

то есть градиент должен быть положительно определенной матрицей. Запишем градиент функции:

$$\nabla f(X) = (\det X)X^{-1}.$$

Поскольку $X \in \mathbb{S}_{++}^d$, то и $X^{-1} \in \mathbb{S}_{++}^d$. Таким образом, имеем

$$\nabla f(X) \succ_{\mathbb{S}_{++}^d} 0.$$

Следовательно, f — $\mathbb{S}_{++}^d$ -возрастающая функция на множестве $\mathbb{S}_{++}^d$. ■

C10.5 Обобщенная выпуклость

Ранее мы вводили понятие выпуклости только для функций, выдающих скалярные значения. Оказывается, что теория конусов позволяет обобщить выпуклость на отображения с образом в произвольное конечномерное евклидово пространство.

Определение C10.9. Пусть V, U — конечномерные евклидовы пространства. Пусть $K \subseteq U$ — правильный конус. Функция $f : V \rightarrow U$ называется K -выпуклой, если для любых $x, y \in V$ и любого $\alpha \in [0, 1]$ выполняется:

$$f(\alpha x + (1 - \alpha)y) \preceq_K \alpha f(x) + (1 - \alpha)f(y).$$

Пример C10.14. Проверьте функцию $f : \mathbb{S}^d \rightarrow \mathbb{S}^d$:

$$f(X) = X^2$$

на $\mathbb{S}_{++}^d$ -выпуклость.

Решение. Зафиксируем $X, Y \in \mathbb{S}^d$ и $\alpha \in [0, 1]$. Раскроем квадрат, учитывая некоммутативность матриц:

$$(\alpha X + (1 - \alpha)Y)^2 = \alpha^2 X^2 + (1 - \alpha)^2 Y^2 + \alpha(1 - \alpha)(XY + YX).$$

Запишем условие $\mathbb{S}_{++}^d$ -выпуклости:

$$\begin{aligned} \alpha X^2 + (1 - \alpha)Y^2 - (\alpha X + (1 - \alpha)Y)^2 &= \alpha(1 - \alpha)(X^2 + Y^2 - XY - YX) \\ &= \alpha(1 - \alpha)(Y - X)^2. \end{aligned}$$

Поскольку $X, Y \in \mathbb{S}^d$, то и $Y - X \in \mathbb{S}^d$. Следовательно, $(Y - X)^2 \succeq 0$. Таким образом, имеем

$$\alpha X^2 + (1 - \alpha)Y^2 - (\alpha X + (1 - \alpha)Y)^2 \succeq 0.$$

Следовательно, функция является $\mathbb{S}_{++}^d$ -выпуклой по определению. ■

Замечание C10.4. Хорошим способом проверки K -выпуклости функции $f : V \rightarrow U$ является проверка выпуклости в классическом смысле ее скаляризации

$$g_y(x) = \langle y, f(x) \rangle, \quad \forall y \in K^*.$$

В контексте предыдущего примера имеем $y = \sum_{i=1}^n z_i z_i^\top$, где $z_i \in \mathbb{R}^d$, а n пробегает всевозможные натуральные значения. Поскольку сумма выпуклых функций выпукла,

будет достаточно показать выпуклость функции

$$g_z(X) = \langle zz^\top, X^2 \rangle = \text{Tr}(zz^\top X^2) = \text{Tr}(z^\top X^2 z) = \|Xz\|_2^2.$$

Нетрудно заметить, что g_z выпукла по X как композиция выпуклой функции и аффинного отображения.

Докажем утверждение из замечания.

Утверждение C10.9. Функция $f : V \rightarrow U$ является K -выпуклой тогда и только тогда, когда

$$g_z(x) = \langle z, f(x) \rangle, \forall z \in K^*$$

является выпуклой по x .

Доказательство. $\Rightarrow$ Пусть f является K -выпуклой. Тогда для любых $x, y \in V$, $\alpha \in [0, 1]$ имеем

$$\alpha f(x) + (1 - \alpha)f(y) - f(\alpha x + (1 - \alpha)y) \in K.$$

По определению сопряжённого конуса выполнено

$$\langle z, \alpha f(x) + (1 - \alpha)f(y) - f(\alpha x + (1 - \alpha)y) \rangle \geq 0,$$

то есть g_z выпукла по x в классическом смысле.

$\Leftarrow$ Пусть для всех $z \in K^*$ выполнено

$$\langle z, \alpha f(x) + (1 - \alpha)f(y) - f(\alpha x + (1 - \alpha)y) \rangle \geq 0.$$

Таким образом, имеем $\alpha f(x) + (1 - \alpha)f(y) - f(\alpha x + (1 - \alpha)y) \in K^{**}$. Так как K — правильный конус, то $K^{**} = K$. Следовательно, f является K -выпуклой. ■

Теперь, когда введено обобщение монотонности и выпуклости, можно доказать обобщенный аналог теоремы о выпуклой композиции.

Теорема C10.3. Пусть $K \subseteq U$ — правильный конус, $h : V \rightarrow U$ — K -выпуклое отображение, $g : U \rightarrow \mathbb{R}$ — выпуклая K -неубывающая функция. Тогда их композиция $f(x) = g(h(x))$ также выпуклая функция.

Доказательство. Рассмотрим произвольные $x, y \in V$, $\alpha \in [0, 1]$. Тогда из K -выпуклости отображения h имеем

$$h(\alpha x + (1 - \alpha)y) \preceq_K \alpha h(x) + (1 - \alpha)h(y).$$

Поскольку g K -неубывающая, можно утверждать

$$g(h(\alpha x + (1 - \alpha)y)) \leq g(\alpha h(x) + (1 - \alpha)h(y)).$$

Далее воспользуемся выпуклостью g и получим

$$g(h(\alpha x + (1 - \alpha)y)) \leq \alpha g(h(x)) + (1 - \alpha)g(h(y)).$$

Таким образом, f — выпуклая функция. ■

Пример C10.15. Покажите, что функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \text{Tr}(Wxx^\top), \quad W \succeq 0$$

является выпуклой в классическом смысле.

Решение. Отметим, что есть два подхода. Классический заключается в вычислении гессиана отображения и последующей проверке на положительную полуопределенность. Вместо этого можно ввести отображения $h(x) = xx^\top$ и $g(X) = \text{Tr}(WX)$ и рассмотреть f как их композицию:

$$f(x) = g(h(x)).$$

Отображение h , очевидно, $\mathbb{S}_+^d$ -выпуклое, поскольку для любого $z \in \mathbb{R}^d$ имеем

$$h_z(x) = z^\top xx^\top z = (z^\top x)^2.$$

То есть скаляризация функции h выпукла как композиция выпуклой функции и аффинного отображения, что влечет $\mathbb{S}_+^d$ -выпуклость h . Отображение g является $\mathbb{S}_+^d$ -неубывающим (Пример C10.11) и выпуклым в классическом смысле в силу линейности следа и линейного отображения. Применяя Теорему C10.3 о выпуклой композиции, получаем, что f — выпуклая функция. ■

C10.6 Задача конической оптимизации в общем виде

Теперь, когда построена вся вспомогательная теория, перейдем к обсуждению задач с коническими ограничениями в общем виде. Начнем с формальной постановки.

Определение C10.10. Задача оптимизации в общем виде с коническими ограничениями записывается как

$$\begin{aligned} \min_{x \in V} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \preceq_{K_i} 0, \quad i = \overline{1, n} \\ & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned}$$

Здесь $\{K_i\}_{i=1}^n$ — набор правильных конусов.

Поймем, как строить двойственную задачу в случае конических ограничений. Двойственная функция Лагранжа этой задачи имеет вид

$$g(\lambda, \nu) = \inf_{x \in V} \left(f_0(x) + \sum_{i=1}^n \langle \lambda_i, f_i(x) \rangle + \sum_{j=1}^m \nu_j h_j(x) \right).$$

Чтобы выполнялась слабая двойственность, нужно потребовать

$$\lambda_i \succeq_{K_i^*} 0.$$

Действительно, в таком случае имеем

$$\langle \lambda_i, f_i(x) \rangle \leq 0.$$

Двойственная задача имеет вид

$$\begin{aligned} \max_{\substack{\lambda \in K_i^* \\ \nu \in \mathbb{R}^m}} \quad & g(\lambda, \nu) \\ \text{s.t.} \quad & \lambda_i \succeq_{K_i^*} 0. \end{aligned}$$

Чтобы гарантировать сильную двойственность, существуют *обобщенные условия Слейтера*.

Утверждение C10.10. Рассмотрим задачу следующего вида:

$$\begin{aligned} \min_{x \in V} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \preceq_{K_i} 0, \quad i = \overline{1, n} \\ & Ax = b. \end{aligned}$$

Пусть f_0 — выпуклая функция, $\{f_i\}_{i=1}^n$ — K_i -выпуклые функции. Если существует такой $\bar{x} \in \text{relint} \bigcap_{i=1}^n \text{dom } f_i$, что

$$f_i(\bar{x}) \prec_{K_i} 0, \quad i = \overline{1, n}, \quad A\bar{x} = b,$$

то выполняется сильная двойственность.

Построение двойственной задачи позволяет упростить проверку принадлежности точки конусу. Например, для задачи SDP нужно проверять на положительную полуопределенность двойственную переменную, а не линейную комбинацию симметричных матриц с коэффициентами, равными компонентам прямой переменной.

Пример C10.16. Постройте двойственную задачу для задачи SDP:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & P_0 + \sum_{i=1}^d P_i x_i \succeq 0. \end{aligned}$$

где $P_i \in \mathbb{S}^d$, $c \in \mathbb{R}^d$.

Решение. Запишем лагранжиан задачи:

$$\begin{aligned} \mathcal{L}(x, \Lambda) &= c^\top x - \text{Tr} \left(\left(P_0 + \sum_{i=1}^d P_i x_i \right) \Lambda \right) = c^\top x - \text{Tr}(P_0 \Lambda) - \sum_{i=1}^d x_i \text{Tr}(P_i \Lambda) \\ &= -\text{Tr}(P_0 \Lambda) + \sum_{i=1}^d x_i (c_i - \text{Tr}(P_i \Lambda)). \end{aligned}$$

Получили смещение, не зависящее от x , и линейную добавку, которую можно сделать сколько угодно большой по модулю, если только коэффициент не равен нулю. Таким образом, имеем

$$g(\Lambda) = \begin{cases} -\text{Tr}(P_0 \Lambda), & \text{Tr}(P_i \Lambda) = c_i, \quad i = \overline{1, n} \\ -\infty, & \text{иначе} \end{cases}.$$

Тогда двойственная задача имеет вид

$$\begin{aligned} \min_{\Lambda \in \mathbb{S}_+^d} \quad & \text{Tr}(P_0 \Lambda) \\ \text{s.t.} \quad & \text{Tr}(P_i \Lambda) = c_i, \quad i = \overline{1, n} \\ & \Lambda \succeq 0. \end{aligned}$$

■

Замечание C10.5. Заметим, что двойственная задача в Примере C10.16 — это снова задача из класса SDP, но теперь для матричных переменных и с более простыми ограничениями.

Замечание C10.6. Обратим внимание, что в Примере C10.16 мы строго обосновали Замечание C9.5 об эквивалентной формулировке задачи SDP.

Пример C10.17. Постройте двойственную задачу для задачи SOCP:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & \|P_i x - q_i\|_2 \leq e_i^\top x + f_i, \quad i = \overline{1, n}, \end{aligned}$$

где $P_i \in \mathbb{R}^{k_i \times d}$, $q_i \in \mathbb{R}^{k_i}$, $e_i \in \mathbb{R}^d$, $f_i \in \mathbb{R}$, $c \in \mathbb{R}^d$.

Решение. Обозначим конус Лоренца (Пример C10.2) размерности $k+1$ как K_L^k . Тогда ограничения переписутся в виде

$$(P_i x - q_i, e_i^\top x + f_i) \in K_L^{k_i}.$$

Конус Лоренца правильный по определению. Более того, из Примера C10.2 видно, что в евклидовой норме он самосопряжённый. Построим лагранжиан задачи. Он имеет вид

$$\begin{aligned} \mathcal{L}(x, \lambda) &= c^\top x - \sum_{i=1}^n \langle \lambda_i, (P_i x - q_i, e_i^\top x + f_i) \rangle \\ &= \sum_{i=1}^n (q_i^\top z_i - f_i t_i) + \left\langle c - \sum_{i=1}^n P_i^\top z_i + \sum_{i=1}^n t_i e_i, x \right\rangle, \end{aligned}$$

где мы обозначили $\lambda_i = (z_i, t_i) \in \mathbb{R}^{k_i} \times \mathbb{R}$. Тогда двойственная функция Лагранжа записывается как

$$g(\lambda) = \begin{cases} \sum_{i=1}^n (q_i^\top z_i - f_i t_i), & c - \sum_{i=1}^n P_i^\top z_i + \sum_{i=1}^n t_i e_i = 0 \\ -\infty, & \text{иначе.} \end{cases}$$

Тогда двойственная задача имеет вид

$$\begin{aligned} \min_{\lambda_i \in \mathbb{R}^{k_i} \times \mathbb{R}} \quad & - \sum_{i=1}^n (q_i^\top z_i - f_i t_i) \\ \text{s.t.} \quad & \sum_{i=1}^n P_i^\top z_i - \sum_{i=1}^n t_i e_i = c, \quad i = \overline{1, n} \\ & \lambda_i \in K_L^{k_i}, \quad i = \overline{1, n}. \end{aligned}$$

■

Замечание C10.7. Заметим, что двойственная задача в Примере C10.17 — это снова задача из класса SOCP, но теперь с более простыми ограничениями.

C10.7 Материал, который не вошел в параграф

Параграф был посвящен применению теории сильной двойственности для получения эквивалентных формулировок задач с более простой проверкой ограничений. Однако это далеко не единственное приложение конусов и сопряжённых конусов. Например, можно пойти дальше и построить обобщение условий ККТ для задач с коническими ограничениями. Кроме того, конусы критически важны в задачах бесконечномерной оптимизации. В частности, условия оптимальности функции в бесконечномерном банаховом пространстве формулируются через принадлежность к конусу особого вида. Таким образом, выпуклые конусы — один из важнейших классов выпуклых множеств, исследованию которого можно было бы посвятить еще не одну главу книги.

С11 Симплекс–метод

В Параграфе С9 мы обзорно рассмотрели различные классы оптимизационных задач. Текущий же параграф посвящён задаче линейного программирования, которая обрела популярность начиная с работы Л.В. Канторовича [43], поскольку оказалась тесно связана с моделированием задач экономики, в частности планирования. Мы рассмотрим более современный вариант симплекс–метода, чем тот, который был предложен в оригинальной работе.

Ранее мы показали (Утверждение С9.1), что общая, стандартная и каноническая формы записи задачи линейного программирования эквивалентны. В дополнение к ним мы также будем рассматривать *базовую форму*.

Определение С11.1. Задача линейного программирования записана в *базовой форме*, если она имеет вид

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & Gx \preceq h, \end{aligned}$$

где $c \in \mathbb{R}^d$, $h \in \mathbb{R}^m$, $G = \begin{pmatrix} g_1^\top \\ \vdots \\ g_m^\top \end{pmatrix} \in \mathbb{R}^{m \times d}$.

Линии уровня целевой функции имеют вид гиперплоскостей, а допустимое множество представляет собой выпуклое связное множество с плоскими многоугольными границами:

$$X = \left\{ x \in \mathbb{R}^d \mid g_i^\top x \leq h_i, \ i = \overline{1, m} \right\}.$$

В данном параграфе будет рассматриваться случай, когда множество X ограничено и непусто, то есть когда X — многогранник. В таком случае решение задачи находится в вершине, а в вырожденном случае — на всей грани.




Рис. С11.1: Допустимое множество (штриховка) и ограничивающие прямые. Уровни $c^\top x$ параллельны штрихам.

Введём вспомогательные определения.

Определение С11.2. Ограничения называются *линейно независимыми*, если множество соответствующих векторов $\{g_j\}$ линейно независимо.

Определение С11.3. Ограничение называется *активным* в точке x , если ограничение превращается в равенство.

Симплекс–метод, которому посвящён параграф, завершает работу в *угловой точке* множества допустимых точек.

Определение С11.4. *Угловой точкой* называется точка, лежащая на границе максимального числа линейно независимых ограничений.

Таким образом, важно сформировать понимание, как геометрически устроена угловая точка.

Утверждение С11.1. $\tilde{x} \in \mathbb{R}^d$ — угловая точка ограниченного множества X тогда и только тогда, когда она лежит на границе d линейно независимых ограничений.

Доказательство. $\Rightarrow$ Пусть $\tilde{x}$ — угловая точка. Составим матрицу $\tilde{G} \in \mathbb{R}^{k \times d}$ из $k < d$ линейно независимых активных ограничений g_i . Тогда уравнение $\tilde{G}x = 0$ имеет ненулевое решение $\hat{x} \in \mathbb{R}^d$. Рассмотрим ограничение g_j , линейно независимое с ограничениями из матрицы $\tilde{G}$, на котором точка $\tilde{x}$ не лежит на границе ограничения: $g_j^\top \tilde{x} < h_j$. Для вектора $x = \tilde{x} + \lambda \hat{x}$:

$$\exists \tilde{\lambda} : g_j^\top (\tilde{x} + \tilde{\lambda} \hat{x}) = g_j^\top \tilde{x} + \tilde{\lambda} g_j^\top \hat{x} = h_j.$$

Заметим, что $g_j^\top \hat{x} \neq 0$, так как в противном случае множество было бы не ограничено. Таким образом, мы нашли точку, которая лежит на границе $k + 1$ ограничения. Случай $k > d$ невозможен, так как количество линейно независимых векторов не может превышать размерность пространства.

$\Leftarrow$ Пусть точка $\tilde{x}$ лежит на границе ровно d линейно независимых ограничений и при этом не является угловой. Она является угловой, так как количество линейно независимых векторов не может превышать размерность пространства, поэтому d — максимальное количество. ■

С11.1 Идея симплекс–метода

В этом разделе представлена интуиция симплекс–метода. Симплекс–метод ищет решение задачи линейного программирования, перебирая вершины многогранника — допустимого множества задачи. Перебор вершин производится направленно, то есть алгоритм проходит по ребрам многогранника, предварительно выбирая на каждой угловой точке ребро, которое больше всего уменьшает значение целевой функции задачи $c^\top x$.

Введём некоторые определения, которые будем активно использовать в данном разделе, в частности, определение базиса.

Определение С11.5. *Базисом, задающим угловую точку B* , называется набор индексов максимального числа линейно независимых активных в этой точке ограничений.

Замечание C11.1. Стоит обратить внимание, что определение является не совсем стандартным, поскольку характеризует множество индексов. Однако данное подмножество целых чисел, например, $B = \{2, 3\}$ порождает невырожденную матрицу $G_B = \begin{pmatrix} g_2^\top \\ g_3^\top \end{pmatrix}$, строки которой можно было бы рассматривать в качестве базиса.




Рис. C11.2: Допустимое множество (штриховка), нормали a_i к ограничениям. Уровни $c^\top x$ параллельны штрихам.

Замечание C11.2. С базисом B можно связать подматрицу G_B , составленную из нормалей базисных ограничений, а также соответствующую ей правую часть h_B . Кроме того, из базиса можно выразить угловую точку:

$$x_B = G_B^{-1} h_B.$$

Замечание C11.3. Векторы ограничений, не входящие в базис, обычно обозначают N , а соответствующую матрицу и правую часть — G_N и h_N .

Определение C11.6. Базис B называется *допустимым*, если полученная угловая точка x_B лежит в допустимом множестве, то есть

$$Gx_B \leq h.$$

На Рисунке C11.2 базисы $\{1, 2\}$, $\{2, 3\}$ — допустимые, а базис $\{1, 4\}$ — недопустимый.

Определение C11.7. Базис B называется *оптимальным*, если полученная угловая точка является решением задачи линейного программирования C11.1, то есть

$$c^\top x_B \leq c^\top x, \forall x \in X.$$

Имея некоторый заданный базис, необходимо иметь способ проверить его оптимальность. В этом помогает следующее утверждение.

Утверждение C11.2. Пусть $\lambda_B = G_B^{-\top} c$ — вектор коэффициентов разложения вектора c по допустимому базису B . Тогда базис B является оптимальным, если

$$\lambda_B \preceq 0.$$

Доказательство. Докажем от противного. Пусть есть такая точка x^* , что $Gx^* \preceq h$ и $c^\top x^* < c^\top x_B$. Тогда из первого неравенства следует, что будет выполняться неравенство для подматрицы G_B и подвектора h_B :

$$G_B x^* \preceq h_B$$

Умножим скалярно на λ_B и получим:

$$\lambda_B^\top G_B x^* \geq \lambda_B^\top h_B \implies c^\top x^* \geq \lambda_B^\top G_B x_B \implies c^\top x^* \geq c^\top x_B.$$

Получили противоречие. ■

Теперь, когда введены все необходимые обозначения и определения, перейдем к главной части этого раздела, а именно к самой идее работы симплекс-метода. Симплекс-метод направленно перебирает угловые точки. Из Определения C11.5 следует, что базис задает угловую точку. Таким образом, симплекс-метод каждую итерацию проверяет оптимальность текущего базиса B , используя Утверждение C11.2. Если базис оптимальный, то угловая точка x_B является решением задачи линейного программирования, однако если текущий базис B не является оптимальным, то алгоритм строит новый базис $\bar{B}$ по следующему правилу:

$$x_{\bar{B}} = x_B + \mu d, \tag{C11.1}$$

где d — направление движения от текущей угловой точки к новой, μ — это шаг, с которым осуществляется переход от старой угловой точки (старого базиса) к новой угловой точке (новому базису).

Если базис B неоптимален, то существует такой индекс p , что $\lambda_p > 0$, тогда симплекс-метод «выкидывает» этот индекс из базиса и идёт вдоль остальных ребер. Данное направление d описывается следующим образом:

$$\begin{cases} G_{B \setminus \{p\}} \cdot d = 0, \\ g_p^\top d = -1. \end{cases} \tag{C11.2}$$

Важно понимать, с каким шагом двигаться, поскольку есть возможность перейти в недопустимый базис. Для того чтобы подобрать шаг μ :

$$x_{\bar{B}} = x_B + \mu d$$

домножим скалярно на $g_i^\top \notin B$ и получим:

$$g_i^\top x_{\bar{B}} = g_i^\top x_B + \mu g_i^\top d \implies \mu_i = \frac{h_i - g_i^\top x_B}{g_i^\top d}. \tag{C11.3}$$

Выберем наименьшее μ_i :

$$\mu = \min_{i: g_i^\top \notin B} \{ \mu_i \mid \mu_i > 0 \}.$$

Теперь, зная все детали замены базиса, можно формально ввести алгоритм симплекс-метода для решения задачи линейного программирования в базовой форме C11.1.

Вход: начальная угловая точка x^0

```

1: while  $B_k$  не оптимален do
2:   Выбрать допустимый базис  $B_k$  по точке  $x^k$ 
3:   Найти  $\lambda_{B_k} = G_{B_k}^{-\top} c$ 
4:   if  $\lambda_{B_k} \preceq 0$  then
5:     Базис  $B_k$  оптимален
6:   else
7:     Обновить точку:  $x^{k+1} = x^k + \mu_k d^k$ 
8:   end if
9: end while
    
```

Замечание C11.4. Обратим внимание, что поиск допустимого базиса зачастую является нетривиальным и в общем случае будет обсуждён ниже. Направление d^k ищется путём решения системы уравнений (C11.2), шаг μ_k выбирается наименьшим из возможных вариантов (C11.3).

C11.2 Примеры

Чтобы отработать идею, рассмотрим сначала простой пример двумерной задачи с тремя ограничениями.

Пример C11.1. Пусть задача линейного программирования задана в базовой форме (C11.1) с матрицами

$$c = \begin{pmatrix} -10 \\ -12 \end{pmatrix}, \quad G = \begin{pmatrix} 1 & 2 \\ -1 & 1 \\ -1 & -10 \end{pmatrix}, \quad h = \begin{pmatrix} 6 \\ 0 \\ 10 \end{pmatrix}.$$

Найдите оптимальное значение, используя

$$x^0 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$$

в качестве начального приближения.

Решение. Начальное приближение задано базисом $B_0 = \{1, 2\}$. Запишем соответствующую матрицу G_{B_0} :

$$G_{B_0} = \begin{pmatrix} 1 & 2 \\ -1 & 1 \end{pmatrix}.$$

Найдём λ_{B_0} :

$$\lambda_{B_0} = G_{B_0}^{-\top} c = \begin{pmatrix} \frac{1}{3} & \frac{1}{3} \\ -\frac{2}{3} & \frac{1}{3} \end{pmatrix} \begin{pmatrix} -10 \\ -12 \end{pmatrix} = \begin{pmatrix} -\frac{22}{3} \\ \frac{8}{3} \end{pmatrix}.$$

Таким образом, $i = 2$ требуется вывести из базиса. Будем идти вдоль направления d^0 , заданного системой уравнений (C11.2):

$$\begin{cases} d_1^0 + 2d_2^0 = 0; \\ -d_1^0 + d_2^0 = -1, \end{cases}$$

имеющей решение $d^0 = \left(\frac{2}{3}, -\frac{1}{3}\right)^\top$. Определим величину шага с помощью (C11.3):

$$\mu_3 = \frac{h_3 - g_3^\top x^0}{g_3^\top d^0} = \frac{10 + 22}{\frac{8}{3}} = 12.$$

Воспользуемся (C11.1) и получим новую точку

$$x^1 = x^0 + \mu_3 d^0 = \begin{pmatrix} 2 \\ 2 \end{pmatrix} + 12 \begin{pmatrix} \frac{2}{3} \\ -\frac{1}{3} \end{pmatrix} = \begin{pmatrix} 10 \\ -2 \end{pmatrix}.$$

Этой точке соответствует базис $B_1 = \{1, 3\}$ с матрицей

$$G_{B_1} = \begin{pmatrix} 1 & 2 \\ -1 & -10 \end{pmatrix}.$$

Вычислив соответствующее разложение, получим

$$\lambda_{B_1} = G_{B_1}^{-\top} c = \begin{pmatrix} \frac{5}{4} & \frac{1}{4} \\ -\frac{1}{8} & -\frac{1}{8} \end{pmatrix} \begin{pmatrix} -10 \\ -12 \end{pmatrix} = \begin{pmatrix} -10 \\ -1 \end{pmatrix}.$$

Таким образом, найдены оптимальный базис и искомая точка минимума. ■

Пример C11.2. Пусть задача линейного программирования задана в базовой форме (C11.1) с матрицами

$$c = \begin{pmatrix} -5 \\ -7 \\ -4 \end{pmatrix}, \quad G = \begin{pmatrix} 1 & 2 & 1 \\ -1 & 1 & 0 \\ 0 & -1 & 2 \\ 2 & 1 & -1 \\ -1 & 0 & -1 \\ 3 & -2 & 1 \end{pmatrix}, \quad h = \begin{pmatrix} 8 \\ 2 \\ 4 \\ 10 \\ 3 \\ 5 \end{pmatrix}.$$

Найдите оптимальное значение, используя

$$x^0 = \begin{pmatrix} \frac{11}{6} \\ \frac{5}{3} \\ \frac{17}{6} \end{pmatrix}$$

в качестве начального приближения.

Решение. Начальное приближение задано базисом $B_0 = \{1, 3, 6\}$. Запишем соответствующую матрицу G_{B_0} :

$$G_{B_0} = \begin{pmatrix} 1 & 2 & 1 \\ 0 & -1 & 2 \\ 3 & -2 & 1 \end{pmatrix}.$$

Найдём λ_{B_0} :

$$\lambda_{B_0} = G_{B_0}^{-\top} c = \begin{pmatrix} \frac{1}{6} & \frac{1}{3} & \frac{1}{6} \\ -\frac{2}{9} & -\frac{1}{9} & \frac{4}{9} \\ \frac{5}{18} & -\frac{1}{9} & -\frac{1}{18} \end{pmatrix} \begin{pmatrix} -5 \\ -7 \\ -4 \end{pmatrix} = \begin{pmatrix} -\frac{23}{6} \\ \frac{1}{9} \\ -\frac{7}{18} \end{pmatrix}.$$

Таким образом, $i = 3$ требуется вывести из базиса. Будем идти вдоль направления d^0 , заданного системой уравнений (C11.2):

$$\begin{cases} d_1^0 + 2d_2^0 + d_3^0 = 0; \\ -d_2^0 + 2d_3^0 = -1; \\ 3d_1^0 - 2d_2^0 + d_3^0 = 0, \end{cases}$$

имеющей решение

$$d^0 = \begin{pmatrix} \frac{2}{9} \\ \frac{1}{9} \\ -\frac{4}{9} \end{pmatrix}.$$

Определим величину шага с помощью (C11.3):

$$\begin{aligned} \mu_2 &= \frac{h_2 - g_2^\top x^0}{g_2^\top d^0} = \frac{2 + \frac{1}{6}}{-\frac{1}{9}} = -\frac{39}{2}, \\ \mu_4 &= \frac{h_4 - g_4^\top x^0}{g_4^\top d^0} = \frac{10 - \frac{5}{2}}{1} = \frac{15}{2}, \\ \mu_5 &= \frac{h_5 - g_5^\top x^0}{g_5^\top d^0} = \frac{3 + \frac{14}{3}}{\frac{2}{9}} = \frac{69}{2}. \end{aligned}$$

Воспользуемся (C11.1) и получим новую точку

$$x^1 = x^0 + \mu_4 d^0 = \begin{pmatrix} \frac{11}{6} \\ \frac{5}{3} \\ \frac{17}{6} \end{pmatrix} + \frac{15}{2} \begin{pmatrix} \frac{2}{9} \\ \frac{1}{9} \\ -\frac{4}{9} \end{pmatrix} = \begin{pmatrix} \frac{7}{2} \\ \frac{5}{2} \\ -\frac{1}{2} \end{pmatrix}.$$

Этой точке соответствует базис $B_1 = \{1, 4, 6\}$ с матрицей

$$G_{B_1} = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & -1 \\ 3 & -2 & 1 \end{pmatrix}.$$

Найдём λ_{B_1} :

$$\lambda_{B_1} = G_{B_1}^{-\top} c = \begin{pmatrix} \frac{1}{18} & \frac{5}{18} & \frac{7}{18} \\ \frac{2}{9} & \frac{1}{9} & -\frac{4}{9} \\ \frac{1}{6} & -\frac{1}{6} & \frac{1}{6} \end{pmatrix} \begin{pmatrix} -5 \\ -7 \\ -4 \end{pmatrix} = \begin{pmatrix} -\frac{34}{9} \\ -\frac{1}{9} \\ -\frac{1}{3} \end{pmatrix}.$$

Таким образом, найдены оптимальный базис и искомая точка минимума. ■

Замечание C11.5. Отметим, что в примерах число итераций, проделанных «вручную», совпадает с числом итераций солвера «linprog» из библиотеки «scipy.optimize».

C11.3 Двухфазный симплекс-метод

Рассмотренные примеры задействуют пространства переменных малых размерностей, что делает поиск допустимого базиса простой задачей. Однако в приложениях приходится иметь дело с сотнями тысяч переменных. Поскольку угловая точка, согласно Утверждению C11.1, обязана быть образована d ограничениями, появляется вопрос о необходимости решения огромных систем линейных уравнений. На практике для

поиска допустимого базиса используются следующие техники.

В Параграфе С9 мы обсуждали, что задачи линейного программирования могут быть эквивалентно сведены друг к другу. Перепишем (С11.5) в стандартной форме:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & x \succeq 0, \end{aligned}$$

где $c \in \mathbb{R}^d$, $b \in \mathbb{R}^n$, $A \in \mathbb{R}^{n \times d}$. Без ограничения общности будем считать, что $b \succeq 0$. Построим вспомогательную задачу:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^d \\ y \in \mathbb{R}^n}} \quad & \mathbf{1}^\top y \\ \text{s.t.} \quad & Ax + y = b \\ & x \succeq 0 \\ & y \succeq 0. \end{aligned}$$

Имеем очевидную начальную угловую точку $(0, b)^\top$. Если допустимое множество исходной задачи было ограниченным и непустым, то найдётся x , который даёт угловую точку исходной задачи.

Замечание С11.6. Сведение к стандартной форме было проделано, чтобы вспомогательная задача имела очевидный допустимый базис. Для случая стандартной формы реализация симплекс-метода описана в Лекции 20.13 в [48].

Л1 Основные понятия

Задачу оптимизации, которая будет рассматриваться в рамках данного пособия, можно сформулировать следующим образом:

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & x \in \mathcal{X} \subseteq \mathbb{R}^d \\ & g_i(x) \leq 0, \quad i = \overline{1, n} \\ & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned} \tag{Л1.1}$$

Получается, что, варьируя вектор x , нам необходимо найти значение f^* — минимум функции f такой, что («s.t.» — «subject to») дополнительно выполнен ряд условий-ограничений. Взглянув на задачу (Л1.1), можно заметить, что с формальной точки зрения нам достаточно найти f^* , что и будет являться решением. Но наряду с f^* часто необходим и вектор x^* , на котором это значение достигается $f^* = f(x^*)$. Получается, что нам скорее интересна не постановка (Л1.1), а постановка вида argmin по поиску x^* . Уже более формально мы определим её в Параграфе Л2. Понятно, что в общем случае уникальность, да и вообще существование x^* и f^* никто не гарантирует (рассмотрите, например, задачу $\min_{x \in \mathbb{R}} x$). Отметим, что задача (Л1.1) имеет общий вид, и мы часто будем её упрощать. Например, можно рассматривать задачу безусловной оптимизации, то есть убрать все ограничения вида равенств и неравенств и положить $\mathcal{X} = \mathbb{R}^d$. Более подробно остановимся на объектах из формулировки (Л1.1):

- $f : \mathcal{X} \rightarrow \mathbb{R}$ — некоторая функция, заданная на множестве $\mathcal{X}$. Данная функция является целевой для задачи оптимизации (Л1.1). Мы будем накладывать дополнительные свойства на f : липшицевость, гладкость, выпуклость. Связано это с тем, что уже в рамках этого параграфа станет понятно, что без предположений на f не получится построить оптимистичную теорию поиска решения (Л1.1).
- $\mathcal{X} \subseteq \mathbb{R}^d$ — подмножество d -мерного пространства. В общем случае $\mathcal{X}$ может быть любым множеством, но часто мы будем предполагать, что $\mathcal{X}$ является «простым» (суть «простоты» в данном случае неоднозначна и будет раскрыта далее, в момент изучения методов оптимизации на «простых» множествах). Например, в качестве $\mathcal{X}$ может выступать шар радиуса R с центром в точке a в p -норме

$$\overline{B}^p(R, a) = \left\{ x \in \mathbb{R}^d \mid \|x - a\|_p \leq R \right\},$$

вероятностный симплекс

$$\triangle_{d-1} = \left\{ x \in \mathbb{R}^d \mid x_i \geq 0, \quad i = \overline{1, d}, \quad \sum_{i=1}^d x_i = 1 \right\}$$

или положительный ортант

$$\perp_d = \left\{ x \in \mathbb{R}^d \mid x_i \geq 0 \right\}.$$

- Также в задаче (Л1.1) присутствуют функциональные ограничения вида неравенств и равенств. $g_i : \mathcal{X} \rightarrow \mathbb{R}$, $i = \overline{1, n}$ и $h_j : \mathcal{X} \rightarrow \mathbb{R}$, $j = \overline{1, m}$ — функции, задающие ограничения. Мы также будем в дальнейшем предполагать, что данные функции являются достаточно «хорошими». Отметим, что формально все функциональные ограничения можно было просто спрятать в $\mathcal{X}$ (часто возможно и обратное: $\mathcal{X}$ записывается в виде набора функциональных ограничений), главной проблемой при таком действии может стать потеря «простоты» $\mathcal{X}$.

Замечание Л1.1. Часто используют краткую запись:

$$\min_{x \in \mathcal{X}} f(x) \quad \text{вместо} \quad \begin{array}{ll} \min_x & f(x) \\ \text{s.t.} & x \in \mathcal{X} \subseteq \mathbb{R}^d. \end{array}$$

Л1.1 Примеры задач оптимизации

Л1.1.1 Оптимизация инвестиционного портфеля

Рассмотрим стандартную постановку задачи оптимизации портфеля, предложенную Г. Марковицем [25]. Цель задачи заключается в оптимальном распределении средств между доступными активами для минимизации совокупного инвестиционного риска при заданном уровне ожидаемой доходности.

Предположим на рынке имеется d акций и мы владеем информацией об изменении цен на акции за n лет:

p_i^j — цена i -ого актива в j -ый год.

Для начала мы можем рассчитать математическое ожидание μ_i доходности i -ой акции за n лет, применив формулу сложного процента:

$$(1 + \mu_i)^n = \frac{p_i^n}{p_i^0} \implies \mu_i = \left(\frac{p_i^n}{p_i^0} \right)^{\frac{1}{n}} - 1.$$

Вектор ожидаемых доходностей всех активов обозначим как:

$$\mu = (\mu_1, \dots, \mu_d)^\top.$$

Выпишем также выборочную ковариационную матрицу этих активов S , то есть информацию о том, насколько сильно коррелируют цены на акции между собой:

$$S = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1d} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \dots & \sigma_{dd} \end{bmatrix},$$

где σ_{ii} — выборочная дисперсия i -го актива, а σ_{ij} — выборочная ковариация i -го и j -го активов, которые считаются по формуле:

$$\sigma_{ij} = \frac{\sum_{k=1}^n (\mu_i^k - \mu_i)(\mu_j^k - \mu_j)}{n},$$

где $\mu_i^k = \frac{p_i^k}{p_i^{k-1}} - 1$ — доходность i -го актива за k -ый год.

Наконец, мы хотим понять, какую долю портфеля стоит выделить на конкретную акцию $\omega = (\omega_1, \dots, \omega_d)^\top$, где $\sum_{i=1}^d \omega_i = 1$ и $\omega_i \geq 0$, $i = \overline{1, d}$, чтобы при фиксированной доходности $\langle \mu, \omega \rangle = r$ иметь наименьший риск. В рамках модели Марковица риск портфеля понимается как его *волатильность*, то есть степень разброса возможных значений доходности вокруг ожидаемого значения. Математически мерой такого разброса служит дисперсия. Тогда можно определить целевую функцию риска как

$$f(\omega) = \text{Var}(\langle \omega, r \rangle) = \langle \omega, S\omega \rangle.$$

Итоговая задача оптимизации в таком случае принимает вид:

$$\begin{aligned} \min_{\omega \in \mathbb{R}^d} \quad & \langle \omega, S\omega \rangle \\ \text{s.t.} \quad & \langle \mu, \omega \rangle - r = 0 \\ & \sum_{i=1}^d \omega_i - 1 = 0 \\ & -\omega_i \leq 0, \quad i = \overline{1, d}. \end{aligned}$$

Л1.1.2 Оптимизация ценообразования

Предположим, что мы владеем небольшим бизнесом. В нашем магазине имеется d товаров. Для каждого товара i , мы знаем его себестоимость C_i , спрос Q_i^0 по начальной цене P_i^0 и функцию спроса $Q_i(P_i)$ от цены. В наших интересах максимизировать оборот, не потеряв при этом текущую прибыль.

Определим целевую функцию как суммарный оборот нашего магазина:

$$\sum_{i=1}^d P_i Q_i(P_i),$$

где $P = (P_1, \dots, P_d)^\top$. Поскольку сильное изменение цен может привести к неожиданным последствиям, например, потере постоянных клиентов, дополнительно потребуем, чтобы изменения цен на товары, которые мы внесли, лежали в допустимых интервалах:

$$P_i \in [P_i^l, P_i^r], \quad i = \overline{1, d}.$$

Максимизируя оборот, мы не хотим потерять прибыль, поэтому нужно потребовать ограничения на неё:

$$\sum_{i=1}^d (P_i - C_i) Q_i(P_i) \geq \sum_{i=1}^d (P_i^0 - C_i) Q_i^0.$$

Наконец, сформулируем оптимизационную задачу:

$$\begin{aligned} \min_{P \in \mathbb{R}^d} \quad & - \sum_{i=1}^d P_i Q_i(P_i) \\ \text{s.t.} \quad & \sum_{i=1}^d (P_i - C_i) Q_i(P_i) \geq \sum_{i=1}^d (P_i^0 - C_i) Q_i^0 \\ & P_i \in [P_i^l, P_i^r], \quad i = \overline{1, d}. \end{aligned}$$

Л1.1.3 Оптимизация в статистике

Пусть есть параметрическое семейство вероятностных распределений $\{P(x|\theta)\}_{\theta \in \Theta}$, и дана независимая выборка $X = (x_1, \dots, x_n) \sim P(x|\theta)$ для некоторого $\theta \in \Theta$. Наша задача — оценить параметр θ . Например, $P(x|\theta)$ — нормальное распределение с математическим ожиданием $\theta \in \mathbb{R}$.

Существуют разные методы оценки параметров распределения по выборке, нас же интересует *метод максимального правдоподобия* [34], суть которого заключается в поиске точки максимума функции совместного распределения наблюдаемых значений.

Предположим, что совместное распределение выборки задаётся функцией $p(X|\theta)$. Тогда функция правдоподобия:

$$L(\theta|X) = p(X|\theta).$$

Мы хотим максимизировать правдоподобие по θ , так как, чем оно больше, тем вероятнее, что наблюдаемые значения пришли из распределения $P(x|\theta)$.

В качестве целевой функции просто возьмем правдоподобие, а так как элементы выборки независимы, то его можно переписать:

$$L(\theta|X) = \prod_{i=1}^n p(x_i|\theta).$$

Зачастую удобно использовать логарифм правдоподобия:

$$\log L(\theta|X) = \sum_{i=1}^n \log p(x_i|\theta).$$

Рассмотрев минус логарифм правдоподобия, мы перейдём от задачи максимизации к задаче минимизации и получим следующую постановку:

$$\min_{\theta \in \Theta} - \sum_{i=1}^n \log p(x_i|\theta).$$

П1.1.4 Оптимизация обработки сигналов

Рассмотрим задачу идентификации неисправностей, произошедших в системе, на основе показаний датчиков. Пусть у нас есть d различных типов неисправностей, причём каждая из них происходит независимо с вероятностью p , также есть n ($n < d$) датчиков, которые получают данные системы с целью выявления неисправностей.

Пусть $x_i \in \{0, 1\}$, $i = \overline{1, d}$ — вектор индикаторов всех неисправностей, а показания датчиков задаются уравнением:

$$y = Ax + v,$$

где $A \in \mathbb{R}^{n \times d}$ — матрица неисправностей, в которой каждый столбец a_i равен показанием датчиков при i -ой неисправности, а $v \sim \mathcal{N}(0, \sigma^2 I_n)$ — случайный вектор шума. Цель состоит в том, чтобы выяснить, какой вид имеет вектор неисправностей x по вектору агрегированных показаний датчиков y .

Распределение датчиков имеет вид $y \sim \mathcal{N}(Ax, \sigma^2 I_n)$, где $x_i \sim \text{Bern}(p)$, $i = \overline{1, d}$. Воспользуемся предыдущим примером П1.1.3. Найдём правдоподобие $L(x|y)$ с точностью до константы по формуле Байеса для апостериорной вероятности:

$$L(x|y) \propto p(y|x)p(x) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp\left(-\frac{\|Ax - y\|_2^2}{2\sigma^2} \right) p^{\sum_{i=1}^d x_i} (1-p)^{d-\sum_{i=1}^d x_i}.$$

Мы хотим максимизировать правдоподобие, поэтому зададим целевую функцию следующим образом:

$$\ell(x) = -\log L(x|y) + \text{const} = \frac{1}{2\sigma^2} \|Ax - y\|_2^2 + \log\left(\frac{1}{p} - 1\right) \sum_{i=1}^d x_i.$$

Таким образом, наша задача оптимизации примет следующий вид:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \frac{1}{2\sigma^2} \|Ax - y\|_2^2 + \log\left(\frac{1}{p} - 1\right) \sum_{i=1}^d x_i \\ \text{s.t.} \quad & x_i \in \{0, 1\}, \quad i = \overline{1, d}. \end{aligned}$$

Л1.1.5 Оптимизация в машинном обучении

Рассмотрим стандартную постановку задачи обучения с учителем. Пусть у нас есть обучающая выборка $\{x_i, y_i\}_{i=1}^n$, где $x_i \in \mathbb{R}^d$ — наши наблюдения, y_i — метки, их вид зависит от рассматриваемой задачи, например:

- $y_i \in \mathbb{R}$ для регрессии (предсказание цен на жильё, прогнозирование спроса, оценка стоимости бизнеса),
- $y_i \in \{0, 1\}$ для бинарной классификации (диагностика заболеваний, кредитный скоринг, фильтрация спама),
- $y_i \in \{c_1, \dots, c_m\}$ для многоклассовой классификации (распознавание объектов на изображении, предсказание следующего слова).

Пусть у нас есть параметризованная модель $f(x|\theta)$, которая делает предсказания по наблюдениям x . Это может быть простая линейная функция: $f(x|\theta) = \langle \theta, x \rangle + b$ или нейросеть с несколькими миллиардами параметров. Задача ставится следующим образом: нужно найти оптимальные параметры модели θ , такие, чтобы предсказания были наиболее близки к истинным меткам.

Для этого вводится функция потерь $\ell(f(x_i|\theta), y_i)$, которая измеряет несоответствие предсказания модели и реального значения. Например, в случае регрессии это может быть среднеквадратичное отклонение:

$$MSE = (f(x_i|\theta) - y_i)^2,$$

а в случае бинарной или многоклассовой классификации — кросс-энтропия:

$$CE = - \sum_{c=1}^m y_{i,c} \log f_c(x_i|\theta),$$

где $y_{i,c}$ — индикатор принадлежности классу c , а $f_c(x_i|\theta)$ — предсказанная вероятность этого класса. Поскольку выборка конечная, то необходимо минимизировать *эмпирический риск*:

$$\frac{1}{n} \sum_{i=1}^n \ell(f(x_i|\theta), y_i).$$

Таким образом, задача нахождения оптимальных параметров модели формулируется в парадигме минимизации эмпирического риска:

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \ell(f(x_i|\theta), y_i).$$

Л1.1.6 Оптимизация объёма эллипсоида

Предположим, есть какая-то выборка из $\mathbb{R}^d$, мы хотим использовать *MVE* (Minimum Volume Ellipsoid, Параграф 8.4 из [6]) — метод поиска эллипсоида минимального объёма, содержащего заданный набор точек, для оценивания параметра многомерного распределения, из которого пришли наблюдения. Зная параметры такого эллипсоида, можно найти сдвиг b и матрицу ковариаций Σ искомого распределения.

Положительно определенное линейное преобразование $A = \Sigma^{\frac{1}{2}}$ и сдвиг на вектор b , примененные к единичной сфере, задают эллипсоид с объёмом, который в $\det(A^{-1})$ раз больше, чем объём единичного шара, поэтому мы параметризуем внутреннюю часть эллипсоида следующим образом:

$$S = \left\{ x \in \mathbb{R}^d \mid \|Ax + b\|_2^2 \leq 1 \right\}.$$

Но есть проблема: функцию $\det(A^{-1})$ сложно минимизировать напрямую. Однако в силу $\det(A^{-1}) = \frac{1}{\det A}$, получаем, что $\log \det(A^{-1}) = -\log \det(A)$. А поскольку логарифм — монотонно возрастающая функция и сохраняет минимум, получим следующую задачу оптимизации:

$$\begin{aligned} \min_{\substack{A \in \mathbb{R}^{d \times d} \\ b \in \mathbb{R}^d}} & -\log \det(A) \\ \text{s.t.} & \|Ax_i + b\|_2 \leq 1, \quad i = \overline{1, n} \\ & A \succ 0. \end{aligned}$$

Л1.1.7 Оптимизационная задача в логистике

Рассмотрим следующую постановку: мы владельцы крупного бизнеса, у нас есть склады, каким-то образом соединенные дорогами. Мы хотим расположить новые склады так, чтобы транспортировочная стоимость была минимальной.

Задачу можно рассматривать как минимизацию функции на графе. Пусть $y_j \in \mathbb{R}^2$, $j = \overline{1, m}$ — наши склады, вершины графа, а $x_i \in \mathbb{R}^2$, $i = \overline{1, n}$ — склады, которые мы хотим поставить. Формализуем целевую функцию в виде:

$$f(x) = \sum_{i=1}^n \sum_{j=1}^m \omega_{ij} g(\|x_i - y_j\|),$$

где $\omega_{ij} \geq 0$ — веса, которые содержат информацию о том, насколько склады важны между собой, g — штрафная функция от расстояний. Также мы можем захотеть, чтобы некоторые склады находились в определенных областях. Это условие можно записать следующим образом:

$$x_i \in S_i, \quad i = \overline{1, n},$$

где S_i — прямоугольник, в котором должен находиться i -ый склад.

Тогда итоговая задача принимает вид:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} & \sum_{i=1}^n \sum_{j=1}^m \omega_{ij} g(\|x_i - y_j\|) \\ \text{s.t.} & x_i \in S_i, \quad i = \overline{1, n}. \end{aligned}$$

Л1.2 Общая схема методов оптимизации

Жизненный опыт подсказывает, что даже в одномерном случае задача оптимизации может не иметь аналитического решения (если вообще имеет). Если же решение существует, то на практике такую задачу обычно решают приближённо, итеративно находя лучшее решение, при этом допуская, что оно может не являться точным. Для этого применяются специальные алгоритмы, которые и называют *методами оптимизации*. При создании методов оптимизации хочется добиться унифицированности. Потому что нет смысла искать лучший метод для решения конкретной задачи. Например, лучший алгоритм для решения задачи $\min_{x \in \mathbb{R}} x^2$ сходится за одну итерацию: этот метод просто всегда выдает ответ $x^* = 0$. Очевидно, что для других задач такой способ находить решение непригоден. Метод должен подходить для целого класса однотипных или похожих задач.

Так как метод разрабатывается для целого класса задач, то он не может иметь с самого начала полной информации о задаче (Л1.1). Вместо этого используется модель задачи, например, формулировка задачи, описание функциональных компонент, множества, на которых происходит оптимизация и так далее. Предполагается, что численный метод может накапливать специфическую информацию о задаче при помощи

некоторого оракула. Под *оракулом* можно понимать некоторое устройство (программу, процедуру), которое отвечает на последовательные вопросы метода оптимизации о свойствах функции. В идеальном мире, наверное, можно было спросить у оракула всю информацию о решении задачи (Л1.1), но очевидно, что такого рода оракулы не интересны для практики. Мы будем работать с более приземленными вариантами оракулов, которые могут возвращать локальную информацию о целевой функции.

Определение Л1.1. Оракулы имеют разный порядок в зависимости от степени подробности, возвращаемой информации:

- *Оракул нулевого порядка* в запрашиваемой точке x возвращает значение целевой функции $f(x)$.
- *Оракул первого порядка* в запрашиваемой точке x возвращает значение целевой функции $f(x)$ и её градиент $\nabla f(x)$.
- *Оракул второго порядка* в запрашиваемой точке x возвращает значение целевой функции $f(x)$, её градиент $\nabla f(x)$ и её гессиан $\nabla^2 f(x)$.

Можно продолжать и до производных более высоких порядков.

Такое определение оракула имеет вполне прикладной смысл. В методах оптимизации обращение к оракулу часто реализуется посредством вызова отдельной от метода функции, программы или процедуры, возвращающей необходимую информацию, будь то значение функции, её градиента или её гессиана.

Методы оптимизации, которые мы будем рассматривать, описываются следующей схемой.

Алгоритм Л1.1 Общая итеративная схема метода оптимизации $\mathcal{M}$

Вход: начальная точка x^0 , счётчик итераций $k = 0$, накапливаемая информационная модель решаемой задачи $I_{-1} = \emptyset$

- 1: **while** не выполнен критерий остановки $\mathcal{T}$ **do**
- 2: Задать вопрос к оракулу $\mathcal{P}$ в точке x^k
- 3: Пересчитать информационную модель: $I_k = I_{k-1} \cup (x^k, \mathcal{P}(x^k))$
- 4: Применить правило метода $\mathcal{M}$ для получения новой точки x^{k+1} по модели I_k
- 5: Положить $k = k + 1$
- 6: **end while**

Выход: $\hat{x}$

Алгоритм состоит из итераций, которые повторяются, пока не выполнен критерий остановки $\mathcal{T}$. В теле итерации мы обращаемся к оракулу, записываем его ответ в информационную модель, и получаем новую точку согласно правилу обновления.

Замечание Л1.2. В Алгоритме Л1.1 и далее мы будем использовать верхний индекс x^k для обозначения переменной x на k -ой итерации.

Пример Л1.1. Рассмотрим задачу оптимизации

$$\min_{x \in \mathbb{R}^d} f(x),$$

где функция $f(x)$ дифференцируема. Предположим, что в любой точке мы можем посчитать её градиент. Тогда можно воспользоваться следующим методом:

Алгоритм Л1.2 Градиентный спуск с постоянным размером шага

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размер шага $\gamma > 0$, количество итераций K

```
1: for  $k = 0, 1, \dots, K - 1$  do
2:    $x^{k+1} = x^k - \gamma \nabla f(x^k)$ 
3: end for
Выход:  $x^K$ 
```

С градиентным спуском мы будем подробнее знакомиться уже в следующих параграфах. Сейчас мы хотим лишь понять, как он ложится в общую модель. В данном случае оракул $\mathcal{P}$ — оракул первого порядка, который возвращает градиенты ∇f в запрашиваемых точках. При этом в информационную модель мы каждую итерацию кладем значения $(x^k, \mathcal{P}(x^k)) = (x^k, \nabla f(x^k))$. Сам же метод градиентного спуска $\mathcal{M}$ использует только последнюю пару точек из информационной модели и получает новую точку по правилу: $x^{k+1} = x^k - \gamma \nabla f(x^k)$.

Замечание Л1.3. В общей итеративной схеме метода оптимизации (Алгоритм Л1.1) информационная модель растёт линейно с номером итерации k . Пример Л1.1 показывает, что для практических методов вовсе не обязательно хранить всю информационную модель — градиентному спуску нужна только текущая точка x^k и $\mathcal{P}(x^k) = \nabla f(x^k)$.

Замечание Л1.4. В Примере Л1.1 в качестве критерия остановки $\mathcal{T}$ используется ограничение на количество итераций, но может быть и требование на достижение точности решения.

Определение Л1.2. Под утверждением, что *задача решена с точностью ε* (найден ε -решение/выполнен критерий остановки), можно понимать:

- По аргументу: $\|x^k - x^*\|_2 \leq \varepsilon$.
- По значению функции: $f(x^k) - f^* \leq \varepsilon$.
- По норме градиента: $\|\nabla f(x^k)\|_2 \leq \varepsilon$.

Отметим, что первые два критерия являются теоретическими. Мы их будем использовать при доказательстве сходимости методов и оценке их скорости работы. На практике же сложно, например, оценить $\|x^k - x^*\|_2$, так как мы не знаем расположение точки x^* . При этом может оказаться полезным критерий сходимости вида: $\|x^{k+1} - x^k\|_2 \leq \varepsilon$. Из такого критерия не следуют какие-либо гарантии на $\|x^k - x^*\|_2$ — можно привести массу очевидно плохих методов, которые стоят на месте вдали от решения. Но верно обратное, а именно, если $\|x^{k+1} - x^k\|_2 \leq \|x^k - x^*\|_2 \leq \varepsilon/2$, то по неравенству треугольника:

$$\|x^{k+1} - x^k\|_2 \leq \|x^{k+1} - x^*\|_2 + \|x^k - x^*\|_2 \leq \varepsilon.$$

Поэтому при имеющейся теории или интуиции о том, что $\|x^k - x^*\|_2 \rightarrow 0$, критерий вида $\|x^{k+1} - x^k\|_2 \leq \varepsilon$ может быть более чем полезен.

Похожая ситуация с критерием на основе $f(x^k) - f^*$ с той лишь разницей, что для некоторых задач мы можем знать значение f^* (например, для $\min_{x \in \mathbb{R}^d} \|Ax - b\|_2^2$, где $b \in \text{Im } A$, известно $f^* = 0$).

Следить за поведением $\|\nabla f(x^k)\|_2$ кажется более практичным. Это является правдой для определенного класса функций, пока мы рассматриваем безусловные варианты задачи (Л1.1) (без ограничений и с $\mathcal{X} = \mathbb{R}^d$). В общем же случае, такого рода критерий

может ничего не сказать — достаточно рассмотреть задачу $\min_{x \in [1,2]} x^2$. Существуют и другие критерии, с которыми познакомимся далее, которые подойдут и для $\mathcal{X} \neq \mathbb{R}^d$.

Л1.3 Сложность методов. Верхние и нижние оценки

Для понимания того, насколько эффективно/быстро/дёшево работают методы оптимизации, как их сравнивать между собой, необходимо ввести формальные понятия для описания *сложности* методов оптимизации:

Определение Л1.3.

- *Аналитическая/Оракульная сложность* — число обращений метода к оракулу, необходимое для решения задачи с точностью ε .
- *Арифметическая/Временная сложность* — общее число вычислений (включая работу оракула), необходимых для решения задачи с точностью ε .
- *Итерационная сложность* — общее число итераций метода, необходимых для решения задачи с точностью ε .

Арифметическая сложность даёт полное количество атомарных операций (сложений/умножений двух чисел), которое выполнил метод для решения задачи оптимизации. Время, которое затратит алгоритм, можно считать пропорциональным арифметической сложности.

Оракульная сложность учитывает только количество вызовов оракула, что пропорционально общему количеству атомарных операций, которые выполнил оракул в ходе работы метода. На самом деле, часто оракульной сложности бывает достаточно для оценки времени работы метода, так как вычисления оракулов являются наиболее дорогой операцией во всем методе. Рассмотрим, например, алгоритм из Примера Л1.1 для целевой функции f из Примера С2.4. Вычисления ∇f требуют умножения матрицы на вектор, а все остальные операции алгоритма производятся с вектором.

Итерационная сложность несёт меньше всего информации о времени работы метода, так как разные методы могут иметь абсолютно разную арифметическую сложность вызова оракула. Поэтому из того, что один метод достигает ε -решения за меньшее число итераций, вообще говоря, не следует, что он работает быстрее по времени.

Теперь попробуем понять, а какие гарантии на сложность мы вообще можем дать при поиске ε -решения (Л1.1). Для этого рассмотрим следующую, на первый взгляд, довольно простую задачу оптимизации:

$$\min_{x \in [0,1]^d} f(x), \quad (\text{Л1.2})$$

где $[0,1]^d = \{x \in \mathbb{R}^d \mid 0 \leq x_i \leq 1, i = \overline{1,d}\}$ — кубик. При этом мы дополнительно предположим, что функция $f(x)$ является M -липшицевой на $[0,1]^d$ относительно ℓ_∞ -нормы, то есть для любых $x, y \in [0,1]^d$ справедливо

$$|f(x) - f(y)| \leq M \|x - y\|_\infty = M \max_{i=\overline{1,d}} |x_i - y_i|. \quad (\text{Л1.3})$$

Замечание Л1.5. Множество $[0,1]^d$ является ограниченным и замкнутым, то есть компактом, а из липшицевости функции f следует и её непрерывность. Поэтому задача (Л1.2) имеет решение, так как по теореме Вейерштрасса (Теорема 2 Параграфа 7 из [41]) непрерывная на компакте функция достигает своих минимального и максимального значений.

В поисках решения давайте ограничимся методами нулевого порядка (то есть методы, которые могут вызывать оракул, возвращающий значения целевой функции). Более формально:

- **Цель:** найти $\hat{x} \in [0, 1]^d$: $f(\hat{x}) - f^* \leq \varepsilon$, где f удовлетворяет (Л1.3).
- **Класс методов:** методы нулевого порядка.

Рассмотрим следующий довольно незатейливый алгоритм для решения поставленной цели:

Алгоритм Л1.3 Метод равномерного перебора

Вход: целочисленный параметр перебора $p \geq 1$

- 1: Сформировать $(p + 1)^d$ точек вида $x_{(i_1, \dots, i_d)} = \left(\frac{i_1}{p}, \frac{i_2}{p}, \dots, \frac{i_d}{p} \right)^\top$, где вектор $(i_1, \dots, i_d) \in \{\overline{0, p}\}^d$
- 2: Среди точек $x_{(i_1, \dots, i_d)}$ найти точку $\hat{x}$ с наименьшим значением целевой функции f .

Выход: $\hat{x}$

Попробуем получить какие-нибудь гарантии на решение, которое находит данный алгоритм.

Теорема Л1.1 (Теорема 1.1.1. из [44]). Пусть задача оптимизации (Л1.2) с M -липпицевой целевой функцией f решается с помощью метода равномерного перебора с параметром p (Алгоритм Л1.3). Тогда справедлива следующая оценка сходимости:

$$f(\hat{x}) - f^* \leq \frac{M}{2p},$$

откуда следует, что методу равномерного перебора нужно в худшем случае

$$\left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor + 2 \right)^d$$

обращений к оракулу, чтобы гарантировать $f(\hat{x}) - f^* \leq \varepsilon$.

Доказательство. Пусть x^* — решение задачи (возможно, не единственная точка минимума функции f). Тогда в построенной методом сетке из точек найдется такая точка $x_{(i_1, \dots, i_d)}$, что

$$x := x_{(i_1, \dots, i_d)} \preceq x^* \preceq x_{(i_1+1, \dots, i_d+1)} =: x',$$

где знак $\preceq$ применяется покомпонентно. Точки x и x' определяют углы кубика сетки, в котором лежит x^* , то есть $x_i^* \in [x_i, x'_i]$ для всех $i = \overline{1, d}$. Отметим, что стороны данного кубика имеют длины $x'_i - x_i = \frac{1}{p}$.

Кроме того, рассмотрим точки $\bar{x}$ и $\tilde{x}$ такие, что $\bar{x} = \frac{x+x'}{2}$ и

$$\tilde{x}_i = \begin{cases} x'_i, & \text{если } x_i^* \geq \bar{x}_i, \\ x_i, & \text{иначе.} \end{cases}$$

$\bar{x}$ — центр кубика, а $\tilde{x}$ определяет ближайший к x^* уголок кубика. Заметим, что $\tilde{x}$ принадлежит сетке и $|\tilde{x}_i - x_i^*| \leq \frac{1}{2p}$, так как в худшем случае x^* расположен в $\bar{x}$, а значит, равноудален от всех уголков. Тогда

$$\|\tilde{x} - x^*\|_\infty = \max_{i \in \overline{1, d}} |\tilde{x}_i - x_i^*| \leq \frac{1}{2p}.$$




Рис. Л1.1: Построенная сетка и кубик в ней, которому принадлежит точка x^* .

Поскольку $f(\hat{x}) \leq f(\tilde{x})$ (так как $f(\hat{x})$ — минимум по всем точкам сетки), получаем

$$f(\hat{x}) - f^* \leq f(\tilde{x}) - f^* \leq M \|\tilde{x} - x^*\|_\infty \leq \frac{M}{2p}.$$

Выписанная выше оценка достигается методом равномерного перебора за $(p+1)^d$ обращений к оракулу. Ограничим сверху значением ε :

$$f(\hat{x}) - f^* \leq \frac{M}{2p} \leq \varepsilon \implies p \geq \frac{M}{2\varepsilon}.$$

Возьмем $p = \left\lfloor \frac{M}{2\varepsilon} \right\rfloor + 1$, тогда метод сделает $\left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor + 2 \right)^d$ обращений к оракулу нулевого порядка и выдаст ответ с ε -точностью. ■

Интересно оценить порядок величин, которые мы получили:

- Предположим, $M = 2$, $d = 13$ и $\varepsilon = 0.01$, то есть размерность задачи сравнительно небольшая (можно сказать, что никакая для задач оптимизации в современных приложениях) и точность решения задачи не слишком высокая.
- Необходимое число обращений к оракулу: $\left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor + 2 \right)^d = 102^{13} > 10^{26}$.
- Сложность одного вызова оракула не менее 1 арифметической операции (FLOP).
- Производительность современной видеокарты порядка 10^{14} арифметических операций в секунду (82 TFLOPs на NVIDIA GeForce RTX 4090).
- Общее время: хотя бы 10^{12} секунд, что займёт порядка 30 тысяч лет.

Выводы получаются не очень оптимистичные. Но есть надежда, что наш теоретический анализ из Теоремы Л1.1 плох, либо метод не самый лучший, и существует какой-нибудь зубодробительный алгоритм, который будет давать куда более приятные гарантии на число оракульных вызовов.

В Теореме Л1.1 мы получили так называемые верхние оценки на гарантии нахождения решения, но существует и обратное понятие — нижние оценки.

Определение Л1.4. Пусть нам дан некоторый класс методов, а также некоторый класс задач оптимизации.

- *Верхняя оценка* — гарантия, что рассматриваемый метод из класса методов на любой задаче из класса решаемых задач имеет оракульную/арифметическую/итерационную сложность не хуже, чем утверждает верхняя оценка.
- *Нижняя оценка* — гарантия, что для любого метода из класса методов существует «плохая» задача из класса решаемых задач, такая, что метод имеет оракульную/арифметическую/итерационную сложность не лучше, чем утверждает нижняя оценка.

Напомним, что в этом параграфе мы рассматриваем класс методов нулевого порядка, то есть все методы, которые каким-либо образом используют информацию о значениях функции (но не градиентов). Также класс задач, которые мы сейчас рассматриваем, описывается с помощью (Л1.2) и (Л1.3).

Нижние оценки нужны, чтобы понять, насколько полученные верхние оценки хороши. В частности, если верхние и нижние оценки совпали, это означает оптимальность предложенного метода для данного класса задач. Но если нижние оценки не совпали с верхними, то это может ничего не значить — возможно, в нижних оценках подобрана недостаточно «плохая» функция, а возможно, при получении верхних оценок пришлось заглубить теоретические выкладки. Нижние оценки можно получать не только для класса методов, но и для определенного метода, чтобы доказать оптимальность и неулучшаемость теоретического анализа и полученной верхней оценки.

Вернемся к нашей задаче: (Л1.2) + (Л1.3) и методам, оперирующим информацией нулевого порядка. Следующая теорема представит нижние оценки на оракульную сложность.

Теорема Л1.2 (Теорема 1.1.2. из [44]). Пусть задача оптимизации (Л1.2) с M -липшицевой целевой функцией f решается с помощью методов нулевого порядка с точностью $\varepsilon < \frac{M}{2}$. Тогда необходимо не менее

$$\left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor - 1 \right)^d - 1$$

обращений к оракулу, чтобы гарантировать $f(\hat{x}) - f^* \leq \varepsilon$.

Доказательство. Доказываем от противного: предположим, что существует такой метод, который решает задачу за $N < \left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor - 1 \right)^d - 1$ обращений к оракулу с точностью ε (по функции). Опровергнем это, построив такую функцию, на которой метод не сможет найти ε -решение, при помощи сопротивляющегося оракула. Пусть изначально наша целевая функция $f(x)$ всюду равна 0. Запустим метод, он запросит значение f в N точках, везде получит 0 и выдаст какую-то точку (возможно, отличную от всех предыдущих N), как ответ. В итоге мы в ходе работы алгоритма заглянули в $N + 1$ точку.

Заметим, что в силу непрерывности функции $\frac{1}{x}$, можно подобрать число $\delta > 0$:

$$\frac{M}{2\varepsilon} - 1 < \frac{M}{(2 + \delta)\varepsilon}.$$

Тогда, в силу монотонности округления:

$$\left\lfloor \frac{M}{2\varepsilon} \right\rfloor - 1 \leq \left\lfloor \frac{M}{(2 + \delta)\varepsilon} \right\rfloor.$$

Теперь из этого неравенства и предположения в начале получим оценку на $N + 1$:

$$N + 1 < \left(\left\lfloor \frac{M}{2\varepsilon} \right\rfloor - 1 \right)^d \leq \left\lfloor \frac{M}{(2 + \delta)\varepsilon} \right\rfloor^d.$$

Обозначим $p = \left\lfloor \frac{M}{(2 + \delta)\varepsilon} \right\rfloor$. Рассмотрим равномерную сетку из $(p + 1)^d$ точек, по аналогии с тем, как сделано в методе равномерного перебора. Из этих точек сформируем p^d кубиков с ребрами длины $\frac{1}{p}$. Воспользуемся тем, что смогли заглянуть в $N + 1$ точку и $N + 1 < p^d$. Тогда по принципу Дирихле (точки — кролики, кубики с углами в соседних вершинах сетки — клетки) найдётся такой кубик

$$C = \left\{ x \mid \tilde{x} \preceq x \preceq \tilde{x} + \frac{1}{p} \mathbf{1} \right\},$$

который не содержит внутри себя ни одной из $N + 1$ точки (в том числе и выхода метода). Здесь $\tilde{x}$ и $\tilde{x} + \frac{1}{p} \mathbf{1}$ — точки из сетки с шагом $\frac{1}{p}$, а $\mathbf{1}$ — вектор из единиц.

Пусть x^* — это центр кубика C , то есть $x^* = \tilde{x} + \frac{1}{2p} \mathbf{1}$. Теперь немного модифицируем целевую функцию f :

$$\bar{f}(x) = \min \left\{ 0, M \|x - x^*\|_\infty - \left(1 + \frac{\delta}{2} \right) \varepsilon \right\}.$$




Рис. Л1.2: График функции $\bar{f}(x)$ в окрестности x^* .

Функция $\bar{f}(x)$ липшицева с константой M относительно ℓ_∞ -нормы и принимает своё минимальное значение $-\varepsilon(1 + \frac{\delta}{2})$ в точке x^* . Более того, по определению функция $\bar{f}(x)$ отлична от нуля только внутри кубика

$$C' = \left\{ x \mid \|x - x^*\|_\infty < \frac{\varepsilon}{M} \left(1 + \frac{\delta}{2} \right) \right\},$$

который лежит внутри кубика C . Это так, поскольку согласно выбору $p = \left\lfloor \frac{M}{(2+\delta)\varepsilon} \right\rfloor$ верно

$$2p = 2 \left\lfloor \frac{M}{(2+\delta)\varepsilon} \right\rfloor \leq \frac{2M}{(2+\delta)\varepsilon},$$

откуда получаем

$$\frac{\varepsilon}{M} \left(1 + \frac{\delta}{2} \right) \leq \frac{1}{2p}.$$

Вложение $C' \subset C$ позволяет нам сказать, что алгоритм заглянул только в точки с нулевым значением, поскольку вне C' функция тождественно равна нулю.

Итак, мы привели пример функции, минимум которой достигается в точке x^* и равен $-\varepsilon(1 + \frac{\delta}{2})$, при этом рассматриваемый метод выдал точку $\hat{x}$ со значением $f(\hat{x}) = 0$. Следовательно, рассмотренный метод на данной функции нашел решение с точностью $f(\hat{x}) - f^* = \varepsilon(1 + \frac{\delta}{2}) > \varepsilon$. Противоречие. ■

Получается, что нижняя оценка из Теоремы Л1.2 не особо лучше Теоремы Л1.1. Зависимость $(\frac{M}{\varepsilon})^d$ присутствует в обоих результатах. А это значит, что для класса липшицевых функций в общем случае все довольно печально. Нужны дополнительные предположения на задачу (Л1.1), чтобы гарантировать более оптимистичные гарантии. Но это вопрос уже следующих параграфов.

Л1.4 Скорость сходимости методов

Поймём, с каким характером верхних оценок на скорость сходимости/скорость приближения к решению мы хотим и будем иметь дело в дальнейшем.

Определение Л1.5. Выделим основные типы сходимостей:

- *Сублинейная*: $\|x^k - x^*\|_2 \leq \frac{C}{k^\alpha}$, $C > 0$, $\alpha > 0$.
 - *Линейная*: $\|x^k - x^*\|_2 \leq Cq^k$, $C > 0$, $0 < q < 1$.
 - *Сверхлинейная*: $\|x^k - x^*\|_2 \leq Cq^{k^p}$, $C > 0$, $0 < q < 1$, $p > 1$.
 - *Квадратичная*: $\|x^k - x^*\|_2 \leq Cq^{2^k}$, $C > 0$, $0 < q < 1$.
- Квадратичная локальная*: $\|x^{k+1} - x^*\|_2 \leq C\|x^k - x^*\|_2^2$, $C > 0$.

Из определения очевидно, что типы следуют в порядке увеличения скоростей сходимости. Приведённые в Определении Л1.5 типы сходимостей могут относиться как к арифметической, так и к оракульной или итерационной сложности. Построим графики представителей каждого из типов сходимостей на Рисунке Л1.3.

Можно лишь примерно оценить, как данные виды сходимостей визуально соотносятся между собой. Однако спустя 5 итераций сверхлинейная и квадратичная сходимости становятся неразличимы, а после 10 итерации все, кроме сублинейной сходимости, сливаются с нулем. Естественным образом возникает вопрос: как визуально сравнивать скорости сходимостей, когда значения критерия близки к нулю? Решением этой проблемы является логарифмический масштаб оси критерия. Построим новый график с предложенным подходом (Рисунок Л1.4).

Теперь каждый график визуально отделяется от других. Также из рисунка становится понятно, почему линейная скорость получила такое название.

Отдельно рассмотрим последний тип сходимости и поймём, почему он так называется. Запишем неравенство из определения:

$$\|x^{k+1} - x^*\|_2 \leq C\|x^k - x^*\|_2^2.$$




Рис. Л1.3: Основные типы сходимостей, линейный масштаб по оси критерия.




Рис. Л1.4: Основные типы сходимостей, логарифмический масштаб по оси критерия.

Запустим рекурсию: продолжим неравенства, записав оценку сначала для $\|x^k - x^*\|_2$ через $\|x^{k-1} - x^*\|_2$, потом для $\|x^{k-1} - x^*\|_2$ и так далее, пока не дойдем до $\|x^0 - x^*\|_2$.

$$\begin{aligned}\|x^{k+1} - x^*\|_2 &\leq C\|x^k - x^*\|_2^2 \leq C \cdot C^2\|x^{k-1} - x^*\|_2^4 \leq \dots \leq \left(\prod_{m=0}^k C^{2^m}\right)\|x^0 - x^*\|_2^{2^{k+1}} \\ &= \left(C^{\sum_{m=0}^k 2^m}\right)\|x^0 - x^*\|_2^{2^{k+1}}.\end{aligned}$$

Если учесть, что $\sum_{m=0}^k 2^m = 2^{k+1} - 1$, то можно записать

$$\|x^{k+1} - x^*\|_2 \leq \frac{1}{C}(C\|x^0 - x^*\|_2)^{2^{k+1}}.$$

Получили определение квадратичной скорости сходимости, где $C \rightarrow \frac{1}{C}$, $q \rightarrow C\|x^0 - x^*\|_2$. Вспомним требование на q :

$$0 < q = C\|x^0 - x^*\|_2 < 1,$$

что можно понимать как требование на достаточно хорошую стартовую точку:

$$\|x^0 - x^*\|_2 < \frac{1}{C}.$$

Поэтому эта сходимость называется локальной: она начинает работать, только если начальное приближение попало в окрестность решения.

Замечание Л1.6. Из Определения Л1.5, где даны скорости приближения к решению через k арифметических операций/оракульных вызовов/итераций, можно легко получить оценки на соответствующие сложности.

Пусть для некоторого метода мы доказали оценку на сходимость: $\|x^k - x^*\|_2 \leq \frac{C}{k^\alpha}$, где k — номер арифметической операций/оракульного вызова/итерации. Тогда, чтобы гарантировать точность ε по аргументу, нам необходимо сделать $k \geq \left(\frac{C}{\varepsilon}\right)^{1/\alpha}$:

$$\|x^k - x^*\|_2 \leq \frac{C}{k^\alpha} \leq \varepsilon \implies k^\alpha \geq \frac{C}{\varepsilon}.$$

Аналогичные манипуляции можно проделать со всеми типами сходимости из Определения Л1.5.

Л2 Условия оптимальности. Выпуклость и гладкость

Напомним, что ключевой задачей курса является (Л1.1). Начнем изучение с задачи без ограничений (безусловной задачи оптимизации):

$$\min_{x \in \mathbb{R}^d} f(x). \quad (\text{Л2.1})$$

Формализуем понятия решения данной задачи.

Л2.1 Условия оптимальности

Определение Л2.1. Точка x^* называется *локальным минимумом* функции f на $\mathbb{R}^d$ (локальным решением задачи минимизации f на $\mathbb{R}^d$), если существует $r > 0$ такое, что для любого $y \in \bar{B}^2(r, x^*) = \{y \in \mathbb{R}^d \mid \|y - x^*\|_2 \leq r\}$ следует, что $f(x^*) \leq f(y)$.

Определение Л2.2. Точка x^* называется *глобальным минимумом* функции f на $\mathbb{R}^d$ (глобальным решением задачи минимизации f на $\mathbb{R}^d$), если для любого $x \in \mathbb{R}^d$ следует, что $f(x^*) \leq f(x)$.

Понятно, что глобальный минимум является одновременно и локальным. Попробуем понять, какие есть свойства локального минимума. В частности, следующая теорема приводит необходимое условие локального минимума безусловной задачи оптимизации (Л2.1).

Теорема Л2.1 (Теорема 1.2.1. из [44]). Пусть x^* — локальный минимум функции f на $\mathbb{R}^d$. Тогда если f дифференцируема, то $\nabla f(x^*) = 0$.

Доказательство. Пойдем от противного и предположим, что x^* — локальный минимум, но $\nabla f(x^*) \neq 0$. Разложим функцию f в ряд в окрестности локального минимума:

$$f(x) = f(x^*) + \langle \nabla f(x^*), x - x^* \rangle + o(\|x - x^*\|_2), \quad (\text{Л2.2})$$

где $\lim_{x \rightarrow x^*} \frac{o(\|x - x^*\|_2)}{\|x - x^*\|_2} = 0$.

Рассмотрим $x_\lambda = x^* - \lambda \nabla f(x^*)$. Найдем $\lambda_1 > 0$ такое, что для любого $0 < \lambda \leq \lambda_1$ можно гарантировать, что $\|x_\lambda - x^*\|_2 \leq r$, то есть x_λ попадает в нужную окрестность из определения локального минимума (Определение Л2.1). Понятно, что такое λ_1 можно найти в силу $r > 0$, а $\nabla f(x^*)$ конечно. Тогда для любого $0 < \lambda \leq \lambda_1$ справедливо

$$f(x_\lambda) \geq f(x^*).$$

При этом разложение в ряд (Л2.2) для точек x_λ имеет вид:

$$\begin{aligned} f(x_\lambda) &= f(x^*) + \langle \nabla f(x^*), x_\lambda - x^* \rangle + o(\|x_\lambda - x^*\|_2) \\ &= f(x^*) - \lambda \|\nabla f(x^*)\|_2^2 + o(\lambda \|\nabla f(x^*)\|_2). \end{aligned}$$

Сделаем еще одно ограничение на «малость» λ . А именно, найдем $\lambda_2 > 0$ такое, что для любого $0 < \lambda \leq \min\{\lambda_1, \lambda_2\}$ выполнено

$$|o(\lambda \|\nabla f(x^*)\|_2)| \leq \frac{\lambda}{2} \|\nabla f(x^*)\|_2^2.$$

Тогда для любого $\lambda > 0$ такого, что $\lambda \leq \min\{\lambda_1, \lambda_2\}$, следует

$$f(x_\lambda) \leq f(x^*) - \frac{\lambda}{2} \|\nabla f(x^*)\|_2^2.$$

Пришли к противоречию, что x^* — локальный минимум. А значит $\nabla f(x^*) = 0$. ■

Наша цель — находить глобальный минимум, а локальных хотелось бы наоборот избегать (зависит от конкретной задачи, но обычно цель именно такая). Как мы поняли в Параграфе Л1, без дополнительных предположений на задачу (Л1.1) в худшем случае полный равномерный перебор является оптимальным алгоритмом. Поэтому пора ввести новые понятия, которые помогут сузить класс изучаемых задач и построить оптимистичную теорию поиска глобального минимума.

Л2.2 Выпуклость

Первое понятие — это выпуклость целевой функции f в задаче (Л2.1).

Определение Л2.3. Пусть дана непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что она является *выпуклой*, если для любых $x, y \in \mathbb{R}^d$ выполнено

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle.$$

Наряду с выпуклостью также вводят еще одно, более сильное понятие.

Определение Л2.4. Пусть дана непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что она является μ -*сильно выпуклой* ($\mu > 0$), если для любых $x, y \in \mathbb{R}^d$ выполнено

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_2^2.$$

Из определений видно, что выпуклость — это сильная выпуклость с $\mu = 0$.

В Параграфе С4 также даны другие определения выпуклости и сильной выпуклости, которые не требуют дифференцируемости. В случае дифференцируемой функции данные выше определения эквивалентны определениям из Параграфа С4.

Физический смысл Определений Л2.3 и Л2.4 проиллюстрирован на Рисунке Л2.1: выпуклая функция в любой точке «подперта» снизу линейной аппроксимацией, а сильно выпуклая — квадратичной функцией.

Введя новые классы функций, попробуем понять, что теперь можно сказать про точки минимума/решения задач оптимизации с такими целевыми функциями.

Теорема Л2.2. Пусть дана выпуклая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Если для некоторой точки $x^* \in \mathbb{R}^d$ верно, что $\nabla f(x^*) = 0$, то x^* — глобальный минимум f на всем $\mathbb{R}^d$.

Доказательство. Достаточно записать определение выпуклости:

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle = f(x^*).$$

■

Докажем несколько полезных фактов о минимумах выпуклых безусловных задач оптимизации.




Рис. 12.1: Иллюстрация понятий выпуклости и μ -сильной выпуклости.

Теорема 12.3. Пусть дана выпуклая на $\mathbb{R}^d$ функция f . Тогда

- всякий локальный минимум f на $\mathbb{R}^d$ является и глобальным,
- если дополнительно f сильно выпуклая, то минимум существует и единственен.

Доказательство. Докажем последовательно пункты теоремы.

- Пусть x^* — локальный минимум. Согласно необходимому условию минимума функции (Теорема 12.1)

$$\nabla f(x^*) = 0.$$

Пусть также x — произвольная точка из $\mathbb{R}^d$. Воспользуемся выпуклостью f :

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle = f(x^*).$$

Получаем, что $f(x^*) \leq f(x)$ для любого $x \in \mathbb{R}^d$. Значит, x^* — глобальный минимум.

- Покажем существование глобального минимума сильно выпуклой функции. Выберем произвольную точку $x^0 \in \mathbb{R}^d$ и положим $\beta = f(x^0)$. Если $\nabla f(x^0) = 0$, то x^0 — глобальный минимум (Теорема 12.2). Далее рассуждаем в предположении, что $\nabla f(x^0) \neq 0$. Рассмотрим множество подуровня функции f :

$$L_\beta = \left\{ x \in \mathbb{R}^d \mid f(x) \leq \beta \right\}.$$

По сильной выпуклости и неравенству Коши–Буняковского–Шварца (0.3) имеем:

$$\begin{aligned} f(x) &\geq f(x^0) + \langle \nabla f(x^0), x - x^0 \rangle + \frac{\mu}{2} \|x - x^0\|_2^2 \\ &\geq \beta - \|\nabla f(x^0)\|_2 \|x - x^0\|_2 + \frac{\mu}{2} \|x - x^0\|_2^2. \end{aligned}$$

Из условия $f(x) \leq \beta$ вытекает:

$$\frac{\mu}{2} \|x - x^0\|_2^2 - \|\nabla f(x^0)\|_2 \|x - x^0\|_2 \leq 0 \implies \|x - x^0\|_2 \leq \frac{2\|\nabla f(x^0)\|_2}{\mu}.$$

Значит

$$L_\beta \subseteq \bar{B}^2(R, x^0) = \left\{ x \in \mathbb{R}^d \mid \|x - x^0\|_2 \leq R \right\}, \text{ где } R = \frac{2\|\nabla f(x^0)\|_2}{\mu}.$$

Из этого вложения получаем, что вне шара $\bar{B}^2(R, x^0)$ значения функции f строго больше β :

$$f(x) > \beta, \forall x \notin \bar{B}^2(R, x^0).$$

При этом, шар $\bar{B}^2(R, x^0)$ замкнутый и ограниченный в конечномерном $\mathbb{R}^d$, следовательно, компактен. Тогда по теореме Вейерштрасса (Теорема 2 Параграфа 7 Главы 2 из [41]) f достигает на $\bar{B}^2(R, x^0)$ своего минимума, который автоматически является глобальным (вне $\bar{B}^2(R, x^0)$ значения f больше β).

Теперь покажем единственность. Пусть x^* — глобальный минимум, $x \in \mathbb{R}^d$. Поскольку f является μ -сильно выпуклой:


$$\begin{aligned} f(x) &\geq f^* + \langle \nabla f(x^*), x - x^* \rangle + \frac{\mu}{2} \|x - x^*\|_2^2 \\ &= f^* + \frac{\mu}{2} \|x - x^*\|_2^2. \end{aligned}$$

Слагаемое с градиентом занулилось, поскольку в точке оптимума $\nabla f(x^*) = 0$. Из свойств нормы получаем, что $f(x)$ достигает минимума только в точке x^* . Значит, если решение существует, то оно единственно. ■

Получается, что в случае выпуклой функции локальный минимум совпадает с глобальным. А значит $\nabla f(x^*) = 0$ является необходимым и достаточным условием. В теореме не сказано про существование или единственность минимума выпуклой функции. Приведем два примера выпуклых функций, где эти свойства могут не выполняться.

Пример Л2.1. Покажем, что у выпуклой функции может быть больше одной точки минимума. Рассмотрим кусочно-заданную функцию f :

$$f(x) = \begin{cases} (x-1)^2, & x \in (1, +\infty) \\ 0, & x \in [-1, 1] \\ (x+1)^2, & x \in (-\infty, -1). \end{cases}$$



Она является выпуклой, однако все точки отрезка $[-1, 1]$ доставляют минимум f , то есть у f несчётное число точек минимума.

Пример Л2.2. Теперь приведем пример, когда выпуклая функция не имеет минимума на $\mathbb{R}$. Для этого подойдет линейная функция

$$f(x) = x.$$

Действительно, она выпукла, поскольку в каждой точке совпадает со своей линейной аппроксимацией, при этом функция не ограничена снизу, поэтому ни одна из точек $\mathbb{R}$ не является точкой минимума f .

Л2.3 Гладкость

Введем еще одно свойство, которое также пригодится для того, чтобы строить теорию сходимости оптимизационных методов.

Определение Л2.5. Пусть дана непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что данная функция имеет *L-Липшицев градиент* (говорить, что она является *L-гладкой*), если для любых $x, y \in \mathbb{R}^d$ выполнено

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2.$$

Определение *L-гладкости* можно задавать и в неевклидовой норме. Обобщение понятия на произвольную норму мы введем в Параграфе Л10.

Теорема Л2.4 (Лемма 1.2.3. из [44]). Пусть дана *L-гладкая* функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда для любых $x, y \in \mathbb{R}^d$ выполнено

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|x - y\|_2^2.$$

Доказательство. Используем (Страница 84 из [42]) формулу Ньютона-Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор-функцией $r(\tau)$:

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

В нашем случае выберем кривую следующим образом $r(\tau) = x + \tau(y - x)$, где $\tau \in [0, 1]$. Тогда

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau \\ &= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau. \end{aligned}$$

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau \right| \\ &\leq \int_0^1 |\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle| d\tau. \end{aligned}$$

В последнем переходе мы использовали факт, что модуль суммы не превосходит сумму модулей слагаемых. Далее воспользуемся неравенством Коши–Буняковского–Шварца (0.3), а затем L -гладкостью (Определение Л2.5):

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &\leq \int_0^1 \|\nabla f(x + \tau(y - x)) - \nabla f(x)\|_2 \|y - x\|_2 d\tau \\ &\leq L \|y - x\|_2^2 \int_0^1 \tau d\tau = \frac{L}{2} \|x - y\|_2^2. \end{aligned}$$

■

Отметим, что Теорема Л2.4 требует только L -гладкости функции f . Посмотрим, что можно получить, если дополнительно предположить еще и выпуклость функции f .

Теорема Л2.5 (Теорема 2.1.5. из [44]). Непрерывно дифференцируемая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ является выпуклой и L -гладкой тогда и только тогда, когда для любых $x, y \in \mathbb{R}^d$ выполнены следующие неравенства:

$$0 \leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle \leq \frac{L}{2} \|x - y\|_2^2, \quad (\text{Л2.3})$$

$$\frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle, \quad (\text{Л2.4})$$

$$\frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq \langle \nabla f(x) - \nabla f(y), x - y \rangle. \quad (\text{Л2.5})$$

Доказательство. Докажем следующее:

$$\left\{ \begin{array}{l} \text{выпуклость} \\ \text{гладкость} \end{array} \right\} \implies (\text{Л2.3}) \implies (\text{Л2.4}) \implies (\text{Л2.5}) \implies \left\{ \begin{array}{l} \text{выпуклость} \\ \text{гладкость} \end{array} \right\}$$

Выпуклость + гладкость $\implies$ (Л2.3). Первое неравенство есть просто определение выпуклости, а второе является следствием из Теоремы Л2.4.

(Л2.3) $\implies$ (Л2.4). Рассмотрим $\phi(y) = f(y) - \langle \nabla f(x), y \rangle$ для некоторого фиксированного $x \in \mathbb{R}^d$. Удостоверимся, что $\phi(y)$ является L -гладкой:

$$\begin{aligned} \|\nabla \phi(y_1) - \nabla \phi(y_2)\|_2 &= \|\nabla f(y_1) - \nabla f(x) - \nabla f(y_2) + \nabla f(x)\|_2 \\ &= \|\nabla f(y_1) - \nabla f(y_2)\|_2 \leq L \|y_1 - y_2\|_2. \end{aligned}$$

Проверим также, что $\phi(y)$ выпуклая (по определению). Так как f выпуклая, для произвольных y_1 и y_2 имеем:

$$\begin{aligned} f(y_1) &\geq f(y_2) + \langle \nabla f(y_2), y_1 - y_2 \rangle \\ &\Updownarrow \\ f(y_1) - \langle \nabla f(x), y_1 \rangle &\geq f(y_2) - \langle \nabla f(x), y_2 \rangle + \langle \nabla f(y_2) - \nabla f(x), y_1 - y_2 \rangle \\ &\Updownarrow \\ \phi(y_1) &\geq \phi(y_2) + \langle \nabla \phi(y_2), y_1 - y_2 \rangle. \end{aligned}$$

А это и есть выпуклость $\phi(y)$. Заметим, что $\nabla\phi(x) = 0$, тогда в силу того, что функция ϕ выпуклая, то $y^* = x$ — точка глобального минимума (Теорема Л2.2). Откуда

$$\phi(x) = \phi(y^*) \leq \phi\left(y - \frac{1}{L}\nabla\phi(y)\right). \quad (\text{Л2.6})$$

Теперь применим первый пункт теоремы для $f \rightarrow \phi$, $y \rightarrow y - \frac{1}{L}\nabla\phi(y)$, $x \rightarrow y$:

$$\phi\left(y - \frac{1}{L}\nabla\phi(y)\right) - \phi(y) - \left\langle \nabla\phi(y), -\frac{1}{L}\nabla\phi(y) \right\rangle \leq \frac{1}{2L}\|\nabla\phi(y)\|_2^2,$$

а значит после небольшой перестановки получим:

$$\phi\left(y - \frac{1}{L}\nabla\phi(y)\right) \leq \phi(y) - \frac{1}{2L}\|\nabla\phi(y)\|_2^2. \quad (\text{Л2.7})$$

Осталось объединить (Л2.6) и (Л2.7):

$$\phi(x) \leq \phi(y) - \frac{1}{2L}\|\nabla\phi(y)\|_2^2,$$

и подставить ϕ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2.$$

Из этого легко получить то, что и хотели доказать

$$\frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle.$$

(Л2.4) $\implies$ (Л2.5). Запишем два раза (Л2.4):

$$\begin{aligned} \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 &\leq f(y) - f(x) - \langle \nabla f(x), y - x \rangle, \\ \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2 &\leq f(x) - f(y) - \langle \nabla f(y), x - y \rangle. \end{aligned}$$

Сложим эти два неравенства:

$$\frac{1}{L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq \langle \nabla f(x) - \nabla f(y), x - y \rangle.$$

(Л2.5) $\implies$ **выпуклость + гладкость**. Из (Л2.5) имеем, что:

$$0 \leq \langle \nabla f(x) - \nabla f(y), x - y \rangle.$$

Снова применим (Страница 84 из [42]) формулу Ньютона–Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор–функцией $r(\tau)$:

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

В нашем случае выберем кривую следующим образом $r(\tau) = x + \tau(y - x)$, где $\tau \in [0, 1]$:

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau \\ &= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau. \end{aligned}$$

Используя, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$, получим:

$$\begin{aligned} f(y) - f(x) &= \langle \nabla f(x), y - x \rangle + \int_0^1 \frac{1}{\tau} \cdot \langle \nabla f(x + \tau(y - x)) - \nabla f(x), \tau(y - x) \rangle d\tau \\ &\geq \langle \nabla f(x), y - x \rangle. \end{aligned}$$

А это и есть эквивалентное определение выпуклости для непрерывно дифференцируемой функции. Также (Л2.5) вместе с неравенством Коши–Буняковского–Шварца (0.3) дает:

$$\begin{aligned} \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2 &\leq \langle \nabla f(x) - \nabla f(y), x - y \rangle \\ &\leq \|\nabla f(x) - \nabla f(y)\|_2 \cdot \|x - y\|_2. \end{aligned}$$

Откуда

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2,$$

а это и есть Определение Л2.5. ■

Первое неравенство из Теоремы Л2.5 может быть полезно в понимании физического смысла L -гладкости (Рисунок Л2.2): функция «подперта» снизу линейной аппроксимацией, а сверху квадратичной функцией. Похожая ситуация с L -гладкой и μ -сильно выпуклой функцией. Из Теоремы Л2.5 и Определения Л2.4 легко заметить, что $L \geq \mu$.




Рис. Л2.2: Иллюстрация выпуклости, μ -сильной выпуклости и L -гладкости.

Упражнение Л2.1. Рассмотрите квадратичную функцию:

$$f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle,$$

где $b, x \in \mathbb{R}^d$, $A \in \mathbb{S}_{++}^d$. Покажите, что константы сильной выпуклости и гладкости можно оценить:

$$\mu \leq \lambda_{\min}(A), \quad L \geq \lambda_{\max}(A).$$

Упражнение Л2.2. Рассмотрите логистическую функцию потерь:

$$f(x) = -\frac{1}{n} \sum_{i=1}^n l(g(x, a_i), b_i) + \frac{\lambda}{2} \|x\|_2^2,$$

где $g : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \{0, 1\}$ — классификатор:

$$g(x, a_i) = \frac{1}{1 + \exp(-\langle x, a_i \rangle)},$$

а $l : \mathbb{R}^d \times \mathbb{R}^d \rightarrow [0, +\infty]$ — бинарная кросс-энтропия:

$$l(x, y) = y \log x + (1 - y) \log(1 - x),$$

$a_i \in \mathbb{R}^d$, $b_i \in \{0, 1\}$, $i = \overline{1, n}$ — данные, $x \in \mathbb{R}^d$ — целевая переменная, $\lambda \in \mathbb{R}_+$ — параметр регуляризации. Покажите, что константы сильной выпуклости и гладкости можно оценить:

$$\mu \leq \lambda, \quad L \geq \frac{1}{4n} \lambda_{\max}(A^\top A) + \lambda.$$

Л3 Градиентный спуск

Рассмотрим задачу безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x), \quad (\text{Л3.1})$$

где функция $f(x)$ дифференцируема.

Алгоритм Л3.1 Градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**


2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k)$

3: **end for**

Выход: x^K

Метод был придуман в середине XIX века Огюстеном Коши [8] для решения систем уравнений $Ax = b$, что эквивалентно решению задачи $\min_{x \in \mathbb{R}^d} \|Ax - b\|_2^2$. Идея метода очень естественна и понятна: градиент показывает направление роста функции, тогда антиградиент — направление убывания. Поэтому давайте пойдем вдоль текущего антиградиента. Сразу же возникает вопрос: а насколько далеко вообще стоит идти по направлению, указанному антиградиентом? Кажется, что не особо далеко, потому что градиент дает только локальную информацию в окрестности текущей точки о функции f , поэтому совсем непонятно, что же происходит вдали от неё.

Пример Л3.1. Рассмотрим градиентный спуск с постоянным шагом $\gamma_k = \gamma$ для простейшей задачи оптимизации $\min_{x \in \mathbb{R}} x^2$. Пусть наш метод стартует из точки $x^0 = 1$. Попробуем различные шаги γ .



1. $\gamma = \frac{1}{10}$: медленная, но монотонная сходимость.
2. $\gamma = \frac{1}{2}$: оптимальный шаг — метод достигает минимума за одну итерацию.
3. $\gamma \approx \frac{1}{1.1}$: наблюдаются колебания между ветвями параболы, но метод сходится.

4. $\gamma = 1$: критический шаг — метод циклично возвращается в исходную точку.

5. $\gamma \approx \frac{1}{0.95}$: метод расходится.

Попробуем построить теорию и доказать сходимость метода градиентного спуска, а также понять допустимые диапазоны шагов γ_k .

Л3.1 Градиентный спуск для гладких сильно выпуклых задач

Отметим сразу, что мы не оформляем дальнейшие рассуждения в виде теоремы, так как они приведут к «топорному» результату. Это пример того, что анализ даже самых простых методов может быть выполнен не лучшим образом. Из Теоремы Л2.3 мы знаем, что для сильно выпуклых функций решение x^* уникально. Попытаемся оценить, как меняется расстояние до него. Используя итерацию градиентного спуска, получаем

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2.\end{aligned}$$

Нужно как-то оценить полученное выражение. Воспользуемся условием оптимальности $\nabla f(x^*) = 0$ (Определение Л2.2) и запишем:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \quad (\text{Л3.2})$$

Для точек x^k и x^* воспользуемся μ -сильной выпуклостью (Определение Л2.4):

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2$$

и гладкостью (Определение Л2.5):

$$\|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq L^2 \|x^k - x^*\|_2^2.$$

Тогда после подстановки неравенств, имеем:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k \left(-\frac{\mu}{2} \|x^k - x^*\|_2^2 + f^* - f(x^k) \right) \\ &\quad + \gamma_k^2 L^2 \|x^k - x^*\|_2^2 \\ &= (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2 + 2\gamma_k (f^* - f(x^k)).\end{aligned}$$

Оценим нулем последнее слагаемое в силу того, что $f(x^k) \geq f^*$:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \gamma_k \mu + \gamma_k^2 L^2) \|x^k - x^*\|_2^2.$$

Хочется, чтобы расстояние до решения уменьшалось, а именно, $(1 - \gamma_k \mu + \gamma_k^2 L^2) < 1$, а лучше вообще найти $\arg\min_{\gamma_k} (1 - \gamma_k \mu + \gamma_k^2 L^2)$. Это несложно — минимизируем одномерную параболу по γ_k и получаем оптимальный шаг: $\gamma_k^* = \frac{\mu}{2L^2}$ и

$$1 - \gamma_k^* \mu + (\gamma_k^*)^2 L^2 = 1 - \frac{\mu^2}{4L^2}.$$

А значит,

$$\|x^{k+1} - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^k - x^*\|_2^2.$$

Это неравенство выполняется для всех $k = \overline{0, K-1}$. Подставим $k = K-1$:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-1} - x^*\|_2^2.$$

Теперь продолжим неравенство, подставляя $k = K-2$:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right) \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-2} - x^*\|_2^2 = \left(1 - \frac{\mu^2}{4L^2}\right)^2 \|x^{K-2} - x^*\|_2^2.$$

И так можно продолжать, вплоть до $k = 0$. Запустим рекурсию:

$$\begin{aligned} \|x^K - x^*\|_2^2 &\leq \left(1 - \frac{\mu^2}{4L^2}\right) \|x^{K-1} - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^2 \|x^{K-2} - x^*\|_2^2 \\ &\leq \left(1 - \frac{\mu^2}{4L^2}\right)^3 \|x^{K-3} - x^*\|_2^2 \leq \dots \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2. \end{aligned}$$

Получили линейную сходимость (Определение Л1.5). Попробуем найти оценку на число итераций, необходимых для достижения точности ε по аргументу: $\|x^K - x^*\|_2 \leq \varepsilon$. Для дальнейшего анализа часто применяют неравенство (0.4)

$$(1 - \alpha)^k \leq \exp(-\alpha k),$$

где $\alpha \in [0, 1]$, $k \in \mathbb{N}$. Его можно получить, записав определение выпуклости $\exp(-x)$ в точке 0:

$$\exp(-x) \geq 1 - x,$$

после чего возвести неравенство в степень k , поскольку обе части неравенства неотрицательны.

Заметим, что $\mu \leq L$ (Теорема Л2.5 и Определение Л2.4), а значит

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu^2}{4L^2}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Мы хотим гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{\mu^2}{4L^2} \cdot K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Тогда логарифмируем и получаем

$$K \geq \frac{4L^2}{\mu^2} \log\left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2}\right).$$

Но этот результат далеко не самый лучший. Анализ можно провести «тоньше».

Теорема Л3.1. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k)\right) \|x^0 - x^*\|_2^2. \quad (\text{Л3.3})$$

Доказательство. Начинаем с применения итерации градиентного спуска и условия оптимальности $\nabla f(x^*) = 0$ (Определение Л2.2):

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2 \\ &= \|x^k - x^*\|_2^2 + 2\gamma_k \langle \nabla f(x^k), x^* - x^k \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.\end{aligned}$$

Для точек x^k и x^* воспользуемся сильной выпуклостью (Определение Л2.4):

$$f^* \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2$$

и гладкостью (Теорема Л2.5):

$$\frac{1}{2L} \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \leq f(x^k) - f^* - \langle \nabla f(x^*), x^k - x^* \rangle,$$

в использовании последнего факта и кроется отличие. Тогда после подстановки неравенств, имеем:

$$\begin{aligned}\|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu}{2} \|x^k - x^*\|_2^2 + f(x^k) - f^* \right) \\ &\quad + 2\gamma_k^2 L (f(x^k) - f^* - \langle \nabla f(x^*), x^k - x^* \rangle) \\ &= (1 - \mu\gamma_k) \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).\end{aligned}\tag{Л3.4}$$

Воспользуемся тем, что $\gamma_k \leq \frac{1}{L}$, а $f(x^k) \geq f^*$, и оценим сверху нулем второе слагаемое:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Запустим рекурсию:

$$\begin{aligned}\|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1}) \|x^{K-1} - x^*\|_2^2 \\ &\leq (1 - \mu\gamma_{K-1})(1 - \mu\gamma_{K-2}) \|x^{K-2} - x^*\|_2^2 \\ &\leq \dots \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.\end{aligned}$$

■

Проведем анализ полученной оценки. Исходя из неравенства (Л3.3), можем заключить, что шаг γ_k следует брать максимально допустимым. В условии теоремы было наложено ограничение $\gamma_k \leq \frac{1}{L}$, поэтому, сформулируем утверждение о скорости сходимости при $\gamma_k = \frac{1}{L}$.

Утверждение Л3.1. Пусть задача удовлетворяет условиям Теоремы Л3.1 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Запишем оценку сходимости из Теоремы Л3.1:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k)\right) \|x^0 - x^*\|_2^2.$$

При $\gamma_k = \frac{1}{L}$ получаем:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Получили линейную сходимость (Определение Л1.5). Найдем оценку на число итераций. Заметим, что $\mu \leq L$ (Теорема Л2.5 и Определение Л2.4), а значит

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2 \leq \exp\left(-\frac{\mu}{L} \cdot K\right) \|x^0 - x^*\|_2^2.$$

Мы хотим гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \exp\left(-\frac{\mu}{L} \cdot K\right) \|x^0 - x^*\|_2^2 \leq \varepsilon^2.$$

Тогда логарифмируем и получаем

$$K \geq \frac{L}{\mu} \log \left(\frac{\|x^0 - x^*\|_2^2}{\varepsilon^2} \right).$$

■

Замечание Л3.1. В дальнейшем будем использовать $\mathcal{O}$ -нотацию для того, чтобы опускать численные константы, так как нас интересует величина, зависящая от параметров задачи. Формально, $f(L, \mu, \varepsilon) \in \mathcal{O}(g(L, \mu, \varepsilon))$, если существует число $C > 0$ такое, что при всех L, μ, ε выполняется

$$f(L, \mu, \varepsilon) \leq C \cdot g(L, \mu, \varepsilon).$$

Однако результат Теоремы Л3.1 можно ещё немного улучшить. Для этого понадобится следующее утверждение.

Утверждение Л3.2. Пусть функция $f: \mathbb{R}^d \rightarrow \mathbb{R}$ является μ -сильно выпуклой и L -гладкой, тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее неравенство:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{\mu L}{\mu + L} \|x - y\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x) - \nabla f(y)\|_2^2.$$

Доказательство. Рассмотрим функцию $\phi(x) = f(x) - \frac{\mu}{2}\|x\|_2^2$. Докажем, что эта функция является выпуклой и $(L-\mu)$ -гладкой. Выпуклость проверим по Определению Л2.3:

$$\begin{aligned}\phi(y) - \phi(x) - \langle \nabla \phi(x), y - x \rangle &= f(y) - \frac{\mu}{2}\|y\|_2^2 - f(x) + \frac{\mu}{2}\|x\|_2^2 \\ &\quad - \langle \nabla f(x) - \mu x, y - x \rangle \\ &= f(y) - f(x) - \langle \nabla f(x), y - x \rangle \\ &\quad + \frac{\mu}{2}(\|x\|_2^2 - \|y\|_2^2 + 2\langle x, y - x \rangle) \\ &= f(y) - f(x) - \langle \nabla f(x), y - x \rangle - \frac{\mu}{2}\|y - x\|_2^2 \geq 0.\end{aligned}\tag{Л3.5}$$

Последнее следует в силу сильной выпуклости f (Определение Л2.4). Таким образом показали выпуклость ϕ .

Для нахождения константы гладкости воспользуемся L -гладкостью f и неравенством (Л2.3) из Теоремы Л2.5:

$$f(y) - f(x) - \langle \nabla f(x), y - x \rangle \leq \frac{L}{2}\|y - x\|_2^2.\tag{Л3.6}$$

Тогда, подставляя оценку (Л3.6) в цепочку равенств (Л3.5), получаем для ϕ :

$$\begin{aligned}\phi(y) - \phi(x) - \langle \nabla \phi(x), y - x \rangle &= f(y) - f(x) - \langle \nabla f(x), y - x \rangle - \frac{\mu}{2}\|y - x\|_2^2 \\ &\leq \frac{L - \mu}{2}\|x - y\|_2^2.\end{aligned}$$

Из этого неравенства по Теореме Л2.5 следует $(L - \mu)$ -гладкость функции ϕ . По той же Теореме Л2.5 для ϕ можно записать неравенство (Л2.5):

$$(L - \mu)\langle \nabla \phi(x) - \nabla \phi(y), x - y \rangle \geq \|\nabla \phi(x) - \nabla \phi(y)\|_2^2.$$

Преобразуем обе части неравенства, подставив $\phi(x) = f(x) - \frac{\mu}{2}\|x\|_2^2$. Для левой части получим:

$$\begin{aligned}(L - \mu)\langle \nabla \phi(x) - \nabla \phi(y), x - y \rangle &= (L - \mu)\langle \nabla f(x) - \mu x - \nabla f(y) + \mu y, x - y \rangle \\ &= (L - \mu)\langle \nabla f(x) - \nabla f(y), x - y \rangle - (L - \mu)\mu\|x - y\|_2^2.\end{aligned}$$

Теперь для правой части неравенства:

$$\begin{aligned}\|\nabla \phi(x) - \nabla \phi(y)\|_2^2 &= \|\nabla f(x) - \mu x - \nabla f(y) + \mu y\|_2^2 \\ &= \|\nabla f(x) - \nabla f(y)\|_2^2 - 2\mu\langle \nabla f(x) - \nabla f(y), x - y \rangle + \mu^2\|x - y\|_2^2.\end{aligned}$$

Подставляем обе части:

$$\begin{aligned}(L - \mu)\langle \nabla f(x) - \nabla f(y), x - y \rangle - (L - \mu)\mu\|x - y\|_2^2 \\ \geq \|\nabla f(x) - \nabla f(y)\|_2^2 - 2\mu\langle \nabla f(x) - \nabla f(y), x - y \rangle + \mu^2\|x - y\|_2^2.\end{aligned}$$

После небольшого упрощения:

$$(L + \mu)\langle \nabla f(x) - \nabla f(y), x - y \rangle - L\mu\|x - y\|_2^2 \geq \|\nabla f(x) - \nabla f(y)\|_2^2.$$

Приведём к требуемому виду:

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{\mu L}{\mu + L}\|x - y\|_2^2 + \frac{1}{\mu + L}\|\nabla f(x) - \nabla f(y)\|_2^2.$$

■

Используя доказанное утверждение, можно получить следующий результат.

Теорема Л3.2. [Теорема 2.1.15. из [44]] Пусть задача безусловной оптимизации (Л3.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \leq \frac{2}{\mu+L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \right) \|x^0 - x^*\|_2^2.$$

Доказательство. Пойдем по уже известному пути (Л3.2):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \end{aligned}$$

Вычтем из первого аргумента скалярного произведения $\nabla f(x^*) = 0$:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \end{aligned}$$

Теперь используем результат Утверждения Л3.2, чтобы оценить скалярное произведение:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(\frac{\mu L}{\mu + L} \|x^k - x^*\|_2^2 + \frac{1}{\mu + L} \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \right) \\ &\quad + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2 \\ &= \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \|x^k - x^*\|_2^2 + \gamma_k \left(\gamma_k - \frac{2}{\mu + L} \right) \|\nabla f(x^k) - \nabla f(x^*)\|_2^2. \end{aligned}$$

Выбрав $\gamma_k \leq \frac{2}{\mu+L}$, имеем

$$\|x^{k+1} - x^*\|_2^2 \leq \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \|x^k - x^*\|_2^2.$$

Запустив рекурсию, получаем

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} \left(1 - \frac{2\gamma_k \mu L}{\mu + L} \right) \right) \|x^0 - x^*\|_2^2.$$

■

Как и в случае с предыдущей оценкой сходимости с произвольным достаточно малым шагом (Теорема Л3.1), сформулируем утверждение с теоретически максимально допустимым значением шага $\gamma_k = \frac{2}{\mu+L}$.

Утверждение Л3.3. Пусть задача удовлетворяет условиям Теоремы Л3.2 и выбрано значение шага $\gamma_k = \frac{2}{\mu+L}$. Тогда справедлива следующая оценка сходимости:

мости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{4\mu L}{(\mu + L)^2}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^k - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Доказательство аналогично доказательству Утверждения Л3.1. ■

Сравним результаты Теорем Л3.1 и Л3.2. С точки зрения $\mathcal{O}$ -оценок, результаты одинаковы, но можно сравнить $(1 - \frac{\mu}{L})$ и $(1 - \frac{4\mu L}{(\mu + L)^2})$. Легко заметить, что

$$\left(1 - \frac{4\mu L}{(\mu + L)^2}\right) < \left(1 - \frac{\mu}{L}\right)$$

при $\mu \neq L$, а значит, результаты Теоремы Л3.2 лучше. Однако более классическим является первый результат. Отчасти это из-за того, что оптимальное значение шага для той оценки $\gamma_k = \frac{1}{L}$ не требует от нас знания константы сильной выпуклости. В Примере Л3.1 можно видеть, что лучшая сходимость достигается при $\gamma_k = \gamma = \frac{1}{L} = \frac{2}{\mu + L} = \frac{1}{2}$.


Рассмотрим другой пример.

Пример Л3.2. Возьмём целевую функцию

$$f(x) = x^2 + \sqrt{1 + x^4}, \quad x \in \mathbb{R}.$$

Для нее константа сильной выпуклости $\mu = 2$, гладкости $L = 2 + 2\sqrt{2}$.

Построим график сходимости градиентного спуска при различных шагах из Теорем Л3.1 и Л3.2 для такой задачи, стартовая точка $x^0 \in \mathbb{R}^d$ одинаковая. Видим, что шаг $\frac{2}{L+\mu}$ показывает сходимость быстрее, чем $\frac{1}{L}$.



Л3.2 Градиентный спуск для гладких выпуклых задач

Рассматривается задача (Л3.1) с выпуклой целевой функцией f . Если мы попытаемся оценивать расстояние до решения $\|x^k - x^*\|_2$, то можем столкнуться с проблемой, что решение для выпуклой задачи может быть не единственным. Это иллюстрирует Пример Л2.1. Следовательно, надо строить другие оценки. Одним из решений является построение оценок на сходимость по функции. То есть будем наблюдать за разностью

$$f(x^k) - f^*.$$

Однако встаёт проблема существования конечного решения. В Примере Л2.2 был показан случай, когда минимум $f^* = -\infty$ достигается на бесконечности. Поэтому будем требовать конечности $f^* > -\infty$, чтобы гарантировать сходимость к некоторому существующему минимуму x^* . Здесь и далее в выпуклом случае под x^* будем понимать некоторую (необязательно единственную, но существующую) точку глобального минимума.

Докажем сперва вспомогательное утверждение о том, что значение функции убывает от итерации к итерации.

Утверждение Л3.4. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, выпуклой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k \in (0, \frac{2}{L})$ справедливо, что $f(x^{k+1}) \leq f(x^k)$.

Доказательство. Воспользуемся L -гладкостью (Теорема Л2.5):

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &= f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned} \tag{Л3.7}$$

Если $\gamma_k \in (0, \frac{2}{L})$, то $f(x^{k+1}) \leq f(x^k)$. ■

Это предложение не просто является вспомогательным фактом, оно отражает и физику градиентного спуска. Шаг метода подбирается исходя из верхней ограничивающей квадратичной функции/параболы, возникающей из-за гладкости. Как и в Примере Л3.1, нам нельзя делать большие шаги, иначе мы перескочим на противоположную ветвь параболы относительно оптимума и можем оказаться выше той точки, где находились до этого. Поэтому и подбирается шаг «осторожно», исходя из худшего варианта скорости/резкости роста функции (верхней оценки). При этом можно заметить, что если мы выбираем $\gamma_k = \frac{1}{L}$, то мы минимизируем выражение (Л3.7):

$$f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2,$$

то есть каждый раз мы минимизируем локальную верхнюю ограничивающую параболу на поведение нашей функции (Рисунок Л3.1).

Теорема Л3.3. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой выпуклой целевой функцией f решается с помощью градиентного спуска (Алго-




Рис. ЛЗ.1: Иллюстрация шага градиентного спуска с оптимальным $\gamma_k = \frac{1}{L}$.

ритм ЛЗ.1). Тогда при $\gamma_k \leq \frac{1}{2L}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Доказательство. Начнем доказательство с оценки (ЛЗ.4) с $\mu = 0$:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*).$$

Учтем, что $\gamma_k L - 1 \leq -\frac{1}{2}$ из-за ограничения на размер шага $\gamma_k \leq \frac{1}{2L}$:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 + 2\gamma_k(\gamma_k L - 1)(f(x^k) - f^*) \\ &\leq \|x^k - x^*\|_2^2 - \gamma_k(f(x^k) - f^*). \end{aligned}$$

Перетасуем неравенство:

$$\gamma_k(f(x^k) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2.$$

Суммируя по всем итерациям от 0 до $K - 1$:

$$\begin{aligned} \sum_{k=0}^{K-1} \gamma_k(f(x^k) - f^*) &\leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2. \end{aligned}$$

Воспользуемся Утверждением ЛЗ.4 и заметим, что $f(x^K) \leq f(x^k)$, $k = \overline{0, K}$:

$$(f(x^K) - f^*) \sum_{k=0}^{K-1} \gamma_k \leq \|x^0 - x^*\|_2^2.$$

Откуда получаем, что

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

■

Утверждение Л3.5. Пусть задача удовлетворяет условиям Теоремы Л3.3 и выбрано значение шага $\gamma_k = \frac{1}{2L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{K}.$$

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Начнем с оценки из Теоремы Л3.3:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Подставим фиксированный шаг $\gamma_k = \frac{1}{2L}$, получим требуемое:

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{\sum_{k=0}^{K-1} \gamma_k} = \frac{2L\|x^0 - x^*\|_2^2}{K}.$$

Это сублинейная сходимость (Определение Л1.5). Чтобы получить оценку на число итераций, отметим, что мы хотим гарантировать:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{K} \leq \varepsilon.$$

Тогда получаем

$$K \geq \frac{2L\|x^0 - x^*\|_2^2}{\varepsilon}.$$

■

Как и в сильно выпуклом случае, данный анализ можно немного улучшить.

Теорема Л3.4. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой выпуклой целевой функцией f решается с помощью градиентного спуска (Алго-

ритм ЛЗ.1). Тогда при $\gamma_k \in [0, \frac{1}{L}]$ справедлива следующая оценка сходимости:

$$f(x^K) - f(x^*) \leq \frac{\|x^0 - x^*\|_2^2}{2 \sum_{k=0}^{K-1} \gamma_k}.$$

Доказательство. Начнём уже привычным образом:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma_k \nabla f(x^k) - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \langle \nabla f(x^k), x^k - x^* \rangle + \gamma_k^2 \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Воспользуемся выпуклостью: $f(x^*) \geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle$ (Определение ЛЗ.3):

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2. \quad (\text{ЛЗ.8})$$

Далее применим результат (ЛЗ.7), а именно оценим $\|\nabla f(x^k)\|_2^2$:

$$\|\nabla f(x^k)\|_2^2 \leq \frac{2}{\gamma_k(2 - L\gamma_k)} (f(x^k) - f(x^{k+1})).$$

Здесь учитывается, что $\gamma_k \in (0, \frac{2}{L})$. Объединяя два предыдущих выражения, получаем

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^k) - f^*) + \frac{2\gamma_k}{2 - L\gamma_k} (f(x^k) - f(x^{k+1})).$$

Продолжим цепочку неравенств, приняв во внимание $f^* \leq f(x^{k+1}) \leq f(x^k)$ (Утверждение ЛЗ.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^k) - f^*) + \frac{2\gamma_k}{2 - L\gamma_k} (f(x^k) - f(x^{k+1})) \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k \left(1 - \frac{1}{2 - L\gamma_k}\right) f(x^k) - \frac{2\gamma_k}{2 - L\gamma_k} f(x^{k+1}) + 2\gamma_k f^* \\ &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \left(1 - \frac{1}{2 - L\gamma_k}\right) f(x^{k+1}) - \frac{2\gamma_k}{2 - L\gamma_k} f(x^{k+1}) + 2\gamma_k f^* \\ &= \|x^k - x^*\|_2^2 - 2\gamma_k (f(x^{k+1}) - f^*). \end{aligned}$$

После небольшой перестановки:

$$2\gamma_k (f(x^{k+1}) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2.$$

Суммируем по всем k от 0 до $K-1$, имеем:

$$\begin{aligned} 2 \sum_{k=0}^{K-1} \gamma_k (f(x^{k+1}) - f^*) &\leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2) \\ &= \|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2 \leq \|x^0 - x^*\|_2^2. \end{aligned}$$

Воспользуемся Утверждением ЛЗ.4:

$$2(f(x^K) - f^*) \sum_{k=0}^{K-1} \gamma_k \leq \|x^0 - x^*\|_2^2.$$

Откуда получаем, что

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2 \sum_{k=0}^{K-1} \gamma_k}.$$

■

Подберем оптимальное значение шага. Как видно из оценки, шаг стоит выбирать максимальным из возможных. Сформулируем отдельное утверждение для $\gamma_k = \frac{1}{L}$.

Утверждение Л3.6. Пусть задача удовлетворяет условиям Теоремы Л3.4 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{L\|x^0 - x^*\|_2^2}{2K}.$$

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Доказательство аналогично доказательству Утверждения Л3.5. ■

Сравним результаты Теорем Л3.3 и Л3.4. С точки зрения $\mathcal{O}$ -оценок, результаты одинаковы, но численный фактор в Теореме Л3.4 лучше.

Л3.3 Градиентный спуск для гладких невыпуклых задач

Теорема Л3.5. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой целевой функцией f решается с помощью градиентного спуска (Алгоритм Л3.1). Тогда при $\gamma_k = \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|\nabla f(\hat{x}^K)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K},$$

где $\hat{x}^K$ — специально выбранная точка из $\{x^k\}$. Более того, чтобы добиться точности ε по норме градиента ($\|\nabla f(x^K)\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{2L(f(x^0) - f^*)}{\varepsilon^2}\right) \text{ итераций.}$$

Здесь $f^* > -\infty$ — глобальный минимум функции.

В данной теореме есть сходимость только к стационарной точке (для невыпуклых функций нет гарантий, что это экстремум), и предполагается существование конечного глобального минимума f^* .

Доказательство. Воспользуемся L -гладкостью (Теорема Л2.4):

$$f(x^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|_2^2.$$

Подставим итерационный шаг градиентного спуска:

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \gamma_k \|\nabla f(x^k)\|_2^2 + \frac{L\gamma_k^2}{2} \|\nabla f(x^k)\|_2^2 \\ &\leq f(x^k) - \gamma_k \left(1 - \frac{L\gamma_k}{2}\right) \|\nabla f(x^k)\|_2^2. \end{aligned}$$

Возьмем $\gamma_k = \frac{1}{L}$. Тогда

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2,$$

или после небольших перестановок:

$$\|\nabla f(x^k)\|_2^2 \leq 2L(f(x^k) - f(x^{k+1})).$$

Суммируя по всем итерациям от 0 до $K-1$, получаем:

$$\sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq 2L(f(x^0) - f(x^K)) \leq 2L(f(x^0) - f^*).$$

Здесь мы воспользовались существованием глобального минимума f^* . Усредним по K :

$$\frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K}.$$

Из левой части непонятно, для какой точки мы получили гарантии сходимости. С такой мы проблемой еще не сталкивались, есть несколько способов ее решить:

- Равномерный случайный выбор $\hat{x}^K$ из $x^0, \dots, x^{K-1}$:

$$\mathbb{E} \left[\|\nabla f(\hat{x}^K)\|_2^2 \right] = \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K};$$

- Выбор точки с минимальным по норме градиентом $\hat{x}^K = \operatorname{argmin}_{k \in \{0, K-1\}} \|\nabla f(x^k)\|_2^2$:

$$\|\nabla f(\hat{x}^K)\|_2^2 = \min_{k \in \{0, K-1\}} \|\nabla f(x^k)\|_2^2 \leq \frac{1}{K} \sum_{k=0}^{K-1} \|\nabla f(x^k)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K}.$$

В любом случае получаем сублинейную сходимость (Определение Л1.5). Чтобы получить оценку на число итераций, потребуем

$$\|\nabla f(\hat{x}^K)\|_2^2 \leq \frac{2L(f(x^0) - f^*)}{K} \leq \varepsilon^2.$$

Тогда получаем

$$K \geq \frac{2L(f(x^0) - f^*)}{\varepsilon^2}.$$

■

Л3.4 Выбор шага градиентного спуска

До этого момента мы доказывали сходимость градиентного спуска для L -гладких функций при достаточно малом шаге γ_k , а затем формулировали утверждения, в которых фиксировали максимально допустимый шаг. Однако в реальных задачах мы не всегда знаем, как подбирать шаг. Во-первых, это может происходить, поскольку нам может не быть известно, является ли функция L -гладкой, но это не означает, что градиентный спуск не будет работать. Во-вторых, нам может быть неизвестна константа липшищности градиента L , от которой зависит теоретическое значение оптимального размера шага. Начнем с метода, который опирается на L -гладкость функции.

Л3.4.1 Линейный поиск значения L

Обратимся к результатам Утверждения Л3.4. В ходе доказательства мы получили оценку (Л3.7) на значение функции f на следующей итерации:

$$f(x^{k+1}) \leq f(x^k) + \underbrace{\left(\frac{L\gamma^2}{2} - \gamma \right)}_{\rightarrow \min} \|\nabla f(x^k)\|_2^2 = \left[\gamma = \frac{1}{L} \right] = f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|_2^2.$$

Из оценки выше сразу же появляется идея для поиска L и шага $\frac{1}{L}$: увеличиваем L в ρ раз, пока условие выше не начинает выполняться. Такого рода подбор называется линейным поиском. Полученную идею можно встроить в метод градиентного спуска (Алгоритм Л3.1), добавив поиск L на каждой итерации.

Алгоритм Л3.2 Градиентный спуск с линейным поиском L

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $L_0 > 0$, параметр $\rho > 1$, число итераций K

```
1: for  $k = 0, 1, \dots, K - 1$  do
2:    $L_{k+1} = \frac{1}{\rho} \cdot L_k$ 
3:    $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f(x^k)$ 
4:   while  $f(x^{k+1}) > f(x^k) - \frac{1}{2L_{k+1}} \|\nabla f(x^k)\|_2^2$  do
5:      $L_{k+1} = \rho \cdot L_{k+1}$ 
6:      $x^{k+1} = x^k - \frac{1}{L_{k+1}} \nabla f(x^k)$ 
7:   end while
8: end for
Выход:  $x^K$ 
```

В процедуру поиска L добавлена строка 2 с уменьшением L , чтобы на каждой итерации пытаться увеличить шаг для лучшей сходимости.

Замечание Л3.2. При использовании линейного поиска L (Алгоритм Л3.2) к итоговой оракульной и итерационной сложности метода добавляется лишь логарифмическое слагаемое.

Замечание Л3.3. Для μ -сильно выпуклых L -гладких функций можно построить критерий выбора шага, зависящий одновременно от μ и от L , но поиск пары (μ, L) становится двумерным и несколько усложняет процедуру. При этом при выборе $\gamma_k = \frac{1}{L}$ линейный характер сходимости сохраняется, хотя может наблюдаться потеря в эффективной константе сходимости.

Л3.4.2 Степенной шаг

В качестве простой альтернативы можно использовать убывающий с номером итерации шаг:

$$\gamma_k := \frac{\gamma}{\delta + (ak + b)^p}, \quad \gamma, \delta, a, b, p > 0.$$

Наиболее часто применяются на практике $\gamma_k = \frac{1}{k+1}$ и $\gamma_k = \frac{1}{\sqrt{k+1}}$.

Л3.4.3 Наискорейший спуск

Итерация градиентного спуска выглядит следующим образом:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Посмотрим на значение целевой функции после сделанного шага как на функцию от одного аргумента γ_k :

$$\phi(\gamma_k) := f(x^k - \gamma_k \nabla f(x^k)). \quad (\text{Л3.9})$$

Поскольку стоит задача минимизации f , то будем выбирать шаг γ_k так, чтобы минимизировать значение функции $\phi(\gamma_k)$:

$$\gamma_k^* = \operatorname{argmin}_{\gamma_k > 0} \phi(\gamma_k) = \operatorname{argmin}_{\gamma_k > 0} f(x^k - \gamma_k \nabla f(x^k)).$$

Такой выбор шага называется *наискорейшим спуском*. Получим важное свойство шага, выпишем необходимое условие оптимума:

$$\begin{aligned} \phi'(\gamma_k^*) &= \left. \frac{\partial f(x^k - \gamma_k \nabla f(x^k))}{\partial \gamma_k} \right|_{\gamma_k = \gamma_k^*} = -\langle \nabla f(x^k - \gamma_k^* \nabla f(x^k)), \nabla f(x^k) \rangle \\ &= -\langle \nabla f(x^{k+1}), \nabla f(x^k) \rangle = 0. \end{aligned}$$

Итак, свойство заключается в следующем: градиент в точке, куда мы шагаем, ортогонален направлению, вдоль которого мы шагаем. Действительно, если бы это было не так, то можно было бы сделать шаг в направлении градиента, чтобы уменьшить значение функции, что противоречит определению шага наискорейшего спуска. Рисунок Л3.2 иллюстрирует это свойство. В качестве целевой функции взята квадратичная функция на $\mathbb{R}^2$, эллипсами показаны линии уровня этой функции. Градиенты в каждой точке направлены ортогонально линии уровня, проходящей через эту точку.

Замечание Л3.4. Если функция f — сильно выпуклая, то её одномерное сужение вдоль направления градиента $\phi(\gamma_k) = f(x^k - \gamma_k \nabla f(x^k))$ в точке $x^k \neq x^*$ — также сильно выпуклая функция.

Оптимальное значение шага γ_k можно находить с помощью методов одномерной оптимизации. Эти методы используют лишь значения функции и не требуют дополнительных вычислений градиента, что делает их особенно эффективными, когда вычисление функции существенно дешевле вычисления градиента. На практике часто бывает достаточно приближённого значения γ_k^* . При этом методы одномерной оптимизации не предъявляют требований ни к липшицевости, ни даже к выпуклости минимизируемой функции скалярного аргумента — достаточно, чтобы функция ϕ была унимодальной на рассматриваемом отрезке.




Рис. ЛЗ.2: Наискорейший градиентный спуск для квадратичной задачи. Эллипсы соответствуют уровням функции. Черным показано направление градиента, пунктиром — продолжение направления градиента.

Определение ЛЗ.1. Одномерная функция $\phi : [a, b] \rightarrow \mathbb{R}$ называется *униmodalьной* на $[a, b]$, если существует $c^* \in [a, b]$ такое, что:

1. Для произвольных $x, y \in [a, c^*]$, таких что $x < y$, выполнено $\phi(x) > \phi(y)$;
2. Для произвольных $x, y \in [c^*, b]$, таких что $x < y$, выполнено $\phi(x) < \phi(y)$.

Замечание ЛЗ.5. Если функция f является сильно выпуклой, то полученная в точке $x^k \neq x^*$ функция ϕ (Уравнение (ЛЗ.9)) будет униmodalьной.

Первым методом для поиска минимума униmodalьных функций будет метод дихотомии. Дополнительно предположим, что нам известен отрезок $[a_0, b_0]$, на котором находится оптимум ϕ . В случае с градиентным спуском, это может быть отрезок $[0, \frac{2}{L}]$, если нам известна константа гладкости, либо $[0, b]$, где b взято достаточно большим, если L нам неизвестна. Будем искать $\gamma^* = \operatorname{argmin}_{\gamma \in [a, b]} \phi(\gamma)$.

Алгоритм Л3.3 Вычисление γ_k с помощью метода дихотомии

Вход: отрезок поиска $[a_0, b_0]$, количество итераций K

```
1: for  $k = 0, \dots, K - 1$  do
2:    $\gamma_k = \frac{a_k + b_k}{2}$ 
3:    $\delta_k = \frac{a_k - b_k}{4}$ 
4:    $x_k = \gamma_k - \delta_k$ 
5:    $y_k = \gamma_k + \delta_k$ 
6:   if  $\phi(\gamma_k) \leq \min\{\phi(x_k), \phi(y_k)\}$  then
7:      $a_{k+1} = x_k$ 
8:      $b_{k+1} = y_k$ 
9:   else if  $\phi(x_k) < \phi(\gamma_k)$  then
10:     $a_{k+1} = a_k$ 
11:     $b_{k+1} = \gamma_k$ 
12:   else
13:     $a_{k+1} = \gamma_k$ 
14:     $b_{k+1} = b_k$ 
15:   end if
16: end for
Выход:  $\gamma_K = \frac{a_K + b_K}{2}$ 
```

Упражнение Л3.1. Докажите корректность метода дихотомии (Алгоритм Л3.3) для унимодальных функций и выведите следующую оценку сходимости метода по аргументу:

$$\left| \gamma^K - \gamma^* \right| \leq \left(\frac{1}{2} \right)^K \frac{b_0 - a_0}{2}.$$

Другой метод для поиска минимума унимодальной функции — метод золотого сечения. Постановка задачи такая же: ищем $\gamma^* = \operatorname{argmin}_{\gamma \in [a, b]} \phi(\gamma)$. Отличие от метода дихотомии заключается в том, в каких точках мы смотрим значения функции.

Алгоритм Л3.4 Вычисление γ_k с помощью золотого сечения

Вход: отрезок поиска $[a_0, b_0]$, число итераций K

```
1:  $\varphi = \frac{\sqrt{5}-1}{2}$ 
2:  $x_0 = b_0 - \varphi(b_0 - a_0)$ 
3:  $y_0 = a_0 + \varphi(b_0 - a_0)$ 
4: for  $k = 0, \dots, K - 1$  do
5:   if  $\phi(x_k) < \phi(y_k)$  then
6:      $a_{k+1} = a_k$ 
7:      $b_{k+1} = y_k$ 
8:      $y_{k+1} = x_k$ 
9:      $x_{k+1} = b_{k+1} - \varphi(b_{k+1} - a_{k+1})$ 
10:  else
11:     $a_{k+1} = x_k$ 
12:     $b_{k+1} = b_k$ 
13:     $x_{k+1} = y_k$ 
14:     $y_{k+1} = a_{k+1} + \varphi(b_{k+1} - a_{k+1})$ 
15:  end if
16: end for
Выход:  $\gamma_k = \frac{a_k + b_k}{2}$ 
```

Разбиение с помощью золотого сечения позволяет нам переиспользовать точки с преды-

дущей итерации: это заметно по строкам 7 и 11 алгоритма. Это приводит к уменьшению количества обращений к функции.

Упражнение Л3.2. Докажите корректность метода золотого сечения (Алгоритм Л3.4) для унимодальных функций и выведите оценку сложности метода по аргументу:

$$|\gamma^K - \gamma^*| \leq \left(\frac{\sqrt{5} - 1}{2} \right)^K \frac{b_0 - a_0}{2}.$$

Упражнение Л3.3. Сравните теорию методов дихотомии и золотого сечения. Какой из них быстрее сходится с точки зрения количества итераций? А с точки зрения обращений к функции?

Л3.4.4 Шаг Поляка–Шора

Рассмотрим другой подход к выбору шага, основанный на минимизации верхней оценки на расстояние до решения, полученной ранее. В ходе доказательства Теоремы Л3.4 о сходимости градиентного спуска для гладких выпуклых функций мы получили неравенство (Л3.8):

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k(f(x^k) - f^*) + \gamma_k^2 \|\nabla f(x^k)\|_2^2.$$

Правая часть неравенства является квадратичной функцией относительно шага γ_k . Попробуем выбрать γ_k так, чтобы минимизировать эту верхнюю оценку. Для этого найдем производную по γ_k и приравняем ее к нулю:

$$-2(f(x^k) - f^*) + 2\gamma_k^* \|\nabla f(x^k)\|_2^2 = 0.$$

Отсюда получаем оптимальное значение шага, минимизирующее данную оценку:

$$\gamma_k^* = \frac{f(x^k) - f^*}{\|\nabla f(x^k)\|_2^2}.$$

Этот выбор шага известен как *шаг Поляка–Шора* (Параграф 5.3 из [32]). В общем виде шаг Поляка–Шора записывается с параметром $\alpha > 0$:

$$\gamma_k^* := \frac{f(x^k) - f^*}{\alpha \|\nabla f(x^k)\|_2^2}.$$

Значение функции в оптимуме часто неизвестно, поэтому в формуле вместо f^* используют некоторую нижнюю оценку. Например, для задачи наименьших квадратов целевая функция неотрицательна $f(x) = \|Ax - b\|_2^2 \geq 0$. При использовании оценки параметр α позволяет корректировать шаг в зависимости от точности оценки минимума.

Л3.4.5 Стратегия бэктрекинга для подбора размера шага

Введем в рассмотрение $\phi(\gamma_k) = f(x^k + \gamma_k h^k)$, где h^k — произвольное направление, также рассмотрим некоторые константы β_1, β_2 , удовлетворяющие условию $0 < \beta_1 < \beta_2 < 1$ (обычно $0 < \beta_1 < 0.3, 0.9 < \beta_2 < 1$). Сформулируем несколько эвристик, которые будут полезными при выборе размера шага:

- **Условие достаточного убывания** гарантирует, что функция в точке x^{k+1} не превосходит линейной аппроксимации с коэффициентом наклона β_1 :

$$f(x^{k+1}) \leq f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle,$$

что эквивалентно

$$\phi(\gamma_k) \leq \phi(0) + \beta_1 \gamma_k \phi'(0).$$

Это условие возникает из первого порядка разложения функции вдоль направления h^k и требует, чтобы новое значение оказалось ниже касательной с запасом, обеспечивая контролируемое убывание функции и гарантируя конечность процедуры подбора шага.

- **Условие существенного убывания** гарантирует, что функция в точке x^{k+1} не меньше линейной аппроксимации с коэффициентом наклона β_2 :

$$f(x^{k+1}) \geq f(x^k) + \beta_2 \gamma_k \langle \nabla f(x^k), h^k \rangle,$$

или в другой записи

$$\phi(\gamma_k) \geq \phi(0) + \beta_2 \gamma_k \phi'(0).$$

Данное условие добавляет нижнюю границу на допустимое уменьшение функции, отсекая слишком малые шаги, при которых уменьшение происходит чересчур медленно и сходимость ухудшается.

- **Условие кривизны** гарантирует, что угол наклона касательной в точке x^{k+1} не меньше, чем угол наклона касательной в точке x^k , умноженный на β_2 :

$$\langle \nabla f(x^{k+1}), h^k \rangle \geq \beta_2 \langle \nabla f(x^k), h^k \rangle,$$

что можно также записать как:

$$\phi'(\gamma_k) \geq \beta_2 \phi'(0).$$

Оно контролирует скорость изменения функции вдоль направления h^k , предотвращая выбор слишком больших шагов, после которых производная становится близкой к нулю и функция перестаёт заметно убывать.

Рассмотрим комбинации условий:

- Правило Армихо (достаточное убывание).

Алгоритм ЛЗ.5 Вычисление γ_k с помощью правила Армихо

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $\gamma_k > 0$, $0 < \beta_1 < 1$, $0 < \rho < 1$,
 $\langle \nabla f(x^k), h^k \rangle < 0$
1: $x^{k+1} = x^k + \gamma_k h^k$
2: **while** $f(x^{k+1}) > f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle$ **do**
3: $\gamma_k = \rho \cdot \gamma_k$
4: $x^{k+1} = x^k + \gamma_k h^k$
5: **end while**
Выход: $\frac{\gamma_k}{\rho}$




Рис. Л3.3: Иллюстрация правила Армихо.

- Вольфа (достаточное убывание + кривизна).

Алгоритм Л3.6 Вычисление γ_k с помощью правила Вольфа

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, начальное значение $\gamma_k > 0$, $l = 0$, $u = \infty$, $\varepsilon > 0$, $0 < \beta_1 < \beta_2 < 1$, $\langle \nabla f(x^k), h^k \rangle < 0$

```

1: while  $u - l > \varepsilon$  do
2:   if  $f(x^{k+1}) > f(x^k) + \beta_1 \gamma_k \langle \nabla f(x^k), h^k \rangle$  then
3:      $u = \gamma_k$ 
4:      $\gamma_k = \frac{l+u}{2}$ 
5:   else
6:     if  $\langle \nabla f(x^{k+1}), h^k \rangle < \beta_2 \langle \nabla f(x^k), h^k \rangle$  then
7:        $l = \gamma_k$ 
8:       if  $u = \infty$  then
9:          $\gamma_k = 2 \cdot l$ 
10:      else
11:         $\gamma_k = \frac{l+u}{2}$ 
12:      end if
13:    end if
14:  end if
15: end while
Выход:  $\gamma_k$ 

```

Иллюстрация условий на Рисунке Л3.4.

- Усиленное правило Вольфа (достаточное убывание + кривизна с двух сторон).
В этом случае условие на строке 6 в Алгоритме Л3.6 заменяется на

$$\left| \langle \nabla f(x^{k+1}), h^k \rangle \right| < \beta_2 \left| \langle \nabla f(x^k), h^k \rangle \right|, \quad \beta_2 \in (0, 1). \quad (\text{Л3.10})$$

Иллюстрация условий на Рисунке Л3.5.

- Правильно Гольдштейна (достаточное убывание + существенное убывание):

Рассматриваются $\beta_2 = 1 - \beta_1$ и $\beta_1 \in (0, \frac{1}{2})$. В этом случае условие на строке 6 в Алгоритме ЛЗ.6 заменяется на

$$f(x^{k+1}) < f(x^k) + (1 - \beta_1)\gamma_k \langle \nabla f(x^k), h^k \rangle.$$

Иллюстрация условий на Рисунке ЛЗ.6.




Рис. ЛЗ.4: Иллюстрация условия Вольфа.

Про условия Вольфа верно утверждение, что подходящее значение шага существует.

Утверждение ЛЗ.7 (Лемма 3.1 из [31]). Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — непрерывно дифференцируема. Пусть h_k — направление убывания в точке x^k , и предположим, что f ограничена снизу на луче $\{x^k + \gamma_k h^k \mid \gamma_k > 0\}$. Тогда при $0 < \beta_1 < \beta_2 < 1$ существуют интервалы шагов, удовлетворяющие правилу Вольфа (Алгоритм ЛЗ.6) и усиленному правилу Вольфа (Алгоритм ЛЗ.6 и неравенство (ЛЗ.10)).




Рис. Л3.5: Иллюстрация усиленного правила Вольфа.




Рис. Л3.6: Иллюстрация правила Гольдштейна.

Л4 Ускоренные и оптимальные методы

В Параграфе Л3 была доказана сходимость градиентного спуска для L -гладких и μ -сильно выпуклых задач. В ней было показано, что для получения ε -решения по аргументу необходимо совершить $\mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right)$ оракульных вызовов. Логичный вопрос — хорошая ли это оценка, или её можно улучшить? Обсудим это в этом параграфе.

Л4.1 Метод тяжёлого шарика


Первое предложение по усовершенствованию градиентного спуска — использовать память с предыдущих итераций, добавив к алгоритму «инерцию». Такую эвристику Б.Т. Поляк в 1964 году предложил в методе тяжёлого шарика [33]:

Алгоритм Л4.1 Метод тяжёлого шарика


Вход: стартовая точка $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k \nabla f(x^k) + \tau_k (x^k - x^{k-1})$
- 3: **end for**

Выход: x^K



(a) Градиентный спуск.



(b) Метод тяжёлого шарика с $\tau = 0.9$.

Рис. Л4.1: Сравнение 6 шагов траекторий градиентного спуска и метода тяжёлого шарика с постоянным шагом $\gamma = 0.1$ при минимизации квадратичной функции $f(x) = \frac{1}{2} \langle x, Ax \rangle$, где $A = \text{diag}(1, 5)$. Эллипсы соответствуют уровням функции. На рисунке справа черным пунктиром показано направление градиента, серым пунктиром — инерция с прошлого шага.

У такой модели есть несколько плюсов. Во-первых, у метода понятная физика и интуиция: направления шага на новой итерации не должно сильно расходиться с направлением, в котором двигались ранее. Во-вторых, этот метод легок в имплементации: мы должны дополнительно хранить только координаты предыдущего состояния, а при вычислении нового просто добавлять слагаемое, отвечающее за «моментум». Однако у такого метода есть и ряд минусов. Помимо подбора шага, теперь необходимо подбирать параметр τ_k , который отвечает за инерцию, хотя обычно его берут близким к единице. Кроме того, мы должны найти ответ на исходный вопрос — лучше ли теоретические оценки сходимости? Для начала, рассмотрим оценки для метода на квадратичной задаче оптимизации.

Теорема Л4.1 (Теорема 3 из [33]). Пусть имеется квадратичная функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle,$$

где A — матрица с положительными собственными числами на отрезке $[\mu, L]$. Пусть задача безусловной оптимизации (Л3.1) решается методом тяжёлого шарика (Алгоритм Л4.1). Тогда при

$$\gamma_k = \gamma = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \tau_k = \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2 \leq \sqrt{2} \cdot \left(\frac{\sqrt{L}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O} \left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right) \text{ итераций.}$$

Доказательство. Функция f является μ -сильно выпуклой (Упражнение Л2.1), поэтому решение единственное (Теорема Л2.3). И так как метод тяжёлого шарика использует в итерации две точки, то модифицируем критерий сходимости и будем рассматривать не только последнюю точку, но и предыдущую. Для этого перепишем метод тяжёлого шарика в векторной форме:

$$\begin{pmatrix} x^{k+1} \\ x^k \end{pmatrix} = \begin{pmatrix} (1+\tau)I_d & -\tau I_d \\ I_d & 0 \end{pmatrix} \begin{pmatrix} x^k \\ x^{k-1} \end{pmatrix} + \begin{pmatrix} -\gamma \nabla f(x^k) \\ 0 \end{pmatrix}. \quad (\text{Л4.1})$$

Введём вектор отклонения от решения: $e^k = x^k - x^*$ и заметим, что для квадратичной функции $f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$ градиент $\nabla f(x) = Ax - b$. В точке минимума x^* градиент обнуляется: $Ax^* = b$, поэтому:

$$\nabla f(x^k) = Ax^k - b = A(x^k - x^*) = Ae^k.$$

Тогда (Л4.1) можно переписать как

$$\begin{pmatrix} e^{k+1} \\ e^k \end{pmatrix} = \begin{pmatrix} (1+\tau)I_d - \gamma A & -\tau I_d \\ I_d & 0 \end{pmatrix} \begin{pmatrix} e^k \\ e^{k-1} \end{pmatrix}.$$

Это задаёт рекуррентное соотношение с матрицей итераций

$$\hat{A} = \begin{pmatrix} (1+\tau)I_d - \gamma A & -\tau I_d \\ I_d & 0 \end{pmatrix}.$$

Запустим рекурсию:

$$\begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} = \hat{A}^K \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix}$$

и оценим норму $\begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix}$:

$$\left\| \begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} \right\|_2 = \left\| \hat{A}^K \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix} \right\|_2 \leq \|\hat{A}^K\|_2 \left\| \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix} \right\|_2.$$

Здесь мы воспользовались свойством из Замечания С1.6.

Теперь нам необходимо оценить $\|\hat{A}^K\|_2$. Воспользуемся неравенством Гельфанда (Задача 1 Лекции 37 из [48]): для любого положительного δ найдётся K такое, что $\|\hat{A}^K\|_2 \leq (\rho(\hat{A}) + \delta)^K$, где $\rho(\hat{A})$ — спектральный радиус матрицы $\hat{A}$. Мы возьмём $\delta = \frac{\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$.

Оценим спектральный радиус матрицы $\hat{A}$. Так как A симметрична, то её можно диагонализировать (Теорема Параграфа 6 Лекции 20 из [48]):

$$A = U\Lambda U^\top, \text{ где } \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d), \quad U^\top U = I_d.$$

Тогда заметим, что

$$\hat{A} = \begin{pmatrix} U & 0 \\ 0 & U \end{pmatrix} \begin{pmatrix} (1 + \tau)I_d - \gamma\Lambda & -\tau I_d \\ I_d & 0 \end{pmatrix} \begin{pmatrix} U^\top & 0 \\ 0 & U^\top \end{pmatrix}.$$

Спектр центральной матрицы совпадает со спектром матрицы $\hat{A}$, так как ортогональные преобразования не меняют спектр матрицы (Теорема Параграфа 6 Лекции 29 из [48]). Заметим, что перестановка строк и столбцов не меняет спектр, тогда спектр $\hat{A}$ совпадает со спектром $\tilde{A}$:

$$\tilde{A} = \text{diag}(T_1, \dots, T_d), \quad T_i = \begin{pmatrix} 1 + \tau_k - \gamma_k \lambda_i & -\tau_k \\ 1 & 0 \end{pmatrix}.$$

Тогда спектральный радиус матрицы $\hat{A}$ равен

$$\rho(\hat{A}) = \max_{i=1, d} \rho(T_i).$$

Найдём собственные числа u матрицы T_i по характеристическому уравнению:

$$\det \begin{pmatrix} 1 + \tau - \gamma\lambda_i - u & -\tau \\ 1 & -u \end{pmatrix} = 0,$$

что даёт:

$$u^2 - u(1 + \tau - \gamma\lambda_i) + \tau = 0.$$

Это квадратное уравнение имеет корни

$$u_{1,2} = \frac{(1 + \tau - \gamma\lambda_i) \pm \sqrt{(1 + \tau - \gamma\lambda_i)^2 - 4\tau}}{2}.$$

При выборе параметров:

$$\gamma = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \tau = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2,$$

получаем, что

$$u_{1,2} = \frac{(L + \mu - 2\lambda_i) \pm 2\sqrt{(L - \lambda_i)(\mu - \lambda_i)}}{(\sqrt{L} + \sqrt{\mu})^2} = \frac{(\sqrt{L - \lambda_i} \pm i\sqrt{\lambda_i - \mu})^2}{(\sqrt{L} + \sqrt{\mu})^2}.$$

Здесь мы воспользовались тем, что $\lambda_i \in [\mu, L]$. Тогда

$$|u_1| = |u_2| = \frac{L - \mu}{(\sqrt{L} + \sqrt{\mu})^2} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}},$$

Получаем, что

$$\rho(\hat{A}) = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}.$$

Тогда

$$\left\| \begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} \right\|_2 \leq \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} + \frac{\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^K \left\| \begin{pmatrix} e^0 \\ e^{-1} \end{pmatrix} \right\|_2,$$

откуда получаем,

$$\|x^K - x^*\|_2 \leq \left\| \begin{pmatrix} e^K \\ e^{K-1} \end{pmatrix} \right\|_2 \leq \sqrt{2} \left(\frac{\sqrt{L}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2.$$

Воспользуемся тем, что $\mu \leq L$, и применим неравенство (0.4):

$$\begin{aligned} \|x^K - x^*\|_2 &\leq \sqrt{2} \left(\frac{\sqrt{L}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2 = \sqrt{2} \left(1 - \frac{\sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^K \|x^0 - x^*\|_2 \\ &\leq \sqrt{2} \left(1 - \frac{\sqrt{\mu}}{2\sqrt{L}} \right)^K \|x^0 - x^*\|_2 \leq \sqrt{2} \exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) \|x^0 - x^*\|_2. \end{aligned}$$

Ограничим правую часть неравенства ε :

$$\|x^K - x^*\|_2 \leq \sqrt{2} \exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) \|x^0 - x^*\|_2 \leq \varepsilon.$$

Тогда после логарифмирования и преобразования получаем:

$$K \geq 2\sqrt{\frac{L}{\mu}} \log \left(\frac{\sqrt{2} \|x^0 - x^*\|_2}{\varepsilon} \right) = \mathcal{O} \left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right).$$

■

Таким образом, на квадратичной задаче метод тяжёлого шарика действительно оказывается быстрее метода градиентного спуска: у градиентного спуска оценка на количество итераций $\mathcal{O} \left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right)$, а у метода тяжёлого шарика $\mathcal{O} \left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon} \right)$.

Но будет ли метод тяжёлого шарика быстрее на более общем классе задач, а именно на μ -сильно выпуклых и L -гладких функциях? Оказывается, что нет. Приведем пример такой μ -сильно выпуклой L -гладкой функции, что при выборе параметров метода, как на квадратичной задаче, метод тяжёлого шарика не сходится вовсе.

Пример Л4.1 (Секция 4.6 из [19]). Рассмотрим функцию

$$f(x) = \begin{cases} \frac{25}{2}x^2 + 12, & x < 1, \\ \frac{1}{2}x^2 + 24x, & 1 \leq x < 2, \\ \frac{25}{2}x^2 - 24x + 48, & x \geq 2, \end{cases}$$

её градиент

$$\nabla f(x) = \begin{cases} 25x, & x < 1, \\ x + 24, & 1 \leq x < 2, \\ 25x - 24, & x \geq 2. \end{cases}$$

Константы гладкости и сильной выпуклости для f : $\mu = 1$, $L = 25$. Однако если выбрать начальное приближение $x_0 \in [3.07, 3.46]$, метод тяжёлого шарика с параметрами из Теоремы Л4.1

$$\gamma_k = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2} = \frac{1}{9}, \quad \tau_k = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 = \frac{4}{9}$$

не сходится, а порождает предельный цикл, как показано на Рисунке Л4.2.




Рис. Л4.2: Иллюстрация предельного цикла в методе тяжёлого шарика на кусочно-гладкой функции $f(x)$.

Действительно, итерация метода тяжёлого шарика в точке x^k выглядит следующим образом:

$$x^{k+1} = \frac{13}{9}x^k - \frac{4}{9}x^{k-1} - \frac{1}{9}\nabla f(x^k).$$

И тогда точки $q = -\frac{2208}{1225}$, $p = \frac{792}{1225}$, $r = \frac{2592}{1225}$ образуют предельный цикл, как показано на Рисунке Л4.2. При этом, если выбрать начальное приближение $x_0 \in [3.07, 3.46]$, то траектория метода будет асимптотически стремиться к предельному циклу.

Таким образом, мы убедились, что оптимальные параметры, подобранные для квадратичной задачи, не гарантируют сходимости на более общем классе μ -сильно выпуклых и L -гладких функций. Для этого класса метод тяжёлого шарика даёт ускорение — $\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right)$ только в случае локальной сходимости [33], когда стартовая точка x^0 уже достаточно близка к решению x^* . Если же рассматривать глобальную сходимость, то есть из произвольной точки x^0 , то при других значениях гиперпараметров можно получить оценки совпадающие с оценками для градиентного спуска: $\mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right)$. Справиться с этой проблемой должен следующий метод.

Л4.2 Ускоренный градиентный метод

В 1983 году Ю.Е. Нестеров предложил ускоренный градиентный метод [28]:

Алгоритм Л4.2 Ускоренный градиентный метод (Метод Нестерова)

Вход: стартовые точки $x^0 = x^{-1} \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $y^k = x^k + \tau_k(x^k - x^{k-1})$
- 3: $x^{k+1} = y^k - \gamma_k \nabla f(y^k)$
- 4: **end for**

Выход: x^K

Этот алгоритм с первого взгляда очень похож на метод тяжёлого шарика. Однако если подробно написать его итерацию:

$$x^{k+1} = x^k + \tau_k(x^k - x^{k-1}) - \gamma_k \nabla f(x^k + \tau_k(x^k - x^{k-1})),$$

то можно заметить, что градиент, как бы, считается из «будущего» состояния. Разницу между градиентным спуском, методом тяжёлого шарика и методом Нестерова можно увидеть на Рисунках Л4.3 и Л4.4. Как можно заметить, метод Нестерова приближается к оптимуму быстрее. Эта техника позволяет добиться $\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f(x^*)}{\varepsilon}\right)$ вызовов оракула для ε -сходимости по функции.






Рис. Л4.3: Сравнение шага методов, серым пунктиром показан $\tau_k(x^k - x^{k-1})$.

Теорема Л4.2 (Теорема 1 из [9]). Пусть задача безусловной оптимизации (Л3.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью ускоренного градиентного метода (Алгоритм Л4.2). Тогда при $\gamma_k = \frac{1}{L}$, $\tau_k = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K \cdot L \|x^0 - x^*\|_2^2.$$



(а) Метод тяжёлого шарика с $\tau = 0.9$.



(б) Метод Нестерова с $\tau = 0.9$.

Рис. Л4.4: Сравнение траекторий: метод тяжёлого шарика и метод Нестерова с $\gamma = 0.1$.

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{\|x^0 - x^*\|_2}{\varepsilon}\right)\right) \text{ итераций.}$$

Доказательство. Подставим в итерацию ускоренного градиентного метода γ_k и τ_k из условия:

$$\begin{aligned} y^k &= x^k + \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}(x^k - x^{k-1}), \\ x^{k+1} &= y^k - \frac{1}{L} \nabla f(y^k). \end{aligned}$$

Введём *функцию Ляпунова*, которая используется в теории устойчивости:

$$V_k := f(x^k) - f^* + \frac{L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2,$$

где $\rho^2 = 1 - \sqrt{\frac{\mu}{L}}$. Покажем, что для неё выполняется $V_{k+1} \leq \rho^2 V_k$.

Для выпуклой L -гладкой функции f запишем неравенство (Л2.3) из Теоремы Л2.5 для точек x^{k+1}, y^k :

$$\begin{aligned} V_{k+1} &= f(x^{k+1}) - f^* + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\ &\leq f(y^k) + \langle \nabla f(y^k), x^{k+1} - y^k \rangle + \frac{L}{2} \|x^{k+1} - y^k\|_2^2 - f^* \\ &\quad + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2. \end{aligned}$$

Подставляем формулу итерации $x^{k+1} - y^k = -\frac{1}{L} \nabla f(y^k)$:

$$\begin{aligned} V_{k+1} &\leq f(y^k) + \left\langle \nabla f(y^k), -\frac{1}{L} \nabla f(y^k) \right\rangle + \frac{L}{2} \left\| -\frac{1}{L} \nabla f(y^k) \right\|_2^2 - f^* \\ &\quad + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\ &= f(y^k) - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 - f^* + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2. \end{aligned}$$

Прибавим и вычтем $\rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle)$:

$$\begin{aligned}
V_{k+1} &\leq f(y^k) - f^* - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\
&\quad + \rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle) - \rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle) \\
&= \underbrace{\rho^2(f(y^k) - f^* + \langle \nabla f(y^k), x^k - y^k \rangle)}_{(1)} - \rho^2 \langle \nabla f(y^k), x^k - y^k \rangle \\
&\quad + (1 - \rho^2)(f(y^k) - \underbrace{f^*}_{(2)} - \langle \nabla f(y^k), y^k \rangle) + (1 - \rho^2) \langle \nabla f(y^k), y^k \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2.
\end{aligned}$$

Далее воспользуемся μ -сильной выпуклостью f (Определение 12.4) для точек x^k, y^k и x^*, y^k :

$$\begin{aligned}
f(y^k) &\leq f(x^k) + \langle \nabla f(y^k), y^k - x^k \rangle - \frac{\mu}{2} \|x^k - y^k\|_2^2, \\
f^* &\geq f(y^k) + \langle \nabla f(y^k), x^* - y^k \rangle + \frac{\mu}{2} \|y^k - x^*\|_2^2.
\end{aligned}$$

Подставляем эти два неравенства в (1) и (2) соответственно и получаем:

$$\begin{aligned}
V_{k+1} &\leq \rho^2 \left(f(x^k) - f^* - \frac{\mu}{2} \|x^k - y^k\|_2^2 \right) - \rho^2 \langle \nabla f(y^k), x^k - y^k \rangle \\
&\quad - (1 - \rho^2) \frac{\mu}{2} \|y^k - x^*\|_2^2 + (1 - \rho^2) \langle \nabla f(y^k), y^k - x^* \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\
&= \rho^2 V_k + R_k,
\end{aligned}$$

где введено обозначение

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - (1 - \rho^2) \frac{\mu}{2} \|y^k - x^*\|_2^2 + \langle \nabla f(y^k), y^k - x^* - \rho^2(x^k - x^*) \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \|x^{k+1} - x^* - \rho^2(x^k - x^*)\|_2^2 \\
&\quad - \frac{\rho^2 L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2.
\end{aligned}$$

Докажем, что $R_k \leq 0$. Подставим x^{k+1} и преобразуем:

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\mu}{2} \|y^k - x^*\|_2^2 + \langle \nabla f(y^k), y^k - x^* - \rho^2(x^k - x^*) \rangle \\
&\quad - \frac{1}{2L} \|\nabla f(y^k)\|_2^2 + \frac{L}{2} \left\| y^k - \frac{1}{L} \nabla f(y^k) - x^* - \rho^2(x^k - x^*) \right\|_2^2 \\
&\quad - \frac{\rho^2 L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2 \\
&= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\mu}{2} \|y^k - x^*\|_2^2 + \frac{L}{2} \|y^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2 \\
&\quad - \frac{\rho^2 L}{2} \|x^k - x^* - \rho^2(x^{k-1} - x^*)\|_2^2.
\end{aligned}$$

Подставим y^k :

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 \\
&\quad - \sqrt{\frac{\mu}{L}} \frac{\mu}{2(\sqrt{L} + \sqrt{\mu})^2} \|2\sqrt{L}(x^k - x^*) - (\sqrt{L} - \sqrt{\mu})(x^{k-1} - x^*)\|_2^2 \\
&\quad + \frac{L}{2(\sqrt{L} + \sqrt{\mu})^2} \left\| \left(\sqrt{L} + \frac{\mu}{\sqrt{L}} \right) (x^k - x^*) - (\sqrt{L} - \sqrt{\mu})(x^{k-1} - x^*) \right\|_2^2 \\
&\quad - \frac{\sqrt{L} - \sqrt{\mu}}{2\sqrt{L}} \|\sqrt{L}(x^k - x^*) - (\sqrt{L} - \sqrt{\mu})(x^{k-1} - x^*)\|_2^2.
\end{aligned}$$

Раскроем квадраты норм и преобразуем:

$$\begin{aligned}
R_k &= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 \\
&\quad - \sqrt{\frac{\mu}{L}} \frac{\rho^2 L}{2} \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 \left(\|x^k - x^*\|_2^2 - 2\langle x^k - x^*, x^{k-1} - x^* \rangle + \|x^{k-1} - x^*\|_2^2 \right) \\
&= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\rho^2 L}{2} \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2 \|x^k - x^{k-1}\|_2^2 \\
&= -\frac{\rho^2 \mu}{2} \|x^k - y^k\|_2^2 - \sqrt{\frac{\mu}{L}} \frac{\rho^2 L}{2} \|x^k - y^k\|_2^2 = -\frac{\rho^2 L}{2} \left(\frac{\mu}{L} + \sqrt{\frac{\mu}{L}} \right) \|x^k - y^k\|_2^2 \leq 0.
\end{aligned}$$

Таким образом, $V_{k+1} \leq \rho^2 V_k$. Тогда $V_K \leq \rho^{2K} V_0$.

Заметим, что $f(x^K) - f^* \leq V_K$. Покажем, что $V_0 \leq L\|x^0 - x^*\|_2^2$, используем свойство гладкости (Л2.3):

$$\begin{aligned}
V_0 &= f(x^0) - f^* + \frac{L}{2} \|x^0 - x^*\|_2^2 - \rho^2 \|x^0 - x^*\|_2^2 \\
&= f(x^0) - f^* + \frac{L}{2} (1 - \rho^2) \|x^0 - x^*\|_2^2 \\
&\leq \langle \nabla f(x^*), x^0 - x^* \rangle + \frac{L}{2} \|x^0 - x^*\|_2^2 + \frac{L}{2} \frac{\mu}{L} \|x^0 - x^*\|_2^2 \leq L\|x^0 - x^*\|_2^2.
\end{aligned}$$

Резюмируя, получаем:

$$f(x^K) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K \cdot L\|x^0 - x^*\|_2^2.$$

Найдём оценку на число итераций:

$$f(x^K) - f^* \leq \left(1 - \sqrt{\frac{\mu}{L}}\right)^K L\|x^0 - x^*\|_2^2 \leq \exp\left(-\sqrt{\frac{\mu}{L}} \cdot K\right) L\|x^0 - x^*\|_2^2.$$

Запишем определение μ -сильной выпуклости (Определение Л2.4) в точке x^* :

$$f(x^K) \geq f^* + \langle \nabla f(x^*), x^K - x^* \rangle + \frac{\mu}{2} \|x^K - x^*\|_2^2 = f^* + \frac{\mu}{2} \|x^K - x^*\|_2^2.$$

Воспользуемся им, чтобы гарантировать, что

$$\|x^K - x^*\|_2^2 \leq \frac{2}{\mu} (f(x^K) - f^*) \leq \exp\left(-\sqrt{\frac{\mu}{L}} \cdot K\right) \frac{2L\|x^0 - x^*\|_2^2}{\mu} \leq \varepsilon^2.$$

Тогда логарифируем и получаем

$$K \geq 2\sqrt{\frac{2L}{\mu}} \log \left(\sqrt{\frac{L}{\mu}} \frac{\|x^0 - x^*\|_2}{\varepsilon} \right).$$

■

Таким образом, для сильно выпуклого случая ускоренный градиентный метод действительно показывает превосходство над методом градиентного спуска.




Рис. Л4.5: Сравнение методов GD (Алгоритм Л3.1), Heavy Ball (Алгоритм Л4.1) и AGD (Алгоритм Л4.2) при неоптимальном подборе параметров на квадратичной задаче.

Однако что же можно сказать про просто выпуклый случай? Для него формулируется следующая теорема о сходимости.

Теорема Л4.3 (Теорема 6 из [23]). Пусть задача безусловной оптимизации (Л3.1) с L -гладкой выпуклой целевой функцией f решается с помощью ускоренного градиентного метода (Алгоритм Л4.2). Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$, $\tau_k = \frac{k}{k+3}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2\|x^0 - x^*\|_2^2}{\gamma(K+2)^2}.$$

Доказательство. Обозначим $a_k = \frac{k+2}{2}$, $k \geq 0$ и $a_0 = 0$, тогда

$$\tau_k = \frac{k}{k+3} = \frac{\frac{k+2}{2} - 1}{\frac{k+3}{2}} = \frac{a_k - 1}{a_{k+1}}. \quad (\text{Л4.2})$$

Введём вектор $p^k = (a_k - 1)(x^k - x^{k-1})$. Из формулы обновления y_k выразим:

$$x^{k-1} = \frac{(1 + \tau_k)x^k - y^k}{\tau_k}.$$

Подставим это в формулу для p^k :

$$p^k = (a_k - 1) \left(x^k - \frac{(1 + \tau_k)x^k - y^k}{\tau_k} \right) = a_{k+1}(y^k - x^k).$$

Последнее верно в силу (Л4.2). Пользуясь формулой итерации метода и (Л4.2), имеем:

$$\begin{aligned} p^{k+1} + x^{k+1} &= (a_{k+1} - 1)(x^{k+1} - x^k) + x^{k+1} \\ &= a_{k+1}x^{k+1} - (a_{k+1} - 1)x^k \\ &= a_{k+1}(y^k - \gamma \nabla f(y^k)) - (a_{k+1} - 1)x^k \\ &= a_{k+1}(y^k - x^k) + x^k - a_{k+1}\gamma \nabla f(y^k) \\ &= p^k + x^k - a_{k+1}\gamma \nabla f(y^k). \end{aligned}$$

Оценим $\|p^{k+1} + x^{k+1} - x^*\|_2^2$, где x^* — одна из точек минимума:

$$\begin{aligned} \|p^{k+1} + x^{k+1} - x^*\|_2^2 &= \|p^k + x^k - x^* - a_{k+1}\gamma \nabla f(y^k)\|_2^2 \\ &= \|p^k + x^k - x^*\|_2^2 - 2a_{k+1}\gamma \langle p^k + x^k - x^*, \nabla f(y^k) \rangle \\ &\quad + a_{k+1}^2 \gamma^2 \|\nabla f(y^k)\|_2^2. \end{aligned}$$

Разобьём скалярное произведение:

$$\begin{aligned} \langle p^k + x^k - x^*, \nabla f(y^k) \rangle &= \langle a_{k+1}(y^k - x^k) + x^k - x^*, \nabla f(y^k) \rangle \\ &= (a_{k+1} - 1) \langle y^k - x^k, \nabla f(y^k) \rangle + \langle y^k - x^*, \nabla f(y^k) \rangle. \end{aligned}$$

Применим выпуклость в точках y^k, x^* и y^k, x^k :

$$\begin{aligned} \langle y^k - x^*, \nabla f(y^k) \rangle &\geq f(y^k) - f^*, \\ \langle y^k - x^k, \nabla f(y^k) \rangle &\geq f(y^k) - f(x^k). \end{aligned}$$

Тогда:

$$\begin{aligned} \langle p^k + x^k - x^*, \nabla f(y^k) \rangle &\geq (a_{k+1} - 1)(f(y^k) - f(x^k)) + (f(y^k) - f^*) \\ &= a_{k+1}(f(y^k) - f^*) - (a_{k+1} - 1)(f(x^k) - f^*) \quad (\text{Л4.3}) \\ &\geq a_{k+1}(f(y^k) - f^*) - \frac{a_k^2}{a_{k+1}}(f(x^k) - f^*). \end{aligned}$$

Последний переход получен благодаря неравенству $(a_{k+1} - 1)a_{k+1} \leq a_k^2$, которое проверяется прямой подстановкой определения a_k . Теперь получим соотношение между $f(y^k)$ и $f(x^{k+1})$, применив свойство выпуклых гладких функций (Л2.3):

$$\begin{aligned} f(x^{k+1}) &\leq f(y^k) + \langle \nabla f(y^k), x^{k+1} - y^k \rangle + \frac{L}{2} \|x^{k+1} - y^k\|_2^2 \\ &= f(y^k) + \gamma \left(-1 + \frac{\gamma L}{2} \right) \|\nabla f(y^k)\|_2^2. \end{aligned}$$

Или, переставив слагаемые:

$$f(y^k) \geq f(x^{k+1}) - \gamma \left(-1 + \frac{\gamma L}{2} \right) \|\nabla f(y^k)\|_2^2.$$

Подставим в неравенство (Л4.3):

$$\begin{aligned} \langle p^k + x^k - x^*, \nabla f(y^k) \rangle &\geq a_{k+1}(f(x^{k+1}) - f^*) - \frac{a_k^2}{a_{k+1}}(f(x^k) - f^*) \\ &\quad - a_{k+1}\gamma \left(-1 + \frac{\gamma L}{2} \right) \|\nabla f(y^k)\|_2^2. \end{aligned}$$

Подставим в оценку $\|p^{k+1} + x^{k+1} - x^*\|_2^2$:

$$\begin{aligned} \|p^{k+1} + x^{k+1} - x^*\|_2^2 &\leq \|p^k + x^k - x^*\|_2^2 \\ &\quad - 2a_{k+1}^2\gamma(f(x^{k+1}) - f^*) + 2a_k^2\gamma(f(x^k) - f^*) \\ &\quad + a_{k+1}^2\gamma^2(\gamma L - 2)\|\nabla f(y^k)\|_2^2 + a_{k+1}^2\gamma^2\|\nabla f(y^k)\|_2^2 \\ &\leq \|p^k + x^k - x^*\|_2^2 \\ &\quad + 2a_k^2\gamma(f(x^k) - f^*) - 2\gamma a_{k+1}^2(f(x^{k+1}) - f^*) \\ &\quad + a_{k+1}^2\gamma^2(\gamma L - 1)\|\nabla f(y^k)\|_2^2 \\ &\leq \|p^k + x^k - x^*\|_2^2 \\ &\quad + 2a_k^2\gamma(f(x^k) - f^*) - 2a_{k+1}^2\gamma(f(x^{k+1}) - f^*). \end{aligned}$$

Слагаемое с градиентом оценено сверху нулем, поскольку $\gamma \leq \frac{1}{L}$. Введём функцию Ляпунова:

$$V_k := \|p_k + x^k - x^*\|_2^2 + 2a_k^2\gamma(f(x^k) - f^*).$$

Будем считать, что γ постоянна, тогда получаем, что $V_{k+1} \leq V_k$ — то есть функция убывает по k . Тогда:

$$2a_K^2\gamma(f(x^K) - f^*) \leq V_K \leq V_0 = \|x^0 - x^*\|_2^2,$$

откуда

$$f(x^K) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2a_K^2\gamma} = \frac{2\|x^0 - x^*\|_2^2}{\gamma(K+2)^2}.$$

■

Утверждение Л4.1. Пусть задача удовлетворяет условиям Теоремы Л4.3 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2L\|x^0 - x^*\|_2^2}{(K+2)^2}.$$

Более того, чтобы достичь точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O} \left(\sqrt{\frac{L\|x^0 - x^*\|_2^2}{\varepsilon}} \right) \text{ итераций.}$$

Доказательство. Подставим $\gamma = \frac{1}{L}$ в оценку из Теоремы Л4.3:

$$f(x^K) - f^* \leq \frac{2\|x^0 - x^*\|_2^2}{\gamma(K+2)^2} = \frac{2L\|x^0 - x^*\|_2^2}{(K+2)^2}.$$

Чтобы получить оценку на число итераций, потребуем:

$$\frac{2L\|x^0 - x^*\|_2^2}{(K+2)^2} \leq \varepsilon.$$

Откуда:

$$(K+2)^2 \geq \frac{2L\|x^0 - x^*\|_2^2}{\varepsilon} \implies K \geq \sqrt{\frac{2L\|x^0 - x^*\|_2^2}{\varepsilon}} - 2.$$

■

Л4.3 Нижние оценки

Снова вернемся к классу L -гладких μ -сильно выпуклых задач. Хочется понять, существует ли метод их решения лучше, чем ускоренный градиентный метод. Для этого прибегнем к построению нижних оценок для класса методов, где лежит рассматриваемый метод. То есть мы хотим показать, что для любого метода из класса существует плохая задача, на которой он работает за нижнюю оценку. Поскольку мы говорим об ускоренном градиентном методе, то целесообразно говорить о методах первого порядка, то есть имеющих доступ к градиенту целевой функции. Будем рассматривать следующий класс алгоритмов:

$$x^{k+1} \in x^0 + \text{span} \{ \nabla f(x^0), \dots, \nabla f(x^k) \},$$

где линейной оболочкой множества S называется множество всех линейных комбинаций элементов S :

$$\text{span } S = \bigcup_{k \in \mathbb{N}} \left\{ \sum_{i=1}^k \alpha_i x_i \mid \alpha_i \in \mathbb{R}, x_i \in S, i = \overline{1, k} \right\}.$$

Выбор такого класса достаточно логичен: на итерации $k+1$ нам известны все предыдущие точки x^i , $i \leq k$, а также градиенты в них $\nabla f(x^i)$, $i \leq k$, а строить новую точку x^{k+1} мы будем как их линейную комбинацию. Но если мы предыдущие точки конструировали как линейные комбинации точек и градиентов, то все точки выражаются только через x^0 и градиенты $\nabla f(x^i)$, $i \leq k$. Выходит, что и x^{k+1} выражается через них же. Отсюда получается, что градиентный спуск (Алгоритм Л3.1), метод тяжёлого шарика (Алгоритм Л4.1) и ускоренный градиентный метод (Алгоритм Л4.2) лежат в описанном классе алгоритмов.

Сформулируем теорему о нижних оценках для этого класса.

Теорема Л4.4. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой μ -сильно выпуклой функцией f решается методом первого порядка, удовлетворяющим Л4.3. Тогда для достижения точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$)

потребуется не менее

$$\Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ оракульных вызовов.}$$

Доказательство. Сконструируем «плохую» функцию, покажем её L -гладкость и μ -сильную выпуклость. Затем покажем, что любой метод из описанного класса решает её «достаточно долго».

Зафиксируем количество итераций метода K , размерность матрицы $d = 2K$ и построим квадратичную функцию

$$f(x) = \frac{L-\mu}{8} \langle x, Ax \rangle - \frac{L-\mu}{4} \langle e_1, x \rangle + \frac{\mu}{2} \|x\|_2^2,$$

где A задана следующим образом:

$$A = \begin{pmatrix} 2 & -1 & 0 & \dots & 0 \\ -1 & 2 & -1 & \dots & 0 \\ 0 & -1 & 2 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 2 \end{pmatrix}.$$

Градиент f будет равен:

$$\nabla f(x) = \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x.$$

1. Проверим свойства задачи. Покажем, что f будет L -гладкой:

$$\left\| \frac{L-\mu}{4} A(x-y) + \mu(x-y) \right\|_2 \leq \frac{L-\mu}{4} \|A\|_2 \|x-y\|_2 + \mu \|x-y\|_2 \leq L \|x-y\|_2,$$

спектральная норма матрицы A ограничена 4, так как $A - 4I_d$ отрицательно полуопределена.

Проверим, что f будет μ -сильно выпуклой:

$$\begin{aligned} \frac{L-\mu}{8} \langle y, Ay \rangle - \frac{L-\mu}{4} \langle e_1, y \rangle + \frac{\mu}{2} \|y\|_2^2 &\geq \frac{L-\mu}{8} \langle x, Ax \rangle - \frac{L-\mu}{4} \langle e_1, x \rangle + \frac{\mu}{2} \|x\|_2^2 \\ &\quad + \left\langle \frac{L-\mu}{4} Ax - \frac{L-\mu}{4} e_1 + \mu x, y - x \right\rangle \\ &\quad + \frac{\mu}{2} \|y - x\|_2^2. \end{aligned}$$

Преобразуем выражение:

$$\frac{L-\mu}{8} (\langle y, Ay \rangle + \langle x, Ax \rangle - 2\langle y, Ax \rangle) \geq \frac{\mu}{2} \|y - x\|_2^2 - \frac{\mu}{2} \|y\|_2^2 - \frac{\mu}{2} \|x\|_2^2 + \mu \langle x, y \rangle = 0.$$

Получаем, что $\langle (y-x), A(y-x) \rangle \geq 0$ — это верно, так как A положительно полуопределена.

2. Найдём решение задачи. Из условия оптимальности — равенства градиента нулю, находим координаты оптимума:

$$\begin{aligned}\frac{L+\mu}{2}x_1^* - \frac{L-\mu}{4}x_2^* &= \frac{L-\mu}{4}, \\ -\frac{L-\mu}{4}x_{i-1}^* + \frac{L+\mu}{2}x_i^* - \frac{L-\mu}{4}x_{i+1}^* &= 0, \quad i = \overline{2, d-1}, \\ -\frac{L-\mu}{4}x_{d-1}^* + \frac{L+\mu}{2}x_d^* &= 0.\end{aligned}$$

Введём искусственные ограничения $x_0^* = 1$, а $x_{d+1}^* = 0$, тогда:

$$-(L-\mu)x_{i-1}^* + 2(L+\mu)x_i^* - (L-\mu)x_{i+1}^* = 0, \quad i = \overline{1, d}.$$

Решим полученную рекурренту, для этого запишем характеристическое уравнение:

$$\lambda^2 - 2\frac{L+\mu}{L-\mu}\lambda + 1 = 0 \implies \lambda_{1,2} = \frac{L+\mu}{L-\mu} \pm \sqrt{\left(\frac{L+\mu}{L-\mu}\right)^2 - 1} = \frac{L \pm 2\sqrt{L\mu} + \mu}{L-\mu}.$$

Тогда решение представимо в виде:

$$x_i^* = c_1 \left(\frac{\sqrt{L} + \sqrt{\mu}}{\sqrt{L} - \sqrt{\mu}} \right)^i + c_2 \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^i.$$

Учтём ограничения на x_0^* и x_{d+1}^* :

$$\begin{aligned}c_1 + c_2 &= 1, \\ c_1 \left(\frac{\sqrt{L} + \sqrt{\mu}}{\sqrt{L} - \sqrt{\mu}} \right)^{d+1} + c_2 \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{d+1} &= 0.\end{aligned}$$

Введём обозначение

$$q = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}},$$

тогда

$$x_i^* = -\frac{q^{2d+2}}{1-q^{2d+2}} \frac{1}{q^i} + \frac{1}{1-q^{2d+2}} q^i.$$

3. Найдём выход метода, удовлетворяющего Л4.3. Так как алгоритм должен сходиться из любой точки, то рассмотрим начальную точку $x^0 = (0, 0, \dots, 0)^\top$. Заметим, что из градиента задачи и начальной точки следует, что $\nabla f(x^0) \in \text{span}(e_1)$, поэтому после первого вызова оракула только первая ктамнаордината может быть ненулевой. После второго — первые две и так далее. То есть $\nabla f(x^k) \in \text{span}(e_1, e_2, \dots, e_{k+1})$, тогда $x^{k+1} \in \text{span}(e_1, e_2, \dots, e_{k+1})$. Таким образом, получается, что только первые K компонент вектора могут совпадать с компонентами решения, остальные компоненты нулевые. Тогда:

$$\|x^K - x^*\|_2^2 \geq \sum_{i=K+1}^d (x_i^*)^2.$$

Таким образом:

$$\begin{aligned}
\|x^K - x^*\|_2^2 &\geq \sum_{i=K+1}^d \left(-\frac{q^{2d+2}}{1-q^{2d+2}} \frac{1}{q^i} + \frac{1}{1-q^{2d+2}} q^i \right)^2 \\
&= \frac{1}{(1-q^{2d+2})^2} \sum_{i=K+1}^d \left(q^i - \frac{q^{2d+2}}{q^i} \right)^2 \\
&= \frac{1}{(1-q^{2d+2})^2} \sum_{i=K+1}^d q^{2i} (1-q^{2d+2-2i})^2.
\end{aligned}$$

Воспользуемся тем, что $q^{2d+2-2i} \leq q^2$:

$$\begin{aligned}
\|x^K - x^*\|_2^2 &\geq \frac{(1-q^2)^2}{(1-q^{2d+2})^2} \sum_{i=K+1}^d q^{2i} = \frac{(1-q^2)^2}{(1-q^{2d+2})^2} \sum_{i=K+1}^{2K} q^{2i} \\
&= \frac{(1-q^2)^2}{(1-q^{2d+2})^2} q^{2K} \sum_{i=1}^K q^{2i} \\
&= (1-q^2)^2 \frac{q^{2K}}{1+q^{2K}} \frac{1}{(1-q^{2d+2})^2} \left(\sum_{i=1}^K q^{2i} + q^{2K} \sum_{i=1}^K q^{2i} \right) \\
&\geq (1-q^2)^2 \frac{q^{2K}}{1+q^{2K}} \|x^0 - x^*\|_2^2 \geq (1-q^2)^2 q^{2K} \frac{\|x^0 - x^*\|_2^2}{2} \\
&= \frac{L}{\mu} \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^{2K} \frac{\|x^0 - x^*\|_2^2}{2}.
\end{aligned}$$

Воспользуемся неравенствами:

$$\log(1+x) \leq x, \quad \log(1-x) \geq -\frac{x}{1-x}, \quad x \in [0, 1).$$

Тогда

$$\log \frac{1-x}{1+x} = \log(1-x) - \log(1+x) \geq -\frac{x}{1-x} - x = -\frac{2x}{1-x}.$$

Продолжим оценку:

$$\|x^K - x^*\|_2^2 \geq \exp\left(-\frac{4K\sqrt{\mu/L}}{1-\sqrt{\mu/L}}\right) \frac{L}{\mu} \frac{\|x^0 - x^*\|_2^2}{2}.$$

Тогда получаем:

$$K \geq \frac{1-\sqrt{\mu/L}}{4\sqrt{\mu/L}} \log\left(\frac{L}{\mu} \cdot \frac{\|x^0 - x^*\|_2^2}{2\varepsilon^2}\right).$$

Таким образом:

$$K = \Omega\left(\sqrt{\frac{L}{\mu}} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right).$$

■

Мы видим, что верхние оценки ускоренного градиентного метода асимптотически совпали с нижними оценками методов первого порядка на классе L -гладких μ -сильно выпуклых задач. То есть асимптотически улучшить метод Нестерова нельзя. Отсюда заключаем, что ускоренный градиентный метод является *оптимальным* в классе методов первого порядка на L -гладких μ -сильно выпуклых задачах.

Л4.4 Линейный каплинг

К текущему моменту мы рассмотрели уже три метода первого порядка: градиентный спуск, метод тяжёлого шарика и ускоренный градиентный метод. В градиентном спуске мы двигаемся против направления роста функции. В методе тяжёлого шарика мы добавляем инерцию к нашему движению, а в методе Нестерова мы вычисляем градиент в будущей точке. Однако класс методов, который мы описали перед теоремой с нижними оценками, позволяет нам конструировать и менее очевидные с точки зрения физики методы. Например, при обновлении точки, мы можем прибавлять градиент в другой точке, или брать выпуклую комбинацию нескольких точек в качестве третьей. Чтобы проиллюстрировать этот подход, рассмотрим один из методов, который тоже получает оптимальные оценки в сильно выпуклом случае.

Алгоритм Л4.3 Линейный каплинг: внутренний цикл

Вход: стартовые точки $x^0 = y^0 = z^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$ и $\{\eta_k\}_{k=0} > 0$, моменты $\{\tau_k\}_{k=0} \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $y^{k+1} = x^k - \eta_k \nabla f(x^k)$
- 3: $z^{k+1} = z^k - \gamma_k \nabla f(x^k)$
- 4: $x^{k+1} = \tau_k z^{k+1} + (1 - \tau_k) y^{k+1}$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$




Рис. Л4.6: Три шага линейного каплинга. Пунктир — градиентные шаги для y и z вдоль градиента в точке x , сплошные линии — вычисление x^k как выпуклой комбинации.

Разберём, что происходит на итерации линейного каплинга. Точка y^{k+1} получается шагом градиентного спуска из x^k . Точка z^{k+1} обновляется через градиентный шаг из z^k вдоль направления $\nabla f(x^k)$. В каком-то смысле она живет сама по себе, однако движется согласно градиенту в точке x^k . Саму же точку x^{k+1} мы получаем как выпуклую комбинацию y^{k+1} и z^{k+1} . Если попытаться интерпретировать, что происходит в методе, то можно сказать, что точки y^k отвечают за классические шаги против градиента, а z^k добавляют инерцию.

Важным замечанием является, что метод линейного каплинга отличается от предыдущих ещё и выходом: раньше мы всегда возвращали точку с последней итерации, теперь возвращаем среднее арифметическое всех точек. В теореме о сходимости будем смотреть за значением функции в средней точке.

Теорема Л4.5. Пусть задача безусловной оптимизации (Л3.1) с L -гладкой выпуклой целевой функцией f решается с помощью линейного каплинга (Алгоритм Л4.3). Тогда при $\eta < \frac{2}{L}$, $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2 - L\eta)K}.$$

Доказательство. Воспользуемся строкой 3 Алгоритма Л4.3:

$$\begin{aligned} \|z^{k+1} - x^*\|_2^2 &= \|z^k - \gamma \nabla f(x^k) - x^*\|_2^2 \\ &= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), z^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 \\ &= \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad - 2\gamma \langle \nabla f(x^k), z^k - x^k \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2. \end{aligned} \quad (\text{Л4.4})$$

Оценим $\|\nabla f(x^k)\|_2^2$, для этого применим свойство гладкой функции из Теоремы Л2.4:

$$f(y^{k+1}) \leq f(x^k) + \langle \nabla f(x^k), y^{k+1} - x^k \rangle + \frac{L}{2} \|y^{k+1} - x^k\|_2^2.$$

Воспользуемся строкой 2 Алгоритма Л4.3:

$$f(y^{k+1}) \leq f(x^k) - \eta \|\nabla f(x^k)\|_2^2 + \frac{L\eta^2}{2} \|\nabla f(x^k)\|_2^2 = f(x^k) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(x^k)\|_2^2.$$

Если $\eta_k \leq \frac{2}{L}$, то $(1 - \frac{L\eta}{2}) > 0$. Получаем оценку на квадрат нормы градиента:

$$\|\nabla f(x^k)\|_2^2 \leq \frac{2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})). \quad (\text{Л4.5})$$

Подставим (Л4.5) в (Л4.4):

$$\begin{aligned} \|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2 - L\eta)} (f(x^k) - f(y^{k+1})) + 2\gamma \langle \nabla f(x^k), x^k - z^k \rangle. \end{aligned} \quad (\text{Л4.6})$$

Теперь оценим $\langle \nabla f(x^k), z^k - x^k \rangle$, для этого задействуем строку 4 Алгоритма Л4.3:

$$\langle \nabla f(x^k), x^k - z^k \rangle = \left\langle \nabla f(x^k), x^k - \frac{1}{\tau} (x^k - (1 - \tau)y^k) \right\rangle = \frac{1 - \tau}{\tau} \langle \nabla f(x^k), y^k - x^k \rangle.$$

Воспользуемся выпуклостью функции f (Определение Л12.3):

$$\langle \nabla f(x^k), x^k - z^k \rangle \leq \frac{1-\tau}{\tau} (f(y^k) - f(x^k)). \quad (\text{Л14.7})$$

Объединяя оценки (Л14.6) и (Л14.7):

$$\begin{aligned} \|z^{k+1} - x^*\|_2^2 &\leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)} (f(x^k) - f(y^{k+1})) + 2\gamma \frac{1-\tau}{\tau} (f(y^k) - f(x^k)). \end{aligned}$$

Подберем τ так, что $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$, тогда

$$\|z^{k+1} - x^*\|_2^2 \leq \|z^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})).$$

Сделаем перестановку:

$$2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \leq \|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2 + \frac{2\gamma^2}{\eta(2-L\eta)} (f(y^k) - f(y^{k+1})),$$

а потом снова применяем выпуклость:

$$2\gamma (f(x^k) - f(x^*)) \leq \|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2 + \frac{2\gamma^2}{\eta(2-L\eta_k)} (f(y^k) - f(y^{k+1})).$$

Суммируем по всем k от 0 до $K-1$, а потом делим на K :

$$\begin{aligned} \frac{2\gamma}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{K} \sum_{k=0}^{K-1} (\|z^k - x^*\|_2^2 - \|z^{k+1} - x^*\|_2^2) \\ &\quad + \frac{2\gamma^2}{\eta(2-L\eta)K} \sum_{k=0}^{K-1} (f(y^k) - f(y^{k+1})) \\ &= \frac{1}{K} (\|z^0 - x^*\|_2^2 - \|z^K - x^*\|_2^2) + \frac{2\gamma^2}{\eta(2-L\eta)K} (f(y^0) - f(y^K)) \\ &\leq \frac{\|z^0 - x^*\|_2^2}{K} + \frac{2\gamma^2 (f(y^0) - f^*)}{\eta(2-L\eta)K}. \end{aligned}$$

Учитывая инициализацию $x^0 = y^0 = z^0$ и применяя неравенство Йенсена для выпуклой функции f (0.1), имеем

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2-L\eta)K}.$$

■

Казалось бы, полученный результат не является оптимальным: в выпуклом случае мы получили сублинейную скорость сходимости $\mathcal{O}(1/K)$, как у обычного градиентного спуска. У метода Нестерова мы получили $\mathcal{O}(1/K^2)$ (Теорема Л14.3). Дальше мы

рассмотрим технику, которая позволит получить оптимальную скорость сходимости в сильно выпуклом случае — рестарты линейного каплинга.

Алгоритм Л4.4 Линейный каплинг: рестарты

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций T

- 1: **for** $t = 0, 1, \dots, T - 1$ **do**
 - 2: Запустить Алгоритм Л4.3 из x^t с параметрами γ, η, τ на K итераций
 - 3: Получить x^{t+1} на выходе Алгоритма Л4.3
 - 4: **end for**
- Выход:** x^T
-

Появляется логичный вопрос: зачем нам делать внешний цикл, вся суть которого перезапускать метод с прошлого выхода внутреннего метода. Чем это отличается от одного цикла на $T \cdot K$ итераций? Ответ стоит искать в том, что мы получаем на выход из внутреннего цикла, а именно, среднюю точку. И теперь уже становится понятно отличие одного цикла от двух вложенных. Более того, с техникой рестартов удастся получить хорошие оценки сходимости. Стоит заметить, что результат прошлой теоремы справедлив для выпуклых функций, а следующую теорему мы формулируем для сильно выпуклых задач.

Теорема Л4.6 (Теорема 3.1 из [21]). Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью рестартов линейного каплинга (Алгоритм Л4.4). Тогда при $\gamma = \frac{1}{\sqrt{\mu L}}$, $\eta = \frac{1}{L}$, $\frac{1-\tau}{\tau} = \frac{\gamma}{\eta(2-L\eta)}$, $K = \sqrt{\frac{16L}{\mu}}$, чтобы добиться точности ε по функции $(f(x^T) - f^* \leq \varepsilon)$, необходимо

$$O\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f^*}{\varepsilon}\right) \text{ оракульных вызовов.}$$

Доказательство. Применим к результату Теоремы Л4.5 сильную выпуклость (Определение Л2.4), учитывая, что $\nabla f(x^*) = 0$:

$$\begin{aligned} f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* &\leq \frac{f(x^0) - f^*}{\mu\gamma K} + \frac{\gamma(f(x^0) - f^*)}{\eta(2-L\eta)K} \\ &= \left(\frac{1}{\mu\gamma K} + \frac{\gamma}{\eta(2-L\eta)K}\right)(f(x^0) - f^*). \end{aligned}$$

Подберем η оптимально, чтобы минимизировать правую часть оценки выше: $\eta = \frac{1}{L}$. Тогда

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \left(\frac{1}{\mu\gamma K} + \frac{\gamma L}{K}\right)(f(x^0) - f^*).$$

Подберем теперь оптимальное $\gamma = \frac{1}{\sqrt{\mu L}}$:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \sqrt{\frac{4L}{\mu K^2}}(f(x^0) - f^*).$$

Положим $K = \sqrt{\frac{16L}{\mu}}$ и получим:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{2}(f(x^0) - f^*).$$

Получается, что за один запуск линейного каплинга на K итераций, мы гарантированно уменьшаем расстояние до решения по функции в 2 раза. А значит для одной итерации Алгоритма Л4.4 имеем

$$f(x^{t+1}) - f^* \leq \frac{1}{2}(f(x^t) - f^*).$$

Запустим теперь рекурсию по t :

$$f(x^T) - f^* \leq \frac{1}{2^T}(f(x^0) - f^*).$$

Отсюда легко выразить число итераций Алгоритма Л4.4 для достижения точности ε по функции:

$$T \geq \log\left(\frac{f(x^0) - f^*}{\varepsilon}\right).$$

В данном случае оракульная сложность Алгоритма Л4.4 не совпадает с итерационной. Оракульную сложность можно получить следующим образом:

$$K \cdot T = O\left(\sqrt{\frac{L}{\mu}} \log \frac{f(x^0) - f^*}{\varepsilon}\right).$$

■

Л4.5 Catalyst

В методе Нестерова мы получили ускорение благодаря добавлению инерции и вычислению градиента в будущей точке. Однако метод можно ускорить и другими способами. Давайте модифицируем саму целевую функцию, чтобы получить ускорение для всех методов, обращающихся к градиенту функции. Это позволяет сделать общую схему ускорения Catalyst, предложенную в 2015 году [21].

Алгоритм Л4.5 Catalyst

Вход: стартовые точки $x^0 = y^0 \in \mathbb{R}^d$, коэффициент регуляризации κ , параметры α_0 и $q = \frac{\mu}{\mu + \kappa}$, последовательность $\{\varepsilon_k\}_{k \geq 0}$, метод оптимизации $\mathcal{M}$

1: **while** не выполнен критерий остановки $\mathcal{T}$ **do**

2: Найти приближенное решение следующей задачи, используя $\mathcal{M}$:

$$\begin{aligned} x^k &\approx \operatorname{argmin}_{x \in \mathbb{R}^d} & g_k(x) &= f(x) + \frac{\kappa}{2} \|x - y^{k-1}\|_2^2 \\ \text{s.t.} & & g_k(x^k) - g_k^* &\leq \varepsilon_k. \end{aligned}$$

3: Выбрать $\alpha_k \in (0, 1)$ из уравнения $\alpha_k^2 = (1 - \alpha_k)\alpha_{k-1}^2 + q\alpha_k$

4: $\beta_k = \frac{\alpha_{k-1}(1 - \alpha_{k-1})}{\alpha_{k-1}^2 + \alpha_k}$

5: $y^k = x^k + \beta_k(x^k - x^{k-1})$

6: **end while**

Выход: x^k

Проанализируем этот метод. Эта схема напоминает метод рестартов: есть внешний цикл, который запускает внутренний метод $\mathcal{M}$. Но дальше идут различия. На каждой итерации внешнего цикла отщипываются разные задачи. К исходной целевой функции $f(x)$ добавляется регуляризатор $\frac{\kappa}{2}\|x - y^{k-1}\|_2^2$, который «тянет» точку x к y^{k-1} . А затем точка y^k обновляется наподобие тому, как это было в ускоренном градиентном методе, то есть с моментумом. Можно сказать, что моментум мы вынесли в виде регуляризатора в модифицированную целевую функцию. Эта идея позволяет, например, ускорить метод градиентного спуска до скорости метода Нестерова. Далее сформулируем конкретные теоремы из оригинальной статьи.

Теорема Л4.7 (Теорема 3.1 из [21]). Пусть задача безусловной оптимизации (Л3.1) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью схемы Catalyst (Алгоритм Л4.5). Тогда при $\rho \leq \sqrt{\kappa}$, $\alpha_0 = \sqrt{q}$ и последовательности

$$\varepsilon_k = \frac{2}{9}(f(x^0) - f^*)(1 - \rho)^k$$

справедлива следующая оценка сходимости:

$$f(x^k) - f^* \leq C(1 - \rho)^{k+1}(f(x^0) - f^*), \quad C = \frac{8}{(\sqrt{q} - \rho)^2}.$$

В таком виде теорема не делает никаких предположений о том методе, который используется для решения подзадач. Мы лишь можем наблюдать за последовательностью x^k , генерируемой алгоритмом. Для того, чтобы понять, насколько дорого обходится работа метода целиком, необходимо сделать предположение о скорости сходимости внутреннего метода $\mathcal{M}$.

Предположение Л4.1. Пусть выполняются условия теоремы Л4.7, а метод $\mathcal{M}$ генерирует последовательность $\{z^t\}_{t \geq 0}$ при минимизации функции g_k с линейной скоростью сходимости:

$$g_k(z^t) - g_k^* \leq A(1 - \tau_{\mathcal{M}})^t(g_k(z^0) - g_k^*).$$

При этом предположении и при $z_0 = x^{k-1}$, точность решения ε_k достигается за $T_{\mathcal{M}} = \tilde{O}(1/\tau_{\mathcal{M}})$ итераций внутреннего метода. Теперь мы можем оценить точность решения и константу сходимости всей схемы Catalyst. Итак, после общего количества итераций метода $\mathcal{M}$, а именно $s = kT_{\mathcal{M}}$, получаем

$$f\left(x^{\frac{s}{T_{\mathcal{M}}}}\right) - f^* \leq C(1 - \rho)^{\frac{s}{T_{\mathcal{M}}}}(f(x^0) - f^*) \leq C\left(1 - \frac{\rho}{T_{\mathcal{M}}}\right)^s(f(x^0) - f^*).$$

Таким образом, константа $\tau_{\mathcal{A}}$ итогового метода равна $\tau_{\mathcal{A}} = \frac{\rho}{T_{\mathcal{M}}} = \tilde{O}\left(\tau_{\mathcal{M}}\sqrt{\frac{\mu}{\mu + \kappa}}\right)$. При этом $\tau_{\mathcal{M}}$ обычно также зависит от κ , так что κ подбирается так, чтобы максимизировать $\tau_{\mathcal{M}}/\sqrt{\mu + \kappa}$.

Сформулируем аналогичную теорему и предположение для выпуклого случая, а затем рассмотрим, какое ускорение удастся получить для изученных методов.

Теорема Л4.8 (Теорема 3.3 из [21]). Пусть задача безусловной оптимизации (Л3.1) с L -гладкой выпуклой целевой функцией f решается с помощью схемы Catalyst (Алгоритм Л4.5). Тогда при $\alpha_0 = \frac{\sqrt{5}-1}{2}$ и последовательности

$$\varepsilon_k = \frac{2}{9}(f(x^0) - f^*)(k+2)^{-4-\eta}, \quad \eta > 0$$

справедлива следующая оценка сходимости:

$$f(x^k) - f^* \leq \frac{8}{(k+2)^2} \left(\left(1 + \frac{2}{\eta}\right)^2 (f(x^0) - f^*) + \frac{\kappa}{2} \|x^0 - x^*\|^2 \right).$$

Снова потребуется сделать предположение о сходимости внутреннего алгоритма для решения подзадачи.

Предположение Л4.2. Пусть выполняются условия Теоремы Л4.8, а метод $\mathcal{M}$ генерирует последовательность $\{z^t\}_{t \geq 0}$ при минимизации функции g_k с линейной скоростью сходимости:

$$g_k(z^t) - g_k^* \leq A(1 - \tau_{\mathcal{M}})^t (g_k(z^0) - g_k^*).$$

Мы потребовали линейной скорости сходимости, но рассматриваем выпуклый случай. Почему такое возможно? На самом деле, выпуклой является функция f , а когда мы к ней добавили регуляризатор $\frac{\kappa}{2} \|x - y^{k-1}\|_2^2$, мы сделали задачу сильно выпуклой с константой $\mu = \kappa$. А для такой задачи уже многие градиентные методы будут иметь линейную скорость сходимости.

При этом предположении и при $z_0 = x^{k-1}$, точность решения ε_k достигается за $T_{\mathcal{M}} = \tilde{O}(1/\tau_{\mathcal{M}})$ итераций внутреннего метода. Если мы захотим более точную оценку, то для k -ой подзадачи число итераций метода $\mathcal{M}$ составляет $T_{\mathcal{M}} \log(k+2)$ из-за полиномиального убывания точности ε_k .

Теперь мы можем оценить точность решения и константу сходимости всей схемы Catalyst. После общего количества итераций внутреннего метода $s = kT_{\mathcal{M}} \log(k+2)$, получаем

$$f\left(x^{\frac{s}{T_{\mathcal{M}} \log(k+2)}}\right) - f^* \leq \frac{8T_{\mathcal{M}}^2 \log^2(s)}{s^2} \left(\left(1 + \frac{2}{\eta}\right)^2 (f(x^0) - f^*) + \frac{\kappa}{2} \|x^0 - x^*\|^2 \right).$$

Если метод $\mathcal{M}$ является методом первого порядка, то данная оценка является почти оптимальной (near-optimal), с точностью до логарифмического множителя, по сравнению с оптимальной скоростью $\mathcal{O}(1/s^2)$, что может быть разумной платой за универсальность схемы Catalyst.

Рассмотрим как метод Catalyst позволяет ускорить метод градиентного спуска, сравним со скоростью метода Нестерова. Все асимптотики написаны для количества итераций, необходимых для достижения ε -точности решения по функции $(f(x) - f^* \leq \varepsilon)$. Параметры были подобраны оптимально. Как мы видим, Catalyst ускоряет метод гра-

	Без Catalyst		Catalyst	
	$\mu > 0$	$\mu = 0$	$\mu > 0$	$\mu = 0$
GD	$\mathcal{O}\left(\frac{L}{\mu} \log\left(\frac{1}{\varepsilon}\right)\right)$	$\mathcal{O}\left(\frac{L}{\varepsilon}\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{1}{\varepsilon}\right)\right)$	$\mathcal{O}\left(\frac{L}{\sqrt{\varepsilon}}\right)$
AGD	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \log\left(\frac{1}{\varepsilon}\right)\right)$	$\mathcal{O}\left(\frac{L}{\sqrt{\varepsilon}}\right)$	нет ускорения	

Таблица 1: Сравнение методов GD (Алгоритм Л3.1), AGD (Алгоритм Л4.2) с использованием Catalyst и без.

диентного спуска так, что получаются асимптотики аналогичные методу Нестерова с точностью до логарифмических факторов. Метод Нестерова дополнительно ускорить

не удастся. Объясняется это тем, что даже с применением схемы ускорения Catalyst ускоренный градиентный метод остается методом первого порядка. А как мы знаем из верхних и нижних оценок, он является оптимальным среди методов первого порядка на классе гладких сильно выпуклых задач.

Л5 Стохастический градиентный спуск

Стохастическая оптимизация возникает в тех случаях, когда точный градиент функции либо невозможно вычислить, либо его вычисление слишком дорого. В таких случаях мы используем приближённые градиенты, построенные на основе случайной информации о функции.

Придём к этой идее через пример из Параграфа Л1, а именно через оптимизацию в машинном обучении Л1.1.5. В этом примере мы приходили к задаче минимизации эмпирического риска, которую можно записать как:

$$\min_{x \in \mathbb{R}^d} \left[f(x) := \frac{1}{n} \sum_{i=1}^n f_i(x) = \frac{1}{n} \sum_{i=1}^n \ell(g(x, \xi_i^a), \xi_i^b) \right], \quad (\text{Л5.1})$$

где введены обозначения:

- $\xi_i = (\xi_i^a, \xi_i^b)$ — элементы выборки: ξ_i^a — объект (картинка, текст) и ξ_i^b — метка (ответ) на i -м объекте,
- g — модель машинного обучения (линейная модель, нейросеть), принимает на вход объект и настраиваемые веса x ,
- ℓ — функция потерь (штрафует модель за несовпадения с реальной меткой ξ^b).

Такую постановку называют *оффлайн* (данные фиксированы, а не поступают в режиме реального времени).

В оффлайн постановке можно считать полный и честный градиент целевой функции f , но в машинном обучении часто этого не делают. Основная причина — полные градиенты дорого и долго считать, поэтому вместо них вызывают лишь приближённый градиент по случайному элементу выборки: $\nabla f_i(x, \xi_i)$, где i генерируется независимо и равномерно из $\overline{1, n}$. Если рассматривать случайный элемент выборки ξ как случайную величину, семплируемую из общего пула данных $\mathcal{D} = \{\xi_1, \dots, \xi_n\}$ с одинаковой вероятностью $\mathbb{P}(\xi = \xi_i) = \frac{1}{n}$, то можно переписать оффлайн постановку (Л5.1) как:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \mathbb{E}_{\xi \sim \mathcal{D}} [f(x, \xi)] = \mathbb{E}_{\xi \sim \mathcal{D}} [\ell(g(x, \xi^a), \xi^b)] \right]. \quad (\text{Л5.2})$$

Теперь продемонстрируем более общий подход. До этого мы рассматривали задачи, где все функции и градиенты были детерминированными:

$$\min_{x \in \mathbb{R}^d} f(x).$$

А сейчас пусть целевая функция — это математическое ожидание от случайной величины ξ из неизвестного распределения $\mathcal{D}$:

$$\min_{x \in \mathbb{R}^d} [f(x) := \mathbb{E}_{\xi \sim \mathcal{D}} [f(x, \xi)]] . \quad (\text{Л5.3})$$

Такую постановку называют *онлайн* (данные поступают потоком в режиме реального времени). При этом оффлайн постановку можно свести к онлайн варианту, как мы показали в (Л5.2), но сведение в обратную сторону уже не работает, так как в онлайн постановке мы можем даже и не увидеть все данные в процессе обучения.

Цель онлайн формата: в ходе минимизации случайной функции потерь мы «подстраиваемся» под природу, чтобы потери модели в *среднем* по всему распределению были наименьшими. Так модель сможем найти хорошие зависимости для любых данных ξ .

Проблема онлайн формата: Функция f , а также градиенты и более старшие производные не считаются точно, так как мы не знаем $\mathcal{D}$, а даже если и знаем, то интеграл в математическом ожидании часто не взять так просто.

Решение проблемы: Возникает потребность в методе, который может оперировать с неточными оценками градиента $\nabla f(x, \xi)$ (например, с градиентом по конкретному объекту из распределения данных или с градиентом с шумом). То есть мы хотим работать в *онлайн* режиме, где данные поступают, а мы их обрабатываем (считаем градиент).

Замечание Л5.1. Всякого рода рандомизированные подходы, основанные на сэмплировании, называются *Монте–Карло подходами*.

Оффлайн постановка — это Монте–Карло аппроксимация исходного математического ожидания. С ростом количества элементов в выборке, аппроксимация через конечную сумму будет стремиться к реальному ожиданию (при определенных предположениях).

Л5.1 Стохастический градиентный спуск

Идея — модифицировать градиентный спуск, заменив полный градиент $\nabla f(x^k)$ в точке x^k на стохастическую оценку $\nabla f(x^k, \xi^k)$.

Алгоритм Л5.1 Стохастический градиентный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:   Сгенерировать независимо  $\xi^k \sim \mathcal{D}$ 
3:    $x^{k+1} = x^k - \gamma_k \nabla f(x^k, \xi^k)$ 
4: end for
Выход:  $x^K$ 

```

Для дальнейшего повествования напомним определение условного математического ожидания и закон полного математического ожидания.

Определение Л5.1. *Условное математическое ожидание:*

$$\mathbb{E} \left[\cdot \mid x^k \right] := \mathbb{E} [\cdot \mid \mathcal{F}_k],$$

где $\mathcal{F}_k$ — σ -алгебра, порождённая $\xi^0, \dots, \xi^{k-1}$.

Суть — фиксируем всю случайность, которая произошла до k итерации, и ожидаем только по случайности, которая осталась размороженной. Такое математическое ожидание даёт на выходе величину, зависящую от случайных величин $\xi^0, \dots, \xi^{k-1}$.

Теорема Л5.1 (Закон полного математического ожидания (Утверждение G из части 4 Параграфа 7 из [49])). Для двух случайных величин X, Y из одного вероятностного пространства верно равенство:

$$\mathbb{E} [\mathbb{E} [X \mid Y]] = \mathbb{E} [X].$$

Суть — чтобы посчитать сложное математическое ожидание для величины X , мы можем сначала заморозить часть случайности Y и посчитать условное ожидание, а потом проожидать оставшуюся замороженную часть Y .

Перейдём к описанию предположений, которые будут использованы при доказательстве сходимости. На функцию f мы оставляем стандартные предположения об L -гладкости и μ -сильной выпуклости. Но если ранее градиент функции был детерминированным, то теперь стохастический градиент — это случайная величина, и нам

потребуется два новых предположения на него: несмещённость (стохастический градиент в среднем дает полный градиент) и ограниченность дисперсии (разброс оценки градиента не слишком велик).

Предположение Л5.1 (*Несмещённость стохастического градиента*). Положим, что $\{\mathcal{F}\}_{k \geq 0}$ — семейство вложенных σ -алгебр, случайная величина $x^0 \in \mathcal{F}_0$ — измерима, для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ случайная величина $\nabla f(x^k, \xi^k)$ является $\mathcal{F}_k$ -измеримой, и выполняется равенство:

$$\mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^k \right] = \nabla f(x^k).$$

Предположение Л5.2 (*Ограниченность дисперсии стохастического градиента*). Существует константа $\sigma^2 \geq 0$, такая, что для любых $x^k \in \mathbb{R}^d$ и $k \in \mathbb{N}$ верна оценка:

$$\mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \sigma^2.$$

Теперь можем доказывать сходимость. Начнём с сильно выпуклого случая.

Теорема Л5.2. Пусть задача безусловной стохастической оптимизации (Л5.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \gamma \leq \frac{1}{L}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}. \quad (\text{Л5.4})$$

Доказательство. Начинаем, как и раньше:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2.$$

Вспомним, что мы знаем предположения про функцию f , а в выражении выше её нет (есть только её стохастический градиент). Значит, надо как-то перейти к этой функции в неравенствах. Для этого берём условное математическое ожидание по случайности только на итерации k (важно, что x^k — это неслучайная величина относительно условного математического ожидания по разбиению $\mathcal{F}_k$, случайными здесь будут только величины x^{k+1} и градиент $\nabla f(x^k, \xi^k)$):

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] \\ &\quad + \gamma^2 \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right]. \end{aligned} \quad (\text{Л5.5})$$

Рассмотрим $\mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right]$ и воспользуемся линейностью условного математического ожидания, а также Предположением Л5.1:

$$\begin{aligned} \mathbb{E} \left[\langle \nabla f(x^k, \xi^k), x^k - x^* \rangle \mid x^k \right] &= \left\langle \mathbb{E} \left[\nabla f(x^k, \xi^k) \mid x^k \right], x^k - x^* \right\rangle \\ &= \langle \nabla f(x^k), x^k - x^* \rangle. \end{aligned}$$

Рассмотрим $\mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right]$, добавим и вычтем градиент, после чего раскроем квадрат нормы:

$$\begin{aligned} \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k) + \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &\quad + \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \mid x^k \right] \\ &\quad + 2\mathbb{E} \left[\langle \nabla f(x^k, \xi^k) - \nabla f(x^k), \nabla f(x^k) \rangle \mid x^k \right]. \end{aligned} \quad (\text{Л5.6})$$

Теперь мы можем воспользоваться Предположением Л5.1 и Предположением Л5.2:

$$\begin{aligned} \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\|\nabla f(x^k, \xi^k) - \nabla f(x^k)\|_2^2 \mid x^k \right] + \|\nabla f(x^k)\|_2^2 \\ &\quad + 2\langle \mathbb{E} [\nabla f(x^k, \xi^k) \mid x^k] - \nabla f(x^k), \nabla f(x^k) \rangle \\ &\leq \sigma^2 + \|\nabla f(x^k)\|_2^2 + 2 \cdot 0. \end{aligned}$$

Объединим все промежуточные шаги, подставим в (Л5.5) и получим:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 + \gamma^2 \sigma^2.$$

Выглядит похоже на то, что было в градиентном спуске, только появляется $\gamma^2 \sigma^2$. Поэтому далее воспользуемся L -гладкостью (Теорема Л2.5) и μ -сильной выпуклостью (Определение Л2.4):

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \left(f(x^k) - f^* + \frac{\mu}{2} \|x^k - x^*\|_2^2 \right) \\ &\quad + 2\gamma^2 L(f(x^k) - f^*) + \gamma^2 \sigma^2 \\ &= (1 - \gamma\mu) \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L)(f(x^k) - f^*) + \gamma^2 \sigma^2. \end{aligned}$$

При выборе $\gamma \leq \frac{1}{L}$ слагаемое $-2\gamma(1 - \gamma L)(f(x^k) - f^*)$ отрицательно, и от него можно избавиться:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \gamma\mu) \|x^k - x^*\|_2^2 + \gamma^2 \sigma^2.$$

Сейчас запустить рекурсию мешает то, что слева и справа стоят случайные величины, причем оценок на $\|x^k - x^*\|_2$ у нас нет. Чтобы перейти к неслучайным величинам, в неравенстве выше берем полное математическое ожидание и применяем результат Теоремы Л5.1:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] \leq (1 - \gamma\mu) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \gamma^2 \sigma^2.$$

Разворачиваем рекурсию:

$$\begin{aligned} \mathbb{E} \left[\|x^K - x^*\|_2^2 \right] &\leq (1 - \gamma\mu) \mathbb{E} \left[\|x^{K-1} - x^*\|_2^2 \right] + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^2 \mathbb{E} \left[\|x^{K-2} - x^*\|_2^2 \right] + (1 - \gamma\mu) \gamma^2 \sigma^2 + \gamma^2 \sigma^2 \\ &\leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \gamma^2 \sigma^2 \sum_{i=0}^{K-1} (1 - \gamma\mu)^i. \end{aligned}$$

Второе слагаемое — сумма первых k членов геометрической прогрессии, оценим её:

$$\sum_{i=0}^{K-1} (1 - \gamma\mu)^i \leq \sum_{i=0}^{+\infty} (1 - \gamma\mu)^i = \frac{1}{\gamma\mu}.$$

После подстановки в выражение выше:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^k \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu}.$$

■

Эта оценка состоит из двух слагаемых: «детерминированного» слагаемого из обычного градиентного спуска с линейной сходимостью к решению, и нового «стохастического» слагаемого — некоторой неточности, зависящей от γ , σ и μ . Эту неточность метод преодолеть не может и начинает осциллировать, больше не приближаясь к решению. В таком случае говорят, что имеет место сходимость к окрестности решения x^* . Пример поведения стохастического градиентного спуска на практике показан на Рисунке Л5.1: большие шаги γ сначала убывают быстрее, но в итоге сходятся к худшим окрестностям.




Рис. Л5.1: Характерная «дрожь» сходимости стохастического градиентного спуска.

Теперь рассмотрим выпуклый случай.

Теорема Л5.3. Пусть задача безусловной стохастической оптимизации (Л5.3) с L -гладкой, выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \gamma \leq \frac{1}{2L}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{\|x^0 - x^*\|_2^2}{\gamma K} + \gamma\sigma^2. \quad (\text{Л5.7})$$

Доказательство. Как и раньше, разложим квадрат нормы:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k, \xi^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k, \xi^k)\|_2^2.$$

Берём условное ожидание по $\mathcal{F}_k$ и пользуемся несмещённостью стохастического градиента (Предположение Л15.1):

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right].$$

Аналогично сильно выпуклому случаю, воспользуемся оценкой на второй момент градиента (Л15.6):

$$\mathbb{E} \left[\|\nabla f(x^k, \xi^k)\|_2^2 \mid x^k \right] \leq \sigma^2 + \|\nabla f(x^k)\|_2^2.$$

Подставим в неравенство:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + \gamma^2 \|\nabla f(x^k)\|_2^2 + \gamma^2 \sigma^2.$$

Вспомним определение выпуклой функции (Определение Л12.3):

$$\langle \nabla f(x^k), x^k - x^* \rangle \geq f(x^k) - f^*,$$

и неравенство для L -гладкой функции (неравенство Л12.4) из Теоремы Л12.5):

$$\|\nabla f(x^k)\|_2^2 \leq 2L(f(x^k) - f^*).$$

Продолжим основное неравенство:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma(f(x^k) - f^*) + 2\gamma^2 L(f(x^k) - f^*) + \gamma^2 \sigma^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma(1 - \gamma L)(f(x^k) - f^*) + \gamma^2 \sigma^2. \end{aligned}$$

Возьмём $\gamma \leq \frac{1}{2L}$, чтобы $1 - \gamma L \geq \frac{1}{2}$, тогда:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - \gamma(f(x^k) - f^*) + \gamma^2 \sigma^2.$$

Берем полное математическое ожидание и суммируем по всем k от 0 до K :

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \|x^0 - x^*\|_2^2 - \gamma \sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] + \gamma^2 \sigma^2 K.$$

Так как $\mathbb{E} \left[\|x^K - x^*\|_2^2 \right]$ — неотрицательное, то:

$$\sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] \leq \frac{\|x^0 - x^*\|_2^2}{\gamma} + \gamma \sigma^2 K.$$

Воспользуемся линейностью математического ожидания и неравенством Йенсена (0.1):

$$\begin{aligned} \mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] &\leq \mathbb{E} \left[\frac{1}{K} \sum_{k=0}^{K-1} f(x^k) - f^* \right] = \frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [f(x^k) - f^*] \\ &\leq \frac{\|x^0 - x^*\|_2^2}{\gamma K} + \gamma \sigma^2. \end{aligned}$$

■

Результат теоремы похож на классическую оценку для градиентного спуска из Теоремы Л3.3 с точностью до стохастической добавки в виде дисперсии решения $\gamma \sigma^2$.

Л5.2 Модификации стохастического градиентного спуска

Стохастический градиентный спуск с постоянным шагом обладает существенным недостатком — сходимостью к окрестности решения. Рассмотрим простые техники, которые помогают решить проблему неточной сходимости.

Уменьшение шага. В сильно выпуклом случае даже маленький постоянный шаг не работает, так как полностью затухает линейная сходимость в (Л5.4), поэтому шаги нужно постепенно уменьшать с большого значения. В работе [2] проведён анализ сходимости метода для таких шагов. Получим следствия из Теоремы 1 этой статьи.

Теорема Л5.4. Пусть задача безусловной стохастической оптимизации (Л5.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \frac{2}{\mu(k+1)}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \frac{\exp(8L^2/\mu^2)}{K^2} \left(\|x^0 - x^*\|_2^2 + \frac{\sigma^2}{L^2} \right) + \frac{8\sigma^2 \log K}{\mu^2 K}.$$

При такой стратегии подбора шага дисперсия решения убывает сублинейно, но мы теряем в скорости сходимости детерминированной части (была линейная, стала сублинейная). Так происходит, потому что размер шага слишком быстро уменьшается ($\sim 1/k$), и метод не успевает быстро сойтись. Можно получить оценку и для менее агрессивно убывающего γ_k .

Теорема Л5.5. Пусть задача безусловной стохастической оптимизации (Л5.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) с $\gamma_k = \frac{2}{\mu\sqrt{k+1}}$ в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq 2K^{16L^2/\mu^2} \exp\left(-\frac{\sqrt{K}}{2}\right) \left(\|x^0 - x^*\|_2^2 + \frac{\sigma^2}{L^2} \right) + \frac{8\sigma^2}{\mu^2 \sqrt{K}}.$$

Сравнивая оценки для шагов $\gamma_k \sim 1/\sqrt{k}$ с $\gamma_k \sim 1/k$, наблюдаем, что дисперсия решения стала убывать медленнее, но сходимость первого слагаемого осталась линейной, хоть и с плохим коэффициентом. Лучшие оценки были получены в работе [38].

Теорема Л5.6. Пусть задача безусловной стохастической оптимизации (Л5.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью стохастического градиентного спуска (Алгоритм Л5.1) в предположениях несмещённости (Предположение Л5.1) и ограниченности дисперсии стохастического градиента (Предположение Л5.2). Тогда при выборе:

$$\gamma_k = \begin{cases} \frac{1}{2L}, & k < \lceil \frac{K}{2} \rceil, \\ \frac{2}{\mu\left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil\right)}, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

$$w_k = \begin{cases} 0, & k < \lceil \frac{K}{2} \rceil, \\ \left(\frac{4L}{\mu} + k - \lceil \frac{K}{2} \rceil\right)^2, & k \geq \lceil \frac{K}{2} \rceil, \end{cases}$$

справедлива следующая оценка:

$$\begin{aligned} \mathbb{E} \left[f(\bar{x}^K) - f^* \right] + \mu \mathbb{E} \left[\|\bar{x}^{K+1} - x^*\|_2^2 \right] \\ \leq \min \left\{ 64LR^2 \exp \left(-\frac{\mu K}{4L} \right) + \frac{36\sigma^2}{\mu K}, \frac{2LR^2}{K} + \frac{2\sigma R}{\sqrt{K}} \right\}, \end{aligned}$$

где $R = \|x^0 - x^*\|_2$, $W_K = \sum_{i=1}^K w_i$, $\bar{x}^K = \frac{1}{W_K} \sum_{i=1}^K w_i x^i$.

Эта оценка сочетает в себе линейную сходимость детерминированного слагаемого из классической оценки, и сублинейный спад слагаемого с шумом, при этом с лучшими скоростями. Стратегию выбора шагов спуска и весов для усреднения точек можно описать следующим образом: первую половину делаем большие шаги с константным значением $\gamma = \frac{1}{2L}$ и не учитываем эти $\lceil \frac{K}{2} \rceil$ точек при усреднении, а затем берём уменьшающийся шаг, получаем сходимость к более точной окрестности, усредняем эти точки с ненулевыми возрастающими весами.

Замечание Л5.2. Усреднение точек ближе к концу, когда они осциллируют вокруг решения, помогает уменьшить колебания и достичь лучшего решения и в других стохастических алгоритмах. Этот подход также известен как *скользящее среднее* и особо полезен в обучении больших нейронных сетей.

Выпуклый случай. Первое слагаемое в оценке (Л5.7) имеет сублинейную сходимость, поэтому достаточно взять постоянный, но маленький шаг, чтобы достичь:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \min_{\gamma \leq \frac{1}{2L}} \left\{ \frac{R^2}{\gamma K} + \gamma \sigma^2 \right\} \leq \frac{2LR^2}{K} + \frac{2\sigma R}{\sqrt{K}}, \quad (\text{Л5.8})$$

где $R^2 = \|x^0 - x^*\|_2^2$ и $\gamma = \min \left\{ \frac{1}{2L}, \frac{R}{\sigma\sqrt{K}} \right\}$. Мы видим, что у первого детерминированного слагаемого осталась скорость обычного градиентного спуска, а плато стало убывать сублинейно. На практике применяют просто уменьшающийся шаг $\gamma_k = \min \left\{ \frac{1}{2L}, \frac{R}{\sigma\sqrt{k}} \right\}$ без фиксированного горизонта K , при том оценка становится хуже лишь на фактор $\log K$. В общем случае, можно легко обобщить доказательство Теоремы Л5.3 на непостоянные шаги $\gamma_k \leq \frac{1}{2L}$:

$$\mathbb{E} \left[f \left(\frac{\sum_{k=0}^{K-1} \gamma_k x^k}{\sum_{k=0}^{K-1} \gamma_k} \right) \right] - f^* \leq \frac{R^2}{\sum_{k=0}^{K-1} \gamma_k} + \frac{\sigma^2 \sum_{k=0}^{K-1} \gamma_k^2}{\sum_{k=0}^{K-1} \gamma_k}.$$

Из этой оценки вытекают необходимые сходимости для γ_k , чтобы и с любой начальной точки сойтись, и шум уменьшить:

$$\sum_{k=0}^{K-1} \gamma_k \xrightarrow{K \rightarrow \infty} \infty, \quad \frac{\sum_{k=0}^{K-1} \gamma_k^2}{\sum_{k=0}^{K-1} \gamma_k} \xrightarrow{K \rightarrow \infty} 0.$$

Например, для шагов $\gamma_k \sim 1/\sqrt{k}$ и $\gamma_k \sim 1/\sqrt{k}$ эти условия выполнены (при $\gamma_k \sim 1/\sqrt{k}$ ряд $\sum_{k=0}^{K-1} \gamma_k^2 \sim \log K$ и даёт экстря фактор в оценку).

Батчирование. Другим подходом борьбы с неточностью решения является уменьшение σ с помощью батчирования. Идея заключается в замене стохастической оценки градиента по одному сэмплу на среднее арифметическое по подвыборке (батчу):

$$\nabla f(x^k, \xi^k) \rightarrow \frac{1}{b} \sum_{j \in S^k} \nabla f(x^k, \xi_j),$$

где S^k — набор случайных индексов из $\overline{1, n}$, $|S^k| = b$, где все индексы генерируются независимо друг от друга (возможны повторы). Оценка по батчу позволяет уменьшить шум σ^2 в стохастических слагаемых, не изменяя детерминированные части.

Утверждение Л5.1. Пусть задача удовлетворяет условиям Теоремы Л5.2 и применена техника батчирования по b независимым сэмплам. Тогда справедлива следующая оценка:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq (1 - \gamma\mu)^K \|x^0 - x^*\|_2^2 + \frac{\gamma\sigma^2}{\mu b}.$$

Доказательство. Посмотрим, что становится со свойствами несмещённости и конечности дисперсии при замене стохастического градиента по одному сэмплу на среднее значение по батчу размера b .

Несмещённость остаётся, так как у каждого сэмпла j есть несмещённость стохастического градиента и выполняется линейность математического ожидания:

$$\mathbb{E} \left[\frac{1}{b} \sum_{j \in S^k} \nabla f(x^k, \xi_j) \middle| x^k \right] = \frac{1}{b} \sum_{j \in S^k} \mathbb{E} \left[\nabla f(x^k, \xi_j) \middle| x^k \right] = \frac{1}{b} \sum_{j \in S^k} \nabla f(x^k) = \nabla f(x^k).$$

А с дисперсией интереснее, её величина убывает как $\frac{\sigma^2}{b}$ с ростом размера выборки b . Обозначим разность $\delta_j := \nabla f(x^k, \xi_j) - \nabla f(x^k)$ и раскроем квадрат нормы в дисперсии:

$$\begin{aligned} (*) &= \mathbb{E} \left[\left\| \left(\sum_{j \in S^k} \frac{\nabla f(x^k, \xi_j)}{b} \right) - \nabla f(x^k) \right\|_2^2 \middle| x^k \right] \\ &= \mathbb{E} \left[\left\| \sum_{j \in S^k} \frac{(\nabla f(x^k, \xi_j) - \nabla f(x^k))}{b} \right\|_2^2 \middle| x^k \right] \\ &= \frac{1}{b^2} \mathbb{E} \left[\left\| \sum_{j \in S^k} \delta_j \right\|_2^2 \middle| x^k \right] = \frac{1}{b^2} \mathbb{E} \left[\sum_{j \in S^k} \|\delta_j\|_2^2 + \sum_{i \neq j \in S^k} 2\langle \delta_j, \delta_i \rangle \middle| x^k \right] \\ &= \frac{1}{b^2} \sum_{j \in S^k} \mathbb{E} \left[\|\delta_j\|_2^2 \middle| x^k \right] + \frac{1}{b^2} \sum_{i \neq j \in S^k} 2\langle \mathbb{E} [\delta_j \middle| x^k], \mathbb{E} [\delta_i \middle| x^k] \rangle \\ &\leq \frac{\sigma^2}{b} + 0, \end{aligned}$$

где в предпоследнем равенстве мы воспользовались свойством математического ожидания для произведения независимых различных сэмплов δ_i и δ_j . Далее последовала оценка дисперсии и несмещённость для одного сэмпла. Остается лишь подставить оценки в (Л5.4) и получить требуемое. ■

Если теперь объединить батчирование и стратегию подбора шага из Теоремы Л5.6, то получится добиться оценки сходимости с меньшей стохастической частью:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = O \left(\frac{L}{\mu} \exp \left(-\frac{\mu}{4L} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 b K} \right). \quad (\text{Л5.9})$$

Получается, дисперсию можно уменьшить в b раз, но тогда на каждой итерации нужно считать в b раз больше стохастических градиентов. К счастью, это вычисление

для независимых сэмплов из подвыборки можно эффективно распараллелить так, что итоговое время одной итерации на практике не сильно изменится. Даже если в b раз дольше считать весь батч последовательно, то выигрыш в количестве итераций при уменьшении дисперсии получается не меньше чем в те же самые b раз: для просто выпуклой оценки (Л5.8) и сильно выпуклой оценки (Л5.9) это как раз $K \sim 1/b$ с σ^2/b . Таким образом, батчирование — это эффективный инструмент для борьбы с шумом, но стоит помнить, что оно не может повлиять на детерминированные части методов. Поэтому увеличивать размер батча стоит до тех пор, пока шумовые слагаемые в оценках всё ещё доминируют.

Моментум. Ранее мы показали, что детерминированный градиентный спуск можно ускорить с помощью инерция так, как это сделано в алгоритме Нестерова (Алгоритм Л4.2). Аналогичным образом алгоритм Нестерова со стохастическими градиентами улучшает оценки по сравнению со стохастическим градиентным спуском, но только их детерминированные части. Если объединить батчирование и результат работы [1], то получается оценка:

$$\mathbb{E} [f(x^{K+1}) - f^*] = O \left(\exp \left(-\frac{1}{2} \sqrt{\frac{\mu}{L}} K \right) (f(x^0) - f^*) + \frac{\sigma^2}{\mu b K} \right), \quad (\text{Л5.10})$$

где в первом слагаемом появляется оптимальный фактор $\sqrt{\mu/L}$ вместо μ/L , но при этом шумовое слагаемое остаётся без изменений (оно уменьшается батчированием). На практике моментум из метода тяжелого шарика (Алгоритм Л4.1) также обладает эффектом накопления и сглаживания градиента и улучшает динамику обучения.

Замечание Л5.3. Для борьбы с выбросами в стохастических градиентах полезно дополнительно обрезать их, и только потом подавать в шаг метода. Например, с помощью клиппирования — обрезания нормы оценки, если она превышает заранее задаваемое значение λ_k ; нормализации — деления оценки на норму; или покоординатного взятия знака от компонент оценки:

$$\nabla f(x^k, \xi^k) \rightarrow \min \{1, \frac{\lambda_k}{\|\nabla f(x^k, \xi^k)\|_2}\} \nabla f(x^k, \xi^k); \quad \frac{\nabla f(x^k, \xi^k)}{\|\nabla f(x^k, \xi^k)\|_2}; \quad \text{sign}(\nabla f(x^k, \xi^k)).$$

Эти модификации делают алгоритмы более устойчивыми, особенно к тяжелым шумам, и гарантируют сходимость не по математическому ожиданию (в среднем по множеству запусков), а с высокой вероятностью (для каждого отдельного запуска).

Л5.3 Нижние оценки

Оценки сходимости (Л5.8), (Л5.9) и (Л5.10) для стохастических методов состоят из двух частей: детерминированной и стохастической. Ранее мы уже построили нижние оценки для детерминированных задач оптимизации (Теорема Л4.4). Эти оценки остаются справедливыми и для детерминированных слагаемых в стохастических методах. Так что в этот раз мы сфокусируемся на стохастической части. Для этого мы применим знания из математической статистики. Следующий результат был получен в работе [3].

Теорема Л5.7. Пусть задача безусловной стохастической оптимизации (Л5.3) с L -гладкой, μ -сильно выпуклой целевой функцией f решается методом с доступом к стохастическому оракулу первого порядка, для которого выполняются предположения несмещённости (Предположение Л5.1) и ограниченности диспер-

сии стохастического градиента (Предположение Л5.2). Тогда выполняется:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \Omega \left(\exp \left(-\sqrt{\frac{\mu}{L}} K \right) \|x^0 - x^*\|_2^2 + \frac{\sigma^2}{\mu^2 K} \right).$$

Доказательство. Нам придется сконструировать не только «плохую» функцию, но и описать стохастический оракул. С одной стороны, задача стала сложнее: стало больше свободы. С другой же, можно не выдумывать сложную функцию, а всю «плохость» задачи сосредоточить в том, насколько зашумленные ответы будет выдавать оракул. Так и поступим — возьмём примитивную целевую функцию $f : \mathbb{R} \rightarrow \mathbb{R}$:

$$f(x) = \frac{\mu}{2} \|x - x^*\|_2^2, \quad \nabla f(x) = \mu(x - x^*).$$

Она μ -сильно выпуклая и μ -гладкая. Считаем, что x^* нам неизвестно, но имеется доступ к зашумленному оракулу первого порядка. На запрос в точке x оракул будет возвращать стохастический градиент:

$$\nabla f(x, \xi) = \mu(x - x^* + \xi), \quad \xi \sim \mathcal{N} \left(0, \frac{\sigma^2}{\mu^2} \right).$$

Проверим предположения о стохастическом градиенте. Несмещённость:

$$\mathbb{E} [\nabla f(x, \xi)] = \mathbb{E} [\mu(x - x^* + \xi)] = \mu(x - x^*) = \nabla f(x).$$

Ограниченность дисперсии:

$$\mathbb{E} [\|\nabla f(x, \xi) - \nabla f(x)\|_2^2] = \mathbb{E} [\|\mu(x - x^* + \xi) - \mu(x - x^*)\|_2^2] = \mathbb{E} [\mu^2 \|\xi\|_2^2] = \sigma^2.$$

Таким образом, все требования на функцию и стохастический градиент выполняются. Пусть мы обратились к оракулу в K точках $\{x^k\}_{k=0}^{K-1}$ и получили в ответ значения $y^k = \mu(x^k + \xi^k - x^*)$, где $\xi^k \sim \mathcal{N}(0, \sigma^2/\mu^2)$ независимы. Хотим получить наилучшую оценку на x^* , используя имеющиеся данные. Введём z^k :

$$z^k = x^k - y^k / \mu = x^* - \xi^k.$$

Тогда задачу можно переформулировать следующим образом: по набору значений $z^k \sim \mathcal{N}(x^*, \sigma^2/\mu^2)$ необходимо восстановить константу x^* . Это можно сделать с помощью оценки максимального правдоподобия:

$$\hat{x} = \frac{1}{K} \sum_{k=0}^{K-1} z^k \sim \mathcal{N} \left(x^*, \frac{\sigma^2}{\mu^2 K} \right).$$

Из математической статистики известно, что для квадратичной функции потерь оценка максимального правдоподобия является оптимальной в смысле минимизации максимального эмпирического риска, то есть получить предсказание лучше оценки максимального правдоподобия невозможно. Из такого распределения на $\hat{x}$, мы сразу видим, что оценка является несмещенной, а ее дисперсия:

$$\mathbb{E} [\|\hat{x} - x^*\|_2^2] = \frac{\sigma^2}{\mu^2 K}.$$

Остается заключить, что поскольку такое значение дисперсии достигается для оптимальной оценки, то все остальные будут не лучше, а значит, они лежат в $\Omega \left(\frac{\sigma^2}{\mu^2 K} \right)$. ■

Смысл этой нижней оценки в том, что дисперсия решения не может убывать быстрее чем $1/K$. Следующий логичный вопрос: являются ли какие-то из ранее полученных оценок оптимальными? Обратимся к результатам Теоремы Л5.6. Из неё можно получить, что $\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] = \mathcal{O} \left(\frac{\sigma^2}{\mu^2 K} \right)$, то есть обычный стохастический градиентный спуск с описанным подбором шага является оптимальным с точки зрения борьбы с шумом в классе методов с доступом к зашумленному оракулу первого порядка. Ускоренные же методы (Л5.10) помогают лишь быстрее справиться с детерминированной частью, а с точки зрения шума (который обычно и доминирует) никакой разницы нет.

Л6 Метод сопряжённых градиентов

Метод сопряжённых градиентов изначально был разработан для решения систем линейных уравнений:

$$Ax = b, \quad (\text{Л6.1})$$

где $A \in \mathbb{S}_{++}^d$, $b \in \mathbb{R}^d$.

Эту систему можно переписать в виде задачи безусловной оптимизации:

$$\min_{x \in \mathbb{R}^d} \left\{ f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle \right\}. \quad (\text{Л6.2})$$

В самом деле, функция f сильно выпукла, поскольку матрица A положительно определена, а её градиент $\nabla f(x) = Ax - b$ зануляется в точке x^* — решении исходной системы (Л6.1).

Далее мы увидим, что метод сопряжённых градиентов можно обобщить за пределы квадратичных функций.

Л6.1 Сопряжённые направления

Ключевым определением в этом параграфе станут сопряжённые направления.

Определение Л6.1. Множество ненулевых векторов $\{p^i\}_{i=0}^{n-1}$ будем называть *сопряжённым* относительно матрицы $A \in \mathbb{S}_{++}^d$, если для любых $i \neq j \in \overline{0, n-1}$ следует

$$\langle p^i, Ap^j \rangle = 0.$$

Свойство сопряжённости во многом похоже на ортогональность. В частности, для сопряжённых векторов выполняется свойство линейной независимости.

Теорема Л6.1. Множество сопряжённых векторов $\{p^i\}_{i=0}^{n-1}$ относительно матрицы $A \in \mathbb{S}_{++}^d$ является линейно независимым.

Доказательство. Пойдём от противного: пусть найдется нетривиальная линейная комбинация сопряжённых векторов, равная нулю. То есть существует набор не равных одновременно нулю чисел $\alpha_0, \dots, \alpha_{n-1} \in \mathbb{R}$: $\sum_{i=0}^{n-1} \alpha_i^2 \neq 0$, для которых:

$$\sum_{i=0}^{n-1} \alpha_i p^i = 0.$$

Домножим на матрицу A и возьмём скалярное произведение с произвольным p^j :

$$\sum_{i=0}^{n-1} \alpha_i \langle p^j, Ap^i \rangle = \alpha_j \langle p^j, Ap^j \rangle = 0.$$

При переходе от суммы к одному слагаемому мы воспользовались определением сопряжённых векторов. Так как $p^j \neq 0$, а матрица A положительно определена, то

$$\langle p^j, Ap^j \rangle > 0.$$

Следовательно, равенство нулю возможно только при $\alpha_j = 0$ для всех $j = \overline{0, n-1}$ — противоречие. ■

Следствием из Теоремы Л6.1 будет полезный факт, что d сопряжённых векторов формируют базис в $\mathbb{R}^d$. Разложим по нему решение x^* :

$$x^* = \sum_{i=0}^{d-1} \lambda_i p^i. \quad (\text{Л6.3})$$

Для нахождения λ_i подействуем матрицей A на обе части (Л6.3) и возьмём скалярное произведение с p^j :

$$\langle p^j, Ax^* \rangle = \sum_{i=0}^{d-1} \lambda_i \langle p^j, Ap^i \rangle = \lambda_j \langle p^j, Ap^j \rangle.$$

При переходе от суммы к одному слагаемому мы опять воспользовались определением сопряжённости векторов.

Так как x^* — решение, то $Ax^* = b$ и получаем, что:

$$\langle p^j, b \rangle = \lambda_j \langle p^j, Ap^j \rangle.$$

Откуда выражается

$$\lambda_j = \frac{\langle p^j, b \rangle}{\langle p^j, Ap^j \rangle}.$$

Л6.2 Метод сопряжённых градиентов

Теперь можно придумать схему обновления x^k для поиска решения:

$$x^{k+1} = x^k + \alpha_k p^k. \quad (\text{Л6.4})$$

Эта схема называется схемой сопряжённых градиентов.

Разложение по сопряжённым направлениям (Л6.3) совпадает с итеративной схемой при $\alpha_k = \lambda_k$ и $x^0 = 0$. А для того, чтобы метод сходился из произвольной точки x^0 , потребуется модифицировать выбор коэффициентов α_k .

Теорема Л6.2 (Теорема 5.1 из [31]). Пусть задача безусловной оптимизации (Л6.2) решается схемой сопряжённых градиентов (Л6.4). Тогда при

$$\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle},$$

где $r^k = Ax^k - b$ — вектор невязки, метод сходится к точному решению x^* за не более чем d итераций.

Доказательство. Как ранее уже обсуждалось, по следствию из Теоремы Л6.1 набор из d сопряжённых векторов образует базис в $\mathbb{R}^d$. Разложим по нему вектор $x^* - x^0$:

$$x^* - x^0 = \sum_{i=0}^{d-1} \lambda_i p^i.$$

Подействуем матрицей A и возьмём скалярное произведение с p^j :

$$\lambda_j = \frac{\langle p^j, A(x^* - x^0) \rangle}{\langle p^j, Ap^j \rangle}, \quad j = 0, d-1.$$

Принимая во внимание, что $A(x^* - x^0) = b - Ax^0 = -r^0$, можно записать:

$$x^* = x^0 + \sum_{i=0}^{d-1} \lambda_i p^i = x^0 - \sum_{i=0}^{d-1} \frac{\langle r^0, p^i \rangle}{\langle p^i, Ap^i \rangle} p^i.$$

Чтобы получить результат теоремы, остаётся показать, что $\langle r^0, p^k \rangle = \langle r^k, p^k \rangle$. Действительно:

$$\langle r^k, p^k \rangle = \langle Ax^k - b, p^k \rangle = \left\langle Ax^0 + \sum_{i=0}^{k-1} A\alpha_i p^i - b, p^k \right\rangle = \langle Ax^0 - b, p^k \rangle = \langle r^0, p^k \rangle.$$

Теперь становится видно, что с выбором коэффициентов $\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle}$ схема сопряжённых градиентов (Л6.4) на итерации d достигнет точного решения x^* :

$$x^d = x^0 - \sum_{i=0}^{d-1} \frac{\langle r^i, p^i \rangle}{\langle p^i, Ap^i \rangle} p^i = x^*.$$

При этом, возможна ситуация, когда точное решение достигается и на более ранней итерации. Например, когда $\langle p^k, r^k \rangle = 0$, начиная с некоторого $k < d$. ■

Добавим другую интерпретацию схеме сопряжённых градиентов. Как мы отметили в самом начале, решение системы (Л6.1) эквивалентно решению безусловной задачи оптимизации (Л6.2). Это минимизация квадратичной функции на $\mathbb{R}^d$. Линии её уровня — это эллипсоиды с центром в x^* .

Рассмотрим задачу минимизации функции $f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle$ из точки x^k вдоль p^k . Если записать в виде задачи оптимизации, то получится

$$\min_{\alpha \in \mathbb{R}} f(x^k + \alpha p^k).$$

Приравняем производную к нулю:

$$\langle \nabla f(x^k + \alpha^* p^k), p^k \rangle = \langle A(x^k + \alpha^* p^k) - b, p^k \rangle = 0 \implies \alpha^* = \alpha_k = -\frac{\langle Ax^k - b, p^k \rangle}{\langle p^k, Ap^k \rangle}.$$

То есть шаг схемы сопряжённых направлений — это шаг наискорейшего спуска для минимизации f вдоль направления p^k .

Наглядно сравним итерации схемы сопряжённых градиентов и наискорейшего покоординатного спуска. Из этой иллюстрации можно сделать несколько выводов.


- Схема сопряжённых градиентов находит точное решение за d итераций, наискорейший покоординатный спуск не сходится точно.
- Сопряжённые направления не ортогональны в привычном смысле этого слова.

Докажем некоторые полезные факты для схемы сопряжённых градиентов.


Теорема Л6.3 (Теорема 5.2 из [31]). Пусть схема сопряжённых градиентов (Л6.4) решает задачу (Л6.2) с выбором коэффициентов $\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle}$.

Тогда

1. $\langle r^k, p^j \rangle = 0$, для всех $j < k$;



(a) Наискорейший спуск (несколько шагов).



(b) Сопряжённые градиенты (2 шага).

Рис. Л6.1: Сравнение траекторий на квадратичной задаче с $A = \text{diag}(1, 5)$.

2. $x^k = \operatorname{argmin}_{x \in P} f(x)$, где $P = x^0 + \operatorname{span}\{p^0, \dots, p^{k-1}\}$.

Доказательство. Обратимся к доказательству Теоремы Л6.2. В нем показывалось, что коэффициенты α_k можно записать как

$$\alpha_k = -\frac{\langle r^0, p^k \rangle}{\langle p^k, Ap^k \rangle}.$$

Подставим их в формулу итерации (Л6.4) в скалярное произведение:

$$\begin{aligned} \langle r^k, p^j \rangle &= \langle Ax^k - b, p^j \rangle = \left\langle A \left(x^0 - \sum_{i=0}^{k-1} \frac{\langle r^0, p^i \rangle}{\langle p^i, Ap^i \rangle} p^i \right) - b, p^j \right\rangle \\ &= \langle Ax^0 - b, p^j \rangle - \sum_{i=0}^{k-1} \frac{\langle r^0, p^i \rangle}{\langle p^i, Ap^i \rangle} \langle p^j, Ap^i \rangle \\ &= \langle r^0, p^j \rangle - \frac{\langle r^0, p^j \rangle}{\langle p^j, Ap^j \rangle} \langle p^j, Ap^j \rangle = 0. \end{aligned}$$

Покажем равносильность 1 и 2. Введём функцию $\phi: \mathbb{R}^k \rightarrow \mathbb{R}$, определённую как

$$\phi(\gamma) = f(x^0 + \gamma_0 p^0 + \dots + \gamma_{k-1} p^{k-1}).$$

По сути, это сужение функции f на множество P . Поскольку функция f — сильно выпукла, а все векторы p^i ненулевые, то и композиция f с линейным взаимно однозначным преобразованием из R^k в P , будет сильно выпуклой функцией. Отсюда следует, что у ϕ существует единственный минимум γ^* (Теорема Л2.3). Тогда, пользуясь необходимым и достаточным условием глобального минимума сильно выпуклой функции, получаем:

$$\frac{\partial \phi(\gamma^*)}{\partial \gamma_j} = \langle \nabla f(x^0 + \gamma_0^* p^0 + \dots + \gamma_{k-1}^* p^{k-1}), p^j \rangle = 0.$$

Воспользуемся явным видом f :

$$\nabla f(x^0 + \gamma_0^* p^0 + \dots + \gamma_{k-1}^* p^{k-1}) = \nabla f(x^k) = Ax^k - b = r^k.$$

■

Суть этой теоремы в том, что вектор невязки на k -ой итерации ортогонален всем найденным направлениям. Этот факт нам понадобится позже для ускорения вычислений и доказательства корректности выбора направлений.

Теперь перейдём к способу поиска p^{k+1} . Если вспомнить формулу обновления x^k (Л6.4), то можно заметить, что она похожа на градиентный спуск. Поэтому в качестве нулевого направления можно взять антиградиент в стартовой точке:

$$p^0 = -\nabla f(x^0) = -r^0.$$

Множество из одного вектора всегда сопряжено, поэтому ничего дополнительно требовать не надо. Последующие направления надо конструировать так, чтобы они были сопряжены всем уже найденным. Для этого предложим следующую формулу:

$$p^{k+1} = -r^{k+1} + \beta_k p^k, \quad (\text{Л6.5})$$

где β_k будем подбирать, требуя сопряжённость p^k и p^{k+1} :

$$\langle p^{k+1}, Ap^k \rangle = \langle -r^{k+1} + \beta_k p^k, Ap^k \rangle = -\langle r^{k+1}, Ap^k \rangle + \beta_k \langle p^k, Ap^k \rangle = 0.$$

Откуда получаем

$$\beta_k = \frac{\langle r^{k+1}, Ap^k \rangle}{\langle p^k, Ap^k \rangle}.$$

Применяя этот алгоритм поиска p^i , можем записать метод сопряжённых градиентов.

Алгоритм Л6.1 Метод сопряжённых градиентов (теоретическая версия)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовая невязка $r^0 = Ax^0 - b$, стартовый сопряжённый вектор $p^0 = -r^0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle}$

3: $x^{k+1} = x^k + \alpha_k p^k$

4: $r^{k+1} = Ax^{k+1} - b$

5: $\beta_k = \frac{\langle r^{k+1}, Ap^k \rangle}{\langle p^k, Ap^k \rangle}$

6: $p^{k+1} = -r^{k+1} + \beta_k p^k$

7: **end for**

Выход: x^K

Сейчас мы можем гарантировать только сопряжённость p^k и p^{k+1} . А по тому, как мы строили метод, нам нужна сопряжённость p^{k+1} со всеми $p^i, i \leq k$. Для этого докажем соответствующую теорему.

Теорема Л6.4 (Теорема 5.3 из [31]). Пусть на k -ой итерации метод сопряжённых градиентов (Алгоритм Л6.1) получил точку x^k , которая не является решением x^* . Тогда верны следующие свойства:

1. $\text{span}\{r^0, r^1, \dots, r^k\} = \text{span}\{r^0, Ar^0, \dots, A^k r^0\};$

2. $\text{span}\{p^0, p^1, \dots, p^k\} = \text{span}\{r^0, Ar^0, \dots, A^k r^0\};$

3. $\langle p^k, Ap^i \rangle = 0, \quad i = \overline{0, k-1};$

4. $\langle r^k, r^i \rangle = 0, \quad i = \overline{0, k-1}.$

Более того, метод сходится к решению x^* не более чем за d шагов.

Доказательство. Предположим, что утверждения (1), (2) и (3) верны для некоторого k и докажем их для $k+1$. Утверждения тривиально верны для $k=0$, а утверждение (3) верно для $k=1$ из-за выбора β .

Доказательство (1). Сначала покажем, что левая часть включена в правую. По предположению индукции:

$$\begin{aligned} r^k &\in \text{span}\{r^0, Ar^0, \dots, A^k r^0\}, \\ p^k &\in \text{span}\{r^0, Ar^0, \dots, A^k r^0\}. \end{aligned}$$

Тогда:

$$Ap^k \in \text{span}\{Ar^0, A^2 r^0, \dots, A^{k+1} r^0\}.$$

По формуле обновления

$$r^{k+1} = Ax^{k+1} - b = A(x^k + \alpha_k p^k) - b = r^k + \alpha_k Ap^k. \quad (\text{Л6.6})$$

Получаем:

$$r^{k+1} \in \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}.$$

Отсюда получаем вложение:

$$\text{span}\{r^0, r^1, \dots, r^k, r^{k+1}\} \subseteq \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}.$$

Для доказательства обратного включения воспользуемся (2) и заметим:

$$A^{k+1} r^0 = A(A^k r^0) \in A \text{span}\{p^0, \dots, p^k\}.$$

Поскольку по формуле обновления невязки:

$$Ap^i = \frac{r^{i+1} - r^i}{\alpha_i}, \quad i = \overline{0, k},$$

то получаем:

$$A^{k+1} r^0 \in \text{span}\{r^0, r^1, \dots, r^{k+1}\},$$

и, следовательно:

$$\text{span}\{r^0, r^1, \dots, r^{k+1}\} \supseteq \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}.$$

Таким образом, утверждение (1) выполнено при $k+1$.

Доказательство (2). Используем формулу для получения нового вектора p^{k+1} (Л6.5) и утверждение (1):

$$\begin{aligned} \text{span}\{p^0, \dots, p^k, p^{k+1}\} &= \text{span}\{p^0, \dots, p^k, r^{k+1}\} \\ &= \text{span}\{r^0, Ar^0, \dots, A^k r^0, r^{k+1}\} \\ &= \text{span}\{r^0, r^1, \dots, r^k, r^{k+1}\} \\ &= \text{span}\{r^0, Ar^0, \dots, A^{k+1} r^0\}, \end{aligned}$$

что и требовалось.

Доказательство (3). Скалярно умножим (Л6.5) на Ap^i при $i = \overline{0, k}$:

$$\langle p^{k+1}, Ap^i \rangle = -\langle r^{k+1}, Ap^i \rangle + \beta_k \langle p^k, Ap^i \rangle.$$

При $i = k$ правая часть обнуляется по определению β_k . Покажем это и при $i < k$.

По предположению индукции направления $p^0, \dots, p^k$ — сопряжённые, а значит по Теореме Л6.3:

$$\langle r^{k+1}, p^i \rangle = 0, \quad i = \overline{0, k}.$$

Воспользуемся утверждением (2):

$$Ap^i \in A \operatorname{span}\{r^0, Ar^0, \dots, A^i r^0\} = \operatorname{span}\{Ar^0, A^2 r^0, \dots, A^{i+1} r^0\} \subset \operatorname{span}\{p^0, \dots, p^{i+1}\}.$$

Следовательно:

$$\langle r^{k+1}, Ap^i \rangle = 0, \quad i = \overline{0, k-1}.$$

Кроме того, по предположению индукции для (3):

$$\langle p^k, Ap^i \rangle = 0, \quad i = \overline{0, k-1}.$$

Таким образом, $\langle p^{k+1}, Ap^i \rangle = 0$ для всех $i = \overline{0, k}$, что завершает доказательство.

Доказательство (4). Покажем, что невязка r^k ортогональна предыдущим. Так как $p^0, \dots, p^{k-1}$ — сопряжены, то по Теореме Л6.3:

$$\langle r^k, p^i \rangle = 0, \quad i = \overline{0, k-1}.$$

Из формулы обновления направления (Л6.5):

$$p^i = -r^i + \beta_i p^{i-1},$$

получаем:

$$r^i \in \operatorname{span}\{p^i, p^{i-1}\}, \quad i = \overline{1, k-1}.$$

Следовательно:

$$\langle r^k, r^i \rangle = 0, \quad i = \overline{1, k-1}.$$

Кроме того, $p^0 = -r^0 \implies \langle r^k, r^0 \rangle = 0$, то есть утверждение также доказано.

Все четыре утверждения выполнены, и по Теореме Л6.2, метод сходится к решению x^* не более чем за d шагов. ■

Теперь, когда доказана корректность и скорость сходимости метода до точного решения, можно проанализировать результаты. Итак, для решения системы из d линейных уравнений методу требуется d итераций. На каждой итерации несколько перемножений векторов, а также два перемножения матрицы A на вектор. Последнее наиболее дорого с точки зрения вычислений, каждое умножение порядка d^2 арифметических операций. При выполнении d итераций, получаем $\mathcal{O}(d^3)$ арифметических операций суммарно. А если вспомнить классические алгоритмы решения систем линейных уравнений, например, метод Гаусса, то мы не получили никакого выигрыша по скорости. Тогда появляется вопрос: чем метод сопряжённых градиентов лучше? Ответ заключается в том, что метод сопряжённых градиентов итеративный, то есть на каждой итерации мы получаем какое-то приближение решения. И зачастую нас устроит неточное, но достаточно хорошее решение. Тогда мы можем сделать не все d итераций, а оборвать цикл раньше.

К тому же, мы на данный момент получили много полезных фактов про сопряжённые направления, векторы невязки и их обновления. Это нам позволит ускорить медленную версию метода в константу раз. Начнем с α_k :

$$\alpha_k = -\frac{\langle r^k, p^k \rangle}{\langle p^k, Ap^k \rangle} = -\frac{\langle r^k, -r^k + \beta_k p^{k-1} \rangle}{\langle p^k, Ap^k \rangle} = \frac{\langle r^k, r^k \rangle}{\langle p^k, Ap^k \rangle}.$$

Также по формуле (Л6.6) можно записать:

$$r^{k+1} = r^k + \alpha_k Ap^k.$$

Остается поработать с β_k . Выражаем $Ap^k = \frac{1}{\alpha_k}(r^{k+1} - r^k)$ и подставляем:

$$\beta_k = \frac{\langle r^{k+1}, Ap^k \rangle}{\langle p^k, Ap^k \rangle} = \frac{\langle r^{k+1}, r^{k+1} - r^k \rangle}{\langle -r^k + \beta_k p^{k-1}, r^{k+1} - r^k \rangle} = \frac{\langle r^{k+1}, r^{k+1} \rangle}{\langle r^k, r^k \rangle}.$$

Запишем обновленную версию алгоритма.

Алгоритм Л6.2 Метод сопряжённых градиентов

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовая невязка $r^0 = Ax^0 - b$, стартовый сопряжённый вектор $p^0 = -r^0$, количество итераций K

1: **for** $k = 0, 1, \dots, K-1$ **do**

2: $\alpha_k = \frac{\langle r^k, r^k \rangle}{\langle p^k, Ap^k \rangle}$

3: $x^{k+1} = x^k + \alpha_k p^k$

4: $r^{k+1} = r^k + \alpha_k Ap^k$

5: $\beta_k = \frac{\langle r^{k+1}, r^{k+1} \rangle}{\langle r^k, r^k \rangle}$

6: $p^{k+1} = -r^{k+1} + \beta_k p^k$

7: **end for**

Выход: x^K

По итогу сэкономили 1 умножение матрицы на вектор и получили ускорение за счёт константы. Проведем теоретический анализ.

Определение Л6.2. Пусть даны матрица $A \in \mathbb{S}_{++}^d$ и вектор $x \in \mathbb{R}^d$. Функцию $\|\cdot\|_A$, определённую как

$$\|x\|_A = \sqrt{\langle x, Ax \rangle},$$

будем называть *A-нормой*.

Теорема Л6.5 (Формула (5.32) из [31]). Пусть система линейных уравнений (Л6.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л6.2). Тогда справедлива следующая оценка скорости сходимости:

$$\|x^K - x^*\|_A^2 \leq \min_{P_{K-1}} \max_{i=1, \dots, d} [1 + \lambda_i P_{K-1}(\lambda_i)]^2 \|x^0 - x^*\|_A^2,$$

где λ_i , $i = \overline{1, d}$ — собственные значения матрицы A , а минимум берется по P_K — все полиномы степени K .

Доказательство. Точку x^{k+1} мы строим как

$$x^{k+1} = x^0 + \sum_{i=0}^k \alpha_i p^i.$$

В Теореме Л6.4 мы показали, что

$$\text{span}\{p^0, \dots, p^k\} = \text{span}\{r^0, Ar^0, \dots, A^k r^0\}.$$

Тогда $x^{k+1} \in x^0 + \text{span}\{r^0, Ar^0, \dots, A^k r^0\}$ и мы можем представить x^{k+1} как линейную комбинацию:

$$x^{k+1} = x^0 + \gamma_0 r^0 + \gamma_1 Ar^0 + \dots + \gamma_k A^k r^0.$$

Можем ввести полином P_k^* степени k . И поскольку A — квадратная матрица, можно взять её в качестве аргумента P_k^* :

$$P_k^*(A) = \gamma_0 I_d + \gamma_1 A + \dots + \gamma_k A^k.$$

Тогда справедлива запись:

$$x^{k+1} = x^0 + P_k^*(A)r^0.$$

Воспользуемся A -нормой и запишем:

$$\frac{1}{2}\|x - x^*\|_A^2 = \frac{1}{2}\langle x - x^*, A(x - x^*) \rangle = f(x) - f^*,$$

где $f(x) = \frac{1}{2}\langle x, Ax \rangle - \langle b, x \rangle$.

Согласно Теореме Л6.3 x^{k+1} минимизирует f на множестве

$$P = x^0 + \text{span}\{p^0, \dots, p^k\} = x^0 + \text{span}\{r^0, Ar^0, \dots, A^k r^0\},$$

а следовательно, минимизирует и $\|x - x^*\|_A^2$.

Любой точке из P можно сопоставить свой полином P_k степени k . Объединяя это с предыдущим фактом, имеем, что

$$P_k^* = \underset{P_k}{\text{argmin}} \|x^0 + P_k(A)r^0 - x^*\|_A.$$

Поскольку

$$r^0 = Ax^0 - b = A(x^0 - x^*),$$

то верно

$$x^{k+1} - x^* = x^0 + P_k^*(A)r^0 - x^* = (I_d + P_k^*(A)A)(x^0 - x^*). \quad (\text{Л6.7})$$

Пусть $0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_d$ — собственные числа A , а $v^1, v^2, \dots, v^d$ — соответствующие ортонормированные собственные векторы. Так как они являются ортонормированным базисом в $\mathbb{R}^d$, то можно разложить по ним:

$$x^0 - x^* = \sum_{i=1}^d \xi_i v^i. \quad (\text{Л6.8})$$

Посмотрим, как матрица $P_k^*(A)$ действует на v^i :

$$P_k^*(A)v^i = \sum_{j=0}^k \gamma_j A^j v^i = \sum_{j=0}^k \gamma_j \lambda_i^j v^i = P_k^*(\lambda_i)v^i, \quad i = \overline{1, d}.$$

Получается, что $P_k^*(\lambda_1), \dots, P_k^*(\lambda_d)$ — собственные значения $P_k^*(A)$, отвечающие собственным векторам $v^1, \dots, v^d$.

Подставляя разложение (Л6.8) в (Л6.7), получим:

$$x^{k+1} - x^* = \sum_{i=1}^d (1 + \lambda_i P_k^*(\lambda_i)) \xi_i v^i,$$

откуда для A -нормы:

$$\|x^{k+1} - x^*\|_A^2 = \langle x^{k+1} - x^*, A(x^{k+1} - x^*) \rangle = \sum_{i=1}^d \lambda_i (1 + \lambda_i P_k^*(\lambda_i))^2 \xi_i^2.$$

Теперь применяем оптимальность P_k^* по отношению к A -норме:

$$\|x^{k+1} - x^*\|_A^2 = \min_{P_k} \sum_{i=1}^d \lambda_i (1 + \lambda_i P_k(\lambda_i))^2 \xi_i^2.$$

Вынося самый большой множитель $(1 + \lambda_i P_k(\lambda_i))^2$ из суммы, получаем оценку:

$$\begin{aligned} \|x^K - x^*\|_A^2 &\leq \min_{P_{K-1}} \max_{i=1, d} (1 + \lambda_i P_{K-1}(\lambda_i))^2 \left(\sum_{i=1}^d \lambda_i \xi_i^2 \right) \\ &= \min_{P_{K-1}} \max_{i=1, d} (1 + \lambda_i P_{K-1}(\lambda_i))^2 \|x^0 - x^*\|_A^2. \end{aligned}$$

■

Теорема Л6.6 (Теорема 5.4 из [31]). Пусть система линейных уравнений (Л6.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л6.2). Тогда если матрица A имеет только r различных собственных значений, то метод сойдётся к точному решению x^* не более чем за r итераций.

Доказательство. Пусть собственные значения матрицы A равны $\lambda_1, \lambda_2, \dots, \lambda_d$ и принимают r различных значений $\tau_1 < \tau_2 < \dots < \tau_r$. Определим полином $Q_r(\lambda)$:

$$Q_r(\lambda) = \frac{(-1)^r}{\tau_1 \tau_2 \dots \tau_r} (\lambda - \tau_1)(\lambda - \tau_2) \dots (\lambda - \tau_r).$$

Его корнями являются $\tau_1, \tau_2, \dots, \tau_r$, а в нуле он принимает значение $Q_r(0) = 1$. Следовательно, многочлен $Q_r(\lambda) - 1$ имеет степень r и корень 0. Тогда, определённый как

$$\bar{P}_{r-1}(\lambda) = \frac{Q(\lambda) - 1}{\lambda}$$

многочлен имеет степень $r-1$. Применяя оценку из Теоремы Л6.5, и в качестве оценки минимума сверху возьмём $\bar{P}_{r-1}$:

$$0 \leq \min_{P_{r-1}} \max_{i=1, d} (1 + \lambda_i P_{r-1}(\lambda_i))^2 \leq \max_{i=1, d} (1 + \lambda_i \bar{P}_{r-1}(\lambda_i))^2 = \max_{i=1, d} Q_r^2(\lambda_i) = 0.$$

Таким образом, мы подобрали многочлен $\bar{P}_{r-1}$, который даёт точную оценку в неравенстве выше. Тогда согласно оценке из Теоремы Л6.5:

$$\|x^r - x^*\|_A^2 \leq \min_{P_{r-1}} \max_{i=1, d} [1 + \lambda_i P_{r-1}(\lambda_i)]^2 \|x^0 - x^*\|_A^2 = 0.$$

■

Помимо оценок для достижения точного решения, есть оценка и для ошибки на k -ой итерации.

Теорема Л6.7 (Теорема 5.5 из [31]). Пусть система линейных уравнений (Л6.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л6.2). Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_A^2 \leq \left(\frac{\lambda_{d-K+1} - \lambda_1}{\lambda_{d-K+1} + \lambda_1} \right)^2 \|x^0 - x^*\|_A^2,$$

где $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_d$ — собственные числа матрицы A .

Доказательство. Запишем оценку сходимости из Теоремы Л6.5:

$$\|x^{K+1} - x^*\|_A^2 \leq \min_{P_K} \max_{i=1,d} [1 + \lambda_i P_K(\lambda_i)]^2 \|x^0 - x^*\|_A^2.$$

Построим многочлен $\bar{P}_K(\lambda)$, который позволит оценить минимум сверху. Для этого определим многочлен $Q_{K+1}(\lambda)$:

$$Q_{K+1}(\lambda) = \frac{(-1)^{K+1} \cdot (\lambda - \lambda_d)(\lambda - \lambda_{d-1}) \dots (\lambda - \lambda_{d-K+1}) \left(\lambda - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)}{\lambda_d \lambda_{d-1} \dots \lambda_{d-K+1} \cdot \frac{\lambda_1 + \lambda_{d-K}}{2}}.$$

В нуле он принимает значение 1, поэтому многочлен $Q_{K+1}(\lambda) - 1$ степени $K+1$ и имеет корень в нуле. Полином $\bar{P}_K$ степени K определим как

$$\bar{P}_K(\lambda) = \frac{Q_{K+1}(\lambda) - 1}{\lambda}.$$

Его и подставим для нашей оценки:

$$0 \leq \min_{P_K} \max_{i=1,d} [1 + \lambda_i P_K(\lambda_i)]^2 \leq \max_{i=1,d} [1 + \lambda_i \bar{P}_K(\lambda_i)]^2 = \max_{i=1,d} Q_{K+1}^2(\lambda_i).$$

Внимательнее посмотрим, как выглядит выражение справа:

$$\max_{i=1,d} Q_{K+1}^2(\lambda_i) = \max_{i=1,d} \frac{(\lambda_i - \lambda_d)^2 (\lambda_i - \lambda_{d-1})^2 \dots (\lambda_i - \lambda_{d-K+1})^2 \left(\lambda_i - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}{\lambda_d^2 \lambda_{d-1}^2 \dots \lambda_{d-K+1}^2 \cdot \left(\frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}.$$

В знаменателе константы, которые не зависят от i . Остаётся максимизировать только числитель. На значениях $\lambda_d, \dots, \lambda_{d-K+1}$ числитель равен нулю. Среди оставшихся собственных чисел скобка $\left(\lambda_i - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2$ максимальна и принимает одинаковые значения в точках λ_1 и λ_{d-K} . Однако другие члены в произведении монотонно растут при движении от λ_{d-K} к λ_1 . Отсюда делаем вывод, что в λ_1 достигается максимум каждого отдельного неотрицательного члена в произведении, поэтому и всего произведения. Продолжаем оценку значением в точке λ_1 :

$$\begin{aligned} \max_{i=1,d} Q_{K+1}^2(\lambda_i) &= \frac{(\lambda_1 - \lambda_d)^2 (\lambda_1 - \lambda_{d-1})^2 \dots (\lambda_1 - \lambda_{d-K+1})^2 \left(\lambda_1 - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}{\lambda_d^2 \lambda_{d-1}^2 \dots \lambda_{d-K+1}^2 \cdot \left(\frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2} \\ &\leq \frac{\left(\lambda_1 - \frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2}{\left(\frac{\lambda_1 + \lambda_{d-K}}{2} \right)^2} = \left(\frac{\lambda_{d-K} - \lambda_1}{\lambda_{d-K} + \lambda_1} \right)^2. \end{aligned}$$

Эта оценка завершает доказательство. ■

Таким образом, если мы сделали k итераций, и разница между λ_{d-k} и λ_1 уже достаточно мала, то можно остановить метод. На практике часто бывает, что у матрицы 5–10 больших собственных значений, а остальные сильно меньше. В таких случаях метод сопряжённых градиентов находит достаточно хорошее решение быстрее остальных методов (метода тяжёлого шарика, метода Нестерова). На самом деле, имеет место и другая оценка, более напоминающая ранее полученные оценки для ускоренных методов.

Теорема Л6.8 (Формула (5.35) из [31]). Пусть система линейных уравнений (Л6.1) решается с помощью метода сопряжённых градиентов (Алгоритм Л6.2). Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_A \leq 4 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^{2K} \|x^0 - x^*\|_A,$$

где $\kappa(A) = \lambda_{\max}(A)/\lambda_{\min}(A)$ — число обусловленности матрицы A .

Доказательство. Обратимся к оценке из Теоремы Л6.5:

$$\|x^K - x^*\|_A^2 \leq \min_{P_{K-1}} \max_{i=1, d} [1 + \lambda_i P_{K-1}(\lambda_i)]^2 \|x^0 - x^*\|_A^2.$$

Обозначим

$$Q_K(\lambda) = 1 + \lambda P_{K-1}(\lambda).$$

Теперь мы можем искать минимум по всем многочленам $Q_K(\lambda)$ степени K с ограничением $Q_K(0) = 1$:

$$\|x^K - x^*\|_A^2 \leq \min_{Q_K: Q_K(0)=1} \max_{i=1, d} Q_K^2(\lambda_i) \|x^0 - x^*\|_A^2.$$

В желаемой оценке должны присутствовать только максимальное и минимальное собственные значения, поэтому подберём многочлен, который минимально отклоняется от нуля на отрезке $[\lambda_{\min}, \lambda_{\max}]$, при этом удовлетворяет ограничению $Q_K(0) = 1$:

$$\|x^K - x^*\|_A^2 \leq \min_{Q_K: Q_K(0)=1} \max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) \|x^0 - x^*\|_A^2.$$

Такой многочлен можно построить, используя полиномы Чебышёва. Определяются они следующим образом:

$$T_k(z) = \begin{cases} \frac{1}{2} \left((z + \sqrt{z^2 - 1})^k + (z - \sqrt{z^2 - 1})^k \right), & |z| > 1, \\ \cos(k \arccos z), & |z| \leq 1. \end{cases}$$

Главное их свойство, что на отрезке $[-1, 1]$ они наименьшим образом отклоняются от 0, ровно то свойство, что нам хочется. Остается только биективно отобразить отрезок $[\lambda_{\min}, \lambda_{\max}]$ на $[-1, 1]$ и выполнить ограничение в нуле. Из этих рассуждений, получаем многочлен

$$Q_K(\lambda) = T_K \left(\frac{\lambda_{\min} + \lambda_{\max} - 2\lambda}{\lambda_{\max} - \lambda_{\min}} \right) / T_K \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} \right).$$

Действительно, это многочлен от λ степени K , линейное преобразование под аргументом биективно отображает отрезок $[\lambda_{\min}, \lambda_{\max}]$ в $[-1, 1]$. Это обеспечивает минимальное отклонение от нуля на заданном отрезке. Деление на константу необходимо, чтобы выполнить ограничение на значение в нуле. Теперь найдём максимум. Известно, что на $[-1, 1]$ максимальное значение модуля многочленов Чебышёва равно 1. С этого начинаем оценку:

$$\begin{aligned} \max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) &= \max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} \left(T_K \left(\frac{\lambda_{\min} + \lambda_{\max} - 2\lambda}{\lambda_{\max} - \lambda_{\min}} \right) / T_K \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} \right) \right)^2 \\ &= T_K^{-2} \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} \right). \end{aligned}$$

Подставляем выражение для полинома Чебышёва при $|z| > 1$:

$$\begin{aligned}
\max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) &= 4 \left(\left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} + \sqrt{\frac{(\lambda_{\max} + \lambda_{\min})^2}{(\lambda_{\max} - \lambda_{\min})^2} - 1} \right)^K \right. \\
&\quad \left. + \left(\frac{\lambda_{\max} + \lambda_{\min}}{\lambda_{\max} - \lambda_{\min}} - \sqrt{\frac{(\lambda_{\max} + \lambda_{\min})^2}{(\lambda_{\max} - \lambda_{\min})^2} - 1} \right)^K \right)^{-2} \\
&= 4 \left(\left(\frac{\lambda_{\max} + \lambda_{\min} + 2\sqrt{\lambda_{\max}\lambda_{\min}}}{\lambda_{\max} - \lambda_{\min}} \right)^K \right. \\
&\quad \left. + \left(\frac{\lambda_{\max} + \lambda_{\min} - 2\sqrt{\lambda_{\max}\lambda_{\min}}}{\lambda_{\max} - \lambda_{\min}} \right)^K \right)^{-2} \\
&= 4 \left(\left(\frac{\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}}}{\sqrt{\lambda_{\max}} - \sqrt{\lambda_{\min}}} \right)^K + \left(\frac{\sqrt{\lambda_{\max}} - \sqrt{\lambda_{\min}}}{\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}}} \right)^K \right)^{-2}.
\end{aligned}$$

Переписывая через число обусловленности $\kappa = \lambda_{\max}/\lambda_{\min}$:

$$\begin{aligned}
\max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} Q_K^2(\lambda) &= 4 \left(\left(\frac{\sqrt{\kappa} + 1}{\sqrt{\kappa} - 1} \right)^K + \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^K \right)^{-2} \\
&\leq 4 \left(\frac{\sqrt{\kappa} + 1}{\sqrt{\kappa} - 1} \right)^{-2K} = 4 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^{2K}.
\end{aligned}$$

■

Эта оценка более грубая, поскольку появляется зависимость от числа обусловленности. Если внимательно посмотреть на прошлую оценку, то в ней спустя k итераций мы обрабатываем k самых больших собственных чисел, и они более не дают свой вклад в оценку. В этой же формуле зависимость от самого большого собственного числа присутствует на всех итерациях. Сама же оценка похожа на оценки для ускоренных методов. Действительно, если перегруппировать и оценить, то можно получить множитель в правой части

$$\left(1 - 2 \frac{1}{\sqrt{\kappa(A)} + 1} \right)^{2K} \leq \left(1 - \sqrt{\frac{\mu}{L}} \right)^{2K}.$$

По этой оценке можно сделать вывод, что метод сопряжённых градиентов сходится как метод Нестерова на квадратичной задаче.

Л6.3 Нелинейные методы сопряжённых градиентов

Мы получили метод сопряжённых градиентов (Алгоритм Л6.2) для решения систем линейных уравнений (Л6.1) или, эквивалентно, минимизации квадратичной функции (Л6.2). Но что делать, если мы хотим решать более общую задачу, а именно безусловную задачу минимизации:

$$\min_{x \in \mathbb{R}^d} f(x),$$

где на f мы как и ранее будем накладывать условия L -гладкости и выпуклости.

Обобщить метод сопряжённых градиентов действительно возможно. Ранее мы подбирали шаг α_k как шаг наискорейшего спуска вдоль p^k . Для квадратичной функции он вычисляется аналитически. Для функции общего вида же потребуются осуществлять линейный поиск, например, как это было описано в Параграфе Л3 в разделе про подбор шага. Другим изменением будет замена r^k на $\nabla f(x^k)$. Это мотивировано тем, что для нелинейной функции нет понятия невязки, зато есть градиент, который в случае квадратичной функции совпадал с невязкой. Полученный модифицированный метод сопряжённых градиентов называется методом Флетчера–Ривса.

Алгоритм Л6.3 Метод сопряжённых градиентов (Флетчер–Ривс)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовый сопряжённый вектор $p^0 = -\nabla f(x^0)$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: α_k = линейный поиск
- 3: $x^{k+1} = x^k + \alpha_k p^k$
- 4: $\beta_k = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) \rangle}{\langle \nabla f(x^k), \nabla f(x^k) \rangle}$
- 5: $p^{k+1} = -\nabla f(x^{k+1}) + \beta_k p^k$
- 6: **end for**

Выход: x^K

В случае когда f — сильно выпуклая квадратичная функция и производится точный поиск α_k , итерации метода Флетчера–Ривса совпадают с классическим методом сопряжённых градиентов. Теоретические гарантии для метода достаточно слабые, и только если использовать сильные условия Вольфа для линейного поиска. Есть также модификации метода Флетчера–Ривса, например, Полак и Рибьер предложили другой вариант для подсчёта β_k .

Алгоритм Л6.4 Метод сопряжённых градиентов (Полак–Рибьер)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовый сопряжённый вектор $p^0 = -\nabla f(x^0)$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: α_k = линейный поиск
- 3: $x^{k+1} = x^k + \alpha_k p^k$
- 4: $\beta_k = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) - \nabla f(x^k) \rangle}{\langle \nabla f(x^k), \nabla f(x^k) \rangle}$
- 5: $p^{k+1} = -\nabla f(x^{k+1}) + \beta_k p^k$
- 6: **end for**

Выход: x^K

Если бы функция f была квадратичной и сильно выпуклой, то градиенты на соседних итерациях были бы ортогональны и итерации снова совпали с классическим вариантом (Алгоритм Л6.2). Для выпуклых гладких функций это не всегда правда, поэтому эта поправка действительно влияет на сходимость. На практике метод Полака–Рибьера сходится быстрее, чем метод Флетчера–Ривса.

Еще один вариант выбора β_k предложили Хестенс и Штифель. На практике такой метод сходится примерно как метод Полака–Рибьера.

Алгоритм Л6.5 Метод сопряжённых градиентов (Хестенс–Штифель)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовый сопряжённый вектор $p^0 = -\nabla f(x^0)$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $\alpha_k =$ линейный поиск

3: $x^{k+1} = x^k + \alpha_k p^k$

4: $\beta_k = \frac{\langle \nabla f(x^{k+1}), \nabla f(x^{k+1}) - \nabla f(x^k) \rangle}{\langle p^k, \nabla f(x^{k+1}) - \nabla f(x^k) \rangle}$

5: $p^{k+1} = -\nabla f(x^{k+1}) + \beta_k p^k$

6: **end for**

Выход: x^K

Л7 Метод Ньютона. Квазиньютоновские методы

Ранее мы рассматривали градиентные методы, которые благодаря низкой вычислительной стоимости шага остаются основным инструментом для задач с очень большой размерностью. Их скорость сходимости обычно линейная — этого достаточно во многих практических случаях. Но если использовать больше информации о целевой функции, можно продвигаться к решению быстрее. Методы второго порядка, такие как метод Ньютона, используют не только значения функции и градиента, но и информацию о гессиане, что позволяет достигать квадратичной скорости сходимости и существенно сокращать число итераций.

Л7.1 Задача поиска нуля

Рассмотрим задачу поиска «корня» функции. Формально требуется для непрерывно дифференцируемой функции $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ найти точку x^* , для которой верно

$$\varphi(x^*) = 0.$$

Пусть мы находимся в точке x^0 и хотим найти такую поправку Δx , что $x^0 + \Delta x \approx x^*$. Разложим φ по формуле Тейлора до первого порядка:

$$\varphi(x^0 + \Delta x) = \varphi(x^0) + \varphi'(x^0)\Delta x + o(\Delta x).$$

Поскольку $x^0 + \Delta x \approx x^*$, то:




$$\varphi(x^0 + \Delta x) \approx \varphi(x^*) = 0 \implies \varphi(x^0) + \varphi'(x^0)\Delta x \approx 0.$$

Таким образом, $\Delta x \approx -\frac{\varphi(x^0)}{\varphi'(x^0)}$, $x^1 = x^0 - \frac{\varphi(x^0)}{\varphi'(x^0)}$. Продолжая строить новые точки, получаем выражение для итерации метода, предложенного Ньютоном в 17-м веке [30]:

$$x^{k+1} = x^k - \frac{\varphi(x^k)}{\varphi'(x^k)}. \quad (\text{Л7.1})$$

Пример Л7.1. Важно отметить ключевую особенность предложенного метода — сходимость к решению только в некоторой его окрестности. В качестве примера можно рассмотреть $\varphi(x) = \frac{x}{\sqrt{1+x^2}}$. Выберем в качестве начального приближения некоторую точку x^0 . Тогда нетрудно видеть, что:

- $|x^0| < 1$ — метод сходится;
- $|x^0| = 1$ — метод колеблется в точках -1 и 1 ;
- $|x^0| > 1$ — метод расходится.



Л7.2 Метод Ньютона

Вернемся к задаче безусловной минимизации:

$$\min_{x \in \mathbb{R}^d} f(x). \quad (\text{Л7.2})$$

Ранее уже обсуждалось, что для выпуклой целевой функции она эквивалентна задаче поиска нуля градиента:

$$\nabla f(x^*) = 0,$$

где $\nabla f : \mathbb{R}^d \rightarrow \mathbb{R}^d$.

Применим рассмотренный ранее подход к этой задаче. Заменяя в формуле (Л7.1) $\varphi = \nabla f$ и $\varphi' = \nabla^2 f$, мы ожидаем получить шаг:

$$x^{k+1} = x^k - (\nabla^2 f(x))^{-1} \nabla f(x).$$

Как ещё можно посчитать такую операцию? Будем минимизировать квадратичную аппроксимацию целевой функции:

$$f(x) \approx f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \langle \nabla^2 f(x^k)(x - x^k), x - x^k \rangle.$$

Построим x^{k+1} как точку, где зануляется градиент квадратичной аппроксимации:

$$\nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0 \implies x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k).$$

Действительно, получили то, что ожидали:

Алгоритм Л7.1 Метод Ньютона

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k)$

3: **end for**

Выход: x^K

Пример Л7.2. Рассмотрим задачу:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{2} \langle x, Ax \rangle - \langle b, x \rangle + c \right],$$

где $A \in \mathbb{S}_+^d$.

Пусть x^* — решение задачи. Тогда нетрудно заметить, что

$$\nabla f(x^*) = Ax^* - b = 0,$$

то есть $x^* = A^{-1}b$. При этом также нетрудно заметить, что

$$(\nabla^2 f(x))^{-1} \nabla f(x) = A^{-1}(Ax - b) = x - A^{-1}b.$$

Таким образом, метод Ньютона для квадратичной задачи сходится за одну итерацию. Важно отметить, что вычислительная стоимость этой итерации очень велика не только из-за использования гессиана, но еще и из-за его обращения за $\mathcal{O}(d^3)$.

Далее будем работать в предположении, что целевая функция в задаче безусловной минимизации является дважды непрерывно дифференцируемой, μ -сильно выпуклой, а также имеет M -Липшицев гессиан:

Определение Л7.1. Пусть дана дважды непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что данная функция имеет *M-Липшицев гессиан*, если для любых $x, y \in \mathbb{R}^d$ выполнено

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq M\|x - y\|_2.$$

Утверждение Л7.1. Пусть функция f имеет *M-Липшицев гессиан*. Введём обозначение

$$G = \nabla^2 f(x) - \int_0^1 \nabla^2 f(x^* + \tau(x - x^*)) d\tau.$$

Тогда справедлива оценка:

$$\|G\|_2 \leq \frac{M}{2} \|x - x^*\|_2.$$

Доказательство. Распишем норму, воспользуемся неравенством треугольника и *M-липшицевостью гессиана*:

$$\begin{aligned} \|G\|_2 &= \left\| \nabla^2 f(x) - \int_0^1 \nabla^2 f(x^* + \tau(x - x^*)) d\tau \right\|_2 \\ &= \left\| \int_0^1 (\nabla^2 f(x) - \nabla^2 f(x^* + \tau(x - x^*))) d\tau \right\|_2 \\ &\leq \int_0^1 \|\nabla^2 f(x) - \nabla^2 f(x^* + \tau(x - x^*))\|_2 d\tau \\ &\leq \int_0^1 M(1 - \tau)\|x - x^*\|_2 d\tau \\ &= M\|x - x^*\|_2 \int_0^1 (1 - \tau) d\tau \\ &= \frac{M}{2} \|x - x^*\|_2. \end{aligned}$$

Получили требуемую оценку. ■

Теперь можем сформулировать теорему о сходимости метода Ньютона.

Теорема Л7.1. Пусть задача безусловной оптимизации (Л7.2) с μ -сильно выпуклой целевой функцией f , имеющей *M-Липшицев гессиан*, решается с помощью метода Ньютона (Алгоритм Л7.1). Тогда справедлива следующая оценка сходимости:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2.$$

Доказательство. Будем изучать, как меняется расстояние до решения:

$$x^{k+1} - x^* = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k) - x^*.$$

Воспользуемся формулой Ньютона-Лейбница для интеграла вдоль кривой:

$$\nabla f(x^k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) \, d\tau.$$

Зная, что $\nabla f(x^*) = 0$, получим:

$$x^{k+1} - x^* = x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) \, d\tau.$$

Домножим $x^k - x^*$ на «умную единицу» ($I = (\nabla^2 f(x^k))^{-1} \nabla^2 f(x^k)$):

$$\begin{aligned} x^{k+1} - x^* &= x^k - x^* - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) \, d\tau \\ &= (\nabla^2 f(x^k))^{-1} \nabla^2 f(x^k) (x^k - x^*) \\ &\quad - (\nabla^2 f(x^k))^{-1} \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) (x^k - x^*) \, d\tau. \end{aligned}$$

Заметим, что $x^k - x^*$ можно вынести за пределы интеграла:

$$\begin{aligned} x^{k+1} - x^* &= (\nabla^2 f(x^k))^{-1} \underbrace{\left(\nabla^2 f(x^k) - \int_0^1 \nabla^2 f(x^* + \tau(x^k - x^*)) \, d\tau \right)}_{=G_k} (x^k - x^*) \\ &= (\nabla^2 f(x^k))^{-1} G_k (x^k - x^*). \end{aligned}$$

Спектральная норма матрицы согласована с евклидовой нормой вектора. Таким образом:

$$\|x^{k+1} - x^*\|_2 \leq \|(\nabla^2 f(x^k))^{-1}\|_2 \|G_k\|_2 \|x^k - x^*\|_2.$$

Норму обратного гессиана оценим как $\|(\nabla^2 f(x^k))^{-1}\|_2 = \frac{1}{\lambda_{\min}(\nabla^2 f(x^k))} \leq \frac{1}{\mu}$. Остается лишь применить результат Утверждения Л7.1, и получим требуемое:

$$\|x^{k+1} - x^*\|_2 \leq \frac{M}{2\mu} \|x^k - x^*\|_2^2.$$

■

Замечание Л7.1. Сходимость является локальной. А именно, чтобы гарантировать

$$\|x^1 - x^*\|_2 < \|x^0 - x^*\|_2,$$

нужно предположить, что:

$$\|x^0 - x^*\|_2 < \frac{2\mu}{M}.$$

Приведем пример, когда метод Ньютона расходится при старте из плохого приближения.

Пример Л7.3. Рассмотрим функцию $f : \mathbb{R} \rightarrow \mathbb{R}$:

$$f(x) = \frac{x^2}{2} + 10 \log \cosh x.$$

Её минимум находится в точке $x^* = 0$.

Найдём константу сильной выпуклости μ и константу липшицевости гессиана M .

Первые три производные имеют вид:

$$\begin{aligned} f'(x) &= x + 10 \tanh x, \\ f''(x) &= 1 + \frac{10}{\cosh^2 x}, \\ f'''(x) &= -20 \frac{\tanh x}{\cosh^2 x}. \end{aligned}$$

Так как $\cosh^2 x \geq 1$, имеем

$$\mu = \min_{x \in \mathbb{R}} f''(x) = 1.$$

Для константы липшицевости гессиана в одномерном случае:

$$M = \sup_{x \in \mathbb{R}} |f'''(x)|.$$

Положим $t = \tanh x \in (-1, 1)$, тогда $\frac{1}{\cosh^2 x} = 1 - t^2$ и

$$|f'''(t)| = 20|t|(1 - t^2).$$

Это выражение достигает максимума при $t = \pm \frac{1}{\sqrt{3}}$, и, следовательно,

$$M = \frac{40}{3\sqrt{3}} \approx 7.692.$$

Согласно теоретическим оценкам, метод сходится при начальном приближении x^0 :

$$|x^0 - x^*| \leq \frac{2\mu}{M} = \frac{3\sqrt{3}}{20} \approx 0.260.$$

Однако оценка достаточно грубая, поскольку использует всего 2 константы, связанных с функцией. Найдём точно, где метод начинает расходиться.

Итерация метода Ньютона имеет вид

$$x^{k+1} = x^k - \frac{x^k + 10 \tanh x^k}{1 + \frac{10}{\cosh^2 x^k}}.$$

Поскольку минимум находится в нуле, функция f четная, то на границе области сходимости модуль следующей точки совпадает с текущим, а знак меняется:

$$x^{k+1} = -x^k.$$

Это условие даёт уравнение

$$2x = \frac{x + 10 \tanh x}{1 + \frac{10}{\cosh^2 x}},$$


положительный корень которого:

$$\bar{x} \approx 1.22258$$

и задаёт границу области сходимости.

Итого, поведение метода Ньютона:

- $|x^0| < \bar{x}$ — сходимость к 0 квадратичная.
- $|x^0| = \bar{x}$ — колебания.
- $|x^0| > \bar{x}$ — расходимость.



Замечание Л7.2. Существует несколько способов сделать сходимость метода Ньютона глобальной. Один из них — так называемый демпфированный метод с шагом

$$x^{k+1} = x^k - \gamma_k (\nabla^2 f(x^k))^{-1} \nabla f(x^k).$$

Стоит отметить, что на практике демпфированные методы сходятся медленнее.

Л7.3 Метод Ньютона с кубической регуляризацией

Вспомним идейно один из способов получить интуицию метода градиентного спуска. Пользуясь гладкостью градиента целевой функции, можно аппроксимировать её значение некоторым эллиптическим параболоидом. Далее можно явно выписать его минимум — это и будет шаг градиентного спуска. Попробуем распространить эту идею на методы высших порядков. Предположим, что целевая функция имеет M -липшицев гессиан. Тогда можно записать аппроксимацию второго порядка:

$$\xi_{2,x}(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3.$$

Она устроена так же, как и квадратичная парабола, которая строилась для L -гладких функций. Эта аппроксимация подпирает сверху целевую функцию, поэтому $f(y) \leq \xi_{2,x}(y)$. Построим итерационную схему, минимизирующую верхнюю оценку:

$$x^{k+1} = \operatorname{argmin}_{y \in \mathbb{R}^d} \xi_{2,x^k}(y).$$

Для простоты анализа определим

$$T_M(x) \in \operatorname{argmin}_{y \in \mathbb{R}^d} \left[\langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3 \right].$$

Здесь константа Липшица гессиана будет параметром, чтобы иметь возможность варьировать шаг. Такой подход называется кубической регуляризацией метода Ньютона.

Алгоритм Л17.2 Метод Ньютона с кубической регуляризацией

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, параметры $\{M_k\}_{k=0}^{K-1}$, количество итераций K
1: **for** $k = 0, \dots, K-1$ **do**
2: $x^{k+1} = T_{M_k}(x^k)$
3: **end for**
Выход: x^K

Далее мы предполагаем, что собственные значения гессиана пронумерованы в порядке убывания.

Теорема Л17.2 (Теорема 3 из [29]). Пусть задача безусловной оптимизации (Л17.2) с M -липшицевым гессианом целевой функции f решается с помощью метода Ньютона с кубической регуляризацией (Алгоритм Л17.2). Тогда при

$$\nabla^2 f(x^0) \succ 0, \quad \frac{M \|\nabla f(x^0)\|_2}{\lambda_d^2(\nabla^2 f(x^0))} \leq \frac{1}{4}$$

справедлива следующая оценка сходимости:

$$\|\nabla f(x^k)\|_2 \leq \lambda_d^2(\nabla^2 f(x^0)) \frac{9e^{3/2}}{16M} \left(\frac{1}{2}\right)^{2^k}.$$

Полученный метод представляет интерес, поскольку не требует выпуклости, только M -липшицевость гессиана и условия из теоремы в стартовой точке. Сходимость при этом квадратичная по норме градиента, то есть очень быстрая.

Стоит отметить, что рассматриваемая задача поиска аргминимума, вообще говоря, не выпуклая из-за кубического члена и может иметь локальные минимумы, в то время как нам нужно отыскать глобальный. Тем не менее, эта задача эквивалентна задаче выпуклой одномерной оптимизации.

Теорема Л17.3 (Теорема 10 из [29]). Задача

$$\min_{y \in \mathbb{R}^d} \left[\langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle \nabla^2 f(x)(y - x), y - x \rangle + \frac{M}{6} \|x - y\|_2^3 \right]$$

эквивалентна задаче

$$\min_{r \in \mathcal{D}} \left[\frac{1}{2} \left\langle \left(\nabla^2 f(x) + \frac{Mr}{2} I_d \right)^{-1} \nabla f(x), \nabla f(x) \right\rangle + \frac{M}{12} r^3 \right],$$

где

$$\mathcal{D} = \left\{ r \in \mathbb{R}_+ \mid \nabla^2 f(x) + \frac{Mr}{2} I_d \succ 0 \right\}.$$

Л17.4 Метод Ньютона с квадратичной регуляризацией

Недостаток стандартной версии метода Ньютона — расходимость даже для некоторых выпуклых задачах. Преимущество — явный вид итерации: необходимо обращать матрицу гессиана или же находить матрично-векторное произведение обратного гессиана на градиент. В то же время метод Ньютона с кубической регуляризацией мало того, что теоретически сходится для выпуклых задач, так ещё и показывает более лучшие

результаты на практике. Недостаток данного метода — для того, чтобы сделать одну итерацию необходимо решить новую оптимизационную задачу.

Чтобы совместить преимущества обоих методов: простоту итерации и хорошую сходимость, был предложен метод Ньютона с квадратичной регуляризацией, или же, регуляризацией Левенберга-Марквардта:

$$x^{k+1} = \operatorname{argmin}_{y \in \mathbb{R}^d} \left\{ \langle \nabla f(x^k), y - x^k \rangle + \frac{1}{2} \langle \nabla^2 f(x^k) (y - x^k), y - x^k \rangle + \frac{\lambda_k}{2} \|y - x^k\|_2^2 \right\}.$$

Преимуществом данной итерации является то, что у x^{k+1} есть явная запись:

$$x^{k+1} = x^k - (\nabla^2 f(x^k) + \lambda_k I_d)^{-1} \nabla f(x^k).$$

То есть сложность итерации такая же, как у метода Ньютона, но в то же время мы сохраняем регуляризацию.

Отдельной задачей является выбор λ на каждой итерации. Один из существующих подходов аналогичен Trust-Region подходу — деление на 2 в случае удачной итерации и домножение на 2 в случае неудачной. Данный подход прост в имплементации, но требователен к вычислительным ресурсам, так как в случае «неудачных итераций» обновление x^k не происходит, но вычисляются матрично-векторные произведения. Недавно в [11] был предложен новый способ выбора множителя λ_k , который каждую итерацию делает успешной и порядки сходимости которого совпадают с методом Ньютона с кубической регуляризацией с точностью до аддитивного логарифмического члена. Для этого достаточно взять

$$\lambda_k \sim \sqrt{M \|\nabla f(x^k)\|_2}.$$

Кроме того, что данный метод применим для выпуклых функций, также, он работает и для невыпуклых [10].

Л7.5 Квазиньютоновские методы

Метод Ньютона обеспечивает быструю локальную сходимость, однако вычислительная стоимость одной итерации часто оказывается слишком высокой: требуется находить обратный гессиан $(\nabla^2 f(x^k))^{-1}$. Идея квазиньютоновских методов заключается в том, чтобы заменить его на приближение H_k , сохраняющее ключевые свойства обратного гессиана, но гораздо более дешёвое в обновлении.

Начнём с линейной аппроксимации приращения градиента:

$$\nabla f(x^{k+1}) - \nabla f(x^k) \approx \nabla^2 f(x^k) (x^{k+1} - x^k).$$

Введём обозначения

$$s^k = x^{k+1} - x^k, \quad y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$$

и положим

$$B_{k+1} \approx \nabla^2 f(x^{k+1}), \quad H_{k+1} \approx (\nabla^2 f(x^{k+1}))^{-1}.$$

Тогда аппроксимация выше принимает вид

$$y^k = B_{k+1} s^k \iff s^k = H_{k+1} y^k. \quad (\text{Л7.3})$$

Это уравнение называют *квазиньютоновским*.

Замечание Л7.3. Условие симметричности и квазиньютоновское уравнение дают

$$\frac{d(d-1)}{2} + d = \frac{d(d+1)}{2}$$

линейно независимых ограничений на $d \times d$ матрицу. Поскольку общее число элементов матрицы равно d^2 , остаётся $\frac{d(d-1)}{2}$ свободных параметров. Это означает, что множество допустимых приближений очень велико и существует широкий спектр стратегий построения H_{k+1} или B_{k+1} . Ниже мы рассмотрим наиболее популярные из них.

Общая схема квазиньютоновских методов выглядит следующим образом:

Алгоритм Л7.3 Общая схема квазиньютоновских методов

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, стартовая матрица H_0 , размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K-1$ **do**

2: $x^{k+1} = x^k - \gamma_k H_k \nabla f(x^k)$

3: Обновить $H_k \rightarrow H_{k+1}$ так, чтобы выполнялось (Л7.3)

4: **end for**

Выход: x^K

Замечание Л7.4. Размеры шагов $\{\gamma_k\}_{k=0}^{K-1}$ могут выбираться с помощью процедуры линейного поиска. При этом можно как находить шаг наискорейшего спуска вдоль направления $H_k \nabla f(x^k)$, так и требовать выполнения условий Вольфа (Алгоритм Л3.6).

Л7.5.1 SR1

Будем использовать для обновления матрицы дешёвую с точки зрения вычислений симметричную одноранговую добавку (отсюда и название Symmetric Rank 1):

$$H_{k+1} = H_k + \mu_k q^k (q^k)^\top,$$

где $\mu_k \in \mathbb{R}$ и $q^k \in \mathbb{R}^d$. Их мы подбираем исходя из квазиньютоновского уравнения:

$$s^k = H_{k+1} y^k = \left(H_k + \mu_k q^k (q^k)^\top \right) y^k = H_k y^k + \mu_k \left((q^k)^\top y^k \right) q^k.$$

Откуда

$$\mu_k \left((q^k)^\top y^k \right) q^k = s^k - H_k y^k.$$

Возьмём $\mu_k = \frac{1}{(q^k)^\top y^k}$ и получим, что $q^k = s^k - H_k y^k$.

Итак, SR1 способ обновления матрицы H_k :

$$H_{k+1} = H_k + \frac{(s^k - H_k y^k) (s^k - H_k y^k)^\top}{(s^k - H_k y^k)^\top y^k}.$$

Л7.5.2 Broyden

Подойдем к задаче иначе. Запишем квазиньютоновское уравнение для матрицы B :

$$y^k = B_{k+1} s^k.$$

Потребуем минимальность фробениусовой нормы поправки при ограничении в виде квазиньютоновского уравнения:

$$\begin{aligned} B_{k+1} &= \operatorname{argmin}_{B \in \mathbb{R}^{d \times d}} \|B - B_k\|_F^2 \\ \text{s.t. } B s^k &= y^k. \end{aligned}$$

Иными словами, хотим найти наиболее близкую матрицу к B_k , которая будет удовлетворять квазиньютоновскому уравнению. Решением такой задачи будет формула обновления:

$$B_{k+1} = B_k + \frac{(y^k - B_k s^k) (s^k)^\top}{(s^k)^\top s^k}.$$

Обратим внимание, что полученная поправка является одноранговой, хотя явно мы этого не требовали. Однако она не является симметричной, что плохо согласуется со свойствами гессиана, который мы хотим аппроксимировать.

Чтобы не обращаться матрицу B_{k+1} и не решать системы линейных уравнений, можем получить явную формулу для $H_{k+1} = B_{k+1}^{-1}$, используя формулу Шермана–Моррисона–Вудбери, впервые предложенную в [37].

Утверждение Л7.2. Пусть $A \in \mathbb{R}^{d \times d}$ — обратимая матрица, а $U, V \in \mathbb{R}^{d \times n}$. Тогда, если также обратима матрица $I_d + V^\top A^{-1} U$, то верна формула:

$$(A + UV^\top)^{-1} = A^{-1} - A^{-1} U (I_d + V^\top A^{-1} U)^{-1} V^\top A^{-1}.$$

После ее применения получаем обновление H_k :

$$H_{k+1} = H_k + \frac{(s^k - H_k y^k) (s^k)^\top H_k}{(s^k)^\top H_k y^k}.$$

Л7.5.3 DFP

Модифицируем задачу поиска B_{k+1} . Добавим требование на симметричность матрицы и заменим обычную норму Фробениуса на взвешенную:

$$\|A\|_W = \|W^{1/2} A W^{1/2}\|_F,$$

где W — произвольная матрица, для которой выполняется $W y^k = s^k$. Для определенности, такой матрицей может быть обратный усредненный гессиан $W = \bar{G}_k^{-1}$, определяющийся следующим образом:

$$\bar{G}_k = \int_0^1 \nabla^2 f(x^k - \tau \gamma_k H_k \nabla f(x^k)) d\tau.$$

Получим задачу оптимизации для поиска B_{k+1} :

$$\begin{aligned} B_{k+1} &= \operatorname{argmin}_{B \in \mathbb{R}^{d \times d}} \|B - B_k\|_W^2 \\ \text{s.t. } \quad &Bs^k = y^k, \\ &B^\top = B. \end{aligned}$$

Решением этой задачи является формула обновления DFP (Davidon–Fletcher–Powell):

$$B_{k+1} = \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) B_k \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) + \frac{y^k (y^k)^\top}{(y^k)^\top s^k}.$$

Обращая ее по формуле Шермана–Моррисона–Вудбери, получаем выражение для H_{k+1} :

$$H_{k+1} = H_k - \frac{H_k y^k (y^k)^\top H_k}{(y^k)^\top H_k y^k} + \frac{s^k (s^k)^\top}{(s^k)^\top y^k}. \quad (\text{Л7.4})$$

Теорема Л7.4 (Теорема 4.2 из [35]). Пусть задача безусловной оптимизации (Л7.2) с M -липшицевым гессианом, L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью метода DFP (Алгоритм Л7.3 с формулой обновления (Л7.4)). Введём обозначение

$$\lambda_f(x) = \sqrt{\langle \nabla f(x), (\nabla^2 f(x))^{-1} \nabla f(x) \rangle}.$$

Тогда при выборе шагов $\gamma_k = 1$ и начальной точке x^0 достаточно близкой к решению, что выполняется

$$\lambda_f(x^0) \leq \frac{\log \frac{3}{2}}{4} \frac{\mu^{5/2}}{LM},$$

справедлива следующая оценка сходимости:

$$\lambda_f(x^K) \leq \left(\frac{11dL^2}{\mu^2 K} \right)^{K/2} \lambda_f(x^0).$$

Л7.5.4 BFGS

Поступим так же, как и в DFP, только будем решать задачу сразу для H . Она получена из таких же рассуждений, меняется только ограничение:

$$\begin{aligned} H_{k+1} &= \operatorname{argmin}_{H \in \mathbb{R}^{d \times d}} \|H - H_k\|_W^2 \\ \text{s.t. } \quad &s^k = Hy^k, \\ &H^\top = H. \end{aligned}$$

Решением будет формула BFGS (Broyden–Fletcher–Goldfarb–Shanno):

$$H_{k+1} = \left(I_d - \frac{s^k (y^k)^\top}{(y^k)^\top s^k} \right) H_k \left(I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k} \right) + \frac{s^k (s^k)^\top}{(y^k)^\top s^k}. \quad (\text{Л7.5})$$

Теорема Л17.5 (Теорема 4.2 из [35]). Пусть задача безусловной оптимизации (Л17.2) с M -липшицевым гессианом, L -гладкой, μ -сильно выпуклой целевой функцией f решается с помощью метода BFGS (Алгоритм Л17.3 с формулой обновления (Л17.5)). Введём обозначение

$$\lambda_f(x) = \sqrt{\langle \nabla f(x), (\nabla^2 f(x))^{-1} \nabla f(x) \rangle}.$$

Тогда при выборе шагов $\gamma_k = 1$ и начальной точке x^0 достаточно близкой к решению, что выполняется

$$\lambda_f(x^0) \leq \frac{\log \frac{3}{2}}{4} \frac{\mu^{5/2}}{LM},$$

справедлива следующая оценка сходимости:

$$\lambda_f(x^K) \leq \left(\frac{11dL}{\mu K} \right)^{K/2} \lambda_f(x^0).$$

Замечание Л17.5. Существует много способов инициализировать матрицу H_0 , но на практике достаточно брать $H_0 = I_d$.

Замечание Л17.6. Сложность всех арифметических операций на одной итерации квазиньютоновских методов составляет $\mathcal{O}(d^2)$. Это дешевле обращения гессиана, но все еще довольно плохой результат для задач экстремально больших размерностей.

Замечание Л17.7. Гессиан (или его аппроксимации) на самом деле не обращают. Вместо это либо используют метод сопряженных градиентов для решения системы $Hy = \nabla f(x^k)$ с решением $y = H^{-1} \nabla f(x^k)$, либо используют MINRES: находят $y \in \arg\min_{y \in \mathbb{R}^d} \|Hy - \nabla f(x^k)\|_2^2$, что более предпочтительно в случаях когда система линейных уравнений нерешаема, либо используют backward propagation для того, чтобы посчитать $\nabla^2 f(x)v$ для любого фиксированного вектора v дифференцируют $\langle v, \nabla f(x) \rangle$ (Параграф С2).

Л17.5.5 Сравнительная таблица

Соберем все формулы для рассмотренных методов в одном месте.

Метод	B^{new}	$H^{\text{new}} = (B^{\text{new}})^{-1}$
SR1	$B + \frac{(y-Bs)(y-Bs)^\top}{(y-Bs)^\top s}$	$H + \frac{(s-Hy)(s-Hy)^\top}{(s-Hy)^\top y}$
Broyden	$B + \frac{y-Bs}{s^\top s} s^\top$	$H + \frac{(s-Hy)s^\top H}{s^\top Hy}$
DFP	$\left(I_d - \frac{ys^\top}{y^\top s}\right) B \left(I_d - \frac{sy^\top}{y^\top s}\right) + \frac{yy^\top}{y^\top s}$	$H + \frac{ss^\top}{s^\top y} - \frac{Hy y^\top H}{y^\top Hy}$
BFGS	$B + \frac{yy^\top}{y^\top s} - \frac{Bss^\top B}{s^\top Bs}$	$\left(I_d - \frac{sy^\top}{y^\top s}\right) H \left(I_d - \frac{ys^\top}{y^\top s}\right) + \frac{ss^\top}{y^\top s}$

Таблица 1: Обновления матриц B и H в различных квазиньютоновских методах. Здесь B , H , s и y соответствуют последней итерации, а B^{new} и H^{new} — их новые значения.

Л7.5.6 L-BFGS

При переходе от метода Ньютона к квазиньютоновским методам мы уже получили ускорение с $\mathcal{O}(d^3)$ до $\mathcal{O}(d^2)$ арифметических операций на итерацию. В памяти же в обоих подходах требуется хранить $\mathcal{O}(d^2)$ значений. Квадратичная стоимость итерации и по арифметическим операциям, и по памяти — это очень дорого для задач большой размерности.

Это подводит нас к следующему методу — L-BFGS из [22], где L означает Limited-memory. Базовая идея — вместо матрицы $H_k \in \mathbb{R}^{d \times d}$, аппроксимирующей Гессиян, хранить несколько подходящих векторов длины d . За улучшение по памяти приходится платить ухудшением скорости сходимости. Тем не менее, оказывается возможным показать линейную сходимость такого метода.

В случае BFGS имели следующее обновление матрицы после применения формулы Шермана–Моррисона–Вудбери:

$$H_{k+1} = V_k^\top H_k V_k + \frac{s^k (s^k)^\top}{(y^k)^\top s^k},$$

где $V_k = I_d - \frac{y^k (s^k)^\top}{(y^k)^\top s^k}$. Предлагается на итерации k выбирать некоторое начальное приближение Гессияна H_k^0 и затем последовательно применить (Л7.5) по последним m парам $\{s^k, y^k\}$:

$$\begin{aligned} H_{k+1} &= (V_{k-1}^\top \dots V_{k-m}^\top) H_k^0 (V_{k-m} \dots V_{k-1}) \\ &\quad + \rho^{k-m} (V_{k-1}^\top \dots V_{k-m+1}^\top) s^{k-m} (s^{k-m})^\top (V_{k-m+1} \dots V_{k-1}) \\ &\quad + \dots \\ &\quad + \rho^{k-1} s^{k-1} (s^{k-1})^\top. \end{aligned}$$

Здесь мы обозначили $\rho^k = \frac{1}{(y^k)^\top s^k}$. Экспериментальные результаты показывают, что m может быть выбрано относительно небольшим (меньше двадцати). Это дает существенное улучшение метода по памяти. Начальное приближение H_k^0 рекомендуется выбирать следующим образом:

$$H_k^0 = \frac{(s^{k-1})^\top y^{k-1}}{(y^{k-1})^\top y^{k-1}} I_d.$$

Множитель перед единичной матрицей реализует шкалирование матрицы вдоль последнего направления поиска. Для поиска шага для робастности важно использовать условия Вольфа (либо сильные условия Вольфа).

Основные недостатки метода L-BFGS заключаются в том, что он часто сходится медленно, особенно на плохо обусловленных задачах.

Л7.6 Trust-Region шаг

Методы линейного поиска основаны на поиске подходящего размера шага γ_k вдоль фиксированного направления p^k , которым может быть градиент $\nabla f(x^k)$ в случае градиентного спуска или $(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$ в случае демпфированного метода Ньютона.

Метод области доверия (Trust-Region) работает иначе. На каждом шаге алгоритма строится квадратичная модель m_k целевой функции f :

$$m_k(p) = f(x^k) + \langle \nabla f(x^k), p \rangle + \frac{1}{2} \langle p, B_k p \rangle,$$

где B_k — некоторая симметричная матрица, приближающая гессиан $\nabla^2 f(x^k)$. Например, в квазиньютоновских методах мы знаем аппроксимацию гессиана B_k .

Эта квадратичная модель совпадает с разложением Тейлора целевой функции f с точностью до первых двух членов. Если B_k в точности равна $\nabla^2 f(x^k)$, то имеем совпадение в первых трех членах.

Чтобы получить шаг согласно стратегии Trust-Region, решается подзадача

$$\begin{aligned} \min_{p \in \mathbb{R}^d} \quad & m_k(p) = f(x^k) + \langle \nabla f(x^k), p \rangle + \frac{1}{2} \langle p, B_k p \rangle \\ \text{s.t.} \quad & \|p\|_2 \leq \Delta_k, \end{aligned} \quad (\text{Л7.6})$$

где Δ_k — радиус области доверия. Эта подзадача является квадратичной: и целевая функция m_k , и ограничение, которое можно переписать как

$$\langle p, p \rangle \leq \Delta_k^2,$$

являются квадратичными.

Понять принцип Trust-Region шага можно при сравнении с демпфированным методом Ньютона со значением шага $\gamma_k = \frac{\Delta_k}{\|p^k\|}$.




Рис. Л7.1: Линии уровня квадратичной модели $m_k(p)$, область доверия ограничена пунктиром, показаны шаги Trust-Region и демпфированного метода Ньютона.

Демпфированный метод Ньютона делает шаг в направлении минимума построенной модели m_k , а Trust-Region минимизирует значение модели $m_k(p)$, оставаясь в области доверия $\|p\|_2 \leq \Delta_k$. Рисунок позволяет понять, почему эти шаги не эквивалентны. Trust-Region существенно учитывает ограничение на размер шага при его поиске.

В случае, когда

$$\|B_k^{-1} \nabla f(x^k)\|_2 \leq \Delta_k,$$

решение (Л7.6) просто

$$p^k = -B_k^{-1} \nabla f(x^k).$$

В ином случае решение не так очевидно, однако может быть найдено не так дорого. Но зачастую достаточно найти лишь приближенное решение для хорошей сходимости на практике.

Поговорим о стратегии подбора радиуса Δ_k . Если выбирать его слишком маленьким, шаги в направлении оптимума будут небольшими, и метод сходиться будет медленно. Если же брать Δ_k чересчур большим, то построенная модель m_k будет плохо приближать целевую функцию f вдали от нуля. Шаги будут большими, но неточными, и можем получить расходимость. Чтобы численно описывать, насколько наша модель точно приближает целевую функцию, определим соотношение

$$\rho_k = \frac{f(x^k) - f(x^k + p^k)}{m_k(0) - m_k(p^k)}. \quad (\text{Л7.7})$$

Числитель этой дроби назовем *действительным убыванием*, а знаменатель — *предсказанным убыванием*. Поскольку p^k — точка оптимума m_k , то предсказанное убывание всегда неотрицательно. Отсюда следует, что если $\rho_k < 0$, то $f(x^k + p^k) > f(x^k)$, и такой шаг должен быть отклонен. С другой стороны, если $\rho_k \approx 1$, то модель и функция хорошо согласуются, и можно увеличивать доверительную область на последующих итерациях. Если ρ_k положительно, но не вблизи 1, то не изменяем Δ_k . Эту стратегию можно описать с помощью алгоритма.

Алгоритм Л7.4 Метод доверительной области

Вход: максимальное значение доверительного радиуса $\bar{\Delta} > 0$, начальный доверительный радиус $\Delta_0 \in (0, \bar{\Delta})$, ограничение снизу на отношение убываний $\eta \in [0, \frac{1}{4}]$

```

1: for  $k = 0, \dots, K - 1$  do
2:   Найти  $p_k$  (приближённо) решением (Л7.6)
3:   Вычислить  $\rho_k$  по формуле (Л7.7)
4:   if  $\rho_k < \frac{1}{4}$  then
5:      $\Delta_{k+1} = \frac{1}{4} \|p_k\|_2$ 
6:   else
7:     if  $\rho_k > \frac{3}{4}$  and  $\|p_k\|_2 = \Delta_k$  then
8:        $\Delta_{k+1} = \min(2\Delta_k, \bar{\Delta})$ 
9:     else
10:       $\Delta_{k+1} = \Delta_k$ 
11:    end if
12:  end if
13:  if  $\rho_k > \eta$  then
14:     $x_{k+1} = x_k + p_k$ 
15:  else
16:     $x_{k+1} = x_k$ 
17:  end if
18: end for
```

В алгоритме мы дополнительно добавили ограничение на максимальный размер шага $\bar{\Delta}$, а также ограничение на минимальное значение отношения ρ_k , при котором совершается шаг, в виде константы η .

Более подробно про приближенное решение подзадачи (Л7.6) рассказано в работе [31].

Л7.7 Метод Гаусса–Ньютона

Для того, чтобы вывести аппроксимацию Гаусса–Ньютона, для начала рассмотрим задачу регрессии $L : \mathbb{R}^d \rightarrow \mathbb{R}$:

$$L(\theta) = \frac{1}{2n} \sum_{i=1}^n (\theta^\top x_i - y_i)^2, \quad x \in \mathbb{R}^d, y \in \mathbb{R}^n,$$

где $\{x_i, y_i\}_{i=1}^n$ — данные. Соответственно, производные данной функции следующие:

$$\nabla L(\theta) = \frac{1}{2n} \sum_{i=1}^n \theta(\theta^\top x_i - y_i), \quad \nabla^2 L(\theta) = \frac{1}{n} \sum_{i=1}^n \theta \theta^\top.$$

Если рассматривать нелинейные модели:

$$L(\theta) = \frac{1}{2n} \sum_{i=1}^n (f(x_i, \theta) - y_i)^2,$$

то гессиан будет иметь вид

$$\nabla^2 L(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla_\theta f(x_i, \theta) \nabla_\theta f(x_i, \theta)^\top + \frac{1}{n} \sum_{i=1}^n \nabla_\theta^2 f(x_i, \theta) (f(x_i, \theta) - y_i).$$

Обозначим первое слагаемое в этой сумме за $G(\theta)$, а второе за $R(\theta)$. Если модель переопределена, то вблизи решения мы ожидаем остатки $(f(x_i, \theta) - y_i)$ близкими к нулю, соответственно, вклад от $R(\theta)$ в гессиан будет небольшой. Соответственно, аппроксимация гессиана $G(\theta)$ называется аппроксимацией Гаусса–Ньютона.

В [36] этот подход был обобщен для функций потерь более общего вида

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n a_i(y_i, b_i(x_i, \theta)),$$

В такой постановке аналогично можно вывести

$$G(\theta) = \frac{1}{n} \sum_{i=1}^n [J_\theta b_i(x_i, \theta)]^\top \nabla_b^2 a_i(y_i, b_i(x_i, \theta)) [J_\theta b_i(x_i, \theta)].$$

Если a_i — выпуклая функция, то приближение Гаусс–Ньютона всегда положительно полуопределенная матрица, даже если Гессиан не является таковой, что делает данный метод применимым даже для невыпуклых задач.

Л7.8 Natural Gradient Descent

Один из существующих взглядов на методы второго порядка — это подходы, учитывающие кривизну функции. Возвращаясь ещё раз к градиентному спуску, который можно вывести из квадратичной регуляризации линейного приближения:

$$x^{k+1} = \underset{y \in \mathbb{R}^d}{\operatorname{argmin}} \left\{ \langle \nabla f(x^k), y - x^k \rangle + \frac{1}{2\gamma_k} \|y - x^k\|_2^2 \right\},$$

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

Если мы знаем, что не все направления оптимизации равноценные, то можем заменить стандартное скалярное произведение на индуцированное $\|x\|_A := \langle x, Ax \rangle^{1/2}$, где A — симметричная положительно определенная матрица. В таком случае итерация будет иметь вид

$$x^{k+1} = \underset{y \in \mathbb{R}^d}{\operatorname{argmin}} \left\{ \langle \nabla f(x^k), y - x^k \rangle + \frac{1}{2\gamma_k} \|y - x^k\|_A^2 \right\},$$

$$x^{k+1} = x^k - \gamma_k A^{-1} \nabla f(x^k).$$

Например, если взять $A = \nabla^2 f(x^k)$, то мы получим стандартный демпфированный метод Ньютона.

Можно пойти дальше и выделять не конкретные направления, а использовать более сложные штрафы на отклонение от предыдущей итерации, если у нас есть дополнительные сведения о внутренней структуре задачи. Например, если есть семейства распределений p_θ , зависящих от параметра, то измеряя близость между распределениями в дивергенции Кульбака–Лейблера, мы получаем

$$\theta^{k+1} = \underset{\delta\theta}{\operatorname{argmin}} \left\{ \langle \nabla L(\theta^k), \delta\theta \rangle + \frac{1}{\gamma_k} \operatorname{KL}(p_\theta \parallel p_{\theta+\delta\theta}) \right\}.$$

Явный вид такой итерации трудоемок для вычисления, поэтому мы будем использовать приближение дивергенции Кульбака–Лейблера:

$$\begin{aligned} \mathbb{E}_{p_\theta} \left[\log \frac{p_\theta}{p_{\theta+\delta\theta}} \right] &= \mathbb{E}_{p_\theta} [\log p_\theta - \log p_{\theta+\delta\theta}] \\ &\approx \mathbb{E}_{p_\theta} \left[\log p_\theta - \log p_\theta - \delta\theta^\top \nabla_\theta \log p_\theta - \frac{1}{2} \delta\theta^\top \nabla_\theta^2 \log p_\theta \delta\theta \right] \\ &= \mathbb{E}_{p_\theta} \left[-\delta\theta^\top \nabla_\theta \log p_\theta - \frac{1}{2} \delta\theta^\top \nabla_\theta^2 \log p_\theta \delta\theta \right]. \end{aligned}$$

Первое слагаемое можно посчитать следующим образом:

$$\begin{aligned} \mathbb{E}_{p_\theta} [\nabla_\theta \log p_\theta] &= \int p_\theta(z) \nabla_\theta \log p_\theta(z) dz = \int p_\theta(z) \frac{\nabla_\theta p_\theta(z)}{p_\theta(z)} dz = \int \nabla_\theta p_\theta(z) dz \\ &= \nabla_\theta \int p_\theta(z) dz = \nabla_\theta 1 = 0. \end{aligned}$$

Второе слагаемое оценивается следующим образом:

$$\begin{aligned} \mathbb{E}_{p_\theta} [\nabla_\theta^2 \log p_\theta] &= \mathbb{E}_{p_\theta} \left[\nabla_\theta \left(\frac{\nabla_\theta p_\theta}{p_\theta} \right) \right] = \mathbb{E}_{p_\theta} \left[\frac{\nabla_\theta^2 p_\theta}{p_\theta} - \frac{\nabla_\theta p_\theta \nabla_\theta p_\theta^\top}{p_\theta^2} \right] \\ &= \int p_\theta(z) \frac{\nabla_\theta^2 p_\theta(z)}{p_\theta(z)} dz - \int p_\theta(z) \left(\frac{\nabla_\theta p_\theta(z)}{p_\theta(z)} \right) \left(\frac{\nabla_\theta p_\theta(z)}{p_\theta(z)} \right)^\top dz \\ &= \int \nabla_\theta^2 p_\theta(z) dz - \int p_\theta(z) \nabla_\theta \log p_\theta(z) \nabla_\theta \log p_\theta(z)^\top dz \\ &= \nabla_\theta^2 \int p_\theta(z) dz - \mathbb{E}_{p_\theta} [\nabla_\theta \log p_\theta \nabla_\theta \log p_\theta^\top] \\ &= \nabla_\theta^2 1 - \mathbb{E}_{p_\theta} [\nabla_\theta \log p_\theta \nabla_\theta \log p_\theta^\top] \\ &= -\mathbb{E}_{p_\theta} [\nabla_\theta \log p_\theta \nabla_\theta \log p_\theta^\top]. \end{aligned}$$

Таким образом, в квадратичном приближении итерация метода следующая:

$$\begin{aligned} F(\theta) &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_{y \sim p_\theta} [\nabla_\theta \log p_\theta(y|x_i, \theta) \nabla_\theta \log p_\theta(y|x_i, \theta)^\top] \\ \theta^{k+1} &= \theta^k - \gamma_k F(\theta^k)^{-1} \nabla L(\theta^k). \end{aligned}$$

Этот метод называется Natural Gradient Descent, а матрица $F(\theta)$ — *матрица Фишера*.

Рассмотрим пример. Предположим, что $y|x \sim \mathcal{N}(f(x, \theta), \sigma^2)$. Тогда

$$\begin{aligned}\log p_\theta(y|x, \theta) &= -\frac{1}{2\sigma^2}(y - f(x, \theta))^2 - \frac{1}{2} \log(2\pi\sigma^2), \\ \nabla_\theta \log p_\theta(y|x, \theta) &= -\frac{1}{\sigma^2}(y - f(x, \theta))\nabla_\theta f(x, \theta).\end{aligned}$$

Посчитаем математическое ожидание:

$$\begin{aligned}\mathbb{E}_{y \sim p_\theta} [\nabla_\theta \log p_\theta(y|x, \theta) \nabla_\theta \log p_\theta(y|x, \theta)^\top] &= \mathbb{E}_{y \sim p_\theta} \left[\frac{1}{\sigma^4} (y - f(x, \theta))^2 \nabla_\theta f(x, \theta) \nabla_\theta f(x, \theta)^\top \right] \\ &= \frac{1}{\sigma^4} \nabla_\theta f(x, \theta) \nabla_\theta f(x, \theta)^\top \mathbb{E}_{y \sim p_\theta} \left[(y - f(x, \theta))^2 \right] \\ &= \frac{1}{\sigma^2} \nabla_\theta f(x, \theta) \nabla_\theta f(x, \theta)^\top,\end{aligned}$$

где последнее равенство следует из $y|x \sim \mathcal{N}(f(x, \theta), \sigma^2)$. Таким образом, матрица Фишера будет иметь следующий вид:

$$F(\theta) = \frac{1}{\sigma^2 n} \sum_{i=1}^n \nabla_\theta f(x_i, \theta) \nabla_\theta f(x_i, \theta)^\top.$$

Мы получили метод, идентичный методу Гаусса–Ньютона, исходя из вероятностной постановки задачи. На самом деле, это не совпадение.

Теорема 9.2 работы [26] утверждает, что если $p(y|x, \theta)$ — распределение из экспоненциального семейства с параметром θ , то матрица Фишера совпадает с матрицей Гаусса–Ньютона.

Л7.9 Аппроксимации матрицы Фишера

Несмотря на хорошую сходимость методов, проблема Natural Gradient Descent кроется в трудоемком посчёте математического ожидания $\mathbb{E}_{p_\theta}$. Самый естественный способ оценить ожидание — это использовать Монте–Карло оценку. Однако это зачастую затратно в имплементации. Для того, чтобы сделать это эффективно, применяются следующие эвристики

Самый простой вариант — приближать это математическое ожидание напрямую по данным из обучающей выборки. Вместо

$$F(\theta) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_{y \sim p_\theta} [\nabla_\theta \log p_\theta(y|x_i, \theta) \nabla_\theta \log p_\theta(y|x_i, \theta)^\top]$$

использовать

$$\hat{F}(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla_\theta \log p_\theta(y_i|x_i, \theta) \nabla_\theta \log p_\theta(y_i|x_i, \theta)^\top.$$

Матрица $\hat{F}(\theta)$ называется *эмпирической матрицей Фишера*. Простота имплементации компенсируется грубостью аппроксимации, в случае больших градиентов модель медленно сходится, так как $\hat{F}^{-1}(\theta) \nabla L(\theta)$ обратно пропорционально норме градиента. Тем не менее для некоторых задач подобная аппроксимация может показывать хорошие результаты.

Если дополнительно знать структуру задачи, то можно использовать более хорошие аппроксимации вместо эмпирической матрицы Фишера. Если наша модель — это полносвязная нейронная сеть, со слоями W_i , предактивациями a_i и backward propagation градиентами g_i , то матрицу Фишера можно приближать следующим образом:

$$F_{i,j} = \mathbb{E} \left[\bar{a}_{i-1} \bar{a}_{j-1}^\top \otimes g_i g_j^\top \right] \approx \mathbb{E} \left[\bar{a}_{i-1} \bar{a}_{j-1}^\top \right] \otimes \mathbb{E} \left[g_i g_j^\top \right] = \bar{A}_{i-1,j-1} \otimes G_{i,j} = \tilde{F}_{i,j}.$$

Это даёт

$$\tilde{F} = \begin{pmatrix} \bar{A}_{0,0} \otimes G_{1,1} & \bar{A}_{0,1} \otimes G_{1,2} & \cdots & \bar{A}_{0,\ell-1} \otimes G_{1,\ell} \\ \bar{A}_{1,0} \otimes G_{2,1} & \bar{A}_{1,1} \otimes G_{2,2} & \cdots & \bar{A}_{1,\ell-1} \otimes G_{2,\ell} \\ \vdots & \vdots & \ddots & \vdots \\ \bar{A}_{\ell-1,0} \otimes G_{\ell,1} & \bar{A}_{\ell-1,1} \otimes G_{\ell,2} & \cdots & \bar{A}_{\ell-1,\ell-1} \otimes G_{\ell,\ell} \end{pmatrix}.$$

В свою очередь матрица $\tilde{F}$ аппроксимируется через Монте-Карло оценки или по выборке. Такой метод называется K-FAC (Kronecker-factored Approximate Curvature).

Л7.10 Вероятностная формулировка задачи

Вместо простого предсказания значения величины y можно искать её распределение. Формализовывается это следующим образом: допустим, перед нами стоит задача приблизить целевое вероятностное распределение с плотностью $q(x, y)$ распределением из параметрического семейства $p_\theta(x, y)$. Тогда нам надо минимизировать дивергенцию Кульбака–Лейблера между этими распределениями:

$$\text{KL}(q(x, y) \parallel p_\theta(x, y)) = \int q(x, y) \log \frac{q(x, y)}{p(x, y|\theta)} dy dx = \int q(x, y) \log \frac{q(y|x)q(x)}{p(y|x, \theta)p(x|\theta)} dy dx.$$

Считая, что предсказываемое нами распределение на исходных данных не зависит от параметра, и более того, совпадает с настоящим распределением, то есть $p(x|\theta) = p(x) = q(x)$, мы получаем

$$\begin{aligned} \text{KL}(q(x, y) \parallel p(x, y)) &= \int q(x, y) \log \frac{q(y|x)}{p(y|x, \theta)} dy dx = \int q(x) \left(\int q(y|x) \log \frac{q(y|x)}{p(y|x, \theta)} dy \right) dx \\ &= \mathbb{E}_{q(x)} \text{KL}(q(y|x) \parallel p(y|x, \theta)) \approx \frac{1}{n} \sum_{i=1}^n \text{KL}(q(y|x_i) \parallel p(y|x_i, \theta)). \end{aligned}$$

Если у нас нет доступа к $q(y|x)$, а только к отдельным элементам, то дивергенции под суммой считаются по сэмплам:

$$\text{KL}(q(y|x_i) \parallel p(y|x_i, \theta)) \sim -\log p(y_i|x_i, \theta).$$

Тогда изначальная задача минимизации сводится к

$$L(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p(y_i|x_i, \theta).$$

Л8 Негладкая оптимизация. Адаптивные методы

До сих пор мы рассматривали только безусловные гладкие выпуклые задачи оптимизации, то есть задачи поиска минимума выпуклой функции с липшицевым градиентом на $\mathbb{R}^d$. Оказывается, что это достаточно сильные требования на целевую функцию, следующий пример это показывает.

Пример Л8.1. Рассмотрим функцию $f : \mathbb{R} \rightarrow \mathbb{R}$ следующего вида:

$$f(x) = |x|.$$

Эта функция достаточно простая и часто встречается, например, в виде ℓ_1 -регуляризатора. При этом из-за отсутствия дифференцируемости в нуле она не является гладкой. Более того, наше определение выпуклости (Определение Л2.3) работает только для дифференцируемых функций, то есть не применимо для модуля.

Это подталкивает нас к развитию теории для негладких задач.

Л8.1 Негладкие задачи

Хотелось бы ослабить требования на функции, в частности перестать требовать дифференцируемость целевой функции. В Параграфе Л2 было введено определение выпуклости для дифференцируемой функции (Определение Л2.3). Теперь обобщим его, не требуя дифференцируемости.

Определение Л8.1. Рассмотрим функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Функция f называется *выпуклой*, если для любых $x_1, \dots, x_k \in \mathbb{R}^d$ и любых $\alpha_1, \dots, \alpha_k$, $\alpha_i \geq 0$, $\sum_{i=1}^k \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i).$$

Замечание Л8.1. В Параграфе С4 более подробно изучаются различные определения выпуклых функций. В частности, в случае дифференцируемой функции показывается, что Определения Л2.3 и Л8.1 эквивалентны (Теорема С4.1).

Требование на дифференцируемость функции осталось только в гладкости. Заменим условие L -липшицевости градиента на M -липшицевость самой функции.

Определение Л8.2. Пусть дана функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Будем говорить, что она является M -липшицевой, если для любых $x, y \in \mathbb{R}^d$ выполнено:

$$|f(x) - f(y)| \leq M \|x - y\|_2.$$

Мы отказались от дифференцируемости целевой функции. Однако можно ввести новую сущность, которая будет обладать некоторыми такими же полезными свойствами, что и градиент для дифференцируемых выпуклых функций.

Определение Л8.3. Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Вектор $g \in \mathbb{R}^d$ будем называть *субградиентом* функции f в точке $x \in \mathbb{R}^d$, если для любого $y \in \mathbb{R}^d$ выполнено

$$f(y) \geq f(x) + \langle g, y - x \rangle.$$

Множество $\partial f(x)$ всех субградиентов f в точке x называется *субдифференциалом*.

Сформулируем критерий минимума выпуклой функции по аналогии с тем, как было для дифференцируемых функций (Теорема Л2.1 и Теорема Л2.2).

Теорема Л8.1. Точка x^* — минимум выпуклой функции f тогда и только тогда, когда

$$0 \in \partial f(x^*).$$

Доказательство. $\Rightarrow$ Если $f(x) \geq f(x^*)$ для любых $x \in \mathbb{R}^d$, то для вектора 0 выполнено

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$$

для любого $x \in \mathbb{R}^d$. Следовательно,

$$0 \in \partial f(x^*).$$

Доказано по определению субградиента.

$\Leftarrow$ Пусть $0 \in \partial f(x^*)$. Тогда по определению субградиента (Определение Л8.3):

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle = f(x^*)$$

для любого $x \in \mathbb{R}^d$. Доказано по определению минимума на множестве (Определение Л2.2). ■

Теорема Л8.2. Пусть дана выпуклая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Тогда функция f является M -липшицевой тогда и только тогда, когда для любого $x \in \mathbb{R}^d$ и $g \in \partial f(x)$ имеем $\|g\|_2 \leq M$.

Доказательство. $\Rightarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента (Определение Л8.3) для любого $y \in \mathbb{R}^d$:

$$f(y) - f(x) \geq \langle g, y - x \rangle.$$

Из M -липшицевости f (Определение Л8.2):

$$M\|y - x\|_2 \geq f(y) - f(x) \geq \langle g, y - x \rangle.$$

Возьмем $y = g + x \in \mathbb{R}^d$, тогда

$$M\|g\|_2 = M\|y - x\|_2 \geq \langle g, y - x \rangle = \|g\|_2^2.$$

Откуда и получаем:

$$\|g\|_2 \leq M.$$

$\Leftarrow$ Рассмотрим $g \in \partial f(x)$, тогда по определению субградиента (Определение Л8.3) для любого $y \in \mathbb{R}^d$:

$$f(x) - f(y) \leq \langle g, x - y \rangle.$$

Используем неравенство Коши–Буняковского–Шварца (0.3):

$$f(x) - f(y) \leq \|g\|_2 \|x - y\|_2.$$

Воспользуемся предположением об ограниченности нормы субградиента и получим:

$$f(x) - f(y) \leq M\|x - y\|_2.$$

Если переобозначить $x \rightarrow y$, $y \rightarrow x$, то можем записать:

$$f(y) - f(x) \leq M\|y - x\|_2.$$

Если объединить оба неравенства, то можем прийти к более краткой записи:

$$|f(y) - f(x)| \leq M\|x - y\|_2.$$

Это и есть свойство M -липшицевости f . ■

Л8.2 Субградиентный метод

Рассматриваем безусловную задачу:

$$\min_{x \in \mathbb{R}^d} f(x), \quad (\text{Л8.1})$$

где функция f выпуклая на $\mathbb{R}^d$ и M -липшицева.

Простая идея — снова модифицировать градиентный спуск, теперь вместо градиента используя какой-то субградиент в текущей точке:

Алгоритм Л8.1 Субградиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $x^{k+1} = x^k - \gamma_k g^k$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Замечание Л8.2. Сходимость у субградиентного метода (Алгоритм Л8.1) по средней точке, а не по последней.

Теорема Л8.3. Пусть задача безусловной оптимизации с M -липшицевой выпуклой целевой функцией f решается с помощью субградиентного метода (Алгоритм Л8.1). Тогда при $\gamma_k = \gamma$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Доказательство. Начнем с рассмотрения квадрата нормы $\|x^{k+1} - x^*\|_2^2$. Подставим формулу обновления

$$x^{k+1} = x^k - \gamma g^k,$$

после чего раскроем квадрат нормы:

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \gamma g^k - x^*\|_2^2 \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2. \end{aligned}$$

Из M -липпицевости f следует, что норма субградиента g^k ограничена M (Теорема Л8.2):

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 M^2.$$

Из определения субградиента (Определение Л8.3) оценим скалярное произведение:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma (f(x^k) - f^*) + \gamma^2 M^2.$$

Перенесем разность значений функции f влево, а норму вправо:

$$2\gamma (f(x^k) - f^*) \leq \|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2.$$

Просуммируем по всем k от 0 до $K-1$:

$$2\gamma \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \sum_{k=0}^{K-1} (\|x^k - x^*\|_2^2 - \|x^{k+1} - x^*\|_2^2 + \gamma^2 M^2).$$

Раскроем телескопическую сумму справа, из которой остается только два слагаемых с нормой, а также разделим на $2\gamma K$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{\|x^0 - x^*\|_2^2 - \|x^K - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

Можно откинуть неположительное $-\frac{\|x^K - x^*\|_2^2}{2\gamma K}$ в правой части, а также воспользоваться выпуклостью функции f (Определение Л8.1) в левой:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}.$$

■

Утверждение Л8.1. Пусть задача удовлетворяет условиям Теоремы Л8.3 и выбрано значение шага $\gamma_k = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}$. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Более того, чтобы добиться точности ε по функции $(f(\frac{1}{K} \sum_{k=0}^{K-1} x^k) - f^* \leq \varepsilon)$, необходимо

$$K = \mathcal{O}\left(\frac{M^2\|x^0 - x^*\|_2^2}{\varepsilon^2}\right) \text{ итераций.}$$

Доказательство. Запишем оценку сходимости из Теоремы Л8.3:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma M^2}{2}. \quad (\text{Л8.2})$$

Минимизируя правую часть оценки по $\gamma > 0$, находим оптимальное значение шага

$$\gamma^* = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}.$$

Подставим его в (Л8.2) и получим:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{M \|x^0 - x^*\|_2}{\sqrt{K}}.$$

Теперь потребуем точность ε по функции, ограничив правую часть неравенства:

$$\frac{M \|x^0 - x^*\|_2}{\sqrt{K}} \leq \varepsilon.$$

Решая это неравенство относительно K , приходим к

$$K \geq \left(\frac{M \|x^0 - x^*\|_2}{\varepsilon} \right)^2,$$

что и даёт заявленную оценку на число итераций. ■

Субградиентный метод является обобщением градиентного спуска на негладкие задачи. Его сходимость оказывается медленнее, чем у градиентного спуска. В общем случае результат для субградиентного метода является неуплучшаемым для выпуклых и сильно выпуклых задач, то есть он оптимален.

Л8.3 Адаптивные методы

В полученной оценке для субградиентного метода шаг выбирается равным

$$\gamma = \frac{\|x^0 - x^*\|_2}{M\sqrt{K}}.$$

Однако такая формула требует знания заранее числа итераций K , константы Липшица M и расстояния $\|x^0 - x^*\|_2$ до решения. На практике эти параметры обычно неизвестны, и их использование существенно ограничивает применимость метода. Возникает естественный вопрос: как построить выбор шага, который не требует этих величин, но при этом сохраняет их смысл и обеспечивает аналогичное поведение алгоритма?

Л8.3.1 AdaGradNorm

Первым шагом можно избавиться от необходимости знать константу Липшица M . Согласно Теореме Л8.2 имеем неравенство:

$$\|g\|_2 \leq M$$

для всех $g \in \partial f(x)$ во всех точках $x \in \mathbb{R}^d$. Отсюда можно оценить

$$M \sim \|g\|_2.$$

Однако этого недостаточно: в оптимальном значении шага в знаменателе стоит $M\sqrt{K}$. Тогда мы можем брать норму не одного субградиента в какой-то точке, а суммировать по всем предыдущим:

$$M\sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} \|g^t\|_2^2}.$$

Неизвестным остается только расстояние до решения $\|x^0 - x^*\|_2$. Его можно оценить лишь какой-то константой D , на практике часто подбираемой эмпирически:

$$\|x^0 - x^*\|_2 \leq D.$$

Замечание Л8.3. Условие $\|x^0 - x^*\|_2 \leq D$ выглядит менее искусственным, если мы знаем, что решение x^* лежит в некотором ограниченном множестве $\mathcal{X}$. Тогда константу D можно оценить как диаметр множества:

$$D = \sup_{x, y \in \mathcal{X}} \|x - y\|_2.$$

Собирая все вместе, имеем шаг

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^k \|g^t\|_2^2 + \varepsilon}},$$

где для вычислительной устойчивости в знаменатель была добавлена константа ε , обычно выбирающаяся достаточно малой.

Таким образом, шаг автоматически уменьшается по мере роста накопленной нормы градиента и метод работает без знания M и K . Метод с таким адаптивным подбором шага называется AdaGradNorm [40].

Алгоритм Л8.2 AdaGradNorm

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G^k = G^{k-1} + \|g^k\|_2^2$
- 4: $x^{k+1} = x^k - \frac{D}{\sqrt{G^k + \varepsilon}} g^k$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.2 DoG: Distance over Gradients

В методе AdaGradNorm шаг имеет вид

$$\gamma_k = \frac{D}{\sqrt{\sum_{t=0}^k \|g^t\|_2^2 + \varepsilon}},$$

где $D = \|x^0 - x^*\|_2$ остаётся неизвестным параметром. Для его замены предлагается использовать наблюдаемую величину

$$d_k = \max_{t=0, k} \|x^t - x^0\|_2,$$

которая служит естественной оценкой D по траектории метода. В самом деле, мы заменили оценку на диаметр множества максимальным расстоянием, на которое удалялись от стартовой точки.

Подставляя эту оценку вместо D , получаем метод без гиперпараметров.

Алгоритм Л8.3 DoG (Distance over Gradients)

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сумма квадратов норм субградиентов $G^{-1} = 0$, оценка диаметра $d_{-1} > 0$, параметр $\varepsilon \sim 10^{-8}$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G^k = G^{k-1} + \|g^k\|_2^2$
- 4: $d_k = \max(d_{k-1}, \|x^k - x^0\|_2)$
- 5: $x^{k+1} = x^k - \frac{d_k}{\sqrt{G^k + \varepsilon}} g^k$
- 6: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.3 AdaGrad

Следующий шаг — учесть неоднородность по координатам. Тогда оптимальный шаг для каждой i -ой компоненты зависит от своей константы Липшица M_i и своего расстояния $|x_i^0 - x_i^*|$. Вместо глобального масштаба можно адаптивно накапливать информацию о каждом направлении:

$$M_i \sqrt{K} \sim \sqrt{\sum_{t=0}^{K-1} (g_i^t)^2},$$

а также оценивать расстояние до решения по каждой координате:

$$|x_i^0 - x_i^*| \leq D_i.$$

Тогда шаг для каждой координаты берётся как

$$\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2 + \varepsilon}}.$$

Такой метод учитывает частоту и величину обновлений в каждой компоненте и особенно эффективен при разреженных признаках. Этот алгоритм получил название AdaGrad [13].

Алгоритм Л8.4 AdaGrad

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $G_i^k = G_i^{k-1} + (g_i^k)^2$
- 4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$
- 5: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Для алгоритма сформулируем и докажем теорему о сходимости.

Теорема Л8.4. Пусть задача оптимизации (Л8.1) с M -липшицевой выпуклой целевой функцией f решается с помощью AdaGrad (Алгоритм Л8.4). Тогда спра-

ведлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}},$$

где $\tilde{D} = \sum_{i=1}^d D_i$, $|x_i^k - x_i^*| \leq D_i$ для любых $i = \overline{1, d}$ и любых $k = \overline{0, K-1}$.

Более того, чтобы добиться точности ε по функции $(f(\frac{1}{K} \sum_{k=0}^{K-1} x^k) - f^* \leq \varepsilon)$, необходимо

$$K = \mathcal{O}\left(\frac{M^2 \tilde{D}^2}{\varepsilon^2}\right) \text{ итераций.}$$

Доказательство. Начнем с квадрата ошибки по i -ой координате $(x_i^{k+1} - x_i^*)^2$. Подставим итерацию метода:

$$\begin{aligned} (x_i^{k+1} - x_i^*)^2 &= (x_i^k - \gamma_{k,i} g_i^k - x_i^*)^2 \\ &= (x_i^k - x_i^*)^2 - 2\gamma_{k,i} g_i^k (x_i^k - x_i^*) + \gamma_{k,i}^2 (g_i^k)^2. \end{aligned}$$

Откуда выражаем перекрестное слагаемое:

$$g_i^k (x_i^k - x_i^*) = \frac{1}{2\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{2\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \frac{\gamma_{k,i}}{2} (g_i^k)^2.$$

Собираем скалярное произведение, суммируя по всем координатам i от 1 до d :

$$\langle g^k, x^k - x^* \rangle = \frac{1}{2} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Оцениваем левую часть, пользуясь определением субградиента (Определение 18.3):

$$f(x^k) - f^* \leq \frac{1}{2} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Суммируем по всем k от 0 до $K-1$ и усредняем, а также меняем порядок суммирования:

$$\begin{aligned} \frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{2K} \sum_{k=0}^{K-1} \sum_{i=1}^d \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\ &= \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 - \frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right]. \end{aligned}$$

Следующим шагом будет приведение подобных слагаемых. Для этого сдвинем индекс суммирования k и аккуратно поработаем с крайними слагаемыми. Для удобства по-

ложим $\gamma_{-1,i} = +\infty$ и преобразуем:

$$\begin{aligned}
\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\
&\quad - \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^{k+1} - x_i^*)^2 \right] \\
&= \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k,i}} (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right] \\
&\quad - \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\frac{1}{\gamma_{k-1,i}} (x_i^k - x_i^*)^2 \right] - \frac{1}{2K} \sum_{i=1}^d \frac{1}{\gamma_{K-1,i}} (x_i^K - x_i^*)^2 \\
&\leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \right) (x_i^k - x_i^*)^2 + \gamma_{k,i} (g_i^k)^2 \right].
\end{aligned}$$

В последнем переходе мы откинули неположительное слагаемое. Теперь воспользуемся константами $D_i : (x_i^k - x_i^*)^2 \leq D_i^2$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\frac{1}{\gamma_{k,i}} - \frac{1}{\gamma_{k-1,i}} \right) D_i^2 + \gamma_{k,i} (g_i^k)^2 \right].$$

Подставим $\gamma_{k,i} = \frac{D_i}{\sqrt{\sum_{t=0}^k (g_i^t)^2}}$ и свернём телескопическую сумму по k :

$$\begin{aligned}
\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) &\leq \frac{1}{2K} \sum_{i=1}^d \sum_{k=0}^{K-1} \left[\left(\sqrt{\sum_{t=0}^k (g_i^t)^2} - \sqrt{\sum_{t=0}^{k-1} (g_i^t)^2} \right) D_i + \frac{D_i (g_i^k)^2}{\sqrt{\sum_{t=0}^k (g_i^t)^2}} \right] \\
&= \frac{1}{2K} \sum_{i=1}^d D_i \left[\sqrt{\sum_{t=0}^{K-1} (g_i^t)^2} + \sum_{k=0}^{K-1} \frac{(g_i^k)^2}{\sqrt{\sum_{t=0}^k (g_i^t)^2}} \right].
\end{aligned}$$

Воспользуемся техническим фактом, который говорит, что для любых неотрицательных чисел $\{a_k\} \geq 0$ выполнено:

$$\sum_{k=0}^{K-1} \frac{a_k^2}{\sqrt{\sum_{t=0}^k a_t^2}} \leq 2 \sqrt{\sum_{k=0}^{K-1} a_k^2}.$$

Применяем его для второго слагаемого в сумме, получаем:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{\sum_{t=0}^{K-1} (g_i^t)^2}.$$

Из неизвестных значений в правой части остается только $\sum_{t=0}^{K-1} (g_i^t)^2$. Оценим её с помощью свойства M -липшицевых функций (Теорема Л8.2):

$$\sum_{t=0}^{K-1} (g_i^t)^2 \leq \sum_{t=0}^{K-1} \|g^t\|_2^2 \leq KM^2.$$

Подставляем в основное неравенство:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^k) - f^*) \leq \frac{3}{2K} \sum_{i=1}^d D_i \sqrt{KM^2} = \frac{3M}{2\sqrt{K}} \sum_{i=1}^d D_i = \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку из условия, остается применить определение выпуклости функции (Определение Л8.1):

$$f\left(\frac{1}{K} \sum_{k=0}^{K-1} x^k\right) - f^* \leq \frac{3M\tilde{D}}{2\sqrt{K}}.$$

Чтобы получить оценку на количество итераций для достижения точности ε по функции ($f(\frac{1}{K} \sum_{k=0}^{K-1} x^k) - f^* \leq \varepsilon$), ограничим правую часть:

$$\frac{3M\tilde{D}}{2\sqrt{K}} \leq \varepsilon.$$

Откуда и получаем:

$$K \geq \frac{9M^2\tilde{D}^2}{4\varepsilon^2}.$$

■

Замечание Л8.4. Константы D_i могут выглядеть немного искусственными, однако их можно обосновать. Например, когда нам известно, что решение x^* лежит в ограниченном множестве $\mathcal{X}$, а стартовая и все последующие точки также лежат внутри этого множества.

Замечание Л8.5. Константы D_i можно также оценивать динамически. В частности, можно использовать идею DoG, адаптированную под координатную запись:

$$d_{k,i} = \max_{0 \leq t \leq k} |x_i^t - x_i^0|.$$

Л8.3.4 RMSProp

У AdaGrad знаменатель монотонно растёт, и шаг со временем может становиться слишком малым. Чтобы избежать затухания шага, вместо суммы используют экспоненциальное скользящее среднее квадратов градиентов:

$$G_i^k = \beta G_i^{k-1} + (1 - \beta)(g_i^k)^2,$$

где моментум $\beta \in [0, 1]$ выбирается порядка ~ 0.99 . Такой приём позволяет учитывать преимущественно недавнюю историю и адаптироваться к меняющейся геометрии задачи. Метод получил название RMSProp [39].

Алгоритм Л8.5 RMSProp

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, параметры $\varepsilon \sim 10^{-8}$, $D_i > 0$, $\beta \in [0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: Вычислить $g^k \in \partial f(x^k)$
 - 3: $G_i^k = \beta G_i^{k-1} + (1 - \beta)(g_i^k)^2$
 - 4: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{G_i^k + \varepsilon}} g_i^k$
 - 5: **end for**
- Выход:** $\frac{1}{K} \sum_{k=0}^{K-1} x^k$
-

Л8.3.5 Adam

Алгоритм Adam объединяет идеи RMSProp и импульса. Помимо экспоненциального сглаживания квадратов градиентов, он усредняет сами градиенты:

$$\begin{aligned}v^k &= \beta_1 v^{k-1} + (1 - \beta_1) g^k, \\G_i^k &= \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2,\end{aligned}$$

где два импульса $\beta_1, \beta_2 \in [0, 1]$ обычно выбираются 0.9 и 0.999 соответственно. Чтобы устранить смещение на ранних итерациях, вводится коррекция:

$$\begin{aligned}\hat{v}^k &= \frac{v^k}{1 - \beta_1^{k+1}}, \\ \hat{G}^k &= \frac{G^k}{1 - \beta_2^{k+1}}.\end{aligned}$$

В итоге шаг получается

$$x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k} + \varepsilon} \hat{v}_i^k.$$

Такой метод даёт устойчивые шаги при шумных и разреженных градиентах и требует минимальной настройки гиперпараметров [16].

Алгоритм Л8.6 Adam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k$
- 4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5: $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2$
- 6: $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k} + \varepsilon} \hat{v}_i^k$

8: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.6 NAdam

Вариант NAdam сочетает Adam с идеей ускорения Нестерова. То есть сначала делаем шаг по инерции, потом вычисляем субградиент и делаем шаг вдоль него [12].

Алгоритм Л8.7 NAdam

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k$
- 4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5: $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2$
- 6: $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7: $m^k = \beta_1 \hat{v}^k + \frac{1 - \beta_1}{1 - \beta_1^{k+1}} g^k$
- 8: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k + \varepsilon}} m_i^k$
- 9: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.3.7 AdamW

В классическом Adam, если применяется ℓ_2 -регуляризация, то градиент от слагаемого $\frac{\lambda}{2} \|x\|_2^2$ добавляется в общий градиент и масштабируется адаптивным шагом, что делает её неэквивалентной классической регуляризации. AdamW отделяет регуляризацию: стягивание весов $-\lambda x^k$ добавляется отдельно от градиентного обновления. Это позволяет контролировать регуляризацию независимо от величины шага и улучшает обобщающую способность моделей [24].

Алгоритм Л8.8 AdamW

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, сглаженные суммы квадратов компонент субградиентов $G_i^{-1} = 0$, сглаженные суммы субградиентов $v^{-1} = 0$, параметры $\beta_1, \beta_2 \in [0, 1]$, $\lambda > 0$, $\varepsilon \sim 10^{-8}$, $D_i > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Вычислить $g^k \in \partial f(x^k)$
- 3: $v^k = \beta_1 v^{k-1} + (1 - \beta_1) g^k$
- 4: $\hat{v}^k = v^k / (1 - \beta_1^{k+1})$
- 5: $G_i^k = \beta_2 G_i^{k-1} + (1 - \beta_2) (g_i^k)^2$
- 6: $\hat{G}^k = G^k / (1 - \beta_2^{k+1})$
- 7: $x_i^{k+1} = x_i^k - \frac{D_i}{\sqrt{\hat{G}_i^k + \varepsilon}} \hat{v}_i^k - \lambda D_i x_i^k$
- 8: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} x^k$

Л8.4 Проксимальный оператор

Негладкие задачи «более сложные» по сравнению с гладкими задачами. Но отсутствие гладкости может получиться «спрятать под ковер» с помощью проксимального оператора.

Определение Л8.4. Для функции $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ проксимальный оператор

определяется следующим образом:

$$\text{prox}_r(x) = \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Пока что мы не потребовали ничего от функции r и мало что можем сказать про проксимальный оператор. Оказывается, что если наложить на r условие выпуклости, то проксимальный оператор для нее становится однозначно определённым.

Утверждение Л8.2. Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Если существует $\hat{x} \in \mathbb{R}^d$ с $r(\hat{x}) < +\infty$, то проксимальный оператор однозначно определен.

Доказательство. Проксимальный оператор возвращает минимум некоторой задачи оптимизации. Задача сильно выпуклая, так как целевая функция — это сумма выпуклой и сильно выпуклой функции. А значит, существует строго один минимум (Теорема Л2.3). А существование $\hat{x}$ необходимо для того, чтобы $r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2$ хотя бы где-то принимала конечное значение. ■

Л8.4.1 Примеры проксимального оператора

Рассмотрим операторы, которые мы будем получать в зависимости от того, какую проксимальную функцию мы используем.

- **ℓ_1 -норма.**

Пусть $r(x) = \lambda \|x\|_1$, где $\lambda > 0$. Тогда

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i),$$

что известно как *оператор трешхолдинга*.

Доказательство. Рассмотрим задачу

$$\begin{aligned} \text{prox}_r(x) &= \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(\lambda \|\tilde{x}\|_1 + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \\ &= \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \sum_{i=1}^d \left(\frac{1}{2} (\tilde{x}_i - x_i)^2 + \lambda |\tilde{x}_i| \right). \end{aligned}$$

Задача распадается по координатам. Для каждой координаты условие оптимальности имеет вид

$$0 \in \tilde{x}_i^* - x_i + \lambda \cdot \partial |\tilde{x}_i^*|,$$

что приводит к правилу софт-трешхолдинга:

$$\tilde{x}_i^* = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i).$$

- **ℓ_2 -норма.**

Пусть $r(x) = \frac{\lambda}{2} \|x\|_2^2$, где $\lambda > 0$. Тогда

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

Доказательство. Рассмотрим

$$\text{prox}_r(x) = \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(\frac{\lambda}{2} \|\tilde{x}\|_2^2 + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Необходимое условие минимума (Теорема Л2.2):

$$\lambda \tilde{x}^* + \tilde{x}^* - x = 0.$$

Откуда и получаем решение:

$$\tilde{x}^* = \frac{x}{1 + \lambda}.$$

■

• **Индикатор множества.**

Пусть $r(x) = \mathbb{I}_{\mathcal{X}}(x)$ для замкнутого множества $\mathcal{X} \subseteq \mathbb{R}^d$, где

$$\mathbb{I}_{\mathcal{X}}(x) = \begin{cases} 0, & x \in \mathcal{X}, \\ +\infty, & x \notin \mathcal{X}. \end{cases}$$

Тогда

$$\text{prox}_r(x) = \underset{\tilde{x} \in \mathcal{X}}{\operatorname{argmin}} \frac{1}{2} \|x - \tilde{x}\|_2^2.$$

Смысл такого оператора в том, что он возвращает ближайшую к x точку из множества $\mathcal{X}$.

Доказательство. Имеем

$$\begin{aligned} \text{prox}_r(x) &= \underset{\tilde{x} \in \mathbb{R}^d}{\operatorname{argmin}} \left(\mathbb{I}_{\mathcal{X}}(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \\ &= \underset{\tilde{x} \in \mathcal{X}}{\operatorname{argmin}} \frac{1}{2} \|x - \tilde{x}\|_2^2. \end{aligned}$$

■

Л8.4.2 Свойства проксимального оператора

Для последующего теоретического анализа алгоритмов на основе проксимального оператора, докажем полезные свойства.

Утверждение Л8.3. Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ следующие три условия являются эквивалентными:

1. $\text{prox}_r(x) = y$,
2. $x - y \in \partial r(y)$,
3. $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^d$.

Доказательство. Запишем первое условие по определению проксимального оператора (Определение Л8.4):

$$y = \operatorname{argmin}_{\tilde{x} \in \mathbb{R}^d} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right).$$

Из условия оптимальности для выпуклой функции r (Теорема Л8.1) это эквивалентно

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|_2^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Получили эквивалентность первого и второго условий.

Теперь свяжем второе и третье. Из определения субдифференциала (Определение Л8.3), для любого субградиента $g \in \partial f(y)$ и для любого $z \in \mathbb{R}^d$:

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности, справедливо и для $g = x - y \in \partial r(y)$ по предположению:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Получили следствие из второго в третье. Теперь в обратную сторону. Пусть выполняется соотношение три:

$$\langle x - y, z - y \rangle \leq r(z) - r(y).$$

Но это же означает, что $x - y$ является субградиентом r в точке y , то есть $g \in \partial r(y)$. ■

Этим свойством мы связали действие проксимального оператора и субградиент. Следующее утверждение позволит работать с действиями проксимального оператора под знаками скалярного произведения и нормы.

Утверждение Л8.4. Пусть $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^d$ выполнено следующее:

- $\langle x - y, \operatorname{prox}_r(x) - \operatorname{prox}_r(y) \rangle \geq \|\operatorname{prox}_r(x) - \operatorname{prox}_r(y)\|_2^2,$
- $\|\operatorname{prox}_r(x) - \operatorname{prox}_r(y)\|_2 \leq \|x - y\|_2.$

Доказательство. Для удобства обозначим $u = \operatorname{prox}_r(x), v = \operatorname{prox}_r(y)$. Начнем с неравенства из Утверждения Л8.3. Запишем для троек точек (x, u, v) и (y, v, u) :

$$\langle x - u, v - u \rangle \leq r(v) - r(u),$$

$$\langle y - v, u - v \rangle \leq r(u) - r(v).$$

Сложим неравенства, справа получим 0:

$$\langle x - u - (y - v), v - u \rangle \leq 0.$$

Разнесем слагаемые в разные стороны:

$$\langle x - y, u - v \rangle \geq \|u - v\|_2^2.$$

Это и есть первое свойство. Из него логично вытекает и второе свойство. Достаточно лишь применить к неравенству выше неравенство Коши–Буняковского–Шварца (0.3):

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle \leq \|x - y\|_2 \|u - v\|_2.$$

Случай $u = v$ тривиален и удовлетворяет неравенству, так что имеем:

$$\|u - v\|_2 \leq \|x - y\|_2.$$

■

Л8.4.3 Проксимальный градиентный метод

Настало время применить проксимальный оператор для построения метода оптимизации. Рассмотрим следующую задачу:

$$\min_{x \in \mathbb{R}^d} f(x) + r(x), \quad (\text{Л8.3})$$

где f является L -гладкой выпуклой функцией, а r — просто выпуклой. Она не обязана быть гладкой, но должна быть проксимально-дружественной, то есть для нее должен считаться проксимальный оператор. Задача (Л8.3) называется *композиционной*. Вновь модифицируем градиентный спуск: добавим применение проксимального оператора $\text{prox}_{\gamma r}$ после градиентного шага $-\gamma_k \nabla f(x^k)$.

Алгоритм Л8.9 Проксимальный градиентный метод

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**
 2: $x^{k+1} = \text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k))$
 3: **end for**

Выход: x^K

Покажем, какую физику несёт метод. Для этого воспользуемся результатами Утверждения Л8.3, тогда $x^{k+1} = \text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k))$ эквивалентно записи:

$$x^k - \gamma_k \nabla f(x^k) - x^{k+1} \in \gamma_k \partial r(x^{k+1}).$$

Или, если переписать в более привычном виде:

$$x^{k+1} \in x^k - \gamma_k (\nabla f(x^k) + \partial r(x^{k+1})).$$

Получили неявную запись метода, из которой видно, что мы делаем шаг вдоль $\nabla f(x^k) + g$, где $g \in \partial r(x^{k+1})$.

Утверждение Л8.5. Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$, $r : \mathbb{R}^d \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Тогда x^* — решение композиционной задачи оптимизации тогда и только тогда, когда для любого $\gamma > 0$ выполнено:

$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*)).$$

Доказательство. Обратимся к Утверждению Л8.3. Согласно нему, выражение

$$x^* = \text{prox}_{\gamma r}(x^* - \gamma \nabla f(x^*))$$

эквивалентно записи:

$$x^* - \gamma \nabla f(x^*) - x^* \in \gamma \partial r(x^*).$$

Сокращаем на $\gamma > 0$ и получаем условие оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*).$$

■

Теперь мы готовы доказывать теорему о скорости сходимости.

Теорема Л8.5. Пусть композитная задача оптимизации (Л8.3) с L -гладкой μ -сильно выпуклой целевой функцией f и выпуклой (необязательно гладкой) проксимально-дружественной функцией r решается с помощью проксимального градиентного метода (Алгоритм Л8.9). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

Доказательство. Рассматриваем $\|x^{k+1} - x^*\|_2^2$. Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \|\text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2.$$

Воспользуемся Утверждением Л8.5:

$$\|x^{k+1} - x^*\|_2^2 = \|\text{prox}_{\gamma_k r}(x^k - \gamma_k \nabla f(x^k)) - \text{prox}_{\gamma_k r}(x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

А теперь применяем неравенство из Утверждения Л8.4:

$$\|x^{k+1} - x^*\|_2^2 \leq \|(x^k - \gamma_k \nabla f(x^k)) - (x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

Раскрываем квадрат нормы:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.$$

Оценим последнее слагаемое, используя свойство L -гладкой выпуклой f (неравенство (Л2.5) из Теоремы Л2.5):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle \\ &\quad + \gamma_k^2 L \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &= \|x^k - x^*\|_2^2 - \gamma_k (2 - \gamma_k L) \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle. \end{aligned}$$

Два раза запишем определение μ -сильной выпуклости f (Определение Л2.4):

$$\begin{aligned} f(x^k) &\geq f(x^*) + \langle \nabla f(x^*), x^k - x^* \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2, \\ f(x^*) &\geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^* - x^k\|_2^2. \end{aligned} \tag{Л8.4}$$

Сложим их и получим:

$$\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \geq \mu \|x^k - x^*\|_2^2.$$

Подставляем в основное неравенство (Л8.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - \mu\gamma_k (2 - \gamma_k L) \|x^k - x^*\|_2^2 \\ &= (1 - \mu\gamma_k (2 - \gamma_k L)) \|x^k - x^*\|_2^2. \end{aligned}$$

Поскольку $\gamma_k \leq \frac{1}{L}$, то $2 - \gamma_k L > 1$. Продолжая цепочку неравенств, имеем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Остается лишь развернуть рекурсию с K -ой итерации по нулевую:

$$\begin{aligned}
 \|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1})\|x^{K-1} - x^*\|_2^2 \\
 &\leq (1 - \mu\gamma_{K-1})(1 - \mu\gamma_{K-2})\|x^{K-2} - x^*\|_2^2 \\
 &\leq \dots \\
 &\leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.
 \end{aligned}$$

■

Утверждение Л8.6. Пусть задача удовлетворяет условиям Теоремы Л8.5 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Повторяет доказательство Утверждения Л3.1.

■

Замечание Л8.6. Проксимальный градиентный спуск для композитной задачи с L -гладкой μ -сильно выпуклой функцией f и выпуклой проксимально-дружественной функцией r имеет такую же скорость сходимости, что и метод градиентного спуска для функции f (Теорема Л3.1). Свойства гладкости/негладкости r при этом не влияют.

Кажется, что положив $f \equiv 0$, с помощью такого метода можно решать любую негладкую задачу. Действительно, если разрешить приближенное вычисление проксимального оператора, то формально можно решать любую выпуклую негладкую задачу. Однако с теоретической точки зрения это не приводит к преимуществам по сравнению с субградиентным методом: для нахождения значения проксимального оператора приходится решать подзадачу, которая сама по себе требует использования дополнительного метода (например, того же субградиентного спуска).

Л9 Градиентный спуск с проекцией. Алгоритм Франк–Вульфа

В предыдущих параграфах рассматривались безусловные задачи оптимизации, то есть задачи без ограничений на всем пространстве $\mathbb{R}^d$. Однако не все задачи на практике можно сформулировать в такой постановке — чаще всего, решается задача с ограничением оптимизируемых переменных на некоторое множество $\mathcal{X} \subseteq \mathbb{R}^d$. В этом параграфе речь пойдет об оптимизации на выпуклых множествах. Определим этот класс множеств.

Определение Л9.1. Множество $\mathcal{X} \subseteq \mathbb{R}^d$ называется *выпуклым*, если для любых двух точек $x_1, x_2 \in \mathcal{X}$ и любого числа $\alpha \in [0, 1]$, точка $\alpha x_1 + (1 - \alpha)x_2$ также принадлежит $\mathcal{X}$.

Физический смысл заключается в том, что вместе с любыми двумя точками выпуклого множества в него входит и отрезок с концами в этих точках. Подробнее выпуклые множества обсуждаются в рамках данного пособия в разделе С3. На выпуклые множества естественно переносится определение выпуклой функции.

Определение Л9.2. Рассмотрим функцию $f : \mathcal{X} \rightarrow \mathbb{R}$. Функция f называется *выпуклой* на выпуклом множестве $\mathcal{X}$, если для любых $x_1, \dots, x_k \in \mathcal{X}$ и любых $\alpha_1, \dots, \alpha_k, \alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1$ выполняется

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i).$$

Теперь мы готовы перейти к постановке задачи.

Л9.1 Задача оптимизации с ограничениями

Ставится задача на множестве

$$\min_{x \in \mathcal{X}} f(x), \quad (\text{Л9.1})$$

где $\mathcal{X} \subset \mathbb{R}^d$ — выпуклое множество (Определение Л9.1), f — выпуклая на $\mathcal{X}$ функция (Определение Л9.2).

Замечание Л9.1. Графически понять, как выглядит задача, поможет иллюстрация Рис. Л9.1.

Здесь $\mathcal{X}$ — выпуклое замкнутое множество: пятиугольник в $\mathbb{R}^2$, а по вертикальной оси отложено значение функции f . Решением задачи будет точка $x \in \mathcal{X}$, лежащая в множестве и доставляющая минимум функции f .

Важным замечанием будет, что минимум выпуклой функции на множестве может не совпадать с глобальным для $\mathbb{R}^d$. Более того, условия оптимальности (Утверждения Л2.1 и Л2.2) для $\mathbb{R}^d$ не будут работать для задачи на выпуклом множестве. Чтобы в этом убедиться, можно рассмотреть пример $\min_{x \in [1, 2]} x^2$. Минимум достигается в точке $x^* = 1$, градиент в ней не равен нулю. Это подводит нас к следующему критерию.

Теорема Л9.1. [Параграф 4.2.3. из [6]] Пусть дана выпуклая непрерывно дифференцируемая на $\mathbb{R}^d$ функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и выпуклое множество $\mathcal{X} \subseteq \mathbb{R}^d$. Тогда




Рис. Л9.1: Пример задачи с ограничением.

$x^* \in \mathcal{X}$ — глобальный минимум f на $\mathcal{X}$ тогда и только тогда, когда для всех $x \in \mathcal{X}$ выполнено:

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0.$$

Доказательство. $\Rightarrow$ Пусть x^* — глобальный минимум на $\mathcal{X}$. Хотим доказать, что $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ для любого $x \in \mathcal{X}$. Пойдем от противного: предположим, что существует $x \in \mathcal{X}$ такой, что:

$$\langle \nabla f(x^*), x - x^* \rangle < 0.$$

Рассмотрим точки вида:

$$x_\lambda = \lambda x + (1 - \lambda)x^*, \quad \lambda \in [0, 1].$$

В силу выпуклости множества $\mathcal{X}$ (Определение Л9.1) точки $x_\lambda \in \mathcal{X}$. Посмотрим, как ведет себя функция $\phi : [0, 1] \rightarrow \mathbb{R}$ вида:

$$\phi(\lambda) = f(x_\lambda) = f(\lambda x + (1 - \lambda)x^*).$$

Её производная вычисляется как:

$$\frac{d\phi}{d\lambda} = \frac{d}{d\lambda} f(\lambda x + (1 - \lambda)x^*) = \langle \nabla f(x^* + \lambda(x - x^*)), x - x^* \rangle.$$

Обратим внимание, что в нуле по предположению

$$\left. \frac{d\phi}{d\lambda} \right|_{\lambda=0} = \langle \nabla f(x^*), x - x^* \rangle < 0.$$

Это значит, что функция ϕ убывает в окрестности нуля. Следовательно, для достаточно малых $\lambda > 0$ выполнено:

$$f(x_\lambda) = \phi(\lambda) < \phi(0) = f(x^*).$$

Пришли к противоречию с тем, что x^* — глобальный минимум на $\mathcal{X}$.

⊖ Пусть $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ для всех $x \in \mathcal{X}$. Тогда воспользуемся выпуклостью f на $\mathbb{R}^d$ (Определение Л2.3):

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle \geq f(x^*).$$

Откуда следует, что x^* — глобальный минимум на $\mathcal{X}$. ■

Физический смысл Теоремы Л9.1 проиллюстрирован на Рисунке Л9.2.




Рис. Л9.2: Геометрическая иллюстрация условия оптимальности для выпуклого множества.

С новым условием оптимальности можно переходить к построению методов.

Л9.2 Градиентный спуск с проекцией

Вновь обратимся к методу градиентного спуска (Алгоритм Л3.1). Он работал на безусловных задачах, то есть на всем $\mathbb{R}^d$. Если просто попытаться его запустить для задачи на множестве, то возникнет проблема: мы можем «выпасть» из множества. Иными словами, на какой-то итерации k может случиться так, что градиентный шаг выводит нас из множества:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k) \notin \mathcal{X}.$$

Чтобы избежать такого поведения, вводится *операция проектирования*.

Определение Л9.3. Проекцией точки $x \in \mathbb{R}^d$ на замкнутое множество $\mathcal{X} \subset \mathbb{R}^d$ называется точка $\Pi_{\mathcal{X}}(x) \in \mathcal{X}$, находящаяся на кратчайшем расстоянии от x , т.е.

$$\|x - \Pi_{\mathcal{X}}(x)\|_2 = \inf_{y \in \mathcal{X}} \|x - y\|_2$$

Замечание Л9.2. Существование проекции гарантируется замкнутостью множества $\mathcal{X}$ и теоремой Вейерштрасса (Теорема 2 Параграфа 7 Главы 2 из [41]), поскольку для непрерывной нормы минимум достигается при заданных условиях.

Из Л9.3 и существования проекции для замкнутого множества можем ввести оператор проекции $\Pi_{\mathcal{X}} : \mathbb{R}^d \rightarrow \mathcal{X}$, который задается как:

$$\Pi_{\mathcal{X}}(x) := \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x - y\|_2^2. \quad (\text{Л9.2})$$

С помощью оператора $\Pi_{\mathcal{X}}(x)$ можно на каждой итерации проецироваться шаг градиентного спуска на множество, чтобы не выходить за его ограничения:

$$x^{k+1} = \Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)) \in \mathcal{X},$$

Эта идея и лежит в основе метода градиентного спуска с проекцией. Запишем формальный алгоритм.

Алгоритм Л9.1 Градиентный спуск с проекцией

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**
 2: $x^{k+1} = \Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k))$
 3: **end for**

Выход: x^K

Геометрически принцип работы алгоритма показан на Рисунке Л9.3.




Рис. Л9.3: Проекция точки на множество $\mathcal{X}$.

Л9.2.1 Свойства оператора проекции

Для последующего анализа метода потребуется изучить оператор проекции подробнее.

Утверждение Л9.1. Для выпуклого замкнутого множества $\mathcal{X}$ и любой точки оператор проекции существует и принимает единственное значение.

Доказательство. Задача проекции — это минимизация сильно выпуклой функции на выпуклом множестве:

$$\Pi_{\mathcal{X}}(x) := \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x - y\|_2^2.$$

Существование и единственность решения в безусловном случае рассматривалось в Теореме Л2.3. Этот результат легко переносится на случай минимизации на выпуклом множестве: достаточно шар $\bar{B}^2(R, x^0)$ заменить на пересечение $\bar{B}^2(R, x^0) \cap \mathcal{X}$, а условие оптимальности для $\mathbb{R}^d$:

$$\nabla f(x^*) = 0$$

заменить на условие для выпуклого $\mathcal{X}$:

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0$$

для всех $x \in \mathcal{X}$. Остальные рассуждения и переходы остаются неизменными. Тогда получаем, что решение такой задачи существует и единственно. ■

Утверждение Л9.2. Пусть $\mathcal{X} \subseteq \mathbb{R}^d$ — выпуклое замкнутое множество, $y \in \mathcal{X}$, $x \in \mathbb{R}^d$. Тогда

$$\langle y - \Pi_{\mathcal{X}}(x), x - \Pi_{\mathcal{X}}(x) \rangle \leq 0.$$

Доказательство. Заметим, что $\Pi_{\mathcal{X}}(x)$ минимизирует дифференцируемую выпуклую функцию $d(z) = \frac{1}{2} \|x - z\|_2^2$ на выпуклом множестве $\mathcal{X}$. Запишем условие оптимальности:

$$\langle \nabla d(\Pi_{\mathcal{X}}(x)), y - \Pi_{\mathcal{X}}(x) \rangle \geq 0$$

для всех $y \in \mathcal{X}$. Подставим $\nabla d(\Pi_{\mathcal{X}}(x)) = \Pi_{\mathcal{X}}(x) - x$ и поменяем местами аргументы скалярного произведения:

$$\langle y - \Pi_{\mathcal{X}}(x), x - \Pi_{\mathcal{X}}(x) \rangle \leq 0$$

для всех $y \in \mathcal{X}$. ■

В следующем утверждении формулируется 1-липшицевость оператора проекции.

Утверждение Л9.3. Пусть $\mathcal{X} \subseteq \mathbb{R}^d$ — выпуклое замкнутое множество, $x_1, x_2 \in \mathbb{R}^d$. Тогда

$$\|\Pi_{\mathcal{X}}(x_1) - \Pi_{\mathcal{X}}(x_2)\|_2 \leq \|x_1 - x_2\|_2.$$

Доказательство. Пользуемся результатом Утверждения Л9.2 для $x_1, x_2 \in \mathbb{R}^d$, $x \in \mathcal{X}$:

$$\langle x_1 - \Pi_{\mathcal{X}}(x_1), x - \Pi_{\mathcal{X}}(x_1) \rangle \leq 0,$$

$$\langle x_2 - \Pi_{\mathcal{X}}(x_2), x - \Pi_{\mathcal{X}}(x_2) \rangle \leq 0.$$

Подставим $x = \Pi_{\mathcal{X}}(x_2)$ в первое неравенство и $x = \Pi_{\mathcal{X}}(x_1)$ во второе:

$$\langle x_1 - \Pi_{\mathcal{X}}(x_1), \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1) \rangle \leq 0,$$

$$\langle x_2 - \Pi_{\mathcal{X}}(x_2), \Pi_{\mathcal{X}}(x_1) - \Pi_{\mathcal{X}}(x_2) \rangle \leq 0.$$

Сложим и получим:

$$\langle \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1), \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1) \rangle \leq \langle \Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1), x_2 - x_1 \rangle.$$

Применим неравенство Коши–Буняковского–Шварца (0.3):

$$\|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2^2 \leq \|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2 \|x_2 - x_1\|_2.$$

Откуда имеем:

$$\|\Pi_{\mathcal{X}}(x_2) - \Pi_{\mathcal{X}}(x_1)\|_2 \leq \|x_2 - x_1\|_2. \quad \blacksquare$$

Утверждение Л9.4. Пусть x^* — решение условной задачи (Л9.1) минимизации выпуклой непрерывно дифференцируемой функции f на выпуклом замкнутом множестве $\mathcal{X}$. Тогда справедливо

$$x^* = \Pi_{\mathcal{X}}(x^* - \gamma \nabla f(x^*))$$

Доказательство. Распишем определение оператора проекции (Л9.2):

$$\begin{aligned} \Pi_{\mathcal{X}}(x^* - \gamma \nabla f(x^*)) &= \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x^* - \gamma \nabla f(x^*) - y\|_2^2 \\ &= \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} [\|x^* - y\|_2^2 + 2\gamma \langle \nabla f(x^*), y - x^* \rangle + \gamma^2 \|\nabla f(x^*)\|_2^2]. \end{aligned}$$

Откуда:

$$\Pi_{\mathcal{X}}(x^* - \gamma \nabla f(x^*)) = \operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} [\|x^* - y\|_2^2 + 2\gamma \langle \nabla f(x^*), y - x^* \rangle].$$

Оба слагаемых под argmin неотрицательны: первое в силу неотрицательности квадрата нормы, второе в силу Теоремы Л9.1. Следовательно, минимум равен 0, и достигается он на x^* . ■

Этих свойств оператора проекции нам будет достаточно, чтобы произвести анализ сходимости метода.

Л9.2.2 Теоретические оценки сходимости

Теорема Л9.2. Пусть задача на ограниченном выпуклом замкнутом множестве $\mathcal{X}$ (Л9.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска с проекцией (Алгоритм Л9.1). Тогда при $\gamma_k \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2.$$

Доказательство. Рассмотрим $\|x^{k+1} - x^*\|_2^2$. Подставим итерацию метода:

$$\|x^{k+1} - x^*\|_2^2 = \|\Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)) - x^*\|_2^2.$$

Воспользуемся Утверждением Л9.4:

$$\|x^{k+1} - x^*\|_2^2 = \|\Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)) - \Pi_{\mathcal{X}}(x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

А теперь применяем неравенство из Утверждения Л9.3:

$$\|x^{k+1} - x^*\|_2^2 \leq \|(x^k - \gamma_k \nabla f(x^k)) - (x^* - \gamma_k \nabla f(x^*))\|_2^2.$$

Раскроем квадрат нормы:

$$\|x^{k+1} - x^*\|_2^2 \leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle + \gamma_k^2 \|\nabla f(x^k) - \nabla f(x^*)\|_2^2.$$

Оценим последнее слагаемое, используя свойство L -гладкой выпуклой f (неравенство (Л2.5) из Теоремы Л2.5):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - 2\gamma_k \langle x^k - x^*, \nabla f(x^k) - \nabla f(x^*) \rangle \\ &\quad + \gamma_k^2 L \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \\ &= \|x^k - x^*\|_2^2 - \gamma_k (2 - \gamma_k L) \langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle. \end{aligned} \quad (\text{Л9.3})$$

Два раза запишем определение μ -сильной выпуклости f (Определение Л2.4):

$$\begin{aligned} f(x^k) &\geq f(x^*) + \langle \nabla f(x^*), x^k - x^* \rangle + \frac{\mu}{2} \|x^k - x^*\|_2^2, \\ f(x^*) &\geq f(x^k) + \langle \nabla f(x^k), x^* - x^k \rangle + \frac{\mu}{2} \|x^* - x^k\|_2^2. \end{aligned} \quad (\text{Л9.4})$$

Сложим их и получим:

$$\langle \nabla f(x^k) - \nabla f(x^*), x^k - x^* \rangle \geq \mu \|x^k - x^*\|_2^2.$$

Подставляем в неравенство (Л9.3) неравенство (Л9.4):

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &\leq \|x^k - x^*\|_2^2 - \mu\gamma_k (2 - \gamma_k L) \|x^k - x^*\|_2^2 \\ &= (1 - \mu\gamma_k (2 - \gamma_k L)) \|x^k - x^*\|_2^2. \end{aligned}$$

Поскольку $\gamma_k \leq \frac{1}{L}$, то $2 - \gamma_k L > 1$. Продолжая цепочку неравенств, имеем:

$$\|x^{k+1} - x^*\|_2^2 \leq (1 - \mu\gamma_k) \|x^k - x^*\|_2^2.$$

Остается лишь развернуть рекурсию с K -ой итерации до нулевой:

$$\begin{aligned} \|x^K - x^*\|_2^2 &\leq (1 - \mu\gamma_{K-1}) \|x^{K-1} - x^*\|_2^2 \\ &\leq (1 - \mu\gamma_{K-1}) (1 - \mu\gamma_{K-2}) \|x^{K-2} - x^*\|_2^2 \\ &\leq \dots \\ &\leq \left(\prod_{k=0}^{K-1} (1 - \mu\gamma_k) \right) \|x^0 - x^*\|_2^2. \end{aligned}$$

■

Утверждение Л9.5. Пусть задача удовлетворяет условиям Теоремы Л9.2 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\|x^K - x^*\|_2^2 \leq \left(1 - \frac{\mu}{L}\right)^K \|x^0 - x^*\|_2^2.$$

Более того, чтобы добиться точности ε по аргументу ($\|x^K - x^*\|_2 \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{L}{\mu} \log \frac{\|x^0 - x^*\|_2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Повторяет доказательство Утверждения Л3.1. ■

Л9.2.3 Проекция как отдельная задача

Рассмотрим задачу поиска проекции:

$$\operatorname{argmin}_{y \in \mathcal{X}} \frac{1}{2} \|x - y\|_2^2. \quad (\text{Л9.5})$$

Получим аналитическое решение для некоторых простых множеств $\mathcal{X}$.

Утверждение Л9.6. Пусть задача проекции (Л9.5) решается на ℓ_1 -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_1 \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = \begin{cases} x, & \|x\|_1 \leq R, \\ \operatorname{sign}(x_i)(|x_i| - \lambda)_+ \quad \forall i \in \overline{1, d}, & \|x\|_1 > R, \end{cases}$$

где λ определяется из уравнения

$$\sum_{i=1}^d (|x_i| - \lambda)_+ = R.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda) = \frac{1}{2} \|x - y\|_2^2 + \lambda (\|y\|_1 - R) = \sum_{i=1}^d \left(\frac{1}{2} (y_i - x_i)^2 + \lambda |y_i| \right) - \lambda R.$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|y\|_1 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda (\|y\|_1 - R) = 0$;
4. Стационарность: $0 \in y_i - x_i + \lambda \partial |y_i|$.

Последнему условию удовлетворяет:

$$y_i = \operatorname{sign}(x_i)(|x_i| - \lambda)_+.$$

- Если $\lambda = 0$, то $y = x$ и требуется $\|x\|_1 \leq R$.
- Если $\lambda > 0$, то $\sum_{i=1}^d |y_i| = R$, что даёт уравнение на λ : $g(\lambda) = \sum_{i=1}^d (|x_i| - \lambda)_+ - R$. Единственность следует из монотонного убывания.

■

Утверждение Л9.7. Пусть задача проекции (Л9.5) решается на ℓ_2 -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_2 \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = \min \left\{ 1, \frac{R}{\|x\|_2} \right\} x.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda) = \frac{1}{2} \|x - y\|_2^2 + \lambda (\|y\|_2^2 - R^2).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|y\|_2 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda (\|y\|_2 - R) = 0$;
4. Стационарность: $y - x + 2\lambda y = 0$.

Из стационарности имеем $(1 + 2\lambda)y = x$.

- Если $\lambda = 0$, то $y = x$, и из ограничений имеем $\|x\|_2 \leq R$.
- Если $\lambda > 0$, то из дополняющей нежёсткости $\|y\|_2 = R$, а потому

$$y = \frac{x}{1 + 2\lambda}, \quad R = \|y\|_2 = \frac{\|x\|_2}{1 + 2\lambda} \implies y = \frac{R}{\|x\|_2} x.$$

Это случай для $\|x\|_2 > R$.

■

Утверждение Л9.8. Пусть задача проекции (Л9.5) решается на ℓ_∞ -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_\infty \leq R \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = \begin{cases} -R, & x_i < -R, \\ x_i, & -R \leq x_i \leq R, \\ R, & x_i > R. \end{cases}$$

Доказательство. Запишем лагранжиан с двумя покомпонентными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $y - \mathbf{R} \preceq 0$ и $-y - \mathbf{R} \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \frac{1}{2} \|x - y\|_2^2 + \lambda_1^\top (y - \mathbf{R}) + \lambda_2^\top (-y - \mathbf{R}).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $-\mathbf{R} \preceq y \leq \mathbf{R}$;
2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;

3. Дополняющая нежёсткость: $\lambda_1^i(y_i - R) = 0$, $\lambda_2^i(-y_i - R) = 0$;

4. Стационарность: $y - x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покоординатно:

- Если $-R < x_i < R$, то $y_i = x_i$, при этом $\lambda_1^i = \lambda_2^i = 0$;
- Если $x_i > R$, то $y_i = R$, при этом условие дополняющей нежёсткости требует $\lambda_2^i = 0$, а стационарность даёт $\lambda_1^i = x_i - R > 0$;
- Если $x_i < -R$, то $y_i = -R$, при этом условие дополняющей нежёсткости требует $\lambda_1^i = 0$, а стационарность даёт $\lambda_2^i = -x_i - R > 0$.

■

Утверждение Л9.9. Пусть задача проекции (Л9.5) решается на симплексе размера R :

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid y \succeq 0, \mathbf{1}^\top y = R \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = (x_i + \nu)_+,$$

где ν определяется из уравнения

$$\sum_{i=1}^d (x_i + \nu)_+ = R.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \lambda, \nu) = \frac{1}{2} \|x - y\|_2^2 - \lambda^\top y - \nu(\mathbf{1}^\top y - R).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $y \succeq 0$, $\mathbf{1}^\top y = R$;
2. Неотрицательность: $\lambda \succeq 0$;
3. Дополняющая нежёсткость: $\lambda_i y_i = 0$;
4. Стационарность: $y - x - \lambda - \nu = 0$.

Из стационарности имеем

$$y = x + \lambda + \nu.$$

Используя дополняющую нежёсткость, получаем:

$$y_i = \frac{1}{2} ((x_i + \nu) + |x_i + \nu|) = (x_i + \nu)_+,$$

$$\lambda_i = \frac{1}{2} (|x_i + \nu| - (x_i + \nu)) = (-x_i - \nu)_+.$$

Подставляя это выражение в ограничение $\mathbf{1}^\top y = R$, получаем уравнение на ν :

$$\sum_{i=1}^d (x_i + \nu)_+ = R.$$

Поскольку функция монотонно возрастает, то решение для ν единственно.

■

Утверждение Л9.10. Пусть задача проекции (Л9.5) решается на гиперпрямоугольнике:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid a \preceq y \preceq b \right\}.$$

Тогда оператор проекции имеет вид:

$$[\Pi_{\mathcal{X}}(x)]_i = \begin{cases} a_i, & x_i < a_i, \\ x_i, & a_i \leq x_i \leq b_i, \\ b_i, & x_i > b_i. \end{cases}$$

Доказательство. Запишем лагранжиан с двумя покомпонентными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $y - b \preceq 0$ и $-y + a \preceq 0$:

$$\mathcal{L}(y, \lambda_1, \lambda_2) = \frac{1}{2} \|x - y\|_2^2 + \lambda_1^\top (y - b) + \lambda_2^\top (-y + a).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $a \preceq y \preceq b$;
2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;
3. Дополняющая нежесткость: $\lambda_1^i (y_i - b_i) = 0, \lambda_2^i (-y_i + a_i) = 0$;
4. Стационарность: $y - x + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покомпонентно:

- Если $a_i < x_i < b_i$, то $y_i = x_i$, при этом $\lambda_1^i = \lambda_2^i = 0$;
- Если $x_i > b_i$, то $y_i = b_i$, при этом условие дополняющей нежесткости требует $\lambda_2^i = 0$, а стационарность даёт $\lambda_1^i = x_i - b_i > 0$;
- Если $x_i < a_i$, то $y_i = a_i$, при этом условие дополняющей нежесткости требует $\lambda_1^i = 0$, а стационарность даёт $\lambda_2^i = -x_i + a_i > 0$.

■

Утверждение Л9.11. Пусть задача проекции (Л9.5) решается на множестве линейных равенств:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid Ay = b \right\},$$

где предполагается, что $AA^\top$ невырождена. Тогда оператор проекции имеет вид:

$$\Pi_{\mathcal{X}}(x) = x - A^\top (AA^\top)^{-1} (Ax - b).$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(y, \nu) = \frac{1}{2} \|x - y\|_2^2 + \nu^\top (Ay - b).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $Ay = b$;

2. Стационарность: $y - x + A^\top \nu = 0$.

Из стационарности

$$y = x - A^\top \nu.$$

Подставляя в ограничение, получаем

$$Ax - AA^\top \nu = b \implies \nu = (AA^\top)^{-1}(Ax - b).$$

Следовательно:

$$y = x - A^\top (AA^\top)^{-1}(Ax - b).$$

■

Л9.3 Метод Франк–Вульфа

В методе градиентного спуска с проекцией (Алгоритм Л9.1) операция проекции для некоторых множеств $\mathcal{X}$ может быть вычислительно дорогой или вовсе не иметь аналитического выражения. Однако во многих случаях доступна более простая процедура — решение задачи линейной минимизации:

$$s^k = \operatorname{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle.$$

Иными словами, мы умеем находить такую точку $s^k \in \mathcal{X}$, которая минимизирует линейное приближение функции f в окрестности x^k . Эту операцию часто записывают через оракул линейной минимизации (Linear Minimization Oracle):

$$\text{LMO}(c) = \operatorname{argmin}_{s \in \mathcal{X}} \langle s, c \rangle.$$

Алгоритм, использующий на каждом шаге вызов LMO и последующее усреднение с текущей точкой, был предложен Маргаритой Франк и Филипом Вульфом в 1956 году [14]. Он известен как *метод условного градиента* или *метод Франк–Вульфа*.

Алгоритм Л9.2 Метод Франк–Вульфа

Вход: стартовая точка $x^0 \in \mathcal{X}$, размеры шагов $\{\gamma_k\}_{k=0} \in [0, 1]$, количество итераций K

```
1: for  $k = 0, 1, \dots, K - 1$  do  
2:    $s^k = \operatorname{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle$   
3:    $x^{k+1} = (1 - \gamma_k)x^k + \gamma_k s^k$   
4: end for
```

Выход: x^K

LMO указывает на экстремальную точку множества $\mathcal{X}$ (интуитивно это «уголок» множества $\mathcal{X}$), а обновление

$$x^{k+1} = (1 - \gamma_k)x^k + \gamma_k s^k$$

усредняет её с текущим приближением, так что последовательность x^k строится как выпуклая комбинация найденных экстремальных точек.




Рис. 19.4: Шаг Франк–Вульфа.

Замечание 19.3. В Алгоритме 19.2 шаг взят произвольным. Классическим выбором считается

$$\gamma_k = \frac{2}{k+2},$$

поскольку для него получаются хорошие теоретические оценки и он легко вычислим на практике. Однако возможен выбор шага линейным поиском:

$$\gamma_k = \operatorname{argmin}_{\gamma \in [0,1]} f(x^k + \gamma(s^k - x^k)).$$

Докажем сходимость для классического выбора шага.

Теорема 19.3. Пусть задача оптимизации на выпуклом замкнутом множестве (19.1) с L -гладкой выпуклой целевой функцией f решается с помощью метода Франк–Вульфа (Алгоритм 19.2). Тогда при $\gamma_k = \frac{2}{k+2}$ справедлива следующая оценка сходимости:

$$f(x^K) - f^* \leq \frac{2 \max \{L \operatorname{diam}(\mathcal{X})^2, f(x^0) - f^*\}}{K+2}, \quad (19.6)$$

где $\operatorname{diam}(\mathcal{X}) := \max_{x,y \in \mathcal{X}} \|x - y\|_2$ — диаметр множества $\mathcal{X}$.

Более того, чтобы добиться точности ε по функции ($f(x^K) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{\max\{L \operatorname{diam}(\mathcal{X})^2, f(x^0) - f^*\}}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Запишем итерацию метода и применим неравенство (12.3) из Теоремы 12.5:

$$\begin{aligned} f(x^{k+1}) - f^* &= f(x^k + \gamma_k(s^k - x^k)) - f^* \\ &\leq f(x^k) - f^* + \gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle + \frac{\gamma_k^2}{2} L \|s^k - x^k\|_2^2 \quad (19.7) \\ &\leq f(x^k) - f^* + \gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle + \gamma_k^2 C. \end{aligned}$$

В последнем переходе мы применили, что $x^k, s^k \in \mathcal{X}$, и $\|s^k - x^k\|_2 \leq \operatorname{diam} \mathcal{X}$, а также ввели обозначение $C = \frac{L(\operatorname{diam} \mathcal{X})^2}{2}$.

Примем во внимание, что s^k ищется как решение линейной минимизации:

$$s^k = \operatorname{argmin}_{s \in \mathcal{X}} \langle s, \nabla f(x^k) \rangle = \operatorname{argmin}_{s \in \mathcal{X}} \gamma_k \langle s - x^k, \nabla f(x^k) \rangle,$$

откуда следует неравенство:

$$\gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle \leq \gamma_k \langle x^* - x^k, \nabla f(x^k) \rangle.$$

Правую часть можно оценить по выпуклости (Определение П2.3) и получить:

$$\gamma_k \langle s^k - x^k, \nabla f(x^k) \rangle \leq \gamma_k (f^* - f(x^k)).$$

Подставляем в основное неравенство (П9.7):

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* + \gamma_k (f^* - f(x^k)) + \gamma_k^2 C \\ &= (1 - \gamma_k)(f(x^k) - f^*) + \gamma_k^2 C. \end{aligned}$$

Докажем по индукции, что для всех целых $k \geq 0$ выполняется:

$$f(x^k) - f^* \leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2}.$$

База индукции: для $k = 0$ верное тождество. Рассмотрим $k \geq 1$:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq (1 - \gamma_k)(f(x^k) - f^*) + \gamma_k^2 C \\ &= \left(1 - \frac{2}{k+2}\right)(f(x^k) - f^*) + \left(\frac{2}{k+2}\right)^2 C \\ &\leq \left(1 - \frac{2}{k+2}\right) \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} + \left(\frac{1}{k+2}\right)^2 2 \cdot 2C, \end{aligned}$$

где в последнем шаге мы использовали предположение индукции. Далее последнее слагаемое оценим максимумом:

$$2 \cdot 2C \leq 2 \max\{2C, f(x^0) - f^*\}.$$

Продолжим неравенство:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \left(1 - \frac{2}{k+2} + \frac{1}{k+2}\right) \\ &= \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \left(1 - \frac{1}{k+2}\right) \\ &= \frac{2 \max\{2C, f(x^0) - f^*\}}{k+2} \frac{k+1}{k+2}. \end{aligned}$$

Докажем неравенство:

$$\frac{k+1}{(k+2)^2} \leq \frac{1}{k+3}.$$

Оно эквивалентно:

$$(k+1)(k+3) \leq (k+2)^2,$$

что после раскрытия скобок равносильно: $3 \leq 4$.

Получили верное тождество, значит, и исходное неравенство верно, так как все переходы равносильны. Завершим доказательство индукционного перехода и основного утверждения теоремы:

$$f(x^{k+1}) - f^* \leq \frac{2 \max\{2C, f(x^0) - f^*\}}{k+3}.$$

Для получения оценки количества итераций для достижения точности ε запишем оценку (Л9.6) и ограничим правую часть:

$$f(x^K) - f^* \leq \frac{2 \max\{L(\text{diam } \mathcal{X})^2, f(x^0) - f^*\}}{K+2} \leq \varepsilon.$$

Откуда выражается K :

$$K = \mathcal{O}\left(\frac{\max\{L(\text{diam } \mathcal{X})^2, f(x^0) - f^*\}}{\varepsilon}\right).$$

■

Получили сублинейную сходимость по функции в выпуклом случае. Для безусловной задачи градиентный спуск имел такие же оценки $\mathcal{O}(\frac{1}{\varepsilon})$. Появляется логичный вопрос об оптимальности метода Франк–Вульфа в классе методов, использующих ЛМО и $\nabla f(x)$, для решения выпуклых задач. Оказывается, имеют место нижние оценки.

Л9.3.1 Нижние оценки для ЛМО

Метод Франк–Вульфа обладает сублинейной скоростью сходимости $\mathcal{O}(\frac{1}{K})$ в классе выпуклых гладких задач. Возникает естественный вопрос — можно ли добиться более быстрой сходимости, используя тот же набор инструментов: градиент $\nabla f(x)$ и оракул линейной минимизации ЛМО? Оказывается, ответ отрицательный: существует фундаментальное ограничение, определяемое самой структурой допустимого множества и характером направлений, которые предоставляет ЛМО.

Оператор линейной минимизации выбирает на каждом шаге одну из экстремальных точек множества $s_i \in \mathcal{X}$. Следовательно, каждое новое направление $s^k - x^k$ формируется как комбинация уже выбранных вершин. Итерации метода Франк–Вульфа, таким образом, представляют собой последовательность выпуклых комбинаций всё большего числа вершин (для простоты возьмем в качестве стартовой точки одну из экстремальных точек $\mathcal{I}_0 = \{s_0\} \subset \mathcal{X}$):

$$x^k = \sum_{i \in \mathcal{I}_k} \alpha_i^{(k)} s_i, \quad \sum_{i \in \mathcal{I}_k} \alpha_i^{(k)} = 1, \quad \alpha_i^{(k)} \geq 0.$$

Чтобы достичь оптимума, лежащего во внутренней точке некоторой грани допустимого множества, алгоритму необходимо постепенно «вымывать» веса вершин ($\alpha_i^{(k)} \rightarrow 0$), не принадлежащих этой грани. Но каждое усреднение даёт лишь малое смещение в сторону нужной грани, и процесс удаления неактуальных компонент происходит очень медленно. Следовательно, за k итераций метод может исследовать не более чем k направлений, что накладывает фундаментальное ограничение на скорость сходимости.

Утверждение Л9.12. Пусть задача оптимизации (Л9.1) с L -гладкой целевой функцией f решается методом, использующим ЛМО. Тогда чтобы добиться точ-

ности ε по функции $(f(x^K) - f^* \leq \varepsilon)$ необходимо

$$K = \Omega\left(\frac{L(\text{diam } \mathcal{X})^2}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Рассмотрим задачу минимизации квадратичной функции

$$\min_{x \in \mathcal{X}} f(x) = \frac{L}{2} \|x\|_2^2,$$

где множество $\mathcal{X} = \text{conv}\{e_1, \dots, e_d\}$ представляет собой симплекс размера R в пространстве $\mathbb{R}^d$. Тогда $\text{diam } \mathcal{X} = \sqrt{2}R$. Оптимальное решение определяется из неравенства Коши–Буняковского–Шварца (0.3): для любых $x \in \Delta_{d-1}$ справедливо $\|x\|_2^2 \geq \frac{R^2}{d}$, причём равенство достигается тогда и только тогда, когда все координаты равны. Отсюда

$$x^* = \frac{R}{d} \mathbf{1}, \quad f(x^*) = \frac{LR^2}{2d} = \frac{L(\text{diam } \mathcal{X})^2}{4d}. \quad (\text{Л9.8})$$

Пусть метод стартует из некоторой вершины симплекса, например e_1 . Так как каждая итерация добавляет не более одной новой вершины, то после $K < d$ вызовов ЛМО множество всех вершин, которые могли быть использованы в выпуклых комбинациях, имеет мощность не более $K + 1$. Обозначим это множество через $S_K \subseteq \{e_1, \dots, e_d\}$, где $|S_K| \leq K + 1$. Тогда

$$x^K \in \text{conv}(S_K).$$

Минимизируя $f(x) = \frac{L}{2} \|x\|_2^2$ на выпуклой оболочке на не более чем $K + 1$ вершинах, получаем

$$f(x^K) \geq \min_{\substack{x \in \text{conv}(S_K) \\ |S_K| \leq K+1}} f(x) = \frac{L(\text{diam } \mathcal{X})^2}{4(K+1)}.$$

Из (Л9.8) следует

$$f(x^K) - f(x^*) \geq \frac{L(\text{diam } \mathcal{X})^2}{4} \left(\frac{1}{K+1} - \frac{1}{d} \right).$$

Устремляя d к бесконечности, получаем, что чтобы достичь точности $f(x^K) - f(x^*) \leq \varepsilon$, требуется не менее чем

$$K = \Omega\left(\frac{L(\text{diam } \mathcal{X})^2}{\varepsilon}\right) \text{ итераций.}$$

■

Этот пример [15, 17] демонстрирует компромисс между разреженностью и оптимальностью: в рассматриваемой задаче в силу построения функции после K вызовов ЛМО решение ограничено подпространством, порождённым не более чем $K + 1$ вершинами, и потому не может быть лучше минимума на этом подпространстве.

Мы рассмотрели замедление, связанное с разреженностью решения, возникающей из-за ограниченного числа вершин, добавляемых при работе ЛМО. Иной источник замедления — геометрический. Предположим, что решается задача оптимизации на многограннике и предположим, что оптимум лежит во внутренней некоторой грани F . По мере приближения решения к оптимуму «угол обзора» из текущей точки на экстремальные вершины грани F становится очень большим. В результате эффективная

часть шага, направленная к оптимуму, начинает затухать, и возникает зигзагообразное поведение: алгоритм постепенно приближается к решению, но каждое последующее направление движения оказывается почти противоположным предыдущему. Для L -гладких и μ -сильно выпуклых функций на многограннике P в работе [7] установлено, что даже при оптимальном выборе шага и сильной выпуклости функции скорость сходимости метода Франк–Вульфа не может быть улучшена сверх

$$f(x^k) - f^* \geq \frac{L(\text{diam } \mathcal{X})^2}{k \log^{2+\delta} k}, \quad \forall \delta > 0.$$

Таким образом, даже при более сильных предположениях улучшение относительно стандартной оценки $\Omega(\frac{1}{k})$ ограничивается лишь логарифмическим множителем.

Л9.3.2 Линейная минимизация как отдельная задача

Рассмотрим линейную задачу на выпуклом замкнутом множестве $\mathcal{X}$:

$$\operatorname{argmin}_{s \in \mathcal{X}} \langle s, c \rangle \quad (\text{Л9.9})$$

Получим аналитическое решение для некоторых простых множеств $\mathcal{X}$.

Утверждение Л9.13. Пусть задача линейной минимизации (Л9.9) решается на ℓ_1 -шаре радиуса R с центром в 0

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \mid \|s\|_1 \leq R \right\}.$$

Тогда её решение:

$$s^* = -R \operatorname{sign}(c_i) e_i, \quad \text{где } i = \operatorname{argmax}_{j=\overline{1,d}} |c_j|.$$

Доказательство. Запишем Лагранжиан:

$$\mathcal{L}(s, \lambda) = \langle s, c \rangle + \lambda (\|s\|_1 - R) = \sum_{i=1}^d (s_i c_i + \lambda |s_i|) - \lambda R.$$

Лагранжиан распадается по координатам, введём обозначение:

$$\mathcal{L}_i(s, \lambda) = s_i c_i + \lambda |s_i|.$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|s\|_1 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежесткость: $\lambda (\|s\|_1 - R) = 0$;
4. Стационарность: $0 \in c_i + \lambda \partial |s_i|$;

$$0 \in c_i + \lambda \begin{cases} -1, & s_i < 0, \\ [-1, 1], & s_i = 0, \\ 1, & s_i > 0. \end{cases}$$

Всем этим условиям удовлетворяет решение:

$$s^* = -R \operatorname{sign}(c_i) e_i, \quad \lambda = |c_i|,$$

где $i = \operatorname{argmax}_{j=1,d} |c_j|$. ■

Утверждение Л9.14. Пусть задача линейной минимизации (Л9.9) решается на ℓ_2 -шаре радиуса R с центром в 0

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \mid \|s\|_2 \leq R \right\}.$$

Тогда её решение:

$$s^* = \begin{cases} -\frac{c}{\|c\|_2} R, & c \neq 0, \\ 0, & c = 0. \end{cases}$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(s, \lambda) = \langle s, c \rangle + \lambda (\|s\|_2^2 - R^2).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $\|s\|_2 - R \leq 0$;
2. Неотрицательность: $\lambda \geq 0$;
3. Дополняющая нежёсткость: $\lambda (\|s\|_2 - R) = 0$;
4. Стационарность: $c + 2\lambda s = 0$.

Рассмотрим варианты:

- Для $c = 0$ пара $s^* = 0$ и $\lambda^* = 0$ удовлетворяет всем условиям.
- Для $c \neq 0$ из стационарности получаем, что $\lambda > 0$ и

$$s = -\frac{c}{2\lambda},$$

а из дополняющей нежёсткости:

$$\|s\|_2 = R.$$

Тогда, собирая все вместе, получаем:

$$\frac{\|c\|_2}{2\lambda} = \|s\|_2 = R \implies \lambda = \frac{\|c\|_2}{2R}, \quad s^* = -\frac{c}{\|c\|_2} R.$$
■

Утверждение Л9.15. Пусть задача линейной минимизации (Л9.9) решается на ℓ_∞ -шаре радиуса R с центром в 0:

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \mid \|s\|_\infty \leq R \right\}.$$

Тогда её решение:

$$s^* = -R \operatorname{sign}(c).$$

Доказательство. Запишем лагранжиан с двумя покомпонентными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $s - \mathbf{R} \preceq 0$ и $-s - \mathbf{R} \preceq 0$:

$$\mathcal{L}(s, \lambda_1, \lambda_2) = \langle s, c \rangle + \lambda_1^\top (s - \mathbf{R}) + \lambda_2^\top (-s - \mathbf{R}).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $-\mathbf{R} \preceq s \preceq \mathbf{R}$;
2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;
3. Дополняющая нежесткость: $\lambda_1^i (s_i - R) = 0, \lambda_2^i (-s_i - R) = 0$;
4. Стационарность: $c + \lambda_1 - \lambda_2 = 0$.

Рассмотрим варианты:

- Если $c_i > 0$, то $s_i^* = -R, \lambda_1^i = 0$ и $\lambda_2^i = c_i$.
- Если $c_i < 0$, то $s_i^* = R, \lambda_1^i = -c_i$ и $\lambda_2^i = 0$.
- Если $c_i = 0$, то $s_i^* = 0, \lambda_1^i = 0$ и $\lambda_2^i = 0$.

■

Утверждение Л9.16. Пусть задача линейной минимизации (Л9.9) решается на симплексе размера R :

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \mid s \succeq 0, \mathbf{1}^\top s = R \right\}.$$

Тогда её решение:

$$s^* = R e_i, \text{ где } i = \operatorname{argmin}_{j=1, d} c_j.$$

Доказательство. Запишем лагранжиан:

$$\mathcal{L}(s, \lambda, \nu) = \langle s, c \rangle - \lambda^\top s - \nu (\mathbf{1}^\top s - R).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $s \succeq 0, \mathbf{1}^\top s = R$;
2. Неотрицательность: $\lambda \succeq 0$;
3. Дополняющая нежесткость: $\lambda_i s_i = 0$;
4. Стационарность: $c - \lambda - \nu = 0$.

Возьмем

$$s^* = R e_i, \lambda_j = c_j - c_i, \nu = -c_i,$$

где $i = \operatorname{argmin}_{j=1, d} c_j$.

■

Утверждение Л9.17. Пусть задача линейной минимизации (Л9.9) решается на гиперпрямоугольнике:

$$\mathcal{X} = \left\{ s \in \mathbb{R}^d \mid a \preceq s \preceq b \right\}.$$

Тогда её решение:

$$s^* = \frac{a+b}{2} + \frac{a-b}{2} \text{sign}(c).$$

Доказательство. Запишем лагранжиан с двумя покоординатными множителями неравенств $\lambda_1, \lambda_2 \geq 0$ для ограничений $s - b \preceq 0$ и $-s + a \preceq 0$:

$$\mathcal{L}(s, \lambda_1, \lambda_2) = \langle s, c \rangle + \lambda_1^\top (s - b) + \lambda_2^\top (-s + a).$$

Воспользуемся теоремой Каруша–Куна–Таккера (Теорема С8.1):

1. Ограничения: $a \preceq s \preceq b$;
2. Неотрицательность: $\lambda_1 \succeq 0, \lambda_2 \succeq 0$;
3. Дополняющая нежесткость: $\lambda_1^i (s_i - b_i) = 0, \lambda_2^i (-s_i + a_i) = 0$;
4. Стационарность: $c + \lambda_1 - \lambda_2 = 0$.

Рассмотрим покоординатно:

- Если $c_i > 0$, то $s_i^* = a_i, \lambda_1^i = 0$ и $\lambda_2^i = c_i$.
- Если $c_i < 0$, то $s_i^* = b_i, \lambda_1^i = -c_i$ и $\lambda_2^i = 0$.
- Если $c_i = 0$, то $s_i^* \in [a_i, b_i], \lambda_1^i = 0$ и $\lambda_2^i = 0$.

■

Л9.3.3 Критерий сходимости

В ходе работы метода Франк–Вульфа (Алгоритм Л9.2) надо как-то оценивать точность текущего решения. В безусловных задачах мы использовали такие классические критерии, как норма градиента, значение целевой функции с известным минимумом. При оптимизации на ограниченном множестве они не применимы — вспоминаем пример $\min_{x \in [1, 2]} x^2$. В оптимуме $x^* = 1$ градиент не равен нулю.

Решением этой проблемы будет метрика гар, которая определяется следующим образом:

$$\text{гар}(x^k) = \max_{y \in \mathcal{X}} \langle \nabla f(x^k), x^k - y \rangle = \langle \nabla f(x^k), x^k \rangle - \min_{y \in \mathcal{X}} \langle \nabla f(x^k), y \rangle. \quad (\text{Л9.10})$$

Её физический смысл становится ясным при применении выпуклости f (Определение Л2.3):

$$\text{гар}(x^k) = \max_{y \in \mathcal{X}} \langle \nabla f(x^k), x^k - y \rangle \geq \max_{y \in \mathcal{X}} (f(x^k) - f(y)) = f(x^k) - f^*.$$

Иными словами, если мы потребуем точность ε по гар, то получим точность ε и по функции:

$$f(x^k) - f^* \leq \text{гар}(x^k) \leq \varepsilon.$$

Другим преимуществом метрики гар является легкость её вычисления. В самом деле, ЛМО возвращает нам решение линейной задачи оптимизации, умножив его скалярно на градиент, получаем второе слагаемое в записи (Л9.10). Первое слагаемое находится так же просто.

Получим аналитические выражения для метрики гар для «простых» множеств.

- ℓ_1 -шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_1 \leq R \right\},$$

$$\text{гар}(x^k) = \langle \nabla f(x^k), x^k \rangle + R \left| (\nabla f(x^k))_i \right|, \text{ где } i = \operatorname{argmax}_{j=\overline{1,d}} \left| (\nabla f(x^k))_j \right|.$$

- ℓ_2 -шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_2 \leq R \right\},$$

$$\text{гар}(x^k) = \langle \nabla f(x^k), x^k \rangle + R \|\nabla f(x^k)\|_2.$$

- ℓ_∞ -шар радиуса R с центром в 0:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid \|y\|_\infty \leq R \right\},$$

$$\text{гар}(x^k) = \langle \nabla f(x^k), x^k \rangle + R \|\nabla f(x^k)\|_1.$$

- Симплекс Δ_{d-1} размера R :

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid y \succeq 0, \mathbf{1}^\top y = R \right\},$$

$$\text{гар}(x^k) = \langle \nabla f(x^k), x^k \rangle - R (\nabla f(x^k))_i, \text{ где } i = \operatorname{argmin}_{j=\overline{1,d}} (\nabla f(x^k))_j.$$

- Гиперпрямоугольник:

$$\mathcal{X} = \left\{ y \in \mathbb{R}^d \mid a \leq y \leq b \right\},$$

$$\text{гар}(x^k) = \langle \nabla f(x^k), x^k \rangle - \frac{1}{2} \left\langle \nabla f(x^k) + \left| \nabla f(x^k) \right|, a \right\rangle - \frac{1}{2} \left\langle \nabla f(x^k) - \left| \nabla f(x^k) \right|, b \right\rangle.$$

Л10 Метод зеркального спуска

В предыдущем параграфе мы рассмотрели модификацию алгоритма градиентного спуска для решения задачи с ограничениями на множестве — градиентный спуск с проекцией. Однако для градиентного спуска существуют и другие способы учета геометрии задачи. Вновь обратимся к итерации метода (Алгоритм Л3.1):

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k). \quad (\text{Л10.1})$$

Здесь точка x^k рассматривается как элемент конечномерного линейного нормированного пространства $E = (U, \|\cdot\|)$ с нормой $\|\cdot\|$. При этом градиент $\nabla f(x^k)$ как линейный дифференциальный оператор принадлежит уже не исходному пространству, а сопряжённому $E^* = (U, \|\cdot\|_*)$ с сопряжённой векторной нормой $\|\cdot\|_*$ из Определения С1.8. Поэтому в общем случае итерация (Л10.1) складывает объекты из разных пространств.

Утверждение Л10.1. Норма дифференциального оператора $\|df(x)\|$ совпадает с сопряжённой векторной нормой градиента $\|\nabla f(x)\|_*$ из Определения С1.8.

Доказательство. Норма дифференциального оператора $df(x)[h] : U \rightarrow \mathbb{R}$ определяется по формуле $\|df(x)\| := \sup_{\|h\|=1} |df(x)[h]|$, аналогично подчинённой матричной норме из Определения С1.4. Распишем дифференциал $df(x)[h]$ через градиент $\nabla f(x)$:

$$\|df(x)\| = \sup_{\|h\|=1} |df(x)[h]| = \sup_{\|h\|=1} |\langle \nabla f(x), h \rangle| = \|\nabla f(x)\|_*.$$

■

В ситуации, когда $\|\cdot\| = \|\cdot\|_2$, исходное и двойственное пространства совпадают, и итерация градиентного спуска корректна.

Однако норма в пространстве задачи не обязана быть евклидовой. Хотя в конечномерных пространствах все нормы эквивалентны (подробно это описано в конце параграфа, где данное утверждение используется для иллюстрации преимуществ зеркального спуска), в случае произвольного E записывать итерацию в виде (Л10.1) некорректно. Эти соображения приводят к идее, предложенной А. Немировским и Д. Юдиным [27]: шаг градиентного спуска должен выполняться не в исходном пространстве, а в сопряжённом. Для этого, введем обратимое отображение $\varphi : E \rightarrow E^*$, требования к которому будут определены ниже. Тогда итерация метода примет вид:

$$x^{k+1} = \varphi^{-1}(\varphi(x^k) - \gamma_k \nabla f(x^k)), \quad (\text{Л10.2})$$

где обратное отображение $\varphi^{-1} : E^* \rightarrow E$ возвращает результат в пространство E .

Замечание Л10.1. Пространство E^* в этом контексте называют «зеркальным». Именно в нём выполняется шаг градиентного спуска, а затем с помощью φ^{-1} результат отображается обратно в исходное пространство.

Л10.1 Дивергенция Брэгмана

Хотя теперь шаг метода стал корректным, остается непонятным, как сходо построить функцию φ , подходящую к геометрии конкретной задачи. Поэтому мы предлагаем пойти по альтернативному пути: мы сначала выберем новую, неевклидовую функцию расстояния под геометрию задачи, а уже потом выведем модифицированный шаг метода с этим новым расстоянием. В частности, в качестве класса функций расстояния будут использоваться дивергенции Брэгмана.

Для начала обобщим Определение Л2.4 μ -сильной выпуклости для произвольной нормы.

Определение Л10.1. Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $d : \mathcal{X} \rightarrow \mathbb{R}$. Будем говорить, что она является μ -сильно выпуклой относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено

$$d(x) - d(y) - \langle \nabla d(y), x - y \rangle \geq \frac{\mu}{2} \|x - y\|^2.$$

Теперь мы можем ввести формальное определение для дивергенции Брэгмана.

Определение Л10.2. Пусть дана непрерывно дифференцируемая 1-сильно выпуклая относительно нормы $\|\cdot\|$ на множестве $\mathcal{X}$ функция d . Дивергенцией Брэгмана, порожденной функцией d на множестве $\mathcal{X}$, называется функция двух аргументов $V(x, y) : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ такая, что для любых $x, y \in \mathcal{X}$ выполняется

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle.$$

Выражение для $V(x, y)$ в точности совпадает с левой частью неравенства из определения μ -сильной выпуклости. Рассмотрим несколько примеров $V(x, y)$ и, то какими функциями $d(x)$ они порождаются.

Пример Л10.1. Квадрат евклидовой нормы $d : \mathbb{R}^d \rightarrow \mathbb{R}$ с евклидовой дивергенцией:

$$d(x) = \frac{1}{2} \|x\|_2^2, \quad V(x, y) = \frac{1}{2} \|x - y\|_2^2.$$

Решение. В этом примере 1-сильная выпуклость $d(x)$ относительно $\|\cdot\|_2$ тривиальна. Далее мы выводим дивергенцию Брэгмана по Определению Л10.2:

$$\begin{aligned} V(x, y) &= \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} (\|x\|_2^2 - \|y\|_2^2 - 2\langle y, x \rangle + 2\|y\|_2^2) \\ &= \frac{1}{2} (\|x\|_2^2 - 2\langle y, x \rangle + \|y\|_2^2) = \frac{1}{2} \|x - y\|_2^2. \end{aligned}$$

Мы получили просто квадрат евклидова расстояния. ■

Пример Л10.2. Энтропия Шеннона $d : \Delta_{d-1} \rightarrow \mathbb{R}$ с дивергенцией Кульбака-Лейблера (KL-дивергенцией):

$$d(x) = \sum_{i=1}^d x_i \log x_i, \quad V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i},$$

где

$$\Delta_{d-1} = \left\{ x \in \mathbb{R}^d \mid \sum_{i=1}^d x_i = 1, x_i > 0 \right\}.$$

Эта дивергенция позволяет измерить расстояние между двумя дискретными вероятностными распределениями, заданными своими векторами вероятности $x, y \in \Delta_{d-1}$.

Решение. Градиент $d(y)$ в точке y считается как:

$$[\nabla d(y)]_i = 1 + \log y_i,$$

Подставляя этот градиент в определение дивергенции Брэгмана (Определение Л10.2), мы получаем:

$$\begin{aligned} V(x, y) &= \sum_{i=1}^d x_i \log x_i - \sum_{i=1}^d y_i \log y_i - \sum_{i=1}^d (1 + \log y_i)(x_i - y_i) \\ &= \sum_{i=1}^d x_i (\log x_i - \log y_i) - \sum_{i=1}^d (x_i - y_i) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}, \end{aligned}$$

где слагаемое $\sum_{i=1}^d (x_i - y_i) = 0$, так как $x, y \in \Delta_{d-1}$ и $\sum_{i=1}^d x_i = \sum_{i=1}^d y_i = 1$. Таким образом, мы получили дивергенцию Кульбака–Лейблера.

К тому же, согласно неравенству Пинскера, энтропия $d(x)$ является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_{d-1} , то есть:

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i} \geq \frac{1}{2} \|x - y\|_1^2.$$

■

Пример Л10.3. Логарифмический барьер $d : \mathbb{S}_{(0,1]}^d \rightarrow \mathbb{R}$ (Пример С2.12):

$$d(X) = -\log(\det X), \quad V(X, Y) = \text{Tr}(XY^{-1} - I_d) - \log \det(XY^{-1}),$$

где

$$\mathbb{S}_{(0,1]}^d := \left\{ X \in \mathbb{S}_{++}^d \mid \left\| X^{\frac{1}{2}} \right\|_F \leq 1 \right\},$$

Эта дивергенция также применяется для измерения расстояния между вероятностными распределениями. В частности, она является KL-дивергенцией между двумя многомерными нормальными распределениями с ковариациями X и Y и одинаковыми средними.

Решение. Вычислим дифференциал:

$$d(-\log(\det X)) = -\frac{1}{\det X} d(\det X) = -\frac{1}{\det X} \det X \langle X^{-\top}, dX \rangle = -\langle X^{-\top}, dX \rangle.$$

Подставляем в определение дивергенции Брэгмана (Определение Л10.2):

$$\begin{aligned} V(X, Y) &= -\log(\det X) + \log(\det Y) - \langle -Y^{-\top}, X - Y \rangle \\ &= -\log(\det X / \det Y) + \text{Tr}(XY^{-1} - I_d) \\ &= \text{Tr}(XY^{-1} - I_d) - \log \det(XY^{-1}). \end{aligned}$$

Для подсчета константы сильной выпуклости относительно Фробениусовой нормы $\|\cdot\|_F$, воспользуемся критерием выпуклости второго порядка. Из Примера С2.12 мы знаем, что второй дифференциал для логарифмического барьера равен:

$$d^2 d(X) [H, H] = \left\| X^{-\frac{1}{2}} H X^{-\frac{1}{2}} \right\|_F^2.$$

Воспользовавшись неравенством норм для произведения матриц и условием на матрицы $\left\| X^{\frac{1}{2}} \right\|_F \leq 1$, получим:

$$\|H\|_F^2 = \left\| X^{\frac{1}{2}} X^{-\frac{1}{2}} H X^{-\frac{1}{2}} X^{\frac{1}{2}} \right\|_F^2 \leq \left\| X^{\frac{1}{2}} \right\|_F^2 \left\| X^{-\frac{1}{2}} H X^{-\frac{1}{2}} \right\|_F^2 = \left\| X^{\frac{1}{2}} \right\|_F^2 \cdot d^2 d(X) [H, H],$$

и как следствие:

$$d^2 d(X) [H, H] \geq \frac{\|H\|_F^2}{\|X^{\frac{1}{2}}\|_F^2} \geq \|H\|_F^2.$$

■

Изучим подробнее свойства нового объекта.

Утверждение Л10.2. Пусть $\mathcal{X}$ — выпуклое множество. Дивергенция Брэгмана в общем случае обладает следующими свойствами:

1. Асимметричность: в общем случае $V(x, y) \neq V(y, x)$.
2. Ограниченность снизу:

$$V(x, y) \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

3. Неотрицательность: $V(x, y) \geq 0$ для всех $x, y \in \mathcal{X}$.
4. Выпуклость по первому аргументу: $V(x, y)$ является 1-сильно выпуклой по x для любого y .
5. Невыпуклость по второму аргументу: $V(x, y)$ может быть невыпуклой по y .

Замечание Л10.2. Дивергенцию Брэгмана можно воспринимать как расстояние между векторами или матрицами, но стоит обратить внимание, что формально она не является метрикой и даже не симметрична относительно перестановки переменных.

Доказательство. Кратко поясним каждый пункт.

1. В качестве примера асимметричной дивергенции Брэгмана рассмотрим дивергенцию Кульбака–Лейблера (Пример Л10.2). Из записи видно отсутствие симметрии:

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}.$$

2. Ограниченность снизу получается из Определения Л10.2 для дивергенции и 1-сильной выпуклости d (Определение Л10.1):

$$V(x, y) = d(x) - d(y) - \langle \nabla d(y), x - y \rangle \geq \frac{1}{2} \|x - y\|^2 \text{ для всех } x, y \in \mathcal{X}.$$

3. Неотрицательность следует из предыдущего пункта. Также можем утверждать, что равенство нулю $V(x, y) = 0$ достигается тогда и только тогда, когда аргументы равны: $x = y$.
4. Относительно первого аргумента дивергенция Брэгмана является суммой 1-сильно выпуклой d и линейной функции, то есть 1-сильно выпуклой функцией.
5. Рассмотрим функцию $d(x) = -\log x$, $x \in (0, 1]$ из Примера Л10.3. Соответствующая дивергенция Брэгмана имеет вид:

$$V(x, y) = d(x) - d(y) - d'(y)(x - y) = -\log x + \log y + \frac{x}{y} - 1.$$

Зафиксируем $x = \frac{1}{4}$ и введём функцию:

$$g(y) = V\left(\frac{1}{4}, y\right) = -\log \frac{1}{4} + \log y + \frac{1}{4y} - 1, \quad y \in (0, 1].$$

Запишем критерий выпуклости второго порядка:

$$g''(y) = -\frac{1}{y^2} + \frac{1}{2y^3} = \frac{1}{y^2} \left(\frac{1}{2y} - 1 \right) \geq 0, \quad \forall y \in (0, 1].$$

Однако при $y > \frac{1}{2}$ мы получаем противоречие. ■

Утверждение Л10.3 (Равенство параллелограмма/теорема Пифагора).

Пусть $\mathcal{X}$ — выпуклое множество. Для любых точек $x, y, z \in \mathcal{X}$ выполняется

$$V(x, y) + V(y, z) - V(x, z) = \langle \nabla d(z) - \nabla d(y), x - y \rangle.$$

Доказательство. Распишем по Определению Л10.2:

$$\begin{aligned} V(x, y) + V(y, z) &= d(x) - d(y) - \langle \nabla d(y), x - y \rangle + d(y) - d(z) - \langle \nabla d(z), y - z \rangle \\ &= d(x) - d(z) - \langle \nabla d(z), x - z \rangle - \langle \nabla d(y) - \nabla d(z), x - y \rangle \\ &= V(x, z) - \langle \nabla d(y) - \nabla d(z), x - y \rangle. \end{aligned}$$
■

Л10.2 Зеркальный спуск

После того как мы ввели новую функцию расстояния через дивергенцию Брэгмана $V(x, y)$, мы приступаем к модификации шага градиентного спуска. Мы повторим вывод классического шага, но вместо квадрата евклидова расстояния $\frac{1}{2}\|x - y\|^2$ мы будем использовать новую функцию $V(x, y)$, подходящую под геометрию конкретной задачи. Решаем задачу оптимизации на множестве $\mathcal{X}$:

$$\min_{x \in \mathcal{X}} f(x). \quad (\text{Л10.3})$$

Запишем итерацию градиентного спуска (Алгоритм Л3.1) на $\mathbb{R}^d$ в готовом виде:

$$x^{k+1} = x^k - \gamma_k \nabla f(x^k).$$

С точки зрения оптимизации данная итерация является решением следующей задачи:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^d} \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\gamma_k} \|x - x^k\|_2^2 \right\}.$$

В самом деле, Теоремы Л2.1 и Л2.2 дают нам необходимое и достаточное условия глобального минимума выпуклой функции:

$$\nabla_x \left(f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\gamma_k} \|x - x^k\|_2^2 \right) = \nabla f(x^k) + \frac{1}{\gamma_k} (x - x^k) = 0,$$

откуда и получается формула для шага градиентного спуска. Можно упростить запись, избавившись от константы $f(x^k)$ и домножив целевую функцию на положительное γ_k :

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^d} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\}.$$

Теперь учтем множество $\mathcal{X}$ с помощью евклидовой проекции, как в Алгоритме Л19.1:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\}. \quad (\text{Л10.4})$$

Действительно, добавим слагаемые не зависящие от x и выделим квадрат нормы, чтобы получить знакомую форму:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \frac{1}{2} \gamma_k^2 \|\nabla f(x^k)\|_2^2 + \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\} \\ &= \operatorname{argmin}_{x \in \mathcal{X}} \|x - (x^k - \gamma_k \nabla f(x^k))\|_2^2 = \Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)). \end{aligned}$$

Наконец, мы учтем геометрию множества $\mathcal{X}$ через дивергенцию Брэгмана, которая имеет смысл расстояния. Мы можем заменить евклидову норму $\frac{1}{2} \|x - x^k\|_2^2$ на $V(x, x^k)$ в задаче (Л10.4), чтобы получить новый итеративный метод:

$$x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \right\}.$$

Алгоритм Л10.1 Зеркальный спуск

Вход: стартовая точка $x^0 \in \mathcal{X}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, дивергенция Брэгмана V , количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \right\}$

3: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k$

Чтобы понять, почему данный метод называется «зеркальным спуском», покажем, как соотносятся Алгоритм Л10.1 и идея шага в сопряжённом пространстве.

Пример Л10.4. Рассмотрим метод при $\mathcal{X} = \mathbb{R}^d$ и некоторой $d: \mathbb{R}^d \rightarrow \mathbb{R}$:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + V(x, x^k) \right\} \\ &= \operatorname{argmin}_{x \in \mathbb{R}^d} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \right\}. \end{aligned}$$

Запишем условие оптимальности (Теорема Л2.2):

$$\gamma_k \nabla f(x^k) + \nabla d(x) - \nabla d(x^k) = 0.$$

Это и есть идея Немировского и Юдина, идея «зеркальности»:

$$\nabla d(x^{k+1}) = \nabla d(x^k) - \gamma_k \nabla f(x^k). \quad (\text{Л10.5})$$

То есть $\nabla d: E \rightarrow E^*$ — это и есть то самое преобразование ϕ из (Л10.2), переносящее шаг градиентного спуска в зеркальное пространство.

Если множество $\mathcal{X}$ не совпадает со всем пространством $\mathbb{R}^d$, то после основного шага (Л10.5) нужно дополнительно найти проекцию точки x^{k+1} на $\mathcal{X}$. Для этого минимизируется дивергенция Брэгмана: $\operatorname{argmin}_{x \in \mathcal{X}} V(x, x^{k+1})$.

Замечание Л10.3. С помощью такого инструмента, как дивергенция Брэгмана, мы научились переходить от задачи в «зеркальном» пространстве к простому поиску argmin , который во многих случаях либо имеет аналитическое решение, либо может быть найден численно с хорошей точностью.

Рассмотрим, какие формулы итераций будут получаться при выборе различных дивергенций Брэгмана.

Пример Л10.5. Квадрат евклидовой нормы $V : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$:

$$V(x, y) = \frac{1}{2} \|x - y\|_2^2, \quad x, y \in \mathcal{X},$$

как обсуждалось, даёт градиентный спуск с евклидовой проекцией (Алгоритм Л9.1):

$$x^{k+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \langle \gamma_k \nabla f(x^k), x - x^k \rangle + \frac{1}{2} \|x - x^k\|_2^2 \right\} = \Pi_{\mathcal{X}}(x^k - \gamma_k \nabla f(x^k)).$$

Пример Л10.6. Дивергенция Кульбака–Лейблера $V : \Delta_{d-1} \times \Delta_{d-1} \rightarrow \mathbb{R}$:

$$V(x, y) = \sum_{i=1}^d x_i \log \frac{x_i}{y_i}, \quad x, y \in \Delta_{d-1}$$

даёт аналитическую итерацию:

$$x_i^{k+1} = x_i^k \frac{\exp(-\gamma_k [\nabla f(x^k)]_i)}{\sum_{i=1}^d x_i^k \exp(-\gamma_k [\nabla f(x^k)]_i)}.$$

Решение. Запишем итерацию зеркального спуска как задачу с ограничениями:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) \\ \text{s.t.} \quad & -x_i \leq 0 \\ & \sum_{i=1}^d x_i - 1 = 0. \end{aligned}$$

Для решения этой задачи воспользуемся условиями Каруша–Куна–Таккера (Определение С8.1), которые в данном случае являются необходимыми и достаточными условиями условного минимума (Теорема С8.2).

Лагранжиан для такой задачи имеет вид:

$$\begin{aligned} \mathcal{L}(x, \lambda, \nu) &= \langle \gamma_k \nabla f(x^k), x \rangle + V(x, x^k) - \sum_{i=1}^d \lambda_i x_i + \nu \left(\sum_{i=1}^d x_i - 1 \right) \\ &= \sum_{i=1}^d \left(\gamma_k [\nabla f(x^k)]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu \right) x_i - \nu, \quad \lambda \in \mathbb{R}^d, \nu \geq 0. \end{aligned}$$

Градиент лагранжиана по x_i :

$$\frac{\partial \mathcal{L}}{\partial x_i}(x, \lambda, \nu) = 1 + \gamma_k [\nabla f(x^k)]_i + \log \frac{x_i}{x_i^k} - \lambda_i + \nu.$$

Из условий стационарности по x находим x^* , доставляющий минимум лагранжиана:

$$\frac{\partial \mathcal{L}}{\partial x_i}(x^*, \lambda^*, \nu^*) = 0 \Rightarrow x_i^* = x_i^k \exp(-1 - \gamma_k [\nabla f(x^k)]_i + \lambda_i^* - \nu^*), \quad i = \overline{1, d}.$$

Условия дополняющей нежёсткости:

$$\lambda_i^* \cdot (-x_i^*) = 0 \Rightarrow -\lambda_i^* \cdot x_i^k \exp(-1 - \gamma_k [\nabla f(x^k)]_i + \lambda_i^* - \nu^*) = 0, \quad i = \overline{1, d}.$$

Точка x_i^k лежит на симплексе Δ_{d-1} и $x_i^k > 0$, и при этом экспонента также всегда положительна. Следовательно, единственный способ удовлетворить условиям нежёсткости — это принять $\lambda_i^* = 0$, $i = \overline{1, d}$ и получить:

$$x_i^* = x_i^k \exp(-1 - \gamma_k [\nabla f(x^k)]_i - \nu^*), \quad i = \overline{1, d}.$$

Чтобы избавиться от $-1 - \nu^*$, вспомним ограничение задачи $\sum_{i=1}^d x_i^* = 1$. Отсюда получаем нормировку и можно записать:

$$x_i^{k+1} = x_i^k \frac{\exp(-\gamma_k [\nabla f(x^k)]_i)}{\sum_{i=1}^d x_i^k \exp(-\gamma_k [\nabla f(x^k)]_i)}.$$

Это и есть итерации зеркального спуска для KL-дивергенции на симплексе. ■

Прежде чем переходить к доказательству сходимости зеркального спуска, мы обобщим свойство гладкости функции для произвольной нормы, как это было сделано для сильной выпуклости в Определении Л10.1.

Определение Л10.3. Пусть дана непрерывно дифференцируемая на выпуклом множестве $\mathcal{X}$ функция $f: \mathcal{X} \rightarrow \mathbb{R}$. Будем говорить, что данная функция имеет L -Липшицев градиент (является L -гладкой) относительно нормы $\|\cdot\|$ на $\mathcal{X}$, если для любых $x, y \in \mathcal{X}$ выполнено:

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\|,$$

где $\|\cdot\|_*$ — это сопряженная векторная норма из Определения С1.8

Теорема Л10.1. Пусть $\mathcal{X}$ — выпуклое множество. Для L -гладкой относительно нормы $\|\cdot\|$ функции $f: \mathcal{X} \rightarrow \mathbb{R}$ выполнено:

$$|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| \leq \frac{L}{2} \|x - y\|^2.$$

Доказательство. Используем (Страница 84 из [42]) формулу Ньютона–Лейбница для криволинейного интеграла второго рода по кривой, заданной вектор функцией $r(\tau)$:

$$\int_a^b \langle \nabla f(r(\tau)), dr(\tau) \rangle = f(r(b)) - f(r(a)).$$

В нашем случае выберем кривую следующим образом $r(\tau) = x + \tau(y - x)$, где $\tau \in [0, 1]$:

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau \\ &= \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau. \end{aligned}$$

Переместив скалярное произведение влево и взяв модуль от обеих частей, получим:

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle d\tau \right| \\ &\leq \int_0^1 |\langle \nabla f(x + \tau(y - x)) - \nabla f(x), y - x \rangle| d\tau. \end{aligned}$$

В последнем переходе мы использовали факт, что модуль суммы не превосходит сумму модулей слагаемых. Далее воспользуемся неравенством Гёльдера (0.2), а затем L -гладкостью относительно нормы $\|\cdot\|$ (Определение Л10.3):

$$\begin{aligned} |f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &\leq \int_0^1 \|\nabla f(x + \tau(y - x)) - \nabla f(x)\|_* \|y - x\| d\tau \\ &\leq L \|y - x\|^2 \int_0^1 \tau d\tau = \frac{L}{2} \|x - y\|^2. \end{aligned}$$

■

Теперь мы готовы перейти к доказательству сходимости зеркального спуска.

Теорема Л10.2. Пусть задача оптимизации на выпуклом замкнутом множестве $\mathcal{X}$ (Л10.3) с L -гладкой относительно нормы $\|\cdot\|$ выпуклой целевой функцией f решается с помощью зеркального спуска (Алгоритм Л10.1). Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K}.$$

Доказательство. Начнем с итерации зеркального спуска:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + V(x, x^k) \} \\ &= \operatorname{argmin}_{x \in \mathcal{X}} \{ \langle \gamma \nabla f(x^k), x - x^k \rangle + d(x) - d(x^k) - \langle \nabla d(x^k), x - x^k \rangle \}. \end{aligned}$$

Запишем условие оптимальности на выпуклом множестве $\mathcal{X}$ (Теорема Л9.1) для функции под argmin :

$$\langle \gamma \nabla f(x^k) + \nabla d(x^{k+1}) - \nabla d(x^k), x - x^{k+1} \rangle \geq 0$$

для всех $x \in \mathcal{X}$. Далее применяем равенство параллелограмма для дивергенции Брэгмана (Утверждение Л10.3) с $x = x$, $y = x^{k+1}$, $z = x^k$:

$$V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) = \langle \nabla d(x^k) - \nabla d(x^{k+1}), x - x^{k+1} \rangle.$$

Подставляем в неравенство выше, учитывая знак, получаем:

$$\langle \gamma \nabla f(x^k), x^{k+1} - x \rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \leq 0. \quad (\text{Л10.6})$$

Теперь запишем свойство L -гладкости (Теорема Л10.1) для $y = x^{k+1}$, $x = x^k$:

$$f(x^{k+1}) - f(x^k) - \langle \nabla f(x^k), x^{k+1} - x^k \rangle \leq \frac{L}{2} \|x^k - x^{k+1}\|^2. \quad (\text{Л10.7})$$

Сложим неравенство (Л10.6) и домноженное на γ неравенство (Л10.7):

$$\begin{aligned} \langle \gamma \nabla f(x^k), x^{k+1} - x \rangle + V(x, x^{k+1}) + V(x^{k+1}, x^k) - V(x, x^k) \\ + \gamma(f(x^{k+1}) - f(x^k) - \langle \nabla f(x^k), x^{k+1} - x^k \rangle) \leq \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned}$$

Перепишем, оставив слева только слагаемые с f :

$$\begin{aligned} \langle \gamma \nabla f(x^k), x^k - x \rangle + \gamma(f(x^{k+1}) - f(x^k)) \leq V(x, x^k) - V(x, x^{k+1}) \\ - V(x^{k+1}, x^k) + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \end{aligned} \quad (\text{Л10.8})$$

Из определения выпуклости (Определение Л2.3) можно оценить:

$$f(x^k) - f(x) + \langle \nabla f(x^k), x - x^k \rangle \leq 0. \quad (\text{Л10.9})$$

Домножим неравенство (Л10.9) на γ и сложим с неравенством (Л10.8) (скалярное произведение $\langle \gamma \nabla f(x^k), x^k - x \rangle$ и $f(x^k)$ сокращаются):

$$\gamma(f(x^{k+1}) - f(x)) \leq V(x, x^k) - V(x, x^{k+1}) - V(x^{k+1}, x^k) + \frac{\gamma L}{2} \|x^k - x^{k+1}\|^2. \quad (\text{Л10.10})$$

Запишем ограниченность снизу дивергенции Брэгмана из Утверждения Л10.2:

$$\frac{1}{2} \|x^{k+1} - x^k\|^2 \leq V(x^{k+1}, x^k).$$

и подставим его в неравенство (Л10.10):

$$\gamma(f(x^{k+1}) - f(x)) \leq V(x, x^k) - V(x, x^{k+1}) + (\gamma L - 1)V(x^{k+1}, x^k).$$

Воспользуемся тем, что $\gamma \leq \frac{1}{L}$ и ограничим нулём сверху последнее слагаемое:

$$\gamma(f(x^{k+1}) - f(x)) \leq V(x, x^k) - V(x, x^{k+1}).$$

Усредним по всем k итераций от 0 до $K - 1$:

$$\frac{\gamma}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{K} \sum_{k=0}^{K-1} (V(x, x^k) - V(x, x^{k+1})).$$

Справа свернем телескопическую сумму:

$$\frac{1}{K} \sum_{k=0}^{K-1} (f(x^{k+1}) - f(x)) \leq \frac{1}{\gamma K} (V(x, x^0) - V(x, x^K)) \leq \frac{V(x, x^0)}{\gamma K}.$$

Для левой части применяем неравенство Йенсена (Неравенство (0.1)):

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f(x) \leq \frac{V(x, x^0)}{\gamma K}.$$

В силу произвольности x , можем взять $x = x^*$:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K}.$$

■

Сформулируем следствие о сходимости и оценке на количество итераций при оптимальном значении шага.

Утверждение Л10.4. Пусть задача удовлетворяет условиям Теоремы Л8.3 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{LV(x^*, x^0)}{K}.$$

Более того, чтобы добиться точности ε по функции ($f(\frac{1}{K} \sum_{k=1}^K x^k) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\frac{LV(x^*, x^0)}{\varepsilon}\right) \text{ итераций.}$$

Доказательство. Выпишем оценку из Теоремы Л10.2 и подставим $\gamma = \frac{1}{L}$:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{V(x^*, x^0)}{\gamma K} = \frac{LV(x^*, x^0)}{K}.$$

Чтобы получить оценку на число итераций, отметим, что мы хотим гарантировать:

$$f\left(\frac{1}{K} \sum_{k=1}^K x^k\right) - f^* \leq \frac{LV(x^*, x^0)}{K} \leq \varepsilon.$$

Тогда:

$$K \geq \frac{LV(x^*, x^0)}{\varepsilon}. \quad (\text{Л10.11})$$

■

Полученный результат сходимости зеркального спуска по форме аналогичен оценке для градиентного спуска. Это объясняется тем, что зеркальный спуск является обобщением градиентного спуска для произвольной дивергенции Брэгмана. В чем тогда преимущество такого метода перед градиентным спуском с проекцией?

Посмотрим внимательно на выражение (Л10.11): константа гладкости L в нем определяется относительно произвольной нормы $\|\cdot\|$ на $\mathcal{X}$, а начальное расстояние $V(x^*, x^0)$ относительно дивергенции V , в отличие от градиентного спуска с проекцией, где $L \equiv$

L_2 и $V(x^*, x^0) \equiv \frac{1}{2} \|x^* - x^0\|_2^2$. Это означает, что может существовать такая дивергенция Брэгмана, при которой мы получим улучшение $LV(x^*, x^0) \ll \frac{1}{2} L_2 \|x^* - x^0\|_2^2$. Проиллюстрируем это более детально на векторных нормах $\|\cdot\| = \|\cdot\|_p$ и $\|\cdot\|_* = \|\cdot\|_q$, где $p, q \in [1, +\infty]$ образуют гёльдеровскую пару, то есть $\frac{1}{p} + \frac{1}{q} = 1$.

Для подмножеств $\mathcal{X} \in \mathbb{R}^d$, константа L определяется через условие гладкости функции следующим образом:

$$\|\nabla f(x) - \nabla f(y)\|_q \leq L \|x - y\|_p.$$

Выбор нормы в этом определении влияет на значение L . Если $1 \leq p \leq 2$, то выполняются соотношения:

$$\|z\|_q \leq \|z\|_2 \leq \|z\|_p,$$

что влечёт $L \leq L_2$. В некоторых задачах константа L может быть существенно меньше евклидовой константы L_2 , например, для функций с плотными градиентами.

Однако из неравенств на нормы выше ясно, что дивергенция Брэгмана не всегда улучшает оценку по сравнению с евклидовой нормой. Действительно, при $1 \leq p \leq 2$ для дивергенции Брэгмана справедлива нижняя оценка (Утверждение Л10.2):

$$V(x, y) \geq \frac{1}{2} \|x - y\|_p^2 \geq \frac{1}{2} \|x - y\|_2^2.$$

Следовательно, преимущество зеркального спуска проявляется тогда, когда уменьшение константы гладкости компенсирует рост дивергенции Брэгмана. Более точно, выигрыш достигается в случае:

$$\frac{L_2}{L} \gg \sup_{x, y \in \mathcal{X}} \frac{2V(x, y)}{\|x - y\|_2^2}.$$

Пример Л10.7. В случае симплекса и KL-дивергенции можно получить выигрыш в $\frac{d}{\log d}$ раз по сравнению с градиентным спуском с евклидовой проекцией.

Решение. Возьмём в качестве начальной точки x^0 равномерный вектор $x^0 = (\frac{1}{d}, \dots, \frac{1}{d})^\top$. Тогда максимальная дивергенция Брэгмана $V(x, x^0) = \sum_{i=1}^d x_i \log \frac{x_i}{x_i^0}$ на симплексе оценивается сверху как:

$$\max_{x \in \Delta_{d-1}} V(x, x^0) = \max_{x \in \Delta_{d-1}} \underbrace{\left\{ \sum_{i=1}^d x_i \log x_i \right\}}_{\leq 0} + \log d \leq \log d.$$

В это же время евклидово расстояние ограничено куда меньшей константой для любых $x, x^0 \in \Delta_{d-1}$, так как $\|x\|_1 = 1$ и $\|x^0\|_1 = 1$:

$$\frac{1}{2} \|x - x^0\|_2^2 \leq \frac{1}{2} \|x - x^0\|_1^2 \leq \frac{1}{2} (\|x\|_1 + \|x^0\|_1)^2 = 2.$$

Однако евклидова константа L_2 в худшем случае в d раз больше, чем константа L_1 , так как выполняются соотношения $\|\cdot\|_1 \leq \sqrt{d} \|\cdot\|_2$ и $\|\cdot\|_2 \leq \sqrt{d} \|\cdot\|_\infty$ (Пример С1.3):

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq \sqrt{d} \|\nabla f(x) - \nabla f(y)\|_\infty \leq \sqrt{d} L_1 \|x - y\|_1 \leq \underbrace{d L_1}_{\leq L_2} \|x - y\|_2.$$

В случае выполнения всех неравенств как равенств, мы получаем:

$$\frac{L_2}{L_1} \approx d, \quad \sup_{x \in \Delta_{d-1}} \frac{2V(x, x^0)}{\|x - x^0\|_2^2} \approx \log d.$$

То есть для зеркального спуска с KL-дивергенцией выигрыш по итерациям может составить до $\frac{d}{\log d}$ раз. ■

Л11 Метод штрафов. ADMM

До этого параграфа мы рассматривали лишь безусловные задачи и задачи оптимизации на множестве. Между тем, общая постановка оптимизационной задачи (Л1.1) включает ограничения вида неравенств и равенств, методы для которой нами ещё не были разработаны. Этот параграф посвящён построению подходов к таким задачам, в частности — методу штрафов.

Л11.1 Штрафная функция

Рассмотрим следующую задачу с ограничениями:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned} \quad (\text{Л11.1})$$

Возьмем некоторое $\rho > 0$ и немного модифицируем нашу задачу:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) + \rho \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned}$$

Замечание Л11.1. Можно заметить, что новая задача эквивалентна старой, так как для x , удовлетворяющих ограничениям, «добавка» равна 0.

Теперь запишем безусловную задачу с такой же целевой функцией:

$$\min_{x \in \mathbb{R}^d} \left[f_\rho(x) = f(x) + \rho \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x) \right]. \quad (\text{Л11.2})$$

Легко проверить, что полученная задача не эквивалентна исходной: безусловный минимум $f_\rho(x)$ вообще не обязан удовлетворять ограничениям.

Задача с ограничениями стала задачей без ограничений, такое мы уже умеем решать. При таком переходе f_ρ называют *штрафной функцией*, а ρ — *параметром штрафа*. Попробуем увеличить штраф за нарушение ограничений. Предельный переход по ρ :

$$\lim_{\rho \rightarrow +\infty} f_\rho(x) = \begin{cases} f(x), & h_j(x) = 0, \quad j = \overline{1, m} \\ +\infty, & \text{иначе} \end{cases}$$

Замечание Л11.2. Есть надежда, что минимизируя f_ρ при решении штрафной задачи для достаточно большого ρ , мы получим неплохое решение и для исходной задачи.

Добавим еще ограничения вида неравенств:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = \overline{1, n} \\ & h_j(x) = 0, \quad j = \overline{1, m}. \end{aligned}$$

Как их добавить в штраф? Сделаем это с помощью положительной «срезки»:

$$f_\rho(x) = f(x) + \rho \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x) + \rho \cdot \frac{1}{2} \sum_{i=1}^n (g_i^+(x))^2,$$

где $y^+ = \max\{y, 0\}$. Штраф активируется только тогда, когда нарушено неравенство.

Л11.2 Свойства решений штрафной задачи

Утверждение Л11.1. Пусть x^* — решение исходной задачи (Л11.1), а x_ρ^* — решение соответствующей штрафной задачи (Л11.2) с $\rho > 0$, тогда

$$f(x^*) \geq f(x_\rho^*).$$

Доказательство. Воспользуемся тем, что x^* удовлетворяет ограничениям, а x_ρ^* — безусловный минимум f_ρ :

$$f(x^*) = f_\rho(x^*) \geq \min_{x \in \mathbb{R}^d} f_\rho(x) = f_\rho(x_\rho^*) \geq f(x_\rho^*).$$

■

Этот результат говорит о том, что либо $f(x^*) = f(x_\rho^*)$, либо мы нарушаем ограничения. Но за счет ρ с этим можно бороться. Следующие два свойства посвящены этому.

Утверждение Л11.2. С увеличением параметра штрафа ρ решения штрафной задачи (Л11.2), при их существовании, гарантированно не ухудшают степень нарушения ограничений, то есть для $\rho_1 > \rho_2$ следует, что

$$\sum_{j=1}^m h_j^2(x_{\rho_2}^*) \geq \sum_{j=1}^m h_j^2(x_{\rho_1}^*),$$

где $x_{\rho_1}^*$ и $x_{\rho_2}^*$ — решения соответствующих штрафных задач.

Доказательство. Пользуемся тем, что $x_{\rho_1}^*$ и $x_{\rho_2}^*$ — решения соответствующих штрафных задач:

$$\begin{aligned} f(x_{\rho_2}^*) + \rho_1 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_2}^*) &\geq f(x_{\rho_1}^*) + \rho_1 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_1}^*) \\ f(x_{\rho_1}^*) + \rho_2 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_1}^*) &\geq f(x_{\rho_2}^*) + \rho_2 \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(x_{\rho_2}^*) \end{aligned}$$

Складываем и делим на $\rho_1 - \rho_2 > 0$ и получаем:

$$\sum_{j=1}^m h_j^2(x_{\rho_2}^*) \geq \sum_{j=1}^m h_j^2(x_{\rho_1}^*).$$

■

Утверждение Л11.3. Пусть функция f и функции h_j являются непрерывными для всех $j = \overline{1, m}$. Пусть X^* — множество решений исходной условной задачи оптимизации (Л11.1) и для $x^* \in X^*$ ограничено множество

$$U = \left\{ x \in \mathbb{R}^d \mid f(x) \leq f(x^*) \right\}.$$

Тогда для любого $\epsilon > 0$ существует $\rho(\epsilon) > 0$ такое, что множество решений штрафной задачи (Л11.2) X_ρ^* для любых $\rho \geq \rho(\epsilon)$ содержится в

$$X_\epsilon^* = \left\{ x \in \mathbb{R}^d \mid \exists x^* \in X^* : \|x - x^*\|_2 \leq \epsilon \right\}.$$

Замечание Л11.3. Ограниченность U нужна для того, чтобы гарантировать, что вне ограничений функция f ведет себя «адекватно» и штрафная функция просто не улетит в $-\infty$. По факту это и гарантирует существование и непустоту X_ρ^* .

Доказательство. Доказательство проведём от противного. Пусть существуют такие $\epsilon > 0$ и последовательность $\{\rho_i\} \rightarrow \infty$, что $X_{\rho_i}^*$ не содержится в X_ϵ^* , то есть существуют

$$x_i^* \in X_{\rho_i}^* \setminus X_\epsilon^*. \quad (\text{Л11.3})$$

Согласно Утверждению Л11.1:

$$f(x^*) \geq f(x_i^*), \quad (\text{Л11.4})$$

а значит все x_i^* лежат в ограниченном множестве U .

По теореме Больцано–Вейерштасса (Теорема 2 Параграфа 9 Главы 1 из [41]) из ограниченной последовательности можно выделить сходящуюся подпоследовательность:

$$\tilde{x}_i^* \rightarrow \tilde{x}^*.$$

Посмотрим, что мы можем сказать про $\tilde{x}^*$. Используя непрерывность f , можем перейти к пределу в неравенстве (Л11.4):

$$f(x^*) \geq \lim_{i \rightarrow \infty} f(\tilde{x}_i^*) = f(\tilde{x}^*).$$

Покажем, что дополнительно $\tilde{x}^*$ удовлетворяет исходным ограничениям h . Пусть для какого-то $k \in \overline{1, m}$ ограничение h_k не выполняется:

$$h_k(\tilde{x}^*) \neq 0.$$

В силу непрерывности h_k , можно заметить, что, начиная с достаточно большого номера i , выполнено

$$|h_k(\tilde{x}_i^*)| \geq \frac{1}{2} |h_k(\tilde{x}^*)| > 0.$$

Но тогда в пределе $\tilde{\rho}_i \rightarrow +\infty$ для последовательности штрафных функций верно:

$$f_{\tilde{\rho}_i}(\tilde{x}_i^*) = f(\tilde{x}_i^*) + \tilde{\rho}_i \cdot \frac{1}{2} \sum_{j=1}^m h_j^2(\tilde{x}_i^*) \rightarrow +\infty.$$

Пришли к противоречию, так как $f_{\tilde{\rho}_i}(\tilde{x}_i^*) \leq f(x^*)$. Значит, $\tilde{x}^*$ удовлетворяет всем ограничениям, а значит, $\tilde{x}^* \in X^*$. Но тогда по определению предела последовательности, начиная с некоторого номера i , будет выполняться

$$\tilde{x}_i^* \in \left\{ x \in \mathbb{R}^d \mid \|x - \tilde{x}^*\|_2 \leq \epsilon \right\} \subseteq X_\epsilon^*.$$

Пришли к противоречию с (Л11.3). ■

Л11.3 Двойственный подъем и аугментация

Рассмотрим задачу с ограничениями

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & Ax = b, \end{aligned} \tag{Л11.5}$$

где $A \in \mathbb{R}^{n \times d}$, $b \in \mathbb{R}^n$. Лагранжиан (Определение С7.1) для неё записывается как:

$$\mathcal{L}(x, \lambda) = f(x) + \lambda^\top (Ax - b).$$

Зная лагранжиан, можем перейти к двойственной функции (Определение С7.2):

$$g(\lambda) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda).$$

Двойственная задача записывается следующим образом:

$$\max_{\lambda \in \mathbb{R}^n} \quad g(\lambda).$$

Тогда запустим градиентный подъем с шагом α для максимизации двойственной функции g :

$$\lambda^{k+1} = \lambda^k + \alpha \nabla_{\lambda^k} \left(\inf_{x \in \mathbb{R}^d} [f(x) + \lambda_k^\top (Ax - b)] \right).$$

Перепишем иначе:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathbb{R}^d} [f(x) + \lambda_k^\top (Ax - b)] = \operatorname{argmin}_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^k) \\ \lambda^{k+1} &= \lambda^k + \alpha \nabla_{\lambda^k} (f(x^{k+1}) + \lambda_k^\top (Ax^{k+1} - b)) = \lambda^k + \alpha (Ax^{k+1} - b). \end{aligned}$$

То есть на каждой итерации считается новый x^{k+1} для λ^k и обновляется по нему λ^{k+1} . Такой метод называется *двойственный подъем*.

Перейдем к аугментации, другими словами — к добавлению штрафа. Уже знаем, что такая «добавка» не меняет задачу:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) + \frac{\rho}{2} \|Ax - b\|_2^2 \\ \text{s.t.} \quad & Ax = b. \end{aligned}$$

Лагранжиан аугментированной задачи:

$$\mathcal{L}_\rho(x, \lambda) = f(x) + \lambda^\top (Ax - b) + \frac{\rho}{2} \|Ax - b\|_2^2.$$

Процедура двойственного подъема для аугментированной задачи:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_{x \in \mathbb{R}^d} \mathcal{L}_\rho(x, \lambda^k) \\ \lambda^{k+1} &= \lambda^k + \rho (Ax^{k+1} - b). \end{aligned}$$

Замечание Л11.4. Использование аугментации позволяет не устремлять ρ к бесконечности.

Замечание Л11.5. Шаг α специально заменен на ρ , чтобы подбирать один параметр для метода.

Теперь можно перейти к следующему методу.

Л11.4 ADMM

Пусть в задаче (Л11.5) целевая функция и ограничения распадаются на две группы переменных. Иначе говоря, пусть задача имеет вид:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^{d_x} \\ y \in \mathbb{R}^{d_y}}} \quad & f(x) + g(y) \\ \text{s.t.} \quad & Ax + By = c, \end{aligned} \tag{Л11.6}$$

где $A \in \mathbb{R}^{n \times d_x}$, $B \in \mathbb{R}^{n \times d_y}$, $c \in \mathbb{R}^n$. Из практики мы знаем, что регуляризация часто делает задачу более стабильной, давайте добавим такую регуляризацию, что наша исходная задача не изменится. Тогда мы получим аугментированную задачу:

$$\begin{aligned} \min_{\substack{x \in \mathbb{R}^{d_x} \\ y \in \mathbb{R}^{d_y}}} \quad & f(x) + g(y) + \frac{\rho}{2} \|Ax + By - c\|_2^2 \\ \text{s.t.} \quad & Ax + By = c. \end{aligned}$$

Запишем лагранжиан аугментированной задачи:

$$\mathcal{L}_\rho(x, y, \lambda) = f(x) + g(y) + \lambda^\top (Ax + By - c) + \frac{\rho}{2} \|Ax + By - c\|_2^2.$$

Как мы уже знаем, мы хотим минимизировать лагранжиан по прямым переменным и минимизировать по двойственным. Давайте по прямым делать явную минимизацию, а по двойственным градиентный подъем. Полученный метод называется *метод альтернативных направлений*, он же Alternating Direction Method of Multipliers (ADMM):

Алгоритм Л11.1 ADMM

Вход: стартовые точки $y^0 \in \mathbb{R}^{d_y}$, $\lambda^0 \in \mathbb{R}^n$, параметр $\rho \in \mathbb{R}$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^{d_x}} \mathcal{L}_\rho(x, y^k, \lambda^k)$ 
3:    $y^{k+1} = \operatorname{argmin}_{y \in \mathbb{R}^{d_y}} \mathcal{L}_\rho(x^{k+1}, y, \lambda^k)$ 
4:    $\lambda^{k+1} = \lambda^k + \rho(Ax^{k+1} + By^{k+1} - c)$ 
5: end for
```

Выход: $\frac{1}{K} \sum_{k=1}^K x^k$, $\frac{1}{K} \sum_{k=1}^K y^k$, $\frac{1}{K} \sum_{k=1}^K \lambda^k$

Поясним смысл названия ADMM:

- Alternating Direction: минимизация по x и y происходит не одновременно, а последовательно, одна за другой.
- Multipliers: наличие двойственных множителей Лагранжа λ .

Замечание Л11.6. В доказательстве сходимости будем использовать версию алгоритма с другим порядком обновления точек:

$$y^{k+1} = \operatorname{argmin}_{y \in \mathbb{R}^{d_y}} \mathcal{L}_\rho(x^k, y, \lambda^k) \tag{Л11.7}$$

$$\lambda^{k+1} = \lambda^k + \rho(Ax^k + By^{k+1} - c) \tag{Л11.8}$$

$$x^{k+1} = \operatorname{argmin}_{x \in \mathbb{R}^{d_x}} \mathcal{L}_\rho(x, y^{k+1}, \lambda^{k+1}). \tag{Л11.9}$$

Теорема Л11.1. Пусть задача оптимизации (Л11.6) с выпуклыми и дружественными с точки зрения вычислений $\arg\min$ функциями f и g решается с помощью ADMM (Алгоритм Л11.1 с обновлением (Л11.7)–(Л11.9)). Тогда справедлива следующая оценка сходимости:

$$\mathcal{L}_0\left(\frac{1}{K}\sum_{k=1}^K x^k, \frac{1}{K}\sum_{k=1}^K y^k, \lambda^*\right) - \mathcal{L}_0\left(x^*, y^*, \frac{1}{K}\sum_{k=1}^K \lambda^k\right) \leq \frac{1}{2K}\|z^* - z^0\|_P^2,$$

где $\mathcal{L}_0$ — Лагранжиан без аугментации и

$$P = \begin{pmatrix} \rho A^\top A & 0 & A^\top \\ 0 & 0 & 0 \\ A & 0 & \frac{1}{\rho} I_n \end{pmatrix}, \quad z^* = \begin{pmatrix} x^* \\ y^* \\ \lambda^* \end{pmatrix}, \quad z^0 = \begin{pmatrix} x^0 \\ y^0 \\ \lambda^0 \end{pmatrix}.$$

Замечание Л11.7. Определение P -нормы приводилось в Параграфе Л6 (Определение Л6.2).

Доказательство. Запишем условие оптимальности для уравнения (Л11.7):

$$\nabla g(y^{k+1}) + B^\top \lambda^k + \rho B^\top (Ax^k + By^{k+1} - c) = 0. \quad (\text{Л11.10})$$

Формула (Л11.8) обновления λ^{k+1} :

$$\lambda^{k+1} - \lambda^k = \rho(Ax^k + By^{k+1} - c). \quad (\text{Л11.11})$$

Условие оптимальности для уравнения (Л11.9):

$$\nabla f(x^{k+1}) + A^\top \lambda^{k+1} + \rho A^\top (Ax^{k+1} + By^{k+1} - c) = 0. \quad (\text{Л11.12})$$

Используя равенства (Л11.10), (Л11.11) и (Л11.12), выразим градиент $\mathcal{L}_0$ в точке $z^{k+1} = (x^{k+1}, y^{k+1}, \lambda^{k+1})^\top$. Для удобства и единообразия записи, градиент по λ будем брать со знаком минус:

$$\begin{aligned} \nabla \mathcal{L}_0(z^{k+1}) &= \begin{pmatrix} \nabla_x \mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda^{k+1}) \\ \nabla_y \mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda^{k+1}) \\ -\nabla_\lambda \mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda^{k+1}) \end{pmatrix} = \begin{pmatrix} \nabla f(x^{k+1}) + A^\top \lambda^{k+1} \\ \nabla g(y^{k+1}) + B^\top \lambda^{k+1} \\ -(Ax^{k+1} + By^{k+1} - c) \end{pmatrix} \\ &= -\begin{pmatrix} \rho A^\top (Ax^{k+1} + By^{k+1} - c) \\ -B^\top (\lambda^{k+1} - \lambda^k) + \rho B^\top (Ax^k + By^{k+1} - c) \\ \frac{1}{\rho} (\lambda^{k+1} - \lambda^k) + A(x^{k+1} - x^k) \end{pmatrix}. \end{aligned}$$

Воспользуемся уравнением (Л11.11):

$$\nabla \mathcal{L}_0(z^{k+1}) = -\begin{pmatrix} A^\top (\lambda^{k+1} - \lambda^k) + \rho A^\top A(x^{k+1} - x^k) \\ 0 \\ \frac{1}{\rho} (\lambda^{k+1} - \lambda^k) + A(x^{k+1} - x^k) \end{pmatrix}.$$

Обозначим

$$P = \begin{pmatrix} \rho A^\top A & 0 & A^\top \\ 0 & 0 & 0 \\ A & 0 & \frac{1}{\rho} I_n \end{pmatrix}.$$

Заметим, что матрица симметричная и положительно полуопределённая. Запишем:

$$\nabla \mathcal{L}_0(z^{k+1}) = -P \begin{pmatrix} x^{k+1} - x^k \\ y^{k+1} - y^k \\ \lambda^{k+1} - \lambda^k \end{pmatrix} = -P(z^{k+1} - z^k).$$

Тогда, переписывая в терминах P -нормы $\|z\|_P = \langle z, Pz \rangle$ (Определение Л6.2), получаем:

$$\begin{aligned} \langle \nabla \mathcal{L}_0(z^{k+1}), z^{k+1} - z \rangle &= -\langle P(z^{k+1} - z^k), z^{k+1} - z \rangle \\ &= \frac{1}{2} (\|z^k - z\|_P^2 - \|z^{k+1} - z\|_P^2 - \|z^{k+1} - z^k\|_P^2) \\ &\leq \frac{1}{2} (\|z^k - z\|_P^2 - \|z^{k+1} - z\|_P^2). \end{aligned}$$

Суммируем по всем k от 0 до $K-1$, усредняем и сворачиваем телескопическую сумму справа:

$$\frac{1}{K} \sum_{k=0}^{K-1} \langle \nabla \mathcal{L}_0(z^{k+1}), z^{k+1} - z \rangle \leq \frac{1}{2K} (\|z^0 - z\|_P^2 - \|z^K - z\|_P^2) \leq \frac{\|z^0 - z\|_P^2}{2K}. \quad (\text{Л11.13})$$

Воспользуемся тем, что $\mathcal{L}_0$ выпукла по (x, y) и вогнута по λ . Тогда для любого $z = (x, y, \lambda)$ и каждого k верно

$$\mathcal{L}_0(x^{k+1}, y^{k+1}, \lambda) - \mathcal{L}_0(x, y, \lambda^{k+1}) \leq \langle \nabla \mathcal{L}_0(z^{k+1}), z^{k+1} - z \rangle. \quad (\text{Л11.14})$$

Применим неравенство Йенсена (0.1) к выпуклой и вогнутой частям, получим:

$$\mathcal{L}_0\left(\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K y^k, \lambda\right) - \mathcal{L}_0\left(x, y, \frac{1}{K} \sum_{k=1}^K \lambda^k\right) \leq \frac{1}{K} \sum_{k=1}^K (\mathcal{L}_0(z^k) - \mathcal{L}_0(z)).$$

Совмещаем с оценкой через скалярное произведение (Неравенство (Л11.14)):

$$\mathcal{L}_0\left(\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K y^k, \lambda\right) - \mathcal{L}_0\left(x, y, \frac{1}{K} \sum_{k=1}^K \lambda^k\right) \leq \frac{1}{K} \sum_{k=1}^K \langle \nabla \mathcal{L}_0(z^k), z^k - z \rangle.$$

Остается подставить более раннюю оценку (Л11.13):

$$\mathcal{L}_0\left(\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K y^k, \lambda\right) - \mathcal{L}_0\left(x, y, \frac{1}{K} \sum_{k=1}^K \lambda^k\right) \leq \frac{\|z^0 - z\|_P^2}{2K}.$$

Возьмём $x = x^*$, $y = y^*$, $\lambda = \lambda^*$:

$$\mathcal{L}_0\left(\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K y^k, \lambda^*\right) - \mathcal{L}_0\left(x^*, y^*, \frac{1}{K} \sum_{k=1}^K \lambda^k\right) \leq \frac{\|z^0 - z^*\|_P^2}{2K}.$$

■

ADMM является одним из ключевых и популярных методов оптимизации. Реализован во многих солверах и часто используется как метод по умолчанию. Нестандартная формулировка самой задачи, для которой придуман ADMM, оказывается, выбирает в себя много важных частных случаев. «Непривычная» переменная y часто играет роль вспомогательной переменной. Разберем несколько прикладных примеров.

Пример Л11.1. В линейной регрессии мы ищем коэффициенты $x \in \mathbb{R}^d$, которые моделируют целевой вектор $b \in \mathbb{R}^n$ по матрице признаков $A \in \mathbb{R}^{n \times d}$. Обычный метод наименьших квадратов минимизирует квадрат ошибки $\frac{1}{2} \|Ax - b\|_2^2$. Однако во многих задачах признаков часто больше, чем наблюдений ($d > n$). В этом режиме метод наименьших квадратов сильно переобучается. Чтобы предотвратить переобучение и выполнить автоматический отбор признаков (занулить часть весов), мы хотим получить модель с высокой степенью разреженности коэффициентов. Для получения разреженности мы добавляем к функции потерь ℓ_1 -регуляризацию. Эта формулировка называется *Lasso*:

$$\min_{x \in \mathbb{R}^d} \frac{1}{2} \|Ax - b\|_2^2 + \tau \|x\|_1,$$

где $\tau > 0$ определяет степень разреженности. Однако, в этой задаче нет двух переменных и ограничений, которые нужны для применения ADMM. Добавим их искусственно — введем вспомогательную переменную $y \in \mathbb{R}^d$, которая будет отвечать за негладкий ℓ_1 -штраф, а чтобы не изменить оригинальную задачу, добавим ограничение на равенство x и y :

$$\begin{aligned} \min_{x, y \in \mathbb{R}^d} \quad & \frac{1}{2} \|Ax - b\|_2^2 + \tau \|y\|_1 \\ \text{s.t.} \quad & x = y. \end{aligned}$$

К этой задаче ADMM уже применим. Чтобы его записать, выпишем лагранжиан аугментированной задачи:

$$\mathcal{L}_\rho(x, y, \lambda) = \frac{1}{2} \|Ax - b\|_2^2 + \tau \|y\|_1 + \frac{\rho}{2} \|x - y + \lambda\|_2^2.$$

Получим итерации ADMM:

- **Обновление x .** Мы фиксируем y и λ и минимизируем $\mathcal{L}_\rho$ по x :

$$\min_{x \in \mathbb{R}^d} \frac{1}{2} \|Ax - b\|_2^2 + \frac{\rho}{2} \|x - y^k + \lambda^k\|_2^2.$$

Это безусловная сильно выпуклая квадратичная задача. Возьмем градиент по x и приравняем к нулю:

$$\nabla_x = A^\top (Ax - b) + \rho(x - y^k + \lambda^k) = 0.$$

Раскроем скобки и сгруппируем члены с x :

$$A^\top Ax + \rho I_d x = A^\top b + \rho(y^k - \lambda^k).$$

В итоге мы решаем систему линейных уравнений:

$$(A^\top A + \rho I_d)x^{k+1} = A^\top b + \rho(y^k - \lambda^k).$$

- **Обновление y .** Фиксируя x и λ , минимизируем по y :

$$\min_{y \in \mathbb{R}^d} \tau \|y\|_1 + \frac{\rho}{2} \|x^{k+1} - y + \lambda^k\|_2^2.$$

Поскольку $\|\cdot\|_1$ и $\|\cdot\|_2^2$ можно разложить по компонентам вектора, задача решается независимо для каждого элемента y_i . Так как функция недифференцируема, мы используем субградиент:

$$0 \in \tau \partial |y_i| - \rho(x_i^{k+1} - y_i + \lambda_i^k).$$

Аналитическим решением этого уравнения будет:

$$y^{k+1} = \text{sign}(x^{k+1} + \lambda^k) \max \left\{ |x^{k+1} + \lambda^k| - \frac{\tau}{\rho}, 0 \right\}.$$

Этот шаг принудительно зануляет коэффициенты.

- **Обновление λ .** Обновление λ — градиентный подъем:

$$\lambda^{k+1} = \lambda^k + \rho(x^{k+1} - y^{k+1}).$$

Пример Л11.2. Восстановление матриц — это задача заполнения пропущенных пикселей. Пусть M — истинное изображение, но мы наблюдаем лишь часть пикселей — Ω . Определим оператор проекции $\mathcal{P}_\Omega(X)$, который оставляет пиксели из Ω без изменений, а остальные зануляет. Тогда наша задача найти такое изображение X , что $\mathcal{P}_\Omega(X) = \mathcal{P}_\Omega(M)$. Однако, эта задача имеет огромное количество решений, которые не будут похожи на реальные изображения. Естественные изображения сильно структурированы, а значит, такую матрицу можно хорошо приблизить матрицей малого ранга. Поиск матрицы минимального ранга это комбинаторная задача. Поэтому мы используем ядерную норму $\|X\|_*$ (сумму сингулярных чисел матрицы), которая является выпуклой релаксацией функции ранга.

$$\begin{aligned} \min_{X \in \mathbb{R}^{n \times d}} \quad & \|X\|_* \\ \text{s.t.} \quad & \mathcal{P}_\Omega(X) = \mathcal{P}_\Omega(M). \end{aligned}$$

Данная задача также не подходит для ADMM, её нужно переформулировать. Перенесем жёсткое ограничение на данные в функцию-индикатор $I_\Omega(X)$, которая равна 0, если известная часть данных совпадает с M , и $+\infty$ в противном случае, и введём вспомогательную переменную Y , которая будет отвечать за выполнение этого ограничения:

$$\begin{aligned} \min_{X, Y \in \mathbb{R}^{n \times d}} \quad & \|X\|_* + I_\Omega(Y) \\ \text{s.t.} \quad & X = Y. \end{aligned}$$

Выпишем лагранжиан аугментированной задачи:

$$\mathcal{L}_\rho(X, Y, \Lambda) = \|X\|_* + I_\Omega(Y) + \frac{\rho}{2} \|X - Y + \Lambda\|_F^2.$$

Теперь мы готовы получить итерации ADMM:

- **Обновление X .** Для этого нам нужно решить следующую задачу:

$$\min_{X \in \mathbb{R}^{n \times d}} \|X\|_* + \frac{\rho}{2} \|X - Y^k + \Lambda^k\|_F^2.$$

Найдем сингулярное разложение матрицы сдвига. Пусть $Y^k - \Lambda^k = U\Sigma V^\top$. Аналитическим решением является:

$$X^{k+1} = U \text{sign}(\Sigma) \max \left\{ |\Sigma| - \frac{1}{\rho}, 0 \right\} V^\top.$$

- **Обновление Y .** Для этого нам нужно решить следующую задачу:

$$\min_{Y \in \mathbb{R}^{n \times d}} I_{\Omega}(Y) + \frac{\rho}{2} \|X^{k+1} - Y + \Lambda^k\|_F^2.$$

Здесь мы ищем матрицу Y , максимально близкую к $V = X^{k+1} + \Lambda^k$ в смысле евклидова расстояния, но при этом строго удовлетворяющую индикатору I_{Ω} . Это поточечная проекция: пиксели из Ω обязаны быть равны изначальным данным, а пиксели не из Ω индикатор не ограничивает, поэтому они просто принимают значения из V :

$$Y_{i,j}^{k+1} = \begin{cases} M_{i,j} & (i, j) \in \Omega; \\ X_{i,j}^{k+1} + \Lambda_{i,j}^k & (i, j) \notin \Omega. \end{cases}$$

- **Обновление Λ .**

$$\Lambda^{k+1} = \Lambda^k + \rho(X^{k+1} - Y^{k+1}).$$

Пример Л11.3. Современные нейронные сети имеют миллиарды параметров, каждый из которых описывается числом с плавающей точкой. Например, если модель имеет 32 миллиарда параметров и хранит веса в формате fp32 (32 бита на параметр), то для её хранения потребуется 128 гигабайт, что довольно много. Для уменьшения веса модели часто используется процедура квантизации, при которой 32-битные числа с плавающей точкой переводятся в более низкую разрядность (например, бинарные веса $\{-1, 1\}$ или 8-битные целые числа). Разберемся, как обучать такие модели. Пусть $\mathcal{Q}$ набор разрешённых дискретных значений. Тогда задачу обучения квантизированной модели можно записать как следующую задачу оптимизации:

$$\begin{aligned} \min_{X \in \mathbb{R}^{n \times d}} \quad & f(X) \\ \text{s.t.} \quad & X_i \in \mathcal{Q}, \quad i = \overline{1, n}. \end{aligned}$$

Поскольку множество $\mathcal{Q}$ дискретно, то решать данную задачу градиентными методами не получится. Однако при использовании ADMM мы можем обучать веса X непрерывным образом, а дискретизацию перенести на переменную Y . Воспользуемся уже разобранным способом свести задачу к виду, пригодному для ADMM:

$$\begin{aligned} \min_{X, Y \in \mathbb{R}^{n \times d}} \quad & f(X) + I_{\mathcal{Q}}(Y) \\ \text{s.t.} \quad & X = Y. \end{aligned}$$

Выпишем лагранжиан аугментированной задачи:

$$\mathcal{L}_{\rho}(X, Y, \Lambda) = f(X) + I_{\mathcal{Q}}(Y) + \frac{\rho}{2} \|X - Y + \Lambda\|_F^2$$

И получим итерации ADMM:

- **Обновление X .**

$$\min_{X \in \mathbb{R}^{n \times d}} f(X) + \frac{\rho}{2} \|X - Y^k + \Lambda^k\|_F^2.$$

Если раньше мы могли решить эту задачу аналитически, то сейчас $f(X)$ это сложная функция, поэтому мы будем делать несколько шагов любым методом оптимизации вместо точного решения. Важно, что в этом случае пропадают теоретические гарантии сходимости.

- **Обновление Y .**

$$\min_{Y \in \mathbb{R}^{n \times d}} I_Q(Y) + \frac{\rho}{2} \|X^{k+1} - Y + \Lambda^k\|_F^2.$$

Нужно найти Y , элементы которого принадлежат строго Q , чтобы он был максимально близок к $V = X^{k+1} + \Lambda^k$. Это решается поэлементным округлением. Например, для бинарной сети $Q = \{-1, +1\}$ обновление имеет строгий аналитический вид:

$$Y^{k+1} = \text{sign}(V).$$

Для 8-битной квантизации мы просто округляем элементы V до ближайшего разрешённого значения.

- **Обновление Λ .**

$$\Lambda^{k+1} = \Lambda^k + \rho(X^{k+1} - Y^{k+1}).$$

Как можно было заметить в примерах, ADMM часто используется в похожих задачах по похожим принципам. Разберем основные паттерны его применения:

1. **Гладкая + Негладкая функции.** Используется в задачах минимизации хорошей функции $f(x)$ с негладким штрафом $g(x)$ (ℓ_1 -норма, ядерная норма). Этот паттерн соответствует следующей форме ADMM:

$$\begin{aligned} \min_{x, y \in \mathbb{R}^d} \quad & f(x) + g(y) \\ \text{s.t.} \quad & x = y. \end{aligned}$$

Данный паттерн хорошо работает, поскольку гладкая функция уходит в x -шаг (обычно линейная система), а негладкая уходит в y -шаг, который превращается в проксимальный оператор от $g(\cdot)$ (часто имеющий красивое точное решение, вроде мягкого порога).

2. **Непрерывная функция + Жесткое ограничение.** Используется в задачах минимизации функции $f(x)$ внутри строго ограниченного (или дискретного) множества C . ADMM для данного паттерна выглядит следующим образом:

$$\begin{aligned} \min_{x, y \in \mathbb{R}^d} \quad & f(x) + I_C(y) \\ \text{s.t.} \quad & x = y. \end{aligned}$$

Данный паттерн хорошо работает, поскольку обновление x происходит без оглядки на границы, а y становится чистой евклидовой проекцией на множество C (например, округление).

3. **«Запутанный оператор».** Применяется в задачах вида $\min_x f(x) + g(Kx)$, где матрица K «перепутывает» переменные, из-за чего g нельзя вычислить поэлементно. В данном случае ADMM применяется в следующем виде:

$$\begin{aligned} \min_{x, y} \quad & f(x) + g(y) \\ \text{s.t.} \quad & Kx = y. \end{aligned}$$

Это хорошо работает, поскольку в шаге обновления y переменные развязаны, что позволяет использовать поэлементные операции.

4. **Распределённые вычисления.** Пусть в задаче обучения данные распределены на N машинах и нужно обучить общую модель: $\min_x \sum_{i=1}^N f_i(x)$. Наивное решение данной задачи приводит к тому, что на каждой итерации машины должны усреднять локально посчитанные градиенты. Однако, можно применить ADMM: узлу i даем локальную копию x_i , и заставляем всех согласиться с центральным сервером y :

$$\begin{aligned} \min_{x_i \in \mathbb{R}^d} \quad & \sum_{i=1}^N f_i(x_i) \\ \text{s.t.} \quad & x_i = y, \quad i = \overline{1, N}. \end{aligned}$$

Такой подход позволяет шагам по x_i вычисляться на узлах параллельно и абсолютно независимо. В то время как шаг по y на центральном сервере просто усредняет присланные локальные модели.

Отметим, что несмотря на то, что эти паттерны являются популярными, применение ADMM не ограничивается только ими, и полезно уметь видеть ADMM.

Поскольку ADMM является крайне практическим алгоритмом, приведем несколько советов по его использованию:

1. Скорость работы ADMM завязана на то, что внутренние задачи для всех переменных решаются аналитически. Если задачи не имеют аналитического решения, то их можно решать численно (например, методами второго порядка для более быстрого нахождения минимума). Однако применение итеративных методов для внутренних задач существенно увеличивает время работы ADMM. Практичным решением в случае отсутствия аналитического решения у внутренних задач является использование нескольких итераций метода оптимизации. В этом случае теряются теоретические гарантии сходимости, но на практике такой вариант зачастую работает.
2. Часто в итерациях ADMM требуется решение системы линейных уравнений вида:

$$(A^\top A + \rho I_d)x = c.$$

Наивное решение на каждой итерации стоит $\mathcal{O}(n^3)$ операций. Однако матрица $(A^\top A + \rho I_d)$ не меняется между итерациями, что позволяет вычислить разложение Холецкого матрицы ровно один раз до начала цикла ADMM и кэшировать его. Внутри цикла поиск x будет иметь сложность $\mathcal{O}(n^2)$.

3. Параметр ρ отвечает за силу штрафа за неудовлетворение условий. Если он слишком мал, переменные будут сходиться вечно. Если он слишком большой — они «слипнутся» сразу, замедлив поиск минимума. Важным моментом является то, что при изменении ρ нужно пересчитать закэшированные значения, зависящие от этого параметра.
4. На практике ADMM быстро сходится до низкой точности, после чего долго «ползет» до высокой. Поэтому не следует использовать ADMM там, где нужна хирургическая точность на уровне машинного нуля (там лучше методы внутренней точки). В задачах, где вас устраивает более грубое решение, ADMM является хорошим выбором.

Л12 Метод внутренней точки

Рассмотрим задачу с ограничениями:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = \overline{1, n}. \end{aligned} \quad (\text{Л12.1})$$

Перейдём к задаче со штрафом:

$$\min_{x \in \mathbb{R}^d} \left[f_\rho(x) = f(x) + \rho \cdot \frac{1}{2} \sum_{i=1}^n (g_i^+(x))^2 \right],$$

где $y^+ = \max\{y, 0\}$.

Решение такой задачи может не удовлетворять ограничениям. Поэтому, если мы хотим всегда получать допустимое решение, то нужно ввести штраф определенным образом. В качестве базового решения рассмотрим барьер:

$$\min_{x \in \mathbb{R}^d} \left[F_\rho(x) = f(x) + \frac{1}{\rho} \cdot \mathbb{I}_G(x) \right],$$

где $\mathbb{I}_G(x)$ — индикаторная функция множества $G = \{x \in \mathbb{R}^d \mid g_i(x) \leq 0, i = \overline{1, n}\}$:

$$\mathbb{I}_G(x) = \begin{cases} 0, & x \in G \\ +\infty, & x \notin G \end{cases}.$$

Задача не стала легче с вычислительной точки зрения, а барьер разрывный и недифференцируемый. Идея — воспроизвести поведение индикатора плавно и непрерывно.

Л12.1 Барьерные функции

Будем считать, что внутренность G непуста и что замыкание внутренности G равно самому G , а также, что выполнено условие Слейтера (Утверждение С7.3) для задачи (Л12.1).

Определение Л12.1. Барьером будем называть функцию $B : \text{int } G \rightarrow \mathbb{R}$, удовлетворяющую следующим предположениям:

- B непрерывно дифференцируема на $\text{int } G$;
- Для любой последовательности $\{x_i\} \subset \text{int } G$, сходящейся к $x \in \partial G$ (границе множества G), выполнено $B(x_i) \rightarrow +\infty$.

Приведем несколько примеров барьерных функций.

Пример Л12.1.

- Барьер Кэррола:

$$B(x) = - \sum_{i=1}^n \frac{1}{g_i(x)}.$$

- Логарифмический барьер:

$$B(x) = - \sum_{i=1}^n \log(-g_i(x)).$$

Таким образом, имеем гладкую функцию, уходящую в бесконечность на границе множества. Поскольку мы хотим аналогию индикатора, а он равен нулю на $\text{int } G$, то при постановке задачи будем рассматривать $\frac{1}{\rho} B(x)$, где при $\rho \rightarrow +\infty$ получаем требуемое. Далее в этом параграфе будем использовать обозначение для суммы целевой функции и барьера:

$$F_\rho(x) = f(x) + \frac{1}{\rho} B(x).$$

Замечание Л12.1. Поясним, почему тот факт, что $F_\rho(x)$ определена только на $\text{int } G$, не создает проблем. Рассмотрим некоторую начальную точку $x^0 \in \text{int } G$. Пусть мы можем гарантировать, что метод минимизации выдает такие точки x^k , что $F_\rho(x^k) \leq F_\rho(x^0)$. Тогда, поскольку $F_\rho \rightarrow +\infty$ при приближении к ∂G , x^k будут оставаться во внутренней допустимой области. Ниже приведем более формальное рассуждение.

Утверждение Л12.1. Пусть G — ограниченное множество, тогда для любого $\rho > 0$ функция $F_\rho(x)$ достигает минимума на $\text{int } G$. Более того, множества вида:

$$U = \{x \in \text{int } G \mid F_\rho(x) \leq a\}$$

являются компактными для любого $a \in \mathbb{R}$.

Доказательство. Начнём со второй части утверждения. Все множества лежат в конечномерном $\mathbb{R}^d$, поэтому компакт — это ограниченное и замкнутое множество. Рассмотрим последовательность $\{x_i\} \subset U$, сходящуюся к x . Пусть $x \in \partial G$. Тогда

$$F_\rho(x_i) \rightarrow F_\rho(x) = +\infty,$$

что невозможно, так как $F_\rho(x_i) \leq a$. Значит, $x \in \text{int } G$.

На $\text{int } G$ функция непрерывна, откуда при переходе к пределу следует:

$$F_\rho(x_i) \rightarrow F_\rho(x) \leq a.$$

$U \subset G$ ограничено, поскольку G ограничено. Таким образом, U — компакт.

Теперь покажем первую часть утверждения. Возьмём число $a \in \mathbb{R}^d$, для которого множество U непусто. Тогда из сказанного выше имеем функцию F_ρ , непрерывную на компакте $U \neq \emptyset$. По теореме Вейерштрасса она достигает на нём минимума. По определению U , он будет и минимумом на $\text{int } G$. ■

Смысл этого утверждения заключается в том, что решая задачу с барьером, мы всегда будем сходиться к внутренней точке множества G . Таким образом, мы будем строго выполнять все ограничения. Чтобы понять, насколько будет отличаться решение задачи с барьером и исходной задачи, сформулируем следующее утверждение.

Утверждение Л12.2. Пусть G — ограниченное множество, тогда для любого $\epsilon > 0$ существует $\rho(\epsilon) > 0$ такое, что множество решений барьерной задачи X_ρ^* для любого $\rho \geq \rho(\epsilon)$ содержится в

$$X_\epsilon^* = \{x \in G \mid \exists x^* \in X^* : \|x - x^*\|_2 \leq \epsilon\},$$

где X^* — множество решений исходной задачи.

Доказательство. Будем доказывать от противного. Пусть существует некоторое $\epsilon > 0$ и последовательность $\{\rho_i\} \rightarrow +\infty$ такие, что $X_{\rho_i}^*$ не содержится в X_ϵ^* . То есть для всех $i \in \mathbb{N}$ существуют точки

$$x_i^* \in X_{\rho_i}^* \setminus X_\epsilon^* \subset G.$$

Так как G ограничено, то последовательность $\{x_i^*\} \subset G$ ограничена. Пользуясь теоремой Больцано–Вейерштрасса, выделим сходящуюся подпоследовательность:

$$\tilde{x}_i^* \rightarrow \tilde{x}^*.$$

Согласно Утверждению Л12.1:

$$x_i^* \in \text{int } G,$$

а так как G — замыкание $\text{int } G$, то $\tilde{x}^* \in G$. При этом $\tilde{x}^*$ не лежит в X^* , иначе, начиная с некоторого i , $\tilde{x}_i^*$ попадали бы в X_ϵ^* . То есть существует $\delta > 0$ такое, что:

$$f(\tilde{x}^*) > f(x^*) + \delta.$$

С другой стороны, так как G — замыкание $\text{int } G$, а f непрерывна на G , то можно найти такую точку $\tilde{x} \in \text{int } G$, что:

$$f(\tilde{x}) \leq f(x^*) + \frac{\delta}{2}.$$

Тогда по определению $\tilde{x}_i^*$:

$$f(\tilde{x}_i^*) + \frac{1}{\rho_i} B(\tilde{x}_i^*) = F_{\rho_i}(\tilde{x}_i^*) = \min_{x_i \in \text{int } G} F_{\rho_i}(x_i) \leq F_{\rho_i}(\tilde{x}) = f(\tilde{x}) + \frac{1}{\rho_i} B(\tilde{x}).$$

Нетрудно видеть, что:

$$B(x) \geq \min_{x' \in \text{int } G} B(x') = B^* > -\infty$$

для всех $x \in \text{int } G$, поэтому имеем:

$$f(\tilde{x}_i^*) \leq f(\tilde{x}) + \frac{1}{\rho_i} B(\tilde{x}) - \frac{1}{\rho_i} B^*.$$

Переходя к пределу при $\rho_i \rightarrow \infty$ в неравенстве, получаем:

$$f(\tilde{x}^*) \leq f(\tilde{x}).$$

Но по определению $\tilde{x}$ и δ :

$$f(\tilde{x}^*) > f(x^*) + \delta > f(x^*) + \frac{\delta}{2} \geq f(\tilde{x}).$$

Пришли к противоречию. ■

Замечание Л12.2. Увеличение ρ помогает лучше аппроксимировать поведение честной индикаторной функции, а значит, приближает нас к исходной задаче. На практике, как и для штрафов, выбираем какое-то ρ и пытаемся решить задачу с барьером. Далее можно пробовать увеличивать ρ .

Замечание Л12.3. Так как в процессе оптимизации мы не покидаем G , то можно сказать, что мы всегда «внутри». Поэтому метод, решающий задачу с барьером, называется *метод внутренней точки*.

Л12.2 Самосогласованные барьеры

Определение Л12.2. Выпуклая трижды непрерывно дифференцируемая на $\text{int } G$ функция $f : G \rightarrow \mathbb{R}$ называется *самосогласованной*, если для любых $x \in \text{int } G$ и $h \in \mathbb{R}^d$ выполнено:

$$\left| \frac{d^3}{dt^3} f(x + th) \right| \leq 2[\langle h, \nabla^2 f(x) h \rangle]^{\frac{3}{2}}.$$

Приведем некоторые базовые примеры самосогласованных функций.

Пример Л12.2.

- Квадратичная функция с $A \in \mathbb{S}_+^d$ на $\mathbb{R}^d$:

$$f(x) = \frac{1}{2} \langle x, Ax \rangle + \langle b, x \rangle + c.$$

- Отрицательный логарифм на $\mathbb{R}_+$:

$$f(x) = -\log(x).$$

- Отрицательный логарифм квадратичной функции $g(x) = \frac{1}{2} \langle x, Ax \rangle + \langle b, x \rangle + c$ с $A \in \mathbb{S}_+^d$ на $G = \{x \in \mathbb{R}^d \mid g(x) < 0\}$:

$$f(x) = -\log(-g(x)).$$

Некоторые базовые свойства:

- Линейная комбинация двух самосогласованных функций $B_1 : \text{int } G_1 \rightarrow \mathbb{R}$ и $B_2 : \text{int } G_2 \rightarrow \mathbb{R}$ с коэффициентами $\alpha_1, \alpha_2 \geq 1$ на $\text{int } G_1 \cap \text{int } G_2$ является самосогласованной функцией:

$$f(x) = \alpha_1 B_1(x) + \alpha_2 B_2(x).$$

- Композиция самосогласованной функции $f : \text{int } G \rightarrow \mathbb{R}$ и аффинного преобразования аргумента $Ax + b$ на $\text{int } \tilde{G} = \{x \mid Ax + b \in \text{int } G\}$ является самосогласованной функцией:

$$\tilde{f}(x) = f(Ax + b).$$

Определение Л12.3. Функция $B : \text{int } G \rightarrow \mathbb{R}$ является ν -самосогласованным барьером ($\nu \geq 1$) на множестве $\text{int } G$, если:

- B — самосогласованна на $\text{int } G$;
- Для любой последовательности $\{x_i\} \subset \text{int } G$, сходящейся к $x \in \partial G$ (границе множества G), выполнено $B(x_i) \rightarrow +\infty$.
- Для любых $x \in \text{int } G$ и $h \in \mathbb{R}^d$ выполнено условие:

$$|\langle h, \nabla B(x) \rangle| \leq \sqrt{\nu} \sqrt{\langle h, \nabla^2 B(x) h \rangle}.$$

Базовые свойства ν -самосогласованных барьеров похожи на свойства самосогласованных функций:

- Линейная комбинация ν_i -самосогласованных барьеров $B_i : \text{int } G_i \rightarrow \mathbb{R}$ с коэффициентами $\alpha_i \geq 1$ на $\cap \text{int } G_i$ является $\sum_{i=1}^n \alpha_i \nu_i$ -самосогласованным барьером:

$$B(x) = \sum_{i=1}^n \alpha_i B_i(x).$$

- Композиция ν -самосогласованного барьера $B : \text{int } G \rightarrow \mathbb{R}$ и аффинного преобразования аргумента $Ax + b$ на $\text{int } \tilde{G} = \{x \mid Ax + b \in \text{int } G\}$ является ν -самосогласованным барьером:

$$\tilde{B}(x) = B(Ax + b).$$

Пример Л12.3. Для множества $\mathbb{R}_+$ можно выбрать 1-самосогласованный барьер

$$B(x) = -\log(x).$$

Расширим этот пример на множество

$$G = \text{cl} \left\{ x \in \mathbb{R}^d \mid g_i(x) < 0, i = \overline{1, n} \right\},$$

где g_i — выпуклые функции, удовлетворяющие условию Слейтера. Предложим n -самосогласованный барьер

$$B(x) = -\sum_{i=1}^n \log(-g_i(x)).$$

Пример Л12.4. Для конуса

$$K_+^d = \left\{ (t, x) \in \mathbb{R} \times \mathbb{R}^d \mid t \geq \|x\| \right\}$$

подойдет 2-самосогласованный барьер

$$B(t, x) = -\log(t^2 - \langle x, x \rangle).$$

Пример Л12.5. Для конуса симметричных положительно полуопределенных матриц $\mathbb{S}_+^d$ подойдет d -самосогласованный барьер

$$B(X) = -\log \det(X).$$

Попробуем понять, что можно получить из локальных характеристик самосогласованного барьера.

Утверждение Л12.3. Пусть B — ν -самосогласованный барьер. Тогда для любых $x, y \in \text{dom } B$ выполнено неравенство

$$\langle \nabla B(x), y - x \rangle < \nu. \quad (\text{Л12.2})$$

Если дополнительно известно, что это скалярное произведение неотрицательно, то

$$\langle \nabla B(y) - \nabla B(x), y - x \rangle \geq \frac{\langle \nabla B(x), y - x \rangle^2}{\nu - \langle \nabla B(x), y - x \rangle}. \quad (\text{Л12.3})$$

Доказательство. Рассмотрим функцию

$$\phi(t) = \langle \nabla B(x + t(y - x)), y - x \rangle,$$

где $t \in [0, 1]$. Сконцентрируемся на случае $\phi(0) > 0$, так как иначе требуемые утверждения тривиальны. Пользуясь определением самосогласованного барьера, запишем

$$\phi'(t) = \langle \nabla^2 B(x + t(y - x))(y - x), y - x \rangle \geq \frac{1}{\nu} \langle \nabla B(x + t(y - x)), y - x \rangle^2 = \frac{1}{\nu} \phi^2(t).$$

То есть при указанных t введенная нами функция положительна и возрастает. Кроме того, из неравенства выше следует:

$$\frac{d\phi(t)}{\phi^2(t)} \geq \frac{dt}{\nu}.$$

Интегрируя от 0 до 1, имеем:

$$-\frac{1}{\phi(1)} + \frac{1}{\phi(0)} \geq \frac{1}{\nu}.$$

Так как ϕ не убывает, то $\phi(1) > 0$, поскольку рассматриваем $\phi(0) > 0$. Тогда справедлива оценка:

$$\frac{1}{\phi(0)} > -\frac{1}{\phi(1)} + \frac{1}{\phi(0)} \geq \frac{1}{\nu}.$$

Поскольку $\langle \nabla B(x), y - x \rangle = \phi(0)$, получаем

$$\langle \nabla B(x), y - x \rangle < \nu.$$

Далее проведём несложное рассуждение:

$$\frac{1}{\phi(1)} \leq \frac{1}{\phi(0)} - \frac{1}{\nu} = \frac{\nu - \phi(0)}{\nu\phi(0)}.$$

Отсюда выражаем $\phi(1)$ и оцениваем $\phi(1) - \phi(0)$:

$$\phi(1) - \phi(0) \geq \frac{\nu\phi(0)}{\nu - \phi(0)} - \phi(0) = \frac{\phi(0)^2}{\nu - \phi(0)}.$$

Получили неравенство (Л12.3). ■

Проверять ν -самосогласованность барьера не всегда легко, запишем критерий.

Утверждение Л12.4. Самосогласованный барьер $B(x)$ — ν -самосогласованный тогда и только тогда, когда функция $\phi : \text{int } G \rightarrow \mathbb{R}$:

$$\phi(x) = \exp \left\{ -\frac{B(x)}{\nu} \right\}$$

вогнута.

Доказательство. Вычислим вторую производную ϕ и получим формулу:

$$\nabla^2 \phi(x) = -\frac{1}{\nu} \exp \left\{ -\frac{B(x)}{\nu} \right\} \left[\nabla^2 B(x) - \frac{1}{\nu} \nabla B(x) \nabla B(x)^\top \right],$$

из которой видна эквивалентность. ■

Далее будем работать с локальной нормой (Определение Л6.2):

$$\|x\|_A = \sqrt{\langle Ax, x \rangle}.$$

Следующее утверждение даёт понимание структуры области определения самосопряжённого барьера, вытекающей из его локальных характеристик.

Утверждение Л12.5. Пусть $B(x)$ — ν -самосопряжённый барьер. Рассмотрим $x, y \in \text{dom } B$ такие, что выполнено

$$\langle \nabla B(x), y - x \rangle \geq 0.$$

Тогда имеем следующую верхнюю оценку на расстояние между точками:

$$\|y - x\|_{\nabla^2 B(x)} \leq \nu + 2\sqrt{\nu}.$$

Доказательство. Обозначим $r = \|y - x\|_{\nabla^2 B(x)}$. Введём $y_t = x + t(y - x)$ для $t \in [0, 1]$ и рассмотрим $g(t) = B(y_t)$. Тогда $g'(t) = \langle \nabla B(y_t), y - x \rangle$ и $g''(t) = \|y - x\|_{\nabla^2 B(y_t)}^2$. Из определения самосопряжённости функции B следует, что для одномерного сечения $g(t)$ верно неравенство

$$|g'''(t)| \leq 2[g''(t)]^{\frac{3}{2}}.$$

Введём вспомогательную функцию $\phi(t) = [g''(t)]^{-\frac{1}{2}}$. Тогда

$$\phi'(t) = -\frac{1}{2} \frac{g'''(t)}{[g''(t)]^{\frac{3}{2}}},$$

а следовательно, $|\phi'(t)| \leq 1$. Интегрируя по t от 0 до произвольного $t \geq 0$, получаем

$$\phi(t) \leq \phi(0) + t \iff \frac{1}{\sqrt{g''(t)}} \leq \frac{1}{\sqrt{g''(0)}} + t.$$

Обращая обе положительные части, получаем:

$$g''(t) \geq \frac{g''(0)}{(1 + t\sqrt{g''(0)})^2}.$$

Так как $g''(0) = \|y - x\|_{\nabla^2 B(x)}^2 = r^2$, получаем

$$g''(t) \geq \frac{r^2}{(1 + tr)^2}.$$

Интегрируя $g''(t)$ от 0 до 1, получаем:

$$g'(1) - g'(0) = \langle \nabla B(y) - \nabla B(x), y - x \rangle \geq \int_0^1 \frac{r^2}{(1 + tr)^2} dt = \frac{r^2}{1 + r}.$$

Рассмотрим это выражение в точке $y = y_t$:

$$\langle \nabla B(y_t) - \nabla B(x), y_t - x \rangle = t \langle \nabla B(y_t) - \nabla B(x), y - x \rangle \geq \frac{t^2 r^2}{1 + tr}.$$

Так как по условию $\langle \nabla B(x), y - x \rangle \geq 0$, получаем:

$$\langle \nabla B(y_t), y - x \rangle \geq \frac{tr^2}{1 + tr}.$$

Применим неравенство (Л12.2):

$$\langle \nabla B(y_t), y - y_t \rangle = (1 - t)\langle \nabla B(y_t), y - x \rangle < \nu \implies \langle \nabla B(y_t), y - x \rangle < \frac{\nu}{1 - t}.$$

Можно считать, что $r \geq \sqrt{\nu}$, так как в противном случае неравенство тривиально, поэтому можно взять $t = \frac{\sqrt{\nu}}{r}$, тогда:

$$\frac{1}{1 + \sqrt{\nu}} \leq \frac{\sqrt{\nu}}{r - \sqrt{\nu}} \implies r \leq \nu + 2\sqrt{\nu}.$$

■

Л12.3 Анализ метода

Вернёмся к исходной постановке задачи:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = \overline{1, n}. \end{aligned}$$

Пусть теперь функции f и g_i — выпуклые на G . Для любой задачи подойдет следующая общая схема внутренней точки:

Алгоритм Л12.1 Метод внутренней точки (общий случай)

Вход: стартовая точка $x^0 \in \text{int } G$, стартовое значение параметра $\rho_{-1} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: Увеличить $\rho_k > \rho_{k-1}$

3: С помощью некоторого метода численно решить задачу безусловной оптимизации с целевой функцией $F_{\rho_k} = f + \frac{1}{\rho_k}B$ и стартовой точкой x^k . Гарантировать, что выход метода x^{k+1} будет близок к реальному решению $x_{\rho_k}^*$.

4: **end for**

Выход: x^K

Идея метода строится на том, что мы постепенно уменьшаем множитель перед барьером ρ_k и находим приближение $x^{k+1} \approx x_{\rho_k}^*$. Таким образом, при $\rho_k \rightarrow \infty$ решение задачи с барьером будет стремиться к решению исходной задачи $x_{\rho_k}^* \rightarrow x^*$, а так как $x^{k+1} \approx x_{\rho_k}^*$, то и приближение будет сходиться к решению $x^{k+1} \rightarrow x^*$.

Переформулируем исходную задачу через надграфик:

$$\begin{aligned} \min_{(x, t) \in \mathbb{R}^d \times \mathbb{R}} \quad & t \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = \overline{1, n} \\ & f(x) - t \leq 0. \end{aligned}$$

Напомним, что функция выпуклая тогда и только тогда, когда ее надграфик — выпуклое множество (Определение С4.5). Таким образом, всё ещё имеем выпуклую задачу,

но теперь с линейной целевой функцией. От неё можно перейти к чуть более общей задаче минимизации линейной функции с выпуклыми ограничениями g_i :

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & \langle c, x \rangle \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = \overline{1, n}. \end{aligned} \quad (\text{Л12.4})$$

Перейдём к частному случаю метода внутренней точки для линейной целевой функции и ν -самосогласованных барьеров. Отметим, что чем меньше ν , тем лучше барьер и, как мы увидим далее, тем быстрее сходится метод.

Введём дополнительные объекты:

1. $\Phi_\rho(x) = \rho F_\rho(x) = \rho \langle c, x \rangle + B(x)$,
2. $\lambda(\Phi_\rho, x) = \sqrt{\left\langle (\nabla^2 \Phi_\rho(x))^{-1} \nabla \Phi_\rho(x), \nabla \Phi_\rho(x) \right\rangle}$.

Алгоритм Л12.2 Метод внутренней точки (демпфированный метод Ньютона)

Вход: стартовая точка $x^0 \in \text{int } G$ такая, что $\lambda(\Phi_{\rho_{-1}}, x^0) \leq e_1$, параметры $e_1, e_2 \in (0, 1)$, стартовое значение параметра $\rho_{-1} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $\rho_k = \left(1 + \frac{e_2}{\sqrt{\nu}}\right) \rho_{k-1}$
- 3: Сделать шаг демпфированного метода Ньютона:

$$x^{k+1} = x^k - \frac{1}{1 + \lambda(\Phi_{\rho_k}, x^k)} [\nabla^2 \Phi_{\rho_k}(x^k)]^{-1} \nabla \Phi_{\rho_k}(x^k)$$

- 4: **end for**

Выход: x^K

Замечание Л12.4. Возможно, понадобится больше одного шага метода Ньютона, но при правильном соотношении e_1 и e_2 достаточно ровно одного.

Замечание Л12.5. Ньютоновский декремент $\lambda(\Phi_\rho, x)$ используется для оценки близости точки x к решению x_ρ^* . При положительно определённой матрице $\nabla^2 \Phi_\rho(x)$ он представляет собой норму градиента $\nabla \Phi_\rho(x)$ в метрике, индуцированной гесссианом. Начальная точка x^0 выбирается так, чтобы $\lambda(\Phi_{\rho_0}, x^0)$ была мала, например, после нескольких итераций демпфированного метода Ньютона при фиксированном ρ_0 . После этого параметр ρ последовательно увеличивается. Для каждого нового значения ρ_k достаточно одного шага метода Ньютона, чтобы снова оказаться в области, где

$$\lambda(\Phi_{\rho_k}, x^{k+1}) \leq e_1.$$

В дальнейшем будет показано, что данное условие выполняется при корректном выборе шага и параметров обновления.

Замечание Л12.6. Обозначим:

$$H(x) = \nabla^2 \Phi_\rho(x) = \nabla^2 B(x),$$

Из свойств ν -самосогласованного барьера следует, что $H(x)$ положительно полуопределена, а для рассматриваемых барьеров — положительно определена для всех $x \in \text{int } G$. В новых обозначениях:

$$\lambda(\Phi_\rho, x) = \|\nabla \Phi_\rho(x)\|_{H^{-1}(x)} = \|\rho c + \nabla B(x)\|_{H^{-1}(x)}.$$

Теорема Л12.1. Пусть задача оптимизации (Л12.4) с выпуклыми ограничениями решается с помощью метода внутренней точки (Алгоритм Л12.2 с настройкой $e_1 = 0.05$, $e_2 = 0.08$), при этом используются ν -самосогласованные барьеры. Тогда, чтобы достичь ε решения по функции ($f(x) - f^* \leq \varepsilon$), необходимо

$$K = \mathcal{O}\left(\sqrt{\nu} \log \frac{\nu}{\varepsilon \rho_0}\right) \text{ итераций.}$$

Доказательство. Пусть для некоторого k выполнено $\lambda(\Phi_{\rho_{k-1}}, x^k) \leq e_1$. Оценим, как изменяется декремент при переходе от ρ_{k-1} к ρ_k . Применяя неравенство треугольника, получаем

$$\begin{aligned} \lambda(\Phi_{\rho_k}, x^k) &= \|\rho_k c + \nabla B(x^k)\|_{H^{-1}(x^k)} \\ &\leq \|\rho_{k-1} c + \nabla B(x^k)\|_{H^{-1}(x^k)} + \|(\rho_k - \rho_{k-1})c\|_{H^{-1}(x^k)} \\ &= \lambda(\Phi_{\rho_{k-1}}, x^k) + \frac{\rho_k - \rho_{k-1}}{\rho_{k-1}} \|\rho_{k-1} c\|_{H^{-1}(x^k)} \\ &\leq e_1 + \frac{\rho_k - \rho_{k-1}}{\rho_{k-1}} \|\rho_{k-1} c\|_{H^{-1}(x^k)}. \end{aligned} \quad (\text{Л12.5})$$

Подставим $h = (\nabla^2 B(x^k))^{-1} \nabla B(x^k)$ в определение ν -самосогласованного барьера (Определение Л12.3):

$$\left| \left\langle (\nabla^2 B(x^k))^{-1} \nabla B(x^k), \nabla B(x^k) \right\rangle \right| \leq \sqrt{\nu} \sqrt{\left\langle (\nabla^2 B(x^k))^{-1} \nabla B(x^k), \nabla B(x^k) \right\rangle}.$$

Отсюда выражается:

$$\|\nabla B(x^k)\|_{H^{-1}(x^k)} = \left\langle (\nabla^2 B(x^k))^{-1} \nabla B(x^k), \nabla B(x^k) \right\rangle \leq \nu.$$

Далее, по неравенству треугольника и неравенству выше имеем:

$$\begin{aligned} \|\rho_{k-1} c\|_{H^{-1}(x^k)} &\leq \|\rho_{k-1} c + \nabla B(x^k)\|_{H^{-1}(x^k)} + \|\nabla B(x^k)\|_{H^{-1}(x^k)} \\ &\leq \lambda(\Phi_{\rho_{k-1}}, x^k) + \sqrt{\nu} \leq e_1 + \sqrt{\nu}. \end{aligned} \quad (\text{Л12.6})$$

Поскольку шаг изменения параметра определяется правилом

$$\rho_k = \left(1 + \frac{e_2}{\sqrt{\nu}}\right) \rho_{k-1},$$

то из (Л12.5) и (Л12.6) следует

$$\lambda(\Phi_{\rho_k}, x^k) \leq e_1 + \frac{e_2}{\sqrt{\nu}} (e_1 + \sqrt{\nu}) = e_1 + e_2 + \frac{e_1 e_2}{\sqrt{\nu}}. \quad (\text{Л12.7})$$

Функция Φ_{ρ_k} самосогласованна, так как является суммой линейной функции и барьера. Для неё справедлива оценка убывания декремента после одного демпфированного шага метода Ньютона (Следствие Теоремы 4.1.14 из [44]):

$$\lambda(\Phi_{\rho_k}, x^{k+1}) \leq 2\lambda(\Phi_{\rho_k}, x^k)^2. \quad (\text{Л12.8})$$

Подставим $e_1 = 0.05$, $e_2 = 0.08$ в (Л12.7):

$$\lambda(\Phi_{\rho_k}, x^k) \leq 0.05 + 0.08 + \frac{0.05 \cdot 0.08}{\sqrt{\nu}} \leq 0.134.$$

Тогда из (Л12.8) имеем

$$\lambda(\Phi_{\rho_k}, x^{k+1}) \leq 2 \cdot 0.134^2 < 0.05 = e_1,$$

то есть после одного шага метода Ньютона условие $\lambda(\Phi_{\rho_k}, x^{k+1}) \leq e_1$ восстанавливается.

Так как $x_{\rho_k}^*$ удовлетворяет $\nabla \Phi_{\rho_k}(x_{\rho_k}^*) = 0$, то

$$\rho_k c + \nabla B(x_{\rho_k}^*) = 0.$$

Разнесём слагаемые по разным сторонам и домножим на $x_{\rho_k}^* - x^*$:

$$\rho_k \langle c, x_{\rho_k}^* - x^* \rangle = \langle \nabla B(x_{\rho_k}^*), x^* - x_{\rho_k}^* \rangle.$$

Продолжим, используя неравенство (Л12.2) для ν -самосогласованных барьеров:

$$\rho_k \langle c, x_{\rho_k}^* - x^* \rangle = \langle \nabla B(x_{\rho_k}^*), x^* - x_{\rho_k}^* \rangle \leq \nu,$$

получаем

$$\langle c, x_{\rho_k}^* - x^* \rangle \leq \frac{\nu}{\rho_k}.$$

Подставим значение $\rho_k = (1 + \frac{e_2}{\sqrt{\nu}})^k \rho_0$, а также применим неравенство (0.4):

$$f(x^K) - f^* \leq \frac{\nu}{\rho_K} = \frac{\nu}{\rho_0} \left(1 + \frac{e_2}{\sqrt{\nu}}\right)^{-K} \leq \frac{\nu}{\rho_0} \exp\left(-\frac{e_2}{\sqrt{\nu}} K\right).$$

Чтобы достичь ε -решения, ограничим правую часть:

$$f(x^K) - f^* \leq \frac{\nu}{\rho_0} \exp\left(-\frac{e_2}{\sqrt{\nu}} K\right) \leq \varepsilon.$$

Отсюда появляется требование:

$$K \geq \frac{\sqrt{\nu}}{e_2} \log \frac{\nu}{\varepsilon \rho_0}.$$

Поскольку $e_2 = 0.08$ — константа, то можно записать асимптотическую оценку:

$$K = \mathcal{O}\left(\sqrt{\nu} \log \frac{\nu}{\varepsilon \rho_0}\right).$$

■

Таким образом, метод внутренней точки — хорошая альтернатива методу штрафов, дополнительно гарантирующая соблюдение ограничений. Для выпуклых задач метод внутренней точки обладает фундаментальной теорией и сильными гарантиями сходимости.

Схема следования по пути, изложенная в этом параграфе, приводит к созданию наиболее эффективных в худшем случае методов внутренних точек для задач выпуклого программирования. Однако на практике в вышеупомянутом виде схема работает довольно плохо. Параметр ρ увеличивается медленно. Таким образом, при прямолинейной реализации схемы оценка сложности из Теоремы Л12.1 не просто верхняя оценка в худшем случае, но оценка типичного поведения метода.

Пример Л12.6. Пусть решается задача линейного программирования с 10^5 переменными и 10^5 ограничениями. Тогда придётся иметь дело с тысячами ньютоновских шагов для матриц $10^5 \times 10^5$. Даже если матрицы очень разреженные, симплекс-метод на практике окажется быстрее.

Понятно, что обновлять параметр штрафа, исходя из анализа в худшем случае, довольно плохая идея: такие оценки чрезвычайно консервативны и приводят к чрезмерно малым шагам. Чтобы строить ориентированные на приложения методы внутренней точки, можно менять параметр штрафа, опираясь, например, на локальную кривизну пути. А реально наблюдаемое количество итераций метода Ньютона, необходимое для решения задачи с приемлемой точностью, практически не зависит от размеров задачи и находится в пределах 30-50.

Л13 Седловые задачи

Рассмотрим задачу условной оптимизации вида:

$$\begin{aligned} \min_{x \in \mathbb{R}^d} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = \overline{1, m} \\ & Ax = b, \end{aligned} \quad (\text{Л13.1})$$

где $A \in \mathbb{R}^{n \times d}$ и $b \in \mathbb{R}^n$. Дополнительно ещё можно было обобщить постановку и добавить, что $x \in \mathcal{X}$.

Функция Лагранжа для этой задачи строится следующим образом:

$$\mathcal{L}(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \nu^\top (Ax - b).$$

В Параграфе С7 была определена двойственная функция к задаче (Л13.1):

$$g(\lambda, \nu) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda, \nu).$$

Далее из Утверждения С7.2 для всех $\lambda \succeq 0$ и $\nu \in \mathbb{R}^n$ имеем:

$$g(\lambda, \nu) \leq f(x^*).$$

Также сформулировано условие Слейтера (Утверждение С7.3).

Утверждение Л13.1. Рассмотрим задачу (Л13.1) с выпуклыми функциями $f_0, \dots, f_m$. Если существует такой $\bar{x} \in \mathbb{R}^d$, что выполняется условие Слейтера:

$$f_i(\bar{x}) < 0, \quad i = \overline{1, m}, \quad A\bar{x} = b,$$

то для задачи (Л13.1) выполняется сильная двойственность:

$$\sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} g(\lambda, \nu) = f_0(x^*).$$

Л13.1 Седловая точка Лагранжиана

Для того чтобы объединить прямую и двойственную задачу, определим понятие седловой точки лагранжиана.

Определение Л13.1. Точка $(x^*, \lambda^*, \nu^*) \in \mathbb{R}^d \times \mathbb{R}_+^m \times \mathbb{R}^n$ называется *седловой* для функции $\mathcal{L}(x, \lambda, \nu)$, если для любых $(x, \lambda, \nu) \in \mathbb{R}^d \times \mathbb{R}_+^m \times \mathbb{R}^n$ выполнено

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Теперь покажем, как связаны седловая точка лагранжиана и решение прямой задачи (Л13.1).

Теорема Л13.1. (Теорема о седловой точке Куна–Таккера)

Пусть для задачи оптимизации (Л13.1) с выпуклыми функциями $f_0, \dots, f_m$ выполняется условие Слейтера (Утверждение Л13.1). Тогда следующие утверждения эквивалентны:

- Для x^* существует $\lambda^* \succeq 0$ и $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа,
- x^* — глобальное решение задачи оптимизации с ограничениями.

Доказательство. $\Rightarrow$ Пусть для $x^* \in \mathbb{R}^d$ существует $\lambda^* \succeq 0$, $\nu^* \in \mathbb{R}^n$ такие, что (x^*, λ^*, ν^*) — седловая точка функции Лагранжа:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

Для начала удостоверимся, что x^* удовлетворяет ограничениям. Если нет, то либо $Ax^* \neq b$, либо $f_i(x^*) > 0$. Рассмотрим случай, когда нарушается ограничение вида неравенства. Тогда

$$\sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} \mathcal{L}(x^*, \lambda, \nu) = +\infty,$$

что невозможно, так как второе неравенство в определении седловой точки рушится для $\lambda = (\lambda_1^*, \dots, \lambda_{i-1}^*, 2\lambda_i^*, \lambda_{i+1}^*, \dots, \lambda_m^*)^\top$. Аналогично разбирается случай, когда нарушается $Ax^* \neq b$.

Теперь поскольку решение x^* удовлетворяет всем ограничениям, то

$$f_0(x^*) = \sup_{\substack{\lambda \succeq 0 \\ \nu \in \mathbb{R}^n}} \mathcal{L}(x^*, \lambda, \nu).$$

Второе неравенство в определении седловой точки даёт:

$$\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Первое неравенство из определения седловой точки даёт:

$$f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + (\nu^*)^\top (Ax - b) \geq \mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*).$$

Остаётся заметить, что для допустимых x ограничения выполнены, а λ_i^* неотрицательные. Поэтому получаем, что левая часть не превосходит $f_0(x)$:

$$f_0(x) \geq f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + (\nu^*)^\top (Ax - b) \geq f_0(x^*).$$

$\Leftarrow$ Пусть x^* — глобальное решение задачи с ограничениями. Условие Слейтера (Утверждение Л13.1) нам даёт:

$$f_0(x^*) = g(\lambda^*, \nu^*).$$

С одной стороны, поскольку x^* — допустимое решение, то оно удовлетворяет всем ограничениям. Поэтому выполняется неравенство:

$$f_0(x^*) \geq f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \nu^\top (Ax^* - b) = \mathcal{L}(x^*, \lambda, \nu),$$

где $\lambda \succeq 0$, $\nu \in \mathbb{R}^n$. С другой стороны, по определению двойственной функции:

$$g(\lambda^*, \nu^*) = \inf_{x \in \mathbb{R}^d} \mathcal{L}(x, \lambda^*, \nu^*) \leq \mathcal{L}(x^*, \lambda^*, \nu^*).$$

Заметим, что $\lambda_i^* f_i(x^*) = 0$ и $Ax^* - b = 0$. Поэтому $\mathcal{L}(x^*, \lambda^*, \nu^*) = f_0(x^*)$. Собираем все неравенства вместе:

$$\mathcal{L}(x, \lambda^*, \nu^*) \geq g(\lambda^*, \nu^*) = f_0(x^*) = \mathcal{L}(x^*, \lambda^*, \nu^*) \geq \mathcal{L}(x^*, \lambda, \nu).$$

■

На самом деле, седловые задачи — это больше, чем просто функция Лагранжа. Это отдельный и более общий класс задач, который имеет свои приложения. Абстрагируемся от функции Лагранжа. Пусть есть некоторая функция:

$$\mathcal{L}(x, \lambda) : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}.$$

Рассмотрим следующую игровую интерпретацию:

- Пусть есть два игрока: первый выбирает $x \in \mathcal{X}$, а второй — $\lambda \in \Lambda$. В конкретной задаче это может означать, например, распределение ресурсов, выбор стратегии или управление параметрами.
- Функция $\mathcal{L}(x, \lambda)$ описывает значение прибыли, зависящей от выбранных x и λ . Первый игрок выплачивает второму сумму $\mathcal{L}(x, \lambda)$, то есть первый стремится минимизировать эту величину, а второй — максимизировать.
- Задача заключается в поиске равновесия между игроками, поскольку экстремальные стратегии не всегда оказываются оптимальными. Например, если второй игрок знает, что при некотором $\tilde{x}$ первый особенно уязвим, он может подобрать $\lambda(\tilde{x})$, при котором его выигрыш будет очень велик. Однако если при других $x \neq \tilde{x}$ та же стратегия $\lambda(\tilde{x})$ не приносит выгоды (даёт нулевой выигрыш), первый игрок просто перестанет выбирать $\tilde{x}$. С другой стороны, может существовать стратегия $\tilde{\lambda}$, обеспечивающая второму игроку небольшой, но стабильный выигрыш при любых x . В этом случае $\tilde{\lambda}$ окажется более рациональным выбором. Именно такие сбалансированные решения и определяются как равновесие.
- С точки зрения седловой задачи, равновесие (x^*, λ^*) является седловой точкой функции $\mathcal{L}$. То есть для любых значений $x \in \mathcal{X}$, $\lambda \in \Lambda$:

$$\mathcal{L}(x, \lambda^*) \geq \mathcal{L}(x^*, \lambda^*) \geq \mathcal{L}(x^*, \lambda).$$

Получается следующее. Пусть $(\tilde{x}, \tilde{\lambda})$ — седловая точка. Тогда любые изменения x со стороны первого игрока приведут к увеличению его выплат (то есть к большему значению $\mathcal{L}$), а любые изменения λ со стороны второго игрока — к уменьшению его выигрыша.

В обратную сторону: если, например, $\tilde{x}$ не является частью седлового решения, то при фиксированной $\tilde{\lambda}$ первый игрок может изменить x так, чтобы платить меньше. Это нарушает равновесие, и значит, $(\tilde{x}, \tilde{\lambda})$ не является седлом.

Рассмотрим теперь вопрос: одинаковым ли будет результат игры, если

1. Сначала выбирает первый игрок, а затем второй;
2. Сначала выбирает второй игрок, а затем первый?

Ответ отрицательный, результаты будут различаться.

Если первым ходит игрок 1, он рассуждает так: если я выберу некоторое x , то второй игрок сразу после этого выберет λ , максимизирующую его выигрыш: $\sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$. Значит, мне нужно выбрать x так, чтобы минимизировать свои потери:

$$\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

В противоположной ситуации, когда первым выбирает игрок 2, результат определяется выражением

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda).$$

Используя эту интуицию, можно понять, что в общем случае выполняется неравенство

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) \leq \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Формально это следует из следующего рассуждения:

$$\inf_{\tilde{x} \in \mathcal{X}} \mathcal{L}(\tilde{x}, \lambda) \leq \mathcal{L}(x, \lambda) \quad \forall x \in \mathcal{X} \implies \sup_{\lambda \in \Lambda} \inf_{\tilde{x} \in \mathcal{X}} \mathcal{L}(\tilde{x}, \lambda) \leq \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda) \quad \forall x \in \mathcal{X},$$

откуда действительно следует

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) \leq \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Как две игры: $\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda)$ и $\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$ связаны с седловой точкой?

Теорема Л13.2. Множество седловых точек функции $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непустое тогда и только тогда, когда обе задачи $\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda)$ и $\inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda)$ имеют решения и эти решения совпадают.

Теорема Л13.3. Пусть $\mathcal{X}$, Λ выпуклые компактные множества, пусть также $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непрерывна, выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x). Тогда $\mathcal{L}$ имеет седловые точки на $\mathcal{X} \times \Lambda$.

Теорема Л13.4. Пусть $\mathcal{X}$, Λ выпуклые множества, и $\mathcal{X}$ или Λ дополнительно компактно, пусть также $\mathcal{L} : \mathcal{X} \times \Lambda \rightarrow \mathbb{R}$ непрерывна, выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x). Тогда (гарантий существования тут нет)

$$\sup_{\lambda \in \Lambda} \inf_{x \in \mathcal{X}} \mathcal{L}(x, \lambda) = \inf_{x \in \mathcal{X}} \sup_{\lambda \in \Lambda} \mathcal{L}(x, \lambda).$$

Л13.2 Метод градиентного спуска–подъёма

Оптимизация функции Лагранжа — седловая задача. Седловые задачи возникают как отдельный большой класс задач. Будем рассматривать следующую задачу:

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \in \mathbb{R}^d} \mathcal{L}(x, \lambda), \quad (\text{Л13.2})$$

где $\mathcal{L}$ непрерывно дифференцируема по обоим группам переменных и выпукла–вогнута: выпукла по x (для любого фиксированного λ) и вогнута по λ (для любого фиксированного x), а также градиенты $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ липшицевы с константой $\frac{L}{\sqrt{2}}$:

$$\begin{aligned} \|\nabla_x \mathcal{L}(x_1, \lambda_1) - \nabla_x \mathcal{L}(x_2, \lambda_2)\|_2^2 &\leq \frac{L^2}{2} \left(\|x_1 - x_2\|_2^2 + \|\lambda_1 - \lambda_2\|_2^2 \right), \\ \|\nabla_\lambda \mathcal{L}(x_1, \lambda_1) - \nabla_\lambda \mathcal{L}(x_2, \lambda_2)\|_2^2 &\leq \frac{L^2}{2} \left(\|x_1 - x_2\|_2^2 + \|\lambda_1 - \lambda_2\|_2^2 \right). \end{aligned}$$

Первый метод, который приходит в голову для решения седловой задачи — это метод спуска–подъёма. Он бывает одновременный (Simultaneous Gradient Descent–Ascent) и поочерёдный (Alternating Gradient Descent–Ascent). Одновременный выглядит следующим образом:

Алгоритм Л13.1 Метод одновременного градиентного спуска–подъёма (Sim–GDA)

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$ 
3:    $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^k, \lambda^k)$ 
4: end for
Выход:  $x^K, \lambda^K$ 

```

То есть обновления переменных происходят с использованием градиентов из одной и той же точки, можно сказать одновременно.

Одновременные обновления просты в анализе. В случае отсутствия ограничения в виде одновременного обновления переменных, лучше показывает себя метод поочерёдного градиентного спуска–подъёма (Alt–GDA). Поочерёдные обновления сильно усложняют анализ сходимости. Идея же очень проста — сначала делаем шаг по одной переменной, а потом из новой точки по второй переменной.

Алгоритм Л13.2 Метод поочерёдного градиентного спуска–подъёма (Alt–GDA)

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:    $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$ 
3:    $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1}, \lambda^k)$ 
4: end for
Выход:  $x^K, \lambda^K$ 

```

К сожалению, метод градиентного спуска–подъёма (и одновременный, и поочерёдный) порой не сходится в не сильно выпуклых–сильно вогнутых задачах. Например, при решении задачи

$$\min_{x \in \mathbb{R}} \max_{\lambda \in \mathbb{R}} x\lambda$$

со стартовой для алгоритма точкой $(1, 1)$. Седловой точкой является точка $(0, 0)$. Сгенерированные обоими алгоритмами точки можно посмотреть на Рисунке Л13.1.

Как видно, Alt–GDA начал двигаться по кругу, а Sim–GDA вообще стал расходиться. Однако в сильно выпуклых–сильно вогнутых задачах оба алгоритма сходятся гарантированно. Одновременный с итерационной скоростью $\mathcal{O}\left(\frac{L^2}{\mu^2}\right)$, а поочерёдный со скоростью $\mathcal{O}\left(\frac{L}{\mu}\right)$, что является оптимальным результатом. В остальных случаях (не учитывая конкретные задачи), сходимость поочерёдного градиентного спуска–подъёма не обязательно достигает оптимальных результатов (если метод вообще сойдется).

Л13.3 Экстраградиентный метод

Идея поочерёдного спуска–подъёма проста в понимании, реализации, и вполне неплохо работает, но с рядом упомянутых выше проблем. Все они решаются в экстраградиентном методе. В некоторой точке (x^k, λ^k) , алгоритм делает одновременный спуск–подъём




Рис. Л13.1: Sim-GDA и Alt-GDA для $\mathcal{L}(x, \lambda) = x\lambda$.

в промежуточную точку $(x^{k+1/2}, \lambda^{k+1/2})$. Затем, алгоритм делает одновременный спуск-подъём из точки (x^k, λ^k) , используя градиенты в $(x^{k+1/2}, \lambda^{k+1/2})$. Обычный градиентный спуск-подъём часто расходится. Более того, если алгоритм и сходится, то делает это в виде вихря, что сильно замедляет сходимость. Экстраградиентный метод решает это «толчком» в направлении решения, используя для движения градиенты не из текущей точки, а из «следующей».

Алгоритм Л13.3 Экстраградиентный метод

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: $x^{k+1/2} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k)$
 - 3: $\lambda^{k+1/2} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^k, \lambda^k)$
 - 4: $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2})$
 - 5: $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2})$
 - 6: **end for**
- Выход:** $\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}$
-

Теперь, когда мы исправили все недостатки метода поочерёдного спуска-подъёма, можно перейти к теоретическим выкладкам по методу экстраградиента. Для начала нам понадобится утверждение.

Утверждение Л13.2. Пусть $z, y \in \mathbb{R}^d$, и $z^+ = z - y$, тогда для любого $u \in \mathbb{R}^d$:

$$\|z^+ - u\|_2^2 = \|z - u\|_2^2 - 2\langle y, z^+ - u \rangle - \|z^+ - z\|_2^2.$$

Доказательство. Тут достаточно обычных алгебраических преобразований:

$$\begin{aligned}
\|z^+ - u\|_2^2 &= \|z^+ - z + z - u\|_2^2 \\
&= \|z - u\|_2^2 + 2\langle z^+ - z, z - u \rangle + \|z^+ - z\|_2^2 \\
&= \|z - u\|_2^2 + 2\langle z^+ - z, z - z^+ + z^+ - u \rangle + \|z^+ - z\|_2^2 \\
&= \|z - u\|_2^2 + 2\langle z^+ - z, z^+ - u \rangle - \|z^+ - z\|_2^2 \\
&= \|z - u\|_2^2 - 2\langle y, z^+ - u \rangle - \|z^+ - z\|_2^2.
\end{aligned}$$

■

Используя это утверждение, докажем теорему о сходимости метода.

Теорема Л13.5. Пусть седловая задача (Л13.2) с L -гладкой, выпукло-вогнутой функцией $\mathcal{L} : \mathbb{R}^d \times \mathbb{R}^n \rightarrow \mathbb{R}$ решается с помощью экстраградиентного метода (Алгоритм Л13.3). Тогда при $\gamma_k = \gamma \leq \frac{1}{L}$ для любого $u \in \mathbb{R}^d \times \mathbb{R}^n$ справедлива следующая оценка сходимости:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}. \quad (\text{Л13.3})$$

Доказательство. Для удобства введём вектор переменных z и оператор:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

Если $\nabla_x \mathcal{L}$ и $\nabla_\lambda \mathcal{L}$ L -липшицевы, то L -липшицев и оператор F . Как проявляется выпуклость по x и вогнутость по λ увидим позже. В новых обозначениях:

$$\begin{aligned}
z^{k+1/2} &= z^k - \gamma F(z^k), \\
z^{k+1} &= z^k - \gamma F(z^{k+1/2}).
\end{aligned}$$

Применим Утверждение Л13.2 два раза для итерации экстраградиентного метода:

- Для $z = z^k$, $y = \gamma F(z^{k+1/2})$ и $z^+ = z^{k+1}$:

$$\|z^{k+1} - u\|_2^2 = \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle - \|z^{k+1} - z^k\|_2^2.$$

- Для $z = z^k$, $y = \gamma F(z^k)$ и $z^+ = z^{k+1/2}$:

$$\|z^{k+1/2} - \tilde{u}\|_2^2 = \|z^k - \tilde{u}\|_2^2 - 2\gamma \langle F(z^k), z^{k+1/2} - \tilde{u} \rangle - \|z^{k+1/2} - z^k\|_2^2.$$

Подставим вместо $\tilde{u} = z^{k+1}$ и сложим:

$$\begin{aligned}
\|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &= \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1} - u \rangle \\
&\quad - 2\gamma \langle F(z^k), z^{k+1/2} - z^{k+1} \rangle - \|z^{k+1/2} - z^k\|_2^2.
\end{aligned}$$

Перегруппируем слагаемые:

$$\begin{aligned}
\|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &= \|z^k - u\|_2^2 + 2\gamma \langle F(z^{k+1/2}) - F(z^k), z^{k+1/2} - z^k \rangle \\
&\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2.
\end{aligned}$$

Оценим первое скалярное произведение:

$$\begin{aligned} \|z^{k+1} - u\|_2^2 + \|z^{k+1/2} - z^{k+1}\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 \|F(z^k) - F(z^{k+1/2})\|_2^2 \\ &\quad + \|z^{k+1/2} - z^{k+1}\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \\ &\quad - \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Слагаемое $\|z^{k+1/2} - z^{k+1}\|_2^2$ уничтожается с обеих сторон:

$$\begin{aligned} \|z^{k+1} - u\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 \|F(z^k) - F(z^{k+1/2})\|_2^2 \\ &\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Используем L -липшицевость F :

$$\begin{aligned} \|z^{k+1} - u\|_2^2 &\leq \|z^k - u\|_2^2 + \gamma^2 L^2 \|z^k - z^{k+1/2}\|_2^2 \\ &\quad - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle - \|z^{k+1/2} - z^k\|_2^2 \\ &= \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle + (\gamma^2 L^2 - 1) \|z^{k+1/2} - z^k\|_2^2. \end{aligned}$$

Учтём $\gamma \leq \frac{1}{L}$ и откинем последнее слагаемое:

$$\|z^{k+1} - u\|_2^2 \leq \|z^k - u\|_2^2 - 2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle.$$

Эквивалентная запись неравенства:

$$2\gamma \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle \leq \|z^k - u\|_2^2 - \|z^{k+1} - u\|_2^2.$$

Рассмотрим левую часть, оценим её снизу:

$$\begin{aligned} \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle &= \left\langle \begin{pmatrix} \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) \\ -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) \end{pmatrix}, \begin{pmatrix} x^{k+1/2} \\ \lambda^{k+1/2} \end{pmatrix} - \begin{pmatrix} u_x \\ u_\lambda \end{pmatrix} \right\rangle \\ &= \langle \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), x^{k+1/2} - u_x \rangle \\ &\quad + \langle -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), \lambda^{k+1/2} - u_\lambda \rangle. \end{aligned}$$

Применим выпуклость по x и вогнутость по λ :

$$\begin{aligned} \langle F(z^{k+1/2}), z^{k+1/2} - u \rangle &= \langle \nabla_x \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), x^{k+1/2} - u_x \rangle \\ &\quad + \langle -\nabla_\lambda \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}), \lambda^{k+1/2} - u_\lambda \rangle \\ &\geq \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) - \mathcal{L}(u_x, \lambda^{k+1/2}) \\ &\quad - \mathcal{L}(x^{k+1/2}, \lambda^{k+1/2}) + \mathcal{L}(x^{k+1/2}, u_\lambda). \end{aligned}$$

В итоге получаем:

$$2\gamma (\mathcal{L}(x^{k+1/2}, u_\lambda) - \mathcal{L}(u_x, \lambda^{k+1/2})) \leq \|z^k - u\|_2^2 - \|z^{k+1} - u\|_2^2.$$

Суммируем по всем k от 0 до $K-1$ и делим на $2\gamma K$:

$$\frac{1}{K} \sum_{k=0}^{K-1} (\mathcal{L}(x^{k+1/2}, u_\lambda) - \mathcal{L}(u_x, \lambda^{k+1/2})) \leq \frac{\|z^0 - u\|_2^2 - \|z^K - u\|_2^2}{2\gamma K} \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.$$

Неравенство Йенсена для выпуклой и вогнутой функции даёт:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{\|z^0 - u\|_2^2}{2\gamma K}.$$

■

Что подставлять в качестве $u = (u_x, u_\lambda)^\top$ в критерий сходимости? Ожидаемый вариант:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, \lambda^*\right) - \mathcal{L}\left(x^*, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right),$$

где x^* и λ^* — решение седловой задачи. Покажем, почему такой выбор не самый удачный. Для этого рассмотрим простую седловую задачу:

$$\min_{x \in \mathcal{X}} \max_{\lambda \in \Lambda} (x - 1)(\lambda + 1).$$

Предположим, что $1 \in \mathcal{X}$, $-1 \in \Lambda$, тогда решение этой задачи — $x^* = 1$, $\lambda^* = -1$ и $\mathcal{L}(1, -1) = 0$. Значение полученного критерия получится следующим:

$$\mathcal{L}(x, \lambda^*) - \mathcal{L}(x^*, \lambda) = 0.$$

Таким образом, такой критерий не подходит для выпукло-вогнутых седел, но подходит для сильно выпукло-сильно вогнутых. Но в сильно выпуклом-сильно вогнутом случае можно доказать линейную сходимость по аргументу, что более сильный результат. Правильный вариант критерия сходимости выглядит так:

$$\max_{\lambda \in \Lambda} \mathcal{L}(x^k, \lambda) - \min_{x \in \mathcal{X}} \mathcal{L}(x, \lambda^k).$$

Сформулируем для него и оптимального значения шага следствие из теоремы.

Утверждение Л13.3. Пусть задача удовлетворяет условиям Теоремы Л13.5 и выбрано значение шага $\gamma_k = \frac{1}{L}$. Тогда справедлива следующая оценка сходимости:

$$\max_{u_\lambda \in \mathbb{R}^d} \mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1/2}, u_\lambda\right) - \min_{u_x \in \mathbb{R}^d} \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1/2}\right) \leq \frac{L\|z^0 - u\|_2^2}{2K}. \quad (\text{Л13.4})$$

Более того, чтобы добиться точности ε по критерию выше, необходимо

$$K = \mathcal{O}\left(\frac{L\|z^0 - z^*\|_2^2}{\varepsilon}\right) \text{ итераций.} \quad (\text{Л13.5})$$

Доказательство. Оценка (Л13.4) напрямую следует из утверждения Теоремы Л13.5: подставляя в Неравенство (Л13.3) шаг $\gamma = \frac{1}{L}$, а также берём от левой части max по u_x и u_λ .

Вторая часть утверждения получается из первой. Ограничим правую часть Неравенства (Л13.4) положительным ε :

$$\frac{L\|z^0 - u\|_2^2}{2K} \leq \varepsilon.$$

Отсюда и получается оценка (Л13.5). ■

Стоит заметить, что переход к максимуму в критерии сходимости корректно определен только на компакте. Кажется, что это означает, что выпукло-вогнутые седловые задачи можно решать только на компактах (об этом говорила теорема Сиона–Какутани). Такую же проблему встречали и в выпуклой минимизации (на $\mathbb{R}^d$ выпуклая задача может не иметь решения). Поэтому мы предполагали, что решение существует. Здесь можно сделать то же самое: предположим, что решение существует и лежит в некотором компактном множестве $\mathcal{X}_* \times \Lambda_*$, тогда в критерии сходимости можно брать $\Lambda = \Lambda_*$ и $\mathcal{X} = \mathcal{X}_*$.

Упомянем также, что в методе экстраградиента можно как итоговую точку использовать не среднее всех полученных точек, а лишь последнюю. Но в этом случае сходимость будет хуже — $\mathcal{O}\left(\frac{1}{\sqrt{K}}\right)$. Взглянем наглядно, какие точки выдают оба алгоритма на все той же задаче

$$\min_{x \in \mathbb{R}} \max_{\lambda \in \mathbb{R}} x\lambda.$$

Результат на Рисунке Л13.2.




Рис. Л13.2: Экстраградиентный метод с разным выходом на задаче поиска седловой точки функции $\mathcal{L}(x, \lambda) = x\lambda$.

Теоретически, алгоритм, выдающий последнюю точку как результат должен быть хуже, но конкретно в этой задаче получилось наоборот.

Л13.4 Модификации экстраградиентного метода

Продолжим использовать следующую нотацию:

$$z = \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad F(z) = F(x, \lambda) = \begin{pmatrix} \nabla_x \mathcal{L}(x, \lambda) \\ -\nabla_\lambda \mathcal{L}(x, \lambda) \end{pmatrix}.$$

Как ранее было сказано, мы можем рассматривать экстраградиентный метод, когда $x \in \mathcal{X} \neq \mathbb{R}^d$ и $\lambda \in \Lambda \neq \mathbb{R}^n$. Тогда $z \in \mathcal{Z} = \mathcal{X} \times \Lambda$. Тогда экстраградиентный метод можно рассматривать как метод с проекцией:

Алгоритм Л13.4 Экстраградиентный метод с проекциями

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^k)]$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k+1/2})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

Алгоритм 2 раза выполняет оператор проекции и 2 раза вызывает оракул, то есть считается градиент. Это проблемы в случаях, когда оператор проекции или вызов оракула стоят дорого. В особенности важен второй случай, так как большинство операций проекции не очень сложны. Например, в глубоком обучении ограничений чаще всего вообще нет, зато подсчёт градиента — весьма нелёгкая операция. Поэтому, в зависимости от проблемы, возникает необходимость получить метод, который будет или реже вызывать оракул, или реже делать проекции, или и то и другое.

Начнем с алгоритма под названием Past Extra-Gradient, опубликованного Леонидом Поповым в 1978 году:

Алгоритм Л13.5 Past Extra-Gradient

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k-1/2})]$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k+1/2})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

В нём в первом шаге используется уже посчитанное значение оракула в точке $z^{k-1/2}$ как приближение оракула в точке z^k , которое неизвестно. Техника называется экстраполяцией из прошлого. Таким образом, мы вызываем оракул лишь раз за итерацию. Другую технику можно увидеть в алгоритме Reflected Gradient, которая дополнительно улучшает Экстраградиентный метод (Алгоритм Л13.3):

Алгоритм Л13.6 Reflected Gradient

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = z^k - (z^{k-1} - z^k)$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k+1/2})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

Здесь, вместо подсчета оракула в точке z^k используется приближение разницей $\frac{z^{k-1} - z^k}{\gamma}$. Reflected в названии взято из первого шага, где наблюдается эффект «отражения» точки z^{k-1} относительно точки z^k . Заметим, что больше нет проекции в первом шаге. Более того, в этой версии алгоритма удобно использовать непостоянный шаг обучения, ведь он используется лишь в одной строке. Теперь стоимость итерации этого алгоритма — 1 проекция и 1 вызов оракула.

Далее идёт алгоритм Пола Ценга с ещё одной техникой, который порой называют Forward–Backward–Forward Algorithm:

Алгоритм Л13.7 Forward–Backward–Forward Algorithm

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^k)]$

3: $z^{k+1} = z^{k+1/2} + \gamma_k F(z^k) - \gamma_k F(z^{k+1/2})$

4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

В этом алгоритме 2 вызова оракула и 1 вызов проекции. Мы его привели, чтобы показать, что изменения можно вводить не только в первом шаге, но и во втором, как в методе Ценга. Здесь z^k приближается выражением $z^{k+1/2} + \gamma_k F(z^k)$, и снова нет проекции. Можно добавить идею из Алгоритма Л13.5, заменив z^k на $z^{k-1/2}$. Получится метод Ценга с экстраполяцией из прошлого, или метод Optimistic Gradient. У него стоимость снова оптимальная — 1 проекция и 1 оракул.

Алгоритм Л13.8 Optimistic Gradient

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

1: **for** $k = 0, 1, \dots, K - 1$ **do**

2: $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k-1/2})]$

3: $z^{k+1} = z^{k+1/2} - \gamma_k (F(z^{k+1/2}) - F(z^{k-1/2}))$

4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

Обратим внимание, что при отсутствии проекций (то есть при решении задачи без ограничений), все эти алгоритмы идентичны друг другу.

Приведены не все алгоритмы. Но получаются они путем комбинаций разных техник, которые и были описаны. Доказано, что все алгоритмы выше в выпукло-вогнутых гладких седловых задачах сходятся так же со скоростью $\frac{1}{K}$, как и экстраградиентный метод, однако для разных ограничений на γ . Если для экстраградиентного метода $\gamma \leq \frac{1}{L}$, то, например, для Reflected Gradient $\gamma \leq \frac{\sqrt{2}-1}{L}$.

При изучении метода тяжёлого шарика (Алгоритм Л4.1) возник моментум, который улучшает физику обычного градиентного спуска. При решении седловых задач было показано, что моментум также позволяет немного ускорить алгоритмы. Однако моментум не всегда должен быть положительным, зависит от метода. У всех алгоритмов для решения седловых задач есть особенность, что они идут к решению вихрем. Моментум позволяет нам уменьшить вихрение. В случае экстраградиентного метода, моментум вставляется во второй шаг с положительным значением.

Алгоритм Л13.9 Экстраградиентный метод с моментумом

Вход: стартовая точка $z^0 \in \mathcal{Z}$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметры моментума $\{\tau_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $z^{k+1/2} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^k)]$
- 3: $z^{k+1} = \Pi_{\mathcal{Z}}[z^k - \gamma_k F(z^{k+1/2}) + \tau_k(z^k - z^{k-1})]$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=0}^{K-1} z^{k+1/2}$

В Alt-GDA хорошо показывает себя именно отрицательный моментум, то есть когда $\tau_k < 0$:

Алгоритм Л13.10 Alt-GDA с отрицательным моментумом

Вход: стартовая точка $(x^0, \lambda^0) \in \mathbb{R}^d \times \mathbb{R}^n$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметры моментума $\{\tau_k\}_{k=0} < 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k \nabla_x \mathcal{L}(x^k, \lambda^k) + \tau_k(x^k - x^{k-1})$
- 3: $\lambda^{k+1} = \lambda^k + \gamma_k \nabla_\lambda \mathcal{L}(x^{k+1}, \lambda^k) + \tau_k(\lambda^k - \lambda^{k-1})$
- 4: **end for**

Выход: x^K, λ^K

Разница в том, какой моментум использовать, вызвана тем, что экстраградиентный метод и обычные градиентные методы работают совсем по-разному физически.

Л13.5 Прямо-двойственный метод

Рассмотрим задачу минимизации с регуляризатором:

$$\min_{x \in \mathbb{R}^d} f(x) + h(Ax).$$

Заметим, что для выпуклой и замкнутой функции:

$$h(Ax) = h^{**}(Ax) = \max_{\lambda \in \mathbb{R}^n} \{(Ax)^\top \lambda - h^*(\lambda)\} = \max_{\lambda \in \mathbb{R}^n} \{-\lambda^\top Ax - h^*(-\lambda)\},$$

тогда, если взять $g(\lambda) = h^*(-\lambda)$, то исходную задачу можно свести к следующей:

$$\min_{x \in \mathbb{R}^d} \max_{\lambda \in \mathbb{R}^n} \mathcal{L}(x, \lambda) = f(x) - \lambda^\top Ax - g(\lambda). \quad (\text{Л13.6})$$

Дополнительно потребуем, чтобы функция f была L_f -гладкой и выпуклой, а функция g была L_g -гладкой и выпуклой.

Алгоритм Л13.11 Прямо-двойственный алгоритм

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: $x^{k+1} = x^k - \gamma_k(\nabla f(x^k) - A^\top \lambda^k)$
- 3: $\lambda^{k+1} = \lambda^k - \gamma_k(\nabla g(\lambda^k) + A(2x^{k+1} - x^k))$
- 4: **end for**

Выход: $\frac{1}{K} \sum_{k=1}^K x^k, \frac{1}{K} \sum_{k=1}^K \lambda^k$

Если вместо $(2x^{k+1} - x^k)$ подставить просто x^k получится просто спуск–подъём. В $(2x^{k+1} - x^k)$ защита «экстраградиентность».

Теорема Л13.6. Пусть седловая задача (Л13.6) с выпуклой L_f -гладкой функцией $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и выпуклой L_g -гладкой функцией $g : \mathbb{R}^n \rightarrow \mathbb{R}$ решается с помощью прямо–двойственного метода (Алгоритм Л13.11). Тогда при $\gamma_k = \gamma \leq \frac{1}{\max(L_g, L_f) + \|A\|_2}$ для любых $u = (x, \lambda) \in \mathbb{R}^d \times \mathbb{R}^n$ справедлива следующая оценка сходимости:

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1}, u_\lambda\right) - \mathcal{L}\left(u_x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1}\right) \leq \frac{\|z^0 - u\|_P^2}{2K}.$$

Доказательство. Распишем разность:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &= f(x^{k+1}) - f(x) - (\lambda^{k+1})^\top A(x^{k+1} - x) \\ &= f(x^{k+1}) - f(x^k) + f(x^k) - f(x) \\ &\quad - (\lambda^{k+1})^\top A(x^{k+1} - x). \end{aligned}$$

Воспользуемся выпуклостью и гладкостью f :

$$f(x^{k+1}) - f(x^k) \leq \langle \nabla f(x^k), x^{k+1} - x^k \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2.$$

Воспользуемся выпуклостью f :

$$f(x^k) - f(x) \leq \langle \nabla f(x^k), x^k - x \rangle.$$

Объединяя полученные результаты, получаем:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x). \end{aligned}$$

Подставим шаг:

$$\langle \nabla f(x^k) - A^\top \lambda^k, x^{k+1} - x \rangle = \frac{1}{\gamma} \langle x^k - x^{k+1}, x^{k+1} - x \rangle.$$

В итоге имеем:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda^{k+1}) - \mathcal{L}(x, \lambda^{k+1}) &\leq \frac{1}{\gamma} \langle x^k - x^{k+1}, x^{k+1} - x \rangle + \frac{L_f}{2} \|x^{k+1} - x^k\|_2^2 \\ &\quad - (\lambda^{k+1} - \lambda^k)^\top A(x^{k+1} - x). \end{aligned}$$

Распишем разность:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &= g(\lambda^{k+1}) - g(\lambda) - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}) \\ &= g(\lambda^{k+1}) - g(\lambda^k) + g(\lambda^k) - g(\lambda) \\ &\quad - (x^{k+1})^\top A^\top (\lambda - \lambda^{k+1}). \end{aligned}$$

Воспользуемся выпуклостью и гладкостью g :

$$g(\lambda^{k+1}) - g(\lambda^k) \leq \langle \nabla g(\lambda^k), \lambda^{k+1} - \lambda^k \rangle + \frac{L_g}{2} \|\lambda^{k+1} - \lambda^k\|_2^2.$$

Воспользуемся выпуклостью g :

$$g(\lambda^k) - g(\lambda) \leq \langle \nabla g(\lambda^k), \lambda^k - \lambda \rangle.$$

Объединяя полученные результаты, получаем:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \rangle \\ &\quad + \frac{Lg}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda). \end{aligned}$$

Подставим шаг:

$$\langle \nabla g(\lambda^k) + A(2x^{k+1} - x^k), \lambda^{k+1} - \lambda \rangle = \frac{1}{\gamma} \langle \lambda^k - \lambda^{k+1}, \lambda^{k+1} - \lambda \rangle.$$

В итоге имеем:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x^{k+1}, \lambda^{k+1}) &\leq \frac{1}{\gamma} \langle \lambda^k - \lambda^{k+1}, \lambda^{k+1} - \lambda \rangle + \frac{Lg}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 \\ &\quad + (x^k - x^{k+1})^\top A^\top (\lambda^{k+1} - \lambda). \end{aligned}$$

Просуммируем два полученных неравенства:

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) &\leq \begin{pmatrix} x^k - x^{k+1} \\ \lambda^k - \lambda^{k+1} \end{pmatrix}^\top \begin{pmatrix} \frac{1}{\gamma} I_d & A^\top \\ A & \frac{1}{\gamma} I_n \end{pmatrix} \begin{pmatrix} x^{k+1} - x \\ \lambda^{k+1} - \lambda \end{pmatrix} \\ &\quad + \frac{Lg}{2} \|\lambda^{k+1} - \lambda^k\|_2^2 + \frac{Lf}{2} \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Введем обозначение:

$$P = \begin{pmatrix} \frac{1}{\gamma} I_d & A^\top \\ A & \frac{1}{\gamma} I_n \end{pmatrix},$$

тогда

$$\begin{aligned} \mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1}) &\leq \langle z^k - z^{k+1}, z^{k+1} - z \rangle_P + \frac{\max(Lg, Lf)}{2} \|z^{k+1} - z^k\|_2^2 \\ &= \frac{1}{2} \|z^k - z\|_P^2 - \frac{1}{2} \|z^{k+1} - z\|_P^2 - \frac{1}{2} \|z^{k+1} - z^k\|_P^2 \\ &\quad + \frac{\max(Lg, Lf)}{2} \|z^{k+1} - z^k\|_2^2. \end{aligned}$$

Просуммируем по k от 0 до $K-1$:

$$\begin{aligned} \sum_{k=0}^{K-1} (\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1})) &\leq \frac{1}{2} \|z^0 - z\|_P^2 - \frac{1}{2} \|z^K - z\|_P^2 \\ &\quad + \sum_{k=0}^{K-1} \left(\frac{\max(Lg, Lf)}{2} \|z^{k+1} - z^k\|_2^2 - \frac{1}{2} \|z^{k+1} - z^k\|_P^2 \right). \end{aligned}$$

Потребуем $P \succ \max(Lg, Lf)I_{d+n}$, чтобы избавиться от последней строки и оставить $\|z^0 - z\|_2^2$. Это достигается при $\gamma \leq \frac{1}{\max(Lg, Lf) + \|A\|_2^2}$.

Делим на K и получаем

$$\frac{1}{K} \sum_{k=0}^{K-1} (\mathcal{L}(x^{k+1}, \lambda) - \mathcal{L}(x, \lambda^{k+1})) \leq \frac{1}{2K} \|z^0 - z\|_P^2.$$

Неравенство Йенсена для выпуклой и вогнутой функции даёт

$$\mathcal{L}\left(\frac{1}{K} \sum_{k=0}^{K-1} x^{k+1}, \lambda\right) - \mathcal{L}\left(x, \frac{1}{K} \sum_{k=0}^{K-1} \lambda^{k+1}\right) \leq \frac{1}{2K} \|z^0 - z\|_P^2.$$

■

Л14 Методы редукции дисперсии

В Параграфе Л5 мы рассмотрели стохастический градиентный спуск и увидели, что его точность ограничена дисперсией стохастических градиентов. Рассмотрим методы, которые уменьшают её — *методы редукции дисперсии*. Они предназначены для решения задачи минимизации эмпирического риска:

$$\min_{x \in \mathbb{R}^d} \left[f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x) \right].$$

Далее будем считать, что $\nabla f(x, \xi) = \nabla f_i(x)$, то есть выбор случайной реализации ξ эквивалентен выбору индекса i .

На практике при использовании стохастического градиентного спуска (Алгоритм Л5.1) с постоянным шагом γ на первых итерациях метод ведёт себя почти так же, как градиентный спуск (Алгоритм Л3.1), однако вокруг минимума он начинает осциллировать. В классическом градиентном спуске градиент стремится к нулю по мере приближения к решению, тогда как стохастический градиент, вообще говоря, не обязан обращаться в ноль в точке минимума. Рассмотрим пример, пусть в задаче машинного обучения x^* минимизирует потери по всей выборке, а $f(x, \xi)$ отражает потери только на отдельном сэмпле ξ . Хотя x^* оптимальна в среднем, но нет никаких гарантий, что x^* оптимальна для отдельного элемента выборки. Поэтому в общем случае $\nabla f(x^*, \xi) \neq 0$, и возникает осциллирующий эффект. Это приводит сразу к двум большим недостаткам стохастического градиентного спуска:

1. Метод не сходится к решению при константном γ , только лишь к его окрестности, размер которой зависит от дисперсии стохастических градиентов $\nabla f(x^*, \xi)$ и размера γ ;
2. Скорость сходимости метода даже с уменьшающимся шагом при оптимизации μ -сильно выпуклой целевой функции сублинейная [38].

Основная идея методов редукции дисперсии заключается в том, чтобы сконструировать аппроксимацию полного градиента g^k на каждой итерации так, чтобы при стремлении траектории метода к решению $x^k \rightarrow x^*$, эта аппроксимация стремилась к нулю $g^k \rightarrow \nabla f(x^*) = 0$. На каждой итерации такой метод производит шаг по g^k :

$$x^{k+1} = x^k - \gamma g^k.$$

Прежде чем перейти к конкретным примерам выбора g^k , отметим, что все g^k должны удовлетворять предположению несмещенности (Предположение Л5.1). Начнем обзор конкретных методов с подходов, использующих несмещенные аппроксиматоры.

Л14.1 SAGA

Идея алгоритма SAGA заключается в том, что на каждой итерации k , считая стохастический градиент по индексу i_k , он сохраняет его в y_{i_k} , а затем использует y_i для конструкции аппроксиматора полного градиента.

Алгоритм Л14.1 SAGA

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, значения памяти $y_i^0 = 0$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

```

1: for  $k = 0, 1, \dots, K - 1$  do
2:   Сгенерировать независимо  $i_k \sim U(\overline{1, n})$ 
3:    $g^k = \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k$ 
4:    $y_i^{k+1} = \begin{cases} \nabla f_i(x^k), & i = i_k \\ y_i^k, & i \neq i_k \end{cases}$ 
5:    $x^{k+1} = x^k - \gamma_k g^k$ 
6: end for

```

Выход: x^K

Отметим, что аппроксиматор g^k обладает свойством несмещенности. Действительно, ввиду равномерного и независимого сэмплирования индекса i_k , имеем

$$\mathbb{E} \left[g^k \mid x^k \right] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n y_i^k + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).$$

Перейдем к утверждению о сходимости метода SAGA.

Теорема Л14.1. Пусть задача безусловной стохастической оптимизации Л14 суммы с L -гладкими, выпуклыми функциями f_i и μ -сильно выпуклой целевой функцией f решается с помощью SAGA (Алгоритм Л14.1) с $\gamma_k = \gamma \leq \frac{1}{6L}$. Тогда справедлива следующая оценка сходимости

$$\mathbb{E} [V_k] \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n} \right) \right\}^k \mathbb{E} [V_0],$$

где $V_k = \|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2$.

Более того, при оптимальном выборе шага для достижения точности ε необходимо

$$\mathcal{O} \left(\left[n + \frac{L}{\mu} \right] \log \frac{1}{\varepsilon} \right) \text{ итераций.}$$

Доказательство. Начнем с подстановки шага $x^{k+1} = x^k - \gamma g^k$ в квадрат нормы разности:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k - \nabla f(x^*)\|_2^2.$$

Возьмем условное математическое ожидание по случайности на итерации k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle \mathbb{E} [g^k \mid x^k], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k - \nabla f(x^*)\|_2^2 \mid x^k \right]. \end{aligned}$$

Рассмотрим слагаемое $\mathbb{E} [g^k \mid x^k]$:

$$\begin{aligned}\mathbb{E} [g^k \mid x^k] &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k \mid x^k \right] \\ &= \mathbb{E} \left[\nabla f_{i_k}(x^k) - y_{i_k}^k \mid x^k \right] + \frac{1}{n} \sum_{i=1}^n y_i^k \\ &= \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - y_i^k) + \frac{1}{n} \sum_{i=1}^n y_i^k = \nabla f(x^k).\end{aligned}$$

Теперь рассмотрим $\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k]$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*) \right. \right. \\ &\quad \left. \left. + \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Воспользуемся тем, что $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 2\mathbb{E} [\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 \mid x^k] \\ &\quad + 2\mathbb{E} \left[\left\| \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^*) \right\|_2^2 \mid x^k \right].\end{aligned}$$

Заметим, что если во втором слагаемом взять ξ равным $\nabla f_{i_k}(x^*) - y_{i_k}^k$, то получим дисперсию $\mathbb{E} [\|\xi - \mathbb{E} [\xi \mid x^k]\|_2^2 \mid x^k]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E} [\xi^2]$:

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 2\mathbb{E} [\|\nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^*)\|_2^2 \mid x^k] \\ &\quad + 2\mathbb{E} [\|\nabla f_{i_k}(x^*) - y_{i_k}^k\|_2^2 \mid x^k].\end{aligned}$$

Раскроем математическое ожидание, пользуясь гладкостью и выпуклостью f_i (Теорема Л2.5):

$$\begin{aligned}\mathbb{E} [\|g^k - \nabla f(x^*)\|_2^2 \mid x^k] &\leq 4L \cdot \frac{1}{n} \sum_{i=1}^n (f_i(x^k) - f_i(x^*) - \langle \nabla f_i(x^*), x^k - x^* \rangle) \\ &\quad + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \\ &= 4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2.\end{aligned}$$

Собирая всё вместе, получаем:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] &\leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \gamma^2 \left(4L(f(x^k) - f^*) + 2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \right). \end{aligned}$$

Воспользуемся μ -сильной выпуклостью функции f :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \middle| x^k \right] &\leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - 2\gamma L)(f(x^k) - f^*) \\ &\quad + 2\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2. \end{aligned}$$

Пришли к тому, что если $y_i^k \rightarrow f_i(x^*)$, то есть линейная сходимость. Возьмем полное математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \right] &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] - 2\gamma(1 - 2\gamma L) \mathbb{E} \left[f(x^k) - f^* \right] \\ &\quad + 2\gamma^2 \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \right]. \end{aligned}$$

Теперь рассмотрим, как ведет себя $\mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|_2^2 \middle| x^k \right]$:

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \middle| x^k \right] &= \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \\ &\quad + \frac{1}{n} \cdot \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^*)\|_2^2. \end{aligned}$$

Воспользуемся выпуклостью и гладкостью f_i (Теорема Л2.5):

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \middle| x^k \right] &\leq \left(1 - \frac{1}{n} \right) \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \\ &\quad + \frac{2L}{n} (f(x^k) - f^*). \end{aligned}$$

Возьмем полное математическое ожидание:

$$\begin{aligned} \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] &\leq \left(1 - \frac{1}{n} \right) \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ &\quad + \frac{2L}{n} \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Получилось две «сходящиеся» последовательности, осталось их аккуратно «сшить». Возьмем $M > 0$ и сложим две рекурренты, которые получились выше:

$$\begin{aligned} &\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + M\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ &\leq (1 - \mu\gamma) \mathbb{E} \left[\|x^k - x^*\|_2^2 \right] + \left(1 + \frac{2}{M} - \frac{1}{n} \right) \mathbb{E} \left[\frac{M\gamma^2}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ &\quad - 2\gamma \left(1 - 2\gamma L - \frac{\gamma ML}{n} \right) \mathbb{E} \left[f(x^k) - f^* \right]. \end{aligned}$$

Возьмем $M = 4n$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq (1 - \mu\gamma) \mathbb{E} [\|x^k - x^*\|_2^2] + \left(1 - \frac{1}{2n}\right) \mathbb{E} \left[4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right] \\ & \quad - 2\gamma(1 - 6\gamma L) \mathbb{E} [f(x^k) - f^*]. \end{aligned}$$

Теперь потребуем $\gamma \leq \frac{1}{6L}$:

$$\begin{aligned} & \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|_2^2 \right] \\ & \leq \max \left\{ (1 - \mu\gamma), \left(1 - \frac{1}{2n}\right) \right\} \mathbb{E} \left[\|x^k - x^*\|_2^2 + 4n\gamma^2 \cdot \frac{1}{n} \sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|_2^2 \right]. \end{aligned}$$

■

Получили сходимость, но не по обычному критерию. Суть критерия в отражении физики как сходимости $x^k \rightarrow x^*$, так и $y_i^k \rightarrow \nabla f_i(x^*)$, что и закладывалось в метод.

Замечание Л14.1. Из сходимости по $\mathbb{E}[V_k]$ следует и сходимость по $\mathbb{E}[\|x^k - x^*\|_2^2]$.

Замечание Л14.2. Нельзя взять M огромным, так как M влияет на критерий сходимости, который также будет расти с ростом M . При этом сходимости лучше, чем $(1 - \frac{1}{n})$, не добиться.

Л14.2 SVRG

В предыдущем разделе мы рассмотрели метод SAGA, который воплощает основную идею редукции дисперсии. Однако этот метод обладает существенным недостатком — он требует хранения матрицы размера $n \times d$, где d — размерность задачи, а n — количество функций в постановке конечной суммы. В то же время, классический стохастический градиентный спуск тратит $\mathcal{O}(d)$ памяти, ведь хранит только текущее состояние оптимизируемых параметров модели. В этом разделе мы рассмотрим метод SVRG, который эффективно по памяти реализует идею редукции дисперсии. Основная идея этого метода заключается в том, чтобы уйти от запоминания стохастических градиентов по каждому индексу i . Вместо восстановления полного градиента с запозданием, как это делает SAGA, SVRG считает полный градиент раз в некоторое время. Такая точка называется *референсной*, а промежуток между подсчетами полного градиента — *эпохой*.

Алгоритм Л14.2 SVRG

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```
1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:   for  $k = 0, 1, \dots, K - 1$  do
4:     Сгенерировать независимо  $i_k \sim U(1, n)$ 
5:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^t) + \nabla f(y^t)$ 
6:      $x^{k+1} = x^k - \gamma_k g^k$ 
7:   end for
8:    $y^{t+1} = x^K$ 
9: end for
Выход:  $y^T$ 
```

Аппроксиматор в SVRG несмещенный:

$$\mathbb{E}[g^k | x^k] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x^k) - \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^t) + \nabla f(y^t) = \nabla f(x^k).$$

Аналогично SAGA можно показать, что из того что $y^k \rightarrow x^*$, следует, что $g^k \rightarrow 0$. Итерационная сложность сходимости метода — $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$ совпадает с SAGA. Однако необходимость вычислять полный градиент даже раз в эпоху, а также два стохастических градиента на каждой итерации требует дополнительных вычислительных мощностей.

Л14.3 SARAH

В предыдущем разделе мы рассмотрели метод редукции дисперсии SVRG, эффективный по памяти. При этом, SVRG не ухудшает теоретическую оценку сходимости SAGA. Однако на практике оказывается, что использование градиента в начальной точке эпохи дестабилизирует траекторию сходимости метода. Решая квадратичную задачу минимизации всего лишь с $d = 2$, $n = 5$, мы наблюдаем траекторию, как на Рисунке Л14.1.




Рис. Л14.1: Сравнение методов SVRG и SARAH на квадратичной функции.

По этой причине, был разработан метод SARAH, конструирующий аппроксиматор таким образом, чтобы использовать градиенты в недавних точках. Он использует идею рекурсивного накопления градиентов. Такая схема на каждой итерации добавляет к аппроксиматору направление градиента в новой точке, при этом вычитая старое направление. В то время как полный градиент в референсной точке из SVRG мешает сходиться к решению, добавляя вклад старого направления в текущий шаг, SARAH динамично подстраивает траекторию под правильное направление к минимуму (Рисунок Л14.1).

Алгоритм Л14.3 SARAH

Вход: стартовая точка $y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций в эпохе K , количество эпох T

```

1: for  $t = 0, 1, \dots, T - 1$  do
2:    $x^0 = y^t$ 
3:    $g^{-1} = \nabla f(x^0)$ 
4:   for  $k = 0, 1, \dots, K - 1$  do
5:     Сгенерировать независимо  $i_k \sim U(\overline{1}, n)$ 
6:      $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}$ 
7:      $x^{k+1} = x^k - \gamma_k g^k$ 
8:   end for
9:    $y^{t+1} = x^K$ 
10: end for
Выход:  $y^K$ 

```

Ввиду такой конструкции аппроксиматора, он является смещенным, что усложняет теоретический анализ. Однако SARAH все еще сохраняет идею редукции дисперсии: при $x^k \rightarrow x^*$ имеем, что $g^k \rightarrow 0$. SARAH, аналогично SVRG имеет итерационную сложность $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$, а также требует периодического вычисления полного градиента и подсчета двух стохастических градиентов на каждой итерации. Тем не менее, SARAH решает проблему с нестабильной траекторией сходимости.

Л14.4 Loopless версии алгоритмов

Отличительной чертой разобранных выше методов SVRG и SARAH является структура, состоящая из двух циклов. Такое построение алгоритма обладает двумя недостатками:

1. Фиксированная длина эпохи в классическом анализе SVRG имеет порядок $\frac{L}{\mu}$, что делает эпоху очень большой ввиду маленьких значений μ на практике;
2. При естественной длине эпохи порядка n метод не достигает скорости сходимости $\mathcal{O}\left(\left[n + \frac{L}{\mu}\right] \log \frac{1}{\varepsilon}\right)$.

По этим причинам были предложены методы редукции дисперсии, которые не используют фиксированную длину эпохи, а значит ограничиваются структурой с одним циклом. Такие модификации называются *loopless* версиями, и как правило используют случайность для решения сделать шаг по аппроксиматору или по полному градиенту:

$$x^{k+1} = x^k - \gamma_k \begin{cases} g^k, & \text{с вероятностью } p \\ \nabla f(x^k), & \text{с вероятностью } 1 - p \end{cases}.$$

Алгоритм Л14.4 L-SVRG (Loopless SVRG)

Вход: стартовая точка $x^0 = y^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, вероятность обновления $p \in (0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
- 3: $g^k = \nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k) + \nabla f(y^k)$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: $y^{k+1} = \begin{cases} x^k, & \text{с вероятностью } p \\ y^k, & \text{с вероятностью } 1 - p \end{cases}$
- 6: **end for**

Выход: x^K

Алгоритм Л14.5 PAGE (Loopless SARAH)

Вход: стартовая точка $x^{-1} = x^0 \in \mathbb{R}^d$, стартовый аппроксиматор $g^{-1} = \nabla f(x^{-1})$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, вероятность обновления $p \in (0, 1]$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $i_k \sim U(\overline{1, n})$
- 3: $g^k = \begin{cases} \nabla f(x^k), & \text{с вероятностью } p \\ \nabla f_{i_k}(x^k) - \nabla f_{i_k}(x^{k-1}) + g^{k-1}, & \text{с вероятностью } 1 - p \end{cases}$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Выход: x^T

Итерационная сложность алгоритмов равна $\mathcal{O}\left(\frac{1}{p} + n + \frac{L}{\mu} + \frac{Lpn}{\mu}\right)$. Таким образом можно выбрать вероятность подсчета полного градиента $p = \frac{1}{n}$, естественным образом связав ее с количеством функций из постановки, а не с числом обусловленности задачи. При этом, сложность сходимости остается $\mathcal{O}\left(n + \frac{L}{\mu}\right)$, как и в базовых версиях алгоритмов.

Л14.5 Унифицированный анализ методов редукции дисперсии

Ранее были изучены отдельные методы редукции дисперсии и их особенности. Однако все эти подходы можно рассматривать как частные случаи единого более общего метода. Такой взгляд позволяет описывать и анализировать различные стохастические алгоритмы редукции дисперсии в рамках одной унифицированной модели. Ниже мы сформулируем ключевое предположение, на котором основан этот подход. Схема обновления стохастических методов может быть обобщена следующим образом:

Алгоритм Л14.6 Общая схема стохастического градиентного спуска

Вход: начальная точка x^0 , число итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать стохастическую переменную ξ^k
- 3: Вычислить стохастическую оценку градиента: $g^k = g^k(x^k, \xi^k, \text{history})$
- 4: Обновить точку: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Предположение Л14.1. Пусть $\{x^t\}$ — последовательность итераций Алгоритма Л14.6, а $\{\xi_t\}$ — случайные величины, порождаемые им. Предположим, что существуют неотрицательные константы A, B, C и параметры $\rho_1, \rho_2 \in (0, 1]$, а также (возможно случайная) последовательность $\{\sigma_t^2\}$, такие что для всех k выполняются неравенства:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &\leq (1 - \rho_1) \|g^{k-1} - \nabla f(x^{k-1})\|_2^2 + A\sigma_{k-1}^2 \\ &\quad + BL^2 \|x^k - x^{k-1}\|_2^2, \\ \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq (1 - \rho_2) \sigma_{k-1}^2 + CL^2 \|x^k - x^{k-1}\|_2^2. \end{aligned}$$

Это предположение описывает, как ведёт себя ошибка стохастического аппроксиматора градиента при последовательных итерациях алгоритма. Параметры ρ_1 и ρ_2 определяют степень сжатия ошибок: чем они больше, тем быстрее различие между стохастической оценкой и истинным градиентом уменьшается при приближении к оптимуму. Константы A, B и C контролируют влияние стохастичности и длины шага на поведение метода. Таким образом, предположение Л14.1 задаёт общую схему, в рамках которой можно описывать как простейший стохастический градиентный спуск, так и более сложные методы с редукцией дисперсии, включая SAGA, SVRG, SARAH. Важно, что данное предположение не требует, чтобы g^k являлся несмещённой оценкой градиента. Кроме того, оно не предполагает использования больших батчей или строгих свойств задачи, что повышает общность получаемых результатов. После введения основного предположения, описывающего поведение стохастической ошибки градиентного оценщика, мы можем перейти к выводам, характеризующим сходимость рассматриваемых алгоритмов. Чтобы обосновать сделанные предположения, начнём с анализа невыпуклой и RL-задачи (условие Поляка–Лоясиевича).

Определение Л14.1. Непрерывно дифференцируемая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ удовлетворяет условию Поляка–Лоясиевича с константой $\mu > 0$, если для всех $x \in \mathbb{R}^d$ выполнено

$$f(x) - f^* \leq \frac{1}{2\mu} \|\nabla f(x)\|_2^2.$$

В невыпуклом случае любой метод, описываемый Алгоритмом Л14.6, обладает сублинейной скоростью сходимости.

Утверждение Л14.1 (Лемма 2 из [20]). Пусть задача безусловной стохастической оптимизации Л14 суммы с L -гладкой целевой функцией f решается с помощью Алгоритма Л14.1. Тогда справедлива следующая оценка сходимости

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) - \frac{\gamma_k}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma_k} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma_k}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Теорема Л14.2. Пусть задача безусловной стохастической оптимизации Л14 с L -гладкой целевой функцией f решается с помощью Алгоритма Л14.6 с

$$\gamma_k = \gamma \leq \frac{1}{L} \left(1 + \sqrt{\frac{B\rho_2 + AC}{\rho_1\rho_2}} \right)^{-1}$$

в Предположении Л14.6. Тогда справедлива следующая оценка сходимости:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \left[\|\nabla f(x^k)\|_2^2 \right] \leq \frac{2V^0}{\gamma K},$$

где $V_0 = f(x^0) - f^* + \frac{\gamma}{2\rho_1} \|g^0 - \nabla f(x^0)\|_2^2 + \frac{\gamma A}{2\rho_1 \rho_2} \sigma_0^2$.

Доказательство. Запишем результат Утверждения Л14.1:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Добавим $\frac{\gamma}{2\rho_1} \|g^{k+1} - \nabla f(x^{k+1})\|_2^2$, $\frac{\gamma A}{2\rho_1 \rho_2} \sigma_{k+1}^2$ к обоим частям и возьмем условное математическое ожидание:

$$\begin{aligned} \mathbb{E} [V_{k+1} \mid x^{k+1}] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{2\rho_1} \mathbb{E} \left[\|g^{k+1} - \nabla f(x^{k+1})\|_2^2 \mid x^{k+1} \right] + \frac{\gamma A}{2\rho_1 \rho_2} \mathbb{E} [\sigma_{k+1}^2 \mid x^{k+1}]. \end{aligned}$$

Воспользуемся Предположением Л14.6:

$$\begin{aligned} \mathbb{E} [V_{k+1} \mid x^{k+1}] &\leq f(x^k) - f^* + \frac{\gamma}{2\rho_1} \|g^k - \nabla f(x^k)\|_2^2 + \frac{\gamma A}{2\rho_1 \rho_2} \sigma_k^2 - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + \gamma^2 L^2 \frac{B\rho_2 + AC}{\rho_1 \rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Учтем, что $\gamma^2 L^2 \frac{B\rho_2 + AC}{\rho_1 \rho_2} + \gamma L \leq 1$ и возьмем полное математическое ожидание:

$$\mathbb{E} [V_{k+1}] \leq \mathbb{E} [V_k] - \frac{\gamma}{2} \mathbb{E} [\|\nabla f(x^k)\|_2^2],$$

откуда получаем, что

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [\|\nabla f(x^k)\|_2^2] \leq \frac{2V^0}{\gamma K}.$$

■

Таким образом, даже без дополнительных условий на выпуклость функции, алгоритм демонстрирует уменьшение нормы градиента в среднем со скоростью $\mathcal{O}(\frac{1}{K})$, что соответствует классическому сублинейному поведению стохастических методов. Далее приведем теорему сходимости для функции, удовлетворяющей условию Поляка–Лоясиевича.

Теорема Л14.3. Пусть задача безусловной стохастической оптимизации Л14 с L -гладкой целевой функцией f , удовлетворяющей условию Поляка–Лоясиевича,

решается с помощью Алгоритма Л14.6 с

$$\gamma_k = \gamma \leq \min \left\{ \frac{1}{L} \left(1 + \sqrt{\frac{B\rho_2 + 2AC}{\rho_1\rho_2}} \right)^{-1}, \frac{\min\{\rho_1, \rho_2\}}{2\mu} \right\}$$

в Предположении Л14.6. Тогда справедлива следующая оценка сходимости:

$$\mathbb{E}[V_K] \leq (1 - \gamma\mu)^K V_0,$$

где $V_k = f(x^k) - f^* + \frac{\gamma}{\rho_1} \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \sigma_k^2$.

Доказательство. Запишем результат Утверждения Л14.1:

$$\begin{aligned} f(x^{k+1}) - f^* &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2. \end{aligned}$$

Добавим $\frac{\gamma}{\rho_1} \|g^{k+1} - \nabla f(x^{k+1})\|_2^2$, $\frac{2\gamma A}{\rho_1\rho_2} \sigma_{k+1}^2$ к обоим частям и возьмем условное математическое ожидание:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^k] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 + \left(\frac{L}{2} - \frac{1}{2\gamma} \right) \|x^{k+1} - x^k\|_2^2 \\ &\quad + \frac{\gamma}{2} \|g^k - \nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{\rho_1} \mathbb{E}[\|g^{k+1} - \nabla f(x^{k+1})\|_2^2 | x^{k+1}] + \frac{2\gamma A}{\rho_1\rho_2} \mathbb{E}[\sigma_{k+1}^2 | x^{k+1}]. \end{aligned}$$

Воспользуемся Предположением Л14.6:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^{k+1}] &\leq f(x^k) - f^* - \frac{\gamma}{2} \|\nabla f(x^k)\|_2^2 \\ &\quad + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + 2\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Воспользуемся условием Поляка–Лоясиевича:

$$\begin{aligned} \mathbb{E}[V_{k+1} | x^{k+1}] &\leq (1 - \gamma\mu)(f(x^k) - f^*) \\ &\quad + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2 \\ &\quad + \frac{1}{2\gamma} \left(\gamma L - 1 + 2\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} \right) \|x^{k+1} - x^k\|_2^2. \end{aligned}$$

Учтем, что $\gamma^2 L^2 \frac{B\rho_2 + 2AC}{\rho_1\rho_2} + \gamma L \leq 1$ и возьмем полное математическое ожидание:

$$\mathbb{E}[V_{k+1}] \leq (1 - \gamma\mu)(f(x^k) - f^*) + \frac{\gamma}{\rho_1} \left(1 - \frac{\rho_1}{2} \right) \|g^k - \nabla f(x^k)\|_2^2 + \frac{2\gamma A}{\rho_1\rho_2} \left(1 - \frac{\rho_2}{2} \right) \sigma_k^2,$$

Следовательно, если $\gamma \leq \frac{\min\{\rho_1, \rho_2\}}{2\mu}$, то

$$V_{k+1} \leq (1 - \gamma\mu)V_k \leq (1 - \gamma\mu)^{k+1} V_0.$$

■

Этот результат показывает, что при выполнении условия Поляка–Лоясиевича и разумном выборе шага γ методы редукции дисперсии достигают экспоненциального уменьшения функционального разрыва, объединяя тем самым свойства как стохастического градиентного спуска, так и его ускоренных вариантов. Далее докажем, что обобщаемые выше методы удовлетворяют Предположению Л14.1. Будем рассматривать батчированные версии и для начала остановимся на вспомогательном утверждении.

Утверждение Л14.2 (Лемма А.1 из [18]). Пусть $x_1, \dots, x_n \in \mathbb{R}^d$ — произвольные вектора с нулевой суммой:

$$\sum_{i=1}^n x_i = 0$$

и S размера b из $U(1, n)$. Тогда

$$\mathbb{E} \left[\left\| \frac{1}{b} \sum_{i \in S} x_i \right\|_2^2 \right] \leq \frac{1}{bn} \sum_{i=1}^n \|x_i\|_2^2.$$

Л14.5.1 SAGA

Сформулируем теорему, устанавливающую параметры Предположения Л14.1 для SAGA.

Теорема Л14.4. SAGA (Алгоритм Л14.1) удовлетворяет предположению Л14.1 с:

$$A = \frac{1}{b} \left(1 + \frac{b}{2n} \right), \quad B = \frac{1}{b} \left(1 + \frac{2n}{b} \right), \quad C = \frac{2n}{b},$$

$$\rho_1 = 1, \quad \rho_2 = \frac{b}{2n},$$

$$\sigma_k^2 = \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^{k+1}\|_2^2.$$

Доказательство. Ограничим разницу между аппроксиматором градиента и реальным градиентом:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} (\nabla f_{i_k}(x^k) - y_{i_k}^k) + \frac{1}{n} \sum_{i=1}^n y_i^k - \nabla f(x^k) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} \left(\nabla f_{i_k}(x^k) - y_{i_k}^k - \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - y_i^k) \right) \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л14.2:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \left\| \nabla f_i(x^k) - y_i^k - \left(\frac{1}{n} \sum_{j=1}^n (\nabla f_j(x^k) - y_j^k) \right) \right\|_2^2$$

Если взять ξ равным $\nabla f_i(x^k) - y_i^k$, то получим дисперсию $\mathbb{E} \left[\|\xi - \mathbb{E}[\xi]\|_2^2 \right]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E}[\xi^2]$:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^k\|_2^2$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] &\leq \frac{1}{bn} \left(1 + \frac{2n}{b} \right) \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^{k-1})\|_2^2 \\ &\quad + \frac{1}{bn} \left(1 + \frac{b}{2n} \right) \sum_{i=1}^n \|\nabla f_i(x^{k-1}) - y_i^k\|_2^2. \end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{b} \left(1 + \frac{b}{2n} \right) \sigma_{k-1}^2 + \frac{1}{b} \left(1 + \frac{2n}{b} \right) \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

Теперь посмотрим на σ_k^2 :

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^{k+1}\|_2^2 \mid x^k \right] = \left(1 - \frac{b}{n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - y_i^k\|_2^2 \\ &= \left(1 - \frac{b}{n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(x^{k-1}) + \nabla f_i(x^{k-1}) - y_i^{k-1}\|_2^2. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq \left(1 - \frac{b}{n} \right) \left(1 + \frac{b}{2n} \right) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(x^{k-1}) - y_i^{k-1}\|_2^2 \\ &\quad + \left(1 - \frac{b}{n} \right) \left(1 + \frac{2n}{b} \right) \|\nabla f_i(x^k) - \nabla f_i(x^{k-1})\|_2^2. \end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\sigma_k^2 \mid x^k \right] \leq \left(1 - \frac{b}{2n} \right) \sigma_{k-1}^2 + \frac{2n}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л14.5.2 L-SVRG

Сформулируем теорему, показывающую соответствие L-SVRG унифицированной схеме анализа.

Теорема Л14.5. L-SVRG (Алгоритм Л14.4) удовлетворяет Предположе-

нию Л14.1 с:

$$\begin{aligned} A &= \frac{2}{b}, \quad B = \frac{2}{b}, \quad C = 1 + \frac{2}{p}, \\ \rho_1 &= 1, \quad \rho_2 = \frac{p}{2}, \\ \sigma_k^2 &= \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^{k+1}) - \nabla f_i(x^k)\|_2^2. \end{aligned}$$

Доказательство. Ограничим разницу между аппроксиматором градиента и реальным градиентом:

$$\begin{aligned} &\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} (\nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k)) + \frac{1}{n} \sum_{i=1}^n \nabla f_i(y^k) - \nabla f(x^k) \right\|_2^2 \mid x^k \right] \\ &= \mathbb{E} \left[\left\| \frac{1}{b} \sum_{i_k \in S} \left(\nabla f_{i_k}(x^k) - \nabla f_{i_k}(y^k) - \frac{1}{n} \sum_{i=1}^n (\nabla f_i(x^k) - \nabla f_i(y^k)) \right) \right\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л14.2:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(y^k) - \left(\frac{1}{n} \sum_{j=1}^n (\nabla f_j(x^k) - \nabla f_j(y^k)) \right) \right\|_2^2$$

Если взять ξ равным $\nabla f_i(x^k) - \nabla f_i(y^k)$, то получим дисперсию $\mathbb{E} [\|\xi - \mathbb{E}[\xi]\|_2^2]$. Воспользуемся тем, что $\mathbb{D}\xi \leq \mathbb{E}[\xi^2]$:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{1}{bn} \sum_{i=1}^n \|\nabla f_i(x^k) - \nabla f_i(y^k)\|_2^2.$$

Продолжим преобразования:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{2}{bn} \sum_{i=1}^n \|\nabla f_i(y^k) - \nabla f_i(x^{k-1})\|_2^2 + \frac{2}{bn} \sum_{i=1}^n \|f_i(x^k) - f_i(x^{k-1})\|_2^2.$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\|g^k - \nabla f(x^k)\|_2^2 \mid x^k \right] \leq \frac{2}{b} \sigma_{k-1}^2 + \frac{2}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

Теперь посмотрим на σ_k^2 :

$$\begin{aligned} \mathbb{E} [\sigma_k^2 \mid x^k] &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^{k+1}) - \nabla f_i(x^k)\|_2^2 \mid x^k \right] \\ &= (1-p) \frac{1}{n} \sum_{i=1}^n \|\nabla f_i(y^k) - \nabla f_i(x^k)\|_2^2. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned}
\mathbb{E} \left[\sigma_k^2 \mid x^k \right] &\leq (1-p) \left(1 + \frac{p}{2} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(y^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\quad + (1-p) \left(1 + \frac{2}{p} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\leq \left(1 - \frac{p}{2} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(y^k) - \nabla f_i(x^{k-1}) \right\|_2^2 \\
&\quad + \left(1 + \frac{2}{p} \right) \frac{1}{n} \sum_{i=1}^n \left\| \nabla f_i(x^k) - \nabla f_i(x^{k-1}) \right\|_2^2.
\end{aligned}$$

Воспользуемся L -гладкостью:

$$\mathbb{E} \left[\sigma_k^2 \mid x^k \right] \leq \left(1 - \frac{p}{2} \right) \sigma_{k-1}^2 + \left(1 + \frac{2}{p} \right) \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л14.5.3 PAGE

Сформулируем теорему для PAGE. Примечательно, что в отличие от SAGA и L-SVRG, здесь $\sigma_k^2 = 0$, что радикально упрощает потенциальную функцию и структуру доказательства сходимости.

Теорема Л14.6. PAGE (Алгоритм Л14.5) удовлетворяет Предположению Л14.1 с:

$$\begin{aligned}
A &= 0, \quad B = \frac{1-p}{b}, \quad C = 0, \\
\rho_1 &= p, \quad \rho_2 = 1, \\
\sigma_k^2 &= 0.
\end{aligned}$$

Доказательство. Воспользуемся Леммой 3 из [20]:

$$\mathbb{E} \left[\left\| \nabla f(x^k) - g^k \right\|_2^2 \mid x^k \right] \leq (1-p) \left\| \nabla f(x^{k-1}) - g^{k-1} \right\|_2^2 + \frac{1-p}{b} \cdot L^2 \|x^k - x^{k-1}\|_2^2.$$

■

Л15 Методы нулевого порядка и координатный спуск

В этом параграфе рассматриваются методы, направленные на снижение вычислительной стоимости одной итерации градиентного спуска. Сначала обсуждаются координатные методы, далее показывается, что та же идея может быть использована, когда градиент недоступен (zero-order оптимизация). Рассмотрим задачу безусловной оптимизации

$$\min_{x \in \mathbb{R}^d} f(x). \quad (\text{Л15.1})$$

Л15.1 Координатный спуск

Координатные методы — это алгоритмы оптимизации, где на каждой итерации обновляется лишь одна (или несколько) координат вектора параметров, при этом остальные фиксируются. Приведем мотивационный пример с линейной регрессией.

Пример Л15.1. Рассмотрим квадратичную задачу

$$\min_{x \in \mathbb{R}^d} f(x) := \frac{1}{2} \|Ax - b\|_2^2 = \frac{1}{2} \sum_{i=1}^n (A_{i,:}x - b_i)^2 = \frac{1}{2} \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle x_j - \frac{1}{2} \langle b, Ax - b \rangle.$$

где $A \in \mathbb{R}^{n \times d}$ — матрица объект-признак, $A_{i,:}$ — i -ая строка матрицы A , $A_{:,j}$ — j -ый столбец матрицы A , $b \in \mathbb{R}^n$ — метки. Полный градиент в этой задаче имеет вид

$$\nabla f(x) = A^\top (Ax - b) = \sum_{i=1}^n A_{i,:}^\top (A_{i,:}x - b_i) = \sum_{j=1}^d \langle A_{:,j}, Ax - b \rangle e_j, \quad (\text{Л15.2})$$

где e_j — j -ый базисный вектор. Рассмотрим два классических подхода к удешевлению стоимости одной итерации вычисления градиентного шага.

1. Стохастический выбор строки (стохастический градиентный спуск по объектам).

На итерации k равномерно выбираем объект $i_k = \overline{1, n}$ и формируем оценку градиента как одно слагаемое из суммы (Л15.2):

$$g^k = n A_{i_k,:}^\top (A_{i_k,:}x^k - b_{i_k}), \\ x^{k+1} = x^k - \gamma_k g^k.$$

Этот шаг использует только одну строку матрицы A . Множитель n нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$. Стоимость одной итерации в n раз дешевле, чем полный градиент, так как выбирается 1 объект из суммы с n слагаемыми.

2. Стохастический выбор столбца (координатный шаг).

На итерации k равномерно выбираем координату градиента $j_k = \overline{1, d}$ и формируем оценку градиента как одну координату из вектора (Л15.2):

$$g^k = d \langle Ax^k - b, A_{:,j_k} \rangle e_{j_k}, \\ x^{k+1} = x^k - \gamma_k g^k.$$

Этот шаг использует только один столбец матрицы A . Множитель d нужен для несмещенности: $\mathbb{E}[g^k] = \nabla f(x^k)$. Стоимость одной итерации в d раз дешевле, чем полный градиент, так как делается 1 скалярное произведение вместо d .

Таким образом, в квадратичной задаче две симметричные экономии достигаются выбором строк или столбцов, что соответствует домножению каждую итерацию на одну случайную строку или столбец матрицы A соответственно.

В этом параграфе мы сосредоточимся на втором подходе, со стохастическими методами можно ознакомиться в Параграфах Л15 и Л14. Перейдём к формальному описанию алгоритма координатного спуска, в котором вместо полного градиента оценивается и используется одна его координата.

Алгоритм Л15.1 Координатный спуск

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
 - 2: Сгенерировать независимо $i_k \sim U(\overline{1, d})$
 - 3: $x^{k+1} = x^k - \gamma_k d[\nabla f(x^k)]_{i_k} e_{i_k}$
 - 4: **end for**
- Выход:** x^K
-

Заметим, что при равномерном выборе координаты стохастический градиент обладает двумя ключевыми свойствами — он остаётся несмещённой оценкой полного градиента и имеет контролируруемую дисперсию.

Утверждение Л15.1. Пусть индекс $i_k = \overline{1, d}$ выбирается независимо и равномерно на каждой итерации. Тогда для любой точки $x \in \mathbb{R}^d$ выполняются равенства:

$$\mathbb{E} [d[\nabla f(x)]_{i_k} e_{i_k}] = \nabla f(x), \quad \mathbb{E} [\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2] = d \|\nabla f(x)\|_2^2.$$

Доказательство. Покажем первое равенство:

$$\mathbb{E} [d[\nabla f(x)]_{i_k} e_{i_k}] = \sum_{i=1}^d \frac{1}{d} d[\nabla f(x)]_i e_i = \nabla f(x).$$

Покажем второе равенство:

$$\mathbb{E} [\|d[\nabla f(x)]_{i_k} e_{i_k}\|_2^2] = \sum_{i=1}^d \frac{1}{d} d^2 [\nabla f(x)]_i^2 \|e_i\|_2^2 = d \|\nabla f(x)\|_2^2.$$

■

Утверждение Л15.1 показывает, что стохастическая координатная оценка градиента $d[\nabla f(x)]_{i_k} e_{i_k}$ несмещена, однако её разброс не является константой: дисперсия масштабируется величиной $\|\nabla f(x)\|_2^2$. Интуитивная причина проста: мы наблюдаем только одну координату из d и затем восстанавливаем масштаб умножением на d . Опираясь на Утверждение Л15.1, которое гарантирует несмещённость и контролируруемую дисперсию стохастической оценки градиента, зафиксируем величину шага и выведем оценку скорости сходимости алгоритма Л15.1.

Теорема Л15.1. Пусть задача безусловной оптимизации (Л15.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью координатного спус-

ка (Алгоритм Л15.1). Тогда при $\gamma_k = \gamma \leq \frac{1}{dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

Доказательство. По определению итерации:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle d[\nabla f(x^k)]_{i_k} e_{i_k}, x^k - x^* \rangle + \gamma^2 \|d[\nabla f(x^k)]_{i_k} e_{i_k}\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \left\langle \mathbb{E} \left[d[\nabla f(x^k)]_{i_k} e_{i_k} \mid x^k \right], x^k - x^* \right\rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|d[\nabla f(x^k)]_{i_k} e_{i_k}\|_2^2 \mid x^k \right]. \end{aligned}$$

Применим Утверждение Л15.1:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle + d\gamma^2 \|\nabla f(x^k)\|_2^2.$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2 - 2\gamma(1 - d\gamma L)(f(x^k) - f^*).$$

При $\gamma \leq \frac{1}{dL}$ последнее слагаемое отрицательно, и остаётся

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq (1 - \mu\gamma) \|x^k - x^*\|_2^2.$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq (1 - \mu\gamma)^k \|x^0 - x^*\|_2^2.$$

■

Одна координатная итерация примерно в d раз дешевле шага полного градиентного спуска, но обычно требуется порядка в d раз больше итераций. В чистом виде это не улучшает асимптотику, однако на практике координатные методы часто выигрывают по времени до заданной точности за счёт разреженности данных и дешёвых локальных операций по столбцам, неравномерного выбора координат с вероятностями, пропорциональными координатным константам Липшица, а также блочно-координатных, параллельных и асинхронных обновлений, эффективно использующих современную вычислительную архитектуру. В неквадратичных задачах вычислить одну координату градиента не всегда дешевле, чем полный градиент. Чтобы получить $[\nabla f(x)]_i$, нередко требуется выполнить почти всю вычислительную цепочку и лишь затем извлечь i -ую компоненту. Поэтому координатный шаг не всегда экономит ресурсы. Характерный неблагоприятный пример — логистическая регрессия: градиент есть сумма по всем объектам, и для любой координаты нужен полный проход по данным. Фактически стоимость одной координаты совпадает со стоимостью полного градиента. В то же время при обучении нейронных сетей ситуация благоприятнее из-за структуры обратного распространения ошибки: градиенты считаются от последнего слоя к первому, и, если обновлять только слой i , можно не вычислять градиенты для слоёв $1, \dots, i-1$. Это уменьшает объём обратных вычислений и снижает пиковые требования к памяти, что даёт реальное ускорение и экономию ресурсов при координатных или

блочно-координатных обновлениях по слоям. Когда прямой градиент недоступен или слишком дорог, координатная логика получает «вторую жизнь», переходя к оценкам направленных производных по случайным направлениям, мы естественно приходим к методам нулевого порядка (ZO), где двухточечные разности выступают оценками градиента.

Л15.2 Координатные идеи в безградиентной постановке

В оптимизации нулевого порядка алгоритм взаимодействует с целевой функцией через её значение. Отсутствие доступа к градиенту вынуждает заменять его на аппроксимацию по значениям функции, что естественным образом сочетается с координатными идеями — можно оценивать лишь нужные координатные направления и выполнять дешёвые обновления. Ключевой приём — аппроксимация направленной производной по значениям функции вдоль направления $e \in \mathbb{R}^d$. Рассмотрим три стандартные схемы.

$$g(x, e) = \begin{cases} d \frac{f(x+\tau e) - f(x-\tau e)}{2\tau} e & \text{(двухточечная симметричная)} \\ \frac{f(x+\tau e) - f(x)}{\tau} e & \text{(двухточечная односторонняя)} \\ \frac{f(x+\tau e)}{\tau} e & \text{(одноточечная),} \end{cases} \quad (\text{Л15.3})$$

где $\tau > 0$ — параметр сглаживания. Двухточечная симметричная схема имеет наименьшее смещение. Двухточечная односторонняя схема используется, когда $f(x)$ уже было посчитано. Одноточечная схема наиболее дешёвая по вычислениям, но обладает большим смещением. Множитель d в (Л15.3) появляется по той же причине, что и в координатных методах: усреднение по случайно выбранному направлению «размазывает» вклад по d осям, и чтобы восстановить исходный масштаб градиента, требуется умножение на d . Перейдём к самой интересной части формулы (Л15.3) — выбору направления e , по которому мы будем оптимизировать целевую функцию. Координатный базис $e = e_i$ воспроизводит покоординатный шаг, но охватывает лишь одну компоненту за вызов оракула. Лучше сразу смотреть на все координаты через случайные направления. Самый простой вариант — брать $e \sim \mathcal{N}(0, I_d)$ — такая выборка случайно смешивает все координаты в каждом направлении и в среднем захватывает всю структуру. Ещё лучше выбирать e равномерно на сфере $S^{d-1} := \{e \in \mathbb{R}^d \mid \|e\|_2 = 1\}$: все направления имеют одинаковую норму, что стабилизирует шаги и улучшает оценки, при этом мы также охватываем все координаты.

У читателя мог возникнуть вопрос: почему в (Л15.3) не устремить $\tau \rightarrow 0$ и не получить градиент по определению? В оптимизации нулевого порядка это невозможно из-за доминирующей роли ошибок оракула: на запрос точки возвращается не истинное значение, а зашумлённая величина $\hat{f}$. В оптимизации первого порядка шум также присутствует, однако его влияние обычно существенно слабее, поскольку градиент сглаживает часть вариативности. Исходя из этих соображений, в формуле (Л15.3) следует везде заменить f на $\hat{f}$. Для двухточечной симметричной оценки:

$$g(x, e) = d \frac{\hat{f}(x + \tau e) - \hat{f}(x - \tau e)}{2\tau} e.$$

Л15.2.1 Гладкий μ -сильно выпуклый случай

Подобно координатной оценке первого порядка, двухточечная схема $g(x, e)$ служит стохастической заменой градиента. Ниже формализуем её несмещённость, характер погрешности, а также оценку второго момента.

Утверждение Л15.2. Пусть дана L -гладкая функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ и пусть

$\hat{f}(x) = f(x) + \xi(x)$, где $|\xi(x)| \leq \Delta$ для всех $x \in \mathbb{R}^d$. Определим оценку градиента

$$g(x, e) = d \frac{\hat{f}(x + \tau e) - \hat{f}(x - \tau e)}{2\tau} e, \quad e \sim U(S^{d-1}).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливы оценки:

1. $\|\mathbb{E}_{e \sim U(S^{d-1})}[g(x, e)] - \nabla f(x)\|_2 \leq L\tau + \frac{d\Delta}{\tau},$
2. $\mathbb{E}_{e \sim U(S^{d-1})}\|g(x, e)\|_2^2 = 4d\|\nabla f(x)\|_2^2 + 4L^2d^2\tau^2 + 2\frac{d^2\Delta^2}{\tau^2}.$

Доказательство. Разложим оценку на две части $g(x, e) = g^{\det} + g^{\text{noise}}$:

$$g^{\det} = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad g^{\text{noise}} = d \frac{\xi(x + \tau e) - \xi(x - \tau e)}{2\tau} e.$$

1. Для шумовой составляющей имеем:

$$\|\mathbb{E}[g^{\text{noise}}]\|_2 = \frac{d}{2\tau} \|\mathbb{E}[(\xi(x + \tau e) - \xi(x - \tau e))e]\|_2 \leq \frac{d}{2\tau} \cdot 2\Delta \cdot \mathbb{E}[\|e\|_2] = \frac{d\Delta}{\tau}.$$

Рассмотрим детерминированную часть, представим симметричную разность в форме интеграла:

$$g^{\det} = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e = de \int_{-1}^1 \frac{1}{2} \langle \nabla f(x + t\tau e), e \rangle dt.$$

Перейдём к математическому ожиданию по равномерному e , воспользуемся тем, что $\mathbb{E}[ee^\top] = \frac{1}{d}I_d$:

$$\mathbb{E}[g^{\det}] = d\mathbb{E}\left[\frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right] = \mathbb{E}[\nabla f(x + t\tau e)].$$

Тогда имеем:

$$\begin{aligned} \|\mathbb{E}[g^{\det}] - \nabla f(x)\|_2 &= \|\mathbb{E}[\nabla f(x + t\tau e)] - \mathbb{E}[\nabla f(x)]\|_2 \\ &= \|\mathbb{E}[\nabla f(x + t\tau e) - \nabla f(x)]\|_2 \\ &\leq \mathbb{E}[\|\nabla f(x + t\tau e) - \nabla f(x)\|_2] \\ &\leq L\tau\|e\|_2 = L\tau. \end{aligned}$$

Воспользуемся неравенством треугольника:

$$\|\mathbb{E}[g(x, e)] - \nabla f(x)\|_2 \leq \|\mathbb{E}[g^{\det}] - \nabla f(x)\|_2 + \|\mathbb{E}[g^{\text{noise}}]\|_2 \leq L\tau + \frac{d\Delta}{\tau}.$$

2. Для шумовой составляющей имеем:

$$\mathbb{E}[\|g^{\text{noise}}\|_2^2] = \frac{d^2}{4\tau^2} \mathbb{E}[\|(\xi(x + \tau e) - \xi(x - \tau e))e\|_2^2] \leq \frac{d^2}{4\tau^2} \cdot 4\Delta^2 \cdot \mathbb{E}[\|e\|_2^2] = \frac{d^2\Delta^2}{\tau^2}.$$

Посмотрим на детерминированную часть, добавим умный ноль $\pm \langle \nabla f(x), e \rangle e$:

$$\mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] = d^2 \mathbb{E} \left[\left\| \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e + \langle \nabla f(x), e \rangle e - \langle \nabla f(x), e \rangle e \right\|_2^2 \right].$$

Воспользуемся тем, что $\|a + b\|_2^2 \leq 2\|a\|_2^2 + 2\|b\|_2^2$:

$$\begin{aligned} \mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] &\leq 2d^2 \mathbb{E} \left[|\langle \nabla f(x), e \rangle|^2 \right] \\ &\quad + \frac{d^2}{2\tau^2} \mathbb{E} \left[|f(x + \tau e) - f(x - \tau e) - \langle \nabla f(x), 2\tau e \rangle|^2 \right]. \end{aligned}$$

Воспользуемся изотропией равномерного направления на сфере и Теоремой Л2.4:

$$\mathbb{E} \left[\|g^{\text{det}}(x, e)\|_2^2 \right] \leq 2d \|\nabla f(x)\|_2^2 + 2L^2 d^2 \tau^2.$$

Получим итоговую оценку:

$$\begin{aligned} \mathbb{E} \left[\|g(x, e)\|_2^2 \right] &= \mathbb{E} \left[\|g^{\text{det}} + g^{\text{noise}}\|_2^2 \right] \leq 2\mathbb{E} \left[\|g^{\text{det}}\|_2^2 \right] + 2\mathbb{E} \left[\|g^{\text{noise}}\|_2^2 \right] \\ &\leq 4d \|\nabla f(x)\|_2^2 + 4L^2 d^2 \tau^2 + 2 \frac{d^2 \Delta^2}{\tau^2}. \end{aligned}$$

■

Используя двухточечную оценку градиента из Утверждения Л15.2, построим базовый стохастический метод нулевого порядка.

Алгоритм Л15.2 ZO-GD с двухточечной оценкой

Вход: стартовая точка $x^0 \in \mathbb{R}^d$, размеры шагов $\{\gamma_k\}_{k=0} > 0$, параметр сглаживания $\tau > 0$, количество итераций K

- 1: **for** $k = 0, 1, \dots, K - 1$ **do**
- 2: Сгенерировать независимо $e_k \sim U(S^{d-1})$
- 3: $g^k = d \frac{\hat{f}(x^k + \tau e_k) - \hat{f}(x^k - \tau e_k)}{2\tau} e_k$
- 4: $x^{k+1} = x^k - \gamma_k g^k$
- 5: **end for**

Выход: x^K

Утверждение Л15.2 даёт контролируемую оценку второго момента, в которой естественным образом появляются параметр сглаживания τ и уровень шумовой погрешности оракула Δ . Это позволяет сформулировать и проанализировать базовый алгоритм нулевого порядка.

Теорема Л15.2. Пусть задача безусловной оптимизации (Л15.1) с L -гладкой μ -сильно выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л15.2). Тогда при $\gamma_k = \gamma \leq \frac{1}{8dL}$ справедлива следующая оценка сходимости:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq \left(1 - \frac{\mu\gamma}{2}\right)^k \|x^0 - x^*\|_2^2 + \frac{4}{\mu} \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

Доказательство. Распишем итерацию:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.$$

Возьмем условное ожидание по случайности на шаге k :

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \langle \mathbb{E} [g^k \mid x^k], x^k - x^* \rangle \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right] \\ &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + 2\gamma \langle \nabla f(x^k) - \mathbb{E} [g^k \mid x^k], x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся неравенством Юнга:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &= \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma}{\mu} \left\| \mathbb{E} [g^k \mid x^k] - \nabla f(x^k) \right\|_2^2 + \frac{\mu\gamma}{2} \|x^k - x^*\|_2^2 \\ &\quad + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right]. \end{aligned}$$

Воспользуемся Утверждением Л15.2:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \left(1 + \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f(x^k), x^k - x^* \rangle \\ &\quad + \frac{2\gamma}{\mu} \left(L^2 \tau^2 + \frac{d^2 \Delta^2}{\tau^2} \right) \\ &\quad + \gamma^2 \left(4d \|\nabla f(x^k)\|_2^2 + 4L^2 d^2 \tau^2 + 2 \frac{d^2 \Delta^2}{\tau^2} \right). \end{aligned}$$

Воспользуемся μ -сильной выпуклостью и L -гладкостью:

$$\begin{aligned} \mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] &\leq \left(1 - \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 - 2\gamma (1 - 4d\gamma L) (f(x^k) - f^*) \\ &\quad + 2\gamma \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{d^2 \Delta^2}{\tau^2} \left(\gamma + \frac{1}{\mu} \right) \right). \end{aligned}$$

Выбирая $\gamma \leq \frac{1}{8dL}$, получаем:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \left(1 - \frac{\mu\gamma}{2} \right) \|x^k - x^*\|_2^2 + 2\gamma \left(2L^2 \tau^2 \left(\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

Возьмем полное математическое ожидание и раскроем рекурсию:

$$\mathbb{E} \left[\|x^k - x^*\|_2^2 \right] \leq \left(1 - \frac{\mu\gamma}{2} \right)^k \|x^0 - x^*\|_2^2 + \frac{4}{\mu} \left(L^2 \tau^2 \left(2\gamma d^2 + \frac{1}{\mu} \right) + \frac{2d^2 \Delta^2}{\mu \tau^2} \right).$$

■

Появление τ отражает баланс смещения/дисперсии: уменьшение τ снижает смещение, но повышает вариативность из-за деления на τ в двухточечной формуле. Наоборот, увеличение τ уменьшает дисперсию, но усиливает сглаживающее смещение. В отсутствие шума оптимальной оказывается $\tau = 0$, при наличии шума целесообразно фиксировать τ близкой к балансу $\tau^* \sim \sqrt{\Delta d/L}$.

Л15.2.2 Негладкий выпуклый случай

В отличие от рассмотренного ранее гладкого μ -сильно выпуклого случая, теперь мы не предполагаем L -Липшицевость, а работаем с M -Липшицевой выпуклой функцией:

$$|f(x) - f(y)| \leq M\|x - y\|_2.$$

Дополнительно мы полагаем отсутствие шума оракула значений, то есть $\Delta = 0$, чтобы не перегружать изложение сложными балансами смещения/дисперсии и сосредоточиться на ключевой идее сферического сглаживания и базовой конвергенции ZO-методов. Случай $\Delta > 0$ приводит лишь к стандартной шумовой добавке в итоговых оценках и разбирается аналогично. В этом разделе ключевым понятием является сферически сглаженная функция f_τ , которая позволит нам перенести технику анализа методов первого порядка в настройках нулевого порядка.

Определение Л15.1. Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ — выпуклая функция. Будем называть *сглаженной функцией* функцию

$$f_\tau(x) = \mathbb{E}_{e \sim U(S^{d-1})}[f(x + \tau e)].$$

Формально, Определение Л15.1 представляет собой сферическое усреднение значения f по равномерному направлению на сфере радиуса τ , в результате чего f_τ становится дифференцируемой, а её градиент естественным образом согласуется с двухточечной ZO-оценкой. Формальные свойства функции $f_\tau(x)$ изложены в следующем утверждении.

Утверждение Л15.3. Для M -Липшицевой выпуклой функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$ выполняется:

1. f_τ дифференцируема и

$$\nabla f_\tau(x) = \mathbb{E}_{e \sim U(S^{d-1})} \left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e \right];$$

2. f_τ выпукла и

$$0 \leq f_\tau(x) - f(x) \leq \tau M;$$

3. Градиент $f_\tau(x)$ ограничен:

$$\|\nabla f_\tau(x)\|_2 \leq dM.$$

Доказательство.

1. Рассмотрим приращение:

$$f_\tau(x + th) - f_\tau(x) = \mathbb{E}_e [f(x + th + \tau e) - f(x + \tau e)].$$

Поделим на t и рассмотрим предел:

$$\lim_{t \rightarrow 0} \frac{f_\tau(x + th) - f_\tau(x)}{t} = \mathbb{E} \left[\lim_{t \rightarrow 0} \frac{f(x + th + \tau e) - f(x + \tau e)}{t} \right] = \langle \mathbb{E} [\nabla f(x + \tau e)], h \rangle.$$

Заметим, что для любого $t \in [-1, 1]$:

$$\mathbb{E}[\nabla f(x + \tau e)] = \mathbb{E}[\nabla f(x + t\tau e)].$$

А в Теореме Л15.2 мы получили, что

$$\mathbb{E}[\nabla f(x + t\tau e)] = \mathbb{E}\left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right].$$

Таким образом получили требуемое.

2. Выпуклость f_τ следует из выпуклости f . Для доказательства второго факта воспользуемся выпуклостью f :

$$f(x) \leq f(x + \tau e) + \langle \nabla f(x), x - (x + \tau e) \rangle = f(x + \tau e) - \tau \langle \nabla f(x), e \rangle.$$

Возьмем математическое ожидание и используем симметрию распределения:

$$f(x) \leq \mathbb{E}[f(x + \tau e)] = f_\tau(x),$$

то есть $f_\tau(x) - f(x) \geq 0$. Для верхней оценки используем M -Липшицевость f :

$$f(x + \tau e) - f(x) \leq M \|\tau e\|_2 = M\tau.$$

Усредняя по e , получим $f_\tau(x) - f(x) \leq \tau M$.

3. Из первого пункта имеем

$$\nabla f_\tau(x) = \mathbb{E}\left[d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e\right].$$

Воспользуемся M -Липшицевостью f :

$$\begin{aligned} \|\nabla f_\tau(x)\|_2 &\leq \mathbb{E}\left[d \frac{|f(x + \tau e) - f(x - \tau e)|}{2\tau} \|e\|_2\right] \\ &\leq \mathbb{E}\left[d \frac{M\|(x + \tau e) - (x - \tau e)\|_2}{2\tau}\right] = dM. \end{aligned}$$

■

Утверждение Л15.3 формализует, что сферическое сглаживание делает целевую функцию «хорошей» в аналитическом и алгоритмическом смысле даже тогда, когда исходная f может быть негладкой.

Утверждение Л15.4. Пусть дана M -Липшицева функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Определим оценку градиента

$$g(x, e) = d \frac{f(x + \tau e) - f(x - \tau e)}{2\tau} e, \quad e \sim U(S^{d-1}).$$

Тогда для любого $x \in \mathbb{R}^d$ справедливо:

1. $\mathbb{E}_{e \sim U(S^{d-1})}[g(x, e)] = \nabla f_\tau(x)$,
2. $\mathbb{E}_{e \sim U(S^{d-1})}\|g(x, e)\|_2^2 \leq d^2 M^2$.

Доказательство.

1. Следует из первого пункта Утверждения Л15.3.
2. Воспользуемся M -Липшицевостью:

$$\mathbb{E} \left[\|g(x, e)\|_2^2 \right] = \frac{d^2}{4\tau^2} \mathbb{E} \left[|f(x + \tau e) - f(x - \tau e)|^2 \right] \leq d^2 M^2.$$

■

Покажем сходимость Алгоритма Л15.2 для выпуклой негладкой f .

Теорема Л15.3. Пусть задача безусловной оптимизации (Л15.1) с M -Липшицевой выпуклой целевой функцией f решается с помощью градиентного спуска нулевого порядка (Алгоритм Л15.2). Тогда при

$$\gamma_k = \gamma \leq \frac{\|x^0 - x^*\|_2}{dM\sqrt{K}}$$

справедлива следующая оценка сходимости:

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}} + \tau M.$$

В частности, при выборе

$$\tau \leq \frac{d\|x^0 - x^*\|_2}{\sqrt{K}}$$

имеем

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f^* \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Доказательство. Распишем итерацию:

$$\|x^{k+1} - x^*\|_2^2 = \|x^k - x^*\|_2^2 - 2\gamma \langle g^k, x^k - x^* \rangle + \gamma^2 \|g^k\|_2^2.$$

Возьмем условное математическое ожидание:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] = \|x^k - x^*\|_2^2 - 2\gamma \langle \nabla f_\tau(x^k), x^k - x^* \rangle + \gamma^2 \mathbb{E} \left[\|g^k\|_2^2 \mid x^k \right].$$

Запишем выпуклость f_τ :

$$\langle \nabla f_\tau(x^k), x^k - x^* \rangle \geq f_\tau(x^k) - f_\tau(x^*)$$

и, используя результат Утверждения Л15.4, получим:

$$\mathbb{E} \left[\|x^{k+1} - x^*\|_2^2 \mid x^k \right] \leq \|x^k - x^*\|_2^2 - 2\gamma (f_\tau(x^k) - f_\tau(x^*)) + \gamma^2 d^2 M^2.$$

Перейдем к полному математическому ожиданию и раскроем рекурсию:

$$\mathbb{E} \left[\|x^K - x^*\|_2^2 \right] \leq \|x^0 - x^*\|_2^2 - 2\gamma \sum_{k=0}^{K-1} \mathbb{E} \left[f_\tau(x^k) - f_\tau(x^*) \right] + K\gamma^2 d^2 M^2.$$

Отбросим неотрицательный левый член и поделим на $2\gamma K$:

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} [f_\tau(x^k) - f_\tau(x^*)] \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma d^2 M^2}{2}.$$

Воспользуемся выпуклостью f_τ :

$$\mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] \leq \frac{\|x^0 - x^*\|_2^2}{2\gamma K} + \frac{\gamma d^2 M^2}{2}.$$

Минимизируя правую часть по γ , получаем, что

$$\gamma = \frac{\|x^0 - x^*\|_2}{dM\sqrt{K}}.$$

Тогда

$$\mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] \leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

Пользуясь тем, что $0 \leq f_\tau(x) - f(x) \leq \tau M$,

$$\begin{aligned} \mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f(x^*) \right] &\leq \mathbb{E} \left[f_\tau \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f_\tau(x^*) \right] + \tau M \\ &\leq \frac{dM\|x^0 - x^*\|_2}{\sqrt{K}} + \tau M. \end{aligned}$$

При выборе $\tau \leq \frac{d\|x^0 - x^*\|_2}{\sqrt{K}}$ получаем

$$\mathbb{E} \left[f \left(\frac{1}{K} \sum_{k=0}^{K-1} x^k \right) - f(x^*) \right] \leq \frac{2dM\|x^0 - x^*\|_2}{\sqrt{K}}.$$

■

Л15.2.3 Ключевые работы

Методы оптимизации нулевого порядка для дообучения больших языковых моделей представляют собой активно развивающуюся область исследований. Ниже представлены ключевые работы, которые расширяют и углубляют понимание данного направления.

- MeZO (Memory-efficient Zeroth-Order) представляет собой основополагающую работу в области применения методов нулевого порядка для дообучения LLM. Авторы адаптируют классический ZO-SGD для работы in-place, обеспечивая дообучение моделей с тем же объемом памяти, что и инференс, достигая при этом производительности, сопоставимой с методами первого порядка при снижении потребления памяти до 12 раз.
- LeZO (Layer-wise Zeroth-Order) вводит послынную разреженную вычислительную стратегию для ZO-оптимизации, обрабатывая слои как фундаментальные единицы разреживания. Метод динамически возмущает различные подмножества параметров на каждом шаге, достигая ускорения более чем в 3 раза по сравнению с MeZO на задачах классификации без дополнительных накладных расходов на память.

- ZO-AdaMU предлагает оригинальное решение проблем осцилляций и вычислительных издержек в MeZO путем адаптации возмущений с моментумом в стохастической аппроксимации градиента. В отличие от существующих адаптивных методов моментума, алгоритм перемещает моментум на симулируемое возмущение в стохастической аппроксимации градиента, что теоретически и эмпирически доказано как более эффективный способ улучшения стабильности и скорости сходимости в ZO-SGD для дообучения LLM.
- HiZOO (Hessian-informed Zeroth-Order Optimizer) впервые интегрирует информацию о диагональном гессиане в оптимизацию нулевого порядка для дообучения LLM. Данный подход решает проблему гетерогенных кривизн в различных размерностях параметров, обеспечивая существенное ускорение сходимости при сохранении преимуществ в потреблении памяти.
- LOZO (Low-rank Zeroth-Order) предлагает новый подход к оценке градиентов нулевого порядка через использование низкоранговых структур. Метод эффективно захватывает низкоранговую структуру градиентов, характерную для дообучения LLM, что позволяет значительно улучшить сходимость по сравнению с существующими ZO-методами, приближаясь к производительности алгоритмов первого порядка.
- MeZO-SVRG интегрирует техники редукции дисперсии в ZO-оптимизацию для повышения стабильности и скорости сходимости при дообучении на основе инференса. Метод превосходит MeZO на 20% по точности тестирования при двукратном снижении времени GPU-часов, существенно уменьшая требования к памяти по сравнению со стохастическим градиентным спуском первого порядка.
- JAGUAR SignSGD / Muon представляют первые методы ZO-оптимизации с гарантиями сходимости для алгоритмов SignSGD и Muon в стохастическом невыпуклом случае. Подходы используют JAGUAR-аппроксимацию градиента и координатный моментум, требуя лишь $\mathcal{O}(1)$ вычислений оракула за итерацию и демонстрируя конкурентную производительность с методами первого порядка при значительной экономии памяти.

Л16 Метод эллипсоидов

Будем рассматривать задачу минимизации

$$\min_{x \in \mathcal{X}} f(x), \quad (\text{Л16.1})$$

где f — выпуклая функция, заданная на выпуклом ограниченном замкнутом множестве $\mathcal{X}$ с непустой внутренностью. Наша цель — обобщить метод дихотомии (Алгоритм Л3.3) на случай многих переменных. В одномерном случае мы легко строили вложенные отрезки, содержащие решение и стремящиеся к нулю по мере. На каждой итерации новая точка выбиралась как середина отрезка. В случае многих переменных мы сталкиваемся с рядом вопросов: как строить такие вложенные множества, как искать их центр и так далее. В следующем разделе наивно обобщим одномерный поиск.

Л16.1 Наивный подход

Выберем $a \in \text{int } \mathcal{X}$. Пользуясь выпуклостью целевой функции запишем

$$f(x) - f(a) \geq \langle g, x - a \rangle,$$

где $g \in \partial f(a)$. Предположим $0 \notin \partial f(a)$, поскольку это означало бы, что задача решена. Имея некоторую внутреннюю точку a , можно утверждать, что множество точек минимума X^* содержится в множестве $\mathcal{X}_a = \{x \in \mathcal{X} \mid \langle g, x - a \rangle \leq 0\}$. Это очевидно, потому что иначе получили бы $f(x) > f(a)$. Нетрудно видеть, что $\mathcal{X}_a$ также выпуклое ограниченное замкнутое множество с непустой внутренностью, которое при этом меньше, чем $\mathcal{X}$. Теперь мы можем выбрать новую точку a уже внутри нового множества и повторить процедуру. Таким образом, можем построить итеративный алгоритм поиска сужающихся множеств, приближающих нас к решению задачи. Возникает закономерный вопрос — как имея множество $\mathcal{X}_k$ выбрать в нем точку x^{k+1} . Наиболее очевидное решение — выбрать центр масс $\mathcal{X}_k$. Используя такой подход, удается построить такую последовательность $\{\mathcal{X}_k\}_{k=1}^\infty$, что

$$\mu(\mathcal{X}_k) \leq \left(1 - \left(\frac{d}{d+1}\right)^d\right)^k \mu(\mathcal{X}_0).$$

Заметим, что скорость сходимости метода зависит только от размерности задачи — вид целевой функции не оказывает на нее влияние. Казалось бы, теперь у нас есть наиболее общий метод решения задач выпуклой минимизации и на этом можно заканчивать. Однако существенно слабое место — необходимость на каждом шаге находить центр тяжести предыдущего локализатора X^* , что, вообще говоря, нетривиальная задача. Таким образом, метод центров масс на практике бесполезен. Попробуем пожертвовать скоростью сходимости ради простоты вычисления новой точки x^{k+1} .

Л16.2 Приближение метода центров масс

Идея, которой мы будем пользоваться, заключается в том, чтобы строить локализаторы, удобные для нахождения центров масс. Конкретно — будем строить $\{\mathcal{X}_k\}_{k=1}^\infty$ как последовательность эллипсоидов. Понятно, что, имея на некотором шаге эллипсоид $\mathcal{X}_k$, мы построим следующий локализатор как пересечение $\mathcal{X}_k$ с некоторым полупространством, что не является эллипсоидом. В качестве $\mathcal{X}_{k+1}$ будем выбирать эллипсоид наименьшего объема, содержащий указанное множество. Таким образом, мы жертвуем скоростью сокращения меры множеств ради удобства нахождения их геометрического центра.

Замечание Л16.1. Поскольку мы погружаем $\mathcal{X}$ в эллипсоид, то возможна ситуация $x^{k+1} \notin \mathcal{X}$. Это не является проблемой для метода, который мы строим, если нам доступен разделяющий оракул. Пользуясь им, возьмём e такой, что для любого $x \in \mathcal{X}$

$$\langle e, x - x^{k+1} \rangle \leq 0.$$

Тогда рассмотрим $\{x \in \mathcal{X}_k \mid \langle e, x - x^{k+1} \rangle \leq 0\}$ и будем строить наименьший эллипсоид, содержащий это множество.

Теперь, когда сформирована интуиция метода, перейдем к формальному описанию. Для начала надо понять, как задавать эллипсоид. Наиболее подходящее для наших целей представление — образ единичного шара под действием аффинного преобразования:

$$E(A, b) = \{Au + b \mid \|u\|_2 \leq 1\}.$$

Пользуясь известными из курса математического анализа формулами преобразования меры под действием аффинного преобразования, получим

$$\mu(E(A, b)) = |\det A| \cdot \mu(B_{\|\cdot\|_2}(0, 1)).$$

Пользуясь отделяющим оракулом, построим

$$E^+ = \{x \in E \mid \langle e, x - b \rangle \leq 0\}.$$

Выполним несложные преобразования:

$$\langle e, x - b \rangle = \langle e, Au \rangle = \langle A^\top e, u \rangle.$$

Таким образом, E^+ является аффинным образом «куска» единичного шара

$$V^+ = \left\{ u \in B_{\|\cdot\|_2}(0, 1) \mid \langle A^\top e, u \rangle \leq 0 \right\} = \left\{ u \in B_{\|\cdot\|_2}(0, 1) \mid \langle p, u \rangle \leq 0 \right\},$$

где $p = \frac{A^\top e}{\|A^\top e\|_2}$. Довольно очевидно, что достаточно покрыть V^+ некоторым эллипсоидом, и затем взять его аффинный образ. V^+ может быть покрыт следующим эллипсоидом:

$$\tilde{V} = \left\{ x \mid \left\langle x + \frac{p}{d+1}, (\alpha(d)I_d - \gamma(d)pp^\top)^{-2} \left(x + \frac{p}{d+1} \right) \right\rangle \leq 1 \right\},$$

где $\alpha(d) = \left(\frac{d^2}{d^2-1} \right)^{1/4}$, $\gamma(d) = \alpha(d)\sqrt{\frac{d-1}{d+1}}$. Рассматривая аффинный образ этого эллипсоида, получим, что E^+ покрывается эллипсоидом $E(\tilde{A}, \tilde{b})$, где

$$\begin{aligned} \tilde{A} &= \alpha(d)A - \gamma(d)App^\top, \\ \tilde{b} &= b - \frac{1}{d+1}Ap. \end{aligned}$$

При этом мера $E(\tilde{A}, \tilde{b})$ оценивается сверху мерой $E(A, b)$ с фактором

$$\frac{d^2}{d^2-1} \sqrt{\frac{d-1}{d+1}} \leq \exp\left(-\frac{1}{2(d-1)}\right) \approx 1 - \frac{1}{2d}.$$

Таким образом мера нового эллипсоида меньше меры предыдущего, хотя убывание и не такое сильное, как было в методе центров масс. Наконец, мы готовы формально выписать алгоритм.

Алгоритм Л16.1 Метод эллипсоидов

Вход: начальная точка $x^0 \in \mathcal{X}$, начальная матрица эллипсоида A_0 , $\alpha(d) = \left(\frac{d^2}{d^2-1}\right)^{1/4}$,

$\gamma(d) = \alpha(d) \sqrt{\frac{d-1}{d+1}}$

```

1: for  $k = 0, \dots, K-1$  do
2:   if  $x^k \in \mathcal{X}$  then
3:      $e^k = g^k \in \partial f(x^k)$ 
4:   else
5:     Вычислить  $e^k$  такое, что для любого  $x \in \mathcal{X}$ :  $\langle e^k, x - x^k \rangle \leq 0$ 
6:   end if
7:    $p^k = \frac{A_k^\top e^k}{\|A_k^\top e^k\|_2}$ 
8:    $A_{k+1} = \alpha(d)A_k - \gamma(d)A_k p^k (p^k)^\top$ 
9:    $x^{k+1} = x^k - \frac{1}{d+1}A_k p^k$ 
10: end for
Выход:  $x^K$ 

```

Теорема Л16.1. Пусть задача оптимизации на выпуклом замкнутом множестве (Л16.1) с выпуклой целевой функцией f решается с помощью метода эллипсоидов (Алгоритм Л16.1). Тогда для достижения точности

$$f(x^K) - \min_{x \in \mathcal{X}} f(x) \leq \varepsilon \left[\max_{x \in \mathcal{X}} f(x) - \min_{x \in \mathcal{X}} f(x) \right]$$

необходимо

$$K = \mathcal{O}\left(d(d-1) \log \frac{\nu}{\varepsilon}\right) \text{ итераций.}$$

где

$$\nu = \left(\frac{\mu(E(A_0, x^0))}{\mu(\mathcal{X})} \right)^{\frac{1}{d}}.$$

Доказательство. Зафиксируем $\varepsilon' \in (\varepsilon, 1)$. Тогда интересующее нас множество $\mathcal{X}^*$ устроено следующим образом:

$$\mathcal{X}^* = x^* + \varepsilon'(\mathcal{X} - x^*).$$

Очевидным образом, имеем:

$$\mu(\mathcal{X}^*) = (\varepsilon')^d \mu(\mathcal{X}) > \varepsilon^d \mu(\mathcal{X}).$$

Пользуясь доказанным выше, имеем:

$$\begin{aligned}
\mu(E(A_K, x^K)) &\leq \exp\left(-\frac{K}{2(d-1)}\right) \mu(E(A_0, x^0)) \\
&\leq \nu^{-d} \varepsilon^d \mu(E(A_0, x^0)) \\
&\leq \frac{\mu(\mathcal{X})}{\mu(E(A_0, x^0))} \varepsilon^d \mu(E(A_0, x^0)) \\
&= \varepsilon^d \mu(\mathcal{X}) < \mu(\mathcal{X}^*).
\end{aligned}$$

Таким образом

$$\mathcal{X}^* \setminus E(A_K, x^K) \neq \emptyset.$$

Выберем $y \in \mathcal{X}^* \setminus E(A_K, x^K)$. Получаем, что $y = (1 - \varepsilon')x^* + \varepsilon'z$ для какого-то $z \in \mathcal{X}$. Заметим также, что $y \in E(A_0, x^0)$, но $y \notin E(A_K, x^K)$. Это означает существование такого k , что $y \in E(A_{k-1}, x^{k-1})$, но $y \notin E(A_k, x^k)$. Из нашей стратегии обновления эллипсоидов получаем, что для данного k выполняется: $\langle y - x_k, e_k \rangle > 0$. Заметим, что это неравенство означает $x^k \in \mathcal{X}$. Таким образом, $e^k = g^k \in \partial f(x^k)$. Пользуясь выражением для y и выпуклостью f , запишем:

$$f(y) \leq (1 - \varepsilon')f(x^*) + \varepsilon'f(z).$$

Это означает, что:

$$f(y) - \min_{x \in \mathcal{X}} f(x) \leq \varepsilon'(f(z) - f(x^*)) \leq \varepsilon' \left[\max_{x \in \mathcal{X}} f(x) - \min_{x \in \mathcal{X}} f(x) \right].$$

Пользуясь тем фактом, что $f(x^K) \leq f(y)$, получаем утверждение теоремы. ■

Замечание Л16.2. Дополнительно предположим, что целевая функция M -липшицева на $\mathcal{X}$ и при этом существуют $\rho > 0$ и $x^0 \in \mathcal{X}$ такие, что $B_{\|\cdot\|_2}(x_0, \rho) \subseteq \mathcal{X}$. Тогда для сходимости к ε -точности требуется

$$N = \mathcal{O}\left((d+1)^2 \log \frac{MR^2}{\rho\varepsilon}\right).$$

Список литературы

- [1] Necdet Serhat Aybat, Alireza Fallah, Mert Gurbuzbalaban, and Asuman Ozdaglar. A universally optimal multistage accelerated stochastic gradient method, 2019.
- [2] Francis Bach and Eric Moulines. Non-asymptotic analysis of stochastic approximation algorithms for machine learning. In *Advances in Neural Information Processing Systems*, volume 24, pages 451–459, December 2011.
- [3] Aleksandr Beznosikov, Valentin Samokhin, and Alexander Gasnikov. Distributed saddle point problems: lower bounds, near-optimal and robust algorithms*. *Optimization Methods and Software*, page 1–18, March 2025.
- [4] Christopher M. Bishop. *Neural Networks for Pattern Recognition*. Oxford University Press, 1995.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning (Information Science and Statistics)*. Springer, 1 edition, 2007.

- [6] Stephen Boyd and Lieven Vandenbergh. *Convex Optimization*. Cambridge University Press, Cambridge, 2004.
- [7] Gábor Braun, Alejandro Carderera, Cyrille W Combettes, Hamed Hassani, Amin Karbasi, Aryan Mokhtari, and Sebastian Pokutta. Conditional gradient methods. *arXiv preprint arXiv:2211.14103*, 2022.
- [8] A. Cauchy. Méthode générale pour la résolution des systèmes d’équations simultanées. *Comptes rendus hebdomadaires des séances de l’Académie des sciences*, 55:536–538, 1847.
- [9] Yudong Chen. Lecture 9–10: Accelerated gradient descent, 2023. UW-Madison CS/ISyE/Math/Stat 726 Spring 2023 Lecture Notes.
- [10] Nikita Doikov, Konstantin Mishchenko, and Yurii Nesterov. Super-universal regularized newton method. 2022.
- [11] Nikita Doikov and Yurii Nesterov. Gradient regularization of newton method with bregman distances. 2021.
- [12] Timothy Dozat. Incorporating nesterov momentum into adam. ICLR Workshop, 2016. OpenReview; NAdam method.
- [13] John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12:2121–2159, 2011.
- [14] Marguerite Frank and Philip Wolfe. An algorithm for quadratic programming. *Naval Research Logistics Quarterly*, 3(1–2):95–110, 1956.
- [15] Martin Jaggi. Revisiting frank-wolfe: Projection-free sparse convex optimization. volume 28, 01 2013.
- [16] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.
- [17] Guanghui Lan. The complexity of large-scale convex programming under a linear optimization oracle. 09 2013.
- [18] Lihua Lei, Cheng Ju, Jianbo Chen, and Michael I Jordan. Non-convex finite-sum optimization via scsg methods. *Advances in neural information processing systems*, 30, 2017.
- [19] Laurent Lessard, Benjamin Recht, and Andrew Packard. Analysis and design of optimization algorithms via integral quadratic constraints. *SIAM Journal on Optimization*, 26(1):57–95, January 2016.
- [20] Zhize Li, Hongyan Bao, Xiangliang Zhang, and Peter Richtárik. Page: A simple and optimal probabilistic gradient estimator for nonconvex optimization. In *International conference on machine learning*, pages 6286–6295. PMLR, 2021.
- [21] Hongzhou Lin, Julien Mairal, and Zaid Harchaoui. A universal catalyst for first-order optimization, 2015.
- [22] Dong C. Liu and Jorge Nocedal. On the limited memory bfgs method for large scale optimization. *Mathematical Programming, Series B*, 45(3):503–528, 1989.

- [23] Jun Liu. A concise lyapunov analysis of nesterov’s accelerated gradient method, 2025.
- [24] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019.
- [25] Harry Markowitz. Portfolio selection. *The Journal of Finance*, 7(1):77–91, 1952.
- [26] James Martens. New insights and perspectives on the natural gradient method. 2020.
- [27] A.S. Nemirovskii and D.B. Iudin. *Problem Complexity and Method Efficiency in Optimization*. A Wiley-Interscience publication. Wiley, 1983.
- [28] Y. Nesterov. A method for solving the convex programming problem with convergence rate $o(1/k^2)$, 1983.
- [29] Yurii Nesterov and B. T. Polyak. Cubic regularization of newton method and its global performance. *Mathematical Programming*, 108(1):177–205, 2006.
- [30] Isaac Newton. *De analysi per aequationes numero terminorum infinitas*. 1669. Unpublished manuscript; first printed edition in 1711.
- [31] J. Nocedal and S. Wright. *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. Springer New York, 2006.
- [32] B.T. Poliak. *Введение в оптимизацию*. "Наука, "Глав. ред. физико-математической литры, 1983.
- [33] B.T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964.
- [34] C. Radhakrishna Rao. *Linear Statistical Inference and its Applications*. Wiley, 1973.
- [35] Anton Rodomanov and Yurii Nesterov. New results on superlinear convergence of classical quasi-newton methods. *Journal of Optimization Theory and Applications*, 188(3):744–769, 2021.
- [36] Nicol N. Schraudolph. Fast curvature matrix-vector products for second-order gradient descent. 14(7):1723–1738, 2002.
- [37] Jack Sherman and Winifred J. Morrison. Adjustment of an inverse matrix corresponding to changes in the elements of a given column or a given row of the original matrix. *Annals of Mathematical Statistics*, 1949. Abstract.
- [38] Sebastian U. Stich. Unified optimal analysis of the (stochastic) gradient method, 2019.
- [39] Tijmen Tieleman and Geoffrey Hinton. Lecture 6.5 – rmsprop: Divide the gradient by a running average of its recent magnitude. COURSERA: Neural Networks for Machine Learning, 2012.
- [40] Rachel Ward, Xiaoxia Wu, and Léon Bottou. Adagrad stepsizes: Sharp convergence over nonconvex landscapes. *Journal of Machine Learning Research*, 21(1):1–30, 2020.
- [41] Г. Е. Иванов. *Лекции по математическому анализу. Часть 1*. МФТИ, Москва, 2011.
- [42] Г. Е. Иванов. *Лекции по математическому анализу. Часть 2*. МФТИ, Москва, 2016.

- [43] Леонид Витальевич Канторович. Математические методы организации и планирования производства. 1939.
- [44] Ю. Е. Нестеров. *Методы выпуклой оптимизации*. Изд-во МЦНМО, Москва, 2010.
- [45] Евгений Сергеевич Половинкин and Максим Викторович Балашов. Элементы выпуклого и сильно выпуклого анализа. 2007.
- [46] Р Рокафеллар. *Выпуклый Анализ*. Мир, 1973.
- [47] Е. Е. Тыртышников. Методы численного анализа. 2006.
- [48] Е. Е. Тыртышников. Матричный анализ и линейная алгебра. 2007.
- [49] Альберт Николаевич Ширяев. *Вероятность – 1: Элементарная теория вероятностей. Математические основания. Предельные теоремы*. Московский центр непрерывного математического образования, Москва, 3-е, перераб. и доп. edition, 2004.